データ解析の数学

主成分分析・カーネル法・ニューラルネットワークの理論

2026 年度 鹿児島大学集中講義

井元佑介（京都大学）

はじめに

本書は鹿児島大学における集中講義「データ解析の数学」（90 分 × 8 コマ）の講義ノートである。

対象は線形代数を履修した学生であり、統計学・関数解析・最適化理論の予備知識は仮定しない。主成分分析から出発し、高次元データに固有の現象、再生核ヒルベルト空間の理論、サポートベクターマシン、そしてニューラルネットワークの万能近似定理まで、線形代数という一つの出発点から到達できる範囲を、証明を省かずにたどることを目指した。

本書の方針は次の三点である。

第一に、**手法の羅列ではなく統一的な視点を与える**。第1章で述べるように、本書で扱う手法の大半は Rayleigh 商の最大化（一般化固有値問題）か、正則化つき経験リスク最小化のいずれかの形に書ける。この二つの枠組みを軸に据えることで、主成分分析・正準相関分析・判別分析・スペクトラルクラスタリングが同じ問題の変奏であり、リッジ回帰・サポートベクターマシン・カーネル法・ニューラルネットワークもまた同じ問題の変奏であることが見えてくる。

第二に、**証明を書く**。「明らかである」で済ませず、なぜその主張が成り立つのかを追えるようにした。測度論を要する箇所など、完全な証明が本書の水準を超える場合には、証明の骨格を示したうえで何を認めて使っているかを明示した。

第三に、**計算と結びつける**。数式がそのままでは計算できない、あるいは計算すべきでない場面は多い。$\boldsymbol{X}^\top \boldsymbol{X}$ を作ってはいけない理由、$O(n^3)$ の Gram 行列をどう回避するか、といった実際的な問題を各所で扱った。Python による実装例を随所に置き、数式と実装の対応を確認できるようにした。

各章末に演習問題を配した。数学的な問題と実装問題を混ぜてあり、難易度を $(\star)$ 基本、$(\star\star)$ 標準、$(\star\star\star)$ 発展で示した。解答は別冊「演習問題解答」にまとめてある。手を動かさずに読み流しても身につかないので、少なくとも $(\star)$ の問題はすべて解いてほしい。

図版はすべて実際の数値計算に基づいて生成した。再現用のコードは各図の説明に対応する本文の記述から復元できる。

本書の執筆にあたっては、Anthropic の Claude Science にサポートしていただいた。原稿の構成、証明の検討、図版の生成、本文中の数値の検証、および演習問題とその解答の作成において広範囲にわたる支援を受けた。記載した数値はすべて実際に計算を実行して確認したものであるが、最終的な内容と誤りの責任は著者にある。

2026 年

目次

はじめに ii

第 1 章 序論：データ解析を数学で考える 1
1.1 なぜ「データ解析の数学」なのか . . . 1
1.2 データ解析の数学的定式化 . . . 2
1.3 線形から非線形へ：三つの戦略 . . . 3
1.4 本講義の構成と 8 コマの対応 . . . 4
1.5 前提知識と記法 . . . 4
1.6 計算環境 . . . 5
演習問題 . . . 6

第 2 章 線形代数とデータ行列 7
2.1 データ行列の二つの見方 . . . 7
2.2 ユークリッド空間の幾何 . . . 8
2.3 正規直交系 . . . 9
2.4 直交射影 . . . 11
2.5 スペクトル定理と Rayleigh 商 . . . 12
2.6 特異値分解 . . . 14
2.7 Eckart–Young–Mirsky の定理 . . . 17
2.8 擬似逆行列と最小二乗 . . . 18
2.9 行列の微分とラグランジュ未定乗数法 . . . 19
演習問題 . . . 20

第 3 章 主成分分析の理論 22
3.1 なぜ次元を減らすのか . . . 22
3.2 記法の確認と三つの定式化 . . . 22
3.3 三つの定式化の同値性 . . . 23
3.4 主成分の逐次的導出 . . . 25
3.5 主成分スコアと負荷量 . . . 26
3.6 寄与率と次元の選択 . . . 27
3.7 三次元点群で見る PCA . . . 28
3.8 中心化とスケーリング . . . 29
3.9 白色化 . . . 31
3.10 確率的 PCA . . . 32

3.11 PCA の幾何と限界 . . . 35
3.12 数式と実装の対応 . . . 35
演習問題 . . . 36

第 4 章 主成分分析の計算技法と拡張 38
4.1 計算量の整理：n と d のどちらが大きいか . . . 38
4.2 双対 PCA：$n \ll d$ のとき . . . 38
4.3 反復法：上位数本だけが欲しいとき . . . 41
4.4 ランダム化 SVD . . . 42
4.5 オンライン PCA と増分 PCA . . . 43
4.6 欠測値のある PCA . . . 45
4.7 ロバスト PCA：外れ値への対処 . . . 46
4.8 スパース PCA：解釈できる主成分 . . . 47
4.9 数値計算上の落とし穴 . . . 49
演習問題 . . . 50

第 5 章 高次元データの数理 52
5.1 なぜ高次元を別扱いするのか . . . 52
5.2 次元の呪い：体積はどこへ行ったか . . . 52
5.3 測度の集中 . . . 53
5.4 Johnson–Lindenstrauss の補題 . . . 55
5.5 ランダム行列理論と Marchenko–Pastur 則 . . . 57
5.6 スパイクモデルと BBP 相転移 . . . 58
5.7 共分散行列の推定と縮小 . . . 60
5.8 摂動論：固有値と固有ベクトルの安定性 . . . 62
5.9 高次元の良い面 . . . 63
演習問題 . . . 63

第 6 章 一般化固有値問題と線形手法の広がり 65
6.1 一般化固有値問題 . . . 65
6.2 正準相関分析 . . . 67
6.3 フィッシャー判別分析 . . . 69
6.4 多次元尺度構成法 . . . 70
6.5 スペクトラルクラスタリング . . . 77
6.6 まとめ：五つの手法は一つの型である . . . 80
演習問題 . . . 81

第 7 章 関数解析の基礎と再生核ヒルベルト空間 83
7.1 なぜ関数解析が要るのか . . . 83
7.2 距離空間と完備性 . . . 85
7.3 ノルム空間・内積空間・Hilbert 空間 . . . 86
7.4 Hilbert 空間の幾何 . . . 87
7.5 有界作用素とコンパクト作用素 . . . 89
7.6 正定値カーネル . . . 90

7.7 再生核ヒルベルト空間 . . . 93
7.8 特徴写像 . . . 95
7.9 Mercer の定理 . . . 97
7.10 四つの見方の整理 . . . 99
演習問題 . . . 99

第 8 章 カーネル PCA と表現定理 101
8.1 カーネルトリック：双対 PCA からの非線形化 . . . 101
8.2 中心化 Gram 行列 . . . 102
8.3 カーネル PCA . . . 103
8.4 無限次元から有限次元へ . . . 106
8.5 表現定理 . . . 106
8.6 カーネルリッジ回帰 . . . 107
8.7 カーネル CCA . . . 110
8.8 カーネル平均埋め込みと MMD . . . 111
8.9 カーネルの選択と設計 . . . 112
8.10 大規模化：$O(n^3)$ の壁を破る . . . 112
演習問題 . . . 114

第 9 章 サポートベクターマシンと凸最適化 119
9.1 分類問題とマージンという規準 . . . 119
9.2 幾何的準備：超平面と点の距離 . . . 120
9.3 ハードマージン SVM の主問題 . . . 121
9.4 凸最適化の道具立て . . . 121
9.5 SVM の双対問題と支持ベクトル . . . 123
9.6 ソフトマージン SVM . . . 125
9.7 正則化リスク最小化としての SVM . . . 127
9.8 カーネル SVM . . . 128
9.9 最適化アルゴリズム . . . 129
9.10 マージンによる汎化誤差の評価 . . . 130
9.11 回帰と一クラスへの拡張 . . . 131
9.12 まとめ . . . 132
演習問題 . . . 132

第 10 章 ニューラルネットワークと万能近似定理 134
10.1 学習される特徴——第三の非線形化戦略 . . . 134
10.2 モデルの定義 . . . 134
10.3 表現力の問い：XOR から万能性へ . . . 136
10.4 万能近似定理 . . . 137
10.5 ReLU 網の近似理論 . . . 143
10.6 深さの効果 . . . 143
10.7 Barron クラス——次元の呪いを回避する . . . 145
10.8 学習：誤差逆伝播法 . . . 147
10.9 非凸性——SVM との対比 . . . 149

演習問題 150

第 11 章 発展的話題 152
11.1 ランダム特徴とニューラルタンジェントカーネル 152
11.2 過剰パラメータ化と二重降下 155
11.3 多様体学習 156
11.4 行列補完と核ノルム 159
11.5 最適輸送と Wasserstein 距離 161
11.6 単一細胞データ解析への応用：RECODE と scEGOT 166
11.7 講義のまとめと読書案内 169
演習問題 169

参考文献 171

第 1 章

序論：データ解析を数学で考える

この章のねらい

この講義の目的は、データ解析の手法を「使い方」ではなく「なぜそう作られているか」から理解することである。出発点は線形代数だけでよい。そこから、高次元データに固有の現象、無限次元の関数空間、そして非線形な表現力の理論までを一本の道筋でたどる。この章では全体の地図を描き、以降の章で繰り返し現れる記法と約束を定める。

1.1　なぜ「データ解析の数学」なのか

データ解析の手法はライブラリの一行で呼び出せる。`PCA(n_components=2).fit_transform(X)` と書けば主成分分析が実行され、`SVC(kernel='rbf').fit(X, y)` と書けばサポートベクターマシンが学習される。にもかかわらず、これらの手法の数学を学ぶ意味はどこにあるのか。理由は三つある。

第一に、**手法が失敗したときに何が起きているかを診断できる**。主成分分析の結果が解釈不能になったとき、それは中心化の忘れなのか、変数のスケールの不揃いなのか、それともサンプル数に対して次元が高すぎるために標本共分散行列の固有ベクトルが真の方向とまったく無関係になっているのか。これらは見た目には区別がつかないが、原因が違えば処方箋も違う。第5章で見るように、三つ目の現象には**相転移**という明確な数学的境界があり、どちら側にいるかは計算できる。

第二に、**手法どうしの関係が見える**。主成分分析、正準相関分析、フィッシャー判別分析、スペクトラルクラスタリングは、教科書では別々の章に置かれることが多い。しかし第6章で示すように、これらはすべて

$$\boldsymbol{A}\boldsymbol{w} = \lambda \boldsymbol{B}\boldsymbol{w} \tag{1.1}$$

という一般化固有値問題の、行列 $\boldsymbol{A}, \boldsymbol{B}$ の選び方が違うだけの例である。一つを理解すれば残りは翻訳作業になる。

第三に、**新しい手法を自分で作れる**。カーネル法は「内積しか使わないアルゴリズムは、内積を別の関数に置き換えても動く」という一つの観察から、既存の線形手法をまるごと非線形化する処方箋を与えた（第8章）。この種の発想は、原理を知らなければ生まれない。

この講義の主張

データ解析の手法の多くは、**線形代数の言葉で書かれた最適化問題**である。その最適化問題を、(i) どの空間で解くか、(ii) どの内積を使うか、(iii) どんな制約を課すか、の三点を変えることで、驚くほど多様な手法が生まれる。本講義はこの視点を一貫して採る。

1.2　データ解析の数学的定式化

観測データは、n 個の対象それぞれについて d 個の量を測ったもの、と考える。第 i 番目の対象の観測値を並べたベクトルを $\boldsymbol{x}_i = (x_{1i}, \dots, x_{di})^\top \in \mathbb{R}^d$ $(i = 1, \dots, n)$ と書き、これを横に並べた

$$\boldsymbol{X} = \begin{pmatrix} \boldsymbol{x}_1 & \cdots & \boldsymbol{x}_n \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1n} \\ \vdots & \ddots & \vdots \\ x_{d1} & \cdots & x_{dn} \end{pmatrix} \in \mathbb{R}^{d \times n} \tag{1.2}$$

を**データ行列**（data matrix）と呼ぶ。

行と列のどちらがサンプルか

文献によって $\boldsymbol{X}$ の行がサンプルの場合と列がサンプルの場合がある。本講義では一貫して**列がサンプル、行が変数**とする（式 (1.2)）。すなわち $\boldsymbol{X}$ の第 i 列がそのまま第 i 番目のデータ点 $\boldsymbol{x}_i$ であり、$\boldsymbol{x}_i$ を「縦ベクトル」として扱う線形代数の習慣と素直に噛み合う。このとき共分散行列は $\frac{1}{n}\boldsymbol{X}\boldsymbol{X}^\top$（$d \times d$）、Gram 行列は $\boldsymbol{X}^\top\boldsymbol{X}$（$n \times n$）である。転置の位置を間違えると次元が合わなくなるので、次元を数える習慣をつけてほしい。

なお **scikit-learn などのライブラリは逆の規約（$n \times d$）を採る**。本講義のコード例では、ライブラリを呼ぶ際に `X.T` と転置して渡す。

$\boldsymbol{X}$ の見方は二通りある。**点の集まりとして**見れば、n 個の点 $\boldsymbol{x}_1, \dots, \boldsymbol{x}_n$ が $\mathbb{R}^d$ の中に散らばっており、「点の配置の形」（広がりの方向、クラスタ、曲がった構造）が関心事になる。**線形写像として**見れば、$\boldsymbol{X} : \mathbb{R}^n \to \mathbb{R}^d$ であり、その像空間 $\mathrm{Im}(\boldsymbol{X}) \subset \mathbb{R}^d$ はデータ点が張る部分空間、特異値はその各方向の伸びの大きさを表す。本講義では両方を行き来する。第一の見方は幾何的直感を与え、第二の見方は計算と証明を与える。

データ解析の問題は、大きく三つに分類できる。**（P1）表現を見つける**：$\boldsymbol{x} \in \mathbb{R}^d$ を、より少ない次元の $\boldsymbol{z} \in \mathbb{R}^k$（$k \ll d$）で情報の損失を小さく保ったまま表したい。これが**次元削減**であり、主成分分析（第3章）、カーネル主成分分析（第8章）、多様体学習（第11章）がここに属する。**（P2）関係を見つける**：二組のデータ $\boldsymbol{X}, \boldsymbol{Y}$ の間の対応、あるいは変数間の依存関係を知りたい。正準相関分析、回帰、独立性検定がここに属する。**（P3）予測する**：入力 $\boldsymbol{x}$ から出力 y を予測する関数 f を、観測された組 $(\boldsymbol{x}_i, y_i)_{i=1}^n$ から作りたい。サポートベクターマシン（第9章）、カーネルリッジ回帰（第8章）、ニューラルネットワーク（第10章）がここに属する。

これら三つは独立ではない。良い表現が得られれば予測は容易になり、予測に有用な方向を探すことは関係を見つけることでもある。実際、本講義で扱う手法の多くは、

$$\min_{f \in \mathcal{F}} \underbrace{\frac{1}{n}\sum_{i=1}^{n} L(y_i, f(\boldsymbol{x}_i))}_{\text{データへの適合}} + \underbrace{\lambda\, \Omega(f)}_{\text{関数の複雑さへの罰則}} \tag{1.3}$$

という共通の形（**正則化つき経験リスク最小化**）に書ける。違いは、関数のクラス $\mathcal{F}$、損失 L、罰則 Ω の三つの選び方にある（表 1.1）。

一方、（P1）の次元削減は式 (1.3)の形ではなく、

$$\max_{\boldsymbol{w}} \frac{\boldsymbol{w}^\top \boldsymbol{A} \boldsymbol{w}}{\boldsymbol{w}^\top \boldsymbol{B} \boldsymbol{w}} \qquad \text{あるいは} \qquad \boldsymbol{A}\boldsymbol{w} = \lambda \boldsymbol{B}\boldsymbol{w} \tag{1.4}$$

という **Rayleigh 商の最大化**（一般化固有値問題）の形をとることが多い。本講義の前半（第2章〜第6章）では主に式 (1.4)の一般化固有値問題を扱う。後半（第7章〜第10章）はまず RKHS を導入し（第7章）、その上で固有値問題のカーネル化（カーネル PCA、第8章）と 式 (1.3)の正則化つき経験リスク最小化（カーネルリッジ回帰・SVM・ニューラルネットワーク）の **双方**を扱う。二つの枠組みが同じ道具立てで非線形化されるところが後半の見どころである。

表1.1　正則化つき経験リスク最小化式 (1.3)の枠組みから見た主要手法。$\mathcal{H}$ は再生核ヒルベルト空間（第7章）を表す。

手法	関数クラス $\mathcal{F}$	損失 $L(y,f)$	罰則 $\Omega(f)$
最小二乗回帰	線形 $f(\boldsymbol{x})=\boldsymbol{w}^\top\boldsymbol{x}$	$(y-f)^2$	なし
リッジ回帰	線形	$(y-f)^2$	$\|\boldsymbol{w}\|_2^2$
Lasso	線形	$(y-f)^2$	$\|\boldsymbol{w}\|_1$
ロジスティック回帰	線形	$\log(1+e^{-yf})$	$\|\boldsymbol{w}\|_2^2$（任意）
ハードマージン SVM	線形	0 $(yf\ge 1)$, $+\infty$ $(yf<1)$	$\|\boldsymbol{w}\|_2^2$
ソフトマージン SVM	線形	$\max(0,1-yf)$	$\|\boldsymbol{w}\|_2^2$
カーネルリッジ回帰	$\mathcal{H}$	$(y-f)^2$	$\|f\|_{\mathcal{H}}^2$
カーネル SVM	$\mathcal{H}$	$\max(0,1-yf)$	$\|f\|_{\mathcal{H}}^2$
ニューラルネットワーク	深層網	任意	重み減衰など

表1.2　非線形化の三戦略の比較。n はサンプル数、d は入力次元、M は特徴次元、C_k はカーネル 1 回の評価コスト。カーネル法の列は **Gram 行列を陽に作る代表的な実装**（カーネルリッジ回帰、カーネル PCA、素朴な SVM ソルバ）を想定した値である。

	明示的特徴	カーネル法（Gram 行列型）	ニューラルネットワーク
特徴写像 ϕ	手で設計	陰に高次元	データから学習
学習の計算量	$O(nM^2)$	構成 $O(n^2C_k)$ ＋分解 $O(n^3)$	$O(n\times\text{epoch})$
記憶量	$O(M^2)$	$O(n^2)$	$O(\text{param})$
予測の計算量	$O(M)$	$O(nC_k)$	$O(\text{param})$
最適化問題	凸	凸（KRR・SVM）／固有値問題（KPCA）	非凸
n が大きいとき	得意	苦手（要近似）	得意
n が小さいとき	普通	得意	苦手（スクラッチ学習の場合）
理論的保証	あり	豊富	発展途上
本講義での章	第3章	第7章–9	第10章

1.3　線形から非線形へ：三つの戦略

現実のデータは線形構造だけでは捉えられない。線形手法を非線形に拡張する戦略は、大きく三つある。本講義はこの三つをそれぞれ扱う。

戦略 1：特徴を明示的に増やす

入力 $\boldsymbol{x}$ から非線形な特徴 $\phi(\boldsymbol{x})=(\phi_1(\boldsymbol{x}),\dots,\phi_M(\boldsymbol{x}))^\top$ を作り、その上で線形手法を使う。多項式回帰がその例である。素直だが、M が次元 d に対して指数的に増えるという問題がある。

戦略 2：内積だけを置き換える（カーネル法）

ϕ を陽に計算せず、内積 $\langle\phi(\boldsymbol{x}),\phi(\boldsymbol{x}')\rangle=k(\boldsymbol{x},\boldsymbol{x}')$ だけを計算する。$M=\infty$ の特徴空間でも、特徴ベクトルを陽に構成せずに計算できる。計算量は特徴次元 M には直接依存せず、主としてサンプル数 n とカーネル 1 回の評価コスト C_k（ガウスカーネルなら $O(d)$）に依存する。第7章〜第9章の主題。

戦略 3：特徴をデータから学ぶ（ニューラルネットワーク）

ϕ 自体をパラメータ化し、データに合わせて最適化する。表現力は最も高いが、最適化は非凸になる。第10章の主題。

三つの戦略には明確なトレードオフがある（表 1.2）。どれが優れているという話ではなく、サンプル数 n、次元 d、事前知識の有無によって適切な選択が変わる。

表の「カーネル法」は代表的な実装についての値

$O(n^3)$ も $O(n^2)$ の記憶量も、**Gram 行列を陽に作って密な分解を行う**実装の値である。Nyström 近似やランダムフーリエ特徴（8.10節）を使えば $O(nm^2)$ 程度まで落ちるし、線形カーネルなら主問題側を直接解いて

表1.3　8 コマと章の対応。† は講義では概略のみ扱い、詳細はノートに委ねる部分。

コマ	章	内容
1	第2章	線形代数の復習、直交射影、スペクトル定理、特異値分解、Eckart–Young の定理
2	第3章	主成分分析の三つの定式化とその同値性、寄与率、確率的 PCA†
3	第4章	PCA の計算技法：双対 PCA、べき乗法、ランダム化 SVD、頑健化・スパース化
4	第5章, 第6章	高次元の数理：距離の集中、Johnson–Lindenstrauss、Marchenko–Pastur 則、BBP 相転移。一般化固有値問題としての CCA・LDA・MDS・スペクトラルクラスタリング
5	第7章	関数解析の基礎、ヒルベルト空間、正定値カーネル、再生核ヒルベルト空間、Mercer の定理
6	第8章	表現定理、カーネル PCA、カーネルリッジ回帰、カーネル平均埋め込みと MMD†、大規模化
7	第9章	サポートベクターマシン：マージン最大化、双対問題、KKT 条件、ソフトマージン、カーネル SVM
8	第10章, 第11章	ニューラルネットワークと万能近似定理、発展的話題（ニューラルタンジェントカーネル、二重降下、多様体学習、最適輸送）†

$O(nd)$ で済む。また「凸」もカーネル法全体の性質ではない。カーネルリッジ回帰とソフトマージン SVM は凸計画だが、カーネル PCA（第8章）は凸最適化ではなく固有値問題であり、固有値が縮退すれば主成分方向は一意でない。

1.4　本講義の構成と 8 コマの対応

本章を含む全 11 章を 8 コマ（各 90 分）に割り当てる（表 1.3）。時間の都合で講義中に扱えない部分（† を付した項目）は、自習用として本ノートに残してある。

各章の末尾に演習問題を置いた。難易度を $(\star)$ 基本、$(\star\star)$ 標準、$(\star\star\star)$ 発展で示してある。数学的な証明問題と Python による実装問題を混ぜてあるので、両方に取り組んでほしい。解答は別冊「演習問題解答」にまとめた。

1.5　前提知識と記法

線形代数の初歩（ベクトル空間、行列の積、行列式、固有値・固有ベクトル、線形独立、基底、階数）を仮定する。ただし、データ解析で特に重要な事項（直交射影、スペクトル定理、特異値分解、行列の微分）は第2章で復習する。微分積分と初等的な確率（期待値、分散、正規分布）も使うが、必要な事項はその都度定義する。測度論やルベーグ積分の知識は仮定しない。関数解析についても、第7章でゼロから積み上げる。

本講義を通じて用いる記法を表 1.4にまとめる。迷ったらこの表に戻ってほしい。

注意 1.1 (勾配の向き)**.** スカラー関数 $f:\mathbb{R}^d\to\mathbb{R}$ の勾配 $\nabla f(\boldsymbol{x})$ は**列ベクトル**とする。行列に関する微分も同様に、$\partial f/\partial \boldsymbol{A}$ は $\boldsymbol{A}$ と同じ形の行列とする。この約束のもとで $\nabla_{\boldsymbol{x}}(\boldsymbol{a}^\top\boldsymbol{x})=\boldsymbol{a}$, $\nabla_{\boldsymbol{x}}(\boldsymbol{x}^\top\boldsymbol{A}\boldsymbol{x})=(\boldsymbol{A}+\boldsymbol{A}^\top)\boldsymbol{x}$ が成り立つ（2.9節で導出する）。

表1.4　本講義で用いる記法。

記号	意味
n, d, k	サンプル数、入力次元、削減後の次元（$k \le d$）
$\boldsymbol{x}, \boldsymbol{y}, \boldsymbol{w}$	列ベクトル（太字イタリック小文字）
$\boldsymbol{X}, \boldsymbol{A}, \boldsymbol{K}$	行列（太字イタリック大文字）
$\boldsymbol{X} \in \mathbb{R}^{d \times n}$	データ行列。第 i 列が $\boldsymbol{x}_i$
$\mathbf{1}_n$, $\boldsymbol{I}_d$	全成分 1 のベクトル、d 次単位行列
$\boldsymbol{H} = \boldsymbol{I}_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top$	中心化行列
$\widetilde{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{H}$	中心化されたデータ行列
$\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top$	標本共分散行列（$d \times d$）
$\boldsymbol{K}$, $K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j)$	Gram 行列（$n \times n$）
$\lambda_1 \ge \lambda_2 \ge \cdots$	固有値（降順）
$\sigma_1 \ge \sigma_2 \ge \cdots$	特異値（降順）
$\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \boldsymbol{x}^\top \boldsymbol{y}$	標準内積（$\mathbb{R}^d$ の場合）
$\|\boldsymbol{x}\| = \sqrt{\langle \boldsymbol{x}, \boldsymbol{x} \rangle}$	ノルム。添字なしは ℓ^2 ノルム
$\|\boldsymbol{A}\|_{\mathrm{F}}$, $\|\boldsymbol{A}\|_{\mathrm{op}}$	Frobenius ノルム、作用素ノルム（最大特異値）
$\mathrm{tr}(\boldsymbol{A})$, $\mathrm{rank}(\boldsymbol{A})$	トレース、階数
$\mathrm{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_k\}$	張られる部分空間
$\mathrm{Im}(\boldsymbol{A}) = \{\boldsymbol{A}\boldsymbol{u}\}$	$\boldsymbol{A}$ の像（列空間）。$\boldsymbol{A} \in \mathbb{R}^{m \times l}$ なら $\mathbb{R}^m$ の部分空間
$\mathrm{Ker}(\boldsymbol{A}) = \{\boldsymbol{u} : \boldsymbol{A}\boldsymbol{u} = \mathbf{0}\}$	$\boldsymbol{A}$ の核（零空間）。$\mathbb{R}^l$ の部分空間（定義 2.1）
$\mathcal{H}$, $\mathcal{F}$	ヒルベルト空間、関数のクラス
$\phi : \mathcal{X} \to \mathcal{H}$	特徴写像
$\mathbb{E}[\cdot]$, $\mathrm{Var}[\cdot]$, $\mathrm{Cov}[\cdot]$	期待値、分散、共分散
$a \coloneqq b$	a を b で定義する
$\mathbf{1}\{P\}$	命題 P が真なら 1、偽なら 0
$\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$	平均 $\boldsymbol{\mu}$、共分散 $\boldsymbol{\Sigma}$ の正規分布
$[n]$	集合 $\{1, 2, \dots, n\}$

1.6　計算環境

演習の実装問題では Python を用いる。必要なライブラリは NumPy、SciPy、Matplotlib、scikit-learn である。

リスト 1.1　本講義で用いる標準的な import

```python
import numpy as np
import scipy.linalg as sla
import matplotlib.pyplot as plt
from sklearn import datasets, decomposition, svm

rng = np.random.default_rng(0)   # 再現性のため seed を固定する
```

数値計算においては、**数式をそのまま実装してはいけない**場面が多い。たとえば $\widehat{\boldsymbol{\Sigma}}^{-1}$ を計算してからベクトルに掛けるのではなく、連立方程式 $\widehat{\boldsymbol{\Sigma}}\boldsymbol{z} = \boldsymbol{v}$ を解くべきである。本講義では、そうした計算上の注意を随時示す。

逆行列を作ってはいけない

$\boldsymbol{A}^{-1}\boldsymbol{v}$ を計算したいとき、`np.linalg.inv(A) @ v` と書くのは避け、`np.linalg.solve(A, v)` を使う。前者は $O(d^3)$ の計算に加えて条件数の悪い行列で精度を大きく失う。正定値対称なら Cholesky 分解（`scipy.linalg.cho_solve`）がさらに速い。

本ノートは自己完結を目指したが、各分野にはさらに深い教科書がある。線形代数と数値計算については Trefethen–Bau [77]、カーネル法については Schölkopf–Smola [71] と Steinwart–Christmann [73]、高次元統計については Vershynin [80] と Wainwright [82]、日本語では青嶋・矢田『高次元の統計学』[6] を薦める。とくに [6] は $d \gg n$ での標本固有値の不一致性や標本共分散行列の双対表現を正面から扱っており、第5章の議論と直接つながる。

演習問題

演習 1.1 (⋆)**.** $\boldsymbol{X} \in \mathbb{R}^{d \times n}$ をデータ行列とする。次の各量の次元（サイズ）を答えよ。また、それぞれが何を表しているか一文で述べよ。

$$\text{(a) } \boldsymbol{X}\boldsymbol{X}^{\top}, \quad \text{(b) } \boldsymbol{X}^{\top}\boldsymbol{X}, \quad \text{(c) } \tfrac{1}{n}\boldsymbol{X}\mathbf{1}_n, \quad \text{(d) } \boldsymbol{X}\boldsymbol{H} \quad (\boldsymbol{H} = \boldsymbol{I}_n - \tfrac{1}{n}\mathbf{1}_n\mathbf{1}_n^{\top}).$$

演習 1.2 (⋆)**.** 中心化行列 $\boldsymbol{H} = \boldsymbol{I}_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^{\top}$ について、次を示せ。(a) $\boldsymbol{H}^{\top} = \boldsymbol{H}$ かつ $\boldsymbol{H}^2 = \boldsymbol{H}$（すなわち $\boldsymbol{H}$ は直交射影行列である）。(b) $\boldsymbol{H}\mathbf{1}_n = \mathbf{0}$。(c) $\operatorname{rank}(\boldsymbol{H}) = n - 1$。また $\boldsymbol{H}$ はどの部分空間への射影か答えよ。

演習 1.3 (⋆⋆)**.** 表 1.1のうち、リッジ回帰とソフトマージン SVM を取り上げる。両者は罰則が同じ $\|\boldsymbol{w}\|_2^2$ で、損失だけが異なる。損失関数 $(y - f)^2$ と $\max(0, 1 - yf)$ を、$y \in \{-1, +1\}$ の分類問題として yf の関数として同じ図に描け（手描きでよい）。二乗損失を分類に用いると何が問題になるか、図から読み取って説明せよ。

演習 1.4 (⋆⋆)**.** 表 1.2で、カーネル法の学習の計算量を $O(n^3)$ とした。$n = 10^6$ のデータに対してカーネル法をそのまま適用するとき、Gram 行列の保存に必要なメモリ量を倍精度で見積もれ。現実的な計算機で扱えるか論ぜよ。

演習 1.5 (⋆（実装）)**.** NumPy で次を実装し、$n = 5, d = 3$ のランダムなデータ行列で検証せよ。(a) 中心化行列 $\boldsymbol{H}$ を陽に構成して $\boldsymbol{X}\boldsymbol{H}$ を計算する関数。(b) $\boldsymbol{H}$ を作らずに `X - X.mean(axis=1, keepdims=True)` で中心化する関数。(c) 両者が数値誤差の範囲で一致することを `np.allclose` で確認する。さらに $n = 10^4$ のとき両者の計算時間を比較し、なぜ差が生じるか説明せよ。

第 2 章

線形代数とデータ行列

この章のねらい

線形代数の道具立てを、データ解析で実際に使う形に組み直す。データ行列を「点の集まり」と「線形写像」の二通りに読む見方を確立し、内積・直交射影・スペクトル定理・特異値分解・擬似逆行列という五つの柱を、後の章で使う定理の形に整えて証明つきで用意する。とくに Rayleigh 商の最大最小定理は第3章の主成分分析の証明の心臓部、特異値分解と Eckart–Young の定理は低ランク近似という発想そのものを与える。

2.1　データ行列の二つの見方

データ解析の出発点は n 個のサンプルを d 個の数値で表した表である。第 i サンプルを $\boldsymbol{x}_i = (x_{1i}, \dots, x_{di})^\top \in \mathbb{R}^d$ とし、列に並べた $\boldsymbol{X} = (\boldsymbol{x}_1 \ \cdots \ \boldsymbol{x}_n) \in \mathbb{R}^{d \times n}$ を**データ行列**（data matrix）と呼ぶ。本書では列がサンプル、行が変数である（$\boldsymbol{x}_i$ をそのまま列ベクトルとして並べる線形代数の流儀に合わせてある）。

実装では行がサンプルであることが多い

Python の機械学習ライブラリは逆の規約を採る。scikit-learn をはじめ `fit(X, y)` 形式の API はほぼすべて $\boldsymbol{X}$ を **（サンプル数）×（特徴量数）**、すなわち**行がサンプル**の $n \times d$ 行列として受け取る（pandas の `DataFrame` も 1 行 1 レコードである）。本書の $\boldsymbol{X} \in \mathbb{R}^{d \times n}$ とは転置の関係にあるので、`X_sklearn = X.T` のように受け渡しのたびに転置する。本書のコードリストでも同じ約束で書いてある。数式の側で列をサンプルに取るのは、$\boldsymbol{x}_i$ を列ベクトルとして扱う線形代数の記法と一致し、$\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top$ や $\boldsymbol{X} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$ のような式が転置なしで書けるからである。どちらが正しいということはなく、**どちらの規約で書かれているかを常に確認する**のがよい。

同じ $\boldsymbol{X}$ を目的に応じて二通りに読む。

見方 1：点の集まり。 $\boldsymbol{X}$ の各列は $\mathbb{R}^d$ の 1 点であり、$\boldsymbol{X}$ は d 次元空間の n 点の点群を表す。重心・広がり・方向といった**幾何**が主役になる見方で、PCA の「点群がもっとも広がっている方向を探す」という発想はここから生まれる。

見方 2：線形写像。 $\boldsymbol{X}$ は写像 $\mathbb{R}^n \to \mathbb{R}^d,\ \boldsymbol{c} \mapsto \boldsymbol{X}\boldsymbol{c}$ を定める。$\boldsymbol{X}\boldsymbol{c} = \sum_{i=1}^{n} c_i \boldsymbol{x}_i$ だから、これは**データ点の線形結合を作る**写像であり、値域 $\mathrm{Im}(\boldsymbol{X}) \subset \mathbb{R}^d$ はデータ点が張る部分空間、核 $\mathrm{Ker}(\boldsymbol{X}) \subset \mathbb{R}^n$ は $\sum_i c_i \boldsymbol{x}_i = \boldsymbol{0}$ となる係数の全体である。一方、$\boldsymbol{w} \in \mathbb{R}^d$ を重みとする**線形予測値**を並べたベクトルは転置の側に現れる：$\boldsymbol{X}^\top \boldsymbol{w} \in \mathbb{R}^n$ の第 i 成分が $\langle \boldsymbol{x}_i, \boldsymbol{w} \rangle$ である。したがって最小二乗法の「$\boldsymbol{y}$ を $\mathrm{Im}(\boldsymbol{X}^\top)$ に近づける」という発想は、この見方を $\boldsymbol{X}^\top$ に対して使ったものになる（2.8節）。値域・核・階数といった**写像の構造**が主役になる見方であり、繰り返し使う二つの部分空間を記号とともに確認しておく。

定義 2.1 (像と核)**.** 行列 $\boldsymbol{A} \in \mathbb{R}^{m \times l}$ に対し

$$\mathrm{Im}(\boldsymbol{A}) := \{\boldsymbol{A}\boldsymbol{u} : \boldsymbol{u} \in \mathbb{R}^l\} \subset \mathbb{R}^m, \qquad \mathrm{Ker}(\boldsymbol{A}) := \{\boldsymbol{u} \in \mathbb{R}^l : \boldsymbol{A}\boldsymbol{u} = \boldsymbol{0}\} \subset \mathbb{R}^l \tag{2.1}$$

と定める。$\mathrm{Im}(\boldsymbol{A})$ を $\boldsymbol{A}$ の**像**（image, range）または**列空間**、$\mathrm{Ker}(\boldsymbol{A})$ を $\boldsymbol{A}$ の**核**（kernel）または**零空間**（null space）という。どちらも部分空間であり、$\dim \mathrm{Im}(\boldsymbol{A}) = \mathrm{rank}(\boldsymbol{A})$ が成り立つ。

$\mathrm{Im}(\boldsymbol{A})$ は「$\boldsymbol{A}$ を掛けて到達できる点の全体」であり、$\boldsymbol{A}$ の列 $\boldsymbol{a}_1, \dots, \boldsymbol{a}_l$ の線形結合全体、すなわち $\mathrm{span}\{\boldsymbol{a}_1, \dots, \boldsymbol{a}_l\}$ に等しい（$\boldsymbol{A}\boldsymbol{u} = \sum_j u_j \boldsymbol{a}_j$ だから）。「列空間」という別名はこのためである。一方 $\mathrm{Ker}(\boldsymbol{A})$ は「$\boldsymbol{A}$ を掛けると消える方向の全体」で、$\boldsymbol{A}\boldsymbol{u} = \boldsymbol{A}\boldsymbol{u}'$ となる $\boldsymbol{u} \neq \boldsymbol{u}'$ があるとき、その差 $\boldsymbol{u} - \boldsymbol{u}'$ はここに属する。

Im と Ker はどちらの空間に住むか

$\boldsymbol{A} \in \mathbb{R}^{m\times l}$ のとき $\mathrm{Im}(\boldsymbol{A}) \subset \mathbb{R}^m$（出力側）、$\mathrm{Ker}(\boldsymbol{A}) \subset \mathbb{R}^l$（入力側）で、一般に別の空間の部分空間である。混同しやすいので、$\boldsymbol{A}$ の形を見てどちらの次元かを確かめる習慣をつけてほしい。データ行列 $\boldsymbol{X} \in \mathbb{R}^{d\times n}$ なら $\mathrm{Im}(\boldsymbol{X}) \subset \mathbb{R}^d$（データ点 $\boldsymbol{x}_1, \dots, \boldsymbol{x}_n$ が張る空間。$\mathbb{R}^d$ の中の「点群が乗っている平坦な部分」）、$\mathrm{Ker}(\boldsymbol{X}) \subset \mathbb{R}^n$（データ点の間の一次関係の空間。$\sum_i c_i \boldsymbol{x}_i = \boldsymbol{0}$ となる係数ベクトル $\boldsymbol{c}$ の全体で、$n > d$ ならば必ず非自明である）である。n 個の予測値の空間 $\mathbb{R}^n$ に住むのは $\mathrm{Im}(\boldsymbol{X}^\top)$ の方であり、どちらの空間の話をしているかは $\boldsymbol{X}$ と $\boldsymbol{X}^\top$ のどちらを見ているかで決まる。なお Ker **という記号はカーネル法のカーネル関数** $k(\cdot,\cdot)$ **とは無関係**である。語源は同じ「核」だが、第7章以降のカーネルは正定値関数を指す。

二つの見方は、$\boldsymbol{X}$ から作られる二つの正方行列に対応する。

$$(\boldsymbol{X}\boldsymbol{X}^\top)_{jl} = \textstyle\sum_i x_{ji}x_{li}\ \text{（変数 } j \text{ と } l \text{ の関係）}, \qquad (\boldsymbol{X}^\top\boldsymbol{X})_{ii'} = \langle \boldsymbol{x}_i, \boldsymbol{x}_{i'}\rangle\ \text{（サンプル } i \text{ と } i' \text{ の関係）}. \tag{2.2}$$

前者（$d\times d$）は変数どうしの共変動をまとめた行列で、中心化すれば標本共分散行列になる。後者（$n\times n$）はサンプルどうしの内積を並べた**グラム行列**（Gram matrix）で、第8章でカーネル $\boldsymbol{K}$ に置き換わる対象そのものである。両者は非零固有値を共有するが（2.6節）、構成に要する演算は $O(nd^2)$ と $O(n^2d)$ で異なる。$n \ll d$ なら後者、$n \gg d$ なら前者を扱うのが得であり、これが第4章の双対 PCA と 第8章のカーネル法の計算上の要になる。どちらの積がどちらのサイズかは、$\boldsymbol{X}$ が $d\times n$ であることから $(d\times n)(n\times d) = (d\times d)$、$(n\times d)(d\times n) = (n\times n)$ と数えれば分かる。

例 2.2 (小さなデータ行列)**.** $\boldsymbol{X} = \begin{pmatrix} 1 & 3 & 5 \\ 2 & 6 & 4 \end{pmatrix} \in \mathbb{R}^{2\times 3}$（$d=2$ 変数、$n=3$ サンプル）の行平均は $(3,4)^\top$、中心化すると $\widetilde{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{H} = \begin{pmatrix} -2 & 0 & 2 \\ -2 & 2 & 0 \end{pmatrix}$ であり、$\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top = \begin{pmatrix} 8 & 4 \\ 4 & 8 \end{pmatrix}$, $\widetilde{\boldsymbol{X}}^\top\widetilde{\boldsymbol{X}} = \begin{pmatrix} 8 & -4 & -4 \\ -4 & 4 & 0 \\ -4 & 0 & 4 \end{pmatrix}$。前者（$d\times d$）の固有値は $12, 4$、後者（$n\times n$）は $12, 4, 0$ で非零部分が一致する。サイズの小さい方を計算すれば十分だ、という事実の最小の例である。

中心化。以後 $\boldsymbol{1} = (1,\dots,1)^\top \in \mathbb{R}^n$ とし、$\boldsymbol{H} \coloneqq \boldsymbol{I}_n - \frac{1}{n}\boldsymbol{1}\boldsymbol{1}^\top$（**中心化行列**, centering matrix）、$\widetilde{\boldsymbol{X}} \coloneqq \boldsymbol{X}\boldsymbol{H}$、$\widehat{\boldsymbol{\Sigma}} \coloneqq \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top$（標本共分散行列）と書く。$\boldsymbol{H}$ は $n\times n$ なので**右から**掛けることになり、$(d\times n)(n\times n) = (d\times n)$ で $\widetilde{\boldsymbol{X}}$ の形は $\boldsymbol{X}$ と同じである。$\boldsymbol{H}$ が直交射影行列であることは2.4節で示す。

2.2　ユークリッド空間の幾何

データ解析で繰り返し現れる操作は三つある。一つの対象の**大きさ**を測ること、二つの対象の**似ている度合い**を測ること、二つの対象の**離れ具合**を測ることである。ベクトル空間そのもの（和とスカラー倍しかない構造）には、この三つはどれも備わっていない。$\mathbb{R}^d$ では、内積を一つ決めるだけで三つがまとめて手に入る。

本節では $\mathbb{R}^d$ の標準内積だけを扱う。内積そのものを取り替える一般化は 第6章で、空間を関数空間に広げる一般化は第7章で扱う。

2.2.1　内積・ノルム・距離

定義 2.3 (ユークリッド内積・ノルム・距離)**.** $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^d$ に対し

$$\langle \boldsymbol{x}, \boldsymbol{y}\rangle \coloneqq \boldsymbol{x}^\top\boldsymbol{y} = \sum_{j=1}^{d} x_j y_j, \qquad \|\boldsymbol{x}\| \coloneqq \sqrt{\langle \boldsymbol{x}, \boldsymbol{x}\rangle} = \sqrt{\textstyle\sum_j x_j^2}, \qquad \rho(\boldsymbol{x}, \boldsymbol{y}) \coloneqq \|\boldsymbol{x} - \boldsymbol{y}\| \tag{2.3}$$

をそれぞれ**（標準）内積**、**ユークリッドノルム**、**ユークリッド距離**という。断らない限り $\langle\cdot,\cdot\rangle$、$\|\cdot\|$ はこれを指す。

内積は $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \langle \boldsymbol{y}, \boldsymbol{x}\rangle$（対称性）と $\langle a\boldsymbol{x} + b\boldsymbol{y}, \boldsymbol{z}\rangle = a\langle \boldsymbol{x}, \boldsymbol{z}\rangle + b\langle \boldsymbol{y}, \boldsymbol{z}\rangle$（双線形性）をみたし、$\langle \boldsymbol{x}, \boldsymbol{x}\rangle = \sum_j x_j^2 \geq 0$ で、等号は $\boldsymbol{x} = \boldsymbol{0}$ のときに限る（正定値性）。以下の議論はすべてこの三つの性質だけから従う。これは後で効いてくる。第6章で内積を取り替えても、第7章で $\mathbb{R}^d$ を関数空間に取り替えても、三つの性質さえ保たれていれば本節の結論はそのまま成り立つからである。

定理 2.4 (Cauchy–Schwarz の不等式)**.** 任意の $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^d$ に対し $|\langle \boldsymbol{x}, \boldsymbol{y}\rangle| \leq \|\boldsymbol{x}\|\,\|\boldsymbol{y}\|$。等号は $\boldsymbol{x}, \boldsymbol{y}$ が一次従属のときかつそのときに限る。

証明. $\boldsymbol{y} = \boldsymbol{0}$ なら両辺 0。以下 $\boldsymbol{y} \neq \boldsymbol{0}$ とする。任意の $t \in \mathbb{R}$ に対し正定値性から $0 \leq \|\boldsymbol{x} - t\boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 - 2t\langle \boldsymbol{x}, \boldsymbol{y}\rangle + t^2\|\boldsymbol{y}\|^2 =: q(t)$。$q$ は最高次係数 $\|\boldsymbol{y}\|^2 > 0$ の二次関数で、すべての t で非負であるから判別式が非正：$4\langle \boldsymbol{x}, \boldsymbol{y}\rangle^2 - 4\|\boldsymbol{x}\|^2\|\boldsymbol{y}\|^2 \leq 0$。整理して主張を得る。等号成立は q が重解をもつこと、すなわちある t_0 で $\|\boldsymbol{x} - t_0\boldsymbol{y}\| = 0$、つまり $\boldsymbol{x} = t_0\boldsymbol{y}$ となることと同値である。 ■

命題 2.5 (ノルムと距離の基本性質)**.** $\boldsymbol{x},\boldsymbol{y},\boldsymbol{z}\in\mathbb{R}^d$、$a\in\mathbb{R}$ に対し次が成り立つ。(i) $\|\boldsymbol{x}\|\geq 0$ かつ $\|\boldsymbol{x}\|=0 \iff \boldsymbol{x}=\boldsymbol{0}$、(ii) $\|a\boldsymbol{x}\|=|a|\|\boldsymbol{x}\|$、(iii) $\|\boldsymbol{x}+\boldsymbol{y}\|\leq\|\boldsymbol{x}\|+\|\boldsymbol{y}\|$ (三角不等式)。したがって $\rho(\boldsymbol{x},\boldsymbol{y})=\|\boldsymbol{x}-\boldsymbol{y}\|$ は $\rho\geq 0$ (等号は $\boldsymbol{x}=\boldsymbol{y}$ のときに限る)、$\rho(\boldsymbol{x},\boldsymbol{y})=\rho(\boldsymbol{y},\boldsymbol{x})$、$\rho(\boldsymbol{x},\boldsymbol{z})\leq\rho(\boldsymbol{x},\boldsymbol{y})+\rho(\boldsymbol{y},\boldsymbol{z})$ をみたす。

証明. (i) は正定値性そのもの、(ii) は双線形性から $\|a\boldsymbol{x}\|^2=a^2\langle\boldsymbol{x},\boldsymbol{x}\rangle$。(iii) は定理 2.4から

$$\|\boldsymbol{x}+\boldsymbol{y}\|^2=\|\boldsymbol{x}\|^2+2\langle\boldsymbol{x},\boldsymbol{y}\rangle+\|\boldsymbol{y}\|^2\leq\|\boldsymbol{x}\|^2+2\|\boldsymbol{x}\|\|\boldsymbol{y}\|+\|\boldsymbol{y}\|^2=(\|\boldsymbol{x}\|+\|\boldsymbol{y}\|)^2.$$

ρ の三つの性質は、$\boldsymbol{x}-\boldsymbol{z}=(\boldsymbol{x}-\boldsymbol{y})+(\boldsymbol{y}-\boldsymbol{z})$ に (i)–(iii) を使えばよい。 ■

なお、大きさの測り方はこれだけではない。たとえば $\|\boldsymbol{x}\|_1=\sum_j|x_j|$ (第4章のスパース PCA で使う) も「大きさ」として使える。これらを含む一般の***ノルム***は第7章で定義する。本章ではユークリッドノルムだけを用いる。

2.2.2 角度と直交

定義 2.6 (なす角・直交)**.** 非零ベクトル $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^d$ に対し

$$\cos\theta\coloneqq\frac{\langle\boldsymbol{x},\boldsymbol{y}\rangle}{\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|} \tag{2.4}$$

により**なす角** $\theta\in[0,\pi]$ を定める (定理 2.4より右辺は $[-1,1]$ に入るので、θ が一意に決まる)。$\langle\boldsymbol{x},\boldsymbol{y}\rangle=0$ のとき $\boldsymbol{x}$ と $\boldsymbol{y}$ は**直交**するといい、$\boldsymbol{x}\perp\boldsymbol{y}$ と書く。

直交はこの後ずっと使う。まず、直交すれば大きさが素直に足し合わさる。

命題 2.7 (ピタゴラスの定理)**.** $\boldsymbol{x}\perp\boldsymbol{y}$ ならば $\|\boldsymbol{x}+\boldsymbol{y}\|^2=\|\boldsymbol{x}\|^2+\|\boldsymbol{y}\|^2$。

証明. $\|\boldsymbol{x}+\boldsymbol{y}\|^2=\|\boldsymbol{x}\|^2+2\langle\boldsymbol{x},\boldsymbol{y}\rangle+\|\boldsymbol{y}\|^2$ で中央の項が 0。 ■

(2.4)は統計とも直結する。二つの変数の観測値を中心化したベクトルを $\widetilde{\boldsymbol{X}}_j,\widetilde{\boldsymbol{X}}_l\in\mathbb{R}^n$ とすれば

$$\cos\theta=\frac{\langle\widetilde{\boldsymbol{X}}_j,\widetilde{\boldsymbol{X}}_l\rangle}{\|\widetilde{\boldsymbol{X}}_j\|\,\|\widetilde{\boldsymbol{X}}_l\|}=\frac{\sum_i(x_{ji}-\bar{x}_j)(x_{li}-\bar{x}_l)}{\sqrt{\sum_i(x_{ji}-\bar{x}_j)^2}\sqrt{\sum_i(x_{li}-\bar{x}_l)^2}}$$

となり、右辺は**相関係数の定義式そのもの**である (近似ではなく恒等式である)。すなわち相関が 0 とは、中心化したデータベクトルが直交することにほかならない。

角度と直交を先に置いたのは、第3章の PCA がこの二つの言葉で書かれるからである。主成分方向は互いに直交する正規直交基底として選ばれ (本節の残り)、データの復元はその基底が張る部分空間への直交射影である (2.4節)。

内積 $\Longrightarrow$ ノルム $\Longrightarrow$ 距離

(2.3)の矢印は**一方向**である。距離しかない空間には大きさの概念がなく、ノルムしかない空間には角度の概念がない。内積はこの鎖の最上流にあり、**角度・直交・射影**という PCA に必要な語彙をすべて供給する唯一の構造である。この鎖は $\mathbb{R}^d$ に固有のものではない。第6章では内積を $\langle\boldsymbol{x},\boldsymbol{y}\rangle_{\boldsymbol{B}}=\boldsymbol{x}^\top\boldsymbol{B}\boldsymbol{y}$ に取り替え、第7章では空間そのものを関数の空間に取り替えるが、どちらでも同じ鎖が成り立つ。

2.3 正規直交系

定義 2.8 (正規直交系)**.** $\boldsymbol{u}_1,\dots,\boldsymbol{u}_k\in\mathbb{R}^d$ が $\langle\boldsymbol{u}_i,\boldsymbol{u}_j\rangle=\delta_{ij}$ を満たすとき **正規直交系** (orthonormal system)、これが $\mathbb{R}^d$ を張るとき (すなわち $k=d$ のとき) **正規直交基底**という。

命題 2.9. 正規直交系 $\boldsymbol{u}_1,\dots,\boldsymbol{u}_k$ について次が成り立つ。(i) 一次独立である。(ii) $V=\operatorname{span}\{\boldsymbol{u}_1,\dots,\boldsymbol{u}_k\}$ の元 $\boldsymbol{v}$ は $\boldsymbol{v}=\sum_i\langle\boldsymbol{v},\boldsymbol{u}_i\rangle\boldsymbol{u}_i$ と一意に展開され、$\|\boldsymbol{v}\|^2=\sum_i\langle\boldsymbol{v},\boldsymbol{u}_i\rangle^2$ (**Parseval の等式**)。(iii) 任意の $\boldsymbol{x}\in\mathbb{R}^d$ に対し $\sum_{i=1}^k\langle\boldsymbol{x},\boldsymbol{u}_i\rangle^2\leq\|\boldsymbol{x}\|^2$ (**Bessel の不等式**)。

証明. (i) $\sum_i c_i\boldsymbol{u}_i=\boldsymbol{0}$ の両辺と $\boldsymbol{u}_j$ の内積をとると $c_j=0$。(ii) $\boldsymbol{v}=\sum_i c_i\boldsymbol{u}_i$ と書けたとすれば $\boldsymbol{u}_j$ との内積から $c_j=\langle\boldsymbol{v},\boldsymbol{u}_j\rangle$ が定まる (一意性)。このとき $\|\boldsymbol{v}\|^2=\sum_{i,j}c_ic_j\delta_{ij}=\sum_i c_i^2$。(iii) $\boldsymbol{v}\coloneqq\sum_i\langle\boldsymbol{x},\boldsymbol{u}_i\rangle\boldsymbol{u}_i$ とおくと各 j で $\langle\boldsymbol{x}-\boldsymbol{v},\boldsymbol{u}_j\rangle=0$、ゆえに $\langle\boldsymbol{x}-\boldsymbol{v},\boldsymbol{v}\rangle=0$。よって $\|\boldsymbol{x}\|^2=\|\boldsymbol{x}-\boldsymbol{v}\|^2+\|\boldsymbol{v}\|^2\geq\sum_i\langle\boldsymbol{x},\boldsymbol{u}_i\rangle^2$。 ■

(ii) が正規直交基底のありがたみである。一般の基底では座標を求めるのに逆行列が要るが、正規直交基底なら内積を k 回計算するだけでよい。PCA を「新しい正規直交基底を作る手法」とみれば、主成分スコアが $\langle\boldsymbol{x},\boldsymbol{u}_i\rangle$ と書ける理由も分かる。

リスト 2.1　Gram–Schmidt の実装と `numpy.linalg.qr` の一致確認、および射影行列の二通りの計算

```python
import numpy as np

def gram_schmidt(A):           # 数式どおりの素朴な実装
    Q = np.zeros(A.shape)
    for j in range(A.shape[1]):
        v = A[:, j].copy()
        for i in range(j):     # v <- v - <a_j, u_i> u_i
            v -= (Q[:, i] @ A[:, j]) * Q[:, i]
        Q[:, j] = v / np.linalg.norm(v)
    return Q

rng = np.random.default_rng(0)
A = rng.standard_normal((6, 3))
Q, (Q_lib, R_lib) = gram_schmidt(A), np.linalg.qr(A)
print(np.abs(Q.T @ Q - np.eye(3)).max())        # 正規直交性: 4.4e-16
print(np.abs(np.abs(Q) - np.abs(Q_lib)).max())  # 符号を除き QR と一致: 3.3e-16
# 射影行列 P = Q Q^T は基底の取り方によらない
print(np.abs(Q @ Q.T - A @ np.linalg.solve(A.T @ A, A.T)).max())   # 4.0e-16
```

定理 2.10 (Gram–Schmidt の直交化)**.** 一次独立な $\boldsymbol{a}_1, \dots, \boldsymbol{a}_k \in \mathbb{R}^d$ に対し、$\operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_j\} = \operatorname{span}\{\boldsymbol{a}_1, \dots, \boldsymbol{a}_j\}$ $(j = 1, \dots, k)$ を満たす正規直交系 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_k$ が存在する。

証明. j についての帰納法で構成する。$\boldsymbol{u}_1 \coloneqq \boldsymbol{a}_1 / \|\boldsymbol{a}_1\|$。$\boldsymbol{u}_1, \dots, \boldsymbol{u}_{j-1}$ が $\operatorname{span}\{\boldsymbol{a}_1, \dots, \boldsymbol{a}_{j-1}\}$ の正規直交基底になっているとし、$\boldsymbol{v}_j \coloneqq \boldsymbol{a}_j - \sum_{i<j} \langle \boldsymbol{a}_j, \boldsymbol{u}_i \rangle \boldsymbol{u}_i$ とおく。$\boldsymbol{v}_j = \boldsymbol{0}$ なら $\boldsymbol{a}_j \in \operatorname{span}\{\boldsymbol{a}_1, \dots, \boldsymbol{a}_{j-1}\}$ となり一次独立性に反するので $\boldsymbol{v}_j \neq \boldsymbol{0}$。$\boldsymbol{u}_j \coloneqq \boldsymbol{v}_j / \|\boldsymbol{v}_j\|$ とすれば、$l < j$ に対し $\langle \boldsymbol{v}_j, \boldsymbol{u}_l \rangle = \langle \boldsymbol{a}_j, \boldsymbol{u}_l \rangle - \langle \boldsymbol{a}_j, \boldsymbol{u}_l \rangle = 0$ だから $\boldsymbol{u}_1, \dots, \boldsymbol{u}_j$ は正規直交系である。さらに $\boldsymbol{u}_j$ は $\boldsymbol{a}_j$ と $\boldsymbol{u}_1, \dots, \boldsymbol{u}_{j-1}$ の一次結合、逆に $\boldsymbol{a}_j$ は $\boldsymbol{u}_1, \dots, \boldsymbol{u}_j$ の一次結合だから、張る空間の一致も保たれる。 ■

$\boldsymbol{A} = (\boldsymbol{a}_1 \ \cdots \ \boldsymbol{a}_k)$、$\boldsymbol{Q} = (\boldsymbol{u}_1 \ \cdots \ \boldsymbol{u}_k)$ とおくと、構成の過程は $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{R}$（$\boldsymbol{R}$ は上三角、対角成分正）という **QR 分解**に他ならない。なお上の素朴な手続き（古典的 Gram–Schmidt）は丸め誤差に弱いので、実務では修正 Gram–Schmidt か Householder 変換を使う。

リスト 2.1は、数式どおりの `gram_schmidt` がライブラリの QR 分解と（列の符号を除いて）一致し、$\boldsymbol{Q}\boldsymbol{Q}^{\top}$ が次節の射影行列と一致することを確認している（三つの誤差はいずれも丸め誤差の水準）。

2.3.1　線形汎関数は内積で書ける

正規直交基底の効用をもう一つ挙げておく。**線形汎関数**（linear functional）とは線形写像 $\varphi : \mathbb{R}^d \to \mathbb{R}$ のことである。たとえば「第 3 成分を読む」$\varphi(\boldsymbol{x}) = x_3$、「成分の総和」$\varphi(\boldsymbol{x}) = \boldsymbol{1}^{\top}\boldsymbol{x}$、「与えられた重みでの加重平均」はいずれも線形汎関数である。実はこれらはすべて**ある一つのベクトルとの内積**という同じ形をしている。

命題 2.11 (Riesz の表現定理・有限次元版)**.** $\varphi : \mathbb{R}^d \to \mathbb{R}$ を線形汎関数とする。このとき

$$\varphi(\boldsymbol{x}) = \langle \boldsymbol{x}, \boldsymbol{a} \rangle \qquad (\forall \boldsymbol{x} \in \mathbb{R}^d) \tag{2.5}$$

を満たす $\boldsymbol{a} \in \mathbb{R}^d$ が**ただ一つ**存在し、$\mathbb{R}^d$ の任意の正規直交基底 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_d$ を使って

$$\boldsymbol{a} = \sum_{i=1}^{d} \varphi(\boldsymbol{u}_i)\, \boldsymbol{u}_i \tag{2.6}$$

と書ける。さらに $\sup_{\boldsymbol{x} \neq \boldsymbol{0}} |\varphi(\boldsymbol{x})| / \|\boldsymbol{x}\| = \|\boldsymbol{a}\|$ であり、とくに φ は有界（したがって連続）である。

証明. 存在. 命題 2.9(ii) より任意の $\boldsymbol{x}$ は $\boldsymbol{x} = \sum_i \langle \boldsymbol{x}, \boldsymbol{u}_i \rangle \boldsymbol{u}_i$ と展開できる。φ の線形性から

$$\varphi(\boldsymbol{x}) = \sum_{i=1}^{d} \langle \boldsymbol{x}, \boldsymbol{u}_i \rangle \varphi(\boldsymbol{u}_i) = \Big\langle \boldsymbol{x},\ \sum_{i=1}^{d} \varphi(\boldsymbol{u}_i) \boldsymbol{u}_i \Big\rangle$$

となり、(2.6)の $\boldsymbol{a}$ が(2.5)を満たす。

一意性. $\langle \boldsymbol{x}, \boldsymbol{a} \rangle = \langle \boldsymbol{x}, \boldsymbol{a}' \rangle$ が全ての $\boldsymbol{x}$ で成り立つなら $\langle \boldsymbol{x}, \boldsymbol{a} - \boldsymbol{a}' \rangle = 0$、ここで $\boldsymbol{x} = \boldsymbol{a} - \boldsymbol{a}'$ と取れば $\|\boldsymbol{a} - \boldsymbol{a}'\|^2 = 0$、すなわち $\boldsymbol{a} = \boldsymbol{a}'$ である。一意なので(2.6)の右辺は基底の取り方に依存しない。

ノルム. Cauchy–Schwarz より $|\varphi(\boldsymbol{x})| = |\langle \boldsymbol{x}, \boldsymbol{a} \rangle| \le \|\boldsymbol{a}\| \|\boldsymbol{x}\|$ だから上限は $\|\boldsymbol{a}\|$ 以下。$\boldsymbol{a} \neq \boldsymbol{0}$ なら $\boldsymbol{x} = \boldsymbol{a}/\|\boldsymbol{a}\|$ で $\varphi(\boldsymbol{x}) = \|\boldsymbol{a}\|$ となり等号が達成される（$\boldsymbol{a} = \boldsymbol{0}$ なら $\varphi \equiv 0$）。 ■

数値で確かめておく。$d = 5$ で $\varphi(\boldsymbol{x}) = \langle \boldsymbol{x}, \boldsymbol{a} \rangle$（$\boldsymbol{a}$ は乱数）と定め、無作為な二つの正規直交基底から(2.6)で表現ベクトルを作ると、どちらも真の $\boldsymbol{a}$ と 1.1×10^{-16} の範囲で一致し、$\boldsymbol{x} = \boldsymbol{a}/\|\boldsymbol{a}\|$ で $\varphi(\boldsymbol{x}) = \|\boldsymbol{a}\| = 0.861015$ の等号が成り立つ。

この命題が言っていること

$\mathbb{R}^d$ 上の線形汎関数の全体（**双対空間** $(\mathbb{R}^d)^*$）は $\mathbb{R}^d$ 自身と **同一視できる**。標準内積のもとで φ は行ベクトル $\boldsymbol{a}^\top$ に、表現ベクトルは列ベクトル $\boldsymbol{a}$ に対応する。データ解析でこれが顔を出す場面は多い。

- **勾配**：微分可能な $F:\mathbb{R}^d\to\mathbb{R}$ の点 $\boldsymbol{x}$ での微分は線形汎関数 $\boldsymbol{h}\mapsto \lim_{t\to 0}\big(F(\boldsymbol{x}+t\boldsymbol{h})-F(\boldsymbol{x})\big)/t$ である。その表現ベクトルが**勾配** $\nabla F(\boldsymbol{x})$ であり、$\mathrm{d}F(\boldsymbol{x})[\boldsymbol{h}]=\langle \boldsymbol{h},\nabla F(\boldsymbol{x})\rangle$ と書ける（2.9節の行列微分はこの対応の計算法である）。
- **評価汎関数**：「関数 f を点 $\boldsymbol{x}$ で評価する」$f\mapsto f(\boldsymbol{x})$ も線形汎関数である。これを内積で書いたものが再生核であり、無限次元での同じ主張が第7章の Riesz の表現定理（定理 7.18）と再生性 $f(\boldsymbol{x})=\langle f,k(\cdot,\boldsymbol{x})\rangle$ になる。

無限次元では本命題は**そのままでは成り立たない**。証明が「有限個の基底で展開する」に依っているためで、一般の Hilbert 空間では φ が**有界**であることを仮定し、完備性を使う必要がある（定理 7.18）。有限次元では有界性が自動的についてくる——それを示したのが本命題の最後の主張である。

2.4　直交射影

「データを k 次元に圧縮する」とは「k 次元部分空間へ落とす」ことであり、落とし方のうち**誤差が最小になる**ものが直交射影である。PCA も最小二乗法も「どの部分空間へ射影するか」を選ぶ問題として書ける。

定理 2.12 (直交射影の存在と一意性)**.** $V\subset\mathbb{R}^m$ を k 次元部分空間とする。任意の $\boldsymbol{x}\in\mathbb{R}^m$ に対し、$\boldsymbol{x}=\boldsymbol{v}+\boldsymbol{z}$, $\boldsymbol{v}\in V$, $\boldsymbol{z}\perp V$ を満たす分解がただ一つ存在する。この $\boldsymbol{v}$ を $\boldsymbol{P}_V\boldsymbol{x}$ と書き、$\boldsymbol{x}$ の V への**直交射影**という。

証明.（存在）定理 2.10により V の正規直交基底 $\boldsymbol{u}_1,\dots,\boldsymbol{u}_k$ をとる。$\boldsymbol{v}:=\sum_i\langle\boldsymbol{x},\boldsymbol{u}_i\rangle\boldsymbol{u}_i\in V$, $\boldsymbol{z}:=\boldsymbol{x}-\boldsymbol{v}$ とおくと各 j で $\langle\boldsymbol{z},\boldsymbol{u}_j\rangle=\langle\boldsymbol{x},\boldsymbol{u}_j\rangle-\langle\boldsymbol{x},\boldsymbol{u}_j\rangle=0$ であり、V の任意の元は $\boldsymbol{u}_j$ の一次結合だから $\boldsymbol{z}\perp V$。（一意性）$\boldsymbol{x}=\boldsymbol{v}+\boldsymbol{z}=\boldsymbol{v}'+\boldsymbol{z}'$ が二通りの分解なら $\boldsymbol{v}-\boldsymbol{v}'=\boldsymbol{z}'-\boldsymbol{z}$。左辺は V の元、右辺は V に直交する元だから、この共通のベクトルを $\boldsymbol{d}$ とおけば $\langle\boldsymbol{d},\boldsymbol{d}\rangle=0$、ゆえに $\boldsymbol{d}=\boldsymbol{0}$。 ■

$\boldsymbol{U}=(\boldsymbol{u}_1\ \cdots\ \boldsymbol{u}_k)$（$\boldsymbol{U}^\top\boldsymbol{U}=\boldsymbol{I}_k$）とすれば $\langle\boldsymbol{x},\boldsymbol{u}_i\rangle=\boldsymbol{u}_i^\top\boldsymbol{x}$ だから、証明中の表示は行列で

$$\boldsymbol{P}_V\boldsymbol{x}=\sum_{i=1}^{k}\boldsymbol{u}_i(\boldsymbol{u}_i^\top\boldsymbol{x})=\boldsymbol{U}\boldsymbol{U}^\top\boldsymbol{x},\qquad\text{すなわち}\quad \boldsymbol{P}_V=\boldsymbol{U}\boldsymbol{U}^\top. \tag{2.7}$$

$\boldsymbol{U}$ の取り方には自由度があるが、$\boldsymbol{P}_V$ は定理 2.12の一意性から V のみで決まる。

定理 2.13 (射影行列の特徴づけ)**.** $\boldsymbol{P}\in\mathbb{R}^{m\times m}$ について、(a) ある部分空間 V が存在して $\boldsymbol{P}=\boldsymbol{P}_V$、(b) $\boldsymbol{P}^\top=\boldsymbol{P}$ かつ $\boldsymbol{P}^2=\boldsymbol{P}$、は同値である。このとき $V=\mathrm{Im}(\boldsymbol{P})$ であり $\operatorname{rank}\boldsymbol{P}=\operatorname{tr}\boldsymbol{P}=\dim V$。ここで $\mathrm{Im}(\boldsymbol{P})=\{\boldsymbol{P}\boldsymbol{u}:\boldsymbol{u}\in\mathbb{R}^m\}$ は $\boldsymbol{P}$ の像（定義 2.1）、$\dim V$ は V の次元である。

証明. (a)⇒(b)：$\boldsymbol{P}=\boldsymbol{U}\boldsymbol{U}^\top$ より $\boldsymbol{P}^\top=\boldsymbol{P}$、$\boldsymbol{P}^2=\boldsymbol{U}(\boldsymbol{U}^\top\boldsymbol{U})\boldsymbol{U}^\top=\boldsymbol{P}$。

(b)⇒(a)：$V:=\mathrm{Im}(\boldsymbol{P})$ とおき、$\boldsymbol{x}=\boldsymbol{P}\boldsymbol{x}+(\boldsymbol{x}-\boldsymbol{P}\boldsymbol{x})$ と分解する。第一項は V の元。V の任意の元は $\boldsymbol{P}\boldsymbol{y}$ と書けるから $\langle\boldsymbol{x}-\boldsymbol{P}\boldsymbol{x},\boldsymbol{P}\boldsymbol{y}\rangle=\boldsymbol{x}^\top\boldsymbol{P}\boldsymbol{y}-\boldsymbol{x}^\top\boldsymbol{P}^\top\boldsymbol{P}\boldsymbol{y}=\boldsymbol{x}^\top\boldsymbol{P}\boldsymbol{y}-\boldsymbol{x}^\top\boldsymbol{P}^2\boldsymbol{y}=0$（$\boldsymbol{P}^\top=\boldsymbol{P}$ と $\boldsymbol{P}^2=\boldsymbol{P}$ を使った）。よって $\boldsymbol{x}-\boldsymbol{P}\boldsymbol{x}\perp V$ となり、定理 2.12の一意性から $\boldsymbol{P}\boldsymbol{x}=\boldsymbol{P}_V\boldsymbol{x}$。最後の主張は $\boldsymbol{P}=\boldsymbol{U}\boldsymbol{U}^\top$ と書けば $\operatorname{tr}\boldsymbol{P}=\operatorname{tr}(\boldsymbol{U}^\top\boldsymbol{U})=k$、$\boldsymbol{U}$ が列フルランクだから $\operatorname{rank}\boldsymbol{P}=k$。 ■

主張の後半は、**射影先の部分空間は射影行列自身から復元できる**という意味である。$\boldsymbol{P}$ を与えられたとき、それがどの V への射影かは $V=\mathrm{Im}(\boldsymbol{P})$ で読み取れる。さらにその次元は、固有値を数えるまでもなく**トレースを取るだけ**で分かる。たとえば中心化行列 $\boldsymbol{H}=\boldsymbol{I}_n-\frac{1}{n}\boldsymbol{1}_n\boldsymbol{1}_n^\top$ は対称かつべき等なので (b) を満たし、$\operatorname{tr}\boldsymbol{H}=n-\frac{1}{n}\operatorname{tr}(\boldsymbol{1}_n\boldsymbol{1}_n^\top)=n-1$ から、$\boldsymbol{H}$ は $n-1$ 次元部分空間 $\{\boldsymbol{v}\in\mathbb{R}^n:\sum_i v_i=0\}$ への射影と分かる。

定理 2.14 (最良近似性質とピタゴラスの定理)**.** V を部分空間、$\boldsymbol{P}=\boldsymbol{P}_V$ とする。任意の $\boldsymbol{x}\in\mathbb{R}^m$ と $\boldsymbol{v}\in V$ に対し

$$\|\boldsymbol{x}-\boldsymbol{v}\|^2=\|\boldsymbol{x}-\boldsymbol{P}\boldsymbol{x}\|^2+\|\boldsymbol{P}\boldsymbol{x}-\boldsymbol{v}\|^2\ \geq\ \|\boldsymbol{x}-\boldsymbol{P}\boldsymbol{x}\|^2, \tag{2.8}$$

すなわち $\boldsymbol{P}\boldsymbol{x}$ は V の中で $\boldsymbol{x}$ にもっとも近い点であり、等号は $\boldsymbol{v}=\boldsymbol{P}\boldsymbol{x}$ に限る。また $\|\boldsymbol{x}\|^2=\|\boldsymbol{P}\boldsymbol{x}\|^2+\|\boldsymbol{x}-\boldsymbol{P}\boldsymbol{x}\|^2$。

証明. $\boldsymbol{x}-\boldsymbol{v}=(\boldsymbol{x}-\boldsymbol{P}\boldsymbol{x})+(\boldsymbol{P}\boldsymbol{x}-\boldsymbol{v})$ と分解すると、$\boldsymbol{x}-\boldsymbol{P}\boldsymbol{x}\perp V$ かつ $\boldsymbol{P}\boldsymbol{x}-\boldsymbol{v}\in V$ だから二つは直交し、交差項が消えて式 (2.8)を得る。右辺第二項が 0 となるのは $\boldsymbol{v}=\boldsymbol{P}\boldsymbol{x}$ のときに限る。後半は式 (2.8)で $\boldsymbol{v}=\boldsymbol{0}$ とおけばよい。 ■

図 2.1に $\mathbb{R}^2$ での様子を示した。$\|\boldsymbol{x}\|^2=\|\boldsymbol{P}\boldsymbol{x}\|^2+\|\boldsymbol{x}-\boldsymbol{P}\boldsymbol{x}\|^2$ はこれから何度も使う。「射影後の大きさの最大化」と「残差の最小化」が同じ問題の裏表だという主張であり、第3章で PCA の二つの定式化が一致する理由である。

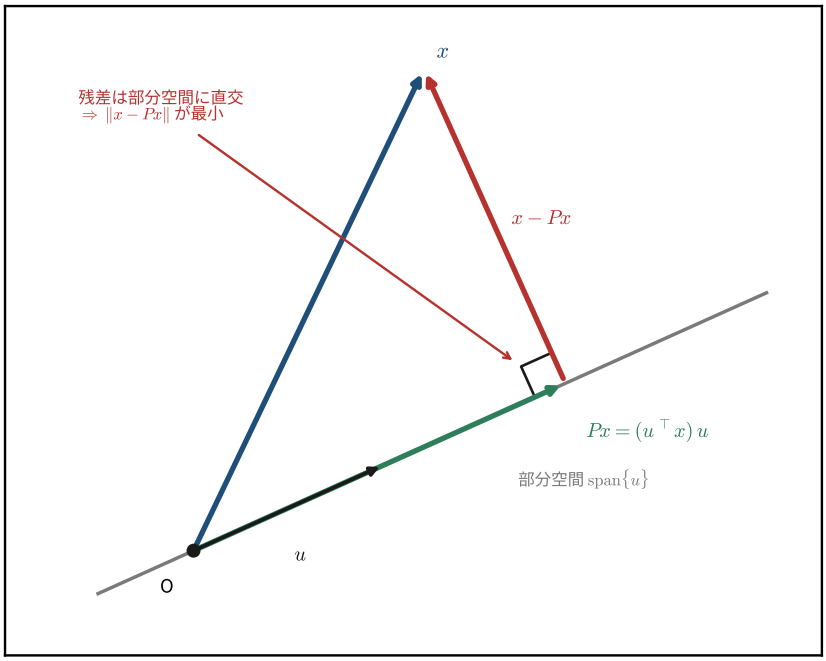


図2.1　$\mathbb{R}^2$ における直交射影。直線 $\mathrm{span}\{\boldsymbol{u}\}$ に $\boldsymbol{x}$ を落とした点が $\boldsymbol{Px}$ で、残差 $\boldsymbol{x}-\boldsymbol{Px}$ は直線と直交する。この直角が定理 2.14の分解を生み、「近似誤差最小」と「残差が直交」が同じことだという内容を与える。

例 2.15 (中心化行列は射影行列)**.** $\boldsymbol{u}\coloneqq \mathbf{1}/\sqrt{n}$ とおけば $\|\boldsymbol{u}\|=1$ であり、中心化行列は $\boldsymbol{H}=\boldsymbol{I}_n-\boldsymbol{u}\boldsymbol{u}^\top$ と書ける。$\boldsymbol{u}\boldsymbol{u}^\top$ は式 (2.7)の形だから $\mathrm{span}\{\mathbf{1}\}$ への射影行列であり、$\boldsymbol{H}$ はその直交補空間 $\mathbf{1}^\perp=\{\boldsymbol{z}\in\mathbb{R}^n:\sum_i z_i=0\}$ への射影行列である。実際 $\boldsymbol{H}^\top=\boldsymbol{H}$ かつ $(\mathbf{1}^\top\mathbf{1}=n$ より$)$ $\boldsymbol{H}^2=\boldsymbol{I}-\frac{2}{n}\mathbf{1}\mathbf{1}^\top+\frac{1}{n^2}\mathbf{1}(\mathbf{1}^\top\mathbf{1})\mathbf{1}^\top=\boldsymbol{H}$、また $\operatorname{tr}\boldsymbol{H}=n-1$ だから射影先の次元は $n-1$。つまり「平均を引く」前処理は、データ行列の各**行**ベクトル（第 j 変数の n 個の観測値を並べた $\mathbb{R}^n$ の元）を「成分の和が 0 の超平面」へ直交射影する操作である。$\boldsymbol{H}$ が $n\times n$ で右から掛かること（$\widetilde{\boldsymbol{X}}=\boldsymbol{X}\boldsymbol{H}$）と、この読み方は同じことを言っている。標本共分散が $\widehat{\boldsymbol{\Sigma}}=\frac{1}{n}\boldsymbol{X}\boldsymbol{H}\boldsymbol{X}^\top$ とも書けるのは $\boldsymbol{H}^2=\boldsymbol{H}$, $\boldsymbol{H}^\top=\boldsymbol{H}$ による。

2.5　スペクトル定理と Rayleigh 商

データ解析に現れる正方行列はほとんどが対称行列である。$\boldsymbol{X}\boldsymbol{X}^\top$、$\boldsymbol{X}^\top\boldsymbol{X}$、共分散行列 $\widehat{\boldsymbol{\Sigma}}$、グラム行列 $\boldsymbol{K}$ はいずれも対称かつ半正定値であり、このクラスに対しては固有値分解が「もっとも良い形」で存在する。それがスペクトル定理である。

補題 2.16. 実対称行列 $\boldsymbol{A}\in\mathbb{R}^{m\times m}$ の固有値はすべて実数であり、実固有ベクトルがとれる。

証明. $\boldsymbol{A}\boldsymbol{z}=\lambda\boldsymbol{z}$, $\boldsymbol{z}\in\mathbb{C}^m\setminus\{\mathbf{0}\}$ とする（複素数の範囲では代数学の基本定理から固有値は存在する）。$\bar{\boldsymbol{z}}^\top$ を左からかけると $\bar{\boldsymbol{z}}^\top\boldsymbol{A}\boldsymbol{z}=\lambda\|\boldsymbol{z}\|^2$。一方 $\boldsymbol{A}$ が実対称であることから $\overline{\bar{\boldsymbol{z}}^\top\boldsymbol{A}\bar{\boldsymbol{z}}}=\boldsymbol{z}^\top\boldsymbol{A}\bar{\boldsymbol{z}}=(\boldsymbol{z}^\top\boldsymbol{A}\bar{\boldsymbol{z}})^\top=\bar{\boldsymbol{z}}^\top\boldsymbol{A}^\top\boldsymbol{z}=\bar{\boldsymbol{z}}^\top\boldsymbol{A}\boldsymbol{z}$ なので $\bar{\boldsymbol{z}}^\top\boldsymbol{A}\boldsymbol{z}$ は実数であり、$\|\boldsymbol{z}\|^2>0$ より $\lambda\in\mathbb{R}$。λ が実なら $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{z}=\mathbf{0}$ は実係数の同次連立一次方程式で、$\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$ だから実の非零解をもつ。 ■

補題 2.17. 実対称行列 $\boldsymbol{A}$ の相異なる固有値 $\lambda\neq\mu$ に属する固有ベクトル $\boldsymbol{u},\boldsymbol{v}$ は直交する。

証明. $\lambda\langle\boldsymbol{u},\boldsymbol{v}\rangle=(\boldsymbol{A}\boldsymbol{u})^\top\boldsymbol{v}=\boldsymbol{u}^\top\boldsymbol{A}^\top\boldsymbol{v}=\boldsymbol{u}^\top\boldsymbol{A}\boldsymbol{v}=\mu\langle\boldsymbol{u},\boldsymbol{v}\rangle$ より $(\lambda-\mu)\langle\boldsymbol{u},\boldsymbol{v}\rangle=0$、$\lambda\neq\mu$ から $\langle\boldsymbol{u},\boldsymbol{v}\rangle=0$。 ■

定理 2.18 (スペクトル定理)**.** 実対称行列 $\boldsymbol{A}\in\mathbb{R}^{m\times m}$ に対し、直交行列 $\boldsymbol{U}=(\boldsymbol{u}_1\ \cdots\ \boldsymbol{u}_m)$ と実対角行列 $\boldsymbol{\Lambda}=\mathrm{diag}(\lambda_1,\dots,\lambda_m)$, $\lambda_1\geq\cdots\geq\lambda_m$ が存在して

$$\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^\top=\sum_{i=1}^{m}\lambda_i\boldsymbol{u}_i\boldsymbol{u}_i^\top. \tag{2.9}$$

証明. m についての帰納法。$m=1$ は自明。$m-1$ 以下で成立するとする。補題 2.16により実固有値 λ_1 と実単位固有ベクトル $\boldsymbol{u}_1$ がとれる。$W\coloneqq\boldsymbol{u}_1^\perp$（$m-1$ 次元）は $\boldsymbol{A}$ で不変である：$\boldsymbol{w}\in W$ に対し $\langle\boldsymbol{A}\boldsymbol{w},\boldsymbol{u}_1\rangle=\boldsymbol{w}^\top\boldsymbol{A}\boldsymbol{u}_1=\lambda_1\langle\boldsymbol{w},\boldsymbol{u}_1\rangle=0$。$W$ の正規直交基底を列にもつ $\boldsymbol{Q}\in\mathbb{R}^{m\times(m-1)}$ をとると $\boldsymbol{A}'\coloneqq\boldsymbol{Q}^\top\boldsymbol{A}\boldsymbol{Q}$ は対称だから、帰納法の仮定より $\boldsymbol{A}'=\boldsymbol{Q}'\boldsymbol{\Lambda}'\boldsymbol{Q}'^\top$ と直交対角化できる。$\boldsymbol{U}\coloneqq(\boldsymbol{u}_1\ \ \boldsymbol{Q}\boldsymbol{Q}')$ とおけば、$\boldsymbol{Q}\boldsymbol{Q}'$ の列は W の正規直交基底で $\boldsymbol{u}_1$ と直交するから $\boldsymbol{U}$ は直交行列である。W の不変性から $\boldsymbol{A}\boldsymbol{Q}=\boldsymbol{Q}\boldsymbol{A}'$ なので $\boldsymbol{A}(\boldsymbol{Q}\boldsymbol{Q}')=\boldsymbol{Q}\boldsymbol{A}'\boldsymbol{Q}'=\boldsymbol{Q}\boldsymbol{Q}'\boldsymbol{\Lambda}'$、よって $\boldsymbol{A}\boldsymbol{U}=\boldsymbol{U}\,\mathrm{diag}(\lambda_1,\boldsymbol{\Lambda}')$、すなわち $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^\top$。最後に列を固有値の降順に並べ替えればよい。 ■

式 (2.9)右側の**ランク 1 行列の重みつき和**という読み方が実用上大切である。λ_i が急速に減衰するなら上位数項だけで $\boldsymbol{A}$ をよく近似できる。これが低ランク近似の発想であり、2.7節で厳密化される。

定理 2.19 (半正定値性の同値な特徴づけ)**.** 実対称行列 $\boldsymbol{A}$ について、(a) 固有値がすべて非負、(b) 任意の $\boldsymbol{x}$ に対し $\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} \geq 0$、(c) ある $\boldsymbol{B}$ が存在して $\boldsymbol{A} = \boldsymbol{B}^{\top}\boldsymbol{B}$、は同値である。これらが成り立つとき $\boldsymbol{A}$ を**半正定値**（positive semidefinite）といい $\boldsymbol{A} \succeq 0$ と書く。

証明. (a)⇒(c)：$\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^{\top}$, $\lambda_i \geq 0$ だから $\boldsymbol{\Lambda}^{1/2} = \operatorname{diag}(\sqrt{\lambda_i})$ が定義でき、$\boldsymbol{B} \coloneqq \boldsymbol{\Lambda}^{1/2}\boldsymbol{U}^{\top}$ とおけば $\boldsymbol{B}^{\top}\boldsymbol{B} = \boldsymbol{A}$。(c)⇒(b)：$\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} = \|\boldsymbol{B}\boldsymbol{x}\|^2 \geq 0$。(b)⇒(a)：$0 \leq \boldsymbol{u}_i^{\top}\boldsymbol{A}\boldsymbol{u}_i = \lambda_i$。 ■

系として任意の $\boldsymbol{X}$ に対し $\boldsymbol{X}\boldsymbol{X}^{\top} \succeq 0$ かつ $\boldsymbol{X}^{\top}\boldsymbol{X} \succeq 0$ である。データから作られる二つの正方行列は自動的に半正定値で、その固有値を σ_i^2 と書けることが 2.6節の伏線になる。

2.5.1　Rayleigh 商と Courant–Fischer の定理

「もっとも分散の大きい方向」を探すという PCA の問題は、次の量の最大化に帰着する。

定義 2.20 (Rayleigh 商)**.** 対称行列 $\boldsymbol{A}$ に対し、$\boldsymbol{x} \neq \boldsymbol{0}$ について $R_{\boldsymbol{A}}(\boldsymbol{x}) \coloneqq \boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} / \boldsymbol{x}^{\top}\boldsymbol{x}$ を **Rayleigh 商**という。$R_{\boldsymbol{A}}(c\boldsymbol{x}) = R_{\boldsymbol{A}}(\boldsymbol{x})$ だから方向のみに依存する量であり、$\|\boldsymbol{x}\| = 1$ に制限して $\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}$ を考えるのと同じである。

定理 2.21 (Rayleigh 商の最大最小と逐次最大化)**.** $\boldsymbol{A}$ を対称行列、$\lambda_1 \geq \cdots \geq \lambda_m$ をその固有値、$\boldsymbol{u}_1, \dots, \boldsymbol{u}_m$ を対応する正規直交固有ベクトルとする。このとき (i) $\max_{\boldsymbol{x}\neq\boldsymbol{0}} R_{\boldsymbol{A}}(\boldsymbol{x}) = \lambda_1$（最大は $\boldsymbol{x} = \boldsymbol{u}_1$ で達成）、$\min_{\boldsymbol{x}\neq\boldsymbol{0}} R_{\boldsymbol{A}}(\boldsymbol{x}) = \lambda_m$。(ii) $k \geq 2$ のとき $\max\{R_{\boldsymbol{A}}(\boldsymbol{x}) : \boldsymbol{x} \neq \boldsymbol{0},\ \boldsymbol{x} \perp \boldsymbol{u}_1, \dots, \boldsymbol{u}_{k-1}\} = \lambda_k$ であり、$\boldsymbol{x} = \boldsymbol{u}_k$ で達成される。

証明. (i) $\|\boldsymbol{x}\| = 1$ としてよい。$\boldsymbol{x} = \sum_i c_i \boldsymbol{u}_i$, $c_i = \langle \boldsymbol{x}, \boldsymbol{u}_i \rangle$ と展開すると Parseval の等式（命題 2.9(ii)）より $\sum_i c_i^2 = 1$ であり、式 (2.9)から

$$\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} = \Big(\sum_i c_i \boldsymbol{u}_i\Big)^{\top}\Big(\sum_j \lambda_j \boldsymbol{u}_j \boldsymbol{u}_j^{\top}\Big)\Big(\sum_l c_l \boldsymbol{u}_l\Big) = \sum_{i=1}^{m} \lambda_i c_i^2 . \tag{2.10}$$

$\lambda_i \leq \lambda_1$, $c_i^2 \geq 0$ から $\sum_i \lambda_i c_i^2 \leq \lambda_1 \sum_i c_i^2 = \lambda_1$ であり、$\boldsymbol{x} = \boldsymbol{u}_1$ で等号。最小の場合も同様。(ii) 制約 $\boldsymbol{x} \perp \boldsymbol{u}_1, \dots, \boldsymbol{u}_{k-1}$ は $c_1 = \cdots = c_{k-1} = 0$ を意味するから、式 (2.10)は $\sum_{i \geq k} \lambda_i c_i^2 \leq \lambda_k \sum_{i \geq k} c_i^2 = \lambda_k$ となり、$\boldsymbol{x} = \boldsymbol{u}_k$ で等号となる。 ■

(ii) は「第 1 主成分を求め、それに直交する範囲で第 2 主成分を求め、…」という PCA の逐次的な定義が固有ベクトルを与えることを保証する。ただし (ii) は「$\boldsymbol{u}_1, \dots, \boldsymbol{u}_{k-1}$ に直交」という**特定の**制約のもとでの話であり、制約部分空間を自由に選べるようにしたのが次の定理である（摂動論や高次元統計（第5章）で効く）。

コラム：名前を残しすぎた物理学者——レイリー卿と Rayleigh 商

Rayleigh 商という名前は、イギリスの物理学者 **レイリー卿**（Lord Rayleigh、本名 John William Strutt, 1842–1919）に由来する。

Rayleigh と聞いて多くの人がまず思い浮かべるのは**レイリー散乱**だろう。大気中の微粒子による散乱は波長の短い光ほど強く、これが空の青さを説明する。彼はまた気体の密度を精密に測る研究から新元素アルゴンの発見（William Ramsay と共同）につながり、1904 年のノーベル物理学賞を受けている。

しかし彼の研究の中心の一つは**音と振動**であった。1877–78 年の大著 *The Theory of Sound*[64] は、弦・膜・気柱の振動を数学的に解析している。振動する系を離散化すると、その固有振動は

$$\boldsymbol{K}\boldsymbol{x} = \omega^2 \boldsymbol{M}\boldsymbol{x} \tag{2.11}$$

という一般化固有値問題（第6章で本格的に扱う）として表される。ここで $\boldsymbol{K}$ は剛性行列、$\boldsymbol{M}$ は質量行列、ω は固有角振動数である。

Rayleigh が着目したのは、ω^2 を 式 (2.11) を解いて求めるのではなく、**エネルギーの比**として捉える見方であった。振動の形を $\boldsymbol{x}$ とすると

$$\omega^2 \simeq \frac{\boldsymbol{x}^{\top}\boldsymbol{K}\boldsymbol{x}}{\boldsymbol{x}^{\top}\boldsymbol{M}\boldsymbol{x}} \tag{2.12}$$

という量が現れる。分子は変形に蓄えられるポテンシャルエネルギー、分母は運動エネルギーに関係する量である。$\boldsymbol{x}$ が真の固有振動モードであればこれは近似ではなく厳密に ω^2 を与え、さらに**真のモードの近くではこの比が一次の変化に対して動かない**。すなわち固有モードにおいてこの比は**停留値**をとる。実際、$\boldsymbol{x} = \boldsymbol{u}_1 + \varepsilon \boldsymbol{p}$（$\boldsymbol{p} \perp \boldsymbol{u}_1$、$\|\boldsymbol{p}\| = 1$）とおくと $\lambda_1 - R_{\boldsymbol{A}}(\boldsymbol{x}) = O(\varepsilon^2)$ であり、ε を 10 分の 1 にすると差は 100 分の 1 になる（演習 2.10で確かめる）。この停留性が、粗い試行関数からでも固有振動数の良い近似が得られる **Rayleigh–Ritz 法**の原理であり、第4章のべき乗法・Lanczos 法にも通じている。

> 質量行列を $\boldsymbol{M}=\boldsymbol{I}$ とすれば $\boldsymbol{x}^\top\boldsymbol{A}\boldsymbol{x}/\boldsymbol{x}^\top\boldsymbol{x}$、すなわち現在 Rayleigh 商と呼ばれる形になる。この見方の面白さは、固有値を $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$ という**方程式の解**としてではなく、**ある量の最大値・最小値**として捉えられる点にある（定理 2.21）。つまり Rayleigh 商は単なる便利な式ではない。その背景には「物体はどの形で振動するのか、その振動数をエネルギーからどう求めるのか」という 19 世紀の物理の問題がある。
>
> 空の青さを説明し、新元素を発見し、音の振動を研究し、そして現代の固有値計算にも名を残した Rayleigh。本講義でも Rayleigh 商は PCA（第3章）から Fisher の判別分析・スペクトラルクラスタリング（第6章）まで、繰り返し主役として現れる。一つの数式の背後に、数学と物理がまだほとんど切り離されていなかった時代の歴史が隠れているのである。

定理 2.22 (Courant–Fischer の最大最小定理)**.** 対称行列 $\boldsymbol{A}$ の固有値を $\lambda_1\ge\cdots\ge\lambda_m$ とすると、各 k について

$$\lambda_k=\max_{\dim S=k}\ \min_{\boldsymbol{0}\neq\boldsymbol{x}\in S} R_{\boldsymbol{A}}(\boldsymbol{x})=\min_{\dim S=m-k+1}\ \max_{\boldsymbol{0}\neq\boldsymbol{x}\in S} R_{\boldsymbol{A}}(\boldsymbol{x})\qquad (S\subset\mathbb{R}^m \text{ は部分空間}). \tag{2.13}$$

証明. 第一の等式を示す（第二も同様）。$S_0:=\operatorname{span}\{\boldsymbol{u}_1,\dots,\boldsymbol{u}_k\}$ をとると、$\boldsymbol{x}\in S_0$, $\|\boldsymbol{x}\|=1$ なら式 (2.10)で $c_i=0$ $(i>k)$ だから $\boldsymbol{x}^\top\boldsymbol{A}\boldsymbol{x}=\sum_{i\le k}\lambda_i c_i^2\ge\lambda_k$。よって右辺の最大値は λ_k 以上。

逆向き。$\dim S=k$ なる任意の S と $T:=\operatorname{span}\{\boldsymbol{u}_k,\dots,\boldsymbol{u}_m\}$（次元 $m-k+1$）に対し、$\dim S+\dim T=m+1>m$ だから $S\cap T\neq\{\boldsymbol{0}\}$ であり、単位ベクトル $\boldsymbol{x}\in S\cap T$ がとれる。$\boldsymbol{x}\in T$ より $c_i=0$ $(i<k)$ だから $\boldsymbol{x}^\top\boldsymbol{A}\boldsymbol{x}=\sum_{i\ge k}\lambda_i c_i^2\le\lambda_k$。したがって $\min_{\boldsymbol{0}\neq\boldsymbol{x}\in S}R_{\boldsymbol{A}}(\boldsymbol{x})\le\lambda_k$ がすべての S で成り立ち、最大値はちょうど λ_k である。 ∎

もう一つ、一本の方向ではなく k 本の正規直交系をまとめて動かす版を用意しておく（2.7節と第3章の両方で使う）。

系 2.23 (トレース最大化、Ky Fan)**.** 対称行列 $\boldsymbol{A}$ の固有値を $\lambda_1\ge\cdots\ge\lambda_m$ とすると

$$\max\{\operatorname{tr}(\boldsymbol{Q}^\top\boldsymbol{A}\boldsymbol{Q}):\boldsymbol{Q}\in\mathbb{R}^{m\times k},\ \boldsymbol{Q}^\top\boldsymbol{Q}=\boldsymbol{I}_k\}=\sum_{i=1}^{k}\lambda_i, \tag{2.14}$$

最大は $\boldsymbol{Q}=(\boldsymbol{u}_1\ \cdots\ \boldsymbol{u}_k)$ で達成される。

証明. $\boldsymbol{Q}$ の列を $\boldsymbol{q}_1,\dots,\boldsymbol{q}_k$（正規直交）とすると $\operatorname{tr}(\boldsymbol{Q}^\top\boldsymbol{A}\boldsymbol{Q})=\sum_j\boldsymbol{q}_j^\top\boldsymbol{A}\boldsymbol{q}_j=\sum_j\sum_i\lambda_i(\boldsymbol{u}_i^\top\boldsymbol{q}_j)^2=\sum_{i=1}^m\lambda_i c_i$、ただし $c_i:=\sum_{j=1}^k(\boldsymbol{u}_i^\top\boldsymbol{q}_j)^2$。Bessel の不等式（命題 2.9(iii)）を正規直交系 $\boldsymbol{q}_1,\dots,\boldsymbol{q}_k$ と単位ベクトル $\boldsymbol{u}_i$ に適用して $0\le c_i\le 1$、また Parseval の等式（命題 2.9(ii)）より $\sum_i c_i=\sum_j\|\boldsymbol{q}_j\|^2=k$。したがって

$$\sum_i\lambda_i c_i-\sum_{i\le k}\lambda_i=\sum_{i\le k}\lambda_i(c_i-1)+\sum_{i>k}\lambda_i c_i\le\lambda_k\Big(\sum_i c_i-k\Big)=0$$

（$i\le k$ では $c_i-1\le 0$ かつ $\lambda_i\ge\lambda_k$、$i>k$ では $c_i\ge 0$ かつ $\lambda_i\le\lambda_k$ を使った）。$\boldsymbol{Q}=(\boldsymbol{u}_1\ \cdots\ \boldsymbol{u}_k)$ では $c_i=\mathbf{1}\{i\le k\}$ となり等号が成り立つ。 ∎

例 2.24 (2×2 の手計算)**.** $\boldsymbol{A}=\begin{pmatrix}2&1\\1&2\end{pmatrix}$ とすると $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=(\lambda-1)(\lambda-3)$ より $\lambda_1=3,\lambda_2=1$。$(\boldsymbol{A}-3\boldsymbol{I})\boldsymbol{u}=\boldsymbol{0}$ は $-u_1+u_2=0$ だから $\boldsymbol{u}_1=\frac{1}{\sqrt{2}}(1,1)^\top$、同様に $\boldsymbol{u}_2=\frac{1}{\sqrt{2}}(1,-1)^\top$ で、確かに $\boldsymbol{u}_1\perp\boldsymbol{u}_2$（補題 2.17）。スペクトル分解は $\boldsymbol{A}=\frac{3}{2}\begin{pmatrix}1&1\\1&1\end{pmatrix}+\frac{1}{2}\begin{pmatrix}1&-1\\-1&1\end{pmatrix}$。Rayleigh 商は $\boldsymbol{x}=(\cos\theta,\sin\theta)^\top$ に対し $R_{\boldsymbol{A}}(\boldsymbol{x})=2+\sin 2\theta$ であり、$\theta=\pi/4$（$\boldsymbol{u}_1$ の方向）で最大値 3、$\theta=-\pi/4$ で最小値 1 をとる。定理 2.21の主張が具体的に見える。

2.6　特異値分解

スペクトル定理は対称な正方行列にしか使えないが、データ行列 $\boldsymbol{X}$ は一般に正方でも対称でもない。$\boldsymbol{X}$ そのものを分解する道具が**特異値分解**（singular value decomposition, SVD）であり、線形代数がデータ解析に与えたもっとも重要な定理といってよい。

定理 2.25 (特異値分解の存在)**.** 任意の $\boldsymbol{X}\in\mathbb{R}^{d\times n}$ に対し、直交行列 $\boldsymbol{U}\in\mathbb{R}^{d\times d}$, $\boldsymbol{V}\in\mathbb{R}^{n\times n}$ と $\sigma_1\ge\cdots\ge\sigma_p\ge 0$ $(p=\min(d,n))$ が存在して

$$\boldsymbol{X}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top,\qquad \boldsymbol{\Sigma}\in\mathbb{R}^{d\times n},\ \ \Sigma_{ii}=\sigma_i,\ \ \Sigma_{ij}=0\ (i\neq j). \tag{2.15}$$

σ_i を**特異値**、$\boldsymbol{U},\boldsymbol{V}$ の列を左・右**特異ベクトル**という。データ行列に適用するときは $\boldsymbol{U}$ の列が**変数側**（$\mathbb{R}^d$）、$\boldsymbol{V}$ の列が**サンプル側**（$\mathbb{R}^n$）に住むことに注意する。

証明. $\boldsymbol{X}\boldsymbol{X}^\top$（$d\times d$）は対称かつ半正定値（定理 2.19）だから、定理 2.18により正規直交固有ベクトル $\boldsymbol{u}_1,\dots,\boldsymbol{u}_d$ と固有値 $\lambda_1\ge\cdots\ge\lambda_d\ge 0$ がとれる。$p:=\min(d,n)$ とし、$i\le p$ に対して $\sigma_i:=\sqrt{\lambda_i}$、$r:=\#\{i:\lambda_i>0\}$ とおく。$\operatorname{rank}(\boldsymbol{X}\boldsymbol{X}^\top)=\operatorname{rank}\boldsymbol{X}\le p$ だから $r\le p$ であり、$d>n$ の場合に現れる添字 $i>p$ では自動的に $\lambda_i=0$ である（つまり σ_i を $i\le p$ でしか定めなくても情報は落ちない）。

$i\le r$ に対し $\boldsymbol{v}_i:=\boldsymbol{X}^\top\boldsymbol{u}_i/\sigma_i\in\mathbb{R}^n$ と定めると、これらは正規直交である：

$$\langle\boldsymbol{v}_i,\boldsymbol{v}_j\rangle=\frac{\boldsymbol{u}_i^\top\boldsymbol{X}\boldsymbol{X}^\top\boldsymbol{u}_j}{\sigma_i\sigma_j}=\frac{\lambda_j\,\boldsymbol{u}_i^\top\boldsymbol{u}_j}{\sigma_i\sigma_j}=\delta_{ij}. \tag{2.16}$$

$i>r$ のときは $\|\boldsymbol{X}^\top\boldsymbol{u}_i\|^2=\boldsymbol{u}_i^\top\boldsymbol{X}\boldsymbol{X}^\top\boldsymbol{u}_i=\lambda_i=0$ だから $\boldsymbol{X}^\top\boldsymbol{u}_i=\boldsymbol{0}$。$\boldsymbol{v}_1,\dots,\boldsymbol{v}_r$ を $\mathbb{R}^n$ の正規直交基底 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_n$ に拡張し（定理 2.10）、$\boldsymbol{U}=(\boldsymbol{u}_1\ \cdots\ \boldsymbol{u}_d)\in\mathbb{R}^{d\times d}$, $\boldsymbol{V}=(\boldsymbol{v}_1\ \cdots\ \boldsymbol{v}_n)\in\mathbb{R}^{n\times n}$ とおく。

示すべき $\boldsymbol{X}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$ は、両辺を転置して $\boldsymbol{U}$ を右から掛けた形 $\boldsymbol{X}^\top\boldsymbol{U}=\boldsymbol{V}\boldsymbol{\Sigma}^\top$ と同値である（$\boldsymbol{U}$ は直交行列）。両辺は $n\times d$ 行列なので、**第 i 列**（$i=1,\dots,d$）を比べればよい。左辺の第 i 列は $\boldsymbol{X}^\top\boldsymbol{u}_i\in\mathbb{R}^n$ である。一方 $\boldsymbol{\Sigma}^\top\in\mathbb{R}^{n\times d}$ の第 i 列は $\boldsymbol{\Sigma}$ の第 i 行を縦にしたものだから、$i\le p$ なら $\sigma_i\boldsymbol{e}_i$（$\boldsymbol{e}_i\in\mathbb{R}^n$）、$i>p$ なら $\boldsymbol{0}$ であり、右辺の第 i 列は

$$(\boldsymbol{V}\boldsymbol{\Sigma}^\top)_{:,i}=\begin{cases}\sigma_i\boldsymbol{v}_i, & i\le p,\\ \boldsymbol{0}, & i>p\quad(d>n\ \text{のときにのみ現れる添字})\end{cases} \tag{2.17}$$

となる。そこで i を三つに分けて確かめる。(a) $i\le r$：構成から $\boldsymbol{X}^\top\boldsymbol{u}_i=\sigma_i\boldsymbol{v}_i$。(b) $r<i\le p$：$\boldsymbol{X}^\top\boldsymbol{u}_i=\boldsymbol{0}$ で、$\sigma_i=0$ かつ $\boldsymbol{v}_i$ は（$i\le p\le n$ だから）確かに存在するので $\sigma_i\boldsymbol{v}_i=\boldsymbol{0}$ と一致する。(c) $i>p$（$d>n$ のときのみ）：$i>p\ge r$ より $\boldsymbol{X}^\top\boldsymbol{u}_i=\boldsymbol{0}$ であり、式 (2.17)の右辺も $\boldsymbol{0}$ である。この場合は **$\boldsymbol{v}_i$ を持ち出す必要がない**——必要なのは $\boldsymbol{\Sigma}^\top$ の第 i 列が $\boldsymbol{0}$ であることだけである。以上より $\boldsymbol{X}^\top\boldsymbol{U}=\boldsymbol{V}\boldsymbol{\Sigma}^\top$、すなわち $\boldsymbol{X}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$ を得る。最後に $\lambda_1\ge\cdots\ge\lambda_p$ から $\sigma_1\ge\cdots\ge\sigma_p\ge 0$ も従う。 ■

$\boldsymbol{u}_i$ と $\boldsymbol{v}_i$ で添字の走る範囲が違う

$\boldsymbol{u}_i\in\mathbb{R}^d$ は $i=1,\dots,d$、$\boldsymbol{v}_i\in\mathbb{R}^n$ は $i=1,\dots,n$ までしか存在しない。したがって $d>n$ のとき「$i>r$ では $\boldsymbol{X}^\top\boldsymbol{u}_i=\boldsymbol{0}=\sigma_i\boldsymbol{v}_i$」と**一息に書くのは誤り**で、$i=n+1,\dots,d$ には対応する $\boldsymbol{v}_i$ も σ_i も存在しない。上の証明が $r<i\le p$ と $i>p$ を分けたのはこのためであり、後者では $\boldsymbol{v}_i$ の代わりに $\boldsymbol{\Sigma}^\top$ の第 i 列が $\boldsymbol{0}$ であることを使う。逆に $d<n$ なら $i>p$ の添字は現れない代わりに、$\boldsymbol{V}$ の側で余った $\boldsymbol{v}_{r+1},\dots,\boldsymbol{v}_n$（$\operatorname{Ker}(\boldsymbol{X})$ を張る分。定理 2.26）が基底の拡張で補われる部分になり、$\boldsymbol{\Sigma}$ の右側の $n-p$ 列が $\boldsymbol{0}$ になる。$d\times n$ という向きを決めても**どちらが長いかは決まらない**ので、$p=\min(d,n)$ を明示して両方の場合を通す書き方をとるのが安全である。

証明の副産物として $\boldsymbol{X}\boldsymbol{X}^\top=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{\Sigma}^\top\boldsymbol{U}^\top$、$\boldsymbol{X}^\top\boldsymbol{X}=\boldsymbol{V}\boldsymbol{\Sigma}^\top\boldsymbol{\Sigma}\boldsymbol{V}^\top$ が読み取れる。つまり非零部分について「$\boldsymbol{X}\boldsymbol{X}^\top$ の固有値 $=\boldsymbol{X}^\top\boldsymbol{X}$ の固有値 $=\sigma_i^2$」であり、**左**特異ベクトル $\boldsymbol{u}_i$ は $\boldsymbol{X}\boldsymbol{X}^\top$（$d\times d$、中心化すれば共分散行列）の、**右**特異ベクトル $\boldsymbol{v}_i$ は $\boldsymbol{X}^\top\boldsymbol{X}$（$n\times n$、グラム行列）の固有ベクトルである。データ解析で「主成分方向」として使うのは前者、すなわち $\boldsymbol{U}$ の列である（第3章）。例 2.2で見た「非零固有値の一致」の正体がこれである。

完全 SVD と簡約 SVD。式 (2.15)は $\boldsymbol{U},\boldsymbol{V}$ が正方直交行列である **完全 SVD**（full SVD）である。$r=\operatorname{rank}\boldsymbol{X}$ とし、$\boldsymbol{U}_r,\boldsymbol{V}_r$ を上位 r 列、$\boldsymbol{\Sigma}_r=\operatorname{diag}(\sigma_1,\dots,\sigma_r)$ とすれば

$$\boldsymbol{X}=\boldsymbol{U}_r\boldsymbol{\Sigma}_r\boldsymbol{V}_r^\top=\sum_{i=1}^{r}\sigma_i\boldsymbol{u}_i\boldsymbol{v}_i^\top \tag{2.18}$$

であり、これを**簡約 SVD**（reduced/thin SVD）という。ここで $\boldsymbol{U}_r\in\mathbb{R}^{d\times r}$、$\boldsymbol{V}_r\in\mathbb{R}^{n\times r}$ である。$n\gg d$ のとき完全 SVD の $\boldsymbol{V}$ は $n\times n$ で巨大だが、簡約 SVD なら $n\times r$ で済む。式 (2.18)右端の「r 個のランク 1 行列の重みつき和」が以降の主役である。

幾何的意味。$\boldsymbol{X}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$ は「回転 → 座標軸方向への伸縮 → 回転」であり、任意の線形写像は入出力側に適切な直交座標系を選べば単なる対角の拡大縮小になる。$\boldsymbol{X}:\mathbb{R}^n\to\mathbb{R}^d$ は入力側（$\mathbb{R}^n$）の単位球を出力側（$\mathbb{R}^d$）の楕円体に写し、主軸の長さが $\sigma_1,\dots,\sigma_p$、方向が $\boldsymbol{u}_1,\dots,\boldsymbol{u}_p$（$\mathbb{R}^d$ の中）である（図 2.2）。とくに $\sigma_1=\max_{\|\boldsymbol{c}\|=1}\|\boldsymbol{X}\boldsymbol{c}\|$（作用素ノルム）。

定理 2.26 (4 つの基本部分空間)**.** $r=\operatorname{rank}\boldsymbol{X}$ とし式 (2.15)の記号を用いると

$$\operatorname{Im}(\boldsymbol{X})=\operatorname{span}\{\boldsymbol{u}_1,\dots,\boldsymbol{u}_r\}\subset\mathbb{R}^d,\qquad \operatorname{Ker}(\boldsymbol{X}^\top)=\operatorname{span}\{\boldsymbol{u}_{r+1},\dots,\boldsymbol{u}_d\}\subset\mathbb{R}^d,$$
$$\operatorname{Im}(\boldsymbol{X}^\top)=\operatorname{span}\{\boldsymbol{v}_1,\dots,\boldsymbol{v}_r\}\subset\mathbb{R}^n,\qquad \operatorname{Ker}(\boldsymbol{X})=\operatorname{span}\{\boldsymbol{v}_{r+1},\dots,\boldsymbol{v}_n\}\subset\mathbb{R}^n.$$

とくに $\mathbb{R}^d=\operatorname{Im}(\boldsymbol{X})\oplus\operatorname{Ker}(\boldsymbol{X}^\top)$、$\mathbb{R}^n=\operatorname{Im}(\boldsymbol{X}^\top)\oplus\operatorname{Ker}(\boldsymbol{X})$（直交直和）。すなわち左特異ベクトルは変数側の空間 $\mathbb{R}^d$ を、右特異ベクトルはサンプル側の空間 $\mathbb{R}^n$ をそれぞれ二つに割る。

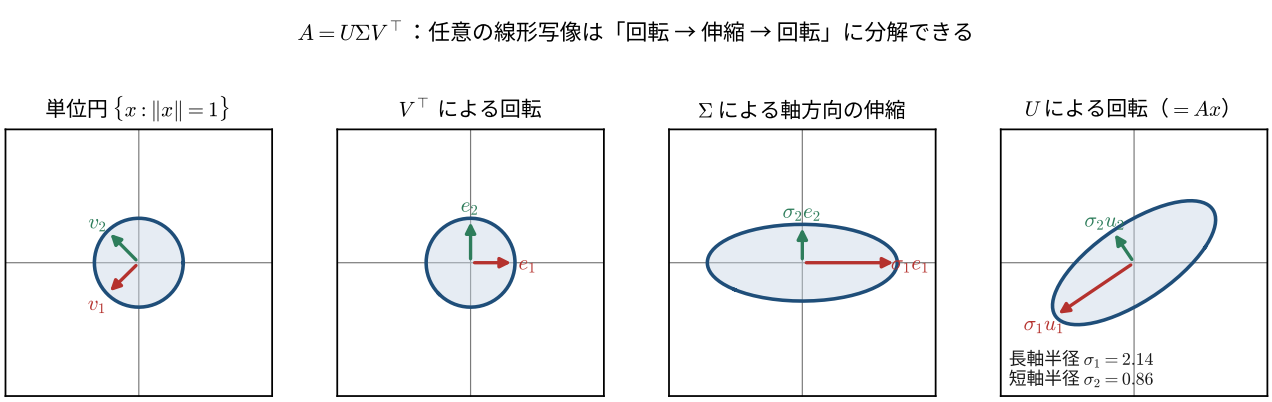


図2.2　SVD の幾何。単位円は $\boldsymbol{V}^\top$ で回転し、$\boldsymbol{\Sigma}$ で伸縮され、$\boldsymbol{U}$ で再び回転して楕円になる。主軸の長さが特異値、方向が左特異ベクトルであり、「任意の線形写像は回転・伸縮・回転に分解できる」という主張を視覚化している。

リスト 2.2　$\boldsymbol{X}\boldsymbol{X}^\top$ の固有値分解と $\boldsymbol{X}$ の SVD の精度比較。条件数を変えながら真の特異値との相対誤差を測る（$\boldsymbol{X}$ は $d \times n$）

```python
import numpy as np

def make_illcond(d, n, kappa, seed=0):    # 特異値 1 ... 1/kappa（対数等間隔）
    rng = np.random.default_rng(seed)
    U0, _ = np.linalg.qr(rng.standard_normal((d, d)))   # 変数側 d×d
    V0, _ = np.linalg.qr(rng.standard_normal((n, d)))   # サンプル側 n×d（列直交）
    s_true = np.logspace(0, -np.log10(kappa), d)
    return (U0 * s_true) @ V0.T, s_true                 # d×n

for kappa in [1e4, 1e8, 1e10]:
    X, s_true = make_illcond(12, 200, kappa)    # d=12 変数, n=200 サンプル
    ev = np.linalg.eigvalsh(X @ X.T)[::-1]      # 方法 A（悪い）：負の値が出うる
    s_gram = np.sqrt(np.maximum(ev, 0.0))
    s_svd = np.linalg.svd(X, compute_uv=False)  # 方法 B（良い）
    err = lambda s: np.max(np.abs(s - s_true) / s_true)
    print(f"kappa={kappa:.0e}  gram={err(s_gram):.2e}  svd={err(s_svd):.2e}")
# kappa=1e+04 gram=2.26e-09 svd=2.77e-14 / 1e+08 gram=1.50e-01 svd=2.22e-11
# kappa=1e+10 gram=5.54e+00 svd=2.94e-08
```

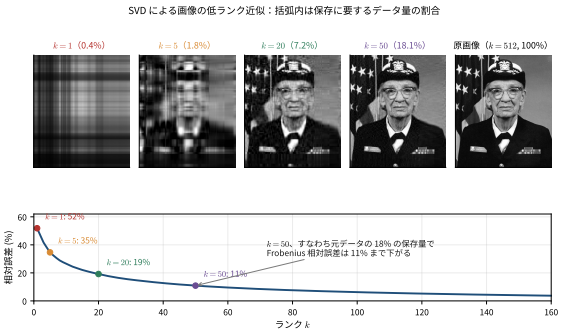
証明. $i \le r$ では $\sigma_i > 0$ かつ $\boldsymbol{X}\boldsymbol{v}_i = \sigma_i \boldsymbol{u}_i$ だから $\operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\} \subset \operatorname{Im}(\boldsymbol{X})$。逆に $\boldsymbol{c} \in \mathbb{R}^n$ を $\boldsymbol{c} = \sum_i c_i \boldsymbol{v}_i$ と展開すれば $\boldsymbol{X}\boldsymbol{c} = \sum_{i \le r} c_i \sigma_i \boldsymbol{u}_i \in \operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\}$。これで第一の等式が示され、同時に $\operatorname{rank} \boldsymbol{X} = r$ も従う。$\boldsymbol{X}\boldsymbol{c} = \boldsymbol{0}$ となるのは上式より $c_i = 0$ $(i \le r)$ のときに限るので $\operatorname{Ker}(\boldsymbol{X}) = \operatorname{span}\{\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n\}$。$\boldsymbol{X}^\top = \boldsymbol{V}\boldsymbol{\Sigma}^\top \boldsymbol{U}^\top$ に同じ議論を適用すれば残りの二つを得る。 ■

二つの像空間の読み方を、データ行列の文脈で確認しておく。$\operatorname{Im}(\boldsymbol{X}) = \operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\} \subset \mathbb{R}^d$ は**データ点が張る部分空間**であり、n 点の点群が実際に乗っている「平坦な部分」を表す。これを k 次元に切り詰めるのが低ランク近似・PCA である（2.7節、第3章）。一方 $\operatorname{Im}(\boldsymbol{X}^\top) = \operatorname{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_r\} \subset \mathbb{R}^n$ は「$\boldsymbol{X}^\top \boldsymbol{w}$ として表せる**予測値ベクトル**の全体」であり、最小二乗法とは $\boldsymbol{y} \in \mathbb{R}^n$ をこの $\operatorname{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_r\}$ に直交射影することである（2.8節で使う）。$\boldsymbol{u}$ と $\boldsymbol{v}$ のどちらがどちらの空間に住むかは $\boldsymbol{X}$ の形から決まる。$\boldsymbol{X} \in \mathbb{R}^{d \times n}$ なら $\boldsymbol{u}_i \in \mathbb{R}^d$（変数側）、$\boldsymbol{v}_i \in \mathbb{R}^n$（サンプル側）である。迷ったら $\boldsymbol{X}\boldsymbol{v}_i = \sigma_i \boldsymbol{u}_i$ の両辺の次元を数えればよい。

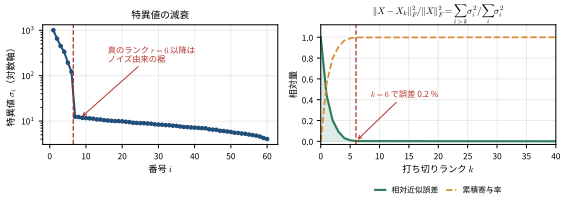
例 2.27 (2×2 の SVD)**.** $\boldsymbol{X} = \begin{pmatrix} 2 & -1 \\ 2 & 1 \end{pmatrix}$ とする。$d \times d$ 側から始めるので、$\boldsymbol{X}\boldsymbol{X}^\top = \begin{pmatrix} 5 & 3 \\ 3 & 5 \end{pmatrix}$ の固有値は $8, 2$、固有ベクトルは $\boldsymbol{u}_1 = \frac{1}{\sqrt{2}}(1,1)^\top$, $\boldsymbol{u}_2 = \frac{1}{\sqrt{2}}(1,-1)^\top$。よって $\sigma_1 = 2\sqrt{2} \approx 2.828$, $\sigma_2 = \sqrt{2} \approx 1.414$ であり、$\boldsymbol{v}_1 = \boldsymbol{X}^\top \boldsymbol{u}_1 / \sigma_1 = (1,0)^\top$, $\boldsymbol{v}_2 = \boldsymbol{X}^\top \boldsymbol{u}_2 / \sigma_2 = (0,-1)^\top$。検算すると $\sigma_1^2 + \sigma_2^2 = 10 = \|\boldsymbol{X}\|_{\mathrm{F}}^2$（成分の二乗和 $4+4+1+1$）、$\sigma_1 \sigma_2 = 4 = |\det \boldsymbol{X}|$ である。

$\boldsymbol{X}\boldsymbol{X}^\top$ を作ってはいけない

$\boldsymbol{X}$ の特異値がほしいとき、$\boldsymbol{X}\boldsymbol{X}^\top$ を作ってその固有値の平方根をとる手順は数学的には正しいが数値的には悪い。条件数 $\kappa(\boldsymbol{X}) = \sigma_1/\sigma_r$ に対し $\kappa(\boldsymbol{X}\boldsymbol{X}^\top) = \kappa(\boldsymbol{X})^2$ であり、積を作った時点で情報が失われるからである。倍精度の丸め単位は $\varepsilon_{\mathrm{mach}} \approx 2.2 \times 10^{-16}$ なので、$\kappa(\boldsymbol{X}) \approx 10^8$ だと $\boldsymbol{X}\boldsymbol{X}^\top$ の小さい固有値は相対誤差 $O(1)$ で壊れうる。実際 $\kappa = 10^{10}$ の 12×200 行列では、$\boldsymbol{X}\boldsymbol{X}^\top$ 経由の最小特異値の相対誤差が 5.5（桁ごと誤り）、$\boldsymbol{X}$ の SVD を直接計算した場合が 2.9×10^{-8} である（リスト 2.2）。**原則：特異値・主成分がほしいなら $\boldsymbol{X}$ の SVD を直接計算する。** $\widehat{\boldsymbol{\Sigma}}$ の固有値分解は「$\widehat{\boldsymbol{\Sigma}}$ そのものが与えられている」場合にのみ使う。



(a) 低ランク近似。k を増やすと視覚的な情報が段階的に復元される。自然な信号の特異値が急速に減衰することが、圧縮が効く理由である。



(b) 特異値の減衰（片対数）と打ち切り誤差 $\|\boldsymbol{X} - \boldsymbol{X}_k\|_{\mathrm{F}}^2 = \sum_{i>k} \sigma_i^2$ の推移。誤差は左図の裾の面積の累積である。

図2.3　低ランク近似の実際と、打ち切り誤差が特異値の裾で決まること。

2.7　Eckart–Young–Mirsky の定理

式 (2.18)の和を上位 k 項で打ち切った $\boldsymbol{X}_k \coloneqq \sum_{i=1}^{k} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\top} = \boldsymbol{U}_k \boldsymbol{\Sigma}_k \boldsymbol{V}_k^{\top}$ を**打ち切り SVD**（truncated SVD）という（$\operatorname{rank} \boldsymbol{X}_k \le k$）。問題は「ランク k 以下の行列で $\boldsymbol{X}$ を近似するとき、これが最善か」である。答えは最善であり、しかもノルムの選び方によらないという強い形で成り立つ。

定理 2.28 (Eckart–Young–Mirsky [40])**.** $\boldsymbol{X} \in \mathbb{R}^{d \times n}$、$k < \operatorname{rank} \boldsymbol{X}$ とすると

$$\min\{\|\boldsymbol{X} - \boldsymbol{B}\|_{\mathrm{F}} : \operatorname{rank} \boldsymbol{B} \le k\} = \|\boldsymbol{X} - \boldsymbol{X}_k\|_{\mathrm{F}} = \Big(\sum_{i>k} \sigma_i^2\Big)^{1/2}, \tag{2.19}$$

また作用素ノルムについても $\min\{\|\boldsymbol{X} - \boldsymbol{B}\|_{\mathrm{op}} : \operatorname{rank} \boldsymbol{B} \le k\} = \|\boldsymbol{X} - \boldsymbol{X}_k\|_{\mathrm{op}} = \sigma_{k+1}$。

Frobenius ノルムの場合の証明. まず値の計算。Frobenius ノルムは直交変換で不変（$\|\boldsymbol{Q}\boldsymbol{A}\|_{\mathrm{F}}^2 = \operatorname{tr}(\boldsymbol{A}^{\top}\boldsymbol{Q}^{\top}\boldsymbol{Q}\boldsymbol{A}) = \|\boldsymbol{A}\|_{\mathrm{F}}^2$）だから $\|\boldsymbol{X} - \boldsymbol{X}_k\|_{\mathrm{F}}^2 = \|\boldsymbol{U}(\boldsymbol{\Sigma} - \boldsymbol{\Sigma}^{(k)})\boldsymbol{V}^{\top}\|_{\mathrm{F}}^2 = \sum_{i>k} \sigma_i^2$（$\boldsymbol{\Sigma}^{(k)}$ は $\boldsymbol{\Sigma}$ の上位 k 個だけ残した行列）。

次に最適性。$\operatorname{rank} \boldsymbol{B} \le k$ とし、$W \coloneqq \operatorname{Im}(\boldsymbol{B}) \subset \mathbb{R}^d$（$\dim W = s \le k$）、$\boldsymbol{P}_W$ を W への直交射影とする。$\boldsymbol{B} \in \mathbb{R}^{d \times n}$ の各列は $\mathbb{R}^d$ の元で W に属し、$\boldsymbol{X}$ の各列も $\mathbb{R}^d$ の元だから、列ごとに定理 2.14を適用して n 本足し合わせると

$$\|\boldsymbol{X} - \boldsymbol{B}\|_{\mathrm{F}}^2 \;\ge\; \|(\boldsymbol{I} - \boldsymbol{P}_W)\boldsymbol{X}\|_{\mathrm{F}}^2 = \|\boldsymbol{X}\|_{\mathrm{F}}^2 - \|\boldsymbol{P}_W \boldsymbol{X}\|_{\mathrm{F}}^2 \tag{2.20}$$

（最後の等式は列ごとのピタゴラスの定理）。W の正規直交基底を列にもつ $\boldsymbol{Q} \in \mathbb{R}^{d \times s}$ をとれば $\boldsymbol{P}_W = \boldsymbol{Q}\boldsymbol{Q}^{\top}$ で $\|\boldsymbol{P}_W \boldsymbol{X}\|_{\mathrm{F}}^2 = \operatorname{tr}(\boldsymbol{X}^{\top}\boldsymbol{Q}\boldsymbol{Q}^{\top}\boldsymbol{Q}\boldsymbol{Q}^{\top}\boldsymbol{X}) = \operatorname{tr}(\boldsymbol{Q}^{\top}\boldsymbol{X}\boldsymbol{X}^{\top}\boldsymbol{Q})$（$\boldsymbol{X}\boldsymbol{X}^{\top}$ は $d \times d$、$\boldsymbol{Q}$ の列も $\mathbb{R}^d$ の元だから次元が合う）。$\boldsymbol{X}\boldsymbol{X}^{\top}$ の固有値は $\sigma_1^2 \ge \sigma_2^2 \ge \cdots$ だから系 2.23により $\operatorname{tr}(\boldsymbol{Q}^{\top}\boldsymbol{X}\boldsymbol{X}^{\top}\boldsymbol{Q}) \le \sum_{i \le s} \sigma_i^2 \le \sum_{i \le k} \sigma_i^2$。これを式 (2.20)に代入して $\|\boldsymbol{X} - \boldsymbol{B}\|_{\mathrm{F}}^2 \ge \|\boldsymbol{X}\|_{\mathrm{F}}^2 - \sum_{i \le k} \sigma_i^2 = \sum_{i>k} \sigma_i^2 = \|\boldsymbol{X} - \boldsymbol{X}_k\|_{\mathrm{F}}^2$ を得る。$\boldsymbol{B} = \boldsymbol{X}_k$（このとき $W = \operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_k\} \subset \mathbb{R}^d$、すなわち上位 k 本の主成分方向が張る部分空間）で等号が成り立つ。 ■

作用素ノルムの場合も同じ枠組みで示せるが、$\mathbb{R}^n$ の中で $\operatorname{Ker}(\boldsymbol{B})$ と $\operatorname{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_{k+1}\}$ の次元を数えて交わりが非自明であることを使う別の議論が要る（$\boldsymbol{B} \in \mathbb{R}^{d \times n}$ なので $\dim \operatorname{Ker}(\boldsymbol{B}) \ge n - k$ であることに注意）。ここでは結果のみを述べ、証明は演習 2.6に回した。

低ランク近似が実際にどう効くかは画像で見るのがわかりやすい。図 2.3aは k を増やしたときの復元の様子、図 2.3bは特異値の減衰と本定理の誤差評価が一致することを示している（両者をまとめて図 2.3）。自然画像の特異値が急速に減衰することが、少数の主成分で足りる理由である。

例 2.29 (画像圧縮)**.** 512×512 のグレースケール画像を行列 $\boldsymbol{X}$ とみなすと（この例は正方なので $d = n = 512$）記憶量は 262,144 個の数値だが、ランク k の近似を $\boldsymbol{U}_k, \boldsymbol{\Sigma}_k, \boldsymbol{V}_k$ の形で保存すれば $k(512 + 512 + 1) = 1025k$ 個で済む。$k = 50$ なら約 51,250 個、圧縮率は約 1/5 であり、定理 2.28によりこの記憶量のもとで誤差は理論的に最小である。図 2.3aに $k = 1, 5, 20, 50$ の結果を、図 2.3bに特異値の減衰と誤差の累積を示した。実用の画像圧縮は離散コサイン変換を使うが、「基底を取り替えて上位の係数だけ残す」という発想は共通である。

注意 2.30. 定理 2.28は第3章の PCA そのものである。中心化データ $\widetilde{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{H}$ に対する「$\mathbb{R}^d$ の k 次元部分空間へ各データ点を射影したとき残差二乗和が最小」という問題は 式 (2.20)右辺の最小化に他ならず、その最適な部分空間は $\operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_k\}$、すなわち $\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$ の上位固有ベクトルが張る空間である。PCA は Eckart–Young の定理の統計的な読み替えだといえる。

2.8　擬似逆行列と最小二乗

重み $\boldsymbol{w} \in \mathbb{R}^d$ による線形予測値は $\boldsymbol{X}^\top \boldsymbol{w} \in \mathbb{R}^n$ である（2.1節）。連立方程式 $\boldsymbol{X}^\top \boldsymbol{w} = \boldsymbol{y}$ が解をもたない（$n > d$、過剰決定）、あるいは解が無数にある（$n < d$、劣決定）のはデータ解析では普通であり、両方を統一的に扱う道具が擬似逆行列である。以下、$\boldsymbol{X} \in \mathbb{R}^{d \times n}$ を計画行列とみなし、$\boldsymbol{X}$ そのものに対する擬似逆を定義したうえで、最小二乗の議論は $\boldsymbol{X}^\top$ に適用する形で述べる。

定義 2.31 (Moore–Penrose 擬似逆行列)**.** $\boldsymbol{X} = \boldsymbol{U}_r \boldsymbol{\Sigma}_r \boldsymbol{V}_r^\top$ を簡約 SVD（$r = \operatorname{rank} \boldsymbol{X}$、$\boldsymbol{U}_r \in \mathbb{R}^{d \times r}$, $\boldsymbol{V}_r \in \mathbb{R}^{n \times r}$）とするとき

$$\boldsymbol{X}^+ \coloneqq \boldsymbol{V}_r \boldsymbol{\Sigma}_r^{-1} \boldsymbol{U}_r^\top = \sum_{i=1}^{r} \frac{1}{\sigma_i} \boldsymbol{v}_i \boldsymbol{u}_i^\top \in \mathbb{R}^{n \times d} \tag{2.21}$$

を $\boldsymbol{X}$ の **Moore–Penrose 擬似逆行列**という。$(\boldsymbol{X}^\top)^+ = (\boldsymbol{X}^+)^\top = \boldsymbol{U}_r \boldsymbol{\Sigma}_r^{-1} \boldsymbol{V}_r^\top \in \mathbb{R}^{d \times n}$ である。

$\boldsymbol{X}$ が正則な正方行列なら $\boldsymbol{X}^+ = \boldsymbol{X}^{-1}$ である。一般には $\boldsymbol{X}\boldsymbol{X}^+ = \boldsymbol{U}_r \boldsymbol{U}_r^\top$（$d \times d$）が $\operatorname{Im}(\boldsymbol{X}) \subset \mathbb{R}^d$ への、$\boldsymbol{X}^+\boldsymbol{X} = \boldsymbol{V}_r \boldsymbol{V}_r^\top$（$n \times n$）が $\operatorname{Im}(\boldsymbol{X}^\top) \subset \mathbb{R}^n$ への射影になる（定理 2.13(b) から分かる）。この二つはそれぞれ「データ点が張る空間への射影」「予測値の空間への射影」である。なお $\boldsymbol{X}^+$ は Penrose の 4 条件 $\boldsymbol{X}\boldsymbol{X}^+\boldsymbol{X} = \boldsymbol{X}$, $\boldsymbol{X}^+\boldsymbol{X}\boldsymbol{X}^+ = \boldsymbol{X}^+$, $(\boldsymbol{X}\boldsymbol{X}^+)^\top = \boldsymbol{X}\boldsymbol{X}^+$, $(\boldsymbol{X}^+\boldsymbol{X})^\top = \boldsymbol{X}^+\boldsymbol{X}$ を満たす唯一の行列としても特徴づけられる（第4章）。

定理 2.32 (最小二乗解と最小ノルム解)**.** $\boldsymbol{X} \in \mathbb{R}^{d \times n}$、$\boldsymbol{y} \in \mathbb{R}^n$ とし $\mathcal{L}(\boldsymbol{w}) = \|\boldsymbol{X}^\top \boldsymbol{w} - \boldsymbol{y}\|^2$（$\boldsymbol{w} \in \mathbb{R}^d$）とすると、(i) $\mathcal{L}$ の最小化解の全体は $\mathcal{W} = \{(\boldsymbol{X}^\top)^+ \boldsymbol{y} + \boldsymbol{z} : \boldsymbol{z} \in \operatorname{Ker}(\boldsymbol{X}^\top)\}$、(ii) $(\boldsymbol{X}^\top)^+ \boldsymbol{y} = (\boldsymbol{X}^+)^\top \boldsymbol{y}$ は $\mathcal{W}$ の中でノルム最小の元であり一意、(iii) $\boldsymbol{w}$ が $\mathcal{L}$ を最小化する必要十分条件は**正規方程式** $\boldsymbol{X}\boldsymbol{X}^\top \boldsymbol{w} = \boldsymbol{X}\boldsymbol{y}$ である。

証明. (i) $\boldsymbol{X}^\top \boldsymbol{w}$ は $\boldsymbol{w}$ が $\mathbb{R}^d$ を動くとき $\operatorname{Im}(\boldsymbol{X}^\top) \subset \mathbb{R}^n$ 全体を動くから、定理 2.14より $\|\boldsymbol{X}^\top \boldsymbol{w} - \boldsymbol{y}\|$ が最小になるのは $\boldsymbol{X}^\top \boldsymbol{w} = \boldsymbol{P}\boldsymbol{y}$（$\boldsymbol{P}$ は $\operatorname{Im}(\boldsymbol{X}^\top)$ への射影）のときに限る。$\boldsymbol{w}_0 \coloneqq (\boldsymbol{X}^\top)^+ \boldsymbol{y} = \boldsymbol{U}_r \boldsymbol{\Sigma}_r^{-1} \boldsymbol{V}_r^\top \boldsymbol{y}$ とおくと $\boldsymbol{X}^\top \boldsymbol{w}_0 = \boldsymbol{V}_r \boldsymbol{\Sigma}_r \boldsymbol{U}_r^\top \boldsymbol{U}_r \boldsymbol{\Sigma}_r^{-1} \boldsymbol{V}_r^\top \boldsymbol{y} = \boldsymbol{V}_r \boldsymbol{V}_r^\top \boldsymbol{y} = \boldsymbol{P}\boldsymbol{y}$ だから $\boldsymbol{w}_0$ は最小化解であり、$\boldsymbol{w}$ が最小化解であることは $\boldsymbol{w} - \boldsymbol{w}_0 \in \operatorname{Ker}(\boldsymbol{X}^\top)$ と同値である。

(ii) $\boldsymbol{w}_0 \in \operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\} = \operatorname{Im}(\boldsymbol{X})$ であり 定理 2.26より $\mathbb{R}^d$ の中で $\operatorname{Im}(\boldsymbol{X}) \perp \operatorname{Ker}(\boldsymbol{X}^\top)$ だから、$\boldsymbol{z} \in \operatorname{Ker}(\boldsymbol{X}^\top)$ に対し $\|\boldsymbol{w}_0 + \boldsymbol{z}\|^2 = \|\boldsymbol{w}_0\|^2 + \|\boldsymbol{z}\|^2 \geq \|\boldsymbol{w}_0\|^2$、等号は $\boldsymbol{z} = \boldsymbol{0}$ に限る。

(iii) $\mathcal{L}$ は凸で、2.9節で導く公式により $\nabla \mathcal{L}(\boldsymbol{w}) = 2\boldsymbol{X}(\boldsymbol{X}^\top \boldsymbol{w} - \boldsymbol{y})$。凸関数の最小点は $\nabla \mathcal{L} = \boldsymbol{0}$ と同値だから $\boldsymbol{X}\boldsymbol{X}^\top \boldsymbol{w} = \boldsymbol{X}\boldsymbol{y}$ を得る。幾何的には残差 $\boldsymbol{y} - \boldsymbol{X}^\top \boldsymbol{w}$ が $\operatorname{Im}(\boldsymbol{X}^\top)$ に直交すること、すなわちすべての変数 j について第 j 行と残差の内積が 0 であることと同じである。 ■

$\boldsymbol{X}$ が行フルランク（$r = d$、すなわち $\boldsymbol{X}^\top$ が列フルランク）なら $\operatorname{Ker}(\boldsymbol{X}^\top) = \{\boldsymbol{0}\}$ で解は一意 $\boldsymbol{w} = (\boldsymbol{X}\boldsymbol{X}^\top)^{-1}\boldsymbol{X}\boldsymbol{y} = (\boldsymbol{X}^\top)^+ \boldsymbol{y}$ であり、$n < d$ の劣決定では解が無数にあり、擬似逆が選ぶのは**最小ノルム解**である。

注意 2.33 (伏線)**.** 「解が無数にあるとき、どれを選ぶか」は、パラメータ数がサンプル数を超える現代の機械学習の中心的な問題である。勾配降下法を $\boldsymbol{w} = \boldsymbol{0}$ から始めると最小ノルム解に収束する。これが 第11章で扱う**二重降下**（double descent）の出発点であり、「過剰パラメータでも汎化する」現象を説明する鍵になる。

リッジ回帰と正則化のスペクトル的理解。 σ_i が小さいと $\boldsymbol{X}^+$ の $1/\sigma_i$ が爆発し、$\boldsymbol{y}$ のわずかなノイズが $\boldsymbol{w}$ を大きく揺らす。これを抑えるのが**リッジ回帰**（ridge regression）である：

$$\boldsymbol{w}_\lambda \coloneqq \operatorname*{arg\,min}_{\boldsymbol{w} \in \mathbb{R}^d} \|\boldsymbol{X}^\top \boldsymbol{w} - \boldsymbol{y}\|^2 + \lambda \|\boldsymbol{w}\|^2, \qquad \lambda > 0. \tag{2.22}$$

勾配は $2\boldsymbol{X}(\boldsymbol{X}^\top \boldsymbol{w} - \boldsymbol{y}) + 2\lambda \boldsymbol{w}$ だから $(\boldsymbol{X}\boldsymbol{X}^\top + \lambda \boldsymbol{I}_d)\boldsymbol{w} = \boldsymbol{X}\boldsymbol{y}$。$\boldsymbol{X}\boldsymbol{X}^\top + \lambda \boldsymbol{I}_d \succ 0$ は必ず正則なので解は一意であり、$\boldsymbol{X}\boldsymbol{X}^\top = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{\Sigma}^\top \boldsymbol{U}^\top$ と $\boldsymbol{X}\boldsymbol{y} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top \boldsymbol{y}$ を代入して整理すると

$$\boldsymbol{w}_\lambda = \sum_{i=1}^{r} \frac{\sigma_i}{\sigma_i^2 + \lambda} (\boldsymbol{v}_i^\top \boldsymbol{y})\, \boldsymbol{u}_i \qquad (\lambda = 0 \text{ なら} \boldsymbol{w}_0 = \textstyle\sum_i \sigma_i^{-1} (\boldsymbol{v}_i^\top \boldsymbol{y}) \boldsymbol{u}_i = (\boldsymbol{X}^\top)^+ \boldsymbol{y}). \tag{2.23}$$

$\boldsymbol{y}$ との内積をとるのが**サンプル側**の $\boldsymbol{v}_i \in \mathbb{R}^n$、係数をかけて足し上げる先が**変数側**の $\boldsymbol{u}_i \in \mathbb{R}^d$ である。($\mathbb{R}^n$ の内積) × ($\mathbb{R}^d$ のベクトル) で $\boldsymbol{w}_\lambda \in \mathbb{R}^d$ となり次元が合う。最小二乗解と比べると、第 i 成分に**フィルタ係数** $f_i(\lambda) \coloneqq \sigma_i^2/(\sigma_i^2 + \lambda) \in (0, 1)$ がかかっている。$\sigma_i \gg \sqrt{\lambda}$ なら $f_i \approx 1$（そのまま通す）、$\sigma_i \ll \sqrt{\lambda}$ なら $f_i \approx \sigma_i^2/\lambda \approx 0$（切り捨てる）。すなわち**正則化とは、特異値の小さい成分を滑らかに遮断するローパスフィルタである。** $\lambda = 0.1$ では $\sigma = 3, 1, 0.1$ に対し $f = 0.989, 0.909, 0.0909$ となる。この見方は第8章のカーネルリッジ回帰でそのまま再登場する（$\boldsymbol{X}$ の特異値がカーネル行列の固有値に置き換わるだけである）。

リスト 2.3　リッジ回帰の SVD 表示の検証と、劣決定系における擬似逆解の最小ノルム性の確認（$d \times n$ 規約）

```python
import numpy as np
from scipy.linalg import null_space

rng = np.random.default_rng(1)
d, n, lam = 10, 30, 0.5
X, y = rng.standard_normal((d, n)), rng.standard_normal(n)   # X は d×n
U, s, Vt = np.linalg.svd(X, full_matrices=False)   # U: d×r（変数側）, Vt: r×n
w_direct = np.linalg.solve(X @ X.T + lam * np.eye(d), X @ y)  # 正規方程式
w_svd = U @ ((s / (s**2 + lam)) * (Vt @ y))                   # SVD 表示
print(np.abs(w_direct - w_svd).max())        # 6.7e-16（一致）

# 劣決定系（d > n）：解は無数にあり、擬似逆は最小ノルム解を選ぶ
X2, y2 = rng.standard_normal((12, 5)), rng.standard_normal(5)  # d=12 > n=5
w_min = np.linalg.pinv(X2.T) @ y2            # 予測値は X2.T @ w なので X2.T の擬似逆
w_other = w_min + null_space(X2.T)[:, 0]     # Ker(X2.T) 方向にずらしても解のまま
print(np.linalg.norm(X2.T @ w_min - y2), np.linalg.norm(X2.T @ w_other - y2))
print(np.linalg.norm(w_min), np.linalg.norm(w_other))   # 0.401 < 1.077
```

2.9　行列の微分とラグランジュ未定乗数法

これまでの議論はすべて「何かを最小化・最大化する」形で書かれていた。最適化には微分が要る。ベクトル・行列を変数とする微分は成分ごとの偏微分を並べたものにすぎないが、公式の形で覚えておくと計算が速い。$f\colon \mathbb{R}^d \to \mathbb{R}$ に対し**勾配**を $\nabla_{\boldsymbol{x}} f \coloneqq (\partial f/\partial x_1, \dots, \partial f/\partial x_d)^\top$、$F\colon \mathbb{R}^{m\times m} \to \mathbb{R}$ に対し $(\nabla_{\boldsymbol{A}} F)_{ij} \coloneqq \partial F/\partial a_{ij}$ と定める。

命題 2.34（基本公式）. $\boldsymbol{a} \in \mathbb{R}^d$, $\boldsymbol{A} \in \mathbb{R}^{d\times d}$, $\boldsymbol{B} \in \mathbb{R}^{m\times m}$ に対し

$$\nabla_{\boldsymbol{x}} (\boldsymbol{a}^\top \boldsymbol{x}) = \boldsymbol{a}, \tag{2.24}$$

$$\nabla_{\boldsymbol{x}} (\boldsymbol{x}^\top \boldsymbol{A} \boldsymbol{x}) = (\boldsymbol{A} + \boldsymbol{A}^\top)\boldsymbol{x} \quad (\boldsymbol{A} \text{ 対称なら } 2\boldsymbol{A}\boldsymbol{x}), \tag{2.25}$$

$$\nabla_{\boldsymbol{A}} \operatorname{tr}(\boldsymbol{A}\boldsymbol{B}) = \boldsymbol{B}^\top, \tag{2.26}$$

$$\nabla_{\boldsymbol{A}} \log\det \boldsymbol{A} = \boldsymbol{A}^{-\top} \quad (\boldsymbol{A} \in \mathbb{R}^{d\times d},\ \det \boldsymbol{A} > 0). \tag{2.27}$$

$\log\det \boldsymbol{A}$ には $\det \boldsymbol{A} > 0$ が必要

(2.27)の条件を「$\boldsymbol{A}$ は正則」と書くのは**誤り**である。実行列では正則であっても行列式が負になりうるので、$\log\det \boldsymbol{A}$ が実数として定義されない。たとえば $\boldsymbol{A} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ は正則（階数 2）だが $\det \boldsymbol{A} = -1$ である。

一般の正則実行列まで扱いたければ絶対値をとって

$$\nabla_{\boldsymbol{A}} \log|\det \boldsymbol{A}| = \boldsymbol{A}^{-\top} \quad (\boldsymbol{A} \text{ は正則}) \tag{2.28}$$

とすればよい（証明は同じで、$\partial \log|\det \boldsymbol{A}|/\partial a_{ij} = C_{ij}/\det \boldsymbol{A}$ が符号によらず成り立つ）。数値微分で確かめると、$\det \boldsymbol{A} = 1.1593$ の例で(2.27)と $\boldsymbol{A}^{-\top}$ の差は 1.5×10^{-10}（刻み 10^{-6} の中心差分の精度）、行を交換して $\det = -1.1593$ にした行列でも(2.28)の差は同じ 1.5×10^{-10} である。

本書でこの公式を使うのは多変量正規分布の対数尤度を共分散行列で微分する場面（第5章）だけであり、そこでの $\boldsymbol{A}$ は**正定値対称**なので $\det \boldsymbol{A} > 0$ は自動的に満たされる。以下ではこの場合だけを考えればよい。

証明. (2.24)：$\boldsymbol{a}^\top \boldsymbol{x} = \sum_j a_j x_j$ より $\partial/\partial x_k = a_k$。

(2.25)：$\boldsymbol{x}^\top \boldsymbol{A} \boldsymbol{x} = \sum_{i,j} a_{ij} x_i x_j$ を x_k で偏微分すると、$i = k$ の項から $\sum_j a_{kj} x_j$、$j = k$ の項から $\sum_i a_{ik} x_i$ が出る（$i = j = k$ の項 $a_{kk} x_k^2$ の微分 $2a_{kk}x_k$ は両者に一度ずつ数えられて整合する）。よって $\partial/\partial x_k = (\boldsymbol{A}\boldsymbol{x})_k + (\boldsymbol{A}^\top \boldsymbol{x})_k$。

(2.26)：$\operatorname{tr}(\boldsymbol{A}\boldsymbol{B}) = \sum_{i,j} a_{ij} b_{ji}$ より $\partial/\partial a_{kl} = b_{lk} = (\boldsymbol{B}^\top)_{kl}$。

(2.27)：まず記号を定める。$\boldsymbol{A}$ から第 i 行と第 j 列を除いた $(d-1)\times(d-1)$ 行列の行列式に $(-1)^{i+j}$ を掛けたものを (i,j) **余因子**といい C_{ij} と書く。余因子を転置して並べた行列

$$\operatorname{adj}(\boldsymbol{A}) \coloneqq (C_{ji})_{ij} \tag{2.29}$$

を $\boldsymbol{A}$ の**余因子行列**（adjugate）という。この adj は、第7章に現れる**自己共役作用素**（self-adjoint operator）の「adjoint」（随伴）とは無関係である。綴りが似ているだけの別概念なので混同しないこと。

第 i 行に関する余因子展開 $\det \boldsymbol{A} = \sum_j a_{ij} C_{ij}$ において C_{ij} は a_{ij} を含まないから

$$\frac{\partial \det \boldsymbol{A}}{\partial a_{ij}} = C_{ij} \tag{2.30}$$

である（余因子展開から直接従う）。また $\boldsymbol{A}$ が正則なら $\boldsymbol{A}^{-1} = \operatorname{adj}(\boldsymbol{A})/\det \boldsymbol{A}$、すなわち $C_{ij} = \det \boldsymbol{A} \cdot (\boldsymbol{A}^{-1})_{ji}$。したがって $\det \boldsymbol{A} > 0$ のもとで

$$\frac{\partial}{\partial a_{ij}} \log\det \boldsymbol{A} = \frac{1}{\det \boldsymbol{A}} \cdot \frac{\partial \det \boldsymbol{A}}{\partial a_{ij}} = \frac{C_{ij}}{\det \boldsymbol{A}} = (\boldsymbol{A}^{-1})_{ji} = (\boldsymbol{A}^{-\top})_{ij}$$

となり $\nabla_{\boldsymbol{A}} \log\det \boldsymbol{A} = \boldsymbol{A}^{-\top}$ を得る。 ■

(2.24)と(2.25)を組み合わせると $\mathcal{L}(\boldsymbol{w}) = \|\boldsymbol{X}^\top \boldsymbol{w} - \boldsymbol{y}\|^2 = \boldsymbol{w}^\top \boldsymbol{X}\boldsymbol{X}^\top \boldsymbol{w} - 2\boldsymbol{y}^\top \boldsymbol{X}^\top \boldsymbol{w} + \boldsymbol{y}^\top \boldsymbol{y}$ の勾配は（$\boldsymbol{A} = \boldsymbol{X}\boldsymbol{X}^\top$ が対称であることと $\boldsymbol{a} = \boldsymbol{X}\boldsymbol{y}$ に注意して）$\nabla \mathcal{L} = 2\boldsymbol{X}\boldsymbol{X}^\top \boldsymbol{w} - 2\boldsymbol{X}\boldsymbol{y} = 2\boldsymbol{X}(\boldsymbol{X}^\top \boldsymbol{w} - \boldsymbol{y})$ となり、定理 2.32(iii) の正規方程式が出る。(2.27)は多変量正規分布の対数尤度を共分散行列で微分するときに使う（第5章）。

注意 2.35（「Jacobi の公式」との区別）. (2.30)を Jacobi の公式と呼ぶ文献もあるが、この名前は通常、行列値の関数 $\boldsymbol{A}(t)$ に対する

$$\frac{\mathrm{d}}{\mathrm{d}t} \det \boldsymbol{A}(t) = \det \boldsymbol{A}(t)\ \operatorname{tr}\bigl(\boldsymbol{A}(t)^{-1} \boldsymbol{A}'(t)\bigr) \tag{2.31}$$

を指す。(2.30)は余因子展開から直接従う成分ごとの公式であり、(2.31)はそれに連鎖律を適用して得られる（$\frac{\mathrm{d}}{\mathrm{d}t}\det \boldsymbol{A} = \sum_{i,j} C_{ij} a'_{ij} = \det \boldsymbol{A} \sum_{i,j} (\boldsymbol{A}^{-1})_{ji} a'_{ij} = \det \boldsymbol{A}\operatorname{tr}(\boldsymbol{A}^{-1}\boldsymbol{A}')$）。本書では前者を「余因子展開から従う公式」と呼び、名前は付けない。

ラグランジュ未定乗数法。制約つき問題 $\max f(\boldsymbol{w})$ s.t. $g(\boldsymbol{w}) = 0$ に対し、$\mathcal{L}(\boldsymbol{w}, \mu) = f(\boldsymbol{w}) - \mu g(\boldsymbol{w})$ とおいて $\nabla_{\boldsymbol{w}} \mathcal{L} = \boldsymbol{0}$, $g(\boldsymbol{w}) = 0$ を解く。幾何的には「最適点では f の等高線と制約曲面が接する、すなわち ∇f と ∇g が平行」ということである（$\nabla g \neq \boldsymbol{0}$ を仮定）。平行でなければ制約曲面に沿って f を増やす方向が残っており、最適でない。

例 2.36（単位球上の二次形式の最大化）. $\boldsymbol{A}$ を対称行列とし $\max_{\boldsymbol{w} \in \mathbb{R}^d} \boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w}$ s.t. $\|\boldsymbol{w}\|^2 = 1$ を考える。$\mathcal{L}(\boldsymbol{w}, \mu) = \boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w} - \mu(\boldsymbol{w}^\top \boldsymbol{w} - 1)$ とおくと、(2.25)を $\boldsymbol{A}$ と $\boldsymbol{I}$ の両方に適用して $\nabla_{\boldsymbol{w}} \mathcal{L} = 2\boldsymbol{A}\boldsymbol{w} - 2\mu\boldsymbol{w} = \boldsymbol{0} \iff \boldsymbol{A}\boldsymbol{w} = \mu \boldsymbol{w}$。すなわち**停留点は固有ベクトル**であり、そのとき目的関数の値は $\boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w} = \mu \boldsymbol{w}^\top \boldsymbol{w} = \mu$、つまり固有値そのものである。単位球はコンパクトで $\boldsymbol{w} \mapsto \boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w}$ は連続だから最大値は必ず存在し、それは最大固有値 λ_1、達成する $\boldsymbol{w}$ は $\boldsymbol{u}_1$ である。定理 2.21(i) の別証明になっている。

例 2.36は本書でもっとも頻繁に使う計算である。第3章では $\boldsymbol{A} = \widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$（$\widetilde{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{H}$、$d \times d$）として PCA の第 1 主成分方向 $\boldsymbol{u}_1 \in \mathbb{R}^d$ を導き、第6章では制約を $\boldsymbol{w}^\top \boldsymbol{B}\boldsymbol{w} = 1$ に変えて一般化固有値問題 $\boldsymbol{A}\boldsymbol{w} = \lambda \boldsymbol{B}\boldsymbol{w}$ を導く。同じ計算が判別分析・正準相関分析・スペクトラルクラスタリングを貫いている。

この章のまとめ

- $\boldsymbol{X}\boldsymbol{X}^\top$（$d \times d$）と $\boldsymbol{X}^\top \boldsymbol{X}$（$n \times n$）は非零固有値を共有し、小さい方を扱うのが得。
- 直交射影は最良近似と同じもので、$\boldsymbol{P} = \boldsymbol{U}\boldsymbol{U}^\top$、$\boldsymbol{P}^\top = \boldsymbol{P} = \boldsymbol{P}^2$ で特徴づく（例：$\boldsymbol{H}$）。
- 対称行列はスペクトル分解をもち、Rayleigh 商の最大化・逐次最大化・トレース最大化が固有値問題に帰着する。
- $\boldsymbol{X} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$（$\boldsymbol{U}$ が変数側 $\mathbb{R}^d$、$\boldsymbol{V}$ がサンプル側 $\mathbb{R}^n$）の上位 k 項での打ち切りが最良ランク k 近似（Eckart–Young）であり、$\operatorname{Im}(\boldsymbol{X}) \subset \mathbb{R}^d$ はデータ点が張る空間。
- 予測は $\boldsymbol{X}^\top \boldsymbol{w}$、正規方程式は $\boldsymbol{X}\boldsymbol{X}^\top \boldsymbol{w} = \boldsymbol{X}\boldsymbol{y}$。擬似逆は最小ノルム解を与え、リッジ回帰は $\sigma_i^2/(\sigma_i^2 + \lambda)$ のフィルタとして働く。
- 制約つき二次形式の最大化は、ラグランジュ未定乗数法により固有値問題になる。

演習問題

演習 2.1 ($\star$). n 個の実数 $a_1, \dots, a_n$ に対し $\bigl(\sum_i a_i\bigr)^2 \le n \sum_i a_i^2$ を Cauchy–Schwarz から示し、等号成立条件を述べよ。またこれが中心化行列 $\boldsymbol{H}$ を用いた $\|\boldsymbol{H}\boldsymbol{a}\|^2 \ge 0$ と同値であることを確かめよ。

演習 2.2 ($\star$). $\boldsymbol{P}$ を部分空間 V への直交射影行列とする。次を示せ。(a) $\boldsymbol{I} - \boldsymbol{P}$ は $V^\perp$ への直交射影行列。(b) $\boldsymbol{P}$ の固有値は $0, 1$ のみで、固有値 1 の固有空間は V、0 の固有空間は $V^\perp$。(c) $\|\boldsymbol{P}\boldsymbol{x}\| \le \|\boldsymbol{x}\|$ であり、等号は $\boldsymbol{x} \in V$ のときに限る。

演習 2.3 ($\star$). $\boldsymbol{X} = \begin{pmatrix} 3 & 4 \\ 0 & 5 \end{pmatrix}$ の特異値分解を手計算で求めよ（$\boldsymbol{X}\boldsymbol{X}^\top$ の固有値分解から出発し、$\boldsymbol{v}_i = \boldsymbol{X}^\top \boldsymbol{u}_i / \sigma_i$ で右特異ベクトルを作る）。さらに $\sigma_1 \sigma_2 = |\det \boldsymbol{X}|$ と $\sigma_1^2 + \sigma_2^2 = \|\boldsymbol{X}\|_{\mathrm{F}}^2$ を確かめ、ランク 1 の最良近似 $\boldsymbol{X}_1$ と誤差 $\|\boldsymbol{X} - \boldsymbol{X}_1\|_{\mathrm{F}}$ を求めよ。

演習 2.4 ($\star\star$). $\boldsymbol{A}$ を対称行列、$\boldsymbol{P}$ を階数 k の直交射影行列とする。$\operatorname{tr}(\boldsymbol{P}\boldsymbol{A}\boldsymbol{P}) = \operatorname{tr}(\boldsymbol{A}\boldsymbol{P})$ を示し、$\max\{\operatorname{tr}(\boldsymbol{A}\boldsymbol{P}) : \boldsymbol{P}$ は階数k の直交射影$\} = \sum_{i=1}^{k} \lambda_i(\boldsymbol{A})$ を 系 2.23から導け。これが第3章の PCA の定式化とどう対応するか述べよ。

演習 2.5 (★★)**.** リッジ解 $\boldsymbol{w}_\lambda$（式 (2.23)）について次を示せ。(a) $\|\boldsymbol{w}_\lambda\|$ は λ について単調非増加で、$\lambda \to \infty$ で $\boldsymbol{0}$、$\lambda \to 0^{+}$ で $\|(\boldsymbol{X}^\top)^{+}\boldsymbol{y}\|$ に収束する。(b) 残差 $\|\boldsymbol{X}^\top \boldsymbol{w}_\lambda - \boldsymbol{y}\|$ は λ について単調非減少である。(c) $\boldsymbol{X}$ が行フルランクでないときでも $\boldsymbol{w}_\lambda$ が一意に定まる理由を述べよ。

演習 2.6 (★★)**.** 作用素ノルムに対する Eckart–Young–Mirsky の定理 $\min\{\|\boldsymbol{X}-\boldsymbol{B}\|_{\mathrm{op}} : \operatorname{rank}\boldsymbol{B} \le k\} = \sigma_{k+1}$ を証明せよ。（ヒント：$\boldsymbol{B} \in \mathbb{R}^{d\times n}$ で $\operatorname{rank}\boldsymbol{B} \le k$ なら $\dim\operatorname{Ker}(\boldsymbol{B}) \ge n-k$ である（核は $\mathbb{R}^n$ の部分空間）。一方 $S := \operatorname{span}\{\boldsymbol{v}_1,\dots,\boldsymbol{v}_{k+1}\} \subset \mathbb{R}^n$ は $k+1$ 次元だから、$(n-k)+(k+1) > n$ より $\operatorname{Ker}(\boldsymbol{B}) \cap S \neq \{\boldsymbol{0}\}$。この共通部分の単位ベクトルを使え。）

演習 2.7 (★★★)**.** （特異値の摂動）$\boldsymbol{X}, \boldsymbol{E} \in \mathbb{R}^{d\times n}$ とし、$\sigma_i(\cdot)$ で降順の特異値を表す。Courant–Fischer の定理（定理 2.22）を $\boldsymbol{X}^\top\boldsymbol{X}$（$n\times n$）に適用して、Weyl の不等式 $|\sigma_i(\boldsymbol{X}+\boldsymbol{E}) - \sigma_i(\boldsymbol{X})| \le \|\boldsymbol{E}\|_{\mathrm{op}}$ を示せ。さらにこれを用いて、定理 2.28の Frobenius 版の別証明（$\|\boldsymbol{X}-\boldsymbol{B}\|_{\mathrm{F}}^2 \ge \sum_{i>k}\sigma_i(\boldsymbol{X})^2$）を与えよ。

演習 2.8 (★★、実装)**.** 条件数の悪いデータ行列に対し、$\boldsymbol{X}\boldsymbol{X}^\top$ の固有値分解から特異値を求める方法と $\boldsymbol{X}$ の SVD を直接計算する方法の精度を比較せよ。

(a) 条件数 κ をもつ 12×200 の行列（$d=12$ 変数、$n=200$ サンプル）を $\boldsymbol{X} = \boldsymbol{U}_0\operatorname{diag}(s)\boldsymbol{V}_0^\top$（$\boldsymbol{U}_0 \in \mathbb{R}^{d\times d}$ はランダムな直交行列、$\boldsymbol{V}_0 \in \mathbb{R}^{n\times d}$ は列直交、s は 1 から $1/\kappa$ まで対数等間隔）として生成せよ。

(b) $\kappa = 10^2, 10^4, \dots, 10^{12}$ に対し両方法で特異値を計算し、真値 s との最大相対誤差を両対数プロットにせよ。

(c) 曲線の傾きから「条件数が 2 乗になる」という主張を読み取り、$\boldsymbol{X}\boldsymbol{X}^\top$ 経由の方法が破綻し始める κ の目安を述べよ。

演習 2.9 (★★、実装)**.** Eckart–Young の定理を数値実験で確かめよ。

(a) ランク 12 程度の 20×50 行列 $\boldsymbol{X}$（$d=20$ 変数、$n=50$ サンプル）を作り、各 k について $\|\boldsymbol{X}-\boldsymbol{X}_k\|_{\mathrm{F}}^2$ と $\sum_{i>k}\sigma_i^2$ が一致することを確認せよ。

(b) ランク k のランダム行列 $\boldsymbol{B}$ を多数生成し、$\|\boldsymbol{X}-\boldsymbol{B}\|_{\mathrm{F}}$ が常に $\|\boldsymbol{X}-\boldsymbol{X}_k\|_{\mathrm{F}}$ 以上であることをヒストグラムで示せ。

(c) 画像（`scipy.datasets.ascent()` 等）に対して $k = 1, 5, 20, 50$ の近似を表示し、記憶量と相対誤差の表を作れ。

演習 2.10 (★★)**.** （Rayleigh 商の停留性）コラムで述べた「固有ベクトルで Rayleigh 商が停留値をとる」ことを確かめる。対称行列 $\boldsymbol{A}$ の最大固有値を λ_1、対応する単位固有ベクトルを $\boldsymbol{u}_1$ とし、$\boldsymbol{p} \perp \boldsymbol{u}_1$, $\|\boldsymbol{p}\| = 1$ として $\boldsymbol{x}_\varepsilon := \boldsymbol{u}_1 + \varepsilon\boldsymbol{p}$ とおく。

(a) $R_{\boldsymbol{A}}(\boldsymbol{x}_\varepsilon) = \dfrac{\lambda_1 + \varepsilon^2\,\boldsymbol{p}^\top\boldsymbol{A}\boldsymbol{p}}{1+\varepsilon^2}$ を示せ。（ヒント：$\boldsymbol{u}_1^\top\boldsymbol{A}\boldsymbol{p} = \lambda_1\boldsymbol{u}_1^\top\boldsymbol{p} = 0$。）

(b) これより $\lambda_1 - R_{\boldsymbol{A}}(\boldsymbol{x}_\varepsilon) = \dfrac{\varepsilon^2(\lambda_1 - \boldsymbol{p}^\top\boldsymbol{A}\boldsymbol{p})}{1+\varepsilon^2} = O(\varepsilon^2)$ を導け。ε の一次の項が現れないことが停留性である。

(c) $d=6$ のランダムな対称行列を作り、$\varepsilon = 10^{-1}, 10^{-2}, 10^{-3}, 10^{-4}$ に対し $\lambda_1 - R_{\boldsymbol{A}}(\boldsymbol{x}_\varepsilon)$ を数値で求め、ε を 10 分の 1 にすると差が 100 分の 1 になることを確認せよ。

(d) 一方 $\boldsymbol{u}_1$ 自体の誤差は $\|\boldsymbol{x}_\varepsilon/\|\boldsymbol{x}_\varepsilon\| - \boldsymbol{u}_1\| = O(\varepsilon)$ である。「固有値の推定は固有ベクトルの推定より一桁精度が良い」と言えるのはなぜか説明せよ。

第 3 章

主成分分析の理論

この章のねらい

主成分分析（principal component analysis, PCA）は、データ行列から「情報の多い少数の方向」を取り出す最も基本的な手法である。この章では PCA を三つの異なる言葉——分散最大化、再構成誤差最小化、低ランク近似——で定式化し、それらが同一の解を与えることを証明する。第2章で用意した固有値分解・特異値分解・Courant–Fischer の定理が、ここで初めて統計的な意味を持つ。さらに次元選択、前処理の落とし穴、白色化、確率モデルとしての PCA を扱い、最後に限界を明示して第8章へ橋を架ける。[a]

[a] この章の計算は演習ノートブック `ch03_pca.ipynb` で再現できる。インストール不要で実行するには Google Colab で開く：`https://colab.research.google.com/github/yusukeimoto/data-analysis-math-demos/blob/main/notebooks/ch03_pca.ipynb`

3.1 なぜ次元を減らすのか

手書き数字の 28×28 濃淡画像は $d = 784$ 個の実数、すなわち $\mathbb{R}^{784}$ の点である。しかし $\mathbb{R}^{784}$ から一様乱数でベクトルを選んで画像にすれば、得られるのは砂嵐であって数字ではない。「人間が書いた数字」は $\mathbb{R}^{784}$ の中でごく薄い部分集合を占めるにすぎず、784 個の座標は互いに強く依存している。遺伝子発現データ（$d \approx 2 \times 10^4$, $n \approx 10^2$）でも遺伝子は経路ごとに協調して動くので変動は少数の「軸」でほぼ説明でき、50 問のアンケートの背後には「外向性」といった少数の潜在因子が仮定される。

この章を貫く問い

観測された d 個の変数は本当に d 次元分の情報を持っているのか。実質的な自由度が $k \ll d$ なら、その k 次元をどう見つければよいのか。

次元削減の動機は三つある。**可視化**——人間が直接見られるのは 2〜3 次元までだが、うまく選んだ 2 次元平面に射影すればクラスタの有無や外れ値が一目で分かることがある。**ノイズ除去**——信号が少数の方向に集中しノイズが全方向に薄く広がっているなら、分散の大きい方向だけを残す操作は信号対ノイズ比（SNR）を改善する（第5章で高次元漸近論により検討する）。**後段の学習の容易化**——d を減らすことは推定すべきパラメータを減らし推定量の分散を下げる。これは第1章の正則化つき経験リスク最小化の枠組みで仮説集合を小さくする操作にあたる。なお第1章で、次元削減系の手法は Rayleigh 商の最大化すなわち一般化固有値問題 $\boldsymbol{A}\boldsymbol{w} = \lambda \boldsymbol{B}\boldsymbol{w}$ に統一できると述べた。PCA はその最も単純な場合 $\boldsymbol{A} = \widehat{\boldsymbol{\Sigma}}$, $\boldsymbol{B} = \boldsymbol{I}_d$ であり、$\boldsymbol{B}$ を別の散布行列に取り替えると線形判別分析や正準相関分析になる（第6章）。

3.2 記法の確認と三つの定式化

3.2.1 データ行列と標本共分散

データ行列 $\boldsymbol{X} \in \mathbb{R}^{d \times n}$ は第 i 列が $\boldsymbol{x}_i$、すなわち**列がサンプル**である。$\bar{\boldsymbol{x}} := \frac{1}{n}\sum_i \boldsymbol{x}_i = \frac{1}{n}\boldsymbol{X}\mathbf{1}$、$\boldsymbol{H} := \boldsymbol{I}_n - \frac{1}{n}\mathbf{1}\mathbf{1}^\top$（$n \times n$）とし、中心化データ行列を $\widetilde{\boldsymbol{X}} := \boldsymbol{X}\boldsymbol{H}$（**右**から掛ける。第 i 列が $\tilde{\boldsymbol{x}}_i = \boldsymbol{x}_i - \bar{\boldsymbol{x}}$）、標本共分散行列を

$$\widehat{\boldsymbol{\Sigma}} := \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top = \frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{x}_i - \bar{\boldsymbol{x}})(\boldsymbol{x}_i - \bar{\boldsymbol{x}})^\top \tag{3.1}$$

と書く。$\widehat{\boldsymbol{\Sigma}}$ は対称かつ半正定値だから、スペクトル分解

$$\widehat{\boldsymbol{\Sigma}} = \boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^{\top} = \sum_{j=1}^{d} \lambda_j \boldsymbol{u}_j \boldsymbol{u}_j^{\top}, \qquad \lambda_1 \geq \cdots \geq \lambda_d \geq 0 \tag{3.2}$$

を持つ（第2章）。$\widetilde{\boldsymbol{X}}$ の特異値分解を $\widetilde{\boldsymbol{X}} = \boldsymbol{U}\boldsymbol{S}\boldsymbol{V}^{\top}$（$\boldsymbol{U} \in \mathbb{R}^{d\times r}$ が変数側、$\boldsymbol{V} \in \mathbb{R}^{n\times r}$ がサンプル側、$r = \operatorname{rank}\widetilde{\boldsymbol{X}}$）と書けば $\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\boldsymbol{U}\boldsymbol{S}\boldsymbol{S}^{\top}\boldsymbol{U}^{\top}$、すなわち

$$\widehat{\boldsymbol{\Sigma}} = \boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^{\top}, \qquad \widetilde{\boldsymbol{X}} = \boldsymbol{U}\boldsymbol{S}\boldsymbol{V}^{\top}, \qquad \lambda_j = \sigma_j^2/n \tag{3.3}$$

であり、**$\widehat{\boldsymbol{\Sigma}}$ の固有ベクトルは $\widetilde{\boldsymbol{X}}$ の左特異ベクトルに他ならない**。この対応は繰り返し使う。なお分母を n とするか $n-1$ とするかは流儀の問題で、固有ベクトルは分母によらず固有値は定数倍されるだけなので方向の議論に影響はない（`scikit-learn` の `explained_variance_` は $n-1$ 版なので手計算と比べる際は注意）。

3.2.2　三つの定式化

PCA は歴史的にも論理的にも異なる三つの出発点を持つ。

(F1) 分散最大化（Hotelling [42]）——方向 $\boldsymbol{w}$（$\|\boldsymbol{w}\| = 1$）に射影して得られる値 $z_i = \boldsymbol{w}^{\top}\tilde{\boldsymbol{x}}_i$ の標本平均は 0、標本分散は

$$\frac{1}{n}\sum_{i} z_i^2 = \frac{1}{n}\|\boldsymbol{w}^{\top}\widetilde{\boldsymbol{X}}\|^2 = \boldsymbol{w}^{\top}\widehat{\boldsymbol{\Sigma}}\boldsymbol{w} \tag{3.4}$$

である。これを最大にする $\boldsymbol{w}$ を選ぶ。「散らばりが大きい方向ほど情報を多く含む」という素朴だが強力な発想に基づく。

(F2) 再構成誤差最小化（Pearson [59]）——k 次元部分空間を選び各点をそこへ直交射影して $\boldsymbol{P}\tilde{\boldsymbol{x}}_i$ と近似し、$\frac{1}{n}\sum_i \|\tilde{\boldsymbol{x}}_i - \boldsymbol{P}\tilde{\boldsymbol{x}}_i\|^2$ を最小にする $\boldsymbol{P}$ を選ぶ。「データを最もよく説明する平面を通す」という回帰的発想だが、通常の回帰と違い誤差を測るのは目的変数方向の距離ではなく平面への**垂直**距離である。

(F3) 低ランク近似——$\boldsymbol{W} \in \mathbb{R}^{d\times k}$（$\boldsymbol{W}^{\top}\boldsymbol{W} = \boldsymbol{I}_k$），$\boldsymbol{Z} \in \mathbb{R}^{k\times n}$ により $\|\widetilde{\boldsymbol{X}} - \boldsymbol{W}\boldsymbol{Z}\|_{\mathrm{F}}^2$ を最小化する。「$d \times n$ の表を二つの小さな表の積に分解して圧縮する」という行列論的発想で、第2章の Eckart–Young の定理が直接効く場面である。

(F1) と (F2) の対比が図 3.1である。左は射影された点の広がりを最大にする直線を、右は各点から直線への垂線の二乗和を最小にする直線を選んでいるが、両者は一致する。

歴史的順序：先に来たのは (F2) である

番号の順序と歴史の順序は逆である。最初の定式化は Pearson (1901) [59] の (F2) で、論文の題名がそのまま「点の集まりに最もよく当てはまる直線と平面について」（On lines and planes of closest fit to systems of points in space）であり、垂直距離の二乗和を最小にする直線・平面を求める問題として立てられている。分散最大化 (F1) を主成分の定義として与え、標本共分散行列の固有値問題として整理し、**主成分**（principal component）という名前を与えたのは 32 年後の Hotelling (1933) [42] である。つまり「最もよく当てはめる」（近似の問題）が先にあり、「分散が最大の方向を探す」（変動の説明の問題）が後から来て、定理 3.2で両者が同じ解に帰着することが分かった。本書が (F1) を先に置くのは、第2章の Rayleigh 商から直接つながって証明が短くなるという教育上の都合にすぎない。

3.3　三つの定式化の同値性

3.3.1　鍵となる補題：ピタゴラスの定理

三つを結ぶ蝶番は初等幾何のピタゴラスの定理である。

補題 3.1（直交分解）**.** $\boldsymbol{P}$ を階数 k の直交射影行列（$\boldsymbol{P}^{\top} = \boldsymbol{P}$, $\boldsymbol{P}^2 = \boldsymbol{P}$）とすると、任意の $\boldsymbol{x} \in \mathbb{R}^d$ に対し $\|\boldsymbol{x}\|^2 = \|\boldsymbol{P}\boldsymbol{x}\|^2 + \|\boldsymbol{x} - \boldsymbol{P}\boldsymbol{x}\|^2$。

証明. $\boldsymbol{x} = \boldsymbol{P}\boldsymbol{x} + (\boldsymbol{x} - \boldsymbol{P}\boldsymbol{x})$ と分解すると、$\boldsymbol{P}^{\top} = \boldsymbol{P}$, $\boldsymbol{P}^2 = \boldsymbol{P}$ から $\langle \boldsymbol{P}\boldsymbol{x}, \boldsymbol{x} - \boldsymbol{P}\boldsymbol{x}\rangle = \boldsymbol{x}^{\top}\boldsymbol{P}^{\top}(\boldsymbol{I} - \boldsymbol{P})\boldsymbol{x} = \boldsymbol{x}^{\top}(\boldsymbol{P} - \boldsymbol{P}^2)\boldsymbol{x} = 0$ であり両成分は直交する。よって $\|\boldsymbol{x}\|^2$ を展開したときの交差項が消えて主張を得る。 ■

これを全データ点で足し合わせる。$\boldsymbol{P} = \boldsymbol{W}\boldsymbol{W}^{\top}$（$\boldsymbol{W}^{\top}\boldsymbol{W} = \boldsymbol{I}_k$）と書けるとき

$$\underbrace{\frac{1}{n}\sum_{i}\|\tilde{\boldsymbol{x}}_i\|^2}_{\text{全分散}=\operatorname{tr}\widehat{\boldsymbol{\Sigma}}} = \underbrace{\frac{1}{n}\sum_{i}\|\boldsymbol{P}\tilde{\boldsymbol{x}}_i\|^2}_{\text{射影の分散}=\operatorname{tr}(\boldsymbol{W}^{\top}\widehat{\boldsymbol{\Sigma}}\boldsymbol{W})} + \underbrace{\frac{1}{n}\sum_{i}\|\tilde{\boldsymbol{x}}_i - \boldsymbol{P}\tilde{\boldsymbol{x}}_i\|^2}_{\text{残差の分散}}. \tag{3.5}$$

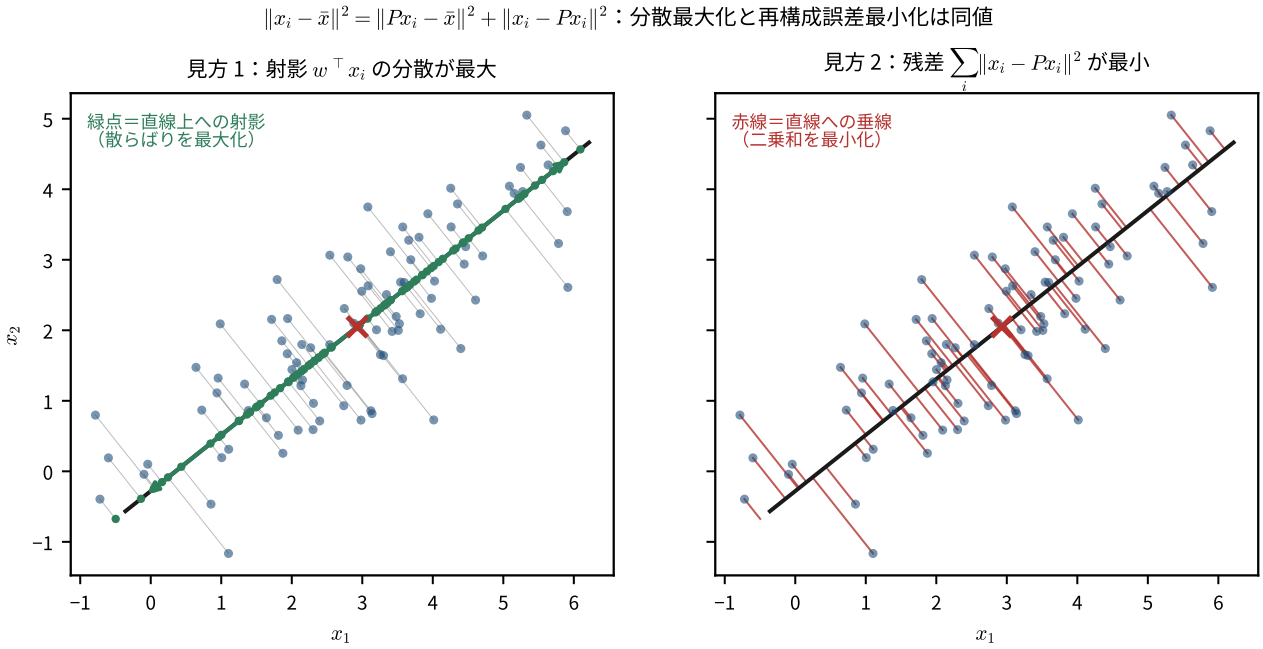


図3.1　主成分分析の二つの見方。左は射影後の分散を最大化する見方、右は直線への垂直距離の二乗和を最小化する見方であり、両者は同じ解を与える。

実際、中央の項は $\boldsymbol{W}^\top \boldsymbol{W} = \boldsymbol{I}_k$ より $\frac{1}{n}\sum_i \tilde{\boldsymbol{x}}_i^\top \boldsymbol{W}\boldsymbol{W}^\top \boldsymbol{W}\boldsymbol{W}^\top \tilde{\boldsymbol{x}}_i = \mathrm{tr}(\boldsymbol{W}^\top (\frac{1}{n}\sum_i \tilde{\boldsymbol{x}}_i \tilde{\boldsymbol{x}}_i^\top)\boldsymbol{W}) = \mathrm{tr}(\boldsymbol{W}^\top \widehat{\boldsymbol{\Sigma}}\boldsymbol{W})$ である。左辺は $\boldsymbol{P}$ に依存しない定数だから、**射影の分散を最大にすることと残差を最小にすることは完全に同じ問題**である。図 3.1が視覚的に表すのもこの一行の恒等式である。

3.3.2　同値性定理

定理 3.2 (三つの定式化の同値性)**.** $\boldsymbol{U}_k \coloneqq (\boldsymbol{u}_1, \dots, \boldsymbol{u}_k)$ とおく（$\boldsymbol{U}$ の先頭 k 列、$d \times k$）。三つの最適化問題

$$\text{(F1)} \quad \max_{\boldsymbol{W}^\top \boldsymbol{W} = \boldsymbol{I}_k} \mathrm{tr}(\boldsymbol{W}^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{W}), \quad \text{(F2)} \quad \min_{\boldsymbol{W}^\top \boldsymbol{W} = \boldsymbol{I}_k} \frac{1}{n}\|\widetilde{\boldsymbol{X}} - \boldsymbol{W}\boldsymbol{W}^\top \widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^2, \quad \text{(F3)} \quad \min_{\boldsymbol{Z},\, \boldsymbol{W}^\top \boldsymbol{W} = \boldsymbol{I}_k} \|\widetilde{\boldsymbol{X}} - \boldsymbol{W}\boldsymbol{Z}\|_{\mathrm{F}}^2$$

は共通の最適解 $\boldsymbol{W} = \boldsymbol{U}_k$（(F3) では $\boldsymbol{Z} = \boldsymbol{U}_k^\top \widetilde{\boldsymbol{X}}$）を持ち、最適値はそれぞれ $\sum_{j \le k} \lambda_j$、$\sum_{j > k} \lambda_j$、$n \sum_{j > k} \lambda_j = \sum_{j > k} \sigma_j^2$ である。さらに $\lambda_k > \lambda_{k+1}$ ならば最適な部分空間 $\mathrm{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_k\}$ は一意である。

***(F1)*$\Longleftrightarrow$*(F2)*.** 式 (3.5)より任意の $\boldsymbol{W}$ に対し $\frac{1}{n}\|\widetilde{\boldsymbol{X}} - \boldsymbol{W}\boldsymbol{W}^\top \widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^2 = \frac{1}{n}\sum_i \|\tilde{\boldsymbol{x}}_i - \boldsymbol{W}\boldsymbol{W}^\top \tilde{\boldsymbol{x}}_i\|^2 = \mathrm{tr}\,\widehat{\boldsymbol{\Sigma}} - \mathrm{tr}(\boldsymbol{W}^\top \widehat{\boldsymbol{\Sigma}}\boldsymbol{W})$。右辺第一項は $\boldsymbol{W}$ に依存しないから、左辺の最小化と $\mathrm{tr}(\boldsymbol{W}^\top \widehat{\boldsymbol{\Sigma}}\boldsymbol{W})$ の最大化は同じ $\boldsymbol{W}$ を最適解に持ち、最適値の和は $\mathrm{tr}\,\widehat{\boldsymbol{\Sigma}} = \sum_j \lambda_j$ に等しい。 ■

***(F2)*$\Longleftrightarrow$*(F3)*.** まず $\boldsymbol{W}$ を固定し $\boldsymbol{Z}$ について最小化する。目的関数 $g(\boldsymbol{Z}) = \mathrm{tr}(\widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}) - 2\,\mathrm{tr}(\boldsymbol{Z}^\top \boldsymbol{W}^\top \widetilde{\boldsymbol{X}}) + \mathrm{tr}(\boldsymbol{Z}^\top \boldsymbol{Z})$（最後の項で $\boldsymbol{W}^\top \boldsymbol{W} = \boldsymbol{I}_k$ を使った）は $\boldsymbol{Z}$ について二次で凸、勾配 $\nabla_{\boldsymbol{Z}} g = -2\boldsymbol{W}^\top \widetilde{\boldsymbol{X}} + 2\boldsymbol{Z}$ より停留点は

$$\boldsymbol{Z}^\star = \boldsymbol{W}^\top \widetilde{\boldsymbol{X}} \tag{3.6}$$

であり、凸性よりこれが最小点である。代入すると $\|\widetilde{\boldsymbol{X}} - \boldsymbol{W}\boldsymbol{W}^\top \widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^2 = \sum_i \|\tilde{\boldsymbol{x}}_i - \boldsymbol{W}\boldsymbol{W}^\top \tilde{\boldsymbol{x}}_i\|^2$（$\widetilde{\boldsymbol{X}}$ の第 i 列が $\tilde{\boldsymbol{x}}_i$）となり、これは (F2) の目的関数の n 倍である。逆向きの見方も有益である。$\boldsymbol{Z}, \boldsymbol{W}$ を動かすと $\boldsymbol{W}\boldsymbol{Z}$ は階数 k 以下の行列全体を走るから (F3) は $\min_{\mathrm{rank}\,\boldsymbol{B} \le k} \|\widetilde{\boldsymbol{X}} - \boldsymbol{B}\|_{\mathrm{F}}^2$ と書き直せ、第2章の Eckart–Young の定理より最小値は $\sum_{j > k} \sigma_j^2$、最小点は打ち切り特異値分解 $\boldsymbol{U}_k \boldsymbol{U}_k^\top \widetilde{\boldsymbol{X}}$ である。式 (3.3)より $\sum_{j > k} \sigma_j^2 = n \sum_{j > k} \lambda_j$ となり、定理の最適値を得る。 ■

残るのは (F1) の最適値が $\sum_{j \le k} \lambda_j$ であり $\boldsymbol{W} = \boldsymbol{U}_k$ で達成されるという事実だが、これは次節で Ky Fan の定理として独立に証明する。なお定理が主張するのは**部分空間**の一意性であって $\boldsymbol{W}$ 自体の一意性ではない（任意の直交行列 $\boldsymbol{Q}$ に対し $\boldsymbol{W}\boldsymbol{Q}$ も同じ射影を与える）。個々の方向 $\boldsymbol{u}_j$ が符号を除いて一意なのは $\lambda_{j-1} > \lambda_j > \lambda_{j+1}$ のときに限り、$\lambda_k = \lambda_{k+1}$ なら k 次元部分空間すら一意でない。

3.4　主成分の逐次的導出

3.4.1　第 1 主成分：ラグランジュ乗数法

まず $k=1$ の場合を丁寧に解く。解くべき問題は

$$\max_{\boldsymbol{w}\in\mathbb{R}^d} \ \boldsymbol{w}^\top \widehat{\boldsymbol{\Sigma}}\boldsymbol{w} \quad \text{s.t.} \quad \|\boldsymbol{w}\|^2 = 1. \tag{3.7}$$

命題 3.3 (第 1 主成分)**.** 式 (3.7)の最大値は λ_1 であり、最大を与える $\boldsymbol{w}$ は $\widehat{\boldsymbol{\Sigma}}$ の固有値 λ_1 に属する単位固有ベクトルである。

証明. 単位球面 $\mathbb{S}^{d-1}=\{\boldsymbol{w}:\|\boldsymbol{w}\|=1\}$ はコンパクトで $\boldsymbol{w}\mapsto \boldsymbol{w}^\top\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}$ は連続だから、Weierstrass の定理により最大値は達成される。ラグランジュ関数を $L(\boldsymbol{w},\mu)=\boldsymbol{w}^\top\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}-\mu(\boldsymbol{w}^\top\boldsymbol{w}-1)$ とおくと、制約 $g(\boldsymbol{w})=\boldsymbol{w}^\top\boldsymbol{w}-1$ の勾配 $\nabla g=2\boldsymbol{w}$ は $\mathbb{S}^{d-1}$ 上で $\boldsymbol{0}$ にならないので制約想定が全点で満たされる。よって最大点 $\boldsymbol{w}^\star$ には乗数 $\mu^\star$ が存在して $2\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}^\star-2\mu^\star\boldsymbol{w}^\star=\boldsymbol{0}$、すなわち $\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}^\star=\mu^\star\boldsymbol{w}^\star$。最大点は $\widehat{\boldsymbol{\Sigma}}$ の固有ベクトルであり、そこでの目的関数の値は $\boldsymbol{w}^{\star\top}\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}^\star=\mu^\star\|\boldsymbol{w}^\star\|^2=\mu^\star$、すなわち対応する固有値そのものである。候補は $\lambda_1,\dots,\lambda_d$ に限られ、$\boldsymbol{w}=\boldsymbol{u}_1$ で最大値 λ_1 が達成される。 ■

ラグランジュ乗数法を使わない見方も与えておく（第 2 主成分以降への拡張がしやすい）。$\boldsymbol{w}=\sum_j c_j\boldsymbol{u}_j$ と展開すれば ($\sum_j c_j^2=1$)、式 (3.2)より

$$\boldsymbol{w}^\top\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}=\sum_{j=1}^{d}\lambda_j c_j^2, \tag{3.8}$$

すなわち二次形式は固有値の、重み $c_j^2\ge 0$（総和 1）による**凸結合**である。凸結合は最大要素を超えないから $\boldsymbol{w}^\top\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}\le\lambda_1$、等号は $\lambda_j<\lambda_1$ なる j すべてで $c_j=0$、すなわち $\boldsymbol{w}$ が λ_1 の固有空間に属するときに限る。この式 (3.8)が以下の議論の核である。

3.4.2　第 2 主成分以降と Ky Fan の定理

次に知りたいのは「第 1 主成分と重複しない情報のうちで最大のもの」である。重複しないことを直交性で表せば、第 j 主成分は既に得た $\boldsymbol{u}_1,\dots,\boldsymbol{u}_{j-1}$ すべてと直交する制約の下での同じ最大化問題の解として定義される。

命題 3.4 (逐次最適化)**.** $\max\{\boldsymbol{w}^\top\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}:\|\boldsymbol{w}\|=1,\ \boldsymbol{w}^\top\boldsymbol{u}_l=0\ (l<j)\}$ の最大値は λ_j であり、$\boldsymbol{w}=\boldsymbol{u}_j$ で達成される。

証明. 展開 $\boldsymbol{w}=\sum_m c_m\boldsymbol{u}_m$ において制約 $\boldsymbol{w}^\top\boldsymbol{u}_l=0$ は $c_l=0$（$l<j$）を意味するから、$\boldsymbol{w}^\top\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}=\sum_{m\ge j}\lambda_m c_m^2$ ($\sum_{m\ge j}c_m^2=1$) は $\lambda_j,\dots,\lambda_d$ の凸結合であり最大要素 λ_j を超えず、$\boldsymbol{w}=\boldsymbol{u}_j$ で等号が達成される。 ■

したがって逐次的に方向を選ぶと $\widehat{\boldsymbol{\Sigma}}$ の固有ベクトルが固有値の降順に得られる。これが「主成分を第 1、第 2、… と順に取る」という実務上の手続きの正当化である。

定義 3.5 (主成分)**.** $\boldsymbol{u}_j$（$\boldsymbol{U}$ の第 j 列）を**第 j 主成分方向**（j-th principal direction）あるいは**負荷ベクトル**（loading vector）と呼び、$z_{ji}:=\boldsymbol{u}_j^\top\tilde{\boldsymbol{x}}_i$ を標本 i の**第 j 主成分スコア**（principal component score）と呼ぶ。

しかし逐次最適化は「一方向ずつ貪欲に選ぶ」手続きであり、貪欲法が大域最適を与えるとは限らないから、これが k 次元部分空間を一度に最適化した答えと一致することは自明ではない。保証を与えるのが Ky Fan の定理であり、定理 3.2の残されたピースでもある。第2章の Courant–Fischer の最小最大定理 $\lambda_j=\max_{\dim\mathcal{L}=j}\min_{\boldsymbol{w}\in\mathcal{L},\|\boldsymbol{w}\|=1}\boldsymbol{w}^\top\boldsymbol{A}\boldsymbol{w}$ は λ_j を特定の固有ベクトルに言及せず部分空間だけで特徴づけるものであった。Ky Fan の定理はそのトレース版である。

定理 3.6 (Ky Fan)**.** $\boldsymbol{A}\in\mathbb{R}^{d\times d}$ を対称行列、固有値を降順に $\lambda_1\ge\cdots\ge\lambda_d$、対応する正規直交固有ベクトルを $\boldsymbol{u}_1,\dots,\boldsymbol{u}_d$ とする。$1\le k\le d$ に対し

$$\max_{\boldsymbol{W}^\top\boldsymbol{W}=\boldsymbol{I}_k}\ \operatorname{tr}(\boldsymbol{W}^\top\boldsymbol{A}\boldsymbol{W})=\sum_{j=1}^{k}\lambda_j$$

であり、最大は $\boldsymbol{W}=\boldsymbol{U}_k=(\boldsymbol{u}_1,\dots,\boldsymbol{u}_k)$ で達成される。

証明. $\boldsymbol{W}=\boldsymbol{U}_k$ のとき $\operatorname{tr}(\boldsymbol{U}_k^\top\boldsymbol{A}\boldsymbol{U}_k)=\sum_{j\le k}\boldsymbol{u}_j^\top\boldsymbol{A}\boldsymbol{u}_j=\sum_{j\le k}\lambda_j$ だから、最大値はこれ以上である。上からの評価を示す。$\boldsymbol{W}^\top\boldsymbol{W}=\boldsymbol{I}_k$ なる任意の $\boldsymbol{W}$ に対し $\boldsymbol{P}:=\boldsymbol{W}\boldsymbol{W}^\top$（階数 k の直交射影）とおき、$\boldsymbol{A}=\sum_j\lambda_j\boldsymbol{u}_j\boldsymbol{u}_j^\top$ を代入すると

$$\operatorname{tr}(\boldsymbol{W}^\top\boldsymbol{A}\boldsymbol{W})=\operatorname{tr}(\boldsymbol{A}\boldsymbol{P})=\sum_{j=1}^{d}\lambda_j c_j,\qquad c_j:=\boldsymbol{u}_j^\top\boldsymbol{P}\boldsymbol{u}_j.$$

係数 c_j は二性質を持つ。第一に $0 \le c_j \le 1$：$\boldsymbol{P}$ は直交射影だから $c_j = \boldsymbol{u}_j^\top \boldsymbol{P}\boldsymbol{P}\boldsymbol{u}_j = \|\boldsymbol{P}\boldsymbol{u}_j\|^2 \ge 0$ であり、補題 3.1より $\|\boldsymbol{P}\boldsymbol{u}_j\|^2 \le \|\boldsymbol{u}_j\|^2 = 1$。第二に $\sum_j c_j = \operatorname{tr}(\boldsymbol{P}\sum_j \boldsymbol{u}_j\boldsymbol{u}_j^\top) = \operatorname{tr}\boldsymbol{P} = \operatorname{tr}(\boldsymbol{W}^\top\boldsymbol{W}) = k$。そこで λ_k を基準に $\sum_j \lambda_j c_j = \sum_j (\lambda_j - \lambda_k)c_j + k\lambda_k$ と書き換える。$j \le k$ では $\lambda_j - \lambda_k \ge 0$, $c_j \le 1$ だから $(\lambda_j - \lambda_k)c_j \le \lambda_j - \lambda_k$。$j > k$ では $\lambda_j - \lambda_k \le 0$, $c_j \ge 0$ だから $(\lambda_j - \lambda_k)c_j \le 0$。よって $\sum_j \lambda_j c_j \le \sum_{j\le k}(\lambda_j - \lambda_k) + k\lambda_k = \sum_{j\le k}\lambda_j$ であり、最大値は $\sum_{j\le k}\lambda_j$ である。 ■

系 3.7. 定理 3.2が完全に証明された。特に、主成分を一方向ずつ逐次的に選ぶ貪欲法は k 次元部分空間を一挙に最適化した結果と一致する。

証明. 定理 3.6を $\boldsymbol{A} = \widehat{\boldsymbol{\Sigma}}$ に適用すれば (F1) の最適値が $\sum_{j\le k}\lambda_j$、最適解が $\boldsymbol{U}_k$ と分かる。(F1)⇔(F2)⇔(F3) は既に示し、命題 3.4の貪欲解 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_k$ はこれと一致する。一意性については、$\lambda_k > \lambda_{k+1}$ のとき上の評価で等号が成立するには $j \le k$ で $c_j = 1$、$j > k$ で $c_j = 0$ が必要であり、$c_j = \|\boldsymbol{P}\boldsymbol{u}_j\|^2$ だから $\boldsymbol{u}_1, \dots, \boldsymbol{u}_k$ が $\boldsymbol{P}$ の像に、残りが核に含まれ、$\boldsymbol{P} = \boldsymbol{U}_k\boldsymbol{U}_k^\top$ が確定する。 ■

例 3.8 (2×2 の手計算)**.** 5 個の 2 次元データ $(1,1),(2,3),(3,5),(4,2),(5,4)$ を列に並べた $\boldsymbol{X} = \begin{pmatrix} 1 & 2 & 3 & 4 & 5 \\ 1 & 3 & 5 & 2 & 4 \end{pmatrix} \in \mathbb{R}^{2\times 5}$ を考える。標本平均は $\bar{\boldsymbol{x}} = (3,3)^\top$、中心化すると $\widetilde{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{H} = \begin{pmatrix} -2 & -1 & 0 & 1 & 2 \\ -2 & 0 & 2 & -1 & 1 \end{pmatrix}$ であり

$$\widehat{\boldsymbol{\Sigma}} = \frac{1}{5}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top = \frac{1}{5}\begin{pmatrix} 10 & 5 \\ 5 & 10 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

特性方程式 $(2-\lambda)^2 - 1 = 0$ より $\lambda_1 = 3$, $\lambda_2 = 1$、固有ベクトルは $\boldsymbol{u}_1 = (1,1)^\top/\sqrt{2}$, $\boldsymbol{u}_2 = (1,-1)^\top/\sqrt{2}$。第 1 主成分スコアは $\boldsymbol{u}_1^\top\widetilde{\boldsymbol{X}} = (-2\sqrt{2}, -\frac{1}{\sqrt{2}}, \sqrt{2}, 0, \frac{3}{\sqrt{2}})$（$\boldsymbol{Z}$ の第 1 行）で、標本分散は $\frac{1}{5}(8 + \frac{1}{2} + 2 + 0 + \frac{9}{2}) = 3 = \lambda_1$ となり式 (3.4)が確認できる。全分散は $\operatorname{tr}\widehat{\boldsymbol{\Sigma}} = 4 = \lambda_1 + \lambda_2$、$k = 1$ での残差二乗和は $n\lambda_2 = 5$ であり、式 (3.5)が $20 = 15 + 5$ の形で成立する。

3.5　主成分スコアと負荷量

$\boldsymbol{W}_k \coloneqq \boldsymbol{U}_k$ とおき $\boldsymbol{Z} \coloneqq \boldsymbol{W}_k^\top\widetilde{\boldsymbol{X}} \in \mathbb{R}^{k\times n}$（**左**から掛ける）を **主成分スコア行列**と呼ぶ。用語が紛らわしいので整理する。**負荷ベクトル** $\boldsymbol{u}_j \in \mathbb{R}^d$ は d 個の**変数**に対する重みで、成分 u_{lj} は「第 j 主成分を作るとき元の第 l 変数をどれだけ使うか」を表す。**スコア** $\boldsymbol{z}_i \in \mathbb{R}^k$（$\boldsymbol{Z}$ の第 i **列**）は n 個の**標本**の新しい座標で、可視化で点として描かれるのはこちらである。**相関負荷量** $\sqrt{\lambda_j}\,u_{lj}/s_l$（$s_l$ は第 l 変数の標本標準偏差）は変数 l とスコア $\boldsymbol{Z}$ の第 j **行** $z_{j\cdot}$ の標本相関係数に等しい。なお $\boldsymbol{u}_j$ そのものを負荷量と呼ぶ流儀と $\sqrt{\lambda_j}\,\boldsymbol{u}_j$ を呼ぶ流儀があり、前者は単位ベクトルなので大きさの比較には向かず、後者はスケールを含むので「その変数がどれだけ効いているか」を表す。出力を読むときはどちらの規約かを必ず確認すること（`scikit-learn` の `PCA.components_` は前者）。

命題 3.9 (スコアの共分散)**.** $\boldsymbol{Z} = \boldsymbol{W}_k^\top\widetilde{\boldsymbol{X}}$ の行平均はすべて 0 であり $\frac{1}{n}\boldsymbol{Z}\boldsymbol{Z}^\top = \boldsymbol{\Lambda}_k \coloneqq \operatorname{diag}(\lambda_1, \dots, \lambda_k)$。すなわち主成分スコアは互いに無相関で、第 j 成分の分散は λ_j に等しい。

証明. $\widetilde{\boldsymbol{X}}\boldsymbol{1} = \boldsymbol{X}\boldsymbol{H}\boldsymbol{1} = \boldsymbol{0}$（$\boldsymbol{H}\boldsymbol{1} = \boldsymbol{0}$）だから $\boldsymbol{Z}\boldsymbol{1} = \boldsymbol{0}$。また $\frac{1}{n}\boldsymbol{Z}\boldsymbol{Z}^\top = \boldsymbol{W}_k^\top\widehat{\boldsymbol{\Sigma}}\boldsymbol{W}_k = \boldsymbol{U}_k^\top\boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^\top\boldsymbol{U}_k$ であり、$\boldsymbol{U}^\top\boldsymbol{U}_k$ は (l,j) 成分が $\boldsymbol{u}_l^\top\boldsymbol{u}_j = \delta_{lj}$ の行列すなわち $\binom{\boldsymbol{I}_k}{\boldsymbol{0}}$ だから、これは $(\boldsymbol{I}_k\ \boldsymbol{0})\boldsymbol{\Lambda}\binom{\boldsymbol{I}_k}{\boldsymbol{0}} = \boldsymbol{\Lambda}_k$ に等しい。 ■

無相関化は実用上重要な副産物である。元の変数が強く相関していると回帰係数の推定が不安定になる（多重共線性）が、主成分に置き換えれば説明変数は直交する。これが主成分回帰（principal component regression）の発想であり、注意 6.34で PLS と比較する。またスコアと負荷量は別々の空間の量だが、$\widetilde{\boldsymbol{X}} = \boldsymbol{U}\boldsymbol{S}\boldsymbol{V}^\top$ を $0 \le \alpha \le 1$ に対し $\widetilde{\boldsymbol{X}} = (\boldsymbol{U}\boldsymbol{S}^{1-\alpha})(\boldsymbol{V}\boldsymbol{S}^{\alpha})^\top$ と分解し、後者（標本の座標、$n\times r$）と前者（変数の座標、$d\times r$）の先頭 2 列を同じ平面に描いた**バイプロット**（biplot）では両者を同時に読める。標本は点、変数は原点からの矢印で描き、矢印の向きが近い変数どうしは相関が高く、長さはその変数が表示平面でどれだけよく表現されているかを表す。$\alpha = 1$ は標本間の距離を、$\alpha = 0$ は変数間の共分散を忠実に再現する。例 3.8では $\boldsymbol{u}_1 = (1,1)^\top/\sqrt{2}$ で二変数の負荷が等符号・同大きさなので「第 1 主成分は 2 変数の和（平均的な大きさ）を測る」と解釈でき、$\boldsymbol{u}_2 = (1,-1)^\top/\sqrt{2}$ は差を測る。相関負荷量は $s_1 = s_2 = \sqrt{2}$ より $\sqrt{3}/2 \approx 0.866$ である。

3.5.1　PCA は距離を縮める

スコアのもう一つの基本性質は、**点と点の距離が縮むことはあっても伸びることはない**という単調性である。次元削減の手法としては当たり前に見えるが、これが成り立つのは射影が直交射影だからであって、一般の線形写像では成り立たない。

定理 3.10 (PCA 射影の非拡大性)**.** $\boldsymbol{W}_k = \boldsymbol{U}_k \in \mathbb{R}^{d\times k}$ を上位 k 本の主成分方向、$\boldsymbol{z}_i = \boldsymbol{W}_k^\top\tilde{\boldsymbol{x}}_i \in \mathbb{R}^k$ をスコアとすると、任意の i, j に対し

$$\|\boldsymbol{z}_i - \boldsymbol{z}_j\| \ \le\ \|\tilde{\boldsymbol{x}}_i - \tilde{\boldsymbol{x}}_j\| \tag{3.9}$$

が成り立つ。等号が成立するのは $\tilde{\boldsymbol{x}}_i - \tilde{\boldsymbol{x}}_j \in \operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_k\}$ のとき、かつそのときに限る。さらに**対距離の二乗和**については

$$\frac{\sum_{i<j} \|\boldsymbol{z}_i - \boldsymbol{z}_j\|^2}{\sum_{i<j} \|\tilde{\boldsymbol{x}}_i - \tilde{\boldsymbol{x}}_j\|^2} = \frac{\lambda_1 + \cdots + \lambda_k}{\lambda_1 + \cdots + \lambda_d} \tag{3.10}$$

であり、右辺は定義 3.12の**累積寄与率**に等しい。

証明. $\boldsymbol{\delta} \coloneqq \tilde{\boldsymbol{x}}_i - \tilde{\boldsymbol{x}}_j \in \mathbb{R}^d$ とおく。$\boldsymbol{z}_i - \boldsymbol{z}_j = \boldsymbol{W}_k^{\top}\boldsymbol{\delta}$ であり、$\boldsymbol{P} \coloneqq \boldsymbol{U}_k\boldsymbol{U}_k^{\top}$ は $V_k \coloneqq \operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_k\}$ への直交射影だから $\|\boldsymbol{W}_k^{\top}\boldsymbol{\delta}\| = \|\boldsymbol{U}_k\boldsymbol{U}_k^{\top}\boldsymbol{\delta}\| = \|\boldsymbol{P}\boldsymbol{\delta}\|$ （$\boldsymbol{U}_k$ の列が正規直交なので $\boldsymbol{U}_k$ を掛けてもノルムは変わらない）。ピタゴラスの定理（補題 3.1）より

$$\|\boldsymbol{\delta}\|^2 = \|\boldsymbol{P}\boldsymbol{\delta}\|^2 + \|(\boldsymbol{I} - \boldsymbol{P})\boldsymbol{\delta}\|^2 \;\geq\; \|\boldsymbol{P}\boldsymbol{\delta}\|^2 \tag{3.11}$$

であり、これが(3.9)である。等号は $\|(\boldsymbol{I} - \boldsymbol{P})\boldsymbol{\delta}\| = 0$、すなわち $\boldsymbol{\delta} \in V_k$ と同値である。

二乗和について。$\sum_i \tilde{\boldsymbol{x}}_i = \boldsymbol{0}$ を使うと、任意の中心化された点集合で

$$\sum_{i<j} \|\tilde{\boldsymbol{x}}_i - \tilde{\boldsymbol{x}}_j\|^2 = \frac{1}{2}\sum_{i,j}\bigl(\|\tilde{\boldsymbol{x}}_i\|^2 + \|\tilde{\boldsymbol{x}}_j\|^2 - 2\langle \tilde{\boldsymbol{x}}_i, \tilde{\boldsymbol{x}}_j\rangle\bigr) = n\sum_i \|\tilde{\boldsymbol{x}}_i\|^2 \tag{3.12}$$

（交差項 $\sum_{i,j}\langle \tilde{\boldsymbol{x}}_i, \tilde{\boldsymbol{x}}_j\rangle = \|\sum_i \tilde{\boldsymbol{x}}_i\|^2 = 0$ が消える）。右辺は $n\|\widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^2 = n^2 \operatorname{tr}\widehat{\boldsymbol{\Sigma}} = n^2\sum_j \lambda_j$ に等しい。スコア側も $\boldsymbol{Z}\boldsymbol{1} = \boldsymbol{0}$ だから同じ等式が使えて $\sum_{i<j}\|\boldsymbol{z}_i - \boldsymbol{z}_j\|^2 = n\|\boldsymbol{Z}\|_{\mathrm{F}}^2 = n^2 \operatorname{tr}\boldsymbol{\Lambda}_k = n^2\sum_{j\leq k}\lambda_j$ （命題 3.9）。比を取れば(3.10)を得る。 ■

寄与率は「距離の保存率」でもある

(3.10)は累積寄与率の読み方をもう一つ与える。「第 k 主成分までで分散の 80 % を説明する」は、同時に「**対距離の二乗和の 80 % を保つ**」という意味でもある。散布図で点の配置を見るとき、この解釈のほうが直接的である。
ただし(3.10)は**総和**についての等式であり、個々の距離が一律に $\sqrt{0.8}$ 倍になるわけではない。主成分部分空間に沿った方向の距離はほぼ保たれ、それに直交する方向の距離はほぼ完全に潰れる。$d = 8$、$n = 60$ の例では、$k = 2$ で対距離二乗和の比が 0.7386、累積寄与率も 0.7386 で一致するが、個々の距離の縮み方は大きくばらつく。

注意 3.11 (Johnson–Lindenstrauss との違い)**.** 第5章で扱う Johnson–Lindenstrauss の補題は、ランダム射影が対距離を**両側から** $(1 \pm \varepsilon)$ 倍以内に保つと主張する。PCA は(3.9)のとおり片側（縮む側）しか保証しない。代わりに PCA は**分散を最大に保つ**という最適性をもつ（定理 3.2）。「どの距離も壊さない」ことを求めるならランダム射影、「全体の散らばりを最大限残す」ことを求めるなら PCA である。

3.6　寄与率と次元の選択

式 (3.5)が示すとおり、全分散 $\operatorname{tr}\widehat{\boldsymbol{\Sigma}} = \sum_j \lambda_j$ は主成分ごとに分割される。

定義 3.12 (寄与率と累積寄与率)**.** $r_j \coloneqq \lambda_j / \sum_l \lambda_l$ を第 j 主成分の**寄与率**（proportion of variance explained）、$R_k \coloneqq \sum_{j\leq k} r_j$ を上位 k 主成分の **累積寄与率**（cumulative proportion）と呼ぶ。

定理 3.2より R_k は「k 次元に落としたときに保たれる分散の割合」、$1 - R_k$ は相対的な再構成誤差 $\|\widetilde{\boldsymbol{X}} - \boldsymbol{U}_k\boldsymbol{U}_k^{\top}\widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^2 / \|\widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^2$ に等しい。例 3.8では $r_1 = 0.75$, $r_2 = 0.25$ で、1 次元でも分散の 75% が保たれる。

k の選択に唯一の正解はない。図 3.2のスクリープロットがすべての指針の出発点である。**エルボー法**——j を横軸、λ_j を縦軸に取った折れ線（山の斜面に溜まった砕石 scree に見立てた命名）で、急な減衰が緩やかな減衰に変わる「肘」（elbow）の手前までを採る。「信号は少数の大きな固有値、ノイズは多数の小さな固有値」という直観に対応し、第5章の Marchenko–Pastur 則が理論的裏づけを与える。欠点は肘が主観的で、しばしば存在しないことである。**Kaiser 基準**——相関行列 PCA では全固有値の平均が 1 になるので $\lambda_j > 1$ なる j までを採る。簡便だが d が大きいと採りすぎる傾向がある。**交差検証**——「学習データで $\boldsymbol{U}_k$ を求め検証データの再構成誤差を測る」という素朴な手続きは失敗する。検証点 $\boldsymbol{x}$ 全体から $\boldsymbol{U}_k^{\top}\boldsymbol{x}$ を計算して再構成すると誤差は k について単調減少し常に $k = d$ が選ばれるからである。正しくは行列の**要素**をランダムに欠測させ、残りから低ランク近似を作って欠測要素を予測する（Gabriel 型／ Wold 型）。こうすれば誤差は k について U 字を描く。**平行分析（parallel analysis）**——各列を独立にランダム置換して相関構造を壊したデータ行列を多数（例えば 500 個）作り、j 番目の固有値の分布を得て、実データの λ_j がその上側 95% 点を超える j までを採用する。Kaiser 基準と違い有限標本の揺らぎを織り込むので、実務的な既定値として推奨できる。

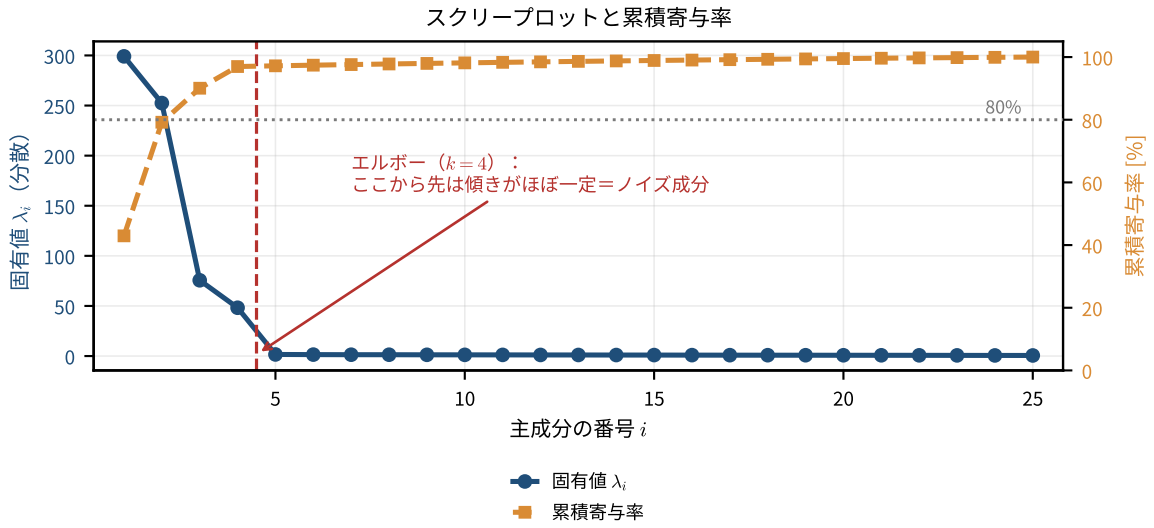


図3.2　スクリープロット（棒）と累積寄与率（折れ線、右軸）。固有値の減衰が急から緩に変わる「肘」が k の目安になるが、肘が明瞭でないデータも多い。

寄与率が高い $\neq$ 役に立つ

PCA は目的変数を一切見ない教師なし手法である。「分散が大きい方向」が「予測に有用な方向」である保証はどこにもない。

具体例は易しい。2 変数と 2 クラスのラベル $y \in \{\pm 1\}$ からなるデータで $x_1 \sim \mathcal{N}(0, 10^2)$（ラベルと独立）、$x_2 \sim \mathcal{N}(2y, 0.5^2)$ とすると $\mathrm{Var}(x_1) = 100$、$\mathrm{Var}(x_2) = 4.25$ だから第 1 主成分はほぼ x_1 軸で寄与率は $100/104.25 \approx 96\%$ に達する。しかし x_1 はラベルと無関係で、分類に使えるのは寄与率 4% の第 2 主成分だけである。$k = 1$ で次元削減すると必要な情報がきれいに捨てられる。必要なのはラベルを見て方向を選ぶ手法——クラス間分散とクラス内分散の比を最大化する線形判別分析（LDA）や、目的変数との共分散を最大化する部分最小二乗法（PLS）——であり、いずれも一般化固有値問題 $\boldsymbol{A}\boldsymbol{w} = \lambda \boldsymbol{B}\boldsymbol{w}$ に収まる（第6章）。

3.7　三次元点群で見る PCA

ここまでの道具（重心、標本共分散、固有分解、スコア、寄与率）を $d = 3$ の例で一度に動かす。$d = 3$ を選ぶ理由は、**答えが目で見える**ことである。高次元では PCA の出力が正しいかどうかを確かめる術がないが、3 次元なら描いて確かめられる。

3.7.1　データと手順

猫の形をした点群を使う。楕円体（胴と頭）、円錐（耳）、管（尾と脚）の**表面**から $n = 6440$ 点を取ったもので、外部データは要らない。設計上の広がりは体長（x）$>$ 高さ（z）$>$ 幅（y）の順である。これを直交行列 $\boldsymbol{R}$ で適当に回した $\boldsymbol{X} = \boldsymbol{R}\boldsymbol{X}_0 \in \mathbb{R}^{3\times 6440}$ を**観測**とする。つまり観測された座標軸 x_1, x_2, x_3 には意味がない——センサの向きが適当だった、という状況の模擬である。手順は3.2節のとおりで、重心を引き、$\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top} \in \mathbb{R}^{3\times 3}$ を作り、固有分解する。

3.7.2　PCA は座標軸を張り替えている

固有値から計算した寄与率は

$$0.782, \qquad 0.190, \qquad 0.028$$

で、三つの方向がはっきり分かれる。得られた主軸 $\boldsymbol{u}_1, \boldsymbol{u}_2, \boldsymbol{u}_3$ を回転前の設計軸（体長・高さ・幅）と比べると、なす角はそれぞれ 1.20°、1.20°、0.03° である。すなわち

- 第 1 主成分 $=$ 猫のもっとも長い方向（体長）
- 第 2 主成分 $=$ 次に広がっている方向（高さ）
- 第 3 主成分 $=$ もっとも薄い方向（幅）

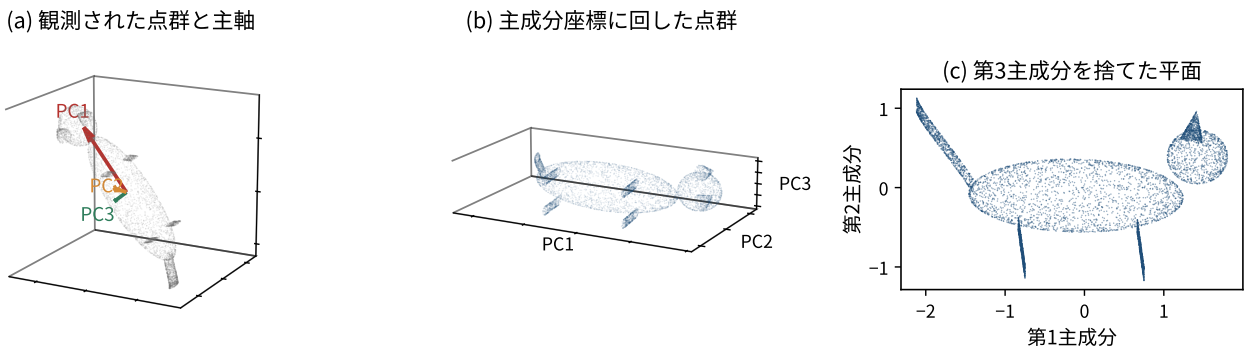


図3.3　三次元点群で見る PCA。(a) 適当に回転した猫型の点群（$n = 6440$、$d = 3$）と、標本共分散の固有ベクトルを $\bar{\boldsymbol{x}} \pm c\sqrt{\lambda_k}\boldsymbol{u}_k$ の向きに描いた主軸。矢印の長さは $\sqrt{\lambda_k}$ に比例させてあるので、長さの比は $1 : 0.49 : 0.19$ である（寄与率 0.782/0.190/0.028 はこれを二乗して和で割ったもので、長さの比とは一致しない。PC1 と PC3 は長さでは 5.3 倍、寄与率では 28 倍の違いである）。(b) 主成分座標 $\boldsymbol{Z} = \boldsymbol{U}^\top \widetilde{\boldsymbol{X}}$ に移すと、直交変換なので形は変わらないまま座標軸に揃う。(c) 第 3 主成分を捨てた平面。分散は 97.2 % 残るが、猫は薄い方向に押し潰されて曲面としての形は失われている。

であり、**PCA は $\boldsymbol{R}$ の情報を捨ててデータ自身がもつ自然な座標軸を復元した**。図 3.3(a) が観測された点群と主軸、(b) が主成分座標 $\boldsymbol{Z} = \boldsymbol{U}^\top \widetilde{\boldsymbol{X}}$ に移した点群である。$\boldsymbol{U}$ は直交行列だから $\boldsymbol{Z}$ への変換は**回転（と鏡映）でしかなく**、形は変わらない。にもかかわらず猫は座標軸に揃って「正面を向く」。次元削減の前に PCA がやっているのはこの**座標軸の張り替え**である。

3.7.3　寄与率が高いことは構造が保たれることではない

第 3 主成分を捨てて 2 次元にしたのが 図 3.3(c) である。累積寄与率は 0.972、つまり分散の 97.2 % が残っている。それでも起きていることを数値で見よう。無作為に取った 6000 対について 3 次元での距離と平面上での距離を比べると、平面上の距離が元を超えた対は一つもない（最大違反 -4.5×10^{-10}、丸め誤差の範囲）。これは定理 3.10の非拡大性そのものである。平均すると距離は 0.939 倍になる。問題は**平均ではなく最悪**のほうで、もっとも潰れた対は 3 次元で 0.546 離れていたのに平面では 0.0059——1/100 以下になっている。さらに、平面上で距離 0.1 未満だった 94 対のうち 44.7 % は、3 次元では 0.3 以上離れていた点対である。

「寄与率 97 %」は「近さが保たれる」ではない

寄与率は**分散**という一つの量がどれだけ残ったかを測るだけで、**どの点対がどれだけ近づいたか**は測らない。この例では 97.2 % の分散を残しながら、平面上で重なって見える点対の半分近くが元は遠く離れていた。猫の腹側と背側が重なったのである。クラスタリングや最近傍探索を射影後の空間で行うなら、残った分散の割合ではなく**距離がどう壊れたか**を見なければならない。

この現象の正体は、この点群が 3 **次元空間の中の** 2 **次元曲面**（閉曲面の表面から点を取った）でありながら**平面ではない**ことである。内在次元は 2 なのに、線形な 2 次元部分空間では表現できない。$d = 3$ ならこのずれは目で見えるが、$d = 10^4$ では見えない——これが3.11節で述べる PCA の限界であり、第11章の多様体学習が扱う問題である。

3.8　中心化とスケーリング

PCA の結果は前処理に敏感である。二つの主要な落とし穴を扱う。

3.8.1　なぜ中心化するのか

中心化せずに $\frac{1}{n}\boldsymbol{X}\boldsymbol{X}^\top$ を固有分解するとどうなるか。$\boldsymbol{x}_i = \tilde{\boldsymbol{x}}_i + \bar{\boldsymbol{x}}$ を代入して展開すると（交差項は $\sum_i \tilde{\boldsymbol{x}}_i = \boldsymbol{0}$ で消える）恒等式

$$\frac{1}{n}\boldsymbol{X}\boldsymbol{X}^\top = \widehat{\boldsymbol{\Sigma}} + \bar{\boldsymbol{x}}\,\bar{\boldsymbol{x}}^\top \tag{3.13}$$

が成り立つ。右辺第二項は階数 1 の半正定値行列であり、$\|\bar{\boldsymbol{x}}\|$ が大きいほど支配的になる。その結果「第 1 主成分」は平均ベクトルの方向に引きずられ、データの散らばりとは無関係な方向を指すようになる。

例 3.13（中心化を忘れる）. データ $(3,7), (4,5), (5,6), (6,4), (7,3)$ を列に並べる。平均は $(5,5)^\top$、中心化後の $\widetilde{\boldsymbol{X}}$ の列は

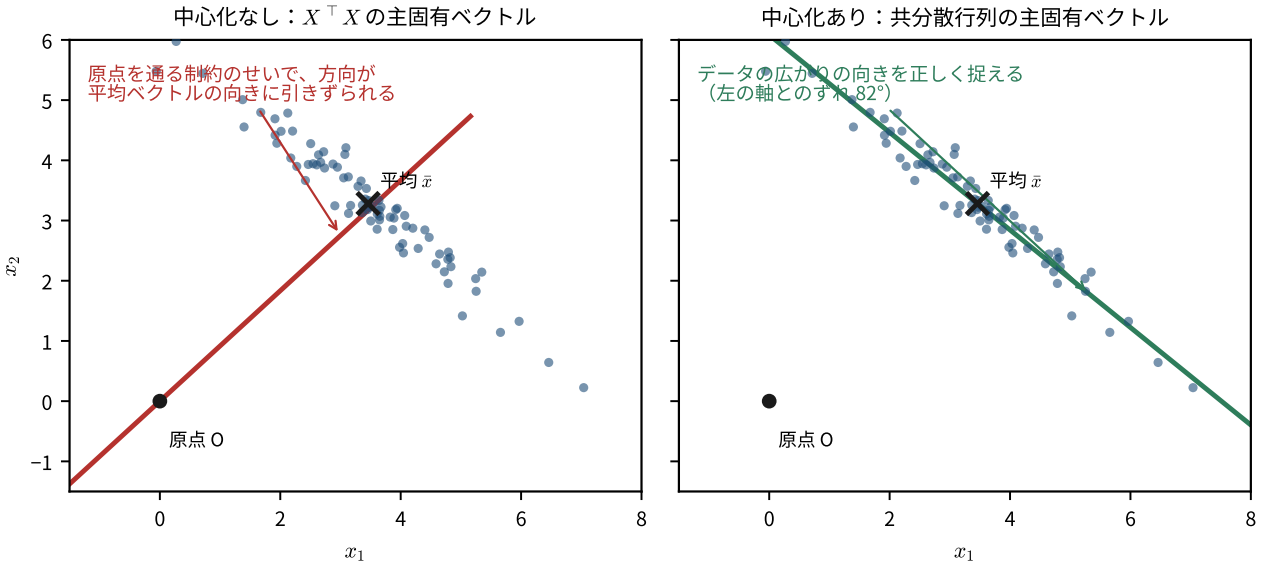


図3.4　中心化の有無による第 1 主成分の違い。中心化しないと主成分は平均ベクトルの方向に引きずられ、データの散らばりの方向を捉えられない。

$(-2,2),(-1,0),(0,1),(1,-1),(2,-2)$ であり $\widehat{\boldsymbol{\Sigma}} = \begin{pmatrix} 2 & -1.8 \\ -1.8 & 2 \end{pmatrix}$、$\lambda_1 = 3.8$, $\boldsymbol{u}_1 = (1,-1)^\top/\sqrt{2}$。データは右下がりに伸びており $\boldsymbol{u}_1$ はその方向を向いている。一方、中心化せずに $\frac{1}{n}\boldsymbol{X}\boldsymbol{X}^\top = \widehat{\boldsymbol{\Sigma}} + \bar{\boldsymbol{x}}\bar{\boldsymbol{x}}^\top = \begin{pmatrix} 27 & 23.2 \\ 23.2 & 27 \end{pmatrix}$ を固有分解すると、最大固有値 50.2 に属する固有ベクトルは $(1,1)^\top/\sqrt{2}$、すなわち真の主軸と**ちょうど直交する方向**である。データの伸びる向きを 90° 取り違えたことになる（図 3.4）。

中心化の必然性は (F2) の側から見るとさらに明快である。アフィン部分空間への近似を考えオフセット $\boldsymbol{b}$ も最適化してみよう。$\boldsymbol{P}$ を階数 k の直交射影、$\boldsymbol{Q} \coloneqq \boldsymbol{I} - \boldsymbol{P}$ として $J(\boldsymbol{b}) \coloneqq \sum_i \|(\boldsymbol{x}_i - \boldsymbol{b}) - \boldsymbol{P}(\boldsymbol{x}_i - \boldsymbol{b})\|^2 = \sum_i (\boldsymbol{x}_i - \boldsymbol{b})^\top \boldsymbol{Q}(\boldsymbol{x}_i - \boldsymbol{b})$（$\boldsymbol{Q}^\top\boldsymbol{Q} = \boldsymbol{Q}$）とおくと $\nabla J(\boldsymbol{b}) = -2n\boldsymbol{Q}(\bar{\boldsymbol{x}} - \boldsymbol{b})$ であり、これが $\boldsymbol{0}$ となる条件は $\bar{\boldsymbol{x}} - \boldsymbol{b} \in \mathrm{Im}(\boldsymbol{P})$、$\boldsymbol{b} = \bar{\boldsymbol{x}}$ が満たす。J は凸（$\boldsymbol{Q} \succeq 0$）だから停留点は最小点である（$\boldsymbol{b}$ が一意でないのは、$\bar{\boldsymbol{x}}$ に $\boldsymbol{P}$ の像の元を足しても同じアフィン部分空間を与えるからで当然である）。つまり**中心化は恣意的な操作ではなく、最適なオフセットを先に決めておくこと**に他ならない。

3.8.2　スケーリングとアフィン変換

変数の単位が異なるとき、PCA の結果は単位の取り方に依存する。

例 3.14 (単位を変えると主成分が変わる)**.** 身長（cm）と体重（kg）の共分散行列が $\widehat{\boldsymbol{\Sigma}} = \begin{pmatrix} 36 & 20 \\ 20 & 25 \end{pmatrix}$（標準偏差 6 cm と 5 kg）であったとする。固有値は $\lambda_1 = 51.24$, $\lambda_2 = 9.76$、$\boldsymbol{u}_1 \approx (0.795, 0.606)^\top$（$x$ 軸から約 37.3°）、寄与率 84%。身長を mm で測り直すと第 1 変数が 10 倍されて $\widehat{\boldsymbol{\Sigma}}' = \begin{pmatrix} 3600 & 200 \\ 200 & 25 \end{pmatrix}$ となり、$\lambda_1 = 3611.15$, $\lambda_2 = 13.85$、$\boldsymbol{u}_1' \approx (0.998, 0.056)^\top$（約 3.2°）、寄与率 99.6%。物理的に同じデータなのに主成分の向きが 34° も変わってしまった。

この不安定性を避ける標準的な処方は、各変数を標準偏差で割ってから PCA を行うことである。これは相関行列 $\boldsymbol{R} \coloneqq \boldsymbol{D}^{-1/2}\widehat{\boldsymbol{\Sigma}}\boldsymbol{D}^{-1/2}$（$\boldsymbol{D} = \mathrm{diag}(\widehat{\Sigma}_{11}, \dots, \widehat{\Sigma}_{dd})$）の固有分解に等しく、**相関行列 PCA** と呼ばれ、単位の取り替えに対して不変である。例 3.14では $\boldsymbol{R} = \begin{pmatrix} 1 & 2/3 \\ 2/3 & 1 \end{pmatrix}$、$\lambda_1 = 5/3$, $\boldsymbol{u}_1 = (1,1)^\top/\sqrt{2}$ となり、cm でも mm でも同じ答えになる（図 3.5）。ただし相関行列 PCA が常に正しいわけではない。すべての変数が同じ単位で測られ（画像の画素値、同一プラットフォームの遺伝子発現量など）分散の大小それ自体が意味を持つ場合は共分散行列 PCA が自然であり、無理に標準化するとほとんど動かないノイズ変数が過大に重みづけられる。単位が混在するアンケートや理化学測定値では相関行列 PCA を既定とするのがよい。

では PCA はどの変換に対して同変なのか。

命題 3.15 (直交変換に対する同変性)**.** $\boldsymbol{Q}$ を直交行列、$\boldsymbol{c}$ を定ベクトルとし $\boldsymbol{y}_i = \boldsymbol{Q}^\top\boldsymbol{x}_i + \boldsymbol{c}$（行列形では $\boldsymbol{Y} = \boldsymbol{Q}^\top\boldsymbol{X} + \boldsymbol{c}\boldsymbol{1}^\top$）とおくと $\widehat{\boldsymbol{\Sigma}}_{\boldsymbol{y}} = \boldsymbol{Q}^\top\widehat{\boldsymbol{\Sigma}}\boldsymbol{Q}$ であり、固有値は $\widehat{\boldsymbol{\Sigma}}$ と同じ、固有ベクトルは $\boldsymbol{Q}^\top\boldsymbol{u}_j$、主成分スコアは変化しない。

証明. $\tilde{\boldsymbol{y}}_i = \boldsymbol{Q}^\top\tilde{\boldsymbol{x}}_i$ より $\widehat{\boldsymbol{\Sigma}}_{\boldsymbol{y}} = \frac{1}{n}\sum_i \boldsymbol{Q}^\top\tilde{\boldsymbol{x}}_i\tilde{\boldsymbol{x}}_i^\top\boldsymbol{Q} = \boldsymbol{Q}^\top\widehat{\boldsymbol{\Sigma}}\boldsymbol{Q}$。$\widehat{\boldsymbol{\Sigma}}\boldsymbol{u}_j = \lambda_j\boldsymbol{u}_j$ に左から $\boldsymbol{Q}^\top$ を掛けて $\widehat{\boldsymbol{\Sigma}}_{\boldsymbol{y}}(\boldsymbol{Q}^\top\boldsymbol{u}_j) = \lambda_j(\boldsymbol{Q}^\top\boldsymbol{u}_j)$。

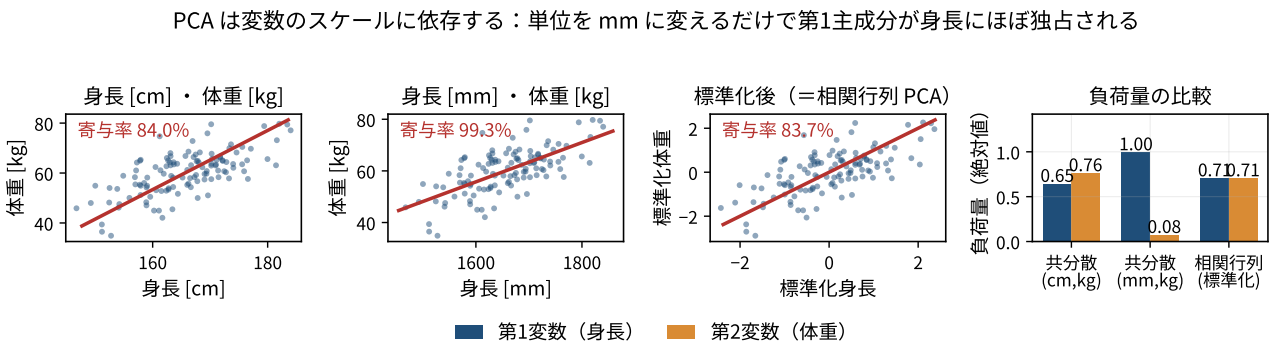


図3.5　スケーリングの影響。単位を cm から mm に変えるだけで共分散行列 PCA の第 1 主成分は大きく傾くが、相関行列 PCA の結果は単位に依存しない。

スコアは $(\boldsymbol{Q}^\top \boldsymbol{u}_j)^\top \tilde{\boldsymbol{y}}_i = \boldsymbol{u}_j^\top \boldsymbol{Q}\boldsymbol{Q}^\top \tilde{\boldsymbol{x}}_i = \boldsymbol{u}_j^\top \tilde{\boldsymbol{x}}_i$ で不変。 ■

これが成り立つのは $\boldsymbol{Q}$ が**直交**のときだけである。$\boldsymbol{A}$ を一般の正則行列とすると $\widehat{\boldsymbol{\Sigma}}_{\boldsymbol{y}} = \boldsymbol{A}^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{A}$ となり、その固有ベクトルは $\boldsymbol{A}^{-1}\boldsymbol{u}_j$ とは一般に一致しない。例 3.14は $\boldsymbol{A} = \mathrm{diag}(10, 1)$ の場合で、対角行列という単純な変換ですら結果が変わった。**PCA は回転と平行移動には同変だが伸縮には同変でなく、アフィン変換一般に対する同変性はない。**

3.9　白色化

主成分スコアは無相関だが分散は $\lambda_1, \dots, \lambda_k$ と異なる。これをすべて 1 に揃える操作を白色化という。

定義 3.16 (白色化)**.** $\widehat{\boldsymbol{\Sigma}}$ が正則（$\lambda_d > 0$）のとき $\boldsymbol{Z}_{\mathrm{white}} \coloneqq \boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^\top \widetilde{\boldsymbol{X}}$（白色化行列 $\boldsymbol{W}_{\mathrm{white}} \coloneqq \boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^\top$ を**左**から掛ける）を（PCA）**白色化**（whitening, sphering）という（$\boldsymbol{\Lambda}^{-1/2} = \mathrm{diag}(\lambda_1^{-1/2}, \dots, \lambda_d^{-1/2})$）。

命題 3.17. $\frac{1}{n}\boldsymbol{Z}_{\mathrm{white}}\boldsymbol{Z}_{\mathrm{white}}^\top = \boldsymbol{I}_d$ であり、任意の直交行列 $\boldsymbol{Q}$ に対し $\boldsymbol{Q}\boldsymbol{Z}_{\mathrm{white}}$ も同じ性質を持つ。逆に $\boldsymbol{A}\widetilde{\boldsymbol{X}}$ の標本共分散が $\boldsymbol{I}_d$ となる正則行列 $\boldsymbol{A}$ は $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^\top$（$\boldsymbol{Q}$ 直交）の形に限る。

証明. $\frac{1}{n}\boldsymbol{Z}_{\mathrm{white}}\boldsymbol{Z}_{\mathrm{white}}^\top = \boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{U}\boldsymbol{\Lambda}^{-1/2} = \boldsymbol{I}_d$ で、$\boldsymbol{Q}$ を掛けても $\boldsymbol{Q}\boldsymbol{I}_d\boldsymbol{Q}^\top = \boldsymbol{I}_d$。逆に $\boldsymbol{A}\widehat{\boldsymbol{\Sigma}}\boldsymbol{A}^\top = \boldsymbol{I}_d$ なら $\boldsymbol{B} \coloneqq \boldsymbol{A}\boldsymbol{U}\boldsymbol{\Lambda}^{1/2}$ が $\boldsymbol{B}\boldsymbol{B}^\top = \boldsymbol{I}_d$ を満たすので $\boldsymbol{B}$ は直交行列 $\boldsymbol{Q}$ であり、$\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^\top$。 ■

すなわち**白色化には回転の自由度が残る。**「共分散が単位行列」という条件は $d(d+1)/2$ 本の方程式にすぎず、d^2 個の自由度を持つ $\boldsymbol{A}$ を一意に定めない。残る自由度はちょうど直交群 $O(d)$ の次元 $d(d-1)/2$ であり、どの回転を選ぶかで白色化の名前が変わる。$\boldsymbol{Q} = \boldsymbol{I}$ とすれば PCA 白色化、$\boldsymbol{Q} = \boldsymbol{U}$ とすれば $\boldsymbol{Z}_{\mathrm{ZCA}} = \boldsymbol{U}\boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^\top \widetilde{\boldsymbol{X}} = \widehat{\boldsymbol{\Sigma}}^{-1/2}\widetilde{\boldsymbol{X}}$ となり、これを **ZCA 白色化**（zero-phase component analysis）と呼ぶ。ZCA は「元のデータにできるだけ近い白色化」という特徴づけを持つ。

命題 3.18 (ZCA の最適性)**.** $\boldsymbol{A}\widehat{\boldsymbol{\Sigma}}\boldsymbol{A}^\top = \boldsymbol{I}_d$ の範囲で $\|\boldsymbol{A}\widetilde{\boldsymbol{X}} - \widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^2$ を最小にするのは $\boldsymbol{A} = \widehat{\boldsymbol{\Sigma}}^{-1/2}$ である。

証明. 命題 3.17より $\boldsymbol{A} = \boldsymbol{Q}\widehat{\boldsymbol{\Sigma}}^{-1/2}$（$\boldsymbol{Q}$ 直交）と書ける。$\widehat{\boldsymbol{\Sigma}}^{-1/2}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top\widehat{\boldsymbol{\Sigma}}^{-1/2} = n\boldsymbol{I}_d$ を使って展開すると $\|\boldsymbol{Q}\widehat{\boldsymbol{\Sigma}}^{-1/2}\widetilde{\boldsymbol{X}} - \widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^2 = nd - 2n\,\mathrm{tr}(\boldsymbol{Q}^\top\widehat{\boldsymbol{\Sigma}}^{1/2}) + n\,\mathrm{tr}\,\widehat{\boldsymbol{\Sigma}}$ であり、$\boldsymbol{Q}$ に依存するのは中央項だけだから $\mathrm{tr}(\boldsymbol{Q}^\top\widehat{\boldsymbol{\Sigma}}^{1/2})$ を最大化すればよい。$\boldsymbol{M} \coloneqq \boldsymbol{U}^\top\boldsymbol{Q}^\top\boldsymbol{U}$（直交行列）とおけば $\mathrm{tr}(\boldsymbol{Q}^\top\boldsymbol{U}\boldsymbol{\Lambda}^{1/2}\boldsymbol{U}^\top) = \mathrm{tr}(\boldsymbol{M}\boldsymbol{\Lambda}^{1/2}) = \sum_j M_{jj}\lambda_j^{1/2}$ であり、直交行列の列のノルムは 1 だから $|M_{jj}| \le 1$、よってこれは $\sum_j \lambda_j^{1/2}$ 以下、等号はすべての $M_{jj} = 1$ すなわち $\boldsymbol{Q} = \boldsymbol{I}_d$ のときに限る。よって $\boldsymbol{A} = \widehat{\boldsymbol{\Sigma}}^{-1/2}$。 ■

画像処理で ZCA が好まれるのはこの性質による。PCA 白色化された画像は座標が並べ替えられて元の画像に見えないが、ZCA 白色化された画像は輪郭が強調されただけの姿を保つ（図 3.6）。

白色化と Z-score（標準化）は違う

実務でよく使われる **Z-score**（$z_j = (x_j - \bar{x}_j)/s_j$、変数ごとに平均を引いて標準偏差で割る）は、白色化ではない。行列で書けば $\boldsymbol{Z}_{\mathrm{std}} = \boldsymbol{D}^{-1/2}\widetilde{\boldsymbol{X}}$、$\boldsymbol{D} \coloneqq \mathrm{diag}(\widehat{\boldsymbol{\Sigma}})$ であり、変換後の共分散は

$$\frac{1}{n}\boldsymbol{Z}_{\mathrm{std}}\boldsymbol{Z}_{\mathrm{std}}^\top = \boldsymbol{D}^{-1/2}\widehat{\boldsymbol{\Sigma}}\boldsymbol{D}^{-1/2} = (\text{標本相関行列}) \tag{3.14}$$

となる。対角成分は 1 になるが**非対角成分は相関係数そのもので、0 にはならない。**$\boldsymbol{D}$ は対角行列なので変数の縮尺を変えるだけであり、雲の傾きは変わらない。

図 3.6の例（$d = 2$）では、元データの相関は 0.934 である。Z-score をとると分散は $(1.003, 1.003)$ になるが相関は 0.934 のまま、PCA 白色化では共分散が $\boldsymbol{I}$（相関 0）になる。$\widehat{\boldsymbol{\Sigma}}$ が対角行列のときに限って両者は一致する。

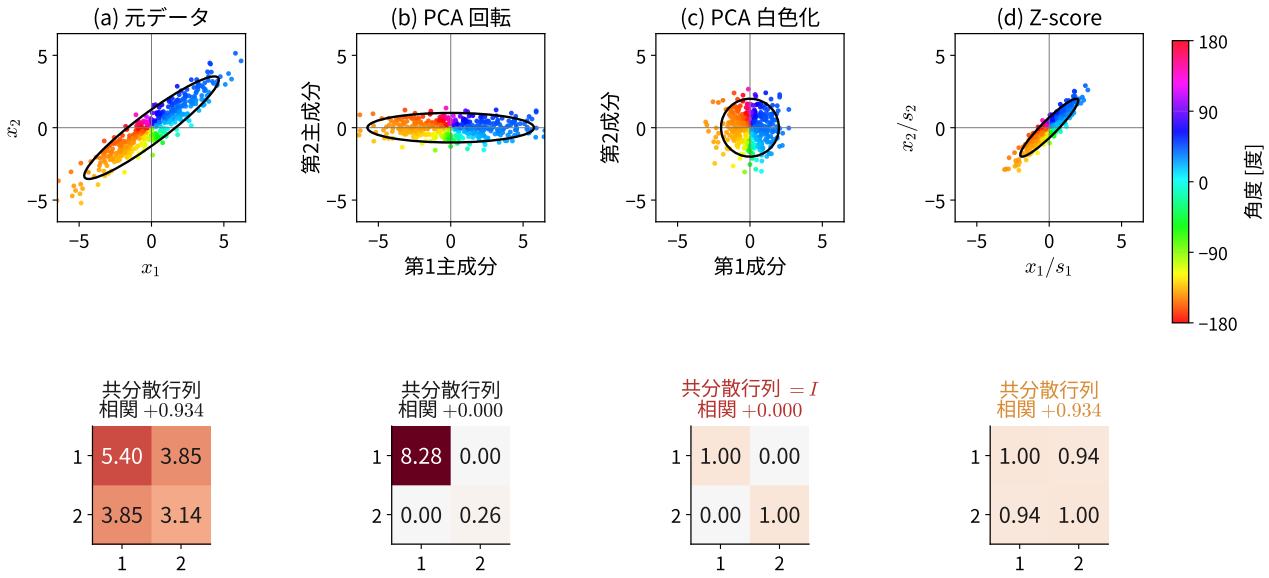


図3.6　白色化と Z-score の違い。上段は散布図、下段は対応する共分散行列。(a) 元データ $\widetilde{\boldsymbol{X}}$、(b) PCA 回転 $\boldsymbol{V}^\top\widetilde{\boldsymbol{X}}$、(c) PCA 白色化 $\boldsymbol{\Lambda}^{-1/2}\boldsymbol{V}^\top\widetilde{\boldsymbol{X}}$、(d) Z-score（変数ごとの標準化）。点の色は**元データでの角度**で、同じ色の点を追えば各変換での移動先がわかる。PCA 回転（第 2 列）は色の並びを保ったまま雲を軸に揃え、PCA 白色化（第 3 列）はさらに各軸を標準偏差で割るので雲が等方的になり共分散が $\boldsymbol{I}$ になる。いっぽう Z-score（第 4 列）は変数ごとに標準偏差で割るだけなので対角は 1 になるが相関 0.934 がそのまま残り、雲は傾いたままである。$n = 400$、共分散は不偏でない標本共分散。

使い分けの目安は、**単位の違いだけを揃えたいなら Z-score、変数間の相関まで消したいなら白色化**である。3.8節で述べた「相関行列の PCA」は (3.14)の相関行列を固有値分解することに相当し、Z-score のあとに PCA をかける操作にほかならない。

注意 3.19 (独立成分分析への前処理)**.**　「回転の自由度が残る」という事実は独立成分分析（independent component analysis, ICA）の出発点である。ICA は「成分が統計的に独立」という、無相関より強い条件を課す。無相関性は 2 次モーメントの条件にすぎず白色化で達成できるので、ICA はまず白色化を行い、残った回転 $\boldsymbol{Q}$ を高次統計量（尖度やネゲントロピー）を最適化するように選ぶ。つまり ICA は「白色化 + 回転の探索」に分解でき、探索空間は d^2 次元から $d(d-1)/2$ 次元に落ちる。

白色化は小さい固有値を増幅する

係数 $\lambda_j^{-1/2}$ は λ_j が小さいほど大きい。つまり白色化は「ほとんど分散のない方向」を無理に引き伸ばす操作であり、その方向がもっぱらノイズであるときノイズを桁違いに増幅する。$\widehat{\boldsymbol{\Sigma}}$ が特異に近い（d が n に比べて大きい）場面では $(\lambda_j + \varepsilon)^{-1/2}$ と正則化するか、上位 k 成分だけを白色化するのが実際的である。

3.10　確率的 PCA

3.10.1　PCA を生成モデルとして書く

ここまでの PCA には確率モデルが登場しなかった。$\widehat{\boldsymbol{\Sigma}}$ を作り固有ベクトルを取っただけである。簡潔だが、欠測値の扱い、k の選択を尤度で議論すること、複数の低次元構造が混在するデータの表現、といった問いには答えられない。これらに答えるには生成モデルが必要である。

定義 3.20 (確率的 PCA)**.**　$k < d$ とする。潜在変数 $\boldsymbol{z} \in \mathbb{R}^k$ と観測 $\boldsymbol{x} \in \mathbb{R}^d$ が

$$\boldsymbol{x} = \boldsymbol{W}\boldsymbol{z} + \boldsymbol{\mu} + \boldsymbol{\varepsilon}, \quad \boldsymbol{z} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}_k), \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\boldsymbol{0}, \sigma^2 \boldsymbol{I}_d), \quad \boldsymbol{z} \perp \boldsymbol{\varepsilon} \tag{3.15}$$

に従うとするモデルを**確率的主成分分析**（probabilistic PCA, PPCA）と呼ぶ。$\boldsymbol{W} \in \mathbb{R}^{d\times k}$, $\boldsymbol{\mu} \in \mathbb{R}^d$, $\sigma^2 > 0$ がパラメータである。

解釈は素直である。データは k 次元の「本当の自由度」$\boldsymbol{z}$ を線形に d 次元へ埋め込み、平均 $\boldsymbol{\mu}$ だけずらして等方的な観測ノ

イズを加えたものだ、という主張である。ノイズの共分散を等方形 $\sigma^2 \boldsymbol{I}_d$ に限っているのが要点で、ここを一般の対角行列 $\boldsymbol{\Psi}$ にすると因子分析（factor analysis）になる。

命題 3.21 (周辺分布)**.** 式 (3.15)のもとで $\boldsymbol{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{C})$、$\boldsymbol{C} \coloneqq \boldsymbol{W}\boldsymbol{W}^{\top} + \sigma^2 \boldsymbol{I}_d$。

証明. 特性関数を計算する。$\boldsymbol{z}$ と $\boldsymbol{\varepsilon}$ の独立性から、$\boldsymbol{t} \in \mathbb{R}^d$ に対し $\mathbb{E}[e^{\mathrm{i}\boldsymbol{t}^{\top}\boldsymbol{x}}] = e^{\mathrm{i}\boldsymbol{t}^{\top}\boldsymbol{\mu}} \mathbb{E}[e^{\mathrm{i}(\boldsymbol{W}^{\top}\boldsymbol{t})^{\top}\boldsymbol{z}}] \mathbb{E}[e^{\mathrm{i}\boldsymbol{t}^{\top}\boldsymbol{\varepsilon}}]$。$\boldsymbol{z} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}_k)$ の特性関数は $\mathbb{E}[e^{\mathrm{i}\boldsymbol{s}^{\top}\boldsymbol{z}}] = e^{-\|\boldsymbol{s}\|^2/2}$ だから第 2 因子は $\exp(-\tfrac{1}{2}\boldsymbol{t}^{\top}\boldsymbol{W}\boldsymbol{W}^{\top}\boldsymbol{t})$、同様に第 3 因子は $\exp(-\tfrac{1}{2}\sigma^2\|\boldsymbol{t}\|^2)$。よって $\mathbb{E}[e^{\mathrm{i}\boldsymbol{t}^{\top}\boldsymbol{x}}] = \exp(\mathrm{i}\boldsymbol{t}^{\top}\boldsymbol{\mu} - \tfrac{1}{2}\boldsymbol{t}^{\top}\boldsymbol{C}\boldsymbol{t})$ であり、これは $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{C})$ の特性関数である。特性関数が分布を一意に定めること（一意性定理）から主張が従う。 ■

$\boldsymbol{C} = \boldsymbol{W}\boldsymbol{W}^{\top} + \sigma^2 \boldsymbol{I}_d$ という構造が本質的である。自由なパラメータは $\boldsymbol{W}$ の dk 個（回転の分だけ冗長）と σ^2 の 1 個で、一般の共分散行列の $d(d+1)/2$ 個よりずっと少ない。PPCA は「共分散行列を低ランク + 等方ノイズで近似する」パラメトリックモデルである。

3.10.2　最尤解

対数尤度は n 個の独立標本に対して

$$\ell(\boldsymbol{\mu}, \boldsymbol{W}, \sigma^2) = -\frac{n}{2}\bigl(d\log 2\pi + \log\det \boldsymbol{C} + \operatorname{tr}(\boldsymbol{C}^{-1}\boldsymbol{S})\bigr), \quad \boldsymbol{S} \coloneqq \frac{1}{n}\sum_{i}(\boldsymbol{x}_i - \boldsymbol{\mu})(\boldsymbol{x}_i - \boldsymbol{\mu})^{\top} \tag{3.16}$$

である。$\boldsymbol{\mu}$ については $\hat{\boldsymbol{\mu}} = \bar{\boldsymbol{x}}$ が最尤推定量なので、以後 $\boldsymbol{S} = \widehat{\boldsymbol{\Sigma}}$ とする。なお $\boldsymbol{C} = \boldsymbol{W}\boldsymbol{W}^{\top} + \sigma^2\boldsymbol{I}$ は $\sigma^2 > 0$ のとき正定値対称なので $\det \boldsymbol{C} > 0$ であり、$\log\det \boldsymbol{C}$ は実数として定義され、命題 2.34の(2.27)がそのまま使える（同命題の注意を参照）。

定理 3.22 (Tipping–Bishop [76])**.** $k < d$ かつ $\lambda_k > \lambda_{k+1}$ のとき、式 (3.16)の大域最大は

$$\hat{\sigma}^2 = \frac{1}{d-k}\sum_{j=k+1}^{d}\lambda_j, \qquad \widehat{\boldsymbol{W}} = \boldsymbol{U}_k(\boldsymbol{\Lambda}_k - \hat{\sigma}^2\boldsymbol{I}_k)^{1/2}\boldsymbol{Q} \tag{3.17}$$

で与えられる（$\boldsymbol{Q} \in \mathbb{R}^{k\times k}$ は任意の直交行列、$\boldsymbol{\Lambda}_k = \operatorname{diag}(\lambda_1, \dots, \lambda_k)$）。

完全な証明——すべての停留点を求め、上位以外の固有ベクトルの組を選んだ停留点が鞍点であることを示す部分——は Tipping と Bishop の原論文に譲る。ここでは**なぜ上位固有ベクトルが現れるのか**を計算を追える形で説明する。**以下で認めて使うのは二つである**：(i) 下の補題 3.23（並べ替え不等式の行列版、von Neumann のトレース不等式から従う）、および (ii) 上位以外の固有ベクトルの組を選んだ停留点が鞍点であること（[76]）。前者は証明を付ける。

補題 3.23 (並べ替え不等式・トレース版)**.** $\boldsymbol{A} \in \mathbb{R}^{d\times d}$ を半正定値対称行列、その固有値を $\lambda_1 \ge \cdots \ge \lambda_d$ とし、$w_1 \ge w_2 \ge \cdots \ge w_k \ge 0$ を固定した重みとする。正規直交列を持つ $\boldsymbol{B}_k = (\boldsymbol{b}_1, \dots, \boldsymbol{b}_k) \in \mathbb{R}^{d\times k}$ に対し

$$\sum_{j=1}^{k} w_j\, \boldsymbol{b}_j^{\top}\boldsymbol{A}\boldsymbol{b}_j \;\le\; \sum_{j=1}^{k} w_j \lambda_j \tag{3.18}$$

であり、等号は $\boldsymbol{b}_j$ が λ_j の固有ベクトルとなるとき——重みが狭義降順 $w_1 > \cdots > w_k$ かつ固有値が $\lambda_1 > \cdots > \lambda_k > \lambda_{k+1}$ なら $\boldsymbol{b}_j = \pm\boldsymbol{u}_j$ に限る——に達成される。

証明. 降順という仮定を Abel の和分（部分和による書き換え）で使う。$w_{k+1} \coloneqq 0$ とおき $\alpha_m \coloneqq w_m - w_{m+1} \ge 0\,(m = 1, \dots, k)$ とすれば $w_j = \sum_{m\ge j}\alpha_m$ だから、和の順序を入れ替えて

$$\sum_{j=1}^{k} w_j\, \boldsymbol{b}_j^{\top}\boldsymbol{A}\boldsymbol{b}_j = \sum_{m=1}^{k}\alpha_m \sum_{j=1}^{m} \boldsymbol{b}_j^{\top}\boldsymbol{A}\boldsymbol{b}_j = \sum_{m=1}^{k}\alpha_m \operatorname{tr}(\boldsymbol{B}_m^{\top}\boldsymbol{A}\boldsymbol{B}_m), \qquad \boldsymbol{B}_m \coloneqq (\boldsymbol{b}_1, \dots, \boldsymbol{b}_m).$$

各 m について $\boldsymbol{B}_m^{\top}\boldsymbol{B}_m = \boldsymbol{I}_m$ だから、**無重みの**定理 3.6（Ky Fan）が $\operatorname{tr}(\boldsymbol{B}_m^{\top}\boldsymbol{A}\boldsymbol{B}_m) \le \sum_{j\le m}\lambda_j$ を与える。$\alpha_m \ge 0$ なので

$$\sum_{j=1}^{k} w_j\, \boldsymbol{b}_j^{\top}\boldsymbol{A}\boldsymbol{b}_j \;\le\; \sum_{m=1}^{k}\alpha_m \sum_{j=1}^{m}\lambda_j \;=\; \sum_{j=1}^{k} w_j\lambda_j$$

（最後は同じ和分を逆にたどった）。これが式 (3.18)である。**要点は、重みが降順であるおかげで「先頭 m 本のトレース」という Ky Fan が押さえられる量の非負結合に分解でき、各 m で同時に等号を達成できることである。**$\boldsymbol{b}_j = \boldsymbol{u}_j$ とすればすべての m で $\operatorname{tr}(\boldsymbol{B}_m^{\top}\boldsymbol{A}\boldsymbol{B}_m) = \sum_{j\le m}\lambda_j$ となり等号が成立する。逆に $\alpha_m > 0$（すなわち $w_1 > \cdots > w_k > 0$）かつ $\lambda_1 > \cdots > \lambda_k > \lambda_{k+1}$ なら、すべての m で Ky Fan の等号が必要で、系 3.7より $\operatorname{span}\{\boldsymbol{b}_1, \dots, \boldsymbol{b}_m\} = \operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_m\}$ $(m = 1, \dots, k)$。m と

$m-1$ の差を取れば $\boldsymbol{b}_m = \pm\boldsymbol{u}_m$ を得る。なお同じ不等式は von Neumann のトレース不等式 $\operatorname{tr}(\boldsymbol{A}\boldsymbol{N}) \le \sum_i \lambda_i(\boldsymbol{A})\lambda_i(\boldsymbol{N})$ を $\boldsymbol{N} = \boldsymbol{B}_k \operatorname{diag}(w_1,\dots,w_k)\boldsymbol{B}_k^\top$（固有値は $w_1,\dots,w_k$ と 0）に適用しても得られる。上の導出は Ky Fan だけで済むので本書では自己完結する。これが**スカラーの並べ替え不等式（大きいものどうしを対応させると和が最大）の行列版**である。 ■

無重みの Ky Fan では足りない

以下の目的関数では $a_j = \boldsymbol{b}_j^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{b}_j$ に j **ごとに異なる重み**が掛かる。無重みの定理 3.6（Ky Fan）が言えるのは $\sum_j a_j = \operatorname{tr}(\boldsymbol{B}_k^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{B}_k) \le \sum_{j\le k} \lambda_j$ までで、これは $\operatorname{span}\{\boldsymbol{b}_1,\dots,\boldsymbol{b}_k\} = \operatorname{span}\{\boldsymbol{u}_1,\dots,\boldsymbol{u}_k\}$ を決めるだけであり、その部分空間の中で**どの $\boldsymbol{b}_j$ にどの固有値を割り当てるか**については何も言わない。実際 $d=6$ の乱数例（$\widehat{\boldsymbol{\Sigma}} = \boldsymbol{A}\boldsymbol{A}^\top/6$）で $\lambda = (2.7050, 1.2883, 0.6593, 0.3614, 0.2035, 0.0129)$、$k=3$、$\hat\sigma^2 = 0.19259$、重み $w_j = \frac{1}{\sigma^2} - \frac{1}{l_j^2+\sigma^2} = (4.8228, 4.4163, 3.6757)$ とすると、無重みの和 $\sum_j a_j$ は $\{\boldsymbol{u}_1,\boldsymbol{u}_2,\boldsymbol{u}_3\}$ の 6 通りの並べ方すべてで 4.65261 と**同じ**なのに、重み付き和 $\sum_j w_j a_j$ は 21.15849, 20.69265, 20.58263, 19.86108, 19.06768, 18.81197 と並べ方によって 2.3 も違う。順序を決めるのに補題 3.23が必要なのである。

定理 *3.22*の証明の筋道. $\boldsymbol{W}$ の特異値分解を $\boldsymbol{W} = \boldsymbol{B}_k \boldsymbol{L} \boldsymbol{Q}^\top$ とする（$\boldsymbol{B}_k = (\boldsymbol{b}_1,\dots,\boldsymbol{b}_k) \in \mathbb{R}^{d\times k}$ は正規直交列、$\boldsymbol{L} = \operatorname{diag}(l_1,\dots,l_k)$）。$\boldsymbol{W}\boldsymbol{W}^\top = \boldsymbol{B}_k \boldsymbol{L}^2 \boldsymbol{B}_k^\top$ は $\boldsymbol{Q}$ に依存しないから尤度も $\boldsymbol{Q}$ に依存せず、これが式 (3.17)の $\boldsymbol{Q}$ の任意性の由来である。$\boldsymbol{C} = \boldsymbol{B}_k(\boldsymbol{L}^2 + \sigma^2\boldsymbol{I}_k)\boldsymbol{B}_k^\top + \sigma^2(\boldsymbol{I}_d - \boldsymbol{B}_k\boldsymbol{B}_k^\top)$ は $\boldsymbol{C}$ のスペクトル分解で、固有値は $l_j^2+\sigma^2$（$j\le k$）と σ^2（重複度 $d-k$）である。よって $a_j \coloneqq \boldsymbol{b}_j^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{b}_j$ とおけば、最小化すべき $f \coloneqq \log\det \boldsymbol{C} + \operatorname{tr}(\boldsymbol{C}^{-1}\widehat{\boldsymbol{\Sigma}})$ は

$$f = \sum_{j=1}^{k} \Big[\log(l_j^2+\sigma^2) + a_j\Big(\frac{1}{l_j^2+\sigma^2} - \frac{1}{\sigma^2}\Big)\Big] + (d-k)\log\sigma^2 + \frac{\operatorname{tr}\widehat{\boldsymbol{\Sigma}}}{\sigma^2}$$

と書ける。

なぜ上位固有ベクトルか。 $l_j > 0$ ならば $\frac{1}{l_j^2+\sigma^2} - \frac{1}{\sigma^2} < 0$、すなわち a_j の係数は負である。そこで

$$w_j \coloneqq \frac{1}{\sigma^2} - \frac{1}{l_j^2+\sigma^2} \;>0 \tag{3.19}$$

とおくと、$\boldsymbol{B}_k$ に依存する部分は $-\sum_{j\le k} w_j a_j$ だけであり、f の最小化は**重み付き和** $\sum_{j\le k} w_j a_j$ の最大化と同値である。ここで各 a_j に掛かる重みは j ごとに異なるので、無重みの定理 3.6をそのまま当てることはできない（上の警告ボックス）。

σ^2 と $l_1 \ge \cdots \ge l_k$ を固定すると式 (3.19)より $w_1 \ge \cdots \ge w_k > 0$ は降順である。したがって補題 3.23を $\boldsymbol{A} = \widehat{\boldsymbol{\Sigma}}$、重み (w_j) に適用して

$$\sum_{j=1}^{k} w_j\, \boldsymbol{b}_j^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{b}_j \;\le\; \sum_{j=1}^{k} w_j \lambda_j$$

であり、等号は $\boldsymbol{b}_j = \boldsymbol{u}_j$（$\lambda_j$ の降順に対応させる）で達成される。すなわち**上位 k 個の固有ベクトルが選ばれること、および大きい l_j に大きい λ_j を対応させる順序まで**が同時に決まる。負の係数の絶対値 w_j が大きい成分に大きい λ_j を割り当てるのが有利、という直観がそのまま並べ替え不等式である。（$l_j = 0$ となる j があれば $w_j = 0$ でその方向は尤度に効かず、$\boldsymbol{b}_j$ は不定になる。以下では最適解で $l_j^2 = \lambda_j - \sigma^2 > 0$ となることを確認する。）実際、$d=6$ の上の乱数例で Stiefel 多様体上を 300 回の初期値から数値最適化すると最大値は 21.1584940143 で、$\sum_j w_j\lambda_j = 21.1584940145$（差 1.6×10^{-10}）と一致する。$\{\boldsymbol{u}_1,\dots,\boldsymbol{u}_6\}$ から 3 本を選ぶすべての順序つき組では降順対応 $(\boldsymbol{u}_1,\boldsymbol{u}_2,\boldsymbol{u}_3)$ が最大 21.15849、逆向きの $(\boldsymbol{u}_6,\boldsymbol{u}_5,\boldsymbol{u}_4)$ が最小 2.28914 であった。

特異値とノイズ分散。 $\boldsymbol{b}_j = \boldsymbol{u}_j$ なら $a_j = \lambda_j \circ t_j \coloneqq l_j^2+\sigma^2$ とおくと f の j 番目の項は $\log t_j + \lambda_j/t_j$ で、微分 $t_j^{-1} - \lambda_j t_j^{-2} = 0$ より $t_j = \lambda_j$、すなわち $l_j^2 = \lambda_j - \sigma^2$。代入すると $f = \sum_{j\le k}\log\lambda_j + k + (d-k)\log\sigma^2 + \sigma^{-2}\sum_{j>k}\lambda_j$ となり、σ^2 で微分して $\frac{d-k}{\sigma^2} - \frac{1}{\sigma^4}\sum_{j>k}\lambda_j = 0$、よって $\hat\sigma^2 = \frac{1}{d-k}\sum_{j>k}\lambda_j$、すなわち**捨てられた方向の平均分散**を得る。 ■

注意 3.24 ($\sigma^2 \to 0$ の極限と確率モデル化の利点)**.** $\hat\sigma^2 \to 0$ とすると $\widehat{\boldsymbol{W}} \to \boldsymbol{U}_k\boldsymbol{\Lambda}_k^{1/2}\boldsymbol{Q}$ である。潜在変数の事後平均は正規分布の条件付き分布の公式から $\mathbb{E}[\boldsymbol{z}\mid\boldsymbol{x}] = \boldsymbol{M}^{-1}\boldsymbol{W}^\top(\boldsymbol{x}-\boldsymbol{\mu})$（$\boldsymbol{M} \coloneqq \boldsymbol{W}^\top\boldsymbol{W} + \sigma^2\boldsymbol{I}_k$）であり、$\sigma^2\to0$ で $\boldsymbol{M}^{-1}\boldsymbol{W}^\top \to (\boldsymbol{W}^\top\boldsymbol{W})^{-1}\boldsymbol{W}^\top = \boldsymbol{W}^+$、すなわち $\boldsymbol{W}$ の列空間への直交射影の座標表示になる。$\boldsymbol{Q} = \boldsymbol{I}$ とすれば $\mathbb{E}[\boldsymbol{z}\mid\boldsymbol{x}] \to \boldsymbol{\Lambda}_k^{-1/2}\boldsymbol{U}_k^\top(\boldsymbol{x}-\boldsymbol{\mu})$、これは白色化された主成分スコアである。つまり**通常の PCA は PPCA のノイズなし極限**である。

確率モデル化で次の拡張が自然に得られる。**欠測値**——未観測成分を潜在変数と同様に扱い EM 法で周辺化できるので「欠測を平均で埋めてから PCA」といった場当たり的処理が不要になる。**混合モデル**——PPCA の混合（mixture of PPCA）は複数の局所的な線形部分空間を表現でき、曲がった多様体の区分線形近似になる。**モデル選択**——k を対数尤度、AIC、BIC、周辺尤度で選べる。$\boldsymbol{W}$ の列ごとに事前分布の精度を置くベイズ PCA では不要な列が 0 に縮小され k が自動決定される。**生成と外れ**

値検出——標本を生成でき、各点の尤度を外れ値スコアにできる。一方で等方ノイズとガウス性の仮定は強く、変数ごとにノイズの大きさが違うなら因子分析、非ガウス性が本質的なら ICA や非線形モデルを検討すべきである。

3.11　PCA の幾何と限界

$\widehat{\boldsymbol{\Sigma}}$ が正則のとき、集合 $\mathcal{E} \coloneqq \{\boldsymbol{x} : (\boldsymbol{x}-\bar{\boldsymbol{x}})^{\top}\widehat{\boldsymbol{\Sigma}}^{-1}(\boldsymbol{x}-\bar{\boldsymbol{x}}) = 1\}$ は楕円体である。$\boldsymbol{x}-\bar{\boldsymbol{x}} = \sum_j c_j \boldsymbol{u}_j$ と展開すれば条件は $\sum_j c_j^2/\lambda_j = 1$、すなわち主軸が $\boldsymbol{u}_1, \dots, \boldsymbol{u}_d$、半軸長が $\sqrt{\lambda_1}, \dots, \sqrt{\lambda_d}$ の楕円体である。つまり **PCA が計算しているのは、データの散らばりを表す楕円体の主軸**である。データが $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ に従うなら $\mathcal{E}$ は密度の等高線に一致する。

この幾何像は同時に限界を教える。PCA が扱えるのは「平均を通る線形部分空間」と「楕円体で表せる散らばり」だけである。

曲がった構造——半径 1 と半径 3 の円周上に一様に散らばる同心円状のデータでは、対称性から $\widehat{\boldsymbol{\Sigma}} \approx c\,\boldsymbol{I}_2$ となりすべての方向の分散が等しいので固有値は縮退し、主成分方向は決まらない。どの 1 次元部分空間に射影しても二つの円は重なって区別できない。しかし人間の目には「半径」という 1 次元の構造がはっきり見えている。本質的な自由度は 1 なのに PCA はそれを見つけられない——線形写像しか使えないことの帰結である。高次元の例として Swiss roll（渦巻き状に巻いた 2 次元シート）があり、内在次元は 2 だが PCA で 2 次元に落とすと巻きが潰れて本来遠い点どうしが重なる。

2 次モーメントしか見ない——$\widehat{\boldsymbol{\Sigma}}$ だけを入力とするから共分散が同じデータは区別できない。「$(\pm 2, 0)$ の周りの二つのクラスタ」と「x 軸方向に細長い一つの雲」はパラメータを合わせれば同じ共分散を持つが構造はまったく違う。クラスタ構造を見つけたいなら混合モデルやクラスタリングが必要である。また $\widehat{\boldsymbol{\Sigma}}$ は二乗の平均なので遠く離れた 1 点が固有ベクトルを大きく動かす（ロバスト化は第4章）。

第1章の非線形化の三戦略が、ここで具体的な意味を持つ。**明示的な特徴写像**——同心円の例では $\phi(\boldsymbol{x}) = (x_1, x_2, x_1^2 + x_2^2)^{\top}$ のように半径の情報を付け加えれば変換後の空間で線形手法が働くが、どの特徴を足すべきかを事前に知る必要がある。**カーネル**——特徴写像を明示せず内積 $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \phi(\boldsymbol{x}), \phi(\boldsymbol{x}') \rangle$ だけを指定する。PCA は $\widehat{\boldsymbol{\Sigma}}$ の固有分解だが、第4章で見るとおり Gram 行列 $\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}$ の固有分解としても書けるので、後者なら内積だけで計算が完結しそのままカーネル化できる——第8章のカーネル PCA である。**学習される特徴**——特徴写像自体を学ぶ。線形の自己符号化器（autoencoder）は PCA と同じ部分空間を学習し、活性化関数を非線形にすれば非線形次元削減になる（第10章）。低次元多様体という仮定を正面から扱う多様体学習（Isomap、局所線形埋め込み、拡散写像）は第11章で紹介する。

3.12　数式と実装の対応

定義式どおりの実装とライブラリの結果を突き合わせよう。リスト 3.1は 式 (3.1)からスコアの定義までをそのままコードにしたものである。

リスト 3.1　定義どおりの PCA と `scikit-learn` の比較

```python
import numpy as np
from numpy.linalg import eigh
from sklearn.decomposition import PCA

rng = np.random.default_rng(0)
d, n, k = 5, 200, 2
mu = np.array([3., -1., .5, 2., 0.]).reshape(d, 1)
X = (rng.normal(size=(n, d)) @ rng.normal(size=(d, d))).T + mu   # X is d x n

Xt = X - X.mean(axis=1, keepdims=True)  # centred data matrix  Xtilde = X H
lam, U = eigh(Xt @ Xt.T / n)            # sample covariance, ascending eigenvalues
order  = np.argsort(lam)[::-1]          # sort in descending order
lam, U = lam[order], U[:, order]
W = U[:, :k]                            # loading vectors u_1,...,u_k
Z = W.T @ Xt                            # scores, k x n (i-th column = z_i)

pca = PCA(n_components=k, svd_solver="full").fit(X.T)   # sklearn は n×d 規約なので転置
sg  = np.sign((W * pca.components_.T).sum(axis=0))      # fix the sign ambiguity
print(np.abs(Z * sg[:, None] - pca.transform(X.T).T).max())
print(lam[:k] / lam.sum(), pca.explained_variance_ratio_)
print(np.round(np.cov(Z, bias=True), 10))               # Z の行が成分なので rowvar=True
```

出力は 2.52×10^{-14}、寄与率は両者ともに $(0.63048, 0.24461)$、スコアの標本共分散は $\mathrm{diag}(8.9581, 3.4755)$ である。スコアは倍精度の丸め誤差の範囲で一致し、寄与率は完全に一致し、共分散は対角行列になっている（命題 3.9）。

符号の任意性

$\widehat{\boldsymbol{\Sigma}}\boldsymbol{u} = \lambda \boldsymbol{u}$ ならば $\widehat{\boldsymbol{\Sigma}}(-\boldsymbol{u}) = \lambda(-\boldsymbol{u})$ でもあるから主成分方向の符号は数学的に決まらず、どちらが返るかは固有値ソルバの実装や BLAS の版に依存しうる。「昨日と今日で散布図が上下反転した」のはバグではない。比較や再現の際は「各負荷

ベクトルの絶対値最大成分を正にする」等の規約で符号を固定するとよい。上のコードでは `np.sign(...)` で両者の符号を機械的に揃えている。

同じ枠組みで白色化（定義 3.16）も検証できる。$\boldsymbol{Z}_{\mathrm{PCA}} = \boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^{\top}\widetilde{\boldsymbol{X}}$ と $\boldsymbol{Z}_{\mathrm{ZCA}} = \boldsymbol{U}\boldsymbol{Z}_{\mathrm{PCA}}$ は $d=3$, $n=500$ の人工データでどちらも $\max|\frac{1}{n}\boldsymbol{Z}\boldsymbol{Z}^{\top} - \boldsymbol{I}_3|$ が 10^{-15} 台（丸め誤差の範囲）になるが、元データとの距離は 58.5 対 112.8 で ZCA のほうが小さく、命題 3.18が裏づけられる。確率的 PCA についても、固有分解の後 $\hat{\sigma}^2 = \frac{1}{d-k}\sum_{j>k}\lambda_j$, $\widehat{\boldsymbol{W}} = \boldsymbol{U}_k(\boldsymbol{\Lambda}_k - \hat{\sigma}^2\boldsymbol{I}_k)^{1/2}$ を計算して ℓ をランダム摂動と比べればよい。$d=5$, $k=2$, $n=400$、真のノイズ分散 0.16 の人工データでは $\hat{\sigma}^2 = 0.1625$、対数尤度 -2400.85 が得られ、標準偏差 0.05 の摂動 200 回のうち尤度を改善したものは 0 件であった。

演習問題

演習 3.1 (★). $k=1$ の場合の (F1)⇔(F2) を、行列記法を使わずに確認せよ。$\|\boldsymbol{w}\|=1$ と中心化データに対し射影を $\boldsymbol{P}\tilde{\boldsymbol{x}}_i = (\boldsymbol{w}^{\top}\tilde{\boldsymbol{x}}_i)\boldsymbol{w}$ として $\sum_i\|\tilde{\boldsymbol{x}}_i - (\boldsymbol{w}^{\top}\tilde{\boldsymbol{x}}_i)\boldsymbol{w}\|^2 = \sum_i\|\tilde{\boldsymbol{x}}_i\|^2 - \sum_i(\boldsymbol{w}^{\top}\tilde{\boldsymbol{x}}_i)^2$ を成分計算で示し、右辺第 1 項が $\boldsymbol{w}$ によらないことから「残差二乗和の最小化」と「射影の二乗和の最大化」が同値であると結論せよ。さらに例 3.8のデータ（$\widetilde{\boldsymbol{X}}$ の**列**が $\tilde{\boldsymbol{x}}_i$）に $\boldsymbol{w}=\boldsymbol{u}_1$ と $\boldsymbol{w}=(1,0)^{\top}$ を代入し、両辺の値を計算して数値で確認せよ。

演習 3.2 (★). 共分散行列 $\widehat{\boldsymbol{\Sigma}} = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}$ について手計算で求めよ。(1) 固有値 λ_1, λ_2。(2) 単位固有ベクトル $\boldsymbol{u}_1, \boldsymbol{u}_2$（成分が簡単な整数比になるように）。(3) 第 1 主成分の寄与率。(4) $k=1$ での標本 1 個あたりの再構成誤差 $\frac{1}{n}\sum_i\|\tilde{\boldsymbol{x}}_i - \boldsymbol{P}\tilde{\boldsymbol{x}}_i\|^2$。

演習 3.3 (★★). 定理 3.6（Ky Fan）の証明では $c_j = \boldsymbol{u}_j^{\top}\boldsymbol{P}\boldsymbol{u}_j$ が $0 \le c_j \le 1$ かつ $\sum_j c_j = k$ を満たすことを使った。(1) 逆に、これらを満たす任意の実数列 (c_j) がある階数 k の直交射影で $c_j = \boldsymbol{u}_j^{\top}\boldsymbol{P}\boldsymbol{u}_j$ として実現できるかを調べよ（$d=2, k=1$ と $d=3, k=1$ で具体的に考察し、一般の場合を述べよ）。(2) $\lambda_k > \lambda_{k+1}$ のとき $\operatorname{tr}(\boldsymbol{W}^{\top}\widehat{\boldsymbol{\Sigma}}\boldsymbol{W}) = \sum_{j\le k}\lambda_j$ を達成する $\boldsymbol{W}$ は $\boldsymbol{W} = \boldsymbol{U}_k\boldsymbol{Q}$（$\boldsymbol{Q}$ は直交）の形に限ることを示せ。

演習 3.4 (★★). 中心化について。(1) 恒等式 $\frac{1}{n}\boldsymbol{X}\boldsymbol{X}^{\top} = \widehat{\boldsymbol{\Sigma}} + \bar{\boldsymbol{x}}\bar{\boldsymbol{x}}^{\top}$ を証明せよ。(2) $\widehat{\boldsymbol{\Sigma}}$ と $\frac{1}{n}\boldsymbol{X}\boldsymbol{X}^{\top}$ の最大固有値を λ_1, λ_1' とし、Weyl の不等式（第2章）で $\lambda_1 \le \lambda_1' \le \lambda_1 + \|\bar{\boldsymbol{x}}\|^2$ を示せ。(3) $\bar{\boldsymbol{x}}$ が $\boldsymbol{u}_1$ と直交するとき、$\frac{1}{n}\boldsymbol{X}\boldsymbol{X}^{\top}$ の最大固有値に属する固有ベクトルが $\widehat{\boldsymbol{\Sigma}}$ の第 1 主成分と一致しないことを例 3.13で説明せよ。

演習 3.5 (★★). 白色化について。(1) $\lambda_d = 0$ のとき定義 3.16の白色化が定義できない理由を述べ、上位 k（$\lambda_k > 0$）成分のみの $\boldsymbol{Z} = \boldsymbol{\Lambda}_k^{-1/2}\boldsymbol{U}_k^{\top}\widetilde{\boldsymbol{X}}$ が $\frac{1}{n}\boldsymbol{Z}\boldsymbol{Z}^{\top} = \boldsymbol{I}_k$ を満たすことを示せ。(2) $\widehat{\boldsymbol{\Sigma}} = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}$ に対し ZCA 白色化行列 $\widehat{\boldsymbol{\Sigma}}^{-1/2}$ を具体的に計算せよ。

演習 3.6 (★★★). 確率的 PCA の周辺分布を導出せよ。(1) 命題 3.21を、特性関数ではなく直接の積分 $p(\boldsymbol{x}) = \int p(\boldsymbol{x}\mid\boldsymbol{z})p(\boldsymbol{z})\,\mathrm{d}\boldsymbol{z}$ で示せ。指数部の $\boldsymbol{z}$ に関する二次形式を平方完成し、Woodbury の恒等式 $(\sigma^2\boldsymbol{I}_d + \boldsymbol{W}\boldsymbol{W}^{\top})^{-1} = \sigma^{-2}(\boldsymbol{I}_d - \boldsymbol{W}(\sigma^2\boldsymbol{I}_k + \boldsymbol{W}^{\top}\boldsymbol{W})^{-1}\boldsymbol{W}^{\top})$ と行列式補題 $\det(\sigma^2\boldsymbol{I}_d + \boldsymbol{W}\boldsymbol{W}^{\top}) = \sigma^{2(d-k)}\det(\sigma^2\boldsymbol{I}_k + \boldsymbol{W}^{\top}\boldsymbol{W})$ を用いて整理せよ。(2) 事後分布が $p(\boldsymbol{z}\mid\boldsymbol{x}) = \mathcal{N}(\boldsymbol{M}^{-1}\boldsymbol{W}^{\top}(\boldsymbol{x}-\boldsymbol{\mu}), \sigma^2\boldsymbol{M}^{-1})$、$\boldsymbol{M} = \boldsymbol{W}^{\top}\boldsymbol{W} + \sigma^2\boldsymbol{I}_k$ となることを示せ。(3) $\sigma^2 \to 0$ の極限で事後平均が $\boldsymbol{W}$ の列空間への射影の座標に収束することを確認せよ。

演習 3.7 (★★、実装). 次元選択の規準を実装して比較せよ。$n=200$, $d=30$ とし $\boldsymbol{x}_i = \boldsymbol{A}\boldsymbol{z}_i + \boldsymbol{\varepsilon}_i$（$\boldsymbol{z}_i \in \mathbb{R}^5$ は標準正規、$\boldsymbol{A} \in \mathbb{R}^{30\times 5}$ は標準正規乱数、$\boldsymbol{\varepsilon}_i \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}_{30})$）、行列形では $\boldsymbol{X} = \boldsymbol{A}\boldsymbol{Z} + \boldsymbol{E} \in \mathbb{R}^{30\times 200}$（$\boldsymbol{Z} \in \mathbb{R}^{5\times 200}$）で人工データを生成する（真の $k=5$）。(1) 相関行列 PCA のスクリープロットを描き、Kaiser 基準（$\lambda_j > 1$）で選ばれる k を報告せよ。(2) 平行分析を実装せよ。各**行**（＝変数）を独立にランダム置換したデータ行列を 500 個作り、j 番目の固有値の 95 パーセンタイルを実データの固有値と重ねて描き、選ばれる k を報告せよ。(3) ノイズを $\mathcal{N}(\boldsymbol{0}, 4\boldsymbol{I}_{30})$ に変えて (1)(2) を繰り返し、どちらの規準が真の $k=5$ に近い答えを与えるか論じよ。

演習 3.8 (★★、実装). 前処理の影響を数値実験で確かめよ。(1) 2 変数のデータを $n=100$ 個生成する。第 1 変数は平均 170、標準偏差 6（身長 cm）、第 2 変数は第 1 変数と相関 0.7 を持ち平均 65、標準偏差 5（体重 kg）とする。共分散行列 PCA を行い、第 1 主成分の方向（x 軸との角度）と寄与率を報告せよ。(2) 第 1 変数を mm 単位（10 倍）にして同じ計算を行い、角度と寄与率の変化を報告せよ。(3) 相関行列 PCA では (1) と (2) の結果が一致することを数値で確認せよ。(4) 中心化せずに $\frac{1}{n}\boldsymbol{X}\boldsymbol{X}^{\top}$ を固有分解すると第 1 主成分がどうなるかを調べ、$\bar{\boldsymbol{x}}$ との角度を報告せよ。

演習 3.9 (★★、実装). 定理 3.10を数値で確かめる。$d=8$、$n=60$ とし、`A = rng.standard_normal((8,8))` を作って $\boldsymbol{X} = \boldsymbol{A}\cdot$`rng.standard_normal((8,60))`（`default_rng(0)`）とする。

(1) $k=1,2,3,5$ について、すべての対 (i,j) で $\|\boldsymbol{z}_i - \boldsymbol{z}_j\| \le \|\tilde{\boldsymbol{x}}_i - \tilde{\boldsymbol{x}}_j\|$ が成り立つことを確認せよ。

(2) 同じ k について対距離の二乗和の比を計算し、累積寄与率と一致することを確認せよ。

(3) $k = 2$ について個々の比 $\|\boldsymbol{z}_i - \boldsymbol{z}_j\| / \|\tilde{\boldsymbol{x}}_i - \tilde{\boldsymbol{x}}_j\|$ の分布（最小・中央値・最大）を求め、$\sqrt{\text{累積寄与率}}$ の付近に集中する**わけではない**ことを確認せよ。なぜそうなるかを、主成分部分空間との位置関係から説明せよ。

(4) $\tilde{\boldsymbol{x}}_i - \tilde{\boldsymbol{x}}_j$ が $\mathrm{span}\{\boldsymbol{u}_1, \boldsymbol{u}_2\}$ に含まれるような人工的な点の組を作り、等号が成立することを数値で示せ。逆に差ベクトルが $\mathrm{span}\{\boldsymbol{u}_3, \ldots, \boldsymbol{u}_8\}$ に含まれるとき、射影後の距離がどうなるかも確認せよ。

第 4 章

主成分分析の計算技法と拡張

この章のねらい

第3章では PCA が何を最適化しているかを見た。本章は「ではどう計算するか」に答える。$n \ll d$ のときの双対 PCA、上位数本だけを取る反復法、ランダム化 SVD、逐次データへのオンライン学習という四つの計算戦略を導出とともに与え、さらに欠測・外れ値・解釈性という現実の困難への三つの拡張と、数値計算上の落とし穴を扱う。双対 PCA は第8章のカーネル PCA の原型であり、本章はその準備でもある。[a]

[a] この章の計算は演習ノートブック `ch04_pca_computation.ipynb` で再現できる。インストール不要で実行するには Google Colab で開く：
`https://colab.research.google.com/github/yusukeimoto/data-analysis-math-demos/blob/main/notebooks/ch04_pca_computation.ipynb`

4.1 計算量の整理：n と d のどちらが大きいか

PCA の解は標本共分散 $\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top} \in \mathbb{R}^{d\times d}$ の上位固有ベクトルであった。数学的には一意だが、計算機上でそれを得る道は三つある。(a) $\widehat{\boldsymbol{\Sigma}}$ を作って**対称固有値分解**にかける（`numpy.linalg.eigh` などの実装）、(b) $\widetilde{\boldsymbol{X}} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$ と直接 SVD する（**左**特異ベクトル $\boldsymbol{U} \in \mathbb{R}^{d\times r}$ が主成分方向、$\lambda_i = \sigma_i^2/n$）、(c) 積 $\boldsymbol{w} \mapsto \widehat{\boldsymbol{\Sigma}}\boldsymbol{w}$ を繰り返して上位 k 本だけを求める。演算回数は、$\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$ が $O(nd^2)$、完全固有値分解が $O(d^3)$ だから (a) は $O(nd^2 + d^3)$ でメモリ $O(d^2)$、(b) は $O(nd\min(n,d))$ で $\widehat{\boldsymbol{\Sigma}}$ を作らず、(c) は 1 反復が $\widetilde{\boldsymbol{X}}^{\top}\boldsymbol{w}$ と $\widetilde{\boldsymbol{X}}(\widetilde{\boldsymbol{X}}^{\top}\boldsymbol{w})$ の 2 回で k 本同時なら $O(ndk)$、追加メモリ $O((n+d)k)$ である。

要点は三つある。d が大きいと $O(d^3)$ が致命的で、$d = 20000$ なら $d^3 = 8\times 10^{12}$ で毎秒 10^{10} 演算の計算機でも 10 分以上かかるが $n = 100$ なら $n^3 = 10^6$ で一瞬である。k が小さいなら完全分解は無駄である。そして $\widehat{\boldsymbol{\Sigma}}$ を陽に作る (a)(b′) は条件数を 2 乗する代償を払っている（4.9節）。

例 4.1 (三つの現場での見積もり)**. アンケート**（$n = 10^5, d = 50$）：$nd^2 = 2.5\times 10^8$、$d^3 = 1.25\times 10^5$ で戦略 (a)。**遺伝子発現**（$n = 100, d = 20000$）：$nd^2 = 4\times 10^{10}$、$d^3 = 8\times 10^{12}$ に対し $n^2 d = 2\times 10^8$、$n^3 = 10^6$ で双対 PCA が圧倒的に有利。**文書 - 単語行列**（$n = 10^6, d = 10^5$、非零 1%）：$\widetilde{\boldsymbol{X}}$ すら密行列として持てず (c)(d) のみ。

注意 4.2. 最後の例には落とし穴がある。疎行列 $\boldsymbol{X}$ を中心化した $\widetilde{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{H} = \boldsymbol{X} - \bar{\boldsymbol{x}}\mathbf{1}^{\top}$ は密になる。そこで $\widetilde{\boldsymbol{X}}$ を作らず、積を $\widetilde{\boldsymbol{X}}^{\top}\boldsymbol{w} = \boldsymbol{X}^{\top}\boldsymbol{w} - \mathbf{1}(\bar{\boldsymbol{x}}^{\top}\boldsymbol{w})$ および $\widetilde{\boldsymbol{X}}\boldsymbol{c} = \boldsymbol{X}\boldsymbol{c} - \bar{\boldsymbol{x}}(\mathbf{1}^{\top}\boldsymbol{c})$ と分解する（第 1 項は疎行列積、第 2 項は $O(n+d)$）。反復法とランダム化 SVD が「行列ベクトル積さえ計算できればよい」形をしていることの実用上の価値がここにある。

4.2 双対 PCA：$n \ll d$ のとき

$d = 20000$、$n = 100$ の遺伝子発現データでは $\widehat{\boldsymbol{\Sigma}}$ は 20000×20000（倍精度で 3.2 GB）だがその階数はたかだか $\min(n-1, d) = 99$ で、実質 99 次元の対象を 4×10^8 個の数で表すのは無駄が大きい。一方、**列どうし**（＝サンプルどうし）の内積を並べたグラム行列（Gram matrix）

$$\boldsymbol{G} := \widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}} \in \mathbb{R}^{n\times n}, \qquad G_{ij} = \langle \tilde{\boldsymbol{x}}_i, \tilde{\boldsymbol{x}}_j \rangle \tag{4.1}$$

は 100×100 にすぎない。$\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$ と $\boldsymbol{G}$ は同じ非零固有値を持つ（第2章の $\boldsymbol{A}\boldsymbol{B}$ と $\boldsymbol{B}\boldsymbol{A}$ のスペクトルの一致。ここで $\boldsymbol{A} = \widetilde{\boldsymbol{X}}$, $\boldsymbol{B} = \widetilde{\boldsymbol{X}}^{\top}$）。ならば小さいほうを解いて主成分方向を復元すればよい。

表4.1　PCA の計算戦略の比較。k は必要な主成分の本数、c は反復回数（通常 10〜10^2）。「陽に作る行列」はデータ行列以外に確保が必要な最大の行列。

戦略	時間	陽に作る行列	適する状況	精度
(a) $\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$ + 対称固有値分解	$O(nd^2+d^3)$	$d \times d$	$d \ll n$	条件数が 2 乗
(b) $\widetilde{\boldsymbol{X}}$ の SVD	$O(nd\min(n,d))$	なし	$n \approx d$	最良
(b′) 双対 $\boldsymbol{G} = \widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}$	$O(n^2d+n^3)$	$n \times n$	$n \ll d$	条件数が 2 乗
(c) 反復法	$O(ndkc)$	なし	$k \ll \min(n,d)$	制御可能
(d) ランダム化 SVD	$O(nd(k+p))$	なし	巨大かつ k 小	確率的保証

用語を決めておく。共分散行列 $\widehat{\boldsymbol{\Sigma}}$（$d \times d$、変数側）の固有値問題を解く従来のやり方を **主 PCA**（primal PCA）、グラム行列 $\boldsymbol{G}$（$n \times n$、サンプル側）の側を解くやり方を **双対 PCA**（dual PCA）と呼ぶ。最適化における主問題と双対問題の関係と同じ意味の「主／双対」で、第9章の SVM でも同じ対応が現れる。以下「主 PCA」と書いたら**通常の**（共分散側の）PCA のことである。

$n \times n$ 側の固有ベクトルは**サンプル側**の空間 $\mathbb{R}^n$ に住み、求めたい主成分方向は**変数側**の空間 $\mathbb{R}^d$ に住む。したがって復元は「$\mathbb{R}^n$ のベクトルに $\widetilde{\boldsymbol{X}}$ を**左から**掛けて $\mathbb{R}^d$ に移す」向きになる。

定理 4.3 (双対 PCA)**.** $\boldsymbol{G} = \widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}} \in \mathbb{R}^{n\times n}$ の固有値を $\mu_1 \geq \cdots \geq \mu_n \geq 0$、対応する正規直交固有ベクトルを $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_n \in \mathbb{R}^n$ とする。$\mu_i > 0$ なる i に対し $\sigma_i \coloneqq \sqrt{\mu_i}$ とおき

$$\boldsymbol{u}_i \coloneqq \frac{1}{\sigma_i}\widetilde{\boldsymbol{X}}\boldsymbol{v}_i \ \in \mathbb{R}^d \tag{4.2}$$

と定めると、(i) $\{\boldsymbol{u}_i\}$ は正規直交系、(ii) $\widehat{\boldsymbol{\Sigma}}\boldsymbol{u}_i = (\mu_i/n)\boldsymbol{u}_i$、(iii) $\widetilde{\boldsymbol{X}} = \sum_{i:\mu_i>0}\sigma_i\boldsymbol{u}_i\boldsymbol{v}_i^{\top}$ は $\widetilde{\boldsymbol{X}}$ の簡約 SVD、(iv) $\widehat{\boldsymbol{\Sigma}}$ の非零固有値はすべてこれで尽くされ、残り $d - \operatorname{rank}(\widetilde{\boldsymbol{X}})$ 個は 0 である。

次元を数えておく。$\widetilde{\boldsymbol{X}}$ は $d \times n$、$\boldsymbol{v}_i$ は n 次元だから $\widetilde{\boldsymbol{X}}\boldsymbol{v}_i$ は $(d\times n)(n\times 1) = (d\times 1)$ で、たしかに $\mathbb{R}^d$ の元、すなわち主成分方向の住む空間の元である。

証明. (i) $\mu_i, \mu_j > 0$ とすると $\langle \boldsymbol{u}_i, \boldsymbol{u}_j\rangle = \frac{1}{\sigma_i\sigma_j}\boldsymbol{v}_i^{\top}\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}\boldsymbol{v}_j = \frac{1}{\sigma_i\sigma_j}\boldsymbol{v}_i^{\top}\boldsymbol{G}\boldsymbol{v}_j = \frac{\mu_j}{\sigma_i\sigma_j}\delta_{ij}$ であり、$i = j$ なら $\mu_i/\sigma_i^2 = 1$、$i \neq j$ なら 0。

(ii) 括弧を付け替えるだけでよい。

$$\widehat{\boldsymbol{\Sigma}}\boldsymbol{u}_i = \frac{1}{n\sigma_i}\widetilde{\boldsymbol{X}}(\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}\boldsymbol{v}_i) = \frac{1}{n\sigma_i}\widetilde{\boldsymbol{X}}(\mu_i\boldsymbol{v}_i) = \frac{\mu_i}{n}\boldsymbol{u}_i.$$

$d \times d$ 行列を一度も作らずにその固有ベクトルが手に入っている。(iii) $r \coloneqq \operatorname{rank}(\widetilde{\boldsymbol{X}})$ とおくと $\operatorname{Ker}\boldsymbol{G} = \operatorname{Ker}\widetilde{\boldsymbol{X}}$ より $\boldsymbol{G}$ の非零固有値も r 個。$\boldsymbol{M} \coloneqq \sum_{i\leq r}\sigma_i\boldsymbol{u}_i\boldsymbol{v}_i^{\top}$ とおく。$\{\boldsymbol{v}_j\}$ は $\mathbb{R}^n$ の正規直交基底だから $\widetilde{\boldsymbol{X}}\boldsymbol{v}_j = \boldsymbol{M}\boldsymbol{v}_j$ を全 j で示せば十分である。$j \leq r$ なら 式 (4.2)より $\boldsymbol{M}\boldsymbol{v}_j = \sigma_j\boldsymbol{u}_j = \widetilde{\boldsymbol{X}}\boldsymbol{v}_j$、$j > r$ なら $\|\widetilde{\boldsymbol{X}}\boldsymbol{v}_j\|^2 = \boldsymbol{v}_j^{\top}\boldsymbol{G}\boldsymbol{v}_j = \mu_j = 0$ より $\widetilde{\boldsymbol{X}}\boldsymbol{v}_j = \boldsymbol{0} = \boldsymbol{M}\boldsymbol{v}_j$。$\{\boldsymbol{u}_i\}, \{\boldsymbol{v}_i\}$ の正規直交性よりこれは SVD の定義を満たす。

(iv) (iii) より $\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\sum_{i\leq r}\sigma_i^2\boldsymbol{u}_i\boldsymbol{u}_i^{\top}$ だから、$\boldsymbol{u} \perp \operatorname{span}\{\boldsymbol{u}_1, \ldots, \boldsymbol{u}_r\}$ なら $\widehat{\boldsymbol{\Sigma}}\boldsymbol{u} = \boldsymbol{0}$。この直交補空間の次元が $d - r$ である。 ■

注意 4.4. 成分で書くと、$\boldsymbol{v}_i$ の第 j 成分を v_{ji} として $\boldsymbol{u}_i = \frac{1}{\sigma_i}\widetilde{\boldsymbol{X}}\boldsymbol{v}_i = \frac{1}{\sigma_i}\sum_{j=1}^{n} v_{ji}\,\tilde{\boldsymbol{x}}_j$ であり、主成分方向はデータ点の線形結合になっている。$\widetilde{\boldsymbol{X}}$ の列がデータ点なのだから、$\widetilde{\boldsymbol{X}}$ を右からベクトルに作用させることは列の線形結合を作ることに等しく、この式は定義から直ちに読み取れる。係数 v_{ji}/σ_i は「サンプル j のこの主成分への寄与」を表し、主成分方向が $\operatorname{Im}(\widetilde{\boldsymbol{X}}) \subset \mathbb{R}^d$、すなわちデータ点の張る空間の中にしかありえないという事実の表現でもある。

例 4.5 ($n = 2$, $d = 5$ の手計算)**.** 例 3.8と**同じ 10 個の数**を、こんどは 5 変数 2 サンプルとして読む。すなわち例 3.8の $\boldsymbol{X} \in \mathbb{R}^{2\times 5}$ を転置した

$$\boldsymbol{X} = \begin{pmatrix} 1 & 1 \\ 2 & 3 \\ 3 & 5 \\ 4 & 2 \\ 5 & 4 \end{pmatrix} \in \mathbb{R}^{5\times 2} \qquad (d = 5 \text{ 変数},\ n = 2 \text{ サンプル})$$

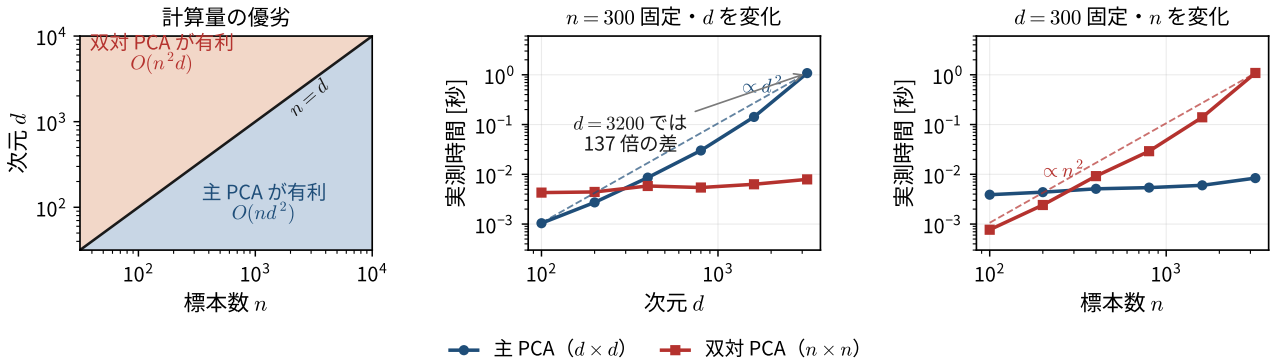


図4.1　主 PCA（$d \times d$ の固有値問題）と双対 PCA（$n \times n$）の計算コストの比較。$n < d$ の領域では双対が有利で、d/n が大きいほど差は劇的になる。

を考える。標本平均は $\bar{\boldsymbol{x}} = \frac{1}{2}\boldsymbol{X}\mathbf{1} = (1, \frac{5}{2}, 4, 3, \frac{9}{2})^\top$ だから

$$\widetilde{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{H} = \begin{pmatrix} 0 & 0 \\ -\frac{1}{2} & \frac{1}{2} \\ -1 & 1 \\ 1 & -1 \\ \frac{1}{2} & -\frac{1}{2} \end{pmatrix}, \qquad \boldsymbol{G} = \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}} = \begin{pmatrix} \frac{5}{2} & -\frac{5}{2} \\ -\frac{5}{2} & \frac{5}{2} \end{pmatrix}.$$

$\boldsymbol{G}$ は 2×2 なので固有値は暗算できて $\mu_1 = 5$, $\mu_2 = 0$、$\boldsymbol{v}_1 = \frac{1}{\sqrt{2}}(1, -1)^\top \in \mathbb{R}^2$（符号は任意）である。$\sigma_1 = \sqrt{5}$ として式 (4.2) より

$$\boldsymbol{u}_1 = \frac{1}{\sigma_1}\widetilde{\boldsymbol{X}}\boldsymbol{v}_1 = \frac{1}{\sqrt{5}} \cdot \frac{1}{\sqrt{2}}(0, -1, -2, 2, 1)^\top = \frac{1}{\sqrt{10}}(0, -1, -2, 2, 1)^\top \in \mathbb{R}^5,$$

確かに $\|\boldsymbol{u}_1\| = 1$ で、5 次元すなわち変数側の空間の元になっている。固有値は $\lambda_1 = \mu_1/n = 5/2$ であり、定理 4.3 (ii) に一致する。

直接 $\widehat{\boldsymbol{\Sigma}} = \frac{1}{2}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top$（$5 \times 5$）を対角化しても同じ $\lambda_1 = 5/2$ が出るが、5×5 の代わりに 2×2 を解んだ点が要点である。$d = 20000$ ならこの差が本質的になる。中心化後の階数は $n - 1 = 1$ なので非零固有値は 1 本しかなく、$n \ll d$ では「サンプル数が主成分の本数を縛る」ことがここにも現れている（第5章）。

同じ数でも「何を変数と見るか」で問題が変わる

例 3.8と本例のデータは同じ 10 個の数だが、前者は 2 変数 5 サンプル、後者は 5 変数 2 サンプルとして読んでいる。前者では $\widehat{\boldsymbol{\Sigma}}$ が 2×2 で固有値 $3, 1$ の **2 本**が意味を持ち、後者では $\widehat{\boldsymbol{\Sigma}}$ が 5×5 でも非零固有値は **1 本**だけである（中心化後の階数が $\min(d, n-1) = 1$ だから）。$d \times n$ 規約では**行が変数、列がサンプル**という約束が計算の中身を決める。転置を取り違えると解く行列の大きさも主成分の本数も変わるので、実装では必ず `X.shape` を確認する習慣をつけたい。

図 4.1 に比較を示す。境界は $n = d$ の対角線で、$n \ll d$ の領域（バイオインフォマティクス、画像、テキストの多く）では双対 PCA が唯一現実的な選択肢になる。実際 $n = 100$, $d = 20000$ では主 PCA が 195 秒、双対 PCA は 0.018 秒であった。

リスト 4.1　双対 PCA の実装と主 PCA との一致の検証

```python
import numpy as np

def pca_primal(X, k):                       # X is d x n. d x d cov: O(n d^2 + d^3)
    Xt = X - X.mean(axis=1, keepdims=True); n = X.shape[1]
    lam, U = np.linalg.eigh(Xt @ Xt.T / n)            # Sighat = Xt Xt^T / n
    idx = np.argsort(lam)[::-1][:k]
    return lam[idx], U[:, idx]              # principal directions live in R^d

def pca_dual(X, k):                         # n x n Gram: O(n^2 d + n^3)
    Xt = X - X.mean(axis=1, keepdims=True); n = X.shape[1]
    lam, V = np.linalg.eigh(Xt.T @ Xt / n)            # G = Xt^T Xt, eigvecs in R^n
    idx = np.argsort(lam)[::-1][:k]
    lam, V = lam[idx], V[:, idx]
    U = Xt @ V / np.sqrt(n * lam)           # u_i = Xt v_i / sigma_i  -> back to R^d
    return lam, U                           # sigma_i = sqrt(n lambda_i)

```

```python
def align_sign(A, B):                       # fix the sign ambiguity
    return A * np.sign(np.sum(A * B, axis=0))

rng = np.random.default_rng(0)
Z = rng.standard_normal((60, 4)); W = rng.standard_normal((4, 3000))
X = (Z @ W + 0.5 * rng.standard_normal((60, 3000))).T   # 3000 x 60, rank 4 + noise
l1, U1 = pca_primal(X, 5); l2, U2 = pca_dual(X, 5)
print(np.max(np.abs(l1 - l2)))              # 2.3e-12
print(np.max(np.abs(align_sign(U2, U1) - U1)))  # 1.5e-13
```

固有値の差は 2.3×10^{-12}、固有ベクトルの差は 1.5×10^{-13} で、倍精度の丸め誤差の範囲で一致している。$\boldsymbol{U}$ の列（$\mathbb{R}^d$ の元）が主成分方向であり、双対側で得た $\mathbb{R}^n$ の固有ベクトルを $\widetilde{\boldsymbol{X}}$ で左から押し出して得たものである点に注意したい。`align_sign` が必要な理由は4.9節で述べる。

双対性がカーネル化を可能にする

$\boldsymbol{G}$ の成分は内積 $\langle\tilde{\boldsymbol{x}}_i,\tilde{\boldsymbol{x}}_j\rangle$ だけで書け、新しい点 $\boldsymbol{x}$ の第 i 主成分スコアも $\langle\boldsymbol{x}-\bar{\boldsymbol{x}},\boldsymbol{u}_i\rangle=\frac{1}{\sigma_i}\sum_j v_{ji}\langle\boldsymbol{x}-\bar{\boldsymbol{x}},\tilde{\boldsymbol{x}}_j\rangle$ とやはり内積だけである。したがって内積を正定値カーネル $k(\cdot,\cdot)$ に置き換えれば、$\mathbb{R}^d$ よりはるかに高次元（無限次元でもよい）な特徴空間での PCA が $n\times n$ の固有値問題だけで実行できる。これがカーネル PCA（第8章）である。

本節の $\boldsymbol{G}$ は第8章の中心化グラム行列 $\widetilde{\boldsymbol{K}}$ の線形カーネルの場合にほかならない。実際 $\widetilde{\boldsymbol{X}}=\boldsymbol{X}\boldsymbol{H}$（$\boldsymbol{H}=\boldsymbol{I}_n-\frac{1}{n}\mathbf{1}\mathbf{1}^\top$、$n\times n$）だから、$\boldsymbol{K}=\boldsymbol{X}^\top\boldsymbol{X}$（$K_{ij}=\langle\boldsymbol{x}_i,\boldsymbol{x}_j\rangle$、$n\times n$）に対して

$$\boldsymbol{G}=\widetilde{\boldsymbol{X}}^\top\widetilde{\boldsymbol{X}}=(\boldsymbol{X}\boldsymbol{H})^\top(\boldsymbol{X}\boldsymbol{H})=\boldsymbol{H}^\top\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{H}=\boldsymbol{H}\boldsymbol{K}\boldsymbol{H}$$

（$\boldsymbol{H}^\top=\boldsymbol{H}$）が成り立っている。$\boldsymbol{H}$ は $n\times n$ なので $\widetilde{\boldsymbol{K}}=\boldsymbol{H}\boldsymbol{K}\boldsymbol{H}$ の形はデータ行列の向きに依存しない量である。第7章で正定値カーネルが「ある特徴空間の内積」であることを保証したうえで、第8章では本節の計算をそのまま繰り返すことになる。

4.3　反復法：上位数本だけが欲しいとき

$d=10^5$ の行列から第 1 主成分だけが欲しいとする。完全分解は 10^{15} 回の演算を要するが求めたいのはベクトル 1 本である。このギャップを埋めるのが反復法で、発想は素朴である。$\widehat{\boldsymbol{\Sigma}}$ を任意のベクトルに何度も作用させれば最大固有値の方向の成分が相対的に増幅される。

定理 4.6（べき乗法の収束）**.** 対称行列 $\boldsymbol{A}$ の固有値を $|\lambda_1|>|\lambda_2|\ge\cdots\ge|\lambda_d|$、正規直交固有ベクトルを $\boldsymbol{q}_1,\dots,\boldsymbol{q}_d$ とする。$\|\boldsymbol{w}^{(0)}\|=1$ かつ $\langle\boldsymbol{w}^{(0)},\boldsymbol{q}_1\rangle\neq0$ なる初期値から $\boldsymbol{w}^{(t)}=\boldsymbol{A}\boldsymbol{w}^{(t-1)}/\|\boldsymbol{A}\boldsymbol{w}^{(t-1)}\|$ を作ると、θ_t を $\boldsymbol{w}^{(t)}$ と $\boldsymbol{q}_1$ のなす角として

$$\sin\theta_t\le\tan\theta_0\cdot|\lambda_2/\lambda_1|^t \tag{4.3}$$

が成り立つ。さらに Rayleigh 商 $\rho_t=\boldsymbol{w}^{(t)\top}\boldsymbol{A}\boldsymbol{w}^{(t)}$ は $|\rho_t-\lambda_1|\le(|\lambda_1|+|\lambda_d|)\tan^2\theta_0|\lambda_2/\lambda_1|^{2t}$ を満たし、**2 乗の速さで**収束する。

証明. $\boldsymbol{w}^{(0)}=\sum_i c_i\boldsymbol{q}_i$（$c_1\neq0$、$\sum_i c_i^2=1$）と展開する。以下で $c_1^2=\cos^2\theta_0$ を使うので $\|\boldsymbol{w}^{(0)}\|=1$ が要る（反復 $\boldsymbol{w}^{(t)}=\boldsymbol{A}\boldsymbol{w}^{(t-1)}/\|\boldsymbol{A}\boldsymbol{w}^{(t-1)}\|$ 自体は初期値のスケールに依らないので、一般の $\boldsymbol{w}^{(0)}\neq\boldsymbol{0}$ には正規化してから適用すればよい）。正規化は方向を変えないから $\boldsymbol{w}^{(t)}$ は $\boldsymbol{A}^t\boldsymbol{w}^{(0)}=c_1\lambda_1^t(\boldsymbol{q}_1+\boldsymbol{r}_t)$、$\boldsymbol{r}_t:=\sum_{i\ge2}\frac{c_i}{c_1}(\frac{\lambda_i}{\lambda_1})^t\boldsymbol{q}_i$ と同じ方向を向く。正規直交性より $\|\boldsymbol{r}_t\|^2\le|\lambda_2/\lambda_1|^{2t}\sum_{i\ge2}(c_i/c_1)^2$ で、$c_1^2=\cos^2\theta_0$、$\sum_{i\ge2}c_i^2=1-c_1^2$ から $\sum_{i\ge2}(c_i/c_1)^2=\tan^2\theta_0$、すなわち $\|\boldsymbol{r}_t\|\le\tan\theta_0|\lambda_2/\lambda_1|^t$。$\boldsymbol{r}_t\perp\boldsymbol{q}_1$ より $\sin\theta_t=\|\boldsymbol{r}_t\|/\sqrt{1+\|\boldsymbol{r}_t\|^2}\le\|\boldsymbol{r}_t\|$ で (4.3) を得る。Rayleigh 商は $\boldsymbol{w}^{(t)}=\cos\theta_t\,\boldsymbol{q}_1+\sin\theta_t\,\boldsymbol{s}_t$（$\boldsymbol{s}_t\perp\boldsymbol{q}_1$、単位）と書けば $\rho_t=\lambda_1\cos^2\theta_t+\sin^2\theta_t\,\boldsymbol{s}_t^\top\boldsymbol{A}\boldsymbol{s}_t$ だから $|\rho_t-\lambda_1|\le\sin^2\theta_t(|\lambda_1|+|\lambda_d|)$ であり、(4.3) を代入すればよい。 ■

1 反復の計算量は $\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}=\frac{1}{n}\widetilde{\boldsymbol{X}}(\widetilde{\boldsymbol{X}}^\top\boldsymbol{w})$ と括弧を付ければ $O(nd)$ で（$\boldsymbol{w}\in\mathbb{R}^d$ に対し $\widetilde{\boldsymbol{X}}^\top\boldsymbol{w}\in\mathbb{R}^n$、それに $\widetilde{\boldsymbol{X}}$ を掛けて $\mathbb{R}^d$ に戻る）、$\widehat{\boldsymbol{\Sigma}}$ を作る必要はない。精度 ε に達する反復回数は $t\approx\log(1/\varepsilon)/\log|\lambda_1/\lambda_2|$ で、$\lambda_2/\lambda_1=0.9$ なら $\varepsilon=10^{-8}$ に 175 回、0.99 なら 1833 回である。ギャップが小さいと反復法は苦しい。

例 4.7（2×2 でのべき乗法）**.** $\boldsymbol{A}=\begin{pmatrix}3&1\\1&3\end{pmatrix}$ の固有値は 4（固有ベクトル $\frac{1}{\sqrt2}(1,1)^\top$）と 2 である。$\boldsymbol{w}^{(0)}=(1,0)^\top$ から始めると $\boldsymbol{w}^{(t)}$ は $(0.9487,0.3162)$, $(0.8575,0.5145)$, $(0.7894,0.6139)$, $(0.7498,0.6616)$, $(0.7288,0.6847)$ と進み、$4-\rho_t$ は 0.400, 0.118, 0.031, 0.0078, 0.0020 とおよそ 4 分の 1 ずつ減る。$|\lambda_2/\lambda_1|^{2t}=0.25^t$ という 定理 4.6 の主張と合致する。

上位 k 本が欲しいときは k 本を同時に走らせる。ただし素直にやると全部が $\boldsymbol{q}_1$ に収束してしまうので、各ステップで直交化する。

これが**同時反復**（subspace iteration）である。$\boldsymbol{W}^{(0)}\in\mathbb{R}^{d\times k}$ をランダムに取り、$\boldsymbol{Y}\leftarrow\boldsymbol{A}\boldsymbol{W}^{(t-1)}$（$O(ndk)$）と $\boldsymbol{W}^{(t)}\leftarrow\mathrm{qr}(\boldsymbol{Y})$（$O(dk^2)$）を繰り返すと、$\mathrm{span}\,\boldsymbol{W}^{(t)}$ は上位 k 次元固有空間に $|\lambda_{k+1}/\lambda_k|^t$ の速さで収束する。最後に $k\times k$ 行列 $\boldsymbol{W}^\top\boldsymbol{A}\boldsymbol{W}$ を

対角化して個々の固有ベクトルを取り出す（Rayleigh–Ritz 法）。QR は $\operatorname{span} \boldsymbol{W}$ を変えずに列を正規直交化するだけなので部分空間としての収束は損なわれず、列どうしの数値的衝突だけが防がれる。収束を支配するのが λ_k と λ_{k+1} のギャップである点に注意したい。

べき乗法は $\boldsymbol{A}^t \boldsymbol{w}^{(0)}$ という最後の 1 本しか使わないが、途中の $\boldsymbol{w}^{(0)}, \boldsymbol{A}\boldsymbol{w}^{(0)}, \dots, \boldsymbol{A}^t\boldsymbol{w}^{(0)}$ もすべて情報を持っている。これらが張る空間 $\mathcal{K}_{t+1}(\boldsymbol{A}, \boldsymbol{w}^{(0)})$ を Krylov 部分空間（Krylov subspace）といい、その中で Rayleigh 商を最大化すれば必ずより良い近似が得られる。これを行うのが Lanczos 法で、$\mathcal{K}_t$ の正規直交基底を三項漸化式 $\beta_j \boldsymbol{q}_{j+1} = \boldsymbol{A}\boldsymbol{q}_j - \alpha_j \boldsymbol{q}_j - \beta_{j-1}\boldsymbol{q}_{j-1}$（$\alpha_j = \boldsymbol{q}_j^{\top}\boldsymbol{A}\boldsymbol{q}_j$）で生成する。対称性のおかげで直交化の相手が直前の 2 本で済むのが要点で、$\boldsymbol{Q}_t^{\top}\boldsymbol{A}\boldsymbol{Q}_t$ は三重対角行列となりその固有値（Ritz 値）が両端の固有値の優れた近似を与える。収束は Chebyshev 多項式で解析され、相対ギャップ γ に対しべき乗法が $O(1/\gamma)$ 回を要するところ Lanczos は $O(1/\sqrt{\gamma})$ 回で済む。

注意 4.8 (実用上の窓口)**.** 自分で Lanczos を書く必要はない。`scipy.sparse.linalg` の `eigsh` が上位固有対を、`svds` が特異値・特異ベクトルを返す。どちらも `LinearOperator` を渡せるので、行列を持たずに行列ベクトル積を計算する関数だけを与えればよく、注意 4.2の疎行列の中心化はこれで自然に実装できる。丸めにより Lanczos ベクトルの直交性は失われるので、実装には再直交化が施されている。

4.4　ランダム化 SVD

Lanczos 法は逐次的で行列ベクトル積を 1 本ずつ行う。現代の計算機は行列行列積（BLAS-3）のほうを効率よく実行できるので、まとめて $k+p$ 本のランダムベクトルを掛けるほうが実時間で有利なことが多い。直感はこうである。ランダムなガウスベクトル $\boldsymbol{\omega} \in \mathbb{R}^n$ に対し $\boldsymbol{X}\boldsymbol{\omega} = \sum_i \sigma_i \langle \boldsymbol{v}_i, \boldsymbol{\omega}\rangle \boldsymbol{u}_i$（$\boldsymbol{u}_i \in \mathbb{R}^d$, $\boldsymbol{v}_i \in \mathbb{R}^n$）は $\boldsymbol{u}_1, \dots, \boldsymbol{u}_k$ の方向の成分を $\sigma_i \langle \boldsymbol{v}_i, \boldsymbol{\omega}\rangle$ だけ含み、$\langle \boldsymbol{v}_i, \boldsymbol{\omega}\rangle \sim \mathcal{N}(0,1)$ は確率 1 で 0 でなく極端に小さくもなりにくい。つまり**ランダムなベクトルは主要な特異ベクトル方向の成分をほぼ確実に、それなりの大きさで含む**。$k+p$ 本（p は 5〜10 程度のオーバーサンプリング）取れば、それらの張る空間は上位 k 次元をほぼ含む。

ランダム化 SVD のアルゴリズム

入力：$\boldsymbol{X} \in \mathbb{R}^{d\times n}$、目標階数 k、オーバーサンプリング p、べき乗反復 q。

1. $\boldsymbol{\Omega} \in \mathbb{R}^{n\times(k+p)}$ の各成分を独立に $\mathcal{N}(0,1)$ から引く。
2. $\boldsymbol{Y} \leftarrow \boldsymbol{X}\boldsymbol{\Omega}$（$d \times (k+p)$）、$\boldsymbol{Q} \leftarrow \operatorname{qr}(\boldsymbol{Y})$（$O(nd(k+p))$）。
3. q 回繰り返す：$\boldsymbol{Q} \leftarrow \operatorname{qr}(\boldsymbol{X}^{\top}\boldsymbol{Q})$、$\boldsymbol{Q} \leftarrow \operatorname{qr}(\boldsymbol{X}\boldsymbol{Q})$。
4. $\boldsymbol{B} \leftarrow \boldsymbol{Q}^{\top}\boldsymbol{X}$（$(k+p)\times n$）の完全 SVD $\boldsymbol{B} = \widehat{\boldsymbol{U}}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$ を計算（$O(n(k+p)^2)$）。
5. $\boldsymbol{U} \leftarrow \boldsymbol{Q}\widehat{\boldsymbol{U}}$ の上位 k 列（$\mathbb{R}^d$ の元）を返す。総計算量は $O(nd(k+p)(1+q))$。

段階 2 の $\boldsymbol{Q}$ は $\operatorname{Im}(\boldsymbol{X}) \subset \mathbb{R}^d$（データ点の張る空間）の良い近似基底で、段階 4 以降は $\boldsymbol{X} \approx \boldsymbol{Q}\boldsymbol{Q}^{\top}\boldsymbol{X} = \boldsymbol{Q}\boldsymbol{B}$ という $(k+p)$ 行の小行列に問題を縮約している（$\boldsymbol{Q}$ は等長だから $\boldsymbol{Q}\boldsymbol{B}$ の SVD は $\boldsymbol{B}$ の SVD から直ちに得られる）。

定理 4.9 (Halko–Martinsson–Tropp [36])**.** $k \ge 2$、$p \ge 2$、$\boldsymbol{\Omega}$ を標準ガウス行列、$\boldsymbol{Q}$ を上のアルゴリズムの段階 2（$q=0$）で得た正規直交基底とすると

$$\mathbb{E}\|\boldsymbol{X} - \boldsymbol{Q}\boldsymbol{Q}^{\top}\boldsymbol{X}\|_{\mathrm{F}} \le \left(1 + \frac{k}{p-1}\right)^{1/2} \left(\sum_{i>k} \sigma_i^2\right)^{1/2}, \tag{4.4}$$

$$\mathbb{E}\|\boldsymbol{X} - \boldsymbol{Q}\boldsymbol{Q}^{\top}\boldsymbol{X}\|_{\mathrm{op}} \le \left(1 + \sqrt{\tfrac{k}{p-1}}\right)\sigma_{k+1} + \frac{\mathrm{e}\sqrt{k+p}}{p}\left(\sum_{i>k}\sigma_i^2\right)^{1/2} \tag{4.5}$$

が成り立つ（期待値は $\boldsymbol{\Omega}$ に関して取る）。

完全な証明は本書の範囲を超えるので与えず、要点と骨格だけ述べる。Eckart–Young の定理（第2章）より階数 k のどんな近似も $\|\boldsymbol{X} - \boldsymbol{X}_k\|_{\mathrm{F}} = (\sum_{i>k}\sigma_i^2)^{1/2}$ より良くはならないから、(4.4) が言うのはランダム化で得た射影がこの**理論的下限の $(1 + k/(p-1))^{1/2}$ 倍以内**に収まることである。$k=10, p=10$ なら係数は 1.45、$p=20$ なら 1.24 で、p を少し増やすだけで最適に近づく。骨格は $\boldsymbol{\Omega}_1 \coloneqq \boldsymbol{V}_k^{\top}\boldsymbol{\Omega}$、$\boldsymbol{\Omega}_2 \coloneqq \boldsymbol{V}_{\perp}^{\top}\boldsymbol{\Omega}$（$\boldsymbol{V}$ はサンプル側の右特異ベクトル、$n \times r$）と分割して残差が $\|\boldsymbol{\Sigma}_2\boldsymbol{\Omega}_2\boldsymbol{\Omega}_1^{+}\|$ で抑えられることを示し、ガウス行列の擬似逆のモーメント $\mathbb{E}\|\boldsymbol{\Omega}_1^{+}\|_{\mathrm{F}}^2 = k/(p-1)$ を使うというものである（$p \ge 2$ はこのモーメントの有限性のために必要）。

注意 4.10 (べき乗反復がなぜ効くか)**.** (4.5) は σ_{k+1} に比例する項を含むので、特異値の減衰が遅いときは精度が出ない。そこで $\boldsymbol{X}$ の代わりに $(\boldsymbol{X}\boldsymbol{X}^{\top})^q\boldsymbol{X}$（$\boldsymbol{X}\boldsymbol{X}^{\top}$ は $d\times d$ なので左から掛かる）を使う。この行列の特異値は σ_i^{2q+1} で、比 σ_{k+1}/σ_k が $(\sigma_{k+1}/\sigma_k)^{2q+1}$ に鋭くなる一方、特異ベクトルは変わらない。ただし素直に計算すると小さい特異値の情報が丸め誤差に埋もれるので、段階 3 のように**毎回 QR で再直交化する**のが実装上の要点である。

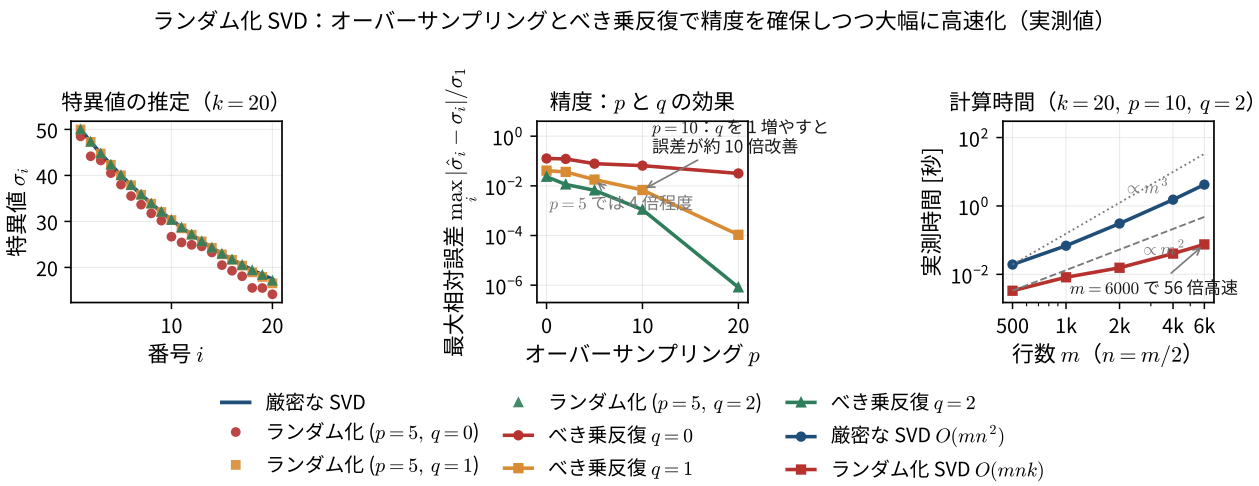


図4.2　ランダム化 SVD の精度と計算時間。オーバーサンプリング p を増やすと特異値の推定誤差が下がり、べき乗反復 q を 1 回増やすだけで誤差が桁で改善する。$k \ll \min(n,d)$ の領域では正確な SVD より 1〜2 桁速い。

以上の効果は実測で確かめられる。図 4.2はオーバーサンプリング p とべき乗反復 q を変えたときの特異値の推定誤差と、厳密な SVD に対する計算時間の比較である。q を 0 から 1 に増やすだけで誤差が約 10 倍改善し、$m=6000$（$n=3000$）では厳密な SVD の 55 倍の速さで上位 20 本が得られている。

リスト 4.2　ランダム化 SVD の実装と正確な SVD との比較

```python
def randomized_svd(X, k, p=10, q=2, seed=0):          # X is d x n
    rng = np.random.default_rng(seed)
    Om = rng.standard_normal((X.shape[1], k + p))     # step 1: Omega is n x (k+p)
    Q, _ = np.linalg.qr(X @ Om)                       # step 2: Y = X Om is d x (k+p)
    for _ in range(q):                                # step 3: re-orthonormalize!
        Q, _ = np.linalg.qr(X.T @ Q)
        Q, _ = np.linalg.qr(X @ Q)
    B = Q.T @ X                                       # step 4: (k+p) x n
    Ub, s, Vt = np.linalg.svd(B, full_matrices=False)
    return (Q @ Ub)[:, :k], s[:k], Vt[:k]             # step 5: U columns in R^d

rng = np.random.default_rng(0)
Un, _ = np.linalg.qr(rng.standard_normal((2000, 200)))   # d = 2000 (variable side)
Ud, _ = np.linalg.qr(rng.standard_normal((1500, 200)))   # n = 1500 (sample side)
A = ((Un * 100 * 0.8 ** np.arange(200)) @ Ud.T           # geometric decay
     + 1e-3 * rng.standard_normal((2000, 1500))).T       # A is 1500 x 2000 -> transpose
s_exact = np.linalg.svd(A, compute_uv=False)             # 0.402 s
for q in (0, 1, 2):
    _, s_r, _ = randomized_svd(A, 10, p=10, q=q)
    print(q, np.max(np.abs(s_r - s_exact[:10]) / s_exact[:10]))
    # q=0: 8.6e-03,  q=1: 1.2e-06,  q=2: 6.7e-11
```

べき乗反復 1 回あたり誤差が 3〜5 桁改善しており、計算時間は正確な SVD の 0.402 秒に対し $q=2$ で 0.012 秒であった。実務では `sklearn.utils.extmath.randomized_svd` や `PCA(svd_solver='randomized')` が同じアルゴリズムを提供する。

4.5　オンライン PCA と増分 PCA

これまでの手法は $\widetilde{\boldsymbol{X}}$ 全体をメモリに置けることを前提にしていた。データがストリームとして到着する、メモリに乗らない（$n=10^9$）、分布が変化していて最近のデータに重みを置きたい、といった状況ではその前提が崩れ、到着した分だけを見て推定を更新する形にしたい。やり方は**更新の単位**で二つに分かれる。

	オンライン PCA（4.5.1節）	**増分 PCA**（4.5.2節）
更新の単位	1 サンプル	ミニバッチ（b 点）
保持するもの	方向 $\boldsymbol{w} \in \mathbb{R}^d$ のみ	平均 $\bar{\boldsymbol{x}}$ と階数 k の要約 $\boldsymbol{U}_k\boldsymbol{\Sigma}_k$
更新の中身	勾配的な 1 行の代入	要約と新バッチを並べて SVD
1 ステップの計算	$O(d)$	$O((k+b)^2 d)$
メモリ	$O(d)$	$O((k+b)d)$
取れる主成分	原理的に 1 本（拡張で k 本）	最初から k 本
代表例	Oja の学習則	`IncrementalPCA`

一言でいえば、**オンライン PCA は「方向を少しずつ回す」**手法、**増分 PCA は「要約を作り直す」**手法である。前者は計算とメモリが最小だが 1 本ずつしか扱えず学習率の調整が要る。後者は 1 ステップが重いかわりに k 本を同時に、しかも調整すべき係数なしで扱える。実務で使われるのは後者が多い。

4.5.1　オンライン PCA：Oja の学習則

まず 1 サンプルずつ更新する方法を見る。第 1 主成分だけを考える。最大化したいのは $\boldsymbol{w}^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{w}$（$\|\boldsymbol{w}\| = 1$）だから制約なしの勾配上昇なら $\boldsymbol{w} \leftarrow \boldsymbol{w} + \eta \widehat{\boldsymbol{\Sigma}} \boldsymbol{w}$ だが、これでは $\|\boldsymbol{w}\|$ が発散する。毎回正規化する代わりに勾配から $\boldsymbol{w}$ 方向の成分を差し引くのが Oja の発想である。さらに $\widehat{\boldsymbol{\Sigma}}$ は全データを見ないと作れないので、$\mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top] = \boldsymbol{\Sigma}$ を使ってその場のサンプル 1 個 $\boldsymbol{x}\boldsymbol{x}^\top$ で置き換える。

定義 4.11 (Oja の学習則)**.** 中心化されたサンプル列 $\boldsymbol{x}_1, \boldsymbol{x}_2, \dots \in \mathbb{R}^d$（データ行列の列を順に取り出したもの）と学習率 $\eta_t > 0$ に対する更新

$$\boldsymbol{w}_t \leftarrow \boldsymbol{w}_{t-1} + \eta_t \big(\boldsymbol{x}_t \boldsymbol{x}_t^\top \boldsymbol{w}_{t-1} - (\boldsymbol{w}_{t-1}^\top \boldsymbol{x}_t \boldsymbol{x}_t^\top \boldsymbol{w}_{t-1}) \boldsymbol{w}_{t-1} \big) \tag{4.6}$$

を Oja の学習則（Oja's rule）という。

括弧の中は $\|\boldsymbol{w}\| = 1$ のとき $(\boldsymbol{I} - \boldsymbol{w}\boldsymbol{w}^\top)\boldsymbol{x}\boldsymbol{x}^\top \boldsymbol{w}$、すなわち勾配から $\boldsymbol{w}$ 方向の成分を除いたものである。更新の向きが $\boldsymbol{w}$ に直交するのでノルムは 1 次で保たれる。

命題 4.12 (単位ノルムの近似的保存)**.** $\|\boldsymbol{w}_{t-1}\| = 1$、$g \coloneqq \boldsymbol{x}_t^\top \boldsymbol{w}_{t-1}$ とすると $\|\boldsymbol{w}_t\|^2 = 1 + \eta_t^2 g^2 (\|\boldsymbol{x}_t\|^2 - g^2)$ である。とくに $\|\boldsymbol{w}_t\|^2 \geq 1$ で、超過は $O(\eta_t^2)$。

証明. $\boldsymbol{w} \coloneqq \boldsymbol{w}_{t-1}$, $\boldsymbol{x} \coloneqq \boldsymbol{x}_t$, $\eta \coloneqq \eta_t$ と略記する。$\boldsymbol{x}\boldsymbol{x}^\top \boldsymbol{w} = g\boldsymbol{x}$、$\boldsymbol{w}^\top \boldsymbol{x}\boldsymbol{x}^\top \boldsymbol{w} = g^2$ より $\boldsymbol{w}_t = (1 - \eta g^2)\boldsymbol{w} + \eta g \boldsymbol{x}$ であり、$\|\boldsymbol{w}\| = 1$、$\langle \boldsymbol{w}, \boldsymbol{x} \rangle = g$ を使うと

$$\|\boldsymbol{w}_t\|^2 = (1 - \eta g^2)^2 + 2\eta g^2 (1 - \eta g^2) + \eta^2 g^2 \|\boldsymbol{x}\|^2 = 1 + \eta^2 g^2 (\|\boldsymbol{x}\|^2 - g^2).$$

Cauchy–Schwarz より $g^2 \leq \|\boldsymbol{x}\|^2$ だから括弧の中は非負である。 ■

したがって $\|\boldsymbol{w}_{t-1}\| = 1$ を保ちたければ毎回明示的に正規化すればよく、その手間を惜しむ場合でも超過は $O(\eta_t^2)$ にとどまる。

この増分式は $\|w_{t-1}\| = 1$ のもとでのもの

命題 4.12は「単位ノルムから出発した 1 ステップ」の式であって、正規化を外した反復に繰り返し適用してはいけない。一般の $r \coloneqq \|\boldsymbol{w}\|$ では

$$\|\boldsymbol{w}^+\|^2 - \|\boldsymbol{w}\|^2 = \underbrace{2\eta g^2 (1 - r^2)}_{\text{一次項}} + \eta^2 g^2 \big(\|\boldsymbol{x}\|^2 - 2g^2 + g^2 r^2 \big) \tag{4.7}$$

であり（$\boldsymbol{w}^+ = \boldsymbol{w} + \eta g (\boldsymbol{x} - g\boldsymbol{w})$ を展開すればよい）、$r = 1$ の瞬間だけ本命題の式に戻る。
注目すべきは一次項で、$r > 1$ なら負、$r < 1$ なら正である。つまり Oja 則には $\|\boldsymbol{w}\|$ を 1 に引き戻す**復元力**が組み込まれている。実測（$d = 5$、定数学習率 $\eta = 0.01$、2×10^4 反復）でも、初期ノルムを 0.5, 1.0, 2.0, 5.0 のどれにしても 1.005 前後に収束する（$0.5 \to 0.724 \to 1.010$、$5.0 \to 1.179 \to 1.010$）。正規化を外しても発散しないので、明示的な正規化は数値的な安全策であり、収束のために不可欠なわけではない（演習 4.7）。

定理 4.13 (Oja 則の平均場としての解釈)**.** $\boldsymbol{x}_t$ が平均 $\boldsymbol{0}$、共分散 $\boldsymbol{\Sigma}$ の独立同分布なら $\mathbb{E}[\boldsymbol{w}_t \mid \boldsymbol{w}_{t-1} = \boldsymbol{w}] = \boldsymbol{w} + \eta_t(\boldsymbol{\Sigma}\boldsymbol{w} - (\boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w})\boldsymbol{w})$ である。すなわち Oja 則は常微分方程式

$$\dot{\boldsymbol{w}} = \boldsymbol{\Sigma}\boldsymbol{w} - (\boldsymbol{w}^\top \boldsymbol{\Sigma} \boldsymbol{w})\boldsymbol{w} \tag{4.8}$$

を確率近似（stochastic approximation）で解いている。(4.8) の単位球面上の平衡点は $\boldsymbol{\Sigma}$ の固有ベクトルであり、漸近安定なのは最大固有値に対応するもの（と符号違い）だけである。

証明. 期待値の式は $\mathbb{E}[\boldsymbol{x}_t\boldsymbol{x}_t^{\top}]=\boldsymbol{\Sigma}$ を代入するだけである。平衡点は $\boldsymbol{\Sigma}\boldsymbol{w}=(\boldsymbol{w}^{\top}\boldsymbol{\Sigma}\boldsymbol{w})\boldsymbol{w}$ を満たす単位ベクトル、すなわち固有ベクトルである。安定性を見る。$\boldsymbol{\Sigma}=\sum_i \lambda_i \boldsymbol{q}_i\boldsymbol{q}_i^{\top}$（$\lambda_1>\lambda_2\geq\cdots$）、$\boldsymbol{w}=\sum_i c_i\boldsymbol{q}_i$、$\rho\coloneqq\sum_i\lambda_i c_i^2$ とおくと (4.8) は成分ごとに $\dot{c}_i=(\lambda_i-\rho)c_i$ となる。比 $s_j\coloneqq c_j/c_1$ の発展は

$$\dot{s}_j=\frac{(\lambda_j-\rho)c_jc_1-c_j(\lambda_1-\rho)c_1}{c_1^2}=(\lambda_j-\lambda_1)s_j$$

であり ρ が消える。$\lambda_j<\lambda_1$ だから $s_j(t)=s_j(0)\mathrm{e}^{(\lambda_j-\lambda_1)t}\to 0$、$c_1(0)\neq 0$ である限り $\boldsymbol{w}\to\pm\boldsymbol{q}_1$（指数的）。逆に $\boldsymbol{w}=\boldsymbol{q}_j$（$j\neq 1$）の近傍では c_1/c_j が $\mathrm{e}^{(\lambda_1-\lambda_j)t}$ で増大するので不安定である。なお確率近似の理論（Robbins–Monro 条件 $\sum\eta_t=\infty$、$\sum\eta_t^2<\infty$ のもとでの ODE 法による概収束）を厳密に適用するにはモーメント条件と軌道の有界性が要り、その部分は省略する。 ■

例 4.14 (数値実験)**.** $d=10$、ランダムな共分散を持つガウス分布から 2×10^4 点を生成し、$\eta_t=1/(100+t)$（Robbins–Monro 条件を満たす）で 1 サンプルずつ (4.6) を回すと、真の第 1 固有ベクトルとの内積の絶対値は 0.99969 に達した。1 サンプルあたり $O(d)$ の計算とメモリしか使わず、データ行列を一度も保持していない。

4.5.2　増分 PCA：要約とバッチの SVD による融合

Oja 則は 1 本ずつしか扱えず学習率の設計も要る。実用上より使われるのは、ミニバッチごとに「これまでの要約」と「新しいバッチ」を SVD で融合する**増分 PCA**（incremental PCA）である。推定を平均 $\bar{\boldsymbol{x}}$ と階数 k の要約 $\boldsymbol{U}_k\boldsymbol{\Sigma}_k$（$d\times k$）で保持し、新バッチ $\boldsymbol{X}_{\mathrm{new}}\in\mathbb{R}^{d\times b}$ が来たら平均を更新して中心化し、$\boldsymbol{U}_k\boldsymbol{\Sigma}_k$・中心化した新バッチ・平均のずれの補正項を**横に**並べた $d\times(k+b+1)$ 行列の SVD の上位 k 本で $(\boldsymbol{U}_k,\boldsymbol{\Sigma}_k)$ を置き換える（1 ステップ $O((k+b)^2d)$、メモリ $O((k+b)d)$）。古い成分を階数 k に打ち切る分の誤差は σ_{k+1} 以下を捨てているだけなので、スペクトルが減衰していれば実害は小さい。`sklearn.decomposition.IncrementalPCA` が `partial_fit` でこれを提供する。分布が変化する場合は古い要約に忘却係数 $\gamma\in(0,1)$ を掛ければよい。

4.6　欠測値のある PCA

実データには欠測がある。最も安直な対処は欠測成分をその変数の平均で埋めることだが、これは分散共分散構造を系統的に歪める。

例 4.15 (平均補完のバイアス)**.** 相関 0.9 の 2 変量正規分布から $n=2000$ 点を生成し（$\boldsymbol{X}\in\mathbb{R}^{2\times2000}$）、第 2 変数すなわち第 2 **行**を無作為に（MCAR）50% 欠測させて観測値の平均で埋めた。標本相関は真の 0.897 から 0.639 に下がり、共分散行列の固有値は $(1.837, 0.099)$ から $(1.235, 0.223)$ に、第 1 主成分の寄与率は 94.9% から 84.7% に落ちた。

理由は明快である。平均で埋めた点は $x_2=\bar{x}_2$ の直線上に集まるので第 2 変数の分散が過小評価され、共分散も（埋めた分の寄与が 0 なので）過小評価される。欠測率が q なら分散も共分散も約 $(1-q)$ 倍に縮み、相関は $\rho\sqrt{1-q}$ となって相関構造が変わってしまう。正しい処方は「補完してから PCA」ではなく「補完と PCA を交互に行う」ことである。確率的 PCA（$\boldsymbol{x}=\boldsymbol{\mu}+\boldsymbol{W}\boldsymbol{z}+\boldsymbol{\varepsilon}$）の枠組みでは欠測が「観測されない確率変数」として自然に EM アルゴリズムに乗るが、実装は次の交互反復でよい。

観測成分の添字集合を Ω として、まず $(i,j)\notin\Omega$ に**行**平均（＝その変数の平均）を入れて初期化し、**M ステップ**で完成した $\widehat{\boldsymbol{X}}$ を中心化して階数 k の最良近似 $\widehat{\boldsymbol{X}}_k$ を SVD で求め、**E ステップ**で欠測成分だけを $\hat{X}_{ij}\leftarrow(\bar{\boldsymbol{x}}\mathbf{1}^{\top}+\widehat{\boldsymbol{X}}_k)_{ij}$ に置き換える（観測成分は動かさない）。これを収束するまで繰り返す。

目的関数の取り方に注意が必要である。代入する $\bar{\boldsymbol{x}}\mathbf{1}^{\top}+\widehat{\boldsymbol{X}}_k$ は平均のぶんを足しているので一般に**階数** $k+1$ であり（$k=2$、$d=6$ の実験で代入行列の階数は 3）、「階数 k 以下の行列 $\boldsymbol{M}$ への近似」という目的関数では上の反復を記述できない。平均項と低階数項を分けて書くのが正しい。

命題 4.16 (単調減少)**.** 目的関数を

$$J(\widehat{\boldsymbol{X}},\boldsymbol{b},\boldsymbol{L})\coloneqq\|\widehat{\boldsymbol{X}}-\mathbf{1}\boldsymbol{b}^{\top}-\boldsymbol{L}\|_{\mathrm{F}}^2,\qquad \operatorname{rank}\boldsymbol{L}\leq k,\quad \boldsymbol{L}\mathbf{1}=\mathbf{0} \tag{4.9}$$

（$\boldsymbol{b}\in\mathbb{R}^d$、$\boldsymbol{L}\in\mathbb{R}^{d\times n}$、$\widehat{\boldsymbol{X}}$ は Ω 上で観測値に一致）とすると、本節の反復は J の交互最小化であり、J は各ステップで非増加である。

証明. **M ステップ**（$\widehat{\boldsymbol{X}}$ を固定して $(\boldsymbol{,L})$ を最小化）：制約 $\boldsymbol{L}\mathbf{1}=\mathbf{0}$ のもとで各行の和を見ると、 の最適値は $\widehat{\boldsymbol{X}}$ の行平均 $\bar{\boldsymbol{x}}$ である。実際 $J=\|(\widehat{\boldsymbol{X}}-\bar{\boldsymbol{x}}\mathbf{1}^\top)-\boldsymbol{L}-(-\bar{\boldsymbol{x}})\mathbf{1}^\top\|_{\mathrm{F}}^2$ を展開すると、$\widehat{\boldsymbol{X}}-\bar{\boldsymbol{x}}\mathbf{1}^\top$ と $\boldsymbol{L}$ はどちらも行和 0 なので $(-\bar{\boldsymbol{x}})\mathbf{1}^\top$ との Frobenius 内積が消え、$J=\|\widetilde{\boldsymbol{X}}-\boldsymbol{L}\|_{\mathrm{F}}^2+n\|-\bar{\boldsymbol{x}}\|^2$（$\widetilde{\boldsymbol{X}}:=\widehat{\boldsymbol{X}}\boldsymbol{H}$）と分離する。第 2 項は $=\bar{\boldsymbol{x}}$ で最小、第 1 項は Eckart–Young より $\widetilde{\boldsymbol{X}}$ の階数 k 打ち切り SVD $\widehat{\boldsymbol{X}}_k$ で最小になる。これは制約 $\boldsymbol{L}\mathbf{1}=\mathbf{0}$ を自動的に満たす（$\widetilde{\boldsymbol{X}}\mathbf{1}=\mathbf{0}$ なのでその特異ベクトルから作る $\widehat{\boldsymbol{X}}_k$ も行和 0）。

E ステップ（$(\boldsymbol{,L})$ を固定して $\widehat{\boldsymbol{X}}$ の欠測成分を最小化）：$J=\sum_{(i,j)\in\Omega}(X_{ij}-m_i-L_{ij})^2+\sum_{(i,j)\notin\Omega}(\hat{X}_{ij}-m_i-L_{ij})^2$ において第 1 項は $\widehat{\boldsymbol{X}}$ の欠測成分に依らず、第 2 項は成分ごとに独立なので $\hat{X}_{ij}=m_i+L_{ij}=(\bar{\boldsymbol{x}}\mathbf{1}^\top+\widehat{\boldsymbol{X}}_k)_{ij}$ で 0 になる。これが本節の代入規則である。よって J は交互最小化で非増加であり、$J\ge 0$ と合わせて値は収束する。 ■

収束するのは目的関数の値であって、大域最適ではない

交互最小化が保証するのは J の単調減少と収束だけで、到達点が大域最小とは限らない（初期値依存）。また J の値が収束しても $(\boldsymbol{,L})$ が収束するとは限らない。実装では J の相対変化が閾値を切ったら止め、初期値を変えて数回走らせるのが実務的である。上の $d=6$、$n=200$、$k=2$、欠測率 25 % の例では $J=311.0\to 141.7\to 86.2\to\cdots\to 48.5$（15 反復）と単調に減った。

ただしこれは値の収束を言うだけで、欠測のある低ランク近似は非凸問題であり初期値によって異なる局所解に落ちうる。欠測率が高いときはとくに注意がいる。別の方法として $\widehat{\boldsymbol{X}}\approx\boldsymbol{A}\boldsymbol{B}^\top$（$\boldsymbol{A}\in\mathbb{R}^{d\times k}$ が変数側、$\boldsymbol{B}\in\mathbb{R}^{n\times k}$ がサンプル側）と二つの因子に分解し、観測成分だけの二乗誤差

$$\min_{\boldsymbol{A},\boldsymbol{B}}\ \sum_{(i,j)\in\Omega}\bigl(X_{ij}-\boldsymbol{a}_i^\top\boldsymbol{b}_j\bigr)^2+\mu\bigl(\|\boldsymbol{A}\|_{\mathrm{F}}^2+\|\boldsymbol{B}\|_{\mathrm{F}}^2\bigr)\tag{4.10}$$

を最小化する交互最小二乗（alternating least squares, ALS）がある。$\boldsymbol{A}$ を固定すれば (4.10) は $\boldsymbol{B}$ の各行について独立なリッジ回帰で閉じた形に解け、逆も同様である。行ごとに並列化できるので巨大な推薦システムの行列分解はこの方式で計算されている。Ω の上でしか誤差を測らないのが単純な補完との決定的な違いで、欠測成分は「予測すべき値」であって「埋めるべき値」ではない。この考え方は $\min\operatorname{rank}(\boldsymbol{M})$ s.t. $M_{ij}=X_{ij}$ on Ω という行列補完（matrix completion）に至り、その凸緩和が第11章の核ノルム最小化である。

4.7　ロバスト PCA：外れ値への対処

PCA は二乗誤差を最小化する手法である。二乗は大きな残差を強く罰するので、遠く離れた 1 点が解を支配してしまう。

例 4.17 (外れ値 1 点の影響)**.** 共分散 $\operatorname{diag}(4,0.25)$ の 2 次元正規分布から $n=200$ 点を生成する（$\boldsymbol{X}=\operatorname{diag}(2,0.5)\cdot$ `standard_normal`$((2,n))$）。第 1 主成分方向は x_1 軸からほとんどずれない（seed 0 で 1.07°、50 シードの中央値 0.77°）。ところが 1 点 $(0,30)$ を加えると 86.31°（同中央値 86.25°）、すなわち**ほぼ x_2 軸方向**に変わる。0.5 % の汚染で主成分が 85° 回転している。

理由は簡単な計算でわかる。外れ値 $\boldsymbol{x}_0$ の共分散への寄与は $\frac{1}{n}\boldsymbol{x}_0\boldsymbol{x}_0^\top$、すなわち $\|\boldsymbol{x}_0\|^2$ に比例するので、$\|\boldsymbol{x}_0\|=30$、他の点が $\|\boldsymbol{x}\|\approx 2$ なら 1 点で $(30/2)^2=225$ 点分の重みを持つ。統計学の言葉では標本共分散の **破綻点（breakdown point）は** 0 であり、汚染の割合をどれだけ小さくしても、外れ値を十分遠くに置けば推定量を任意に狂わせられる。

図 4.3 がこの現象と改善を示している。対処は大別して三つある。

(a) ロバストな共分散推定. 代表格は最小共分散行列式（minimum covariance determinant, MCD）推定量で、n 点から $h\approx n/2$ 点を選び、その部分集合の標本共分散の行列式が最小になるものを採る。行列式は散らばりの体積を測るので最も密に固まった半数を選ぶことに相当し、外れ値は自動的に除かれる。破綻点は $(n-h+1)/n$ で、$h=\lceil(n+d+1)/2\rceil$ なら約 50% に達する。組合せ探索が必要だが FAST-MCD という近似がある。より軽量には、ロバスト距離 δ_i による重み $w_i=\min\{1,(c/\delta_i)^2\}$ で $\widehat{\boldsymbol{\Sigma}}_w=\sum_i w_i\tilde{\boldsymbol{x}}_i\tilde{\boldsymbol{x}}_i^\top/\sum_i w_i$ を反復更新する M 推定もある（演習 4.8 (4)）。

(b) L_1 ノルム PCA. 分散最大化の代わりに射影の L_1 ノルム $\max_{\|\boldsymbol{w}\|_2=1}\sum_i|\langle\tilde{\boldsymbol{x}}_i,\boldsymbol{w}\rangle|$ を最大化する。二乗が 1 乗になるので大きな残差の影響が線形にしか効かない。凸関数の最大化なので大域最適解を得るのは難しい（NP 困難であることが知られている）が、反復再重み付けや貪欲法による近似解法がある。

(c) 主成分追跡. Candès らは外れ値を「疎な誤差行列」としてモデル化した。$\boldsymbol{X}=\boldsymbol{L}_0+\boldsymbol{S}_0$（いずれも $d\times n$。$\boldsymbol{L}_0$ が低ランク、$\boldsymbol{S}_0$ が疎）と分解して両者を分離したい。素直な定式化 $\min\operatorname{rank}(\boldsymbol{L})+\lambda\|\boldsymbol{S}\|_0$ は非凸なので、それぞれを凸緩和する。

定義 4.18 (核ノルム)**.** $\boldsymbol{M}$ の特異値を $\sigma_1,\dots,\sigma_r$ とするとき $\|\boldsymbol{M}\|_*:=\sum_i\sigma_i$ を核ノルム（nuclear norm）という。

命題 4.19 (核ノルムは階数の凸緩和)**.** $\|\boldsymbol{M}\|_{\mathrm{op}}\le 1$ なる行列の集合上で $\|\cdot\|_*$ は $\operatorname{rank}(\cdot)$ の凸包絡である。

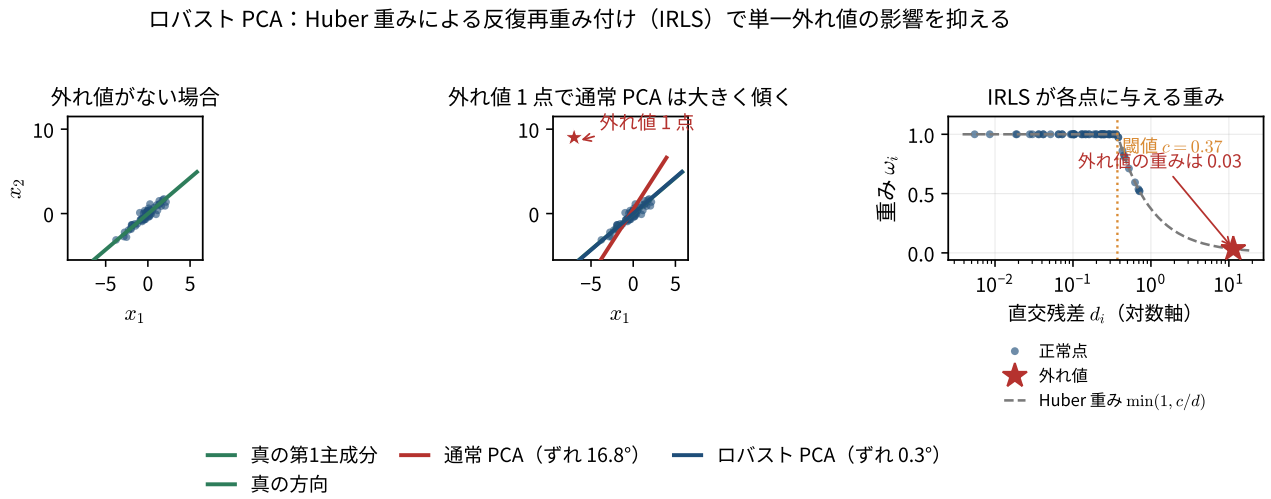


図4.3　外れ値が 1 点混入したときの通常の PCA の主成分方向の崩れ。多数派の構造を無視して主成分が外れ値のほうを向くのに対し、ロバスト化した推定は多数派の方向を保つ。

証明の概略. $\|\boldsymbol{M}\|_{\mathrm{op}} \le 1$ ならすべての $\sigma_i \le 1$ だから $\|\boldsymbol{M}\|_* \le \#\{i:\sigma_i>0\} = \mathrm{rank}(\boldsymbol{M})$、すなわち下界である。凸性は $\|\boldsymbol{M}\|_* = \max\{\mathrm{tr}(\boldsymbol{M}^\top \boldsymbol{Z}) : \|\boldsymbol{Z}\|_{\mathrm{op}} \le 1\}$ という線形関数族の上限として書けることから従う（上限は凸性を保つ）。これが**最大の**凸下界であることは双共役 rank^{**} を計算して一致を示せばよいが、その部分は省く。スカラーで $|x|$ が $\mathbf{1}\{x \ne 0\}$ の $[-1,1]$ 上の凸包絡である、という事実の行列版と理解しておけばよい。 ■

同様に $\|\boldsymbol{S}\|_0$ を $\|\boldsymbol{S}\|_1 = \sum_{ij}|S_{ij}|$ で緩和して

$$\min_{\boldsymbol{L},\boldsymbol{S}} \|\boldsymbol{L}\|_* + \lambda\|\boldsymbol{S}\|_1 \quad \text{s.t.} \quad \boldsymbol{X} = \boldsymbol{L} + \boldsymbol{S} \tag{4.11}$$

を得る。これが主成分追跡（principal component pursuit, PCP）で、凸問題だから大域解が得られる。驚くべきことにこの緩和は緩すぎない。Candès–Li–Ma–Wright [21] は、$\boldsymbol{L}_0$ の特異ベクトルが座標軸に整列していないという非整合性（incoherence）条件と $\boldsymbol{S}_0$ の台が一様ランダムで十分疎であることのもとで、$\lambda = 1/\sqrt{\max(n,d)}$ という**データに依存しない**選択で高い確率で解が $(\boldsymbol{L}_0, \boldsymbol{S}_0)$ に厳密一致することを示した。低ランク成分と疎成分は、両方が構造を持ってさえいれば分離できるのである。

注意 4.20. 典型的な応用は監視カメラ映像の背景・前景分離である。各フレームをベクトル化して**列**として並べると、静止背景は全フレームでほぼ同じだから低ランク、動く人物は一部の画素にしか現れないから疎になる。(4.11) は第11章の行列補完と核ノルムの技法を共有し、どちらも近接勾配法や ADMM で解かれる。第1章の枠組みで見れば $\|\boldsymbol{L}\|_*$ は低ランク性を促す正則化項 Ω にほかならない。

4.8　スパース PCA：解釈できる主成分

$d = 20000$ 個の遺伝子に PCA をかけると第 1 主成分の負荷量 $\boldsymbol{u}_1 \in \mathbb{R}^d$ は 20000 個すべてが非零になり、「第 1 主成分は何を表すのか」を説明しようにも 20000 個の係数は眺められない。解釈のためには負荷量の**ほとんどが** 0 で、「この主成分は遺伝子 A、B、C の組合せである」と言えてほしい。これがスパース PCA（sparse PCA）の動機で、図 4.4 が両者の違いを示す。

回帰の LASSO と同じ発想で L_1 罰則を加える。ここで $\|\boldsymbol{w}\|_1 := \sum_j |w_j|$ は L_1 **ノルム**で、命題 2.5(i)–(iii) をみたす（内積から来ないノルムの代表例である）。以下、区別が要るときはユークリッドノルムを $\|\cdot\|_2$ と書く。

$$\max_{\boldsymbol{w}} \ \boldsymbol{w}^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{w} - \lambda\|\boldsymbol{w}\|_1 \quad \text{s.t.} \quad \|\boldsymbol{w}\|_2 = 1. \tag{4.12}$$

L_1 ノルムは原点で微分不可能な角を持ち、その角が座標軸上にあるため最適解が軸上（＝一部の成分が厳密に 0）に落ちやすい。L_2 罰則では成分は小さくなるが 0 にはならない。Jolliffe–Trendafilov–Uddin の SCoTLASS は罰則でなく制約の形で $\max \boldsymbol{w}^\top\widehat{\boldsymbol{\Sigma}}\boldsymbol{w}$ s.t. $\|\boldsymbol{w}\|_2 = 1,\ \|\boldsymbol{w}\|_1 \le c$ と書き、両者は Lagrange 双対性により（λ と c の適切な対応のもとで）ほぼ等価である。$c = 1$ なら解は単一の座標軸、$c = \sqrt{d}$ なら制約が効かず通常の PCA に戻る。

例 4.21 (2×2 でのスパース化). $\widehat{\boldsymbol{\Sigma}} = \begin{pmatrix} 1 & 0.6 \\ 0.6 & 0.8 \end{pmatrix}$ とし、$\boldsymbol{w} = (\cos\theta, \sin\theta)^\top$ とパラメータ化して (4.12) を数値的に最大化すると

λ	0	0.3	0.8	1.2	1.30
θ^*（度）	40.27	39.27	36.16	28.86	0.00

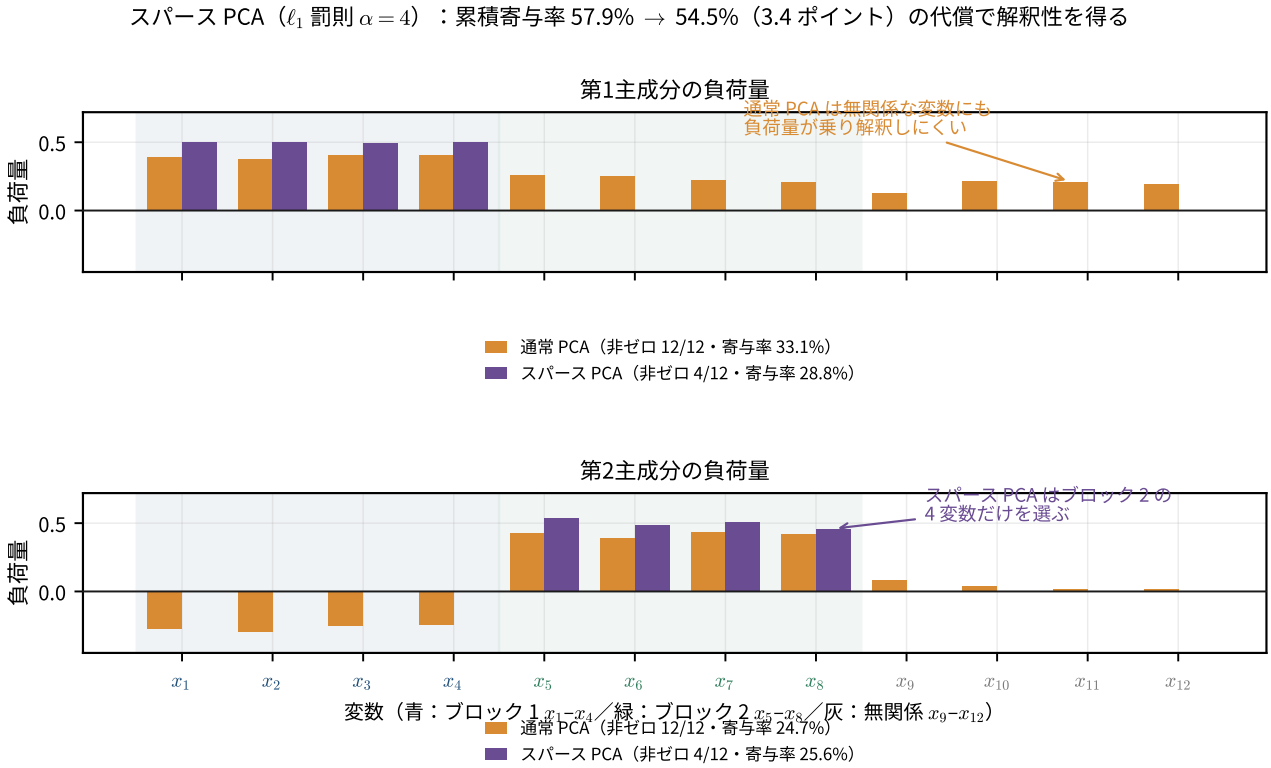


図4.4　通常の PCA とスパース PCA の負荷量の比較。通常の PCA では全変数に小さな係数が散らばるのに対し、スパース PCA では少数の変数だけが大きな係数を持ち、主成分の意味を言葉で説明できるようになる。

となる。λ を上げると解は第 1 座標軸に引き寄せられ、$\lambda \approx 1.29$ を境に第 2 成分が厳密に 0 になる。罰則が徐々に効くのではなく、ある閾値で**一気に**スパースになるのが L_1 の特徴である。

(4.12) は非凸で扱いにくい。Zou–Hastie–Tibshirani [87] は PCA が回帰として書けることを利用した。

命題 4.22 (PCA の自己回帰表現)**.** $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{d \times k}$ に対し

$$\min_{\boldsymbol{A},\boldsymbol{B}} \|\widetilde{\boldsymbol{X}} - \boldsymbol{A}\boldsymbol{B}^{\top}\widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^{2} \quad \text{s.t.} \quad \boldsymbol{A}^{\top}\boldsymbol{A} = \boldsymbol{I}_k \tag{4.13}$$

の最適解は $\boldsymbol{A} = \boldsymbol{B} = \boldsymbol{U}_k$、すなわち上位 k 個の主成分方向である。

$\widetilde{\boldsymbol{X}}$ が $d \times n$ なので、$\boldsymbol{B}^{\top}\widetilde{\boldsymbol{X}}$（$k \times n$）がスコアの役を務め、それに $\boldsymbol{A}$（$d \times k$）を左から掛けて $\mathbb{R}^d$ に戻す形になる。次元は $(d \times k)(k \times d)(d \times n) = (d \times n)$ で合う。

証明. $\widehat{\boldsymbol{\Sigma}}' := n\widehat{\boldsymbol{\Sigma}} = \widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$（$d \times d$）とおく。$\boldsymbol{B}$ を固定して $\boldsymbol{A}$ について最小化する。目的関数は $\|\widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^2 - 2\,\mathrm{tr}(\boldsymbol{A}\boldsymbol{B}^{\top}\widehat{\boldsymbol{\Sigma}}') + \mathrm{tr}(\boldsymbol{A}\boldsymbol{B}^{\top}\widehat{\boldsymbol{\Sigma}}'\boldsymbol{B}\boldsymbol{A}^{\top})$ で、$\boldsymbol{A}^{\top}\boldsymbol{A} = \boldsymbol{I}_k$ より第 3 項は $\mathrm{tr}(\boldsymbol{B}^{\top}\widehat{\boldsymbol{\Sigma}}'\boldsymbol{B})$ となり $\boldsymbol{A}$ に依らない。よって $\mathrm{tr}(\boldsymbol{A}\boldsymbol{M})$（$\boldsymbol{M} := \boldsymbol{B}^{\top}\widehat{\boldsymbol{\Sigma}}'$）の最大化、すなわち直交 Procrustes 問題で、$\boldsymbol{M}^{\top} = \boldsymbol{U}_M\boldsymbol{\Sigma}_M\boldsymbol{V}_M^{\top}$ を SVD として $\boldsymbol{A} = \boldsymbol{U}_M\boldsymbol{V}_M^{\top}$ が最適である。次に $\boldsymbol{A}$ を固定すると最適な $\boldsymbol{B}$ は $\widehat{\boldsymbol{\Sigma}}'\boldsymbol{B} = \widehat{\boldsymbol{\Sigma}}'\boldsymbol{A}$ の解、$\widehat{\boldsymbol{\Sigma}}'$ が正則なら $\boldsymbol{B} = \boldsymbol{A}$。代入すると (4.13) は $\|\widetilde{\boldsymbol{X}} - \boldsymbol{A}\boldsymbol{A}^{\top}\widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^2$、すなわち $\widetilde{\boldsymbol{X}}$ の**列**を $\mathrm{span}\,\boldsymbol{A}$ に射影した残差になり、第3章のとおりその最小化は上位 k 主成分部分空間を与える（$\widehat{\boldsymbol{\Sigma}}'$ が特異でも $\boldsymbol{B} = \boldsymbol{A}$ は解の一つで最適値は同じ）。 ■

回帰の形になれば罰則を足すのは自然で、

$$\min_{\boldsymbol{A},\boldsymbol{B}} \|\widetilde{\boldsymbol{X}} - \boldsymbol{A}\boldsymbol{B}^{\top}\widetilde{\boldsymbol{X}}\|_{\mathrm{F}}^{2} + \mu\sum_{j}\|\boldsymbol{b}_j\|_2^2 + \sum_{j}\lambda_j\|\boldsymbol{b}_j\|_1 \quad \text{s.t.} \quad \boldsymbol{A}^{\top}\boldsymbol{A} = \boldsymbol{I}_k \tag{4.14}$$

を得る。$\boldsymbol{A}$ を固定すれば $\boldsymbol{B}$ の各列は elastic net 回帰、$\boldsymbol{B}$ を固定すれば $\boldsymbol{A}$ は Procrustes 問題（SVD で解ける）なので交互最適化で計算でき、$\boldsymbol{b}_j$ を正規化したものがスパースな負荷量になる。これが `sklearn.decomposition.SparsePCA` の方式である。

スパース PCA で失われる性質

(1) **直交性**。通常の PCA の負荷量は互いに直交するが、スパース PCA の解は一般に直交せず、異なる成分が同じ変数を共有しうる。

(2) **無相関性**。主成分スコアどうしが無相関でなくなるので「寄与率の和 = 説明された分散の割合」が成り立たず、寄与率の定義を修正（調整寄与率）する必要がある。
(3) **分散**。制約が増えるので $\boldsymbol{w}^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{w}$ は必ず通常の PCA 以下になる。
(4) **最適性**。(4.12) も (4.14) も非凸で、得られるのは局所解である。

「説明力」と「解釈可能性」のトレードオフを λ 一つで調整していることになる。

4.9　数値計算上の落とし穴

理論どおり実装したつもりでも、有限精度の計算機では思わぬことが起こる。遭遇頻度の高い四つを挙げる。

落とし穴 1：$\widehat{\Sigma}$ を作ると有効桁数が半分になる

$\widetilde{\boldsymbol{X}}$ の特異値が σ_i なら $\widehat{\boldsymbol{\Sigma}}$ の固有値は σ_i^2/n だから $\kappa(\widehat{\boldsymbol{\Sigma}}) = \kappa(\widetilde{\boldsymbol{X}})^2$ である。倍精度の相対精度は $\varepsilon_{\mathrm{mach}} \approx 2.2 \times 10^{-16}$ なので、$\kappa(\widetilde{\boldsymbol{X}}) > 10^8$ になると $\widehat{\boldsymbol{\Sigma}}$ 経由では小さい固有値が失われる。

例 4.23 (条件数の 2 乗を測る)**.** 特異値が $\{1, s\}$ の 2×50 行列（$d = 2$, $n = 50$）で、小さいほうの特異値を (i) 直接 SVD で、(ii) $\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top$ の固有値の平方根として求めた相対誤差は次のとおり。

s	10^{-4}	10^{-6}	10^{-8}	10^{-9}	10^{-10}
SVD 経由	2.5×10^{-13}	6.4×10^{-12}	2.9×10^{-10}	1.2×10^{-8}	1.6×10^{-7}
$\widehat{\boldsymbol{\Sigma}}$ 経由	2.6×10^{-10}	9.8×10^{-6}	1.4×10^{-2}	6.5	1.0 (完全に0)

$\kappa(\widetilde{\boldsymbol{X}}) = 10^9$ の時点で $\widehat{\boldsymbol{\Sigma}}$ 経由の答えは意味を失っているが、SVD 経由なら相対誤差は 10^{-8} 台である。

上位数本だけが目的なら実害はないことも多いが、「寄与率が小さい方向」や「ほぼ零空間」を調べたいときには致命的である。迷ったら SVD が安全である。

落とし穴 2：固有値が近いと固有ベクトルは不安定

λ_i と λ_{i+1} が近いとき、第 i 主成分「方向」はわずかな摂動で大きく回転する。しかし両者をまとめた 2 次元**固有空間**は安定である。個々のベクトルを解釈してはいけない。

例 4.24 (縮退の実演)**.** $\boldsymbol{A} = \mathrm{diag}(1.001, 0.999, 0.1)$ の最大固有ベクトルは $\boldsymbol{e}_1$ だが、$E_{12} = E_{21} = 10^{-3}$ の摂動を加えると $(-0.924, -0.383, 0)^\top$、すなわち 22.5° 回転する。摂動は 10^{-3} にすぎないのに、である。一方、上位 2 次元固有空間への射影行列の変化は 2.3×10^{-16}、つまり機械精度の範囲で不変であった。

この現象は定量的に記述できる。

定理 4.25 (Davis–Kahan の $\sin\Theta$ 定理（簡易版） [28])**.** $\boldsymbol{A}, \widehat{\boldsymbol{A}}$ を対称行列、$\boldsymbol{A}$ の固有値を $\lambda_1 \geq \cdots \geq \lambda_d$ とする。上位 k 個の固有ベクトルが張る部分空間を $\mathcal{V}$、$\widehat{\boldsymbol{A}}$ の対応する部分空間を $\widehat{\mathcal{V}}$、両者の主角（principal angles）を Θ、ギャップを $\delta := \lambda_k - \lambda_{k+1} > 0$ とすると、$\|\widehat{\boldsymbol{A}} - \boldsymbol{A}\|_{\mathrm{op}} \leq \delta/2$ のもとで

$$\|\sin\Theta\|_{\mathrm{F}} \leq \frac{2\|\boldsymbol{A} - \widehat{\boldsymbol{A}}\|_{\mathrm{F}}}{\delta} \tag{4.15}$$

が成り立つ。ここで $\|\sin\Theta\|_{\mathrm{F}} = \|\boldsymbol{P}_{\mathcal{V}} - \boldsymbol{P}_{\widehat{\mathcal{V}}}\|_{\mathrm{F}}/\sqrt{2}$ である。

証明の骨子．$\boldsymbol{E} := \widehat{\boldsymbol{A}} - \boldsymbol{A}$ とおき、$\boldsymbol{V}$ を $\mathcal{V}$ の正規直交基底、$\widehat{\boldsymbol{V}}_\perp$ を $\widehat{\mathcal{V}}^\perp$ のそれとすると $\|\sin\Theta\|_{\mathrm{F}} = \|\widehat{\boldsymbol{V}}_\perp^\top \boldsymbol{V}\|_{\mathrm{F}}$ である。$\boldsymbol{A}\boldsymbol{V} = \boldsymbol{V}\boldsymbol{\Lambda}_1$、$\widehat{\boldsymbol{A}}\widehat{\boldsymbol{V}}_\perp = \widehat{\boldsymbol{V}}_\perp\widehat{\boldsymbol{\Lambda}}_2$ から $\boldsymbol{S}\boldsymbol{\Lambda}_1 - \widehat{\boldsymbol{\Lambda}}_2\boldsymbol{S} = -\widehat{\boldsymbol{V}}_\perp^\top \boldsymbol{E}\boldsymbol{V}$（$\boldsymbol{S} := \widehat{\boldsymbol{V}}_\perp^\top \boldsymbol{V}$）という Sylvester 方程式を得る。$\boldsymbol{\Lambda}_1$ と $\widehat{\boldsymbol{\Lambda}}_2$ の固有値が δ' 以上離れていれば固有基底で成分ごとに $|S_{ij}| \leq |(\widehat{\boldsymbol{V}}_\perp^\top \boldsymbol{E}\boldsymbol{V})_{ij}|/\delta'$、すなわち $\|\boldsymbol{S}\|_{\mathrm{F}} \leq \|\boldsymbol{E}\|_{\mathrm{F}}/\delta'$ となる。Weyl の不等式 $|\hat{\lambda}_j - \lambda_j| \leq \|\boldsymbol{E}\|_{\mathrm{op}}$ より $\delta' \geq \delta - \|\boldsymbol{E}\|_{\mathrm{op}} \geq \delta/2$ が保証され (4.15) が従う。分離条件を仮定せず定数 2 で押し切る Yu–Wang–Samworth 版 [85] もあるが、精密化は省略する。 ■

例 4.24 に当てはめる。$k = 1$ なら $\delta = 0.002$、$\|\boldsymbol{E}\|_{\mathrm{F}} = \sqrt{2} \times 10^{-3}$ で右辺は 1.41、$\sin\Theta \leq 1$ は自明で何も言えない（実際に大きく回った）。$k = 2$ なら $\delta = 0.899$ で右辺は 0.0031 となり、部分空間の安定性が正しく予言される。**ギャップが分母に来ている**のが本質である。これは第5章への伏線でもある。高次元では $\widehat{\boldsymbol{\Sigma}}$ が真の $\boldsymbol{\Sigma}$ から $O(\sqrt{d/n})$ ずれるので、固有ベクトルの近似精度は「$\sqrt{d/n}$ とギャップ δ の競争」で決まり、これが BBP 相転移の背後にある構造である。

落とし穴 3：主成分の符号は決まらない

$\boldsymbol{u}$ が固有ベクトルなら $-\boldsymbol{u}$ もそうである。どちらが返るかは LAPACK の内部処理や BLAS の並列スケジューリングに依存し、同じデータ・同じコードでも実行のたびに変わりうる。散布図が上下反転して「結果が再現しない」と慌てる前にこれを疑うこと。

再現性のためには符号を固定する慣習を決めておく。よく使われるのは最大絶対値成分を正にする方式（$j^{*}=\arg\max_j |v_j|$ として $v_{j^{*}}>0$; `svd_flip` の方式）と成分の総和を正にする方式で、後者は総和が 0 に近いと不安定なので前者が安全である。実装やデータセットを比較するときは リスト 4.1 の `align_sign` のように参照側との内積の符号で揃える。縮退があるときは固有空間内の回転の任意性も残るので、本来の比較は部分空間どうし（射影行列の差や主角）で行うべきである。

落とし穴 4：`float32` の限界

単精度の相対精度は $\varepsilon_{\mathrm{mach}}\approx 1.2\times 10^{-7}$ で、$\widehat{\boldsymbol{\Sigma}}$ を作る戦略と組み合わせると $\kappa(\widetilde{\boldsymbol{X}})>3000$ 程度で小さい固有値が壊れる。巨大データでメモリ節約のため `float32` を使うのは合理的だが、**共分散の蓄積だけは `float64` で行う**のが定石である。

具体的には $\widetilde{\boldsymbol{X}}$ を `float32` で保持しつつ積の計算だけ倍精度で行う。n が大きいときは総和の累積誤差も無視できず、Kahan の補正総和や pairwise summation が有効である（NumPy の `sum` は既に後者）。さらに $\widehat{\boldsymbol{\Sigma}}=\frac{1}{n}\boldsymbol{X}\boldsymbol{X}^{\top}-\bar{\boldsymbol{x}}\bar{\boldsymbol{x}}^{\top}$ という展開公式は 1 パスで済んで魅力的だが、$\|\bar{\boldsymbol{x}}\|$ が散らばりに比べて大きいとき（値が 10^{6} 前後で標準偏差が 1 など）桁落ちで有効数字がほとんど失われる。必ず**先に中心化してから**積を取ること。

実務のための処方箋

$d\lesssim 10^{3}$ なら $\widehat{\boldsymbol{\Sigma}}$ を作って対称固有値分解、$n\ll d$ なら双対 PCA（定理 4.3）、$k\ll\min(n,d)$ かつ巨大ならランダム化 SVD（$q=1$ か 2）、疎行列や行列ベクトル積しか使えない場合は反復法（`svds` / `eigsh`）、メモリに乗らないかストリームなら `IncrementalPCA` か Oja 則、精度が要って小さい固有値も見たいなら $\widehat{\boldsymbol{\Sigma}}$ を作らず SVD。そして常に、中心化は先に、符号は固定、蓄積は `float64` で。

本章の計算技法は結局「$\widetilde{\boldsymbol{X}}$ の上位特異部分空間をどう捉えるか」という一つの問題であり、n と d のどちらが小さいかで作業する空間を選び（双対性）、必要な本数が少なければ全体を分解せず（反復法・ランダム化）、一度に見られなければ逐次更新する（オンライン）。拡張の三つも、二乗誤差最小化に制約や罰則を足したものであり、第1章の正則化つき経験リスク最小化の枠組みで Ω を核ノルムや L_1 ノルムに取り替えたものにすぎない。そして双対 PCA は、内積だけで書けるという構造を通じて 第8章のカーネル PCA へつながっている。

演習問題

演習 4.1 (双対 PCA の正当性 ($\star$))**.** $\widetilde{\boldsymbol{X}}\in\mathbb{R}^{d\times n}$ を中心化データ行列、$n<d$ とする。$\boldsymbol{G}=\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}\in\mathbb{R}^{n\times n}$ の固有値 $\mu>0$ と単位固有ベクトル $\boldsymbol{v}\in\mathbb{R}^{n}$ に対し $\boldsymbol{u}:=\widetilde{\boldsymbol{X}}\boldsymbol{v}/\sqrt{\mu}$ とおく（$\boldsymbol{u}\in\mathbb{R}^{d}$ であることを次元を数えて確かめよ）。(1) $\|\boldsymbol{u}\|=1$ を示せ。(2) $\widehat{\boldsymbol{\Sigma}}\boldsymbol{u}=(\mu/n)\boldsymbol{u}$ を示せ。(3) $\boldsymbol{G}$ の固有値 0 の固有ベクトル $\boldsymbol{v}_0$ について $\widetilde{\boldsymbol{X}}\boldsymbol{v}_0=\boldsymbol{0}$ を示し、この方法で $\widehat{\boldsymbol{\Sigma}}$ の非零固有値がすべて得られる理由を説明せよ。(4) $\operatorname{rank}(\widehat{\boldsymbol{\Sigma}})\le\min(n-1,d)$ を示せ。

演習 4.2 (べき乗法の収束速度 ($\star\star$))**.** 対称行列 $\boldsymbol{A}$ の固有値を $\lambda_1>\lambda_2\ge\cdots\ge\lambda_d\ge 0$ とする。(1) $\lambda_1=10$, $\lambda_2=9$ のとき $\sin\theta_t\le 10^{-6}$ を保証する反復回数を (4.3) から見積もれ（$\tan\theta_0=1$ とせよ）。(2) シフト $\boldsymbol{A}-c\boldsymbol{I}$ では収束比が $|(\lambda_2-c)/(\lambda_1-c)|$ になる。$\lambda_d=0$ が既知のとき c をどう選ぶべきか。(1) の設定で $c=4.5$ としたときの反復回数を求め比較せよ。(3) $\boldsymbol{A}$ の**最小**固有値を求める方法を二つ述べよ。

演習 4.3 (ランダム化 SVD の誤差界 ($\star\star$))**.** (1) $k=20$ のとき係数 $(1+k/(p-1))^{1/2}$ を 1.1 以下にする p の範囲を求めよ。(2) $\sigma_i=\sigma_1\rho^{i-1}$ のとき $(\sum_{i>k}\sigma_i^{2})^{1/2}$ を閉じた形で求め、$\rho=0.8, k=10, \sigma_1=1$ での値を計算せよ。(3) べき乗反復 q 回で誤差はどう改善されるか。$\sigma_{k+1}/\sigma_k=0.9$、$q=2$ で論ぜよ。

演習 4.4 (Davis–Kahan の適用 ($\star\star$))**.** $\boldsymbol{\Sigma}=\operatorname{diag}(5,4.9,1)$ を真の共分散、$\widehat{\boldsymbol{\Sigma}}=\boldsymbol{\Sigma}+\boldsymbol{E}$、$\|\boldsymbol{E}\|_{\mathrm{F}}=0.05$ とする。(1) $k=1$ での (4.15) の右辺を計算せよ。意味のある評価か。(2) $k=2$ での右辺を計算せよ。(3) 「第 1 主成分の解釈」と「上位 2 主成分が張る空間の解釈」のどちらを報告すべきか論ぜよ。(4) $\|\boldsymbol{E}\|_{\mathrm{F}}\approx\sqrt{d^{2}/n}$ で減るとして、(1) の評価を 0.1 にするには n が何倍必要か。

演習 4.5 (実装：双対 PCA ($\star\star$))**.** リスト 4.1 を出発点として次を行え。(1) $d=5000$, $n=50$（$\boldsymbol{X}\in\mathbb{R}^{5000\times 50}$）の低ランク（真の階数 3）＋ノイズのデータで `pca_primal` と `pca_dual` の実行時間を計測し比を報告せよ。(2) 固有値と（符号を揃えた）固有ベクトルの差が丸め誤差の範囲であることを確認せよ。(3) 第 4 主成分以降で固有ベクトルの一致が悪くなる理由を 定理 4.25 で説明せよ。(4) `numpy.linalg.svd(Xt, full_matrices=False)` とも比較し、三つが一致することを示せ。

演習 4.6 (実装：ランダム化 SVD (★★★))**.** リスト 4.2 を用いて次を調べよ。(1) 特異値が $\sigma_i = i^{-1}$（緩やかな減衰）と $\sigma_i = 0.8^{i-1}$（速い減衰）の 1000×1000 行列（$d = n = 1000$）で $q = 0, 1, 2$ の誤差を比較し、q の効き方の違いを論ぜよ。(2) $p = 0, 2, 5, 10, 20$ で誤差を測り理論係数 $(1 + k/(p-1))^{1/2}$ と比較せよ。$p = 0, 1$ では何が起こるか。(3) 中間の再直交化（段階 3 の QR）を外し、$q = 2, 5, 10, 20$ と `float64` ／ `float32` で比較して何が起きるか説明せよ（$q = 5$ の倍精度ではまだ壊れない。$\boldsymbol{Y}$ の条件数も併せて観察するとよい）。(4) $\|\boldsymbol{X} - \boldsymbol{Q}\boldsymbol{Q}^{\top}\boldsymbol{X}\|_{\mathrm{F}}$ を乱数の種 100 通りで測り、界を超える割合を求めよ。

演習 4.7 (実装：Oja の学習則 (★★))**.** $d = 10$、既知の共分散を持つガウス分布から (4.6) を実装せよ（サンプルはデータ行列 $\boldsymbol{X} \in \mathbb{R}^{10 \times n}$ の列を順に取り出す）。(1) $\eta_t = \eta_0$（定数）と $\eta_t = \eta_0/(t_0 + t)$ で $|\langle \boldsymbol{w}_t, \boldsymbol{q}_1 \rangle|$ の推移を比較せよ。定数だと何が起こるか。(2) λ_1/λ_2 を $1.1, 2, 10$ と変え、定理 4.13 の $\mathrm{e}^{(\lambda_2 - \lambda_1)t}$ という予言と比較せよ。(3) 命題 4.12 を数値的に確認し、正規化しないと $\|\boldsymbol{w}_t\|$ がどうなるか調べよ。(4) Sanger 則を実装し、上位 3 主成分を同時に推定せよ。

演習 4.8 (欠測とロバスト性の実験 (★★★))**.** (1) 相関 0.9 の 2 変量正規分布 $n = 2000$ 点（$\boldsymbol{X} \in \mathbb{R}^{2 \times 2000}$）で第 2 変数（＝第 2 行）を $q = 0.1, 0.3, 0.5, 0.7$ の割合で MCAR 欠測させ、平均補完後の標本相関を測って理論的な予想と比較せよ。(2) 同じデータに4.6節の EM 反復（$k = 1$）を適用し、改善を示せ。(3) 外れ値を $m = 0, 1, 2, 5, 10$ 点（各 $\|\boldsymbol{x}\| = 30$）加えたとき、第 1 主成分方向が真の方向となす角を m の関数としてプロットせよ。(4) マハラノビス距離が下位 80% の点だけを使う簡易ロバスト推定（2 回反復）を実装し (3) と比較せよ。

第 5 章

高次元データの数理

この章のねらい

低次元で培った幾何的直感は、次元が大きくなると次々に破綻する。単位球の体積は消え、すべての点対距離はほぼ等しくなり、無関係な二つのベクトルはほぼ直交する。本章ではこれらを測度の集中という一つの原理から導き、Johnson–Lindenstrauss の補題、Marchenko–Pastur 則、BBP 相転移によって、d/n が有限に留まる現代的な設定で第3章の PCA が何を返すのかを定量化する。最後に、同じ集中現象が高次元の**利点**にもなることを見る。[a]

[a] この章の計算は演習ノートブック `ch05_highdim.ipynb` で再現できる。インストール不要で実行するには Google Colab で開く：https://colab.research.google.com/github/yusukeimoto/data-analysis-math-demos/blob/main/notebooks/ch05_highdim.ipynb

5.1 なぜ高次元を別扱いするのか

古典的な漸近理論は次元 d を固定して $n \to \infty$ とし、$\widehat{\boldsymbol{\Sigma}} \to \boldsymbol{\Sigma}$、すなわち「データをたくさん集めれば正しい答えが得られる」と結論する。しかし現代のデータでこの枠組みが妥当な場面は少ない。遺伝子発現では $d \approx 2 \times 10^4$ に対し n は 10^2〜10^4、256×256 の画像は $d = 65536$ 次元、テキストを語彙ベクトルにすれば d は 10^4〜10^6 である。いずれも d は n に比べて小さくなく、n を増やせば d も増える。

本章で採用する漸近の枠組み

$n \to \infty$ かつ $d = d(n) \to \infty$ で $\gamma_n := d/n \to \gamma \in (0, \infty)$ とする。これを**比例的高次元漸近**（proportional high-dimensional asymptotics）あるいは Kolmogorov 漸近という。$\gamma \to 0$ が古典理論に対応する。

この枠組みを採るのは現実的だからだけではない。5.5節以降で見るように、$\gamma > 0$ では PCA の振る舞いが $\gamma = 0$ の場合と**質的に**異なり、n をいくら増やしても d/n を一定に保つ限り決して消えない誤差が残る。議論の道具は一つ、**測度の集中**（concentration of measure）——「高次元空間上のなめらかな関数は、ほとんどすべての点で自分の平均にきわめて近い値をとる」——であり、次元の呪いも距離の集中も JL 補題もここから導かれる。

5.2 次元の呪い：体積はどこへ行ったか

記号を決めておく。$\mathbb{R}^d$ の**閉球**を、中心を原点、半径を $r > 0$ として

$$\overline{B}_d(r) := \{\boldsymbol{x} \in \mathbb{R}^d : \|\boldsymbol{x}\| \le r\}$$

と書き、$r = 1$ の場合を**単位閉球** $\overline{B}_d := \overline{B}_d(1)$ と略記する（以下、断らない限りたんに単位球と呼ぶ）。その体積を

$$V_d := \mathrm{vol}\big(\overline{B}_d\big) = \frac{\pi^{d/2}}{\Gamma\big(\frac{d}{2} + 1\big)} \tag{5.1}$$

と書く。すなわち V_d と $\mathrm{vol}(\overline{B}_d)$ は同じものを指す記号で、以下では短い V_d のほうを使う。半径 r の球は単位球を r 倍に相似拡大したものだから、体積は各座標方向に r 倍された分だけ増えて

$$\mathrm{vol}\big(\overline{B}_d(r)\big) = r^d V_d$$

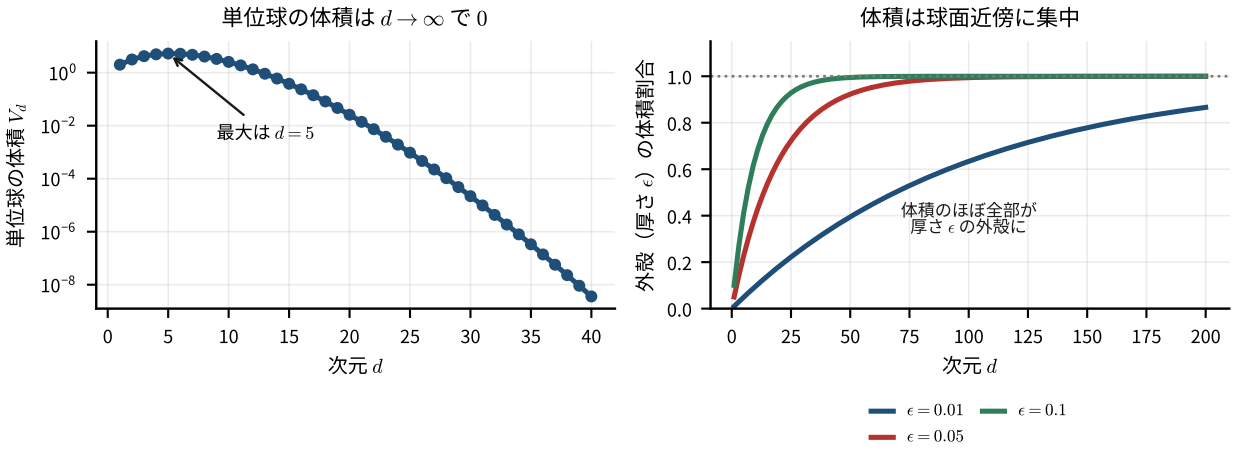


図5.1　次元の呪いの二側面。左は単位球の体積 V_d が $d=5$ をピークに急速に 0 へ向かう様子、右は外側 ε の殻が全体積に占める割合 $1-(1-\varepsilon)^d$ が次元とともに 1 へ飽和する様子である。

となる。この**相似則**が本節の議論のほとんどを動かす。

さて V_d は $d=1,2,3$ で $2,\ 3.14,\ 4.19$ と増えるが、$d=5$ の 5.26 を最大に減少に転じ、$d=20$ で 0.026、$d=50$ で 1.7×10^{-13} になる。

命題 5.1 (単位球の体積の消失)**.** $V_d\to0$（$d\to\infty$）であり、より精密に $V_d=\frac{1}{\sqrt{\pi d}}\left(\frac{2\pi e}{d}\right)^{d/2}(1+o(1))$。

証明. Stirling の公式 $\Gamma(z+1)=\sqrt{2\pi z}(z/e)^z(1+o(1))$ を $z=d/2$ に適用すると $\Gamma(\frac{d}{2}+1)=\sqrt{\pi d}\,(\frac{d}{2e})^{d/2}(1+o(1))$。これを 式 (5.1) に代入すれば主張の式を得る。$d>2\pi e\approx17.08$ で括弧の中身が 1 を下回るので、V_d は超指数的に 0 に収束する。 ■

単位閉球を包む立方体 $[-1,1]^d$ の体積は 2^d だから比 $V_d/2^d$ は $d=20$ で 2.5×10^{-8}——**高次元立方体の体積はほとんどすべてが「隅」にある**のであり、立方体から一様に点を取ればほぼ確実に内接球の外側である。球の内部での分布はさらに極端である。相似則を $r=1-\varepsilon$ に使えば、半径を 1% 縮めた球が元の球に占める割合は

$$\frac{\mathrm{vol}\big(\overline{B}_d(1-\varepsilon)\big)}{\mathrm{vol}\big(\overline{B}_d\big)}=\frac{(1-\varepsilon)^dV_d}{V_d}=(1-\varepsilon)^d\le e^{-\varepsilon d} \tag{5.2}$$

である。$\varepsilon=0.01$、$d=1000$ で右辺は 4.5×10^{-5}。つまり**単位球の体積の** 99.99% **以上が厚さ** 1% **の外殻に入る**。高次元の球は「詰まった玉」ではなく中身のない「殻」である（図 5.1）。

例 5.2 (近傍が空になる)**.** $[0,1]^d$ に一様な n 点で、一辺 s の小立方体に入る点の期待個数は ns^d だから、これを 10 にするには $s=(10/n)^{1/d}$ が要る。$n=10^6$、$d=100$ なら $s\approx0.891$、つまり各辺の 89% を覆う立方体が必要である。これは「局所的な近傍」ではなくほぼ定義域全体であり、k 近傍法やカーネル密度推定が前提とする局所性はここで失われる。

注意 5.3. ただしこの計算は「データが d 次元に一様に散る」という最悪の仮定に基づく。実データは低次元の部分多様体の近くに集中しており内在次元は d よりずっと小さく、第3章の PCA や第11章の多様体学習はこの構造を使って呪いを回避する。呪いは「高次元は絶望的」ではなく「**構造なしの**高次元は絶望的」と読むべきである。

5.3　測度の集中

$\boldsymbol{x}\sim\mathcal{N}(\mathbf{0},\boldsymbol{I}_d)$ なら $\mathbb{E}\|\boldsymbol{x}\|^2=d$ で典型的な長さは $\sqrt{d}$ である。問題はそのばらつきで、幅が $\sqrt{d}$ 程度なら高次元は「広い」が、実際には d に依らず $O(1)$ に留まる。これが集中である。

定理 5.4 (ガウスノルムの集中)**.** $\boldsymbol{x}\sim\mathcal{N}(\mathbf{0},\boldsymbol{I}_d)$ のとき、任意の $t>0$ に対し $\mathbb{P}(|\|\boldsymbol{x}\|-\sqrt{d}|>t)\le2e^{-t^2/2}$（定数の調整を許す）。

これはより一般な次の不等式から従う。

定理 5.5 (Gauss–Lipschitz 集中不等式)**.** $f:\mathbb{R}^d\to\mathbb{R}$ が L-Lipschitz、$\boldsymbol{x}\sim\mathcal{N}(\mathbf{0},\boldsymbol{I}_d)$ とすると

$$\mathbb{P}\big(|f(\boldsymbol{x})-\mathbb{E}f(\boldsymbol{x})|>t\big)\le2\exp\!\left(-\frac{t^2}{2L^2}\right). \tag{5.3}$$

証明の概略（*Herbst* の議論）．出発点はガウス測度の**対数 Sobolev 不等式** $\mathrm{Ent}(g^2) \coloneqq \mathbb{E}[g^2 \log g^2] - \mathbb{E}[g^2]\log \mathbb{E}[g^2] \le 2\mathbb{E}\|\nabla g\|^2$ である（これ自体は $d=1$ を二点空間の Bernoulli 版から中心極限定理で導き、テンソル化で一般の d に拡げる。この部分のみ省く）。$F \coloneqq f - \mathbb{E}f$、$H(\lambda) \coloneqq \mathbb{E}[e^{\lambda F}]$ とおいて $g = e^{\lambda F/2}$ を代入すると、左辺は $\lambda H' - H\log H$、右辺は $\frac{\lambda^2}{2}\mathbb{E}[\|\nabla F\|^2 e^{\lambda F}] \le \frac{\lambda^2 L^2}{2} H$（$L$-Lipschitz より $\|\nabla f\| \le L$ a.e.）。両辺を $\lambda^2 H$ で割ると $K(\lambda) \coloneqq \frac{1}{\lambda}\log H(\lambda)$ が $K' \le L^2/2$ をみたし、$\lambda \to 0^+$ で $K \to \mathbb{E}F = 0$ だから $K(\lambda) \le \lambda L^2/2$、すなわち $\mathbb{E}[e^{\lambda F}] \le e^{\lambda^2 L^2/2}$（$F$ は分散代理 L^2 の劣ガウス変数）。あとは Chernoff 界 $\mathbb{P}(F > t) \le e^{-\lambda t + \lambda^2 L^2/2}$ を $\lambda = t/L^2$ で最小化して $e^{-t^2/(2L^2)}$、$-F$ にも同じ議論を適用して和を取ればよい。 ■

定理 5.4 の証明．$f(\boldsymbol{x}) = \|\boldsymbol{x}\|$ は三角不等式より 1-Lipschitz なので 式 (5.3) が $L=1$ で使え、あとは $\mathbb{E}\|\boldsymbol{x}\|$ を $\sqrt{d}$ に置き換えてよいことを見ればよい。Jensen より $\mathbb{E}\|\boldsymbol{x}\| \le \sqrt{\mathbb{E}\|\boldsymbol{x}\|^2} = \sqrt{d}$、逆向きには Gauss–Poincaré 不等式 $\mathrm{Var}(f) \le \mathbb{E}\|\nabla f\|^2 \le 1$ と $d = (\mathbb{E}\|\boldsymbol{x}\|)^2 + \mathrm{Var}(\|\boldsymbol{x}\|)$ から $\mathbb{E}\|\boldsymbol{x}\| \ge \sqrt{d-1}$、よって $0 \le \sqrt{d} - \mathbb{E}\|\boldsymbol{x}\| \le \frac{1}{2\sqrt{d-1}}$ は微小量である。 ■

高次元ガウスの姿

$\mathcal{N}(\mathbf{0}, \boldsymbol{I}_d)$ のサンプルは原点付近にはほとんど存在せず、質量は半径 $\sqrt{d}$、厚さ $O(1)$ の球殻に集中する（$d = 1000$ ならほぼすべての点の長さが 31.6 ± 3）。「ガウス分布は原点付近に集中する」という一次元の直感は誤りである。

5.3.1　χ^2 の集中：Laurent–Massart 不等式

$\|\boldsymbol{x}\|^2 \sim \chi^2_d$ を使えば、モーメント母関数の直接計算でより明示的な両側界が得られる。これは次節の JL 補題でそのまま使う形である。

補題 5.6 (Laurent–Massart)**.** $Z \sim \chi^2_d$ とすると任意の $t > 0$ に対し

$$\mathbb{P}\big(Z \ge d + 2\sqrt{dt} + 2t\big) \le e^{-t}, \qquad \mathbb{P}\big(Z \le d - 2\sqrt{dt}\big) \le e^{-t}. \tag{5.4}$$

系として $\varepsilon \in (0,1)$ に対し

$$\mathbb{P}\big(|Z/d - 1| \ge \varepsilon\big) \le 2\exp\!\left(-\frac{d}{4}(\varepsilon^2 - \varepsilon^3)\right) \le 2\exp\!\left(-\frac{d\varepsilon^2}{8}\right). \tag{5.5}$$

証明. $Z = \sum_{i=1}^d g_i^2$、$g_i \sim \mathcal{N}(0,1)$ i.i.d.。$\lambda < 1/2$ で $\mathbb{E}[e^{\lambda g_1^2}] = (1-2\lambda)^{-1/2}$ だから $\log \mathbb{E}[e^{\lambda(Z-d)}] = -\frac{d}{2}\log(1-2\lambda) - \lambda d$。$-\log(1-u) - u \le \frac{u^2}{2(1-u)}$（$0 \le u < 1$）を $u = 2\lambda$ に使うと $\log \mathbb{E}[e^{\lambda(Z-d)}] \le \frac{d\lambda^2}{1-2\lambda}$ であり、Chernoff 界で $\lambda = \frac{1}{2}(1 - \sqrt{d/(d+s)})$、$s = 2\sqrt{dt} + 2t$ とすると指数部が $-t$ 以下になって 式 (5.4) の上側を得る。下側は $\lambda < 0$ とし、$-\log(1-2\lambda) - 2\lambda \le 2\lambda^2$ から $\mathbb{P}(Z - d \le -s) \le \exp(d\lambda^2 + \lambda s)$、$\lambda = -s/(2d)$ で最小化して $\exp(-s^2/(4d))$、$s = 2\sqrt{dt}$ とおけば e^{-t} である。

系は次のように出る。上側では $d\varepsilon = 2\sqrt{dt} + 2t$ を解くと $t = \frac{d}{4}(\sqrt{1+2\varepsilon} - 1)^2$ で、$\sqrt{1+2\varepsilon} \ge 1 + \varepsilon - \frac{\varepsilon^2}{2}$ より $t \ge \frac{d}{4}(\varepsilon^2 - \varepsilon^3)$。下側は $s = d\varepsilon$ で直ちに $\exp(-d\varepsilon^2/4)$ を得る。両者を合わせ $\varepsilon < 1$ で係数を 8 に取り直せば 式 (5.5) の右端が従う。 ■

数値で見ると、$d = 1000$ での 式 (5.5) の右辺は $\varepsilon = 0.1$ で $2e^{-1.25} \approx 0.573$、$\varepsilon = 0.3$ で 2.6×10^{-5}。$d = 10^4$ なら $\varepsilon = 0.1$ でも 7.5×10^{-6} で、次元が上がるほど相対的なばらつきが消える。

5.3.2　距離の集中と「ほとんど直交」

命題 5.7 (距離の集中)**.** $\boldsymbol{x}_1, \dots, \boldsymbol{x}_n$ を $\mathcal{N}(\mathbf{0}, \boldsymbol{I}_d)$ からの独立サンプルとすると、小さい $\delta > 0$ に対し $\mathbb{P}\big(\max_{i \ne j} \big|\|\boldsymbol{x}_i - \boldsymbol{x}_j\|/\sqrt{2d} - 1\big| > \delta\big) \le 2n^2 \exp(-d\delta^2/4)$。とくに $d/\log n \to \infty$ なら $\max_{i\ne j}\|\boldsymbol{x}_i - \boldsymbol{x}_j\| \big/ \min_{i \ne j}\|\boldsymbol{x}_i - \boldsymbol{x}_j\| \to 1$（確率収束）。

証明. 以下 $0 < \delta < 1$ とする。一対を固定し、$\boldsymbol{x}_i - \boldsymbol{x}_j \sim \mathcal{N}(\mathbf{0}, 2\boldsymbol{I}_d)$ から

$$Z \coloneqq \frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2}{2} \sim \chi^2_d, \qquad u \coloneqq \frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|}{\sqrt{2d}} = \sqrt{Z/d}$$

とおく。示すべきは $\mathbb{P}(|u - 1| > \delta)$ の評価である。

第 1 段（u の逸脱を Z の逸脱に翻訳する）。 $u \ge 0$ だから $|u-1| > \delta$ は $u > 1+\delta$ または $u < 1-\delta$ を意味する。前者なら $Z/d = u^2 > (1+\delta)^2 \ge 1 + 2\delta$、後者なら $Z/d = u^2 < (1-\delta)^2 \le 1 - \delta$（どちらも $\delta^2 \le \delta$ による）。すなわち

$$\mathbb{P}\big(|u-1| > \delta\big) \le \underbrace{\mathbb{P}\big(Z \ge d(1+2\delta)\big)}_{\text{(A)}} + \underbrace{\mathbb{P}\big(Z \le d(1-\delta)\big)}_{\text{(B)}}.$$

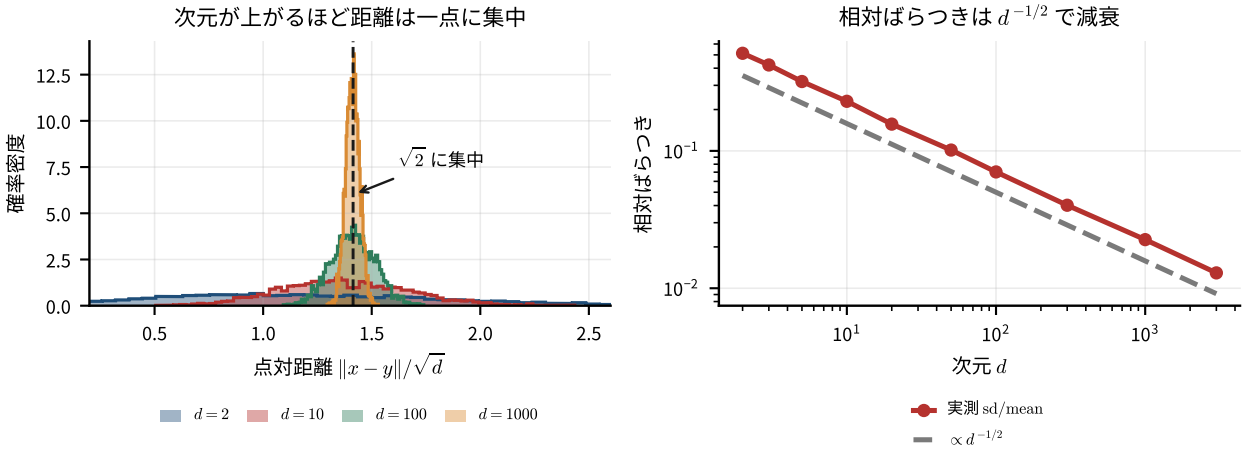


図5.2　$d=2,10,100,1000$ の標準正規から取った点対距離を $\sqrt{d}$ で正規化したヒストグラム。次元が上がるにつれ分布の相対的な幅が $O(d^{-1/2})$ で縮み、すべての点対がほぼ同じ距離に見えるようになる。

第 2 段（式 (5.4)を当てる）。上側は $d+2\sqrt{dt}+2t=d(1+2\delta)$ を t について解いて $t_+=\frac{d}{4}\bigl(\sqrt{1+4\delta}-1\bigr)^2$ とすればよい。$\delta\le 2$ で $\sqrt{1+4\delta}\ge 1+\delta$（両辺を二乗すると $2\delta\ge\delta^2$）だから $t_+\ge\frac{d\delta^2}{4}$ である。下側は $2\sqrt{dt}=d\delta$、すなわち $t_-=\frac{d\delta^2}{4}$ と取ればちょうど $Z\le d(1-\delta)$ の確率が押さえられる。よって (A), (B) はともに $e^{-d\delta^2/4}$ 以下で、

$$\mathbb{P}\bigl(|u-1|>\delta\bigr)\le 2e^{-d\delta^2/4}.$$

定数 $1/4$ は式 (5.4)の指数そのもので、余分な定数は入らない。

第 3 段（すべての対へ）。対の個数は $\binom{n}{2}<n^2/2$ だから、いまの一対あたりの界に union bound を取って $\mathbb{P}\bigl(\max_{i\neq j}|u_{ij}-1|>\delta\bigr)\le n^2e^{-d\delta^2/4}$、主張の界（係数 2 は余裕をもたせたもの）を得る。

第 4 段（比の収束）。δ を固定すると上の界は $\exp\bigl(2\log n-\frac{d\delta^2}{4}\bigr)$ の形で、$d/\log n\to\infty$ のとき 0 に収束する。その補事象ではすべての対の距離が $\sqrt{2d}\,[1-\delta,1+\delta]$ に入るので最大と最小の比は $\frac{1+\delta}{1-\delta}$ 以下である。$\delta>0$ は任意に小さく取れるから比は 1 に確率収束する。 ■

これは最近傍探索にとって致命的である。「最も近い点」と「最も遠い点」の距離比が 1.01 なら、ノイズや丸め誤差で順位が容易に入れ替わる（図 5.2）。

命題 5.8 (ランダムな二方向はほぼ直交する)**.** $\boldsymbol{u},\boldsymbol{v}$ を $\mathbb{S}^{d-1}$ 上の独立一様乱数とすると

$$\mathbb{P}\bigl(|\langle\boldsymbol{u},\boldsymbol{v}\rangle|>t\bigr)\le 2e^{-dt^2/2}. \tag{5.6}$$

とくに $\langle\boldsymbol{u},\boldsymbol{v}\rangle=O(d^{-1/2})$ が高確率で成り立ち、なす角は $\pi/2$ に集中する。

証明. 回転不変性より $\boldsymbol{v}$ を固定してよい。$\boldsymbol{u}\mapsto\langle\boldsymbol{u},\boldsymbol{v}\rangle$ は球面上の 1-Lipschitz 関数で対称性からその平均は 0 だから、球面上の一様測度に対する Lévy の集中不等式 $\mathbb{P}(|f-\mathbb{E}f|>t)\le 2e^{-dt^2/2}$ を適用すればよい。球面版を仮定せずに済ませるには $\boldsymbol{u}=\boldsymbol{g}/\|\boldsymbol{g}\|$、$\boldsymbol{g}\sim\mathcal{N}(\boldsymbol{0},\boldsymbol{I}_d)$ と書く。$\langle\boldsymbol{g},\boldsymbol{v}\rangle\sim\mathcal{N}(0,1)$、$\|\boldsymbol{g}\|\approx\sqrt{d}$（定理 5.4）より $\langle\boldsymbol{u},\boldsymbol{v}\rangle\approx\mathcal{N}(0,1)/\sqrt{d}$ となり同じ結論に至る。 ■

$d=1000$、$t=0.1$ なら右辺は $2e^{-5}\approx 0.013$ で、ランダムな二方向のなす角は 99% 近い確率で 84.3°〜95.7° に入る。「たまたま似た方向を向く」ことは高次元では起こらない。

5.4　Johnson–Lindenstrauss の補題

集中は困りごとばかりではない。$\|\boldsymbol{x}\|$ の値がほとんどぶれないとは、「一回のランダムな測定で長さが正確に分かる」ということでもあり、m 回平均すれば精度はさらに上がる。これを形にしたのが JL 補題である。

定理 5.9 (Johnson–Lindenstrauss [45])**.** $\varepsilon\in(0,1)$、$n\ge 2$、$m\ge\dfrac{24\log n}{\varepsilon^2}$ とする。このとき任意の n 点 $\boldsymbol{x}_1,\dots,\boldsymbol{x}_n\in\mathbb{R}^d$ に対し線形写像 $\boldsymbol{R}:\mathbb{R}^d\to\mathbb{R}^m$ が存在して、すべての i,j で

$$(1-\varepsilon)\|\boldsymbol{x}_i-\boldsymbol{x}_j\|^2\le\|\boldsymbol{R}\boldsymbol{x}_i-\boldsymbol{R}\boldsymbol{x}_j\|^2\le(1+\varepsilon)\|\boldsymbol{x}_i-\boldsymbol{x}_j\|^2. \tag{5.7}$$

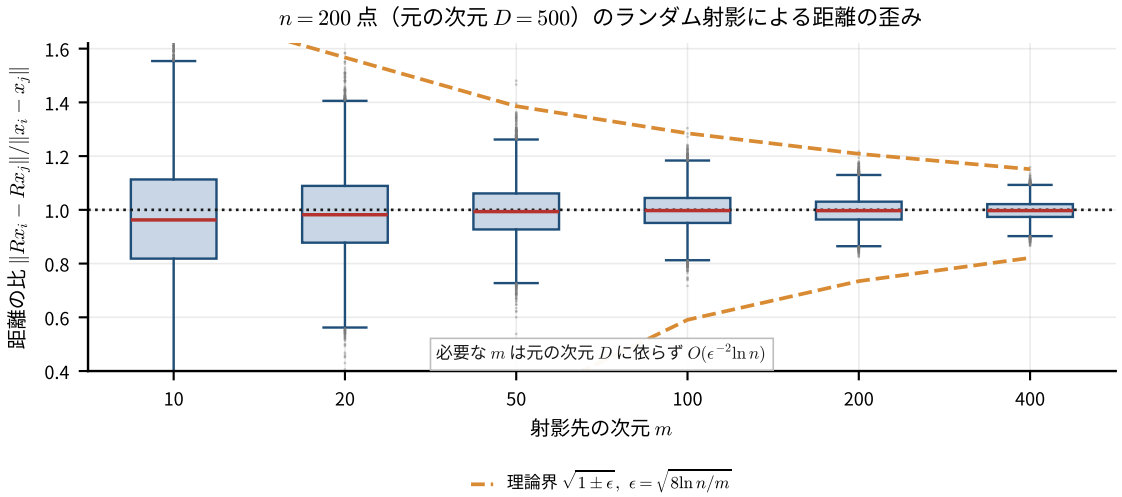


図5.3　Johnson–Lindenstrauss の数値検証。n 点の対距離が射影次元 m を変えたときどれだけ歪むかを箱ひげ図で示し、理論が保証する ε 界を破線で重ねてある。歪みは $O(m^{-1/2})$ で縮む。

しかも $\boldsymbol{R}$ の各成分を独立に $\mathcal{N}(0,1/m)$ から取れば、式 (5.7) は確率 $1-1/n$ 以上で成り立つ。（存在の主張は [45] による。ガウス行列による構成と $m \ge 24\log n/\varepsilon^2$ という明示的な定数は、以下の証明のように集中不等式から得られる現代的な形で、[80] の第 5 章などに整理されている。）

データ行列の言葉で言い直しておく。$\boldsymbol{X}=(\boldsymbol{x}_1,\dots,\boldsymbol{x}_n)\in\mathbb{R}^{d\times n}$ に対し射影後のデータ行列は $\boldsymbol{RX}\in\mathbb{R}^{m\times n}$ であり、$\boldsymbol{R}$ を**左から**掛ける。$(m\times d)(d\times n)=(m\times n)$ で、その第 i 列がちょうど $\boldsymbol{Rx}_i$、すなわち**列がサンプルという規約が射影の前後で保たれる**。$\boldsymbol{R}$ が変数の側（$\mathbb{R}^d$）だけに作用し、サンプルの側（$\mathbb{R}^n$）には触れないことがこの形からひと目で分かる。

証明の核は「一本のベクトルの長さがランダム射影で保たれる」ことである。

補題 5.10. $\boldsymbol{R}\in\mathbb{R}^{m\times d}$ の各成分を独立に $\mathcal{N}(0,1/m)$ から取る。固定した $\boldsymbol{z}\neq\boldsymbol{0}$ に対し

$$\mathbb{P}\big(\,|\,\|\boldsymbol{Rz}\|^2-\|\boldsymbol{z}\|^2\,|>\varepsilon\|\boldsymbol{z}\|^2\big)\le 2\exp\!\left(-\frac{m\varepsilon^2}{8}\right). \tag{5.8}$$

証明. スケール不変なので $\|\boldsymbol{z}\|=1$ としてよい。$\boldsymbol{R}$ の第 k 行を $\boldsymbol{r}_k^{\top}$ と書くと $\boldsymbol{r}_k\sim\mathcal{N}(\boldsymbol{0},\frac{1}{m}\boldsymbol{I}_d)$ で、$\boldsymbol{z}$ が固定されているからガウスの線形性より $\langle\boldsymbol{r}_k,\boldsymbol{z}\rangle\sim\mathcal{N}(0,\frac{1}{m}\|\boldsymbol{z}\|^2)=\mathcal{N}(0,\frac{1}{m})$ が k について独立。よって $g_k:=\sqrt{m}\langle\boldsymbol{r}_k,\boldsymbol{z}\rangle$ は i.i.d. の $\mathcal{N}(0,1)$ で $\|\boldsymbol{Rz}\|^2=\sum_k\langle\boldsymbol{r}_k,\boldsymbol{z}\rangle^2=Z/m$、$Z\sim\chi^2_m$。とくに $\mathbb{E}\|\boldsymbol{Rz}\|^2=1=\|\boldsymbol{z}\|^2$（不偏）であり、自由度 m の 式 (5.5) がそのまま式 (5.8) を与える。 ■

定理 5.9 の証明. 各対 (i,j)、$i<j$ に $\boldsymbol{z}_{ij}:=\boldsymbol{x}_i-\boldsymbol{x}_j$ を対応させる。$\boldsymbol{R}$ は線形なので $\boldsymbol{Rx}_i-\boldsymbol{Rx}_j=\boldsymbol{Rz}_{ij}$ であり、$\boldsymbol{z}_{ij}$ は $\boldsymbol{R}$ と独立に定まっているから 補題 5.10 が使え、各対の失敗確率は $2e^{-m\varepsilon^2/8}$ 以下。対の個数は $\binom{n}{2}<n^2/2$ なので union bound より

$$\mathbb{P}(\text{どれかの対で失敗})\le\frac{n^2}{2}\cdot 2e^{-m\varepsilon^2/8}=n^2e^{-m\varepsilon^2/8}.$$

仮定 $m\ge 24\log n/\varepsilon^2$ より $e^{-m\varepsilon^2/8}\le n^{-3}$ だから右辺は n^{-1} 以下。よって確率 $1-1/n>0$ で 式 (5.7) が全対で成立し、とくにそのような $\boldsymbol{R}$ が存在する。定数 24 は本質的でなく、式 (5.5) の鋭い形を使えば $m\ge\frac{12\log n}{\varepsilon^2(1-\varepsilon)}$ で足りる。重要なのは $m=O(\varepsilon^{-2}\log n)$ という依存性である。 ■

JL 補題が言っていること

n 点の対距離をすべて相対誤差 ε 以内で保つのに必要な次元は $m=O(\varepsilon^{-2}\log n)$ であり、**元の次元 d に全く依存しない**。$n=10^6$ 点を $\varepsilon=0.2$ で埋め込むなら $m\ge 24\log(10^6)/0.04\approx 8290$ で足り、d が 10^6 でも 10^9 でも同じである。

図 5.3はこの主張を数値で確かめたものである。射影次元 m を変えて対距離の相対歪みを箱ひげ図で描くと、m が理論の要求を満たす領域では歪みが ε 界の内側に収まり、m を下げると急速に崩れることが見える。

リスト 5.1　JL 補題の数値検証。ガウスランダム行列（成分は $\mathcal{N}(0,1/m)$）で射影し、全点対距離の相対歪みの最大値を測る。

```
import numpy as np
from scipy.spatial.distance import pdist
```

```
rng = np.random.default_rng(1)
n, d, eps = 500, 2000, 0.3
X = rng.standard_normal((d, n))                    # d×n：列がサンプル
dist0 = pdist(X.T)                                 # pdist は n×d 規約なので転置
m_theory = int(np.ceil(24 * np.log(n) / eps**2))
print("理論が要求する m =", m_theory)
for m in [50, 100, 200, 400, 800, m_theory]:
    R = rng.standard_normal((m, d)) / np.sqrt(m)   # R は m×d、成分は N(0, 1/m)
    dist1 = pdist((R @ X).T)                       # 射影は左から：R X は m×n
    print(f"m={m:5d}  最大歪み={np.abs(dist1/dist0 - 1).max():.4f}")
```

最大歪みは $m=50$ で 0.419、100 で 0.303、200 で 0.239、400 で 0.154、800 で 0.109、$m=m_{\mathrm{theory}}$ で 0.082。m を 4 倍するごとにほぼ半分、すなわち歪み $\propto m^{-1/2}$ という理論の予言と整合する（理論値 $m_{\mathrm{theory}}=\lceil 24\log 500/0.09\rceil=1658$ は保守的で、$\varepsilon=0.3$ の保証に対し実測の歪みは 0.082 にすぎない）。

注意 5.11 (JL と PCA の違い、そして実用)**.** どちらも線形の次元削減だが性格は正反対である。JL の射影行列は**データを見ずに**決まり、保証は「すべての対距離が相対誤差 ε 以内」という一様なもの。どんな分布でも成り立つ代わりに、データが実は 2 次元部分空間に乗っていても $m=O(\varepsilon^{-2}\log n)$ 次元は要る。PCA は射影がデータに適応し、保証は「二乗誤差の総和が最小」という平均的なもので個々の対距離は壊れうるが、データが k 次元部分空間に乗っていれば $m=k$ で誤差ゼロである。実務ではまず JL で d を数千まで落としてから PCA をかける二段構えがよく使われる（$O(nd^2)$ が $O(nm^2)$ になる）。JL の考え方は局所鋭敏ハッシュ（LSH）やストリーミングデータのスケッチングの基礎でもある。$\operatorname{sign}(\boldsymbol{r}^\top\boldsymbol{x})$ という 1 ビットの符号を m 本作れば、そのハミング距離が二点のなす角の推定量になる（$\mathbb{P}(\operatorname{sign}(\boldsymbol{r}^\top\boldsymbol{x})\neq\operatorname{sign}(\boldsymbol{r}^\top\boldsymbol{y}))=\theta/\pi$）。成分をガウスでなく ±1 や $\{-1,0,+1\}$（確率 $\frac16,\frac23,\frac16$、Achlioptas の構成）にしても同次数の保証が得られ、計算がずっと速い。

5.5　ランダム行列理論と Marchenko–Pastur 則

ここからが本章の核心である。観測が $\mathcal{N}(\mathbf{0},\boldsymbol{I}_d)$、すなわち**真の共分散が単位行列（相関構造がまったくない）**のとき、$\widehat{\boldsymbol{\Sigma}}=\frac1n\boldsymbol{X}\boldsymbol{X}^\top$（$\boldsymbol{X}\in\mathbb{R}^{d\times n}$ なので $d\times d$）の固有値はどうなるか。古典的な直感は「$\widehat{\boldsymbol{\Sigma}}\to\boldsymbol{I}_d$ だから固有値はすべて 1 の近く」だが、$d/n\to\gamma>0$ では話が違う。

定理 5.12 (Marchenko–Pastur [49]；一般形は [9])**.** $\boldsymbol{X}\in\mathbb{R}^{d\times n}$ の成分が i.i.d. で平均 0、分散 1、$\mathbb{E}X_{ji}^4<\infty$ とする（X_{ji} は第 i サンプルの第 j 変数、$\widehat{\boldsymbol{\Sigma}}=\frac1n\boldsymbol{X}\boldsymbol{X}^\top$）。$n,d\to\infty$、$d/n\to\gamma\in(0,1]$ のとき、$\widehat{\boldsymbol{\Sigma}}$ の経験固有値分布 $\frac1d\sum_i\delta_{\lambda_i}$ は確率 1 で次の密度をもつ分布に弱収束する：

$$p_\gamma(x)=\frac{\sqrt{(\lambda_+-x)(x-\lambda_-)}}{2\pi\gamma x},\qquad \lambda_\pm=(1\pm\sqrt{\gamma})^2, \tag{5.9}$$

台は $[\lambda_-,\lambda_+]$。$\gamma>1$ では $\operatorname{rank}\widehat{\boldsymbol{\Sigma}}\le n<d$ なので原点に質量 $1-1/\gamma$ の原子が付く。

証明の筋道（*Stieltjes* 変換）．測度 μ の **Stieltjes 変換**を $s(z)\coloneqq\int\frac{\mu(\mathrm{d}x)}{x-z}$（$\operatorname{Im}z>0$）で定める。これは μ を一意に決め、反転公式 $p(x)=\frac1\pi\lim_{\eta\downarrow0}\operatorname{Im}s(x+\mathrm{i}\eta)$ で密度が復元できる。行列側では $s_d(z)=\frac1d\operatorname{tr}(\widehat{\boldsymbol{\Sigma}}-z\boldsymbol{I}_d)^{-1}$、すなわちレゾルベントの正規化トレースである。鍵は **Schur 補行列の公式**である。$\widehat{\boldsymbol{\Sigma}}=\frac1n\boldsymbol{X}\boldsymbol{X}^\top$ は変数について添字づけられているから、抜くのは**行**である：$\boldsymbol{X}$ の第 j 行（第 j 変数の n 個の観測値を並べたベクトル）を $\boldsymbol{x}^{(j)}\in\mathbb{R}^n$、それを除いた行列を $\boldsymbol{X}_{(j)}\in\mathbb{R}^{(d-1)\times n}$ とすると

$$G_{jj}(z)=\Big[\tfrac1n\|\boldsymbol{x}^{(j)}\|^2-z-\tfrac{1}{n^2}\boldsymbol{x}^{(j)\top}\boldsymbol{X}_{(j)}^\top\big(\tfrac1n\boldsymbol{X}_{(j)}\boldsymbol{X}_{(j)}^\top-z\boldsymbol{I}\big)^{-1}\boldsymbol{X}_{(j)}\boldsymbol{x}^{(j)}\Big]^{-1}$$

（次元は $(1\times n)(n\times(d-1))\cdot((d-1)\times(d-1))\cdot((d-1)\times n)(n\times1)$ でスカラーになる）。$\boldsymbol{x}^{(j)}$ は $\boldsymbol{X}_{(j)}$ と独立なので、右辺の二次形式は集中不等式によりその期待値に近い：$\frac1n\|\boldsymbol{x}^{(j)}\|^2\approx1$、第三項はトレースに集中する。これを s_d 自身で書き直すと（$d\times d$ の $\boldsymbol{X}\boldsymbol{X}^\top/n$ と $n\times n$ の $\boldsymbol{X}^\top\boldsymbol{X}/n$ の非零固有値が一致することを使う）、極限で**自己無撞着方程式**

$$s(z)=\frac{1}{1-z-\gamma-\gamma z\,s(z)} \tag{5.10}$$

が得られる（すべての j で同じ式になるのは成分が同分布だからである）。整理すると $\gamma z s^2+(z+\gamma-1)s+1=0$ で、$\operatorname{Im}s>0$ かつ $z\to\infty$ で $s\sim-1/z$ という条件から根を選ぶと

$$s(z)=\frac{(1-\gamma-z)+\sqrt{(z-1-\gamma)^2-4\gamma}}{2\gamma z}.$$

$z=x+\mathrm{i}0^+$ とすると、平方根の中身が負になるのは $|x-1-\gamma|<2\sqrt{\gamma}$、すなわち $\lambda_-<x<\lambda_+$ のときで、そこでは $\operatorname{Im}\sqrt{\cdot}=\sqrt{(\lambda_+-x)(x-\lambda_-)}$。反転公式より $p(x)=\frac1\pi\cdot\frac{\sqrt{(\lambda_+-x)(x-\lambda_-)}}{2\gamma x}$、これが 式 (5.9) である。省いたのは (i) s_d が非確率的な極限をもつことの証明と (ii) 近似の $O(1/n)$ 誤差評価のみである。 ∎

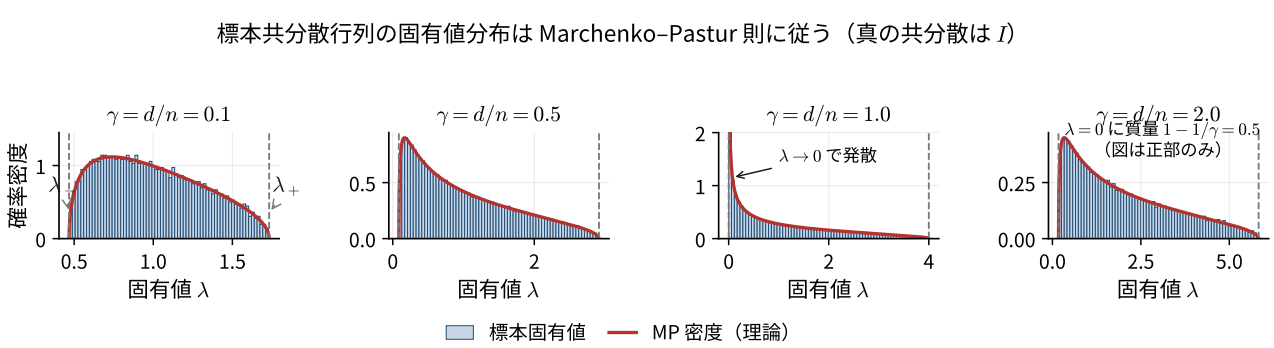


図5.4　Marchenko–Pastur 則。$\gamma = d/n = 0.1, 0.5, 1.0$ について、真の共分散が $\boldsymbol{I}_d$ であるデータの標本固有値ヒストグラムと理論密度 式 (5.9) を重ねてある。γ が大きいほど台が広がり、$\gamma = 1$ では下端が 0 に達する。

注意 5.13 (なぜ半円則ではないのか)**.** Wigner の半円則は、成分が独立な対称ランダム行列の固有値分布が $[-2, 2]$ 上の半円になるという定理である。$\widehat{\boldsymbol{\Sigma}}$ がこれに従わない理由は二つある。第一に $\widehat{\boldsymbol{\Sigma}}$ は半正定値で固有値が非負なので原点対称の台はあり得ない。第二に $\hat{\Sigma}_{jk} = \frac{1}{n}\sum_i X_{ij}X_{ik}$ は同じ X_{ij} を複数の (j,k) で共有し、成分が独立でない。なお $\gamma \to 0$ では $\sqrt{n/d}(\widehat{\boldsymbol{\Sigma}} - \boldsymbol{I})$ の固有値分布が半円則に従う——半円則は MP 則の「γ が小さいときのゆらぎ」を記述しているので、両者は矛盾しない。

図 5.4は $\gamma = d/n = 0.1, 0.5, 1.0$ について、真の共分散が $\boldsymbol{I}_d$ であるデータの標本固有値ヒストグラムに(5.9)の理論密度を重ねたものである。γ が大きいほど台が広がり、$\gamma = 1$ では左端が 0 に達する。真の固有値がすべて 1 なのに標本固有値が広い区間に散らばる——これが高次元で標本共分散を信用してはいけない理由の核心である。

例 5.14 (台の広がり)**.** $\gamma = 0.5$（$n = 4000$、$d = 2000$）では $\lambda_- = 0.0858$、$\lambda_+ = 2.914$。真の固有値はすべて 1 なのに、標本固有値は**最大と最小で** 34 **倍**散らばる。$\gamma = 1$（$n = d$）では $\lambda_- = 0$、$\lambda_+ = 4$ となり、$\widehat{\boldsymbol{\Sigma}}$ はほぼ特異になる。

スクリープロットの読み方に注意

3.6節で見たスクリープロットに大きな固有値がいくつか見えても、それが信号の証拠だとは限らない。$\gamma = 0.5$ なら**完全に構造のないノイズでも**最大固有値は 2.9 になる。判定の基準は「1 より大きいか」ではなく「$\lambda_+ = (1+\sqrt{\gamma})^2$ より大きいか」である。自分のデータの $\gamma = d/n$ から λ_+ を計算してからスクリープロットを見る習慣をつけたい。

リスト 5.2　Marchenko–Pastur 則の数値確認。真の共分散が単位行列のデータを生成し、標本固有値の範囲を理論の台と比べる。

```
import numpy as np
rng = np.random.default_rng(0)
n, d = 4000, 2000
gamma = d / n
X = rng.standard_normal((d, n))          # d×n：列がサンプル、真の共分散は I_d
S = X @ X.T / n                          # 標本共分散（d×d）
ev = np.linalg.eigvalsh(S)
lam_m, lam_p = (1 - np.sqrt(gamma))**2, (1 + np.sqrt(gamma))**2
print(f"理論の台 [{lam_m:.4f}, {lam_p:.4f}]")
print(f"実測の範囲 [{ev.min():.4f}, {ev.max():.4f}]")

def mp_density(x, g):                    # 式 (5.9) をそのまま実装
    lm, lp = (1 - np.sqrt(g))**2, (1 + np.sqrt(g))**2
    return np.where((x > lm) & (x < lp),
                    np.sqrt(np.maximum((lp - x) * (x - lm), 0)) / (2*np.pi*g*x), 0.0)
grid = np.linspace(lam_m, lam_p, 2001)
print("密度の積分 =", np.trapezoid(mp_density(grid, gamma), grid))
```

理論の台 $[0.0858, 2.9142]$ に対し実測は $[0.0861, 2.9017]$ で、有限サイズ効果でわずかに内側に寄るものの一致する。密度の数値積分は 0.99993 で、式 (5.9) が確率密度であることも確かめられる。

5.6　スパイクモデルと BBP 相転移

MP 則は「信号ゼロ」の基準線を与えた。では信号があるとき PCA はそれを見つけられるか。最も単純な設定が**スパイク共分散モデル**（spiked covariance model）

$$\boldsymbol{\Sigma} = \boldsymbol{I}_d + \theta\, \boldsymbol{v}\boldsymbol{v}^{\top}, \qquad \|\boldsymbol{v}\| = 1,\ \theta > 0 \tag{5.11}$$

である。$\boldsymbol{\Sigma}$ は $d \times d$ の行列である。真の第一主成分方向は $\boldsymbol{v}$、真の最大固有値は $1+\theta$、残りはすべて 1 で、θ が信号強度を表す。標本の生成は $\boldsymbol{X} = \boldsymbol{\Sigma}^{1/2}\boldsymbol{Z} \in \mathbb{R}^{d\times n}$（$\boldsymbol{Z}$ の成分は i.i.d. の $\mathcal{N}(0,1)$）と書ける。階数 1 の摂動なので $\boldsymbol{\Sigma}^{1/2} = \boldsymbol{I}_d + (\sqrt{1+\theta}-1)\boldsymbol{v}\boldsymbol{v}^{\top}$

と陽に書けることを使うと、$d\times d$ 行列の平方根を作らずに $\boldsymbol{X}=\boldsymbol{Z}+(\sqrt{1+\theta}-1)\boldsymbol{v}(\boldsymbol{v}^{\top}\boldsymbol{Z})$ で済む。古典的には「$\theta>0$ なら n を増やせば $\boldsymbol{v}$ は推定できる」はずだが、$d/n\to\gamma$ を保つ限りこれは正しくない。

定理 5.15 (スパイクモデルの相転移（BBP 相転移） [10, 11, 58])**.** 式 (5.11) から n 個のサンプルを取り、$\widehat{\boldsymbol{\Sigma}}$ の最大固有値を $\hat{\lambda}_1$、対応する固有ベクトルを $\hat{\boldsymbol{v}}$ とする。$d/n\to\gamma\in(0,1)$ のとき確率 1 で

$$\hat{\lambda}_1\to\begin{cases}(1+\sqrt{\gamma})^2=\lambda_+, & \theta\le\sqrt{\gamma},\\ (1+\theta)\left(1+\dfrac{\gamma}{\theta}\right), & \theta>\sqrt{\gamma},\end{cases}\qquad \langle\hat{\boldsymbol{v}},\boldsymbol{v}\rangle^2\to\begin{cases}0, & \theta\le\sqrt{\gamma},\\ \dfrac{1-\gamma/\theta^2}{1+\gamma/\theta}, & \theta>\sqrt{\gamma}.\end{cases}\tag{5.12}$$

注意 5.16 (出典の切り分け)**.** この定理は歴史的に三つの仕事に分かれる。相転移という現象そのものを見出したのは Baik–Ben Arous–Péché [10] であり、同論文が扱ったのは**複素**ガウス標本共分散行列の最大固有値の**極限分布**（臨界点前後で Tracy–Widom 分布と Gauss 分布が入れ替わる）である。(5.12)左の**概収束極限**を実ガウスを含む一般のスパイクモデルについて明示したのは Baik–Silverstein [11]、(5.12)右の**固有ベクトルの**相転移と漸近挙動を扱ったのは Paul [58] である。本講義では現象の名前として定着した「BBP 相転移」を用いるが、固有ベクトル側の主張を引くときは Paul を挙げるのが正確である。

証明の筋道. $\widehat{\boldsymbol{\Sigma}}$ をノイズ部分と階数 1 の摂動の和と見る。固有値 λ がノイズの台の外にあるとき、行列式の恒等式 $\det(\boldsymbol{I}+\boldsymbol{AB})=\det(\boldsymbol{I}+\boldsymbol{BA})$ により λ は **永年方程式**

$$\frac{1}{\theta}=\int\frac{x}{\lambda-x}p_\gamma(x)\,\mathrm{d}x=:\Psi(\lambda)\tag{5.13}$$

をみたす。Ψ は $\lambda>\lambda_+$ で単調減少し、$\lambda\to\infty$ で 0、$\lambda\downarrow\lambda_+$ で**有限の**値 $\Psi(\lambda_+)=1/\sqrt{\gamma}$ に近づく。ここが要点で、Ψ が発散しないために解が存在しない領域が生じる。すなわち $\lambda>\lambda_+$ の解をもつのは $\frac{1}{\theta}<\frac{1}{\sqrt{\gamma}}$、つまり $\theta>\sqrt{\gamma}$ のときに限り、そうでなければ最大固有値はバルクの端 λ_+ に張り付く。$\theta>\sqrt{\gamma}$ で 式 (5.13) を解くと $\lambda=(1+\theta)(1+\gamma/\theta)$ を得る。

overlap はレゾルベントの留数計算による。$\langle\hat{\boldsymbol{v}},\boldsymbol{v}\rangle^2$ は $\boldsymbol{v}^{\top}(\widehat{\boldsymbol{\Sigma}}-z\boldsymbol{I})^{-1}\boldsymbol{v}$ の $z=\lambda$ における極の留数 $-1/(\theta^2\Psi'(\lambda))$ に等しく、Ψ を微分して $\lambda=(1+\theta)(1+\gamma/\theta)$ を代入すれば 式 (5.12) の右式になる。省いたのは有限 n での揺らぎが $o(1)$ であることと、閾値近傍の臨界的振る舞い（スケール $n^{-2/3}$ の Tracy–Widom 揺らぎ）の解析である。 ■

数値で確かめておく。$\gamma=0.5$、$\theta=1.5$ なら $\lambda=2.5\cdot\frac{4}{3}=3.333$ で、これを 式 (5.13) の右辺に入れて数値積分すると $\Psi(3.333)=0.66667=1/1.5$ と一致する。$\gamma=0.25$、$\theta=2.5$ でも $\Psi=0.400=1/2.5$ である。

BBP 相転移が意味すること

(1) γ は極限値である。定理 5.15が述べているのは $d,n\to\infty$ かつ $d/n\to\gamma\in(0,1)$ という**比例的高次元極限**での主張であり、γ は有限の d,n から計算される d/n そのものではなくアスペクト比の極限値である。この極限における検出可能性の閾値は

$$\theta_{\mathrm{c}}=\sqrt{\gamma}.$$

(2) $\sqrt{d/n}$ は有限標本での目安である。手元のデータに対しては γ の近似として d/n を用い、

$$\theta_{\mathrm{c}}\approx\sqrt{\frac{d}{n}}$$

を閾値の**目安**として使う。$\theta_{\mathrm{c}}=\sqrt{d/n}$ と等号で結んではいけないが、n と d だけから——すなわち**データを見る前に**——計算できる量で難しさの見当がつくこと自体が、この定理の実用上の価値である。

(3) 閾値以下では無情報である。$\theta\le\sqrt{\gamma}$ なら $\langle\hat{\boldsymbol{v}},\boldsymbol{v}\rangle^2\to0$、つまり PCA の第一主成分は真の方向 $\boldsymbol{v}$ と **漸近的に直交する**。信号があってもまったく拾えない。

(4) 閾値以上でも一般には完全一致しない。$\theta>\sqrt{\gamma}$ でも overlap の極限は $\frac{1-\gamma/\theta^2}{1+\gamma/\theta}<1$ にとどまる。$\gamma=0.5$ なら $\theta=1,2,5,10$ に対し 0.333, 0.700, 0.891, 0.948 で、$\theta\to\infty$ で 1 に近づくが有限の θ では届かない。したがって正しい読み方は「閾値の下では改善しない」ではなく、**比例的高次元極限では PCA の固有ベクトルは（古典的な意味での）一致推定量にならない**——閾値以下では無情報、閾値以上でも一致はしない——である。γ を固定したまま n を増やしても、d が同じオーダーで増える限りこの極限値は変わらない。

古典的な漸近（d 固定で $n\to\infty$）は $\gamma\to0$ に対応し、このとき overlap の極限は 1 に戻る。実際 $\theta=2$ を固定して $\gamma=0.5, 0.1, 0.01$ と下げると 0.700, 0.929, 0.993 と 1 に近づく。一致性が失われるのは高次元そのものではなく、d **が** n **に比例して増えること**が原因である、というのがこの節の含意である。

図 5.5はこの相転移を数値実験と理論曲線で比べたものである。θ を上げていくと、閾値 $\sqrt{\gamma}$ を越えた途端に真の方向との重なりが 0 から立ち上がる。閾値の手前では n を増やしても（γ を保つ限り）重なりは改善しない。

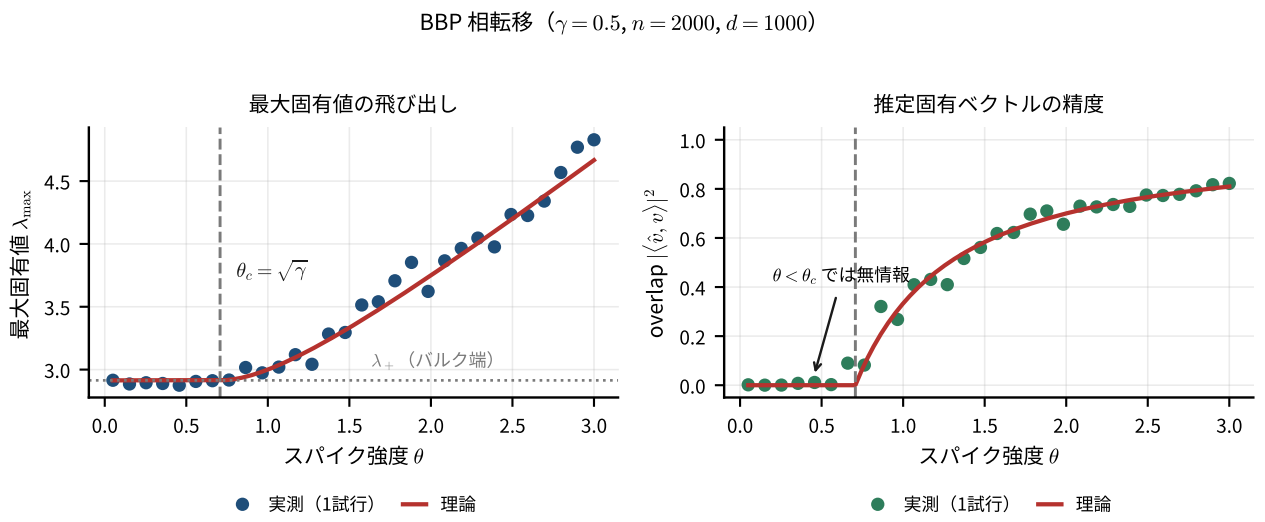


図5.5　BBP 相転移。スパイク強度 θ に対する標本最大固有値と真の方向との重なりを数値実験と理論曲線 式 (5.12) で比べたもの。$\theta = \sqrt{\gamma}$ を境に、それまで 0 に張り付いていた重なりが立ち上がる。

リスト 5.3　BBP 相転移の数値確認。スパイク共分散 $\boldsymbol{I}_d + \theta \boldsymbol{v}\boldsymbol{v}^\top$ からデータを生成し、最大固有値と真の方向との重なりを理論値と比べる。

```
import numpy as np

def spike_experiment(theta, n=2000, d=1000, seed=0):
    rng = np.random.default_rng(seed)
    v = np.zeros(d); v[0] = 1.0
    Z = rng.standard_normal((d, n))                       # d×n：列がサンプル
    X = Z + (np.sqrt(1 + theta) - 1) * np.outer(v, v @ Z)  # X = Sigma^{1/2} Z
    S = X @ X.T / n                                       # 標本共分散（d×d）
    lam, U = np.linalg.eigh(S)
    return lam[-1], (U[:, -1] @ v)**2    # 最大固有値と overlap^2

g = 1000 / 2000                          # gamma = 0.5, 閾値 sqrt(g) = 0.707
for theta in [0.3, 0.5, 0.707, 1.0, 1.5, 2.0]:
    lam1, ov2 = spike_experiment(theta)
    if theta > np.sqrt(g):               # 式 (5.12) の理論値
        lam_th = (1 + theta) * (1 + g / theta)
        ov_th  = (1 - g / theta**2) / (1 + g / theta)
    else:
        lam_th, ov_th = (1 + np.sqrt(g))**2, 0.0
    print(f"theta={theta:5.3f} lam1={lam1:6.3f}({lam_th:6.3f})"
          f" ov2={ov2:6.3f}({ov_th:6.3f})")
```

実測を $(\hat{\lambda}_1, \mathrm{ov}^2)$ の形で、括弧内に理論値を添えて示す。$\theta = 0.3$: 2.855 (2.914), 0.000 (0)；$\theta = 0.5$: 2.858 (2.914), 0.035 (0)；$\theta = 0.707$: 2.883 (2.914), 0.120 (0)；$\theta = 1.0$: 2.989 (3.000), 0.346 (0.333)；$\theta = 1.5$: 3.330 (3.333), 0.594 (0.583)；$\theta = 2.0$: 3.752 (3.750), 0.707 (0.700)。閾値の十分下（$\theta = 0.3$）では重なりが 10^{-3} を切り、実質的に直交している。閾値 $\sqrt{\gamma} \approx 0.707$ の近傍で 0 から離れるのは有限 n の効果で、遷移は $n \to \infty$ でのみ鋭くなる。

実務での使い方はこうである。$n = 200$ サンプル、$d = 20000$ 遺伝子なら $d/n = 100$、閾値の目安は $\theta_{\mathrm{c}} \approx 10$、つまり第一主成分方向の分散が背景の 11 倍以上ないと検出できない。d を 2000 遺伝子に絞れば $d/n = 10$、$\theta_{\mathrm{c}} \approx 3.2$ に下がる。**変数を減らすことが検出力を上げる**——高次元では情報を捨てるのが得になる場面がある。

ただしこの見積もりは二重に目安である。第一に、上の keybox (2) のとおり $\sqrt{d/n}$ は極限値 $\sqrt{\gamma}$ の近似である。第二に、$d/n > 1$ は 定理 5.15の仮定 $\gamma \in (0, 1)$ の外にある（固有ベクトルの主張を与えた Paul [58] は $\gamma < 1$ を仮定している）。閾値 $\sqrt{\gamma}$ 自体は $\gamma > 1$ でも成り立つことが知られているが（$d > n$ では $\widehat{\boldsymbol{\Sigma}}$ が特異で、非零固有値の側で同じ端 λ_+ を見ることになる）、本書の定理としては $\gamma < 1$ で述べてあることに注意されたい。桁の見当をつける道具として使うのが正しい使い方である。

5.7　共分散行列の推定と縮小

MP 則は標本共分散の欠陥を定量化した。$\gamma > 0$ である限り、大きい固有値は上に、小さい固有値は下に偏り、$d > n$ では $d - n$ 個が 0 になって $\widehat{\boldsymbol{\Sigma}}$ は特異である。$\widehat{\boldsymbol{\Sigma}}^{-1}$ を使う手法（判別分析、ポートフォリオ最適化、Gauss 過程回帰）は小さい固有値の下方バイアスに直撃される。処方箋は**縮小**（shrinkage）である。

定義 5.17 (Ledoit–Wolf の線形縮小 [47])**.** $\mu := \frac{1}{d}\operatorname{tr}\widehat{\boldsymbol{\Sigma}}$、$\rho \in [0, 1]$ として $\widehat{\boldsymbol{\Sigma}}_{\mathrm{LW}}(\rho) := (1 - \rho)\widehat{\boldsymbol{\Sigma}} + \rho\,\mu\,\boldsymbol{I}_d$。

$\rho=0$ で標本共分散、$\rho=1$ で「全方向に等分散」という最も単純な推定量である。

縮小の効き方を定量化するには、まず **target を固定した**場合を調べるのが正しい。μ 自体がデータの関数であることは後で扱う。

定理 5.18（オラクル縮小率（決定論的 target））**.** $\boldsymbol{T}\in\mathbb{R}^{d\times d}$ を**データに依存しない**（決定論的な）対称行列とし、$\widehat{\boldsymbol{\Sigma}}$ は不偏、すなわち $\mathbb{E}\widehat{\boldsymbol{\Sigma}}=\boldsymbol{\Sigma}$ とする。$\widehat{\boldsymbol{\Sigma}}(\rho)\coloneqq(1-\rho)\widehat{\boldsymbol{\Sigma}}+\rho\boldsymbol{T}$ に対し

$$\beta^2\coloneqq\mathbb{E}\|\widehat{\boldsymbol{\Sigma}}-\boldsymbol{\Sigma}\|_{\mathrm{F}}^2,\qquad \alpha^2\coloneqq\|\boldsymbol{T}-\boldsymbol{\Sigma}\|_{\mathrm{F}}^2,\qquad \delta^2\coloneqq\mathbb{E}\|\widehat{\boldsymbol{\Sigma}}-\boldsymbol{T}\|_{\mathrm{F}}^2$$

とおく。$\beta^2+\alpha^2>0$ ならば Frobenius 損失 $L(\rho)\coloneqq\mathbb{E}\|\widehat{\boldsymbol{\Sigma}}(\rho)-\boldsymbol{\Sigma}\|_{\mathrm{F}}^2$ を $\rho\in[0,1]$ で最小にするのは

$$\rho^\star=\frac{\beta^2}{\alpha^2+\beta^2}=\frac{\beta^2}{\delta^2}\in[0,1] \tag{5.14}$$

であり、$L(\rho^\star)=(1-\rho^\star)\beta^2\le\beta^2=L(0)$。等号は $\alpha^2=0$（$\boldsymbol{T}=\boldsymbol{\Sigma}$）のときのみ。

証明. $\widehat{\boldsymbol{\Sigma}}(\rho)-\boldsymbol{\Sigma}=(1-\rho)(\widehat{\boldsymbol{\Sigma}}-\boldsymbol{\Sigma})+\rho(\boldsymbol{T}-\boldsymbol{\Sigma})$ を Frobenius 内積で展開すると

$$L(\rho)=(1-\rho)^2\beta^2+2\rho(1-\rho)\,\mathbb{E}\langle\widehat{\boldsymbol{\Sigma}}-\boldsymbol{\Sigma},\boldsymbol{T}-\boldsymbol{\Sigma}\rangle_{\mathrm{F}}+\rho^2\alpha^2.$$

$\boldsymbol{T}-\boldsymbol{\Sigma}$ は**定数**行列だから内積の期待値の中で外に出せて、$\mathbb{E}\langle\widehat{\boldsymbol{\Sigma}}-\boldsymbol{\Sigma},\boldsymbol{T}-\boldsymbol{\Sigma}\rangle_{\mathrm{F}}=\langle\mathbb{E}\widehat{\boldsymbol{\Sigma}}-\boldsymbol{\Sigma},\boldsymbol{T}-\boldsymbol{\Sigma}\rangle_{\mathrm{F}}=0$（ここで不偏性 $\mathbb{E}\widehat{\boldsymbol{\Sigma}}=\boldsymbol{\Sigma}$ を使う）。よって $L(\rho)=(1-\rho)^2\beta^2+\rho^2\alpha^2$ は ρ の凸二次関数で、$L'(\rho)=-2(1-\rho)\beta^2+2\rho\alpha^2=0$ から $\rho^\star=\beta^2/(\alpha^2+\beta^2)\in[0,1]$。同じ交差項が消えることから Pythagoras の関係 $\delta^2=\mathbb{E}\|(\widehat{\boldsymbol{\Sigma}}-\boldsymbol{\Sigma})+(\boldsymbol{\Sigma}-\boldsymbol{T})\|_{\mathrm{F}}^2=\beta^2+\alpha^2$ が従うので (5.14)の第二の表示を得る。最適値は $L(\rho^\star)=\frac{\alpha^2\beta^2}{\alpha^2+\beta^2}=(1-\rho^\star)\beta^2$。 ■

target をデータから決めると上の証明は使えない

定義 5.17の $\mu=\frac{1}{d}\operatorname{tr}\widehat{\boldsymbol{\Sigma}}$ は**データの関数**なので、$\boldsymbol{T}=\mu\boldsymbol{I}$ に定理 5.18をそのまま適用してはいけない。交差項 $\mathbb{E}\langle\widehat{\boldsymbol{\Sigma}}-\boldsymbol{\Sigma},\mu\boldsymbol{I}-\boldsymbol{\Sigma}\rangle_{\mathrm{F}}$ は μ と $\widehat{\boldsymbol{\Sigma}}$ の相関のぶん一般に 0 にならない。極端な例として $d=1$ を取ると $\mu=\widehat{\boldsymbol{\Sigma}}$ だから $\widehat{\boldsymbol{\Sigma}}_{\mathrm{LW}}(\rho)=(1-\rho)\widehat{\boldsymbol{\Sigma}}+\rho\widehat{\boldsymbol{\Sigma}}=\widehat{\boldsymbol{\Sigma}}$ となり、損失は ρ に**まったく依存しない**。実際 $n=50$、$\boldsymbol{\Sigma}=1$ で 2000 回の試行を共通乱数で比べると $\rho=0,0.3,0.7,1$ のいずれでも損失は 0.0389271 で一致する。このとき $\delta^2=\mathbb{E}\|\widehat{\boldsymbol{\Sigma}}-\mu\boldsymbol{I}\|_{\mathrm{F}}^2=0$ なので (5.14)の $\rho^\star=\beta^2/\delta^2$ は**定義すらできない**。さらに本書の $\widehat{\boldsymbol{\Sigma}}=\frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top$ は標本平均で中心化しているので $\mathbb{E}\widehat{\boldsymbol{\Sigma}}=\frac{n-1}{n}\boldsymbol{\Sigma}\neq\boldsymbol{\Sigma}$ であり、不偏性の仮定も満たさない（$n=50$、$\boldsymbol{\Sigma}=\boldsymbol{I}_3$ で 2 万回平均すると対角は 0.980、理論値 $(n-1)/n=0.980$ と一致する）。不偏にしたいなら分母を $n-1$ に取る。

それでは定義 5.17の縮小はどう正当化されるのか。Ledoit–Wolf [47] の主張はオラクル最適性ではなく**漸近的**なものである。$d,n\to\infty$、$d/n\to\gamma$ の枠組みで、μ は真の平均分散 $\frac{1}{d}\operatorname{tr}\boldsymbol{\Sigma}$ に確率収束し、$\alpha^2,\beta^2,\delta^2$ の一致推定量

$$\hat\delta^2=\|\widehat{\boldsymbol{\Sigma}}-\hat\mu\boldsymbol{I}\|_{\mathrm{F}}^2,\qquad \hat\beta^2=\min\Big\{\frac{1}{n^2}\sum_{i=1}^n\|\tilde{\boldsymbol{x}}_i\tilde{\boldsymbol{x}}_i^\top-\widehat{\boldsymbol{\Sigma}}\|_{\mathrm{F}}^2,\ \hat\delta^2\Big\}$$

を代入した $\hat\rho=\hat\beta^2/\hat\delta^2$ が、決定論的 target $\boldsymbol{T}=\big(\frac{1}{d}\operatorname{tr}\boldsymbol{\Sigma}\big)\boldsymbol{I}$ に対するオラクル率 $\rho^\star$ に収束する。つまり定理 5.18は d が大きいときの**目標**を与える定理であり、有限標本で $\mu\boldsymbol{I}$ を使うことの最適性を主張するものではない。$\hat\beta^2$ に $\hat\delta^2$ との min が入っているのは $\hat\rho\le1$ を保証するためである。

例 5.19. $n=60$、$d=40$（$\gamma=0.67$）、真の共分散 $\boldsymbol{I}_{40}$ のデータ（$\boldsymbol{X}\in\mathbb{R}^{40\times60}$、$\widetilde{\boldsymbol{X}}=\boldsymbol{X}\boldsymbol{H}$、$\widehat{\boldsymbol{\Sigma}}=\frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top$）で上の推定量を計算すると $\hat\rho=0.9637$。標本共分散の固有値は $[0.0195,2.919]$ と大きく開くのに対し縮小後は $[0.950,1.055]$ と真値 1 の近くに集まり、条件数は 150 から 1.11 へ改善する。`sklearn.covariance.LedoitWolf` は $n\times d$ 規約なので `LedoitWolf().fit(X.T)` と転置して渡す必要があり、その `shrinkage_` は上の $\hat\rho$ と 7×10^{-16} の精度で一致する。

図 5.6は、標本固有値が真値に対して上下に開くバイアスと、線形縮小後の固有値の集中を並べたものである。縮小は大きい固有値を下げ小さい固有値を上げる向きに働き、MP 則が予言する歪みをちょうど打ち消している。

線形縮小は全固有値を同率で μ に寄せるが、MP 則が教える歪みは固有値の大きさに依存する。そこで固有ベクトルは変えず固有値だけを $\hat\lambda\mapsto\psi(\hat\lambda)$ と補正する**非線形縮小**が考えられ、最適な ψ は Stieltjes 変換 s を使って $\psi(\lambda)=\lambda/|1-\gamma-\gamma\lambda s(\lambda)|^2$ と陽に書ける（Ledoit–Péché の公式）。実装では s を経験固有値から推定する。

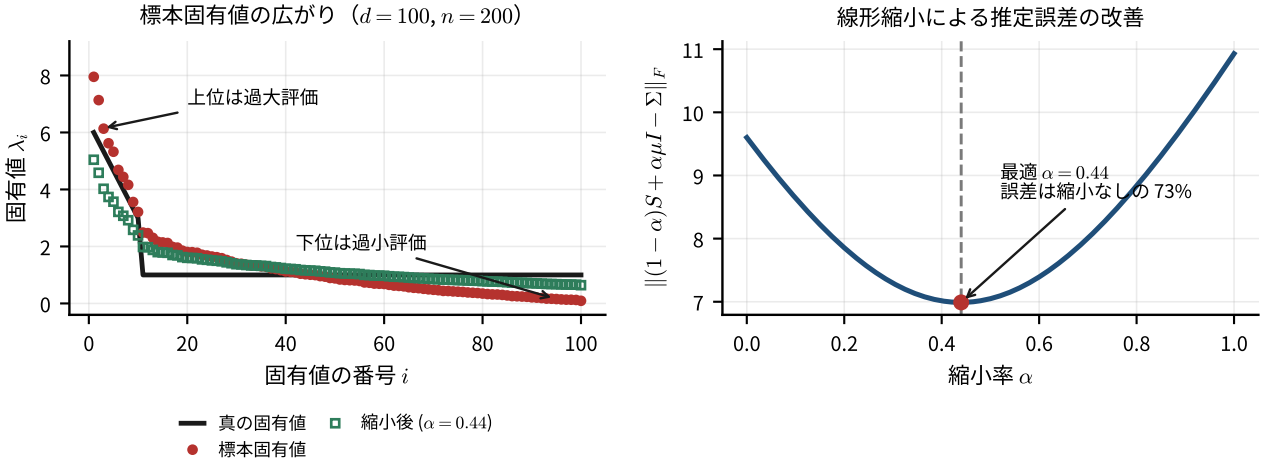


図5.6　共分散行列の縮小推定。標本固有値が真値に対して上下に開くバイアスと、線形縮小後の固有値の集中を比べている。縮小は大きい固有値を下げ小さい固有値を上げ、MP 則が予言する歪みをちょうど打ち消す向きに働く。

5.8　摂動論：固有値と固有ベクトルの安定性

BBP 相転移が示したのは「ノイズで固有ベクトルが壊れる」ことだった。壊れ方を一般に支配するのが摂動論であり、第4章で述べた「固有値が近接すると主成分方向が不安定になる」事実の裏付けがここで得られる。

定理 5.20 (Weyl の不等式)**.** $\boldsymbol{A}, \boldsymbol{E}$ を対称行列、λ_i を $\boldsymbol{A}$ の、$\tilde\lambda_i$ を $\boldsymbol{A}+\boldsymbol{E}$ の（降順の）固有値とすると $\max_i |\tilde\lambda_i - \lambda_i| \le \|\boldsymbol{E}\|_{\mathrm{op}}$。

証明. Courant–Fischer の最小最大原理 $\lambda_i = \max_{\dim V = i} \min_{\boldsymbol{w}\in V, \|\boldsymbol{w}\|=1} \boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w}$ を使う。任意の単位ベクトルで $\boldsymbol{w}^\top(\boldsymbol{A}+\boldsymbol{E})\boldsymbol{w} \le \boldsymbol{w}^\top\boldsymbol{A}\boldsymbol{w} + \|\boldsymbol{E}\|_{\mathrm{op}}$ だから、任意の i 次元部分空間 V で $\min_{\boldsymbol{w}\in V} \boldsymbol{w}^\top(\boldsymbol{A}+\boldsymbol{E})\boldsymbol{w} \le \min_{\boldsymbol{w}\in V} \boldsymbol{w}^\top\boldsymbol{A}\boldsymbol{w} + \|\boldsymbol{E}\|_{\mathrm{op}}$、$V$ について最大を取って $\tilde\lambda_i \le \lambda_i + \|\boldsymbol{E}\|_{\mathrm{op}}$。$\boldsymbol{A}$ と $\boldsymbol{A}+\boldsymbol{E}$ の役割を入れ替え $-\boldsymbol{E}$ を摂動と見れば逆向きも従う。 ■

固有値は Lipschitz 定数 1 で安定である。固有**ベクトル**はそうではない。

定理 5.21 (Davis–Kahan の $\sin\Theta$ 定理、単一固有ベクトル版 [28])**.** $\boldsymbol{A}$ を対称、$\lambda_1 > \lambda_2 \ge \cdots$、$\boldsymbol{v}_1$ を λ_1 の単位固有ベクトル、$\tilde{\boldsymbol{v}}_1$ を $\boldsymbol{A}+\boldsymbol{E}$ の最大固有値の単位固有ベクトルとする。ギャップを $\Delta := \lambda_1 - \lambda_2 > 0$、$\theta := \angle(\boldsymbol{v}_1, \tilde{\boldsymbol{v}}_1) \in [0, \pi/2]$ とすると

$$\sin\theta \;\le\; \frac{2\|\boldsymbol{E}\|_{\mathrm{op}}}{\Delta}. \tag{5.15}$$

証明. 符号を選んで $\langle \boldsymbol{v}_1, \tilde{\boldsymbol{v}}_1\rangle \ge 0$ とし、$\tilde{\boldsymbol{v}}_1 = c\,\boldsymbol{v}_1 + s\,\boldsymbol{w}$（$c=\cos\theta$, $s=\sin\theta$, $\boldsymbol{w}\perp\boldsymbol{v}_1$, $\|\boldsymbol{w}\|=1$）と分解する。$(\boldsymbol{A}+\boldsymbol{E})\tilde{\boldsymbol{v}}_1 = \tilde\lambda_1\tilde{\boldsymbol{v}}_1$ より $(\boldsymbol{A}-\tilde\lambda_1\boldsymbol{I})\tilde{\boldsymbol{v}}_1 = -\boldsymbol{E}\tilde{\boldsymbol{v}}_1$ で、右辺のノルムは $\|\boldsymbol{E}\|_{\mathrm{op}}$ 以下。左辺は

$$\|(\boldsymbol{A}-\tilde\lambda_1\boldsymbol{I})\tilde{\boldsymbol{v}}_1\|^2 = c^2(\lambda_1-\tilde\lambda_1)^2 + s^2\|(\boldsymbol{A}-\tilde\lambda_1\boldsymbol{I})\boldsymbol{w}\|^2 \;\ge\; s^2 \min_{i\ge 2}|\lambda_i - \tilde\lambda_1|^2,$$

ここで $\boldsymbol{w}\perp\boldsymbol{v}_1$ より $\boldsymbol{A}$ の $\boldsymbol{v}_1^\perp$ への制限の固有値が $\lambda_2, \dots, \lambda_d$ であることを使った。Weyl の不等式より $\tilde\lambda_1 \ge \lambda_1 - \|\boldsymbol{E}\|_{\mathrm{op}}$ なので、$i\ge 2$ で $\tilde\lambda_1 - \lambda_i \ge \lambda_1 - \lambda_2 - \|\boldsymbol{E}\|_{\mathrm{op}} = \Delta - \|\boldsymbol{E}\|_{\mathrm{op}}$。まとめて $s(\Delta - \|\boldsymbol{E}\|_{\mathrm{op}}) \le \|\boldsymbol{E}\|_{\mathrm{op}}$。$\|\boldsymbol{E}\|_{\mathrm{op}} \le \Delta/2$ なら $\Delta - \|\boldsymbol{E}\|_{\mathrm{op}} \ge \Delta/2$ より $s \le 2\|\boldsymbol{E}\|_{\mathrm{op}}/\Delta$、$\|\boldsymbol{E}\|_{\mathrm{op}} > \Delta/2$ なら右辺が 1 を超えるので $s\le 1$ から自明に成立する。 ■

ギャップがすべてを決める

固有値の推定誤差は $\|\boldsymbol{E}\|_{\mathrm{op}}$ で押さえられる（絶対的）が、固有ベクトルの誤差は $\|\boldsymbol{E}\|_{\mathrm{op}}/\Delta$ で押さえられる（相対的）。$\Delta \to 0$ で界は意味を失う。実際 $\lambda_1 = \lambda_2$ なら固有ベクトルはその二次元固有空間内で自由に回転でき、そもそも一意に定まらない。

例 5.22 (2×2 で見るギャップの効果)**.** $\boldsymbol{A} = \mathrm{diag}(1+\Delta, 1)$、$\boldsymbol{E} = \left(\begin{smallmatrix} 0 & \eta \\ \eta & 0 \end{smallmatrix}\right)$ とすると、$\boldsymbol{A}+\boldsymbol{E}$ の固有ベクトルは $\tan 2\theta = 2\eta/\Delta$ をみたす角 θ だけ座標軸から回転する。$\Delta = 1$, $\eta = 0.01$ なら $\theta \approx 0.57^\circ$ とほぼ動かないが、$\Delta = 0.02$, $\eta = 0.01$ なら $\tan 2\theta = 1$ すなわち $\theta = 22.5^\circ$ と大きく傾く。$\|\boldsymbol{E}\|_{\mathrm{op}} = \eta$ は同じでも、ギャップが 1/50 になると方向の誤差は 40 倍近い。なお BBP 相転移は Davis–Kahan の界が破れた例ではない。$\theta < \sqrt{\gamma}$ ではスパイクがバルクに埋もれて実効的ギャップが $\Delta \approx 0$ になり、界の右辺が 1 を超えて何も言わなくなるだけである。$\theta > \sqrt{\gamma}$ では正のギャップが生じ、式 (5.12) が界の中で実際に達成される値を教えてくれる。

5.9　高次元の良い面

命題 5.8を裏返すと次の強力な事実が出る。

定理 5.23 (ほとんど直交な方向は指数的に多い)**.** $\varepsilon \in (0,1)$ に対し、単位ベクトルの族 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_N$ で $|\langle \boldsymbol{u}_i, \boldsymbol{u}_j \rangle| \le \varepsilon$ $(i \neq j)$ をみたすものが $N \ge \frac{1}{2} e^{d\varepsilon^2/4}$ 個存在する。

証明. 確率的方法による。$\boldsymbol{u}_1, \dots, \boldsymbol{u}_N$ を $\mathbb{S}^{d-1}$ 上の独立一様乱数とすると 命題 5.8 より各対の失敗確率は $2e^{-d\varepsilon^2/2}$ 以下。$\binom{N}{2} < N^2/2$ 対に union bound を取ると $\mathbb{P}(\text{失敗}) < N^2 e^{-d\varepsilon^2/2}$。$N = \frac{1}{2} e^{d\varepsilon^2/4}$ とすればこれは $1/4 < 1$ となり、条件をみたす族が確率正で存在する。すなわち存在する。 ∎

厳密に直交するベクトルは d 本しか取れない。ところが「ε の範囲でほとんど直交」を許すと本数が d の**指数関数**に跳ね上がる。$d = 1000$、$\varepsilon = 0.2$ なら $e^{10}/2 \approx 1.1 \times 10^4$ 本である。

集中は資源でもある

高次元では「たまたまぶつかる」ことが起こらない。だからランダムに作った膨大な数の方向がほぼ互いに干渉しない基底として使える。**ランダム特徴**（第11章）：ランダムに引いた m 個の特徴 $\cos(\boldsymbol{w}_j^\top \boldsymbol{x} + b_j)$ がほぼ独立な情報を持つので、m を増やすだけでカーネルを近似できる。**過剰パラメータ化**：パラメータ数がサンプル数を超えても汎化する現象の一因は、高次元パラメータ空間で「データに合う解」が広大な平坦領域を成すことにある。**圧縮センシング**：スパース信号がランダム測定 $O(k \log(d/k))$ 回で復元できるのも、ランダムな部分空間がほぼ直交することの帰結である。

本章をまとめる。第一に、高次元では距離が意味を失う（5.2節と5.3節）。第二に、$d/n = \gamma > 0$ では PCA が信号を取り逃す領域があり、その境界 $\theta = \sqrt{\gamma}$ は事前に計算できる（5.5節と5.6節）。第三に、同じ集中現象が JL 補題やランダム特徴という高次元固有の道具を可能にしている（5.4節と5.9節）。次章ではいったん低次元に戻り、PCA を含む線形手法の全体が一般化固有値問題という一つの型に収まることを見る。

さらに学ぶために

本章は $d/n \to \gamma$ という比例的高次元の枠組みを扱ったが、遺伝子発現データのように d が n より桁違いに大きい **高次元小標本**（high-dimension, low-sample-size, HDLSS）の設定では、$d \to \infty$ で n を固定する別の漸近論が有効である。青嶋・矢田『高次元の統計学』[6] はこの立場からの日本語の入門書で、標本固有値・固有ベクトルの一致性と不一致性、それを回復するノイズ掃き出し法とクロスデータ行列法による高次元 PCA、高次元での平均ベクトルの検定と判別分析を扱う。本章の定理 5.15が「比例的高次元では推定が破綻する境界がある」ことを述べたのに対し、同書は「破綻した推定量をどう作り直すか」を与える点で相補的である。また同書が出発点に置く標本共分散行列の**双対表現**は、本講義の双対 PCA（第4章）と同じ $n \times n$ 側への言い換えである。$\widehat{\boldsymbol{\Sigma}} = \frac{1}{n} \widetilde{\boldsymbol{X}} \widetilde{\boldsymbol{X}}^\top$（$d \times d$）に対し双対側が $\frac{1}{n} \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$（$n \times n$）で、両者の非零固有値は一致する。$d \gg n$ では後者のサイズが n にしかならないので、計算上も理論上もこちらが本質的になる。測度の集中とランダム行列のより体系的な扱いは Vershynin [80]、Wainwright [82]、ランダム行列理論そのものは Bai–Silverstein [9] を参照されたい。

演習問題

演習 5.1 ((★) 単位球の体積と殻)**.** $\varepsilon = 0.05$ とする。d 次元単位球の体積のうち半径 $1-\varepsilon$ の球の外側にある割合 $1-(1-\varepsilon)^d$ が 0.99 を超える最小の d を求めよ。また V_d（式 (5.1)）が最大になる整数 d を求めよ。

演習 5.2 ((★★) ガウスノルムの集中の直接計算)**.** $\boldsymbol{x} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}_d)$ とする。(1) $\mathbb{E}\|\boldsymbol{x}\|^2 = d$、$\mathrm{Var}(\|\boldsymbol{x}\|^2) = 2d$ を示せ。(2) Chebyshev の不等式から $\mathbb{P}(|\|\boldsymbol{x}\|^2 - d| > t\sqrt{2d}) \le 1/t^2$ を導き、式 (5.5) と比べて指数界の優位性を論ぜよ。とくに union bound を n^2 個の事象に取る場面で何が違うかを述べよ。(3) $\mathbb{E}\|\boldsymbol{x}\| = \sqrt{2}\,\Gamma(\frac{d+1}{2})/\Gamma(\frac{d}{2})$ を示し、$d = 10, 100$ で $\sqrt{d}$ との差を数値評価せよ。

演習 5.3 ((★★) ほとんど直交の球面版)**.** $\boldsymbol{u}, \boldsymbol{v}$ を $\mathbb{S}^{d-1}$ 上の独立一様乱数、$t = \langle \boldsymbol{u}, \boldsymbol{v} \rangle$ とする。t の密度が $c_d (1-t^2)^{(d-3)/2}$ $(-1 \le t \le 1)$ であることを、$\boldsymbol{v} = \boldsymbol{e}_1$ と固定して示せ。また $\mathrm{Var}(t) = 1/d$ を示し、式 (5.6) と整合することを確かめよ。

演習 5.4 ((★★) JL の定数の最適化)**.** 定理 5.9 の証明で、式 (5.5) の鋭い形 $2\exp(-\frac{m}{4}(\varepsilon^2 - \varepsilon^3))$ を用いて必要な m の下界を ε, n の式で書け。$\varepsilon = 0.1$、$n = 10^5$ で数値を求めよ。また失敗確率の要求を $1/n$ から $1/2$ に緩めると m がどれだけ下がるか比べよ。

演習 5.5 ((★★★) MP 則のモーメント)**.** MP 分布 式 (5.9) について $\int x\, p_\gamma(x)\,\mathrm{d}x = 1$ と $\int x^2 p_\gamma(x)\,\mathrm{d}x = 1+\gamma$ を示し、分散が γ であることを導け。（ヒント：$\frac{1}{d}\mathbb{E}\,\mathrm{tr}\,\widehat{\boldsymbol{\Sigma}}$ と $\frac{1}{d}\mathbb{E}\,\mathrm{tr}\,\widehat{\boldsymbol{\Sigma}}^2$ を直接計算して経験分布のモーメントと対応づけるのが簡明である。）

$\gamma \to 0$ で何が起こるかを述べよ。

演習 5.6 ((⋆⋆) 実装：MP 則の数値確認)**.** $\gamma = 0.1, 0.5, 1.0$ について $n = 4000$、$d = \gamma n$ とし、$\mathcal{N}(\mathbf{0}, \boldsymbol{I}_d)$ から生成したデータの標本固有値ヒストグラムに理論密度 式 (5.9) を重ねよ。さらに標本最大固有値が λ_+ にどれだけ近いかを $n = 500, 1000, 2000, 4000$ で調べ、差が $n^{-2/3}$ 程度で縮むこと（Tracy–Widom 揺らぎ）を確認せよ。

演習 5.7 ((⋆⋆) 実装：JL の数値確認)**.** $n = 1000$ 点を $d = 5000$ 次元の標準正規から生成し、$m = 2^k$（$k = 5, \dots, 11$）でガウスランダム射影を行い、全点対距離の相対歪みの 95 パーセンタイルを求めよ。両対数プロットで傾きが $-1/2$ になることを確認し、演習 5.4の理論値と比べよ。さらに $\boldsymbol{R}$ の成分を $\pm 1/\sqrt{m}$ の一様な符号に変えても結果がほとんど変わらないことを確かめよ。

演習 5.8 ((⋆⋆⋆) 実装：BBP 相転移の数値確認)**.** $\gamma = 0.5$（$n = 2000$、$d = 1000$）で θ を 0 から 3 まで動かし、$\hat{\lambda}_1$ と $\langle \hat{\boldsymbol{v}}, \boldsymbol{v} \rangle^2$ を 20 回平均で求めてプロットし、理論曲線 式 (5.12) を重ねて $\theta_{\mathrm{c}} = \sqrt{0.5} \approx 0.707$ での折れ曲がりを確認せよ。次に $\gamma = 0.1$ と $\gamma = 2.0$ でも同じことを行い、閾値が $\sqrt{\gamma}$ とともに動くことを確かめよ。$\gamma > 1$ では何が起こるか論ぜよ。

第 6 章

一般化固有値問題と線形手法の広がり

この章のねらい

第1章で予告した第二の統一的枠組み——Rayleigh 商の最大化、すなわち一般化固有値問題 $\boldsymbol{A}\boldsymbol{w} = \lambda \boldsymbol{B}\boldsymbol{w}$——をここで回収する。主成分分析、正準相関分析、フィッシャー判別分析、多次元尺度構成法、スペクトラルクラスタリングという一見ばらばらな五つの手法が、$\boldsymbol{A}$ と $\boldsymbol{B}$ の選び方だけで互いに移り合うことを示す。章末の一覧表がこの章の要であり、第8章でこれら全部がカーネル化されることの下敷きにもなる。[a]

[a] この章の計算は演習ノートブック `ch06_geneig.ipynb` で再現できる。インストール不要で実行するには Google Colab で開く：`https://colab.research.google.com/github/yusukeimoto/data-analysis-math-demos/blob/main/notebooks/ch06_geneig.ipynb`

6.1　一般化固有値問題

第3章の PCA は「分散 $\boldsymbol{w}^\top \widehat{\boldsymbol{\Sigma}} \boldsymbol{w}$ を $\|\boldsymbol{w}\| = 1$ の下で最大化する」問題だった。しかし実際には、最大化したい量と「大きさ 1」を測る基準が別々に与えられることが多い。判別分析ではクラス間のばらつきを大きくしたいがクラス内のばらつきで割って評価したいし、正準相関分析では二つのビューの共分散を大きくしたいが各ビューの分散で正規化したい。いずれも「二つの二次形式の比」を最大化する問題である。

定義 6.1 (一般化固有値問題)**.** $\boldsymbol{A} \in \mathbb{R}^{p\times p}$ を対称、$\boldsymbol{B} \in \mathbb{R}^{p\times p}$ を正定値対称とする。

$$\boldsymbol{A}\boldsymbol{w} = \lambda \boldsymbol{B}\boldsymbol{w}, \qquad \boldsymbol{w} \neq \boldsymbol{0} \tag{6.1}$$

をみたす $(\lambda, \boldsymbol{w})$ を、対 $(\boldsymbol{A}, \boldsymbol{B})$ の**一般化固有値**（generalized eigenvalue）と**一般化固有ベクトル**という。

また $\boldsymbol{B}$ を正定値対称とするとき

$$\mathcal{R}(\boldsymbol{w}) \coloneqq \frac{\boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w}}{\boldsymbol{w}^\top \boldsymbol{B}\boldsymbol{w}}, \qquad \boldsymbol{w} \neq \boldsymbol{0} \tag{6.2}$$

を**一般化 Rayleigh 商**という（$\boldsymbol{B} = \boldsymbol{I}$ で通常の Rayleigh 商）。

(6.2)の分母は**内積を取り替えたときの長さの二乗**として読める。$\boldsymbol{B}$ が正定値対称のとき

$$\langle \boldsymbol{x}, \boldsymbol{y} \rangle_{\boldsymbol{B}} \coloneqq \boldsymbol{x}^\top \boldsymbol{B}\boldsymbol{y}, \qquad \|\boldsymbol{x}\|_{\boldsymbol{B}} \coloneqq \sqrt{\langle \boldsymbol{x}, \boldsymbol{x} \rangle_{\boldsymbol{B}}} \tag{6.3}$$

は2.2節の標準内積と同じ三つの性質（対称性・双線形性・正定値性）をみたす。$\langle \boldsymbol{x}, \boldsymbol{y} \rangle_{\boldsymbol{B}} = \langle \boldsymbol{y}, \boldsymbol{x} \rangle_{\boldsymbol{B}}$ は $\boldsymbol{B}$ の対称性、双線形性は行列積の線形性、$\langle \boldsymbol{x}, \boldsymbol{x} \rangle_{\boldsymbol{B}} = \boldsymbol{x}^\top \boldsymbol{B}\boldsymbol{x} > 0$（$\boldsymbol{x} \neq \boldsymbol{0}$）は正定値性による。したがって2.2節の議論——Cauchy–Schwarz、三角不等式、角度、直交、直交射影——がそのまま $\boldsymbol{B}$-内積について成り立つ。これを **$\boldsymbol{B}$-内積**、$\langle \boldsymbol{x}, \boldsymbol{y} \rangle_{\boldsymbol{B}} = 0$ を **$\boldsymbol{B}$-直交**という。この言葉で書けば(6.2)は「$\boldsymbol{B}$-内積で測って長さ 1 の $\boldsymbol{w}$ のうち $\boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w}$ を最大にするものを探す」問題であり、本章の主題は **内積を取り替えた PCA** だと言ってよい。実際、後で見るように一般化固有ベクトルは $\boldsymbol{w}_i^\top \boldsymbol{B}\boldsymbol{w}_j = \delta_{ij}$、すなわち $\boldsymbol{B}$-内積についての正規直交系をなす。たとえば $\boldsymbol{B} = \operatorname{diag}(\widehat{\boldsymbol{\Sigma}})$ と取れば変数ごとのスケールで割ることになり、相関行列に基づく PCA（3.8節）がこの形に入る。

6.1.1　白色化による標準形への還元

一般化固有値問題は、$\boldsymbol{B}$ で測った長さを 1 に直す座標変換によって通常の固有値問題に化ける。これが理論と実装の両方で基本になる。

定理 6.2 (標準固有値問題への変換)**.** $\boldsymbol{B}$ を正定値対称、$\boldsymbol{B}^{1/2}$ をその正定値対称平方根（$\boldsymbol{B}=\boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^{\top}$ から $\boldsymbol{B}^{1/2}\coloneqq\boldsymbol{U}\boldsymbol{\Lambda}^{1/2}\boldsymbol{U}^{\top}$）とし、$\boldsymbol{C}\coloneqq\boldsymbol{B}^{-1/2}\boldsymbol{A}\boldsymbol{B}^{-1/2}$ とおく。このとき $\boldsymbol{C}$ は対称で、(1) $(\lambda,\boldsymbol{w})$ が 式 (6.1) の解であることと、$\boldsymbol{u}=\boldsymbol{B}^{1/2}\boldsymbol{w}$ として $(\lambda,\boldsymbol{u})$ が $\boldsymbol{C}\boldsymbol{u}=\lambda\boldsymbol{u}$ の解であることは同値；(2) 一般化固有値はすべて実で $\lambda_1\geq\cdots\geq\lambda_p$ と並べられる；(3) 対応する $\boldsymbol{w}_1,\dots,\boldsymbol{w}_p$ は $\boldsymbol{B}$-直交にとれる（$\boldsymbol{w}_i^{\top}\boldsymbol{B}\boldsymbol{w}_j=\delta_{ij}$）；(4) $\max_{\boldsymbol{w}\neq\boldsymbol{0}}\mathcal{R}(\boldsymbol{w})=\lambda_1$ で最大は $\boldsymbol{w}=\boldsymbol{w}_1$ で達成され、より一般に $\boldsymbol{w}_1,\dots,\boldsymbol{w}_{k-1}$ と $\boldsymbol{B}$-直交な範囲で $\mathcal{R}$ を最大化すると λ_k と $\boldsymbol{w}_k$ が得られる。

証明. (1) $\boldsymbol{B}$ が正定値なら $\boldsymbol{B}^{1/2}$ も可逆である。式 (6.1) の両辺に左から $\boldsymbol{B}^{-1/2}$ を掛け $\boldsymbol{w}=\boldsymbol{B}^{-1/2}\boldsymbol{u}$ を代入すると $\boldsymbol{B}^{-1/2}\boldsymbol{A}\boldsymbol{B}^{-1/2}\boldsymbol{u}=\lambda\boldsymbol{B}^{-1/2}\boldsymbol{B}\boldsymbol{B}^{-1/2}\boldsymbol{u}=\lambda\boldsymbol{u}$、すなわち $\boldsymbol{C}\boldsymbol{u}=\lambda\boldsymbol{u}$。逆向きは変形を戻せばよい。$\boldsymbol{C}^{\top}=(\boldsymbol{B}^{-1/2})^{\top}\boldsymbol{A}^{\top}(\boldsymbol{B}^{-1/2})^{\top}=\boldsymbol{C}$ より $\boldsymbol{C}$ は対称である。(2) $\boldsymbol{C}$ は実対称なのでスペクトル定理より固有値は実、固有ベクトルの正規直交系 $\boldsymbol{u}_1,\dots,\boldsymbol{u}_p$ が取れる。(1) の対応で移せばよい。(3) $\boldsymbol{w}_i\coloneqq\boldsymbol{B}^{-1/2}\boldsymbol{u}_i$ とおくと $\boldsymbol{w}_i^{\top}\boldsymbol{B}\boldsymbol{w}_j=\boldsymbol{u}_i^{\top}\boldsymbol{B}^{-1/2}\boldsymbol{B}\boldsymbol{B}^{-1/2}\boldsymbol{u}_j=\boldsymbol{u}_i^{\top}\boldsymbol{u}_j=\delta_{ij}$。(4) $\boldsymbol{u}=\boldsymbol{B}^{1/2}\boldsymbol{w}$ と置換すると

$$\mathcal{R}(\boldsymbol{w})=\frac{\boldsymbol{w}^{\top}\boldsymbol{A}\boldsymbol{w}}{\boldsymbol{w}^{\top}\boldsymbol{B}\boldsymbol{w}}=\frac{\boldsymbol{u}^{\top}\boldsymbol{B}^{-1/2}\boldsymbol{A}\boldsymbol{B}^{-1/2}\boldsymbol{u}}{\boldsymbol{u}^{\top}\boldsymbol{u}}=\frac{\boldsymbol{u}^{\top}\boldsymbol{C}\boldsymbol{u}}{\boldsymbol{u}^{\top}\boldsymbol{u}}$$

となって $\boldsymbol{C}$ の通常の Rayleigh 商になる。$\boldsymbol{w}\mapsto\boldsymbol{u}$ は全単射だから最大値も一致し、対称行列の Rayleigh 商の最大値が最大固有値であること（第2章）より $\max\mathcal{R}=\lambda_1$。制約付きの場合も Courant–Fischer の最小最大原理を移せばよい。 ■

$\boldsymbol{u}=\boldsymbol{B}^{1/2}\boldsymbol{w}$ という変換は、$\boldsymbol{B}$ が共分散行列であるとき「$\boldsymbol{B}$ で測った分散を等方的にする」操作であり、3.9節の**白色化**と同じものである。一般化固有値問題を解くとは、白色化して通常の固有値問題を解き座標を戻すことなのである。

例 6.3 (2×2 の手計算)**.** $\boldsymbol{A}=\begin{pmatrix}2&1\\1&2\end{pmatrix}$、$\boldsymbol{B}=\begin{pmatrix}2&0\\0&1\end{pmatrix}$ とすると $\det(\boldsymbol{A}-\lambda\boldsymbol{B})=(2-2\lambda)(2-\lambda)-1=2\lambda^2-6\lambda+3=0$、よって $\lambda=\frac{3\pm\sqrt{3}}{2}$、数値では 0.6340 と 2.3660。これは $\boldsymbol{B}^{-1/2}=\mathrm{diag}(1/\sqrt{2},1)$ として $\boldsymbol{C}=\begin{pmatrix}1&1/\sqrt{2}\\1/\sqrt{2}&2\end{pmatrix}$ の固有値でもあり、$\operatorname{tr}\boldsymbol{C}=3=\lambda_1+\lambda_2$、$\det\boldsymbol{C}=\frac{3}{2}=\lambda_1\lambda_2$ と整合する。λ_1 に対応する $\boldsymbol{w}_1$ を $\boldsymbol{B}$-正規化すると $\boldsymbol{w}_1\approx(0.3251,\ 0.8881)^{\top}$ で、確かに $\boldsymbol{w}_1^{\top}\boldsymbol{B}\boldsymbol{w}_1=1$ である。

リスト 6.1　一般化固有値問題の解法。`eigh(A, B)` の結果と、定理 6.2の白色化を手で実行した結果が一致することを確かめる。

```python
import numpy as np
from scipy.linalg import eigh
A = np.array([[2., 1.], [1., 2.]]); B = np.array([[2., 0.], [0., 1.]])
lam, W = eigh(A, B)                    # A w = lambda B w を直接解く
wb, Ub = np.linalg.eigh(B)
Bmh = Ub @ np.diag(wb**-0.5) @ Ub.T    # B^{-1/2}
mu, U = np.linalg.eigh(Bmh @ A @ Bmh)  # C = B^{-1/2} A B^{-1/2} の固有値問題
print(np.round(lam, 6), np.round(mu, 6))          # 固有値が一致
print(np.round(W.T @ B @ W, 10))                  # B-直交性
print(np.allclose(np.abs(W), np.abs(Bmh @ U)))    # 固有ベクトルも一致
```

固有値はどちらも $(0.633975,\ 2.366025)$、$\boldsymbol{W}^{\top}\boldsymbol{B}\boldsymbol{W}=\boldsymbol{I}_2$、固有ベクトルは符号を除いて一致する。

$\boldsymbol{B}$ が特異あるいは悪条件のとき

$\boldsymbol{B}$ が正定値でないと 定理 6.2 は崩れる。$\boldsymbol{w}\in\operatorname{Ker}\boldsymbol{B}$ では分母 $\boldsymbol{w}^{\top}\boldsymbol{B}\boldsymbol{w}$ が 0 になるので、そこでは**一般化 Rayleigh 商がそもそも定義できない**。このとき「$\mathcal{R}(\boldsymbol{w})=+\infty$、つまり無限に良い解が現れる」と**決め打ちしてはいけない**。一般の対称 $\boldsymbol{A}$ では分子 $\boldsymbol{w}^{\top}\boldsymbol{A}\boldsymbol{w}$ の符号が定まらないので、$\operatorname{Ker}\boldsymbol{B}$ に近づく方向によって振る舞いが変わる。高次元（第5章）では $\boldsymbol{B}$ が標本共分散である場合が多く、$d>n$ なら必ず特異である。正確な言い方は「$\mathcal{R}$ は $\operatorname{Ker}\boldsymbol{B}$ 上で定義されず、一般には有限な最大値をもつとは限らない」である（命題 6.4）。実務では $\boldsymbol{B}\to\boldsymbol{B}+\varepsilon\boldsymbol{I}$（$\varepsilon>0$）と正則化するのが標準で、これは $\boldsymbol{w}$ に ℓ_2 罰則 $\varepsilon\|\boldsymbol{w}\|^2$ を課すことに等しい。ε は $\operatorname{tr}\boldsymbol{B}/p$ の 10^{-6}〜10^{-2} 倍程度から交差検証で選ぶ。第5章の Ledoit–Wolf 縮小を使うのも同じ発想である。

零方向が構造的な場合は正則化だけでは足りない。$\boldsymbol{B}$ の零空間が「たまたま標本が足りない」ことによるのではなく問題の構造から必然的に生じている場合、正則化は零方向を消さずに小さな固有値として残すだけである。カーネル化した CCA がその例で、中心化 Gram 行列が $\widetilde{\boldsymbol{K}}\boldsymbol{1}=\boldsymbol{0}$ をみたすため $\boldsymbol{B}=\widetilde{\boldsymbol{K}}^2+\kappa\widetilde{\boldsymbol{K}}$ は κ をどれだけ大きくしても $\boldsymbol{1}$ 方向で退化する（第8章）。このときは正則化に加えて **零方向を張る部分空間を明示的に除いて解く**——$\boldsymbol{1}^{\perp}$ の正規直交基底に制限する、あるいは擬似逆を使う——のが正しい。つまり処方は「ε（または κ）で条件数を改善する」と「構造的な零方向を除く」の

二段構えである。
ただし正則化は問題を有限にするだけで、$\varepsilon \to 0$ で最大値が発散すること自体は変わらない（下の 3×3 の例では $\boldsymbol{B}+\varepsilon\boldsymbol{I}$ の最大一般化固有値が $\varepsilon = 10^{-1}, 10^{-2}, 10^{-3}, 10^{-4}$ に対し $10, 10^2, 10^3, 10^4$、最小固有値が $-10, -10^2, -10^3, -10^4$ と、いずれも ε^{-1} の速さで両側に発散する）。

命題 6.4 ($\boldsymbol{B}$ が特異なときに起こる三つの場合)**.** $\boldsymbol{A}, \boldsymbol{B}$ を対称、$\boldsymbol{B} \succeq 0$ で $\operatorname{Ker}\boldsymbol{B} \neq \{\boldsymbol{0}\}$ とする。$\boldsymbol{w}_0 \in \operatorname{Ker}\boldsymbol{B} \setminus \{\boldsymbol{0}\}$ と $\boldsymbol{w}_1 \notin \operatorname{Ker}\boldsymbol{B}$ をとり $\boldsymbol{w}(t) \coloneqq \boldsymbol{w}_0 + t\boldsymbol{w}_1$（$t \neq 0$）とおくと $\boldsymbol{w}(t)^\top \boldsymbol{B}\boldsymbol{w}(t) = t^2\, \boldsymbol{w}_1^\top \boldsymbol{B}\boldsymbol{w}_1 > 0$ で、

$$\mathcal{R}(\boldsymbol{w}(t)) = \frac{\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0 + 2t\, \boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_1 + t^2\, \boldsymbol{w}_1^\top \boldsymbol{A}\boldsymbol{w}_1}{t^2\, \boldsymbol{w}_1^\top \boldsymbol{B}\boldsymbol{w}_1} \tag{6.4}$$

である。したがって $t \to 0$ での挙動は分子の t^0 項 $\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0$ で決まり、

(i) $\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0 > 0$ なら $\mathcal{R}(\boldsymbol{w}(t)) \to +\infty$（$\mathcal{R}$ は上に非有界）、
(ii) $\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0 < 0$ なら $\mathcal{R}(\boldsymbol{w}(t)) \to -\infty$（下に非有界）、
(iii) $\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0 = 0$ なら $0/0$ の形で、極限は $\boldsymbol{w}_1$ の選び方（近づき方）に依存する。

とくに $\mathcal{R}$ が**上下とも有界**になるのは $\operatorname{Ker}\boldsymbol{B} \subset \operatorname{Ker}\boldsymbol{A}$ のときであり、このとき $\mathcal{R}(\boldsymbol{w}) = \mathcal{R}(\boldsymbol{P}\boldsymbol{w})$（$\boldsymbol{P}$ は $(\operatorname{Ker}\boldsymbol{B})^\perp$ への直交射影）が成り立つので、$(\operatorname{Ker}\boldsymbol{B})^\perp$ に制限した正定値の一般化固有値問題を解けばよい。

証明. 式 (6.4)は $\boldsymbol{B}\boldsymbol{w}_0 = \boldsymbol{0}$（$\boldsymbol{B} \succeq 0$ より $\boldsymbol{w}_0^\top \boldsymbol{B}\boldsymbol{w}_0 = 0$ と同値）を代入した直接計算である。(i)(ii) は分子が $\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0 \neq 0$ に収束し分母が t^2 の速さで 0 に落ちることから従う。(iii) は例 6.5で二つの経路が別の極限を与える。最後の主張：$\operatorname{Ker}\boldsymbol{B} \subset \operatorname{Ker}\boldsymbol{A}$ なら、$\boldsymbol{w} = \boldsymbol{P}\boldsymbol{w} + \boldsymbol{z}$（$\boldsymbol{z} \in \operatorname{Ker}\boldsymbol{B}$）に対し $\boldsymbol{A}\boldsymbol{z} = \boldsymbol{0}$、$\boldsymbol{B}\boldsymbol{z} = \boldsymbol{0}$ だから分子・分母がともに $\boldsymbol{P}\boldsymbol{w}$ だけで決まり $\mathcal{R}(\boldsymbol{w}) = \mathcal{R}(\boldsymbol{P}\boldsymbol{w})$。よって $\mathcal{R}$ の値域は $(\operatorname{Ker}\boldsymbol{B})^\perp$ 上での値域に等しく、そこでは $\boldsymbol{B}$ が正定値なので 定理 6.2が使えて最大値・最小値が存在する。 ■

例 6.5 (三つの場合を数値で見る)**.** $\boldsymbol{A} = \operatorname{diag}(2, 1, -1)$、$\boldsymbol{B} = \operatorname{diag}(1, 0, 0)$ とすると $\operatorname{Ker}\boldsymbol{B} = \operatorname{span}\{\boldsymbol{e}_2, \boldsymbol{e}_3\}$ で、$\mathcal{R}(\boldsymbol{w}) = (2w_1^2 + w_2^2 - w_3^2)/w_1^2$ である。$t = 10^{-1}, 10^{-2}, 10^{-3}$ に対する実測値は次のとおり。

- (i) $\boldsymbol{w}_0 = \boldsymbol{e}_2$（$\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0 = 1 > 0$）、$\boldsymbol{w}(t) = t\boldsymbol{e}_1 + \boldsymbol{e}_2$：$\mathcal{R} = 1.02 \times 10^2,\ 1.0002 \times 10^4,\ 1.000002 \times 10^6$ と $+\infty$ に向かう。
- (ii) $\boldsymbol{w}_0 = \boldsymbol{e}_3$（$\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0 = -1 < 0$）、$\boldsymbol{w}(t) = t\boldsymbol{e}_1 + \boldsymbol{e}_3$：$\mathcal{R} = -9.8 \times 10^1,\ -9.998 \times 10^3,\ -9.99998 \times 10^5$ と $-\infty$ に向かう。
- (iii) $\boldsymbol{w}_0 = \boldsymbol{e}_2 + \boldsymbol{e}_3$（$\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0 = 1 - 1 = 0$）：経路 $\boldsymbol{w}(t) = t\boldsymbol{e}_1 + \boldsymbol{e}_2 + \boldsymbol{e}_3$ では $\mathcal{R} = 2$（$t = 10^{-1}$ から 10^{-4} まで 2.000000 で一定）、経路 $\boldsymbol{w}(t) = t\boldsymbol{e}_1 + (1+t)\boldsymbol{e}_2 + \boldsymbol{e}_3$ では $\mathcal{R} = 2.3 \times 10^1,\ 2.03 \times 10^2,\ 2.003 \times 10^3,\ 2.0003 \times 10^4$ と発散する。同じ $\boldsymbol{w}_0$ に近づいているのに極限が違うので、値を割り当てようがない。

なお `scipy.linalg.eigh(A, B)` はこの $\boldsymbol{B}$ に対し `LinAlgError`（$\boldsymbol{B}$ が正定値でない）を送出する——ライブラリも 定義 6.1の仮定を要求している。$(\operatorname{Ker}\boldsymbol{B})^\perp = \operatorname{span}\{\boldsymbol{e}_1\}$ に制限すれば $\mathcal{R}(\boldsymbol{e}_1) = 2$ が唯一の値で有限だが、この例は $\operatorname{Ker}\boldsymbol{B} \not\subset \operatorname{Ker}\boldsymbol{A}$ なので、制限して得た 2 はもとの $\mathcal{R}$ の上限ではない（上で見たように上に非有界である）。

$\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0 = 0$ でも安心できない。 $\boldsymbol{A} = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$、$\boldsymbol{B} = \operatorname{diag}(1, 0, 0)$ では $\boldsymbol{w}_0 = \boldsymbol{e}_2 \in \operatorname{Ker}\boldsymbol{B}$ に対し $\boldsymbol{w}_0^\top \boldsymbol{A}\boldsymbol{w}_0 = 0$ だが $\boldsymbol{A}\boldsymbol{w}_0 = \boldsymbol{e}_1 \neq \boldsymbol{0}$ であり、$\boldsymbol{w}(t) = t\boldsymbol{e}_1 \pm \boldsymbol{e}_2$ とすると $\mathcal{R} = \pm 2/t$、実測で $t = 10^{-1}, 10^{-2}, 10^{-3}$ に対し $\pm 2\times 10^1, \pm 2\times 10^2, \pm 2\times 10^3$ と上下ともに非有界である。有界性の判定は「$\operatorname{Ker}\boldsymbol{B}$ 上で $\boldsymbol{A}$ の二次形式が消えること」ではなく 命題 6.4の $\operatorname{Ker}\boldsymbol{B} \subset \operatorname{Ker}\boldsymbol{A}$ である（$\boldsymbol{A} = \operatorname{diag}(2, 3, 0)$、$\boldsymbol{B} = \operatorname{diag}(1, 2, 0)$ なら $\operatorname{Ker}\boldsymbol{B} = \operatorname{Ker}\boldsymbol{A} = \operatorname{span}\{\boldsymbol{e}_3\}$ で、乱数 2000 本の $\boldsymbol{w}$ に対する $\mathcal{R}$ の実測範囲は $[1.500000,\ 1.999999]$——$(\operatorname{Ker}\boldsymbol{B})^\perp$ 上の一般化固有値 $3/2$ と $2/1$ にきちんと収まる）。

以下、この型に収まる四つの手法を順に見ていく。PCA が $\boldsymbol{A} = \widehat{\boldsymbol{\Sigma}}$、$\boldsymbol{B} = \boldsymbol{I}$ の場合であることは 式 (6.2) に代入すれば直ちに分かるので繰り返さない。

6.2　正準相関分析

同じ n 個の対象について二種類の測定 $\boldsymbol{X} \in \mathbb{R}^{p\times n}$、$\boldsymbol{Y} \in \mathbb{R}^{q\times n}$ があるとする（遺伝子発現と臨床所見、画像とキャプション、脳活動と刺激）。どちらも**列がサンプル**で、第 i 列が同じ対象 i の二種類の観測 $\boldsymbol{x}_i \in \mathbb{R}^p$、$\boldsymbol{y}_i \in \mathbb{R}^q$ である。それぞれを一次元に射影した $\boldsymbol{X}^\top \boldsymbol{a} \in \mathbb{R}^n$ と $\boldsymbol{Y}^\top \boldsymbol{b} \in \mathbb{R}^n$ の**相関**が最大になる方向の組 $(\boldsymbol{a}, \boldsymbol{b}) \in \mathbb{R}^p \times \mathbb{R}^q$ を探すのが正準相関分析（canonical correlation analysis, CCA）である。射影が $\boldsymbol{X}^\top \boldsymbol{a}$（$(n\times p)(p\times 1)$）という形になるのは、$\boldsymbol{a}$ が変数の側のベクトルで、その各成分をサンプルごとに集めた n 個のスカラーが並ぶからである。

以下 $\boldsymbol{X}, \boldsymbol{Y}$ はサンプルについて中心化済み（$\widetilde{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{H}$、$\widetilde{\boldsymbol{Y}} = \boldsymbol{Y}\boldsymbol{H}$ を改めて $\boldsymbol{X}, \boldsymbol{Y}$ と書く）とし、$\boldsymbol{\Sigma}_{xx} \coloneqq \frac{1}{n}\boldsymbol{X}\boldsymbol{X}^\top$（$p\times p$）、$\boldsymbol{\Sigma}_{yy} \coloneqq \frac{1}{n}\boldsymbol{Y}\boldsymbol{Y}^\top$（$q\times q$）、$\boldsymbol{\Sigma}_{xy} \coloneqq \frac{1}{n}\boldsymbol{X}\boldsymbol{Y}^\top$（$p\times q$）とおく。$\boldsymbol{\Sigma}_{xy}$ が $p\times q$ であること、したがって 式 (6.6) のブロック行列が $(p+q)\times(p+q)$ であることは規約に依らない。

定義 6.6 (正準相関)**.**

$$\rho_1 \coloneqq \max_{\boldsymbol{a},\boldsymbol{b}} \frac{\boldsymbol{a}^\top \boldsymbol{\Sigma}_{xy} \boldsymbol{b}}{\sqrt{\boldsymbol{a}^\top \boldsymbol{\Sigma}_{xx} \boldsymbol{a}}\sqrt{\boldsymbol{b}^\top \boldsymbol{\Sigma}_{yy} \boldsymbol{b}}} \tag{6.5}$$

を第一**正準相関**、最大を与える $(\boldsymbol{a}_1, \boldsymbol{b}_1)$ を第一**正準ベクトル**、$\boldsymbol{X}^\top \boldsymbol{a}_1, \boldsymbol{Y}^\top \boldsymbol{b}_1 \in \mathbb{R}^n$ を第一**正準変数**という。第 k 番目は、それまでの正準変数と無相関という制約の下で同じ最大化を行って定める。

式 (6.5) は $\boldsymbol{a}, \boldsymbol{b}$ のスケールに依らないので、$\boldsymbol{a}^\top \boldsymbol{\Sigma}_{xx} \boldsymbol{a} = \boldsymbol{b}^\top \boldsymbol{\Sigma}_{yy} \boldsymbol{b} = 1$ と正規化して $\boldsymbol{a}^\top \boldsymbol{\Sigma}_{xy} \boldsymbol{b}$ を最大化する問題と同値である。

命題 6.7 (一般化固有値問題への帰着)**.** $\boldsymbol{w} = (\boldsymbol{a}^\top, \boldsymbol{b}^\top)^\top \in \mathbb{R}^{p+q}$ とし

$$\boldsymbol{A} = \begin{pmatrix} \boldsymbol{0} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{xy}^\top & \boldsymbol{0} \end{pmatrix}, \qquad \boldsymbol{B} = \begin{pmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{\Sigma}_{yy} \end{pmatrix} \tag{6.6}$$

とおく。このとき 式 (6.5) の最大値は $\boldsymbol{A}\boldsymbol{w} = \lambda \boldsymbol{B}\boldsymbol{w}$ の最大固有値に等しく、$\rho_1 = \lambda_1$ である。一般化固有値は $\pm\rho_1, \dots, \pm\rho_r$ $(r = \min(p, q))$ と符号対称に並ぶ。

証明. $\boldsymbol{w}^\top \boldsymbol{A} \boldsymbol{w} = 2\, \boldsymbol{a}^\top \boldsymbol{\Sigma}_{xy} \boldsymbol{b}$、$\boldsymbol{w}^\top \boldsymbol{B} \boldsymbol{w} = \boldsymbol{a}^\top \boldsymbol{\Sigma}_{xx} \boldsymbol{a} + \boldsymbol{b}^\top \boldsymbol{\Sigma}_{yy} \boldsymbol{b}$ である。正規化 $\boldsymbol{a}^\top \boldsymbol{\Sigma}_{xx} \boldsymbol{a} = \boldsymbol{b}^\top \boldsymbol{\Sigma}_{yy} \boldsymbol{b} = 1$ を課すと $\mathcal{R}(\boldsymbol{w}) = \boldsymbol{a}^\top \boldsymbol{\Sigma}_{xy} \boldsymbol{b}$ となり 式 (6.5) の目的関数に一致する。この正規化は一般性を失わない：分母が二つの二次形式の**和**なので、相加相乗平均の不等式 $s^2 + t^2 \geq 2st$ により $\mathcal{R}$ の最大は $\boldsymbol{a}^\top \boldsymbol{\Sigma}_{xx} \boldsymbol{a} = \boldsymbol{b}^\top \boldsymbol{\Sigma}_{yy} \boldsymbol{b}$ のところで達成される。符号対称性は、$(\boldsymbol{a}^\top, \boldsymbol{b}^\top)^\top$ が固有値 λ の固有ベクトルなら $(\boldsymbol{a}^\top, -\boldsymbol{b}^\top)^\top$ が $-\lambda$ の固有ベクトルであることから従う。 ■

6.2.1　SVD による安定な解法

実装では 式 (6.6) を直接解くより、白色化してから特異値分解に持ち込むほうが数値的に安定である。

定理 6.8 (CCA の SVD 解法)**.** $\boldsymbol{M} \coloneqq \boldsymbol{\Sigma}_{xx}^{-1/2} \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1/2}$ の特異値分解を $\boldsymbol{M} = \boldsymbol{U}\boldsymbol{S}\boldsymbol{V}^\top$、$\boldsymbol{S} = \operatorname{diag}(s_1 \geq \cdots \geq s_r)$ とする。このとき $\rho_k = s_k$ であり、正準ベクトルは

$$\boldsymbol{a}_k = \boldsymbol{\Sigma}_{xx}^{-1/2} \boldsymbol{u}_k, \qquad \boldsymbol{b}_k = \boldsymbol{\Sigma}_{yy}^{-1/2} \boldsymbol{v}_k \tag{6.7}$$

で与えられる。とくに $\rho_k \in [0, 1]$。

証明. $\boldsymbol{\alpha} \coloneqq \boldsymbol{\Sigma}_{xx}^{1/2} \boldsymbol{a}$、$\boldsymbol{\beta} \coloneqq \boldsymbol{\Sigma}_{yy}^{1/2} \boldsymbol{b}$ と置換すると 式 (6.5) の目的関数は $\frac{\boldsymbol{\alpha}^\top \boldsymbol{\Sigma}_{xx}^{-1/2} \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1/2} \boldsymbol{\beta}}{\|\boldsymbol{\alpha}\| \|\boldsymbol{\beta}\|} = \frac{\boldsymbol{\alpha}^\top \boldsymbol{M} \boldsymbol{\beta}}{\|\boldsymbol{\alpha}\| \|\boldsymbol{\beta}\|}$ になる。作用素ノルムの変分表示 $\max_{\boldsymbol{\alpha}, \boldsymbol{\beta} \neq \boldsymbol{0}} \frac{\boldsymbol{\alpha}^\top \boldsymbol{M} \boldsymbol{\beta}}{\|\boldsymbol{\alpha}\| \|\boldsymbol{\beta}\|} = \|\boldsymbol{M}\|_{\mathrm{op}} = s_1$ より最大値は最大特異値で、最大を与えるのは左右の第一特異ベクトル $\boldsymbol{\alpha} = \boldsymbol{u}_1$、$\boldsymbol{\beta} = \boldsymbol{v}_1$。置換を戻せば 式 (6.7) を得る。第 k 番目も、それまでの特異ベクトルと直交する範囲での同じ変分問題である。$\rho_k \leq 1$ は、ρ_k が確率変数 $\boldsymbol{X}^\top \boldsymbol{a}_k$ と $\boldsymbol{Y}^\top \boldsymbol{b}_k$ の相関係数であることから従う。 ■

例 6.9 (対角の場合の手計算)**.** $p = q = 2$ で $\boldsymbol{\Sigma}_{xx} = \operatorname{diag}(4, 1)$、$\boldsymbol{\Sigma}_{yy} = \operatorname{diag}(1, 9)$、$\boldsymbol{\Sigma}_{xy} = \operatorname{diag}(1.2,\ 1.5)$ とする。$\boldsymbol{\Sigma}_{xx}^{-1/2} = \operatorname{diag}(1/2, 1)$、$\boldsymbol{\Sigma}_{yy}^{-1/2} = \operatorname{diag}(1, 1/3)$ なので $\boldsymbol{M} = \operatorname{diag}\left(\frac{1.2}{2},\ \frac{1.5}{3}\right) = \operatorname{diag}(0.6,\ 0.5)$。$\boldsymbol{M}$ は対角なので特異値はそのまま $\rho_1 = 0.6$、$\rho_2 = 0.5$ で、正準ベクトルは $\boldsymbol{a}_1 = \boldsymbol{\Sigma}_{xx}^{-1/2} \boldsymbol{e}_1 = (1/2, 0)^\top$、$\boldsymbol{b}_1 = \boldsymbol{e}_1$。一般化固有値問題 式 (6.6) を数値的に解いても固有値の上位二つが $0.6,\ 0.5$ となり一致する。

リスト 6.2　CCA の二通りの解法。ブロック行列の一般化固有値問題（式 (6.6)）と $\boldsymbol{\Sigma}_{xx}^{-1/2} \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1/2}$ の SVD が同じ正準相関を返すことを確認する。

```
import numpy as np
from scipy.linalg import eigh, svd
rng = np.random.default_rng(0)
n, p, q = 500, 4, 3
Z1 = rng.standard_normal((2, n))                 # 共通の潜在因子 2 本（2×n）
X = rng.standard_normal((p, 2)) @ Z1 + 0.5 * rng.standard_normal((p, n))
Y = rng.standard_normal((q, 2)) @ Z1 + 0.5 * rng.standard_normal((q, n))
X -= X.mean(1, keepdims=True)                    # サンプル方向（列方向）に中心化
Y -= Y.mean(1, keepdims=True)
Sxx = X @ X.T / n + 1e-8*np.eye(p)               # p×p、微小な正則化
Syy = Y @ Y.T / n + 1e-8*np.eye(q); Sxy = X @ Y.T / n   # Sxy は p×q
A = np.block([[np.zeros((p, p)), Sxy], [Sxy.T, np.zeros((q, q))]])
B = np.block([[Sxx, np.zeros((p, q))], [np.zeros((q, p)), Syy]])
rho_gev = np.sort(eigh(A, B, eigvals_only=True))[::-1][:min(p, q)]
def isqrt(M):                                    # M^{-1/2}
    w, U = np.linalg.eigh(M); return U @ np.diag(w**-0.5) @ U.T
print("一般化固有値:", np.round(rho_gev, 6))
print("SVD の特異値:", np.round(svd(isqrt(Sxx) @ Sxy @ isqrt(Syy),
                                    compute_uv=False), 6))
```

出力はどちらも $(0.9503,\ 0.2842,\ 0.0190)$ である。潜在因子が 2 本なので上位二つの正準相関が有意に大きく、第三の相関は 0.019 とノイズ水準に留まる——CCA が共通の潜在構造の本数を検出できている。（正準相関の値は乱数の実現に依存するので、乱数種を変えれば数値そのものは変わる。見るべきは「上位 2 本が大きく第 3 本がノイズ水準」という構造である。）

CCA は簡単に過学習する

中心化後の階数を $r_X \coloneqq \operatorname{rank}(\boldsymbol{X}\boldsymbol{H})$、$r_Y \coloneqq \operatorname{rank}(\boldsymbol{Y}\boldsymbol{H})$ とする。

$$r_X + r_Y > n - 1 \tag{6.8}$$

ならば $\boldsymbol{X}^\top \boldsymbol{a} = \boldsymbol{Y}^\top \boldsymbol{b} \neq \boldsymbol{0}$ をみたす $(\boldsymbol{a}, \boldsymbol{b})$ が必ず存在し、データの中身によらず $\rho_1 = 1$ が達成される。$\boldsymbol{X} \in \mathbb{R}^{p\times n}$ なので、比べるべきは $\operatorname{Im}\big((\boldsymbol{X}\boldsymbol{H})^\top\big)$ と $\operatorname{Im}\big((\boldsymbol{Y}\boldsymbol{H})^\top\big)$ ——どちらも $\mathbf{1}^\perp \subset \mathbb{R}^n$（次元 $n-1$）の部分空間で、「n 人の被験者にひとつの数値を割り当てる関数」のうち各ビューの変数の線形結合で書けるものの全体である。次元の和が $n-1$ を超えれば必ず非自明に交わる（次元定理）。つまり $\rho_1 = 1$ **は「強い関係の発見」ではなく次元の不足の合図**かもしれない。対策は $\boldsymbol{\Sigma}_{xx} + \varepsilon_x \boldsymbol{I}$、$\boldsymbol{\Sigma}_{yy} + \varepsilon_y \boldsymbol{I}$ という正則化（正則化 CCA）か、あらかじめ PCA で p, q を落とすことである。

これは階数の条件であって次元の条件ではない。データが一般位置にあれば $r_X = \min(p, n-1)$、$r_Y = \min(q, n-1)$ なので (6.8)は $p + q \geq n$ に帰着するが、階数が落ちていると成り立たない。極端な例として $\boldsymbol{X} = \boldsymbol{0}$ なら $p + q \geq n$ でも ρ_1 は定義できない（実測 0）。$\boldsymbol{X}$ の 5 行がすべて同じ方向（$r_X = 1$）の場合、$p = q = 5$、$n = 10$ でも $r_X + r_Y = 6 \leq 9$ で条件を外れ、実測の ρ_1 は 0.757 にとどまる。境界も鋭い：$n = 10$、$r_X = 5$、$r_Y = 4$（和がちょうど $n - 1 = 9$）で乱数を 200 回引くと ρ_1 の平均は 0.978 だが $\rho_1 = 1$ は一度も起こらず、$r_X = r_Y = 5$（和が $10 > 9$）にすると 200 回すべて $\rho_1 = 1.000000$ になる。

6.3　フィッシャー判別分析

クラスラベル $y_i \in \{1, \dots, C\}$ が付いたデータ $\boldsymbol{X} \in \mathbb{R}^{d\times n}$ で、クラス c のサンプル数を n_c、平均を $\boldsymbol{\mu}_c$、全平均を $\boldsymbol{\mu}$ とする。クラス平均は**列の部分集合についての平均** $\boldsymbol{\mu}_c = \frac{1}{n_c}\sum_{i:y_i=c} \boldsymbol{x}_i = \frac{1}{n_c}\boldsymbol{X}\mathbf{1}_c$（$\mathbf{1}_c \in \mathbb{R}^n$ はクラス c の指示ベクトル）であり、$\boldsymbol{\mu}_c \in \mathbb{R}^d$ という帰属先は変わらない。以下の散布行列はいずれも $d \times d$ であり、データ行列の向きに依存しない。

定義 6.10 (散布行列)**.**

$$\boldsymbol{S}_W \coloneqq \frac{1}{n}\sum_{c}\sum_{i:y_i=c} (\boldsymbol{x}_i - \boldsymbol{\mu}_c)(\boldsymbol{x}_i - \boldsymbol{\mu}_c)^\top, \quad \boldsymbol{S}_B \coloneqq \frac{1}{n}\sum_{c} n_c (\boldsymbol{\mu}_c - \boldsymbol{\mu})(\boldsymbol{\mu}_c - \boldsymbol{\mu})^\top \tag{6.9}$$

をそれぞれ**クラス内散布行列**、**クラス間散布行列**という。

全散布 $\boldsymbol{S}_T \coloneqq \frac{1}{n}\sum_i (\boldsymbol{x}_i - \boldsymbol{\mu})(\boldsymbol{x}_i - \boldsymbol{\mu})^\top$ について $\boldsymbol{S}_T = \boldsymbol{S}_W + \boldsymbol{S}_B$ が成り立つ（$\boldsymbol{x}_i - \boldsymbol{\mu} = (\boldsymbol{x}_i - \boldsymbol{\mu}_c) + (\boldsymbol{\mu}_c - \boldsymbol{\mu})$ と分解しクラス内で和を取ると交差項が消える）。つまり全体のばらつきは「クラス内のばらつき」と「クラス平均のばらつき」に分かれる。

定義 6.11 (フィッシャー判別基準)**.**

$$J(\boldsymbol{w}) \coloneqq \frac{\boldsymbol{w}^\top \boldsymbol{S}_B \boldsymbol{w}}{\boldsymbol{w}^\top \boldsymbol{S}_W \boldsymbol{w}} \tag{6.10}$$

を最大化する $\boldsymbol{w}$ を求める問題を（フィッシャーの）線形判別分析（linear discriminant analysis, LDA）という。

これは $\boldsymbol{A} = \boldsymbol{S}_B$、$\boldsymbol{B} = \boldsymbol{S}_W$ の Rayleigh 商そのもので、$\boldsymbol{S}_W$ が正定値であれば 定理 6.2 より $\boldsymbol{S}_B \boldsymbol{w} = \lambda \boldsymbol{S}_W \boldsymbol{w}$ を解けばよい。

$\boldsymbol{S}_W$ が特異なとき——命題 6.4の実例

式 (6.9)の $\boldsymbol{S}_W$ は $n - C$ 本の（クラス内で中心化した）ベクトルの和なので $\operatorname{rank}\boldsymbol{S}_W \leq \min(d,\ n - C)$ である。したがって $d > n - C$、とくに $n \leq d$ では $\boldsymbol{S}_W$ は**必ず特異**であり、$J(\boldsymbol{w})$ は $\operatorname{Ker}\boldsymbol{S}_W$ 上で定義されない。これは命題 6.4がそのまま当てはまる状況で、$\boldsymbol{S}_B \succeq 0$ だから起こるのは (i) と (iii) の二つだけである。

- $\boldsymbol{w}_0 \in \operatorname{Ker}\boldsymbol{S}_W$ かつ $\boldsymbol{w}_0^\top \boldsymbol{S}_B \boldsymbol{w}_0 > 0$（クラス平均の差が $\boldsymbol{w}_0$ 方向に成分をもつ）：J は上に非有界で、**クラス内分散 0 で完全に分離する方向**が見つかってしまう。これは標本上の見かけの分離であり、汎化の保証はない。
- $\boldsymbol{w}_0 \in \operatorname{Ker}\boldsymbol{S}_W \cap \operatorname{Ker}\boldsymbol{S}_B$：$0/0$ で不定である。

$d = 3$、$n = 4$、$C = 2$ の実例（$\operatorname{rank}\boldsymbol{S}_W = 1$、$\operatorname{Ker}\boldsymbol{S}_W$ の単位ベクトル $\boldsymbol{e}_3$ に対し $\boldsymbol{e}_3^\top \boldsymbol{S}_W \boldsymbol{e}_3 = 0$、$\boldsymbol{e}_3^\top \boldsymbol{S}_B \boldsymbol{e}_3 = 2.25 > 0$）では、$\boldsymbol{w} = \boldsymbol{e}_3 + t\boldsymbol{e}_1$ とすると $J = 1.156 \times 10^3,\ 9.2416 \times 10^4,\ 9.024 \times 10^6$（$t = 10^{-1}, 10^{-2}, 10^{-3}$）と発散する。一方、第 3 変数がクラス平均差をもたない別の配置では $\boldsymbol{e}_3^\top \boldsymbol{S}_W \boldsymbol{e}_3 = \boldsymbol{e}_3^\top \boldsymbol{S}_B \boldsymbol{e}_3 = 0$ となり、$\boldsymbol{w} = \boldsymbol{e}_3 + t\boldsymbol{e}_1$ に沿った J は t に依らず 16.000000 で一定——これが (iii) の $0/0$、すなわち $\operatorname{Ker}\boldsymbol{S}_W \subset \operatorname{Ker}\boldsymbol{S}_B$ が成り立つ場合である。対処は命題 6.4のとおり、$(\operatorname{Ker}\boldsymbol{S}_W)^\perp$（実務では PCA で張られる部分空間）に制限するか、$\boldsymbol{S}_W + \varepsilon \boldsymbol{I}$ と正則化することである。

6.3.1　2 クラスの閉形式

定理 6.12 (2 クラス LDA の解)**.** $C=2$ のとき、式 (6.10) の最大を与える $\boldsymbol{w}$ はスカラー倍を除いて

$$\boldsymbol{w}^{\star} \propto \boldsymbol{S}_W^{-1}(\boldsymbol{\mu}_1-\boldsymbol{\mu}_2) \tag{6.11}$$

である（$\boldsymbol{S}_W$ は正則とする）。

証明. $\boldsymbol{\delta}\coloneqq\boldsymbol{\mu}_1-\boldsymbol{\mu}_2$ とおく。$C=2$ では $\boldsymbol{\mu}=\frac{n_1\boldsymbol{\mu}_1+n_2\boldsymbol{\mu}_2}{n}$ だから $\boldsymbol{\mu}_1-\boldsymbol{\mu}=\frac{n_2}{n}\boldsymbol{\delta}$、$\boldsymbol{\mu}_2-\boldsymbol{\mu}=-\frac{n_1}{n}\boldsymbol{\delta}$ で、式 (6.9) に代入すると

$$\boldsymbol{S}_B=\frac{1}{n}\left[n_1\frac{n_2^2}{n^2}+n_2\frac{n_1^2}{n^2}\right]\boldsymbol{\delta}\boldsymbol{\delta}^{\top}=\frac{n_1n_2}{n^2}\boldsymbol{\delta}\boldsymbol{\delta}^{\top}=:c\,\boldsymbol{\delta}\boldsymbol{\delta}^{\top}.$$

つまり $\boldsymbol{S}_B$ は階数 1 で、$J(\boldsymbol{w})=c(\boldsymbol{w}^{\top}\boldsymbol{\delta})^2/\boldsymbol{w}^{\top}\boldsymbol{S}_W\boldsymbol{w}$ となる。$\boldsymbol{S}_W$ は正定値なので $\boldsymbol{v}\coloneqq\boldsymbol{S}_W^{1/2}\boldsymbol{w}$ と置換すれば $J=c\big(\boldsymbol{v}^{\top}\boldsymbol{S}_W^{-1/2}\boldsymbol{\delta}\big)^2/\|\boldsymbol{v}\|^2$ で、Cauchy–Schwarz より右辺は $c\|\boldsymbol{S}_W^{-1/2}\boldsymbol{\delta}\|^2=c\,\boldsymbol{\delta}^{\top}\boldsymbol{S}_W^{-1}\boldsymbol{\delta}$ で押さえられ、等号は $\boldsymbol{v}\propto\boldsymbol{S}_W^{-1/2}\boldsymbol{\delta}$ のときに限る。このとき $\boldsymbol{w}=\boldsymbol{S}_W^{-1/2}\boldsymbol{v}\propto\boldsymbol{S}_W^{-1}\boldsymbol{\delta}$ であり 式 (6.11) を得る。最大値は $J(\boldsymbol{w}^{\star})=\frac{n_1n_2}{n^2}\boldsymbol{\delta}^{\top}\boldsymbol{S}_W^{-1}\boldsymbol{\delta}$ である。 ■

注意 6.13. $\boldsymbol{S}_B$ が階数 1 だから $\boldsymbol{S}_W^{-1}\boldsymbol{S}_B$ の非零固有値も一つだけで、2 クラス問題では一般化固有値問題を解く必要すらない。なお 式 (6.11) は、両クラスが共通共分散をもつガウス分布と仮定したときのベイズ最適判別関数の係数とも一致する。判別基準から出発しても確率モデルから出発しても同じ方向に至るのは LDA の魅力の一つである。

6.3.2　多クラスと次元の上限

命題 6.14 (LDA が取り出せる次元数)**.** $\operatorname{rank}\boldsymbol{S}_B\le C-1$ である。したがって LDA で得られる非零固有値の個数は高々 $C-1$ 個で、判別に使える方向は $C-1$ 本までである。

証明. $\boldsymbol{S}_B$ は C 個のベクトル $\boldsymbol{\mu}_c-\boldsymbol{\mu}$ の張る空間に像をもつので $\operatorname{rank}\boldsymbol{S}_B\le C$。さらに $\sum_c n_c(\boldsymbol{\mu}_c-\boldsymbol{\mu})=n\boldsymbol{\mu}-n\boldsymbol{\mu}=\boldsymbol{0}$ という一次関係があるので独立なものは高々 $C-1$ 本、よって $\operatorname{rank}\boldsymbol{S}_B\le C-1$。 ■

$C=2$ なら 1 本、$C=10$ なら 9 本で、クラス数が少ないときは LDA で落とせる次元に厳しい上限がある。

6.3.3　PCA と LDA は違う方向を選ぶ

PCA は教師なしで「分散が最大の方向」を、LDA は教師ありで「クラスが分かれる方向」を選ぶ。この二つは一致しないどころか直交することさえある。

例 6.15 (PCA が判別を壊す)**.** $\mathbb{R}^2$ で二クラス、$n_1=n_2$、$\boldsymbol{\mu}_1=(1,0)^{\top}$、$\boldsymbol{\mu}_2=(-1,0)^{\top}$、$\boldsymbol{S}_W=\operatorname{diag}(0.25,\ 4)$ とする。各クラスは横に細く縦に大きく広がった雲である。

LDA は 式 (6.11) より $\boldsymbol{w}^{\star}\propto\boldsymbol{S}_W^{-1}(2,0)^{\top}=(8,0)^{\top}$、つまり x **軸方向**を選ぶ。一方 PCA は全散布 $\boldsymbol{S}_T=\boldsymbol{S}_W+\boldsymbol{S}_B$ を使い、$\boldsymbol{S}_B=\frac{1}{4}(2,0)^{\top}(2,0)=\operatorname{diag}(1,0)$ なので $\boldsymbol{S}_T=\operatorname{diag}(1.25,\ 4)$、その最大固有値は 4 で固有ベクトルは y **軸方向**である。

x 軸に射影するとクラス間分散とクラス内分散の比は $1/0.25=4$、y 軸に射影すれば $0/4=0$ で二クラスは完全に重なる。PCA が選ぶ方向に射影した時点で判別情報は失われるのである。

図 6.1は、この対比を数値例で示したものである。二クラスが共通の細長い共分散をもつとき、最大分散の方向はクラスを結ぶ方向ではなく雲の伸びる方向であり、そこに射影するとクラスは重なってしまう。

PCA と LDA の使い分け

分散の大きさは「情報の多さ」を意味しない。ラベルがあるならラベルに関係する方向を選ぶべきである。ただし $d>n-C$ では $\boldsymbol{S}_W$ が特異で J が定義できなくなるので、実務では PCA で $\boldsymbol{S}_W$ が正則になる次元まで落としてから LDA をかける（PCA+LDA、いわゆる Fisherface）か、$\boldsymbol{S}_W+\varepsilon\boldsymbol{I}$ と正則化する。どちらも命題 6.4の「$(\operatorname{Ker}\boldsymbol{B})^{\perp}$ に制限する」「$\boldsymbol{B}+\varepsilon\boldsymbol{I}$ とする」という二つの処方をそのまま LDA に適用したものである。なお 例 6.15 のような状況は PCA の欠陥ではなく、教師なし手法に判別を期待するほうが誤りである。

6.4　多次元尺度構成法

ここまでは各サンプルの座標 $\boldsymbol{x}_i$ が与えられていた。ところが手元にあるのが距離（あるいは非類似度）D_{ij} だけという場面は珍しくない（都市間の道路距離、生物種間の遺伝的距離、アンケートの「似ている度合い」）。これらから座標を復元するのが多次元尺度構成法（multidimensional scaling, MDS）である。

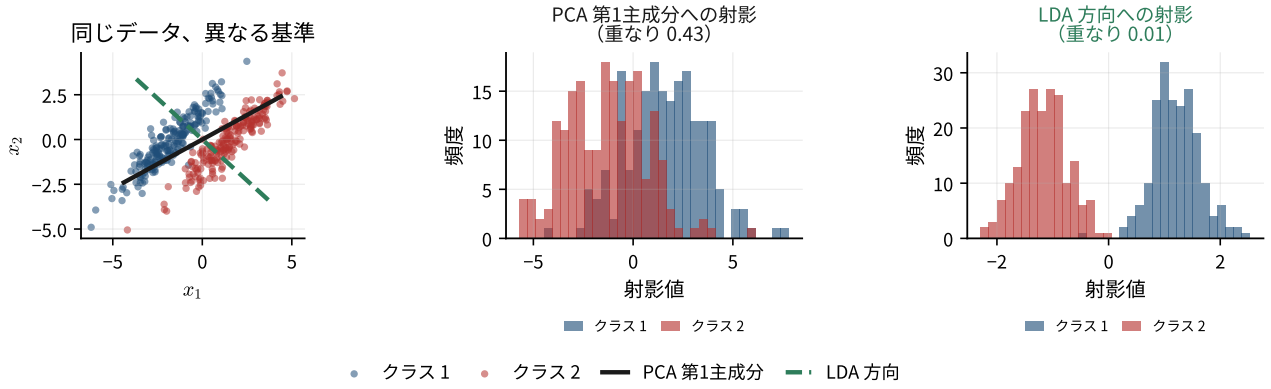


図6.1　同一データに対する PCA と LDA の選ぶ方向の違い。二クラスは相関の強い共通の共分散をもち、分散が最大なのはクラスを結ぶ方向ではない。左が二方向の比較、中央と右がそれぞれの方向へ射影したときのクラス別ヒストグラムで、括弧内は二つの分布の重なり（小さいほど分離が良い）。PCA の方向では二クラスが大きく重なるのに対し、LDA の方向ではほぼ完全に分かれる。

以下 $\boldsymbol{D}^{(2)} \coloneqq (D_{ij}^2)$ を二乗距離行列、$\boldsymbol{H} = \boldsymbol{I}_n - \frac{1}{n}\mathbf{1}\mathbf{1}^\top$ を中心化行列とする。

定義 6.16 (二重中心化と古典的 MDS)**.**

$$\boldsymbol{B} \coloneqq -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H} \tag{6.12}$$

を $\boldsymbol{D}$ の**二重中心化**（double centering）という。$\boldsymbol{B}$ の固有分解 $\boldsymbol{B} = \sum_k \lambda_k \boldsymbol{q}_k \boldsymbol{q}_k^\top$（$\lambda_1 \geq \lambda_2 \geq \cdots$、$\boldsymbol{q}_k \in \mathbb{R}^n$）から k 次元の座標を

$$\boldsymbol{Z} \coloneqq \boldsymbol{\Lambda}_k^{1/2}\boldsymbol{Q}_k^\top = \begin{pmatrix} \sqrt{\lambda_1}\,\boldsymbol{q}_1^\top \\ \vdots \\ \sqrt{\lambda_k}\,\boldsymbol{q}_k^\top \end{pmatrix} \in \mathbb{R}^{k\times n}, \qquad \boldsymbol{Q}_k \coloneqq [\boldsymbol{q}_1, \ldots, \boldsymbol{q}_k] \tag{6.13}$$

で与える手続きを**古典的 MDS**（classical MDS）あるいは主座標分析（principal coordinate analysis）という。ここで $\sqrt{\lambda_j}$ を取るために $\lambda_1, \ldots, \lambda_k \geq 0$ が必要であり、$\boldsymbol{B} \succeq 0$ でない場合は**正の固有値だけを上から k 個**使う（負の固有値を捨てることがこの意味で最良であることは命題 6.25で示す）。$\boldsymbol{Z}$ は $k \times n$、その**第 i 列**が第 i 対象の埋め込み座標 $\boldsymbol{z}_i \in \mathbb{R}^k$ である（第 j 行が第 j 軸の座標を n 個並べたもの、すなわち $\sqrt{\lambda_j}\,\boldsymbol{q}_j^\top$）。

なぜ 式 (6.12) で座標が復元できるのか。鍵になるのは、二乗距離とグラム行列の間の初等的な関係である。

補題 6.17. $\boldsymbol{z}_1, \ldots, \boldsymbol{z}_n \in \mathbb{R}^k$ が中心化されている（$\sum_i \boldsymbol{z}_i = \boldsymbol{0}$）とし、$D_{ij} = \|\boldsymbol{z}_i - \boldsymbol{z}_j\|$、$G_{ij} = \langle \boldsymbol{z}_i, \boldsymbol{z}_j \rangle$ とする。このとき

$$G_{ij} = -\frac{1}{2}\left(D_{ij}^2 - \frac{1}{n}\sum_a D_{aj}^2 - \frac{1}{n}\sum_b D_{ib}^2 + \frac{1}{n^2}\sum_{a,b} D_{ab}^2 \right), \tag{6.14}$$

すなわち $\boldsymbol{G} = -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H}$。

証明. $D_{ij}^2 = \|\boldsymbol{z}_i\|^2 + \|\boldsymbol{z}_j\|^2 - 2G_{ij}$ である。$g_i \coloneqq \|\boldsymbol{z}_i\|^2$、$\bar{g} \coloneqq \frac{1}{n}\sum_i g_i$ と書く。中心化より $\sum_i G_{ij} = \langle \sum_i \boldsymbol{z}_i, \boldsymbol{z}_j \rangle = 0$ なので、j を固定して i について平均を取ると $\frac{1}{n}\sum_a D_{aj}^2 = \bar{g} + g_j$。同様に $\frac{1}{n}\sum_b D_{ib}^2 = g_i + \bar{g}$、両方平均して $\frac{1}{n^2}\sum_{a,b} D_{ab}^2 = 2\bar{g}$。これらを 式 (6.14) の右辺に代入すると

$$-\frac{1}{2}\Big[(g_i + g_j - 2G_{ij}) - (\bar{g} + g_j) - (g_i + \bar{g}) + 2\bar{g} \Big] = G_{ij}.$$

行列の形は、$\boldsymbol{H}$ を左から掛けるのが行方向（i について）、右から掛けるのが列方向（j について）の平均引きであることに対応する。$\boldsymbol{D}^{(2)}$ は $n \times n$ で両側の添字がともにサンプルなので、この二重中心化はデータ行列の規約に依存しない。 ■

定理 6.18 (ユークリッド距離行列の特徴づけ)**.** $\boldsymbol{D} = (D_{ij})$ を $D_{ij} = D_{ji} \geq 0$、$D_{ii} = 0$ をみたす行列とすると、次は同値である：(1) ある k と点配置 $\boldsymbol{z}_1, \ldots, \boldsymbol{z}_n \in \mathbb{R}^k$ が存在して $D_{ij} = \|\boldsymbol{z}_i - \boldsymbol{z}_j\|$（$\boldsymbol{D}$ はユークリッド距離行列である）；(2) $\boldsymbol{B} = -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H}$ が半正定値である。さらに (2) のとき最小の k は $\operatorname{rank}\boldsymbol{B}$ に等しく、式 (6.13) で $k = \operatorname{rank}\boldsymbol{B}$ とした $\boldsymbol{Z} \in \mathbb{R}^{k\times n}$ の**列**がその配置を与える。

証明. (1)⇒(2)：平行移動しても距離は変わらないので $\sum_i \boldsymbol{z}_i = \boldsymbol{0}$ としてよい。配置を列に並べて $\boldsymbol{Z}_0 \coloneqq [\boldsymbol{z}_1, \dots, \boldsymbol{z}_n] \in \mathbb{R}^{k\times n}$ とおくと、グラム行列は $\boldsymbol{Z}_0^\top \boldsymbol{Z}_0$（$n \times n$、$(i,j)$ 成分が $\langle \boldsymbol{z}_i, \boldsymbol{z}_j \rangle$）なので 補題 6.17 より $\boldsymbol{B} = \boldsymbol{Z}_0^\top \boldsymbol{Z}_0$ であり、任意の $\boldsymbol{c} \in \mathbb{R}^n$ に対し $\boldsymbol{c}^\top \boldsymbol{B} \boldsymbol{c} = \|\boldsymbol{Z}_0 \boldsymbol{c}\|^2 \geq 0$、すなわち $\boldsymbol{B}$ は半正定値。

(2)⇒(1)：半正定値なら固有分解 $\boldsymbol{B} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^\top$（$\lambda_i \geq 0$）が取れる。$r \coloneqq \operatorname{rank} \boldsymbol{B}$ として $\boldsymbol{Z} \coloneqq \boldsymbol{\Lambda}_r^{1/2} \boldsymbol{Q}_r^\top \in \mathbb{R}^{r\times n}$（上位 r 個のみ）とおくと $\boldsymbol{Z}^\top \boldsymbol{Z} = \boldsymbol{Q}_r \boldsymbol{\Lambda}_r \boldsymbol{Q}_r^\top = \boldsymbol{B}$。$\boldsymbol{Z}$ の第 i 列を $\boldsymbol{z}_i$ とすれば $\langle \boldsymbol{z}_i, \boldsymbol{z}_j \rangle = B_{ij}$ で、$\|\boldsymbol{z}_i - \boldsymbol{z}_j\|^2 = B_{ii} + B_{jj} - 2B_{ij}$。一方 $\boldsymbol{B}$ の定義 式 (6.12) から $B_{ii} + B_{jj} - 2B_{ij} = D_{ij}^2$ が成り立つ（$\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H}$ の $(i,i)+(j,j)-2(i,j)$ 成分を書き下すと平均項がすべて打ち消し合い $-\frac{1}{2}(-2D_{ij}^2)$ が残る）。よって $\|\boldsymbol{z}_i - \boldsymbol{z}_j\| = D_{ij}$。

最小性：$\mathbb{R}^k$ に配置できれば上の議論から $\operatorname{rank} \boldsymbol{B} \leq k$ なので、最小の k は $\operatorname{rank} \boldsymbol{B}$ である。 ■

例 6.19 (正方形と四点輪)**.** $\mathbb{R}^2$ の単位正方形の四頂点 $(0,0),(1,0),(1,1),(0,1)$ の二乗距離行列 $\boldsymbol{D}^{(2)}$（隣は 1、対角は 2）を二重中心化すると

$$\boldsymbol{B} = -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H} = \frac{1}{2}\begin{pmatrix} 1 & 0 & -1 & 0 \\ 0 & 1 & 0 & -1 \\ -1 & 0 & 1 & 0 \\ 0 & -1 & 0 & 1 \end{pmatrix},$$

固有値は $(1,1,0,0)$ で半正定値、階数 2。定理 6.18の通り $k=2$ で復元でき、実際 式 (6.13) の $\boldsymbol{Z}$ は元の四頂点を（回転・平行移動を除いて）再現する。

対照的に、四点輪グラフ C_4 の最短路距離（隣は 1、対角は 2）では二重中心化した $\boldsymbol{B}$ の固有値が $(2,2,0,-1)$ となって**負の固有値が現れる**。定理 6.18よりこの距離はユークリッドではない。古典的 MDS はこの場合、負の固有値を捨てて（0 に丸めて）配置を返す。これが**どういう意味で最良**なのかは命題 6.25で正確に述べる。

6.4.1　古典的 MDS は PCA と同じものである

定理 6.20 (古典的 MDS と PCA の同値性)**.** $\boldsymbol{X} \in \mathbb{R}^{d\times n}$ を与えられたデータ行列、$\widetilde{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{H}$ をその中心化、$D_{ij} = \|\boldsymbol{x}_i - \boldsymbol{x}_j\|$（ユークリッド距離）とする。このとき

$$\boldsymbol{B} = -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H} = \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}} \tag{6.15}$$

であり、古典的 MDS が 式 (6.13) で返す k 次元座標は、PCA の第 1〜k 主成分スコアと（各軸の符号を除いて）一致する。

証明. 距離は平行移動で不変なので $D_{ij} = \|\tilde{\boldsymbol{x}}_i - \tilde{\boldsymbol{x}}_j\|$ であり、$\widetilde{\boldsymbol{X}}$ の**列**（各データ点）は中心化されている（$\widetilde{\boldsymbol{X}}\boldsymbol{1}_n = \boldsymbol{0}$）。よって補題 6.17 を配置 $\boldsymbol{z}_i = \tilde{\boldsymbol{x}}_i$ に適用して $\boldsymbol{B} = \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$、これが 式 (6.15) である。

$\widetilde{\boldsymbol{X}}$ の特異値分解を $\widetilde{\boldsymbol{X}} = \boldsymbol{U}\boldsymbol{S}\boldsymbol{V}^\top$ とする。$\boldsymbol{U} \in \mathbb{R}^{d\times r}$ が**変数側**、$\boldsymbol{V} \in \mathbb{R}^{n\times r}$ が**サンプル側**なので、$\boldsymbol{B} = \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}} = \boldsymbol{V}\boldsymbol{S}^2\boldsymbol{V}^\top$ であり、$\boldsymbol{B}$ の固有ベクトルは $\boldsymbol{U}$ ではなく $\boldsymbol{V}$ の列、固有値は σ_k^2 である。したがって 式 (6.13) の $\boldsymbol{q}_k = \boldsymbol{v}_k$ で、MDS 座標は $\boldsymbol{Z}_{\mathrm{MDS}} = \boldsymbol{S}_k \boldsymbol{V}_k^\top \in \mathbb{R}^{k\times n}$。一方 PCA スコアは主成分方向 $\boldsymbol{u}_k$ への射影を集めた $\boldsymbol{Z}_{\mathrm{PCA}} = \boldsymbol{U}_k^\top \widetilde{\boldsymbol{X}} = \boldsymbol{U}_k^\top \boldsymbol{U}\boldsymbol{S}\boldsymbol{V}^\top = \boldsymbol{S}_k \boldsymbol{V}_k^\top$ で、両者は一致する（$\boldsymbol{B}$ の固有ベクトルの符号の任意性が各軸の符号反転に対応する）。

要点は「**グラム行列側の固有ベクトルに特異値を掛けたものが埋め込み座標である**」という一文に尽きる。$\boldsymbol{B} = \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$ の固有ベクトルはサンプル側の $\boldsymbol{V}$ であり、$\sqrt{\lambda_j} = \sigma_j$ を掛けた $\boldsymbol{S}_k \boldsymbol{V}_k^\top \in \mathbb{R}^{k\times n}$ が座標になる。 ■

同じ計算の二つの入口

$\boldsymbol{B} = \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$ は $n \times n$ 行列であり、第4章の**双対 PCA**（グラム行列側の固有値問題）と同一である。共分散側は $\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^\top$（$d \times d$）、グラム側が $\widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$（$n \times n$）であり、転置の位置でどちらの空間の話かが読み取れる。つまり「座標が既知なら PCA、距離のみ既知なら古典的 MDS」という区別は、$d \times d$ の共分散側から入るか $n \times n$ のグラム側から入るかの違いに過ぎない。そして**グラム側からしか入れない**状況でグラム行列をカーネル $K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j)$ に置き換えたものが第8章のカーネル PCA であり、古典的 MDS はその線形の特別な場合、逆にカーネル PCA は「一般化された MDS」だと読める。

定理 6.20をデータ解析の側から読み直すと、次の系が得られる。PCA の入力は座標である必要がない、という主張である。

系 6.21 (PCA は距離行列だけで計算できる)**.** $\boldsymbol{D}$ がユークリッド距離行列（定理 6.18の意味で $\boldsymbol{B} \succeq 0$）とし、$\mu_1 \geq \cdots \geq \mu_n \geq 0$ を $\boldsymbol{B} = -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H}$ の固有値、$\boldsymbol{q}_1, \dots, \boldsymbol{q}_n$ をその固有ベクトルとする。座標 $\boldsymbol{X}$ を知らなくても、$\boldsymbol{D}$ のみから次が計算できる。

(i) 標本共分散 $\widehat{\boldsymbol{\Sigma}}$ の固有値 $\lambda_j = \mu_j / n$

(ii) 寄与率 $\lambda_j / \sum_l \lambda_l = \mu_j / \sum_l \mu_l$、累積寄与率、および k 次元に落としたときの復元誤差 $\sum_{j>k} \lambda_j$

(iii) 上位 k 主成分スコア $\boldsymbol{Z} = \boldsymbol{\Lambda}_k^{1/2} \boldsymbol{Q}_k^\top \in \mathbb{R}^{k\times n}$（各軸の符号を除いて PCA スコアに一致）

一方、主成分方向 $\boldsymbol{u}_j \in \mathbb{R}^d$（負荷量）は $\boldsymbol{D}$ からは**決まらない**。

証明. $\boldsymbol{B}$ は $\boldsymbol{D}$ の二重中心化だけで作れる。定理 6.20より $\boldsymbol{B} = \widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}$ なので、$\widetilde{\boldsymbol{X}} = \boldsymbol{U}\boldsymbol{S}\boldsymbol{V}^{\top}$ とすれば $\mu_j = \sigma_j^2$ であり、$\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$ の固有値は $\sigma_j^2/n = \mu_j/n$。これが (i) で、(ii) は (i) の比を取るだけである（$\frac{1}{n}$ が分母分子で消える）。(iii) は式 (6.13)そのもので、定理 6.20の証明で $\boldsymbol{S}_k\boldsymbol{V}_k^{\top}$ が PCA スコアと一致することを見た。

$\boldsymbol{u}_j$ が決まらないことは反例で分かる。任意の直交行列 $\boldsymbol{R} \in \mathbb{R}^{d\times d}$ に対し $\boldsymbol{R}\boldsymbol{X}$ は $\boldsymbol{X}$ と**同じ**距離行列を与える（$\|\boldsymbol{R}\boldsymbol{x}_i - \boldsymbol{R}\boldsymbol{x}_j\| = \|\boldsymbol{x}_i - \boldsymbol{x}_j\|$）。一方その標本共分散は $\boldsymbol{R}\widehat{\boldsymbol{\Sigma}}\boldsymbol{R}^{\top}$ で、固有ベクトルは $\boldsymbol{R}\boldsymbol{u}_j$ になる。したがって $\boldsymbol{D} \mapsto \boldsymbol{u}_j$ という対応は一価の写像として定義できない。 ■

数値で確かめる。$d = 5$、$n = 60$、$k = 2$ のデータで、座標から計算した PCA と距離行列のみから計算した量を比べると、固有値は 8.57586, 2.54504, 0.15207 が両者で一致し、寄与率も 0.746335, 0.221488 が一致する。スコアは符号を揃えたうえで最大差 5.3×10^{-15}、復元誤差 $\sum_{j>2}\lambda_j$ も 0.369733 で一致する。一方、$\boldsymbol{X}$ を無作為な直交行列で回すと距離行列は 3.6×10^{-15} の範囲で不変なのに、第 1 主成分方向は $|\langle \boldsymbol{u}_1, \boldsymbol{u}_1' \rangle| = 0.237$ まで変わる——主軸が距離から決まらないことが数値にも出る。

距離しかない場面で PCA が使える／使えない部分

非類似度の判断（アンケート）、配列間の編集距離、化合物の類似度、測定装置が距離だけを返す場合——座標が手に入らない状況は珍しくない。系 6.21が言うのは、そのとき**スコアと寄与率は使える**（＝低次元配置を描き、何次元取るかを決められる）が、**負荷量は使えない**（＝「どの変数が効いているか」は語れない）ということである。主成分方向は変数空間に住む量で、距離は変数空間の回転で不変だから、原理的に復元できない。同じ制約は第8章のカーネル PCA にもそのまま現れる。特徴写像 ϕ の像の座標を書けないので、そこでも負荷量は得られない。

6.4.2　距離を直接あわせる：計量 MDS

ここで一度立ち止まって、MDS が何を最小化しているのかを確かめておく。古典的 MDS は式 (6.13)のとおり $\boldsymbol{B}$ の上位固有対を取る手続きで、定理 2.28により**グラム行列 $\boldsymbol{B}$ の二乗誤差** $\|\boldsymbol{B} - \boldsymbol{Z}^{\top}\boldsymbol{Z}\|_{\mathrm{F}}$ を最小にしている。しかし MDS の目的として自然なのは **距離そのもの**を合わせることであり、両者は別の問題である。後者を直接立てるのが**計量 MDS**（metric MDS）である。

定義 6.22 (ストレスと計量 MDS)**.** 与えられた非類似度 D_{ij} と埋め込み $\boldsymbol{Z} = [\boldsymbol{z}_1, \dots, \boldsymbol{z}_n] \in \mathbb{R}^{k\times n}$ に対し $d_{ij}(\boldsymbol{Z}) \coloneqq \|\boldsymbol{z}_i - \boldsymbol{z}_j\|$ とおき、

$$\sigma(\boldsymbol{Z}) \coloneqq \sum_{i<j} w_{ij}\bigl(D_{ij} - d_{ij}(\boldsymbol{Z})\bigr)^2 \tag{6.16}$$

を（生の）**ストレス**（stress）という（$w_{ij} \geq 0$ は重み、既定では 1）。比較しやすいよう正規化した $\sigma_1(\boldsymbol{Z}) \coloneqq \bigl(\sigma(\boldsymbol{Z})/\sum_{i<j} D_{ij}^2\bigr)^{1/2}$ を **Kruskal のストレス**と呼ぶ。σ を $\boldsymbol{Z} \in \mathbb{R}^{k\times n}$ について最小化する問題を**計量 MDS** という。

定義を置くと、すぐに次の問いが立つ。**ストレスを 0 にできるのはいつか**。$\sigma(\boldsymbol{Z}) = 0$ とは、埋め込みが与えられた距離を**厳密に**再現することである。これが達成できる次元を与えるのが定理 6.23(i) で、答えは $k \geq r \coloneqq \operatorname{rank}\boldsymbol{B}$、すなわち**計量 MDS の目的関数を 0 にできる最小の次元が** $\operatorname{rank}\boldsymbol{B}$ である。ユークリッド距離行列に対する「完全な埋め込み」とはストレス 0 の埋め込みのことであり、しかもそれは剛体運動を除いて一意である。

逆に $k < r$ では一般にストレスは 0 にできず、そこでは「グラム行列を合わせる」古典的 MDS と「距離を合わせる」計量 MDS が**食い違う**。$\boldsymbol{B} \succeq 0$（距離がユークリッド）であっても食い違うことに注意したい。$d = 5$、$n = 12$ の乱数配置から作ったユークリッド距離（$r = 5$）で生ストレスを測ると

埋め込み次元 k	2	3	4	5 $(= r)$
古典的 MDS	44.10	11.46	2.11	0.00
計量 MDS（Guttman 反復）	19.62	4.83	0.67	0.00

であり、$k = r = 5$ では両者ともストレス 0（定理 6.23(i)）だが、$k < r$ ではどの k でも計量 MDS のほうが小さい（$k = 2$ で 44.10 → 19.62、Kruskal ストレスで 0.274 → 0.183）。**古典的 MDS は $k < r$ ではストレス最小ではない**——ユークリッド距離であっても、である。解法（SMACOF と Guttman 変換）と、距離がユークリッドから遠いときの挙動は 6.4.5節で扱う。

6.4.3　古典的 MDS を二段階で読む

定理 6.20は「座標が与えられていれば PCA と一致する」という主張だった。距離しか与えられていない場合でも、同じことが**二段階**の形で言える。いったん距離を完全に再現する座標——いま見たストレス 0 の埋め込み、すなわち **十分な次元での計量**

MDS の解——を作ってしまえば、あとは通常の PCA で落とすだけでよい。前節で「$k < r$ では古典的 MDS と計量 MDS は食い違う」と述べたが、裏を返せば**次元を r 以上に取れば食い違いは消える**。それを正確に述べる。

定理 6.23 (埋め込み次元が十分なら計量 MDS → PCA ＝古典的 MDS)**.** $\boldsymbol{D}$ がユークリッド距離行列（定理 6.18の意味で $\boldsymbol{B} \succeq 0$）とし、$r \coloneqq \operatorname{rank} \boldsymbol{B}$、埋め込み次元を $m \geq r$ とする。このとき

(i) **ストレスの最小値は 0 である**。すなわち $\sigma(\boldsymbol{Y}) = 0$ （$\|\boldsymbol{y}_i - \boldsymbol{y}_j\| = D_{ij}$ が**すべての** i, j で成立）となる $\boldsymbol{Y} \in \mathbb{R}^{m \times n}$ が存在する。具体例は $\boldsymbol{\Lambda}_r^{1/2} \boldsymbol{Q}_r^{\top}$ に零行を $m - r$ 本足したものである。さらに $\sigma(\boldsymbol{Y}) = 0$ をみたす配置は **剛体運動（平行移動と直交変換）を除いて一意**である。

(ii) **そのような任意の最小化元 $\boldsymbol{Y}$** に PCA を適用して上位 k 成分を取ったものは、$\boldsymbol{D}$ から直接計算した古典的 MDS の k 次元座標 (6.13)と（各軸の符号を除いて）一致する。

すなわち $m \geq r$ のとき、「**計量 MDS で m 次元に埋め込んでから PCA で k 次元に落とす**」**手続きは古典的 MDS と同値**である。古典的 MDS は「距離をユークリッド空間に完全に埋め込んでから PCA する」手続きに他ならない。

証明. (i) **存在.** $\boldsymbol{B} \succeq 0$ かつ $\operatorname{rank} \boldsymbol{B} = r$ なら $\boldsymbol{B} = \boldsymbol{Q}_r \boldsymbol{\Lambda}_r \boldsymbol{Q}_r^{\top}$ （$\boldsymbol{\Lambda}_r$ の対角は正）と書けるので、$\boldsymbol{Y}_0 \coloneqq \boldsymbol{\Lambda}_r^{1/2} \boldsymbol{Q}_r^{\top} \in \mathbb{R}^{r \times n}$ は $\boldsymbol{Y}_0^{\top} \boldsymbol{Y}_0 = \boldsymbol{B}$ を満たす。補題 6.17を逆向きに使えば $\boldsymbol{Y}_0$ の点間距離は D_{ij} を厳密に再現し、$\boldsymbol{B}\mathbf{1} = \mathbf{0}$（二重中心化の帰結）より $\boldsymbol{Y}_0 \mathbf{1} = \mathbf{0}$、すなわち $\boldsymbol{Y}_0$ は中心化されている。零行を足して $\boldsymbol{Y} \in \mathbb{R}^{m \times n}$ と見れば距離は変わらないので $\sigma(\boldsymbol{Y}) = 0$、$\sigma \geq 0$ だからこれが最小値である。

剛体運動を除く一意性. $\sigma(\boldsymbol{Y}) = \sigma(\boldsymbol{Y}') = 0$ とする。σ は平行移動で不変なので両者とも中心化してよい。距離が等しいので 補題 6.17より $\boldsymbol{Y}^{\top}\boldsymbol{Y} = \boldsymbol{B} = (\boldsymbol{Y}')^{\top}\boldsymbol{Y}'$、すなわち **すべての内積が一致する**：$\langle \boldsymbol{y}_i, \boldsymbol{y}_j \rangle = \langle \boldsymbol{y}'_i, \boldsymbol{y}'_j \rangle$。そこで $V \coloneqq \operatorname{span}\{\boldsymbol{y}_1, \dots, \boldsymbol{y}_n\}$ 上で $\boldsymbol{R}\boldsymbol{y}_i \coloneqq \boldsymbol{y}'_i$ と定める。これは矛盾なく定まる——$\sum_i c_i \boldsymbol{y}_i = \mathbf{0}$ なら $\|\sum_i c_i \boldsymbol{y}'_i\|^2 = \sum_{i,j} c_i c_j \langle \boldsymbol{y}'_i, \boldsymbol{y}'_j \rangle = \sum_{i,j} c_i c_j \langle \boldsymbol{y}_i, \boldsymbol{y}_j \rangle = 0$ だから $\sum_i c_i \boldsymbol{y}'_i = \mathbf{0}$ である——うえに内積を保つので V から $V' \coloneqq \operatorname{span}\{\boldsymbol{y}'_1, \dots, \boldsymbol{y}'_n\}$ への等長同型である。$\dim V = \dim V' = r$ だから直交補空間どうしを任意の等長写像で結べば $\boldsymbol{R}$ は $m \times m$ の直交行列に延長でき、$\boldsymbol{Y}' = \boldsymbol{R}\boldsymbol{Y}$ を得る。

(ii) **第一段：PCA スコアは剛体運動で不変である.** $\boldsymbol{Y}' = \boldsymbol{R}\boldsymbol{Y} + \boldsymbol{t}\mathbf{1}^{\top}$（$\boldsymbol{R}$ は直交）とすると、中心化で $\boldsymbol{t}$ は消えて $\widetilde{\boldsymbol{Y}}' = \boldsymbol{R}\widetilde{\boldsymbol{Y}}$、標本共分散は $\boldsymbol{R}\big(\frac{1}{n}\widetilde{\boldsymbol{Y}}\widetilde{\boldsymbol{Y}}^{\top}\big)\boldsymbol{R}^{\top}$ となり、固有ベクトルは $\boldsymbol{R}\boldsymbol{u}_j$、固有値は不変である。したがってスコアは $(\boldsymbol{R}\boldsymbol{u}_j)^{\top}\widetilde{\boldsymbol{Y}}' = \boldsymbol{u}_j^{\top}\boldsymbol{R}^{\top}\boldsymbol{R}\widetilde{\boldsymbol{Y}} = \boldsymbol{u}_j^{\top}\widetilde{\boldsymbol{Y}}$ で**変わらない**（固有ベクトルの符号の任意性を除く）。(i) よりストレスの最小化元は $\boldsymbol{Y}_0$ の剛体運動に限るから、どの最小化元から出発しても PCA スコアは同じである。

第二段：$\boldsymbol{Y}_0$ の PCA は上位 k 行を取る操作である. $\boldsymbol{Y}_0$ の標本共分散は

$$\frac{1}{n}\boldsymbol{Y}_0\boldsymbol{Y}_0^{\top} = \frac{1}{n}\boldsymbol{\Lambda}_r^{1/2}\boldsymbol{Q}_r^{\top}\boldsymbol{Q}_r\boldsymbol{\Lambda}_r^{1/2} = \frac{1}{n}\boldsymbol{\Lambda}_r \tag{6.17}$$

であり、$\boldsymbol{Q}_r^{\top}\boldsymbol{Q}_r = \boldsymbol{I}_r$ から**対角行列**になる。つまり $\boldsymbol{Y}_0$ の座標軸はすでに主軸であり、固有値は λ_j/n の降順に並んでいる（零行を足した $\boldsymbol{Y}$ でも固有値 0 が $m - r$ 個増えるだけで上位 k 個は変わらない）。したがって $\boldsymbol{Y}_0$ の PCA は「上位 k 行を取り出す」操作に還元され、その結果は $\boldsymbol{\Lambda}_k^{1/2}\boldsymbol{Q}_k^{\top}$、すなわち(6.13)に一致する。（主成分方向を表す行列は $\boldsymbol{I}_r$ の先頭 k 列であり、固有値が縮退している場合の符号・回転の任意性がそのまま残る。） ■

この読み方は $B \succeq 0$ でこそ成り立つ

定理 6.23(i) の「完全埋め込み」は $\boldsymbol{B} \succeq 0$ を本質的に使う。$\boldsymbol{B}$ に負の固有値があると、**どんな次元のユークリッド空間にも $\boldsymbol{D}$** を厳密に埋め込めない（定理 6.18）。$n = 14$ 点のユークリッド距離を $D_{ij} \mapsto D_{ij}^{1.4}$ と単調変換した例では、$\boldsymbol{B}$ の負固有値が 10 個（最小 -467.2）になり、正の固有値だけで作った $\boldsymbol{Y}$ の距離の再現誤差は最大 8.65 に達する（元がユークリッドなら同じ計算で 7.1×10^{-15}、すなわち丸め誤差の範囲）。
したがって非ユークリッドな非類似度に対しては、6.4.2節の計量 MDS を k 次元で直接回すほうが理にかなっている（解法は6.4.5節）。「まず完全に埋め込んでから落とす」という二段階は、埋め込みが可能なときにしか意味を持たない。

この読み方は、古典的 MDS が距離について何を保証するかもはっきりさせる。第二段階が PCA なのだから、定理 3.10がそのまま効く。

この同値が崩れる三つの場合

定理 6.23は**ストレスの大域最小元**についての主張である。実際に使うときは次の三点に注意する。
(1) $m < r$ のとき。ストレスは 0 にできず、計量 MDS と古典的 MDS は別の解を返す（前節の表）。同じ例で $m = 2$ の計量 MDS 解に PCA をかけても、古典的 MDS の座標とは最大 0.92 ずれる。
(2) SMACOF が大域最小に達しないとき。σ は非凸で、Guttman 変換は単調減少を保証するだけである（命題 6.26）。上の例（$n = 12$、$r = 5$）では $m = r = 5$ として無作為な初期値 8 通りから回すと全てストレス $\leq 1.0 \times 10^{-13}$ に達し、PCA 後の座標は古典的 MDS と 8.1×10^{-8} で一致した。ただし $m = 7$（$> r$）にすると同じ反復回数では 6.0×10^{-4} までしか下がらない。余分な次元は最小値を変えないが**収束を遅くする**ので、$m = r$ に取るのがよい。

(3) D が非ユークリッドのとき。$B \not\succeq 0$ ならストレスの最小値は 0 でなく、そもそも完全埋め込みが存在しない。この場合は二段階の読み替えが成立せず、k 次元で計量 MDS を直接回すしかない（6.4.5節）。

系 6.24 (古典的 MDS は距離を縮める)**.** $\boldsymbol{D}$ がユークリッド距離行列（$\boldsymbol{B} \succeq 0$）のとき、古典的 MDS が返す k 次元座標 $\boldsymbol{z}_1, \dots, \boldsymbol{z}_n$ は

$$\|\boldsymbol{z}_i - \boldsymbol{z}_j\| \le D_{ij} \quad (\forall i, j), \qquad \frac{\sum_{i<j} \|\boldsymbol{z}_i - \boldsymbol{z}_j\|^2}{\sum_{i<j} D_{ij}^2} = \frac{\lambda_1 + \cdots + \lambda_k}{\lambda_1 + \cdots + \lambda_r} \tag{6.18}$$

を満たす。

証明. 定理 6.23より、この座標は完全埋め込み $\boldsymbol{Y}$（距離を厳密に再現）に PCA を施したものである。$\boldsymbol{Y}$ の点間距離が D_{ij} に一致することと 定理 3.10を合わせればよい。二番目の等式も (3.10)を $\boldsymbol{Y}$ に適用したものである（$\boldsymbol{Y}$ の共分散の固有値が λ_j/n なので比は変わらない）。 ■

つまり**古典的 MDS の埋め込みは距離を縮める側にしか誤らず**、対距離の二乗和をどれだけ保つかは $\boldsymbol{B}$ の固有値の累積比で読める。$n = 14$ 点の例では $k = 1, 2, 3$ で二乗和の保存率が 0.8325, 0.9427, 0.9971 となり、いずれも累積比と厳密に一致し、D_{ij} を超える対は一つもなかった。

単調性も $B \succeq 0$ に依存する

系 6.24の証明は定理 6.23を経由するので、$\boldsymbol{B} \succeq 0$ が崩れると結論も崩れる。実際、上と同じ 14 点で $D_{ij} \mapsto D_{ij}^{1.4}$ と単調変換した非ユークリッドな非類似度では、古典的 MDS の $k = 3$ の解は 91 対**すべて**で D_{ij} を超えた（$k = 2$ でも 80 対）。負の固有値を捨てた分だけ「距離が足りない」ので、残った正の成分が引き伸ばされる格好になる。
6.4.2節の計量 MDS も同様に単調性を持たない（同じ例で $k = 2$ のとき 59/91 対が超過、最大超過 $+4.32$）。D_{ij} より大きい距離も許す自由度と引き換えに距離の再現精度を上げているわけである。**「MDS は距離を縮める」は、距離がユークリッドのときに限った性質である。**

リスト 6.3　古典的 MDS と PCA の一致の数値確認。二重中心化した行列の固有分解から得た座標と、中心化データの SVD から得た主成分スコアを比べる。

```
import numpy as np
rng = np.random.default_rng(3)
n, d = 6, 4
X = rng.standard_normal((d, n))                      # d×n：列がサンプル
H = np.eye(n) - np.ones((n, n)) / n
Xc = X @ H                                           # 中心化は右から H
D2 = ((Xc[:, :, None] - Xc[:, None, :])**2).sum(0)   # 距離行列（変数軸で和）
B = -0.5 * H @ D2 @ H                                # 二重中心化（式 (6.12)）
print("B = Xc^T Xc か:", np.allclose(B, Xc.T @ Xc))  # Gram 行列は Xc^T Xc
lam, V = np.linalg.eigh(B); idx = np.argsort(lam)[::-1]
Z_mds = (V[:, idx[:2]] * np.sqrt(np.maximum(lam[idx[:2]], 0))).T   # 2×n
U = np.linalg.svd(Xc, full_matrices=False)[0]        # 主成分方向は U の列
Z_pca = U[:, :2].T @ Xc                              # PCA スコア（2×n）
print("符号を除いて一致:", np.allclose(np.abs(Z_mds), np.abs(Z_pca)))
print(np.round(Z_mds[:, :3], 4)); print(np.round(Z_pca[:, :3], 4))
```

どちらの検証も `True` を返し、座標も第 1 列が $(-2.8323,\ 1.1918)$ などと符号を除いて完全に一致する（`Z_mds` と `Z_pca` は第 1 軸・第 2 軸とも符号が反転した組として得られる）。$\boldsymbol{Z} \in \mathbb{R}^{k \times n}$ なので、第 i サンプルの座標は**第 i 列**である。

6.4.4　B が不定なとき：半正定値制約つきの最良近似

$\boldsymbol{B}$ が半正定値でないとき、式 (6.13)で負の固有値を捨てる手続きはどんな最適化問題を解いているのか。埋め込み座標を $\boldsymbol{Y} \in \mathbb{R}^{k \times n}$ と書くと、座標から作れるグラム行列は $\boldsymbol{Y}^{\top}\boldsymbol{Y}$ という形のものだけであり、これは必ず半正定値で階数が k 以下である。逆に半正定値で階数 k 以下の $n \times n$ 行列は必ずこの形に書ける（定理 2.19の (a)⇒(c) を上位 k 成分に適用すればよい）。したがって解くべき問題は

$$\min_{\boldsymbol{Y} \in \mathbb{R}^{k \times n}} \|\boldsymbol{B} - \boldsymbol{Y}^{\top}\boldsymbol{Y}\|_{\mathrm{F}}^2 = \min\{\|\boldsymbol{B} - \boldsymbol{M}\|_{\mathrm{F}}^2 : \boldsymbol{M} \succeq 0,\ \operatorname{rank} \boldsymbol{M} \le k\} \tag{6.19}$$

であって、$\operatorname{rank} \boldsymbol{M} \le k$ だけを課す定理 2.28（Eckart–Young）の問題とは違う。

命題 6.25 (半正定値制約つき最良ランク k 近似)**.** $\boldsymbol{B}$ を対称、$\boldsymbol{B}=\sum_{i=1}^{n}\lambda_i\boldsymbol{q}_i\boldsymbol{q}_i^{\top}$（$\lambda_1\ge\cdots\ge\lambda_n$、$\boldsymbol{q}_i$ は正規直交）とし、$\lambda_i>0$ となる添字の個数を r_+ とする。このとき式 (6.19)の最小値は $m:=\min(k,r_+)$ として

$$\boldsymbol{M}^{\star}=\sum_{i=1}^{m}\lambda_i\boldsymbol{q}_i\boldsymbol{q}_i^{\top},\qquad \boldsymbol{Y}^{\star}=\boldsymbol{\Lambda}_m^{1/2}\boldsymbol{Q}_m^{\top},\qquad \|\boldsymbol{B}-\boldsymbol{M}^{\star}\|_{\mathrm{F}}^2=\sum_{i=m+1}^{n}\lambda_i^2 \tag{6.20}$$

で達成される。すなわち**正の固有値の上位 k 個だけを使い、負の固有値は捨てる**のが最良である。

証明. $\boldsymbol{B}_+:=\sum_{\lambda_i>0}\lambda_i\boldsymbol{q}_i\boldsymbol{q}_i^{\top}$、$\boldsymbol{B}_-:=\sum_{\lambda_i<0}(-\lambda_i)\boldsymbol{q}_i\boldsymbol{q}_i^{\top}$ とおくと $\boldsymbol{B}=\boldsymbol{B}_+-\boldsymbol{B}_-$、$\boldsymbol{B}_\pm\succeq 0$、かつ固有空間が直交するので $\operatorname{tr}(\boldsymbol{B}_+\boldsymbol{B}_-)=0$ である。$\boldsymbol{M}\succeq 0$ に対し

$$\|\boldsymbol{B}-\boldsymbol{M}\|_{\mathrm{F}}^2=\|(\boldsymbol{B}_+-\boldsymbol{M})-\boldsymbol{B}_-\|_{\mathrm{F}}^2=\|\boldsymbol{B}_+-\boldsymbol{M}\|_{\mathrm{F}}^2+\|\boldsymbol{B}_-\|_{\mathrm{F}}^2-2\operatorname{tr}(\boldsymbol{B}_+\boldsymbol{B}_-)+2\operatorname{tr}(\boldsymbol{M}\boldsymbol{B}_-).$$

ここで $\boldsymbol{M}\succeq 0$、$\boldsymbol{B}_-\succeq 0$ なら $\operatorname{tr}(\boldsymbol{M}\boldsymbol{B}_-)=\operatorname{tr}(\boldsymbol{M}^{1/2}\boldsymbol{B}_-\boldsymbol{M}^{1/2})\ge 0$ だから

$$\|\boldsymbol{B}-\boldsymbol{M}\|_{\mathrm{F}}^2\ \ge\ \|\boldsymbol{B}_+-\boldsymbol{M}\|_{\mathrm{F}}^2+\|\boldsymbol{B}_-\|_{\mathrm{F}}^2, \tag{6.21}$$

等号は $\operatorname{tr}(\boldsymbol{M}\boldsymbol{B}_-)=0$、すなわち $\operatorname{Im}(\boldsymbol{M})\perp\operatorname{Im}(\boldsymbol{B}_-)$ のときに限る。右辺第一項は $\operatorname{rank}\boldsymbol{M}\le k$ の下で定理 2.28により $\boldsymbol{M}=\sum_{i\le m}\lambda_i\boldsymbol{q}_i\boldsymbol{q}_i^{\top}$（$\boldsymbol{B}_+$ の上位 m 項での打ち切り）で最小になり、その値は $\sum_{i>m,\,\lambda_i>0}\lambda_i^2$ である。この $\boldsymbol{M}$ は半正定値なので制約を満たし、しかも像が $\operatorname{Im}(\boldsymbol{B}_-)$ と直交するので 式 (6.21)の等号も成り立つ。よって下界が達成され、最小値は $\sum_{i>m,\,\lambda_i>0}\lambda_i^2+\sum_{\lambda_i<0}\lambda_i^2=\sum_{i>m}\lambda_i^2$ である（$\lambda_i=0$ の項は寄与しない）。 ■

$\boldsymbol{B}\succeq 0$ でなければ Eckart–Young の答えとは違う

$\boldsymbol{B}\succeq 0$ ならば $|\lambda_i|$ の上位 k 個は λ_i の上位 k 個と一致するので、命題 6.25は定理 2.28と同じ答えを返す。$\boldsymbol{B}$ が**不定**のときは一致しない。例 6.19の C_4（$\lambda=(2,2,0,-1)$）で $k=3$ とすると、rank ≤ 3 だけを課す Eckart–Young の最良近似は $\lambda=2,2,-1$ の三項を使って誤差 0 を達成するが、これは負の固有値を含むためグラム行列になりえず、座標として実現できない。半正定値制約つきの最小値は $\|\boldsymbol{B}-\boldsymbol{M}^{\star}\|_{\mathrm{F}}=1.000000$ である（式 (6.20)の $\sqrt{\sum_{i>m}\lambda_i^2}=\sqrt{0^2+1^2}$。$\boldsymbol{Y}$ について直接数値最適化しても 1.000000 で一致した）。差はもっと極端にもなる。完全二部グラフ $K_{3,3}$ の最短路距離では $\boldsymbol{B}$ の固有値が $(2,2,2,2,0,-2.5)$ で、**絶対値最大の固有値が負**である。$k=1$ の Eckart–Young はこの -2.5 の固有対を選んで誤差 4.000000 とするが、それは実現不能であり、半正定値制約つきの最小値は 4.272002（$\lambda_1=2$ を使う）である（$k=2$ では 3.464102 対 3.774917。いずれも数値最適化で確認した）。

グラフ距離から作った B は一般に PSD ではない

定理 6.20のようにユークリッド距離から出発すれば $\boldsymbol{B}=\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}\succeq 0$ が**自動的に**成り立ち、負の固有値は現れない。一方、k 近傍グラフの最短経路長で測地距離を近似したものを $\boldsymbol{D}$ とすると、測地距離は一般にユークリッド埋め込み可能ではないので $\boldsymbol{B}=-\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H}$ は**不定になるのが普通**である。Swiss roll（$n=600$、10 近傍グラフ、連結）でグラフ最短路距離から $\boldsymbol{B}$ を作ると、負の固有値が 317 個現れ、最小固有値は -2.8099×10^{3}、$\lambda_1=4.2991\times10^{5}$ に対する比は 6.54×10^{-3}、$\sum|\lambda_i^-|/\sum|\lambda_i|=4.03\times10^{-2}$ である。リスト 6.4の三日月データ（$n=300$、10 近傍）でも負の固有値が 149 個、最小固有値 -24.2047（$\lambda_1=638.3250$ に対し 3.79×10^{-2}）、$\sum|\lambda_i^-|/\sum|\lambda_i|=3.26\times10^{-2}$ である。負成分の大きさが数パーセントに留まるのは「測地距離がほぼユークリッド埋め込み可能」という経験的事実であって、定理ではない。この $\boldsymbol{B}$ に対して埋め込みを求めるのが 第11章の Isomap であり、そこで使うべき近似は 定理 2.28ではなく命題 6.25である。

6.4.5　計量 MDS の解法：SMACOF と Guttman 変換

6.4.2節で立てたストレス最小化問題 (6.16)を実際に解く。σ は $\boldsymbol{Z}$ について非凸であり、大域最適解を求める公式はない。標準的な解法は **SMACOF**（scaling by majorizing a complicated function）で、凸関数による優関数（majorizer）を反復的に最小化する。

命題 6.26 (Guttman 変換とストレスの単調減少)**.** $w_{ij}=1$ とし、$\boldsymbol{Z}$ における $\boldsymbol{B}(\boldsymbol{Z})\in\mathbb{R}^{n\times n}$ を

$$B_{ij}(\boldsymbol{Z}):=\begin{cases}-D_{ij}/d_{ij}(\boldsymbol{Z}) & (i\ne j,\ d_{ij}(\boldsymbol{Z})>0)\\ 0 & (i\ne j,\ d_{ij}(\boldsymbol{Z})=0)\end{cases},\qquad B_{ii}:=-\sum_{j\ne i}B_{ij} \tag{6.22}$$

で定める。このとき **Guttman 変換**

$$\boldsymbol{Z}^{+}:=\frac{1}{n}\,\boldsymbol{Z}\,\boldsymbol{B}(\boldsymbol{Z})^{\top} \tag{6.23}$$

は $\sigma(\boldsymbol{Z}^{+}) \le \sigma(\boldsymbol{Z})$ を満たす。

証明の要点. d_{ij}^2 が $\boldsymbol{Z}$ の二次形式であることから、$\sigma(\boldsymbol{Z}) = \sum_{i<j} D_{ij}^2 + \operatorname{tr}(\boldsymbol{Z}\boldsymbol{V}\boldsymbol{Z}^{\top}) - 2\sum_{i<j} D_{ij} d_{ij}(\boldsymbol{Z})$ と分解できる（$\boldsymbol{V} \coloneqq n\boldsymbol{I}_n - \boldsymbol{1}\boldsymbol{1}^{\top}$）。第二項は $\boldsymbol{Z}$ の凸二次関数である。問題は第三項で、$-d_{ij}(\boldsymbol{Z})$ は凹でないが、Cauchy–Schwarz より任意の $\boldsymbol{Z}_0$ に対し $d_{ij}(\boldsymbol{Z}) \ge \langle \boldsymbol{z}_i - \boldsymbol{z}_j, \boldsymbol{z}_{0i} - \boldsymbol{z}_{0j} \rangle / d_{ij}(\boldsymbol{Z}_0)$ （$d_{ij}(\boldsymbol{Z}_0) > 0$）が成り立つので、$-\sum D_{ij} d_{ij}(\boldsymbol{Z})$ を $\boldsymbol{Z}$ の**線形**関数で上から抑えられる。こうして得た二次の優関数は $\boldsymbol{Z}_0$ で σ と接し、その停留点がちょうど(6.23)である。優関数の最小値は元の関数の値以下だから $\sigma(\boldsymbol{Z}^{+}) \le \sigma(\boldsymbol{Z})$ を得る。 ■

例 6.27 (古典的 MDS と計量 MDS の比較)**.** $n = 12$ 点の平面配置から作ったユークリッド距離を $D_{ij} \mapsto D_{ij}^{1.5}$ と単調変換して非ユークリッドな非類似度を作る。二重中心化すると $\boldsymbol{B}$ の固有値は $(323.7,\ 121.7,\ 0,\ -0.06,\ \dots,\ -91.5)$ で負が 9 個あり、最小固有値は -91.5（λ_1 の 28 %）に達する。

$k = 2$ に埋め込むと Kruskal ストレスは

古典的 MDS（正の固有値上位 2 個）	0.2667
計量 MDS（Guttman 変換を 60 回）	0.1520

となり、距離の再現という基準では計量 MDS が 43 % 改善する。生ストレスの推移は $2212 \to 88.7 \to 86.7 \to \cdots \to 85.78$ と 命題 6.26のとおり単調に減り、20 回程度で収束した。

二つの MDS の使い分け

古典的 MDS は固有値問題なので一発で解け、解が一意（符号を除く）で、PCA と同一視できるという理論的な見通しがある（定理 6.20）。距離がユークリッドならこれで十分である。

計量 MDS は距離の再現という本来の目的を直接最適化するので、$\boldsymbol{B}$ が大きな負の固有値をもつ（＝距離がユークリッドから遠い）ときに有利である。代償は、非凸なので初期値依存があること、反復が要ること、そして PCA との対応が失われることである。実務では**古典的 MDS の解を初期値として計量 MDS を回す**のが定石で、`sklearn.manifold.MDS` の既定もこの構成になっている。

非類似度の**順序**だけが意味を持つ場合（アンケートの順位など）は、D_{ij} を単調変換 $f(D_{ij})$ に置き換えて f ごと最適化する **非計量 MDS**（non-metric MDS）を使う。f の推定は単調回帰（pool-adjacent-violators 法）で行い、f の更新と $\boldsymbol{Z}$ の更新を交互に繰り返す。

6.5　スペクトラルクラスタリング

データ点を頂点、点の近さを辺の重みとするグラフを作る。重み行列 $\boldsymbol{W} = (W_{ij})$ は対称・非負で $W_{ii} = 0$ とし、たとえばガウス類似度 $W_{ij} = \exp(-\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2 / 2\sigma^2)$ か k 近傍グラフで作る。次数行列を $\boldsymbol{D} \coloneqq \operatorname{diag}(d_1, \dots, d_n)$、$d_i \coloneqq \sum_j W_{ij}$ とする。

定義 6.28 (グラフラプラシアン)**.**

$$\boldsymbol{L} \coloneqq \boldsymbol{D} - \boldsymbol{W}, \qquad \boldsymbol{L}_{\mathrm{sym}} \coloneqq \boldsymbol{D}^{-1/2} \boldsymbol{L} \boldsymbol{D}^{-1/2}, \qquad \boldsymbol{L}_{\mathrm{rw}} \coloneqq \boldsymbol{D}^{-1} \boldsymbol{L} \tag{6.24}$$

をそれぞれ（非正規化）ラプラシアン、対称正規化ラプラシアン、ランダムウォークラプラシアンという。

$\boldsymbol{L}$ の意味は次の等式に尽きる。

命題 6.29 (ラプラシアンの二次形式)**.** 任意の $\boldsymbol{w} \in \mathbb{R}^n$ に対し

$$\boldsymbol{w}^{\top} \boldsymbol{L} \boldsymbol{w} = \frac{1}{2} \sum_{i,j=1}^{n} W_{ij} (w_i - w_j)^2. \tag{6.25}$$

とくに $\boldsymbol{L}$ は半正定値である。

証明. 右辺を展開すると $\frac{1}{2}\sum_{i,j} W_{ij} w_i^2 - \sum_{i,j} W_{ij} w_i w_j + \frac{1}{2}\sum_{i,j} W_{ij} w_j^2$。第一項は $\frac{1}{2}\sum_i w_i^2 \sum_j W_{ij} = \frac{1}{2}\boldsymbol{w}^{\top}\boldsymbol{D}\boldsymbol{w}$ で、$\boldsymbol{W}$ の対称性から第三項も同じ値。第二項は $-\boldsymbol{w}^{\top}\boldsymbol{W}\boldsymbol{w}$。合わせて $\boldsymbol{w}^{\top}\boldsymbol{D}\boldsymbol{w} - \boldsymbol{w}^{\top}\boldsymbol{W}\boldsymbol{w} = \boldsymbol{w}^{\top}(\boldsymbol{D} - \boldsymbol{W})\boldsymbol{w} = \boldsymbol{w}^{\top}\boldsymbol{L}\boldsymbol{w}$ となり 式 (6.25) を得る。右辺は $W_{ij} \ge 0$ より非負なので $\boldsymbol{L}$ は半正定値である。 ■

式 (6.25) の右辺は「辺で結ばれた頂点に近い値を割り当てているか」を測るなめらかさの尺度である。$\boldsymbol{w}^{\top}\boldsymbol{L}\boldsymbol{w}$ が小さい $\boldsymbol{w}$ は強く結ばれた頂点の組で値がほぼ等しい。これがスペクトラルクラスタリングの原理である。

定理 6.30 (零固有値の重複度＝連結成分の数)**.** $\boldsymbol{L}$ の固有値 0 の重複度は、グラフの連結成分の数 m に等しい。また固有値 0 の固有空間は、各連結成分 $A_1, \dots, A_m$ の指示ベクトル $\boldsymbol{1}_{A_1}, \dots, \boldsymbol{1}_{A_m}$ が張る空間である。

証明. まず $m=1$（連結）の場合。$\boldsymbol{L}\boldsymbol{w}=\boldsymbol{0}$ なら $\boldsymbol{w}^{\top}\boldsymbol{L}\boldsymbol{w}=0$ で、式 (6.25) より $\sum_{i,j}W_{ij}(w_i-w_j)^2=0$。各項が非負なので $W_{ij}>0$ となるすべての (i,j) で $w_i=w_j$ である。連結なら任意の二頂点が辺の列で結ばれ、その列に沿って値が伝播するので $\boldsymbol{w}$ の全成分が等しい、すなわち $\boldsymbol{w}\in\operatorname{span}\{\boldsymbol{1}\}$。逆に $\boldsymbol{L}\boldsymbol{1}=\boldsymbol{D}\boldsymbol{1}-\boldsymbol{W}\boldsymbol{1}=\boldsymbol{0}$（各行の和が $d_i-d_i=0$）だから固有空間はちょうど $\operatorname{span}\{\boldsymbol{1}\}$、重複度 1 である。

一般の m では、頂点を連結成分ごとにまとめて番号を付け替えると $\boldsymbol{W}$ がブロック対角になり $\boldsymbol{L}=\boldsymbol{L}^{(1)}\oplus\cdots\oplus\boldsymbol{L}^{(m)}$ となる。ブロック対角行列のスペクトルは各ブロックのスペクトルの和集合（重複度も加算）で、各 $\boldsymbol{L}^{(a)}$ は連結グラフのラプラシアンだから前段より固有値 0 の重複度は 1、固有ベクトルはそのブロック内で定数。全体のベクトルに戻すと $\boldsymbol{1}_{A_a}$ である。よって重複度は m、固有空間は $\operatorname{span}\{\boldsymbol{1}_{A_1},\dots,\boldsymbol{1}_{A_m}\}$。 ■

例 6.31 (三角形二つ)**.** 頂点 $\{1,2,3\}$ と $\{4,5,6\}$ がそれぞれ三角形を作り両者の間に辺がないグラフで、すべての重みを 1 とすると $\boldsymbol{L}$ の固有値は $(0,0,3,3,3,3)$、定理 6.30の通り 0 の重複度が連結成分数 2 に等しい。ここに弱い橋 $W_{34}=W_{43}=0.1$ を足すとグラフは連結になり固有値は $(0,\ 0.0638,\ 3,\dots)$ となる。第二固有値が 0 からわずかに持ち上がるだけで、対応する固有ベクトルは $(0.417,0.417,0.390,-0.390,-0.417,-0.417)^{\top}$ ——すなわち**符号がもとの二つの塊をそのまま分けている**。これが Fiedler ベクトルである。

連結グラフの $\boldsymbol{L}$ の第二小固有値 $\lambda_2>0$ を**代数的連結度**、対応する固有ベクトルを **Fiedler ベクトル**と呼ぶ。

6.5.1　カット問題の緩和としての導出

なぜ第二固有ベクトルの符号で分けるのが良いのか。これはグラフ分割の組合せ最適化問題からの緩和として導かれる。頂点集合を A とその補集合 $\bar{A}$ に分けるとき、切れる辺の重み和を $\operatorname{cut}(A,\bar{A}):=\sum_{i\in A,j\in\bar{A}}W_{ij}$ とする。これを単純に最小化すると孤立点を一つ切り出す自明な解に落ちるので、大きさで正規化した目的関数を使う：

$$\begin{aligned}\operatorname{RatioCut}(A,\bar{A})&:=\operatorname{cut}(A,\bar{A})\left(\frac{1}{|A|}+\frac{1}{|\bar{A}|}\right),\\ \operatorname{NCut}(A,\bar{A})&:=\operatorname{cut}(A,\bar{A})\left(\frac{1}{\operatorname{vol}(A)}+\frac{1}{\operatorname{vol}(\bar{A})}\right)\end{aligned}\tag{6.26}$$

$(\operatorname{vol}(A):=\sum_{i\in A}d_i)$。

命題 6.32 (カットの緩和と Fiedler ベクトル)**.** 分割 $(A,\bar{A})$ に対し $\boldsymbol{w}\in\mathbb{R}^n$ を

$$w_i=\sqrt{|\bar{A}|/|A|}\ (i\in A),\qquad w_i=-\sqrt{|A|/|\bar{A}|}\ (i\in\bar{A})\tag{6.27}$$

と定めると $\boldsymbol{w}^{\top}\boldsymbol{1}=0$、$\|\boldsymbol{w}\|^2=n$、$\boldsymbol{w}^{\top}\boldsymbol{L}\boldsymbol{w}=n\cdot\operatorname{RatioCut}(A,\bar{A})$ が成り立つ。また 式 (6.27) で $|A|$ を $\operatorname{vol}(A)$ に置き換えると NCut について $\boldsymbol{w}^{\top}\boldsymbol{L}\boldsymbol{w}=\operatorname{vol}(V)\operatorname{NCut}(A,\bar{A})$、$\boldsymbol{w}^{\top}\boldsymbol{D}\boldsymbol{w}=\operatorname{vol}(V)$、そして $\boldsymbol{w}^{\top}\boldsymbol{D}\boldsymbol{1}=0$ が成り立つ。したがって離散制約を落とした緩和は、二つの目的関数に対してそれぞれ

$$\begin{aligned}&(\text{RatioCut})\qquad \min_{\substack{\boldsymbol{w}\neq\boldsymbol{0}\\ \boldsymbol{w}^{\top}\boldsymbol{1}=0}}\frac{\boldsymbol{w}^{\top}\boldsymbol{L}\boldsymbol{w}}{\boldsymbol{w}^{\top}\boldsymbol{w}}\quad\Longrightarrow\quad\boldsymbol{L}\boldsymbol{w}=\lambda\boldsymbol{w},\\ &(\text{NCut})\qquad \min_{\substack{\boldsymbol{w}\neq\boldsymbol{0}\\ \boldsymbol{w}^{\top}\boldsymbol{D}\boldsymbol{1}=0}}\frac{\boldsymbol{w}^{\top}\boldsymbol{L}\boldsymbol{w}}{\boldsymbol{w}^{\top}\boldsymbol{D}\boldsymbol{w}}\quad\Longrightarrow\quad\boldsymbol{L}\boldsymbol{w}=\lambda\boldsymbol{D}\boldsymbol{w}\end{aligned}\tag{6.28}$$

となり、解はそれぞれ**第 2** 固有ベクトル（λ_2 に対応するもの）である。すなわち RatioCut は**標準固有値問題**（$\boldsymbol{L}$ の Fiedler ベクトル）、NCut は**一般化固有値問題**（$\boldsymbol{L}\boldsymbol{w}=\lambda\boldsymbol{D}\boldsymbol{w}$、同じことだが $\boldsymbol{L}_{\mathrm{rw}}:=\boldsymbol{D}^{-1}\boldsymbol{L}$ の固有値問題）に対応する。違いは**何で釣り合いを取るか**だけで、RatioCut は頂点数 $|A|$、NCut は体積 $\operatorname{vol}(A)$ である。

証明. $\boldsymbol{w}^{\top}\boldsymbol{1}=|A|\sqrt{|\bar{A}|/|A|}-|\bar{A}|\sqrt{|A|/|\bar{A}|}=0$、$\|\boldsymbol{w}\|^2=|\bar{A}|+|A|=n$ は直接計算で分かる。式 (6.25) より $\boldsymbol{w}^{\top}\boldsymbol{L}\boldsymbol{w}$ には $W_{ij}>0$ かつ i,j が別グループにある対だけが寄与し、そのとき $(w_i-w_j)^2=(|A|+|\bar{A}|)^2/(|A||\bar{A}|)=n(|A|^{-1}+|\bar{A}|^{-1})$ なので $\boldsymbol{w}^{\top}\boldsymbol{L}\boldsymbol{w}=n\operatorname{RatioCut}(A,\bar{A})$。離散制約を落とすと、$\boldsymbol{1}$ に直交し長さ固定という条件下で Rayleigh 商 $\boldsymbol{w}^{\top}\boldsymbol{L}\boldsymbol{w}/\|\boldsymbol{w}\|^2$ を最小化する問題になり、$\boldsymbol{1}$ が $\boldsymbol{L}$ の最小固有値 0 の固有ベクトルだから Courant–Fischer より最小値は λ_2、最小化するのは Fiedler ベクトルである。NCut 版は $|A|\to\operatorname{vol}(A)$ の置き換えで同じ計算を繰り返せばよい。$\boldsymbol{w}^{\top}\boldsymbol{D}\boldsymbol{1}=\operatorname{vol}(A)\sqrt{\operatorname{vol}(\bar{A})/\operatorname{vol}(A)}-\operatorname{vol}(\bar{A})\sqrt{\operatorname{vol}(A)/\operatorname{vol}(\bar{A})}=0$ に注意する。$\boldsymbol{u}:=\boldsymbol{D}^{1/2}\boldsymbol{w}$ と置くと商は $\boldsymbol{u}^{\top}\boldsymbol{L}_{\mathrm{sym}}\boldsymbol{u}/\|\boldsymbol{u}\|^2$（$\boldsymbol{L}_{\mathrm{sym}}=\boldsymbol{D}^{-1/2}\boldsymbol{L}\boldsymbol{D}^{-1/2}$）になり、制約 $\boldsymbol{w}^{\top}\boldsymbol{D}\boldsymbol{1}=0$ は $\boldsymbol{u}\perp\boldsymbol{D}^{1/2}\boldsymbol{1}$ に対応する。$\boldsymbol{D}^{1/2}\boldsymbol{1}$ は $\boldsymbol{L}_{\mathrm{sym}}$ の最小固有値 0 の固有ベクトルだから（$\boldsymbol{L}\boldsymbol{1}=\boldsymbol{0}$ より）、Courant–Fischer よりこの制約下の最小値は $\boldsymbol{L}_{\mathrm{sym}}$ の第 2 固有値 λ_2、最小化するのは対応する固有ベクトルである。$\boldsymbol{w}=\boldsymbol{D}^{-1/2}\boldsymbol{u}$ に戻せば $\boldsymbol{L}\boldsymbol{w}=\lambda_2\boldsymbol{D}\boldsymbol{w}$、すなわち一般化固有値問題の第 2 固有ベクトルを得る。$\boldsymbol{D}$ は正定値なので $\boldsymbol{D}^{-1}$ を掛ければ $\boldsymbol{L}_{\mathrm{rw}}\boldsymbol{w}=\lambda\boldsymbol{w}$ とも書ける。 ■

制約を落とすと自明解になる

(6.28)から $\boldsymbol{w}^\top \boldsymbol{D}\mathbf{1} = 0$ を外すと、$\boldsymbol{w} = \mathbf{1}$ が $\boldsymbol{L}\mathbf{1} = \mathbf{0}$ より商 0 を達成してしまい、最小値は常に 0、解は自明な第 1 固有ベクトルである（$n = 8$ の乱数グラフで確認すると $\mathbf{1}^\top \boldsymbol{L}\mathbf{1} = -1.8 \times 10^{-15}$、$\mathbf{1}^\top \boldsymbol{D}\mathbf{1} = 42.28$ で商は機械精度、実際に第 1 一般化固有ベクトルは $\mathbf{1}$ の定数倍だった）。RatioCut 側で $\boldsymbol{w}^\top \mathbf{1} = 0$ を残したのと同じ理由で、NCut 側では $\boldsymbol{D}$-内積についての直交条件 $\boldsymbol{w}^\top \boldsymbol{D}\mathbf{1} = 0$ が必要である。一般化固有ベクトルは $\boldsymbol{D}$ 内積について直交する（定理 6.2）ので、第 2 固有ベクトルはこの制約を自動的に満たす。実装で $\boldsymbol{w}_1 = \mathbf{1}$ を捨てるのは、この制約を課すことに他ならない。

スペクトラルクラスタリングの手順（RatioCut 版と NCut 版）

(1) 類似度 W_{ij}（ガウス類似度または k 近傍）を計算する。
(2) $\boldsymbol{D} = \mathrm{diag}(\boldsymbol{W}\mathbf{1})$、$\boldsymbol{L} = \boldsymbol{D} - \boldsymbol{W}$ を作る。
(3) **ここで二通りに分かれる**（式 (6.28)）。

- **RatioCut 版（非正規化）**：標準固有値問題 $\boldsymbol{L}\boldsymbol{w} = \lambda \boldsymbol{w}$ を解く。
- **NCut 版（正規化）**：一般化固有値問題 $\boldsymbol{L}\boldsymbol{w} = \lambda \boldsymbol{D}\boldsymbol{w}$ を解く。$\boldsymbol{u} = \boldsymbol{D}^{1/2}\boldsymbol{w}$ と置いて対称行列 $\boldsymbol{L}_{\mathrm{sym}} = \boldsymbol{D}^{-1/2}\boldsymbol{L}\boldsymbol{D}^{-1/2}$ の固有値問題として解いてもよい（数値的にはこちらが安定）。

どちらも小さいほうから k 本の固有ベクトルを取り、$\boldsymbol{w}_1$（$\mathbf{1}$ または $\boldsymbol{D}^{-1/2}$ 倍）は捨てる。
(4) それらを**行**に並べた $\boldsymbol{Z} \in \mathbb{R}^{k \times n}$ の**列**を新しい座標と見て k-means にかける（$\boldsymbol{Z}$ の第 i 列が頂点 i の k 次元表現。列がサンプルである。`sklearn` に渡すときは `KMeans().fit(Z.T)` と転置する）。$k = 2$ なら第 (4) 段は Fiedler ベクトルの符号を見るだけでよい。$\boldsymbol{L}_{\mathrm{sym}}$ 経由の場合は $\boldsymbol{w} = \boldsymbol{D}^{-1/2}\boldsymbol{u}$ に戻すか、$\boldsymbol{Z}$ の列を長さ 1 に正規化してから k-means にかける（後者が Ng–Jordan–Weiss の標準的な実装で、`sklearn.cluster.SpectralClustering` の既定もこの正規化版である）。**どちらを使うか**。次数がほぼ一様なら両者はほぼ同じ答えを返す。次数のばらつきが大きいときは、体積で釣り合いを取る NCut のほうが「小さく次数の高い塊」を切り出しにくく、既定としては NCut が推奨される。

例 6.33 (RatioCut と NCut が違う答えを返す例)**.** 次数が一様なら両者の差は小さい。実際、リスト 6.4の三日月データ（$\sigma = 0.18$、次数は 7.52 から 21.18 の範囲）では RatioCut 版も NCut 版も正解率 0.997 で一致する。

差が出るのは次数のばらつきが大きいときである。鎖状につないだ 60 頂点（次数 ≈ 2）の端に 20 頂点の完全グラフ（次数 19）を重み 0.3 の辺一本で接続した $n = 80$ のグラフを考える。体積はクリーク側が 380.3、鎖側が 118.3 である。第 2 固有ベクトルの符号で分けると

	分割サイズ	RatioCut 値	NCut 値
RatioCut 版（$\boldsymbol{L}\boldsymbol{w} = \lambda \boldsymbol{w}$）	$(41, 39)$	**0.0500**	0.0154
NCut 版（$\boldsymbol{L}\boldsymbol{w} = \lambda \boldsymbol{D}\boldsymbol{w}$）	$(56, 24)$	0.0595	**0.0116**

となり、**切る辺の位置が違う**。RatioCut 版は鎖の 39 番目の辺を切って頂点数を 41 : 39 に揃え、NCut 版は 56 番目の辺を切ってクリークと鎖の一部（計 24 頂点）を切り出す。どちらの緩和も**自分の目的関数のほうを小さくしている**（太字）。切れる辺の重みはどちらも 1.000 で同じなので、差は分母の釣り合いの取り方だけから来ている。

リスト 6.4　スペクトラルクラスタリング。三日月形の二クラスタに対し NCut 版 $\boldsymbol{L}\boldsymbol{w} = \lambda \boldsymbol{D}\boldsymbol{w}$ と RatioCut 版 $\boldsymbol{L}\boldsymbol{w} = \lambda \boldsymbol{w}$ を解き、Fiedler ベクトルの符号で分割する。

```python
import numpy as np
from scipy.linalg import eigh
rng = np.random.default_rng(0)
t = np.linspace(0, np.pi, 150)
X = np.hstack([np.vstack([np.cos(t), np.sin(t)]),              # 上の三日月
               np.vstack([1 - np.cos(t), 0.5 - np.sin(t)])])   # 下の三日月
X = X + 0.06 * rng.standard_normal((2, 300))                 # 2×300：列がサンプル
sigma = 0.18                                                 # 図6.2 と同じ設定
D2 = ((X[:, :, None] - X[:, None, :])**2).sum(0)             # 変数軸(0)で和を取る
W = np.exp(-D2 / (2 * sigma**2)); np.fill_diagonal(W, 0)     # ガウス類似度（n×n）
D = np.diag(W.sum(1)); L = D - W
lam, V = eigh(L, D)                          # NCut 版：L w = lambda D w
labels = (V[:, 1] > 0).astype(int)           # Fiedler ベクトルの符号で 2 分割
truth = np.r_[np.zeros(150), np.ones(150)]
acc = lambda v: max(((v > 0) == truth).mean(), ((v > 0) != truth).mean())
print("NCut     : lambda_1..4 =", np.round(lam[:4], 5), " 正解率 =", acc(V[:, 1]))

lam_r, V_r = eigh(L)                         # RatioCut 版：L w = lambda w（D を使わない）
print("RatioCut : lambda_1..4 =", np.round(lam_r[:4], 5), " 正解率 =", acc(V_r[:, 1]))
# → NCut     : [-0.  0.00463 0.02061 0.02189]  正解率 = 0.997
#   RatioCut : [ 0.  0.08423 0.36355 0.38276]  正解率 = 0.997
```

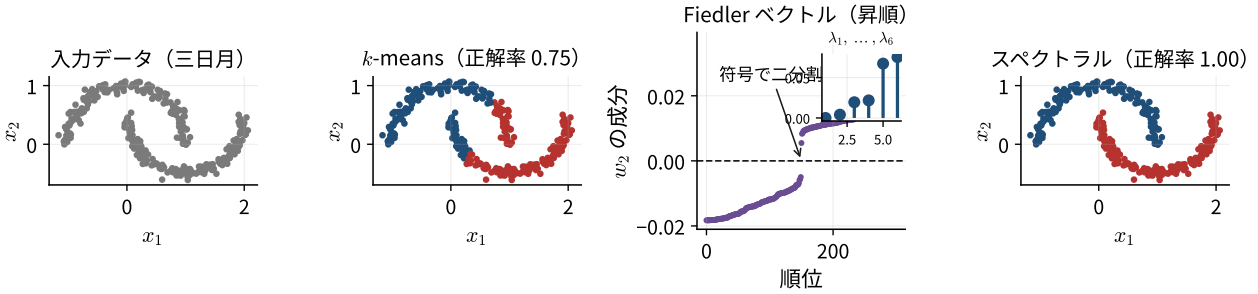


図6.2　スペクトラルクラスタリングの動作（$n = 300$、$\sigma = 0.18$）。k-means はユークリッド距離で球状のクラスタを探すため三日月を切り違えるが、グラフラプラシアンの第二固有ベクトル（Fiedler ベクトル）は符号だけで正しく二分割する。第三パネルの挿入図は最小側の固有値で、λ_2 が λ_3 の 1/4.5 程度に落ち込むことが「クラスタが二つ」という構造を示す。

表6.1　一般化固有値問題 $\boldsymbol{A}\boldsymbol{w} = \lambda \boldsymbol{B}\boldsymbol{w}$ としての線形手法。最後の列は最適化の向き（最大化／最小化）を示す。MDS は $n \times n$ のグラム側で解く点だけが異なるが、定理 6.20により中身は PCA と同じである。$\boldsymbol{X} \in \mathbb{R}^{d \times n}$（列がサンプル）の規約では、共分散側が $\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$（$d \times d$）、グラム側が $\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}$（$n \times n$）である。

手法	$\boldsymbol{A}$	$\boldsymbol{B}$	向き
PCA（第3章）	$\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$	$\boldsymbol{I}_d$	最大
双対 PCA / 古典的 MDS	$\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}} = -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H}$	$\boldsymbol{I}_n$	最大
白色化つき PCA	$\widehat{\boldsymbol{\Sigma}}$	$\mathrm{diag}(\widehat{\boldsymbol{\Sigma}})$	最大
CCA	$\begin{pmatrix} \boldsymbol{0} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{xy}^{\top} & \boldsymbol{0} \end{pmatrix}$	$\begin{pmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{\Sigma}_{yy} \end{pmatrix}$	最大
LDA	$\boldsymbol{S}_B$	$\boldsymbol{S}_W$（または $\boldsymbol{S}_T$）	最大
PLS（注意 6.34）	$\boldsymbol{\Sigma}_{xy}\boldsymbol{\Sigma}_{xy}^{\top}$	$\boldsymbol{I}_d$	最大
スペクトラルクラスタリング	$\boldsymbol{L} = \boldsymbol{D} - \boldsymbol{W}$	$\boldsymbol{D}$（NCut）／$\boldsymbol{I}_n$（RatioCut）	最小

```
#     （固有値の尺度は両者で違うのでギャップは同じ版の中で比べる。
#       同じデータに k-means を当てると 0.743。図6.2 を再現する）
```

NCut 版の出力は $\lambda_{1..4} = (0,\ 0.00463,\ 0.02061,\ 0.02189)$、正解率 0.997（300 点中 1 点の誤り）。RatioCut 版は $\lambda_{1..4} = (0,\ 0.08423,\ 0.36355,\ 0.38276)$ で正解率は同じ 0.997 である（固有値の**尺度**は両者で違うので、ギャップは同じ版の中だけで比べる）。λ_2 が λ_3 の 1/4.5 程度で明確に落ち込むことが「クラスタが二つ」という構造の指標である（この**固有値ギャップ**の位置がクラスタ数を教える）。線形分離不能な三日月形が 300 点中 1 点の誤りで分けられるのは、グラフが局所的な近さだけを見ているからである。なお σ の選択は敏感で、$\sigma = 0.3$ では二つの月をまたぐ重みが最大 0.72 まで上がってつながりはじめ正解率 0.863、$\sigma = 0.5$ では最大 0.89 に達して 0.793 に落ちる（$\sigma = 0.18$ でのまたぎ重みは最大 0.40）。逆に σ が小さすぎるとグラフが分断され、$\sigma = 0.03$ では正解率 0.500 に落ちて分割そのものが成立しなくなる。ただしこのときの破綻の機構は少し意外である。$\sigma = 0.03$ で実際に起こるのはグラフの分断だが、連結成分は**三つ**（サイズ $149, 1, 150$）――つまり三日月二つに加えて**孤立点が一つ**できる。そして $\lambda_1 = \lambda_2 = 0$（実測 -7.8×10^{-17}, 6.2×10^{-18}）と **固有値 0 が重複**するため 0 固有空間が三次元になり、数値解法が返す「第二固有ベクトル」は三つの成分の指示ベクトルの任意の線形結合になってしまう（定理 6.30）。実際この例では符号がすべて同じ側に寄って 300 : 0 となり、分割が成立しない（正解率 0.500）。つまり**グラフが真に非連結なとき Fiedler ベクトルは意味を失う**。正しい対処は 0 固有空間の次元（＝成分数）を先に調べ、成分ごとに処理することである。とくに一点だけ切り離された成分は、σ が小さすぎることの典型的な兆候である。シードを変えても正解率が 0.997 以上で安定するのは $\sigma \in [0.05, 0.2]$ の範囲で（8 通りの種で最小 0.997）、$\sigma = 0.03$ 前後は分断が起こる境目にあたり乱数に強く依存する（同じ設定で種だけ変えると 0.50〜0.90 に振れる）。なお $\boldsymbol{W}, \boldsymbol{D}, \boldsymbol{L}$ はいずれも $n \times n$ でデータ行列の規約に依らず、変わるのは距離行列 `D2` の計算で和を取る軸だけである。

図 6.2にこの過程を可視化した。k-means が失敗するのは距離を直接使うからであり、スペクトラル法が成功するのは、グラフを経由することで「つながっているか」という位相的な近さに問題をすり替えているからである。

6.6　まとめ：五つの手法は一つの型である

表 6.1が本章の要である。どの手法も「二つの二次形式の比を最適化する」という同じ骨格をもち、違いは $\boldsymbol{A}$ と $\boldsymbol{B}$ に何を入れるかだけである。

注意 6.34 (主成分回帰と部分最小二乗法（PLS）)**.** 3.5節で予告した主成分回帰との比較をここで済ませる。主成分回帰は $\boldsymbol{X}$ だけを見て方向を選び、その主成分に $\boldsymbol{y}$ を回帰する。説明変数が直交するので多重共線性は解消するが、**$\boldsymbol{y}$ を一切見ずに方向を決めている**ため、$\boldsymbol{y}$ と関係の薄い方向に大きな分散が乗っていれば無駄な成分を選んでしまう。これに対し PLS は $\boldsymbol{y}$ との共分散 $\boldsymbol{\Sigma}_{xy} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{Y}}^{\top}$ を見て

$$\max_{\|\boldsymbol{w}\|=1} \|\boldsymbol{\Sigma}_{xy}^{\top}\boldsymbol{w}\|^2 \quad\Longleftrightarrow\quad \boldsymbol{\Sigma}_{xy}\boldsymbol{\Sigma}_{xy}^{\top}\boldsymbol{w} = \lambda\boldsymbol{w} \tag{6.29}$$

の第一方向を取る。すなわち $\boldsymbol{A} = \boldsymbol{\Sigma}_{xy}\boldsymbol{\Sigma}_{xy}^{\top}$、$\boldsymbol{B} = \boldsymbol{I}_d$ の一般化固有値問題であり、表 6.1の一行として本章の枠に収まる（$\boldsymbol{\Sigma}_{xy}$ の左特異ベクトルにほかならない）。$d = 8$、$n = 300$、$\boldsymbol{y} = \boldsymbol{w}_\star^{\top}\boldsymbol{X}+$ ノイズという設定で確かめると、(6.29)の最大固有ベクトルは `scikit-learn` の `PLSRegression` の第一重みと $|\cos| = 1.000000000000$ で一致し、真の方向 $\boldsymbol{w}_\star$ との重なりは PLS が 0.992、第 1 主成分は 0.297 にとどまる。$\boldsymbol{y}$ を見るかどうかがそのまま効いている。LDA が $\boldsymbol{y}$ をクラスラベルとして使うのに対し PLS は連続値の $\boldsymbol{y}$ を使う、という違いだけである。

読み取るべき点は三つある。第一に、**$\boldsymbol{B}$ は「何を 1 と見なすか」を決める**。$\boldsymbol{B} = \boldsymbol{I}$ なら座標の長さ、$\boldsymbol{B} = \boldsymbol{S}_W$ ならクラス内のばらつき、$\boldsymbol{B} = \boldsymbol{D}$ なら頂点の次数で、$\boldsymbol{B}$ を変えることは問題に合った内積（$\boldsymbol{B}$-内積）を導入することに等しい。第二に、**最小化問題も同じ枠に入る**。$\mathcal{R}$ の最小化は $-\boldsymbol{A}$ の最大化、あるいは固有値を小さいほうから取ることに対応する。スペクトラルクラスタリングだけ向きが逆なのは、ラプラシアンが「なめらかさの罰則」であって「分散」ではないからである。第三に、**どれも $n \times n$ 側に書き換えられる**。$\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$（$d \times d$）を $\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}$（$n \times n$）に取り替えればよく、古典的 MDS が双対 PCA に一致したのと同じ理屈で、CCA も LDA もスペクトラルクラスタリングもサンプル間の内積だけで表せる。ここに $k(\boldsymbol{x}_i, \boldsymbol{x}_j)$ を差し込むことで**形式的な**カーネル化が得られる——これが 第7章で理論的基礎を与え第8章で実行する道筋であり、カーネル CCA、カーネル LDA、カーネル MDS（＝カーネル PCA）、拡散写像（スペクトラルクラスタリングのカーネル版）がすべてこの表の行に対応して得られる。ただし形式的な置き換えがそのまま使えるとは限らない。カーネル CCA では素朴なカーネル化が退化して正準相関がつねに 1 になってしまい、正則化が不可欠である（8.7節）。何が壊れるかは手法ごとに確かめる必要がある。

演習問題

演習 6.1 ((⋆) 一般化固有値の手計算)**.** $\boldsymbol{A} = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$、$\boldsymbol{B} = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}$ とする。$\det(\boldsymbol{A} - \lambda\boldsymbol{B}) = 0$ から一般化固有値を求め、対応する固有ベクトルを $\boldsymbol{w}^{\top}\boldsymbol{B}\boldsymbol{w} = 1$ と正規化して書け。また $\boldsymbol{C} = \boldsymbol{B}^{-1/2}\boldsymbol{A}\boldsymbol{B}^{-1/2}$ を書き下し、その固有値が一致することを確かめよ。

演習 6.2 ((⋆⋆) LDA の 2 クラス閉形式を導出せよ)**.** $C = 2$ のとき $\boldsymbol{S}_B = \frac{n_1 n_2}{n^2}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^{\top}$ を示し、そこから Cauchy–Schwarz の不等式を用いて $\boldsymbol{w}^{\star} \propto \boldsymbol{S}_W^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$ を導け。最大値 $J(\boldsymbol{w}^{\star})$ を $\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2$ と $\boldsymbol{S}_W$ で表せ。さらに、$\boldsymbol{S}_W$ の代わりに $\boldsymbol{S}_T = \boldsymbol{S}_W + \boldsymbol{S}_B$ を分母に使っても最適方向が変わらないことを示せ。

演習 6.3 ((⋆⋆) CCA の過学習)**.** 中心化後の階数を $r_X = \operatorname{rank}(\boldsymbol{X}\boldsymbol{H})$、$r_Y = \operatorname{rank}(\boldsymbol{Y}\boldsymbol{H})$ とする。$r_X + r_Y > n - 1$ のとき $\rho_1 = 1$ が達成できることを、$\operatorname{Im}((\boldsymbol{X}\boldsymbol{H})^{\top})$ と $\operatorname{Im}((\boldsymbol{Y}\boldsymbol{H})^{\top})$（ともに $\mathbf{1}^{\perp} \subset \mathbb{R}^n$ の部分空間）についての次元定理から示せ。データが一般位置なら $p + q \geq n$ で十分だが、$\boldsymbol{X} = \boldsymbol{0}$ のように階数が落ちると成り立たないことも確認せよ。また、$\boldsymbol{\Sigma}_{xx} \to \boldsymbol{\Sigma}_{xx} + \varepsilon\boldsymbol{I}$、$\boldsymbol{\Sigma}_{yy} \to \boldsymbol{\Sigma}_{yy} + \varepsilon\boldsymbol{I}$ という正則化が $\rho_1 < 1$ を保証することを説明せよ。

演習 6.4 ((⋆⋆) 古典的 MDS が PCA と一致することを示せ)**.** $D_{ij} = \|\boldsymbol{x}_i - \boldsymbol{x}_j\|$ のとき $-\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H} = \widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}$（$\boldsymbol{X} \in \mathbb{R}^{d\times n}$、$\widetilde{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{H}$）を示し、そこから古典的 MDS の座標が PCA スコアに一致することを $\widetilde{\boldsymbol{X}}$ の SVD を使って導け。$\widetilde{\boldsymbol{X}} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$ の $\boldsymbol{V}$（サンプル側）が $\boldsymbol{B}$ の固有ベクトルを与えることに注意せよ。また、距離を α 倍（$\alpha > 0$）したとき MDS 座標がどう変わるかを述べよ。

演習 6.5 ((⋆⋆) グラフラプラシアンの零固有値の重複度)**.** 式 (6.25) を示したうえで、$\boldsymbol{L}$ の固有値 0 の重複度がグラフの連結成分の数に等しいことを証明せよ。また $\boldsymbol{L}_{\mathrm{sym}}$ と $\boldsymbol{L}_{\mathrm{rw}}$ についても同じ主張が成り立つことを、$\boldsymbol{u} = \boldsymbol{D}^{1/2}\boldsymbol{w}$ の対応を用いて示せ。$\boldsymbol{L}_{\mathrm{sym}}$ の零固有ベクトルは何になるか。

演習 6.6 ((⋆⋆) 実装：PCA と LDA の比較)**.** 例 6.15の設定（$\boldsymbol{\mu}_{1,2} = (\pm 1, 0)$、クラス内共分散 $\operatorname{diag}(0.25, 4)$）で各クラス 200 点を生成し、(1) PCA の第一主成分方向、(2) LDA の方向 $\boldsymbol{S}_W^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$ を数値的に求めて散布図に矢印で重ねよ。それぞれの方向に射影した一次元ヒストグラムを描き、LDA では二山に分かれ PCA では完全に重なることを確認せよ。分離度として $J(\boldsymbol{w}) = \frac{\boldsymbol{w}^{\top}\boldsymbol{S}_B\boldsymbol{w}}{\boldsymbol{w}^{\top}\boldsymbol{S}_W\boldsymbol{w}}$ を両方向で計算せよ。

演習 6.7 ((⋆ ⋆ ⋆) 実装：スペクトラルクラスタリングと σ 依存性)**.** リスト 6.4の三日月データに対し、$\sigma \in \{0.05, 0.1, 0.15, 0.2, 0.3, 0.5\}$ で (1) 一般化固有値 λ_2, λ_3、(2) Fiedler ベクトルの符号による正解率を表にまとめよ。λ_3/λ_2 の比が大きいときに正解率が高いことを確認し、この比をクラスタ数の推定に使う方法（固有値ギャップ法）を説明せよ。さらに、同じデータに k-means を直接適用した場合の正解率と比べよ。

演習 6.8 (★★、実装)**.** 定理 6.23を数値で確かめる。$\boldsymbol{Z}_{\mathrm{true}} \in \mathbb{R}^{4\times 14}$ を `default_rng(3)` の標準正規に $\mathrm{diag}(3,2,1,0.4)$ を掛けて作り、$\boldsymbol{D}$ をその点間ユークリッド距離とする。

(1) $\boldsymbol{B} = -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H}$ の固有値を求め、負の固有値がないこと、正の固有値の個数 r が 4 であることを確認せよ。

(2) $\boldsymbol{Y} = \boldsymbol{\Lambda}_r^{1/2}\boldsymbol{Q}_r^{\top} \in \mathbb{R}^{r\times n}$ を作り、その点間距離が $\boldsymbol{D}$ を厳密に再現すること、および $\boldsymbol{Y}\mathbf{1} = \mathbf{0}$ を確認せよ。

(3) $\boldsymbol{Y}$ の標本共分散が対角行列になることを確認し、その対角成分が λ_j/n に一致することを示せ。これが「$\boldsymbol{Y}$ の座標軸がすでに主軸である」ことの意味である。

(4) $\boldsymbol{Y}$ に PCA をかけて上位 2 成分を取ったものと、$\boldsymbol{D}$ から直接計算した古典的 MDS の 2 次元座標が符号を除いて一致することを確認せよ。

(5) $\boldsymbol{D}$ を $D_{ij} \mapsto D_{ij}^{1.4}$ と単調変換して (1)–(2) を繰り返し、完全埋め込みが不可能になることを確認せよ。さらに古典的 MDS の $k=3$ の解で D_{ij} を超える対がいくつあるか数え、系 6.24の単調性が失われることを示せ。

第 7 章

関数解析の基礎と再生核ヒルベルト空間

この章のねらい

本章は講義の折り返し点であり、有限次元の線形代数から無限次元の世界への橋を架ける。まず距離空間の完備性から出発してヒルベルト空間の幾何を組み立て、射影定理と Riesz の表現定理という二本の柱を証明する。次に正定値カーネルを定義し、Moore–Aronszajn の定理によって「正定値カーネル」と「再生核ヒルベルト空間」が同じものの二つの顔であることを示す。最後に Mercer の定理で固有関数による具体的な表示を与える。第8章・第9章で使う道具は、すべてここで揃う。[a]

[a] この章の計算は演習ノートブック `ch07_rkhs.ipynb` で再現できる。インストール不要で実行するには Google Colab で開く：`https://colab.research.google.com/github/yusukeimoto/data-analysis-math-demos/blob/main/notebooks/ch07_rkhs.ipynb`

7.1 なぜ関数解析が要るのか

第4章の双対 PCA を思い出そう。中心化データ行列 $\widetilde{\boldsymbol{X}} \in \mathbb{R}^{d\times n}$（第 i 列が $\tilde{\boldsymbol{x}}_i$）に対し、主 PCA が共分散行列 $\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$（$d \times d$）の固有値問題を解くのに対し、双対 PCA は Gram 行列 $\boldsymbol{K} = \widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}$、$K_{ij} = \langle \tilde{\boldsymbol{x}}_i, \tilde{\boldsymbol{x}}_j \rangle$（$n \times n$）の固有値問題を解いた。決定的なのは、双対側に現れるデータの情報が **内積の値だけ**だったことである。個々の座標は $\boldsymbol{K}$ を作った後は現れず、射影後の座標も新しい点の射影も、すべて内積を通してのみデータに触れる。

すると自然に次の問いが立つ。

本章を貫く問い

内積 $\langle \boldsymbol{x}, \boldsymbol{y} \rangle$ を、別の二変数関数 $k(\boldsymbol{x}, \boldsymbol{y})$ に取り替えたら何が起こるか。(1) k はどんな条件を満たせばよいのか。(2) そのとき暗黙のうちに働いている空間は何か。(3) その空間で「大きさ」「近さ」「直交」は何を意味するのか。

答えは順に**正定値性**、**再生核ヒルベルト空間**、そして**有限次元とまったく同じ幾何**である。最後の点が本章の要なので、先に結論の形を述べておく。

本章の一行要約

カーネル法は線形代数の各概念を**別物に置き換えているのではない**。$\mathbb{R}^d$ でやっていた線形代数を、**別の Hilbert 空間 $\mathcal{H}$ で同じようにやっている**だけである。置き換わるのは内積の**計算式**だけで、内積・ノルム・距離・直交・射影・固有値分解という道具立ては何も変わらない。

対応を一覧にしておく。以降の章はこの表を縦に読み下していく作業だと思ってよい。

表 7.1の右列を**使えるようにするための保証**が、本章で証明する定理である。どれも「有限次元では当たり前だったことが、無限次元でも壊れない」という形をしている。

- **正定値性**（7.6節）——「k は本当にどこかの空間の内積なのか」を k だけ見て判定する条件。有限次元で $\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}$ が必ず半正定値になったことの一般化である。
- **RKHS の存在**（定理 7.32）——「その内積が住んでいる空間は何か」への答え。正定値な k に対して Hilbert 空間 $\mathcal{H}_k$ が実際に存在し、標準的な特徴写像は $\phi(\boldsymbol{x}) = k(\cdot, \boldsymbol{x})$ で与えられる。

表7.1　有限次元の線形代数とカーネル化後の対応。特徴写像 $\phi : \mathcal{X} \to \mathcal{H}$ を陽に作らず、右列の量はすべて k の値だけから計算できる。

有限次元（第2章）	カーネル化後（特徴空間 $\mathcal{H}$）	本書での扱い
データ点 $\boldsymbol{x} \in \mathbb{R}^d$	特徴ベクトル $\phi(\boldsymbol{x}) \in \mathcal{H}$	7.8節
内積 $\langle \boldsymbol{x}, \boldsymbol{y} \rangle$	$k(\boldsymbol{x}, \boldsymbol{y}) = \langle \phi(\boldsymbol{x}), \phi(\boldsymbol{y}) \rangle_{\mathcal{H}}$	7.6節
ノルム $\|\boldsymbol{x}\|^2 = \langle \boldsymbol{x}, \boldsymbol{x} \rangle$	$\|\phi(\boldsymbol{x})\|^2 = k(\boldsymbol{x}, \boldsymbol{x})$	7.6節
距離 $\|\boldsymbol{x} - \boldsymbol{y}\|^2$	$k(\boldsymbol{x}, \boldsymbol{x}) + k(\boldsymbol{y}, \boldsymbol{y}) - 2k(\boldsymbol{x}, \boldsymbol{y})$	7.8節
直交 $\langle \boldsymbol{x}, \boldsymbol{y} \rangle = 0$	$k(\boldsymbol{x}, \boldsymbol{y}) = 0$	7.4節
線形結合 $\sum_i c_i \boldsymbol{x}_i$	$\sum_i c_i \phi(\boldsymbol{x}_i)$	定理 7.32
Gram 行列 $\widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$	$K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j)$	7.6節
共分散行列 $\frac{1}{n} \widetilde{\boldsymbol{X}} \widetilde{\boldsymbol{X}}^\top$	特徴空間の共分散作用素	第8章
$\widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$ の固有値問題	$\boldsymbol{K}$ の固有値問題	第8章
線形 PCA（双対 PCA）	カーネル PCA	第8章
線形 CCA	カーネル CCA	第8章
線形 SVM	カーネル SVM	第9章

- **完備性**（7.2節）——有限次元では自動だった「極限が空間の外に逃げない」という性質。これを仮定しないと、最適化の最小化列の極限や、無限級数の和が空間の元として存在しない。
- **射影定理**（定理 7.10）——線形 PCA で使った「部分空間への最良近似が存在して一意」（2.4節）が、無限次元の **一般の閉部分空間**に対しても成り立つことの保証。（カーネル PCA が扱うのは有限個の $\tilde{\phi}(\boldsymbol{x}_i)$ が張る有限次元部分空間なので、そこへの射影だけなら完備性がなくても意味をもつ。射影定理が効くのは、RKHS の構成そのもの（定理 7.32）や Riesz の表現定理のように一般の閉部分空間を相手にする場面である。）
- **Riesz の表現定理**（定理 7.18）——有限次元で示した「線形汎関数は内積で書ける」（命題 2.11）の無限次元版。RKHS の再生性 $f(\boldsymbol{x}) = \langle f, k(\cdot, \boldsymbol{x}) \rangle_{\mathcal{H}}$ を支える定理である。
- **Mercer の定理**(定理 7.40)——有限次元のスペクトル分解 $\boldsymbol{A} = \sum_j \lambda_j \boldsymbol{u}_j \boldsymbol{u}_j^\top$ (2.5節)に対応する。$k(\boldsymbol{x}, \boldsymbol{y}) = \sum_j \lambda_j e_j(\boldsymbol{x}) e_j(\boldsymbol{y})$ と展開すると「特徴空間の座標」が具体的に見える。

言い換えれば、**本章で調べているのは、線形代数の道具が無限次元の特徴空間でも壊れずに使えるかどうか**である。そのために無限次元で「収束する」「直交射影する」「最小値が存在する」という操作を正当化する枠組みが要る。それが関数解析であり、本章の前半（7.2節–7.5節）はその準備に充てられる。後半（7.6節以降）でカーネルに戻る。

7.1.1　最小の例：内積を取り替えると何が起こるか

抽象論の前に、内積を取り替えることの威力を見ておこう。$\mathcal{X} = \mathbb{R}^2$ 上の二値分類問題で、正例が原点近くの円板に、負例がそれを囲む円環にあるとする (図 7.1 左)。この二つは $\mathbb{R}^2$ の直線では分離できない。

そこで写像 $\phi : \mathbb{R}^2 \to \mathbb{R}^3$, $\phi(\boldsymbol{x}) = (x_1^2, \sqrt{2} x_1 x_2, x_2^2)$ で $\mathbb{R}^3$ に持ち上げる。第 1 座標と第 3 座標の和は $x_1^2 + x_2^2 = \|\boldsymbol{x}\|^2$ だから、原点からの距離の二乗が $\mathbb{R}^3$ では**線形な**量になっている。よって平面 $z_1 + z_3 = c$ が二つのクラスを分離し (図 7.1 右)、入力空間に引き戻せば半径 $\sqrt{c}$ の円になる。

この ϕ を実際に計算する必要はあるだろうか。双対 PCA の教訓に従えば、必要なのは内積 $\langle \phi(\boldsymbol{x}), \phi(\boldsymbol{y}) \rangle$ だけである。手で計算しよう。

$$
\begin{aligned}
\langle \phi(\boldsymbol{x}), \phi(\boldsymbol{y}) \rangle &= x_1^2 y_1^2 + 2 x_1 x_2 y_1 y_2 + x_2^2 y_2^2 \\
&= (x_1 y_1)^2 + 2 (x_1 y_1)(x_2 y_2) + (x_2 y_2)^2 \\
&= \big(x_1 y_1 + x_2 y_2 \big)^2 = \big(\boldsymbol{x}^\top \boldsymbol{y} \big)^2 .
\end{aligned}
\tag{7.1}
$$

3 次元の内積が、2 次元の内積を二乗するだけで得られた。ϕ を陽に作る手間が消え、$\boldsymbol{x}^\top \boldsymbol{y}$ の 1 回の内積と 1 回の二乗で済む。これが**カーネルトリック**の最も簡単な例である。数値で確かめておこう。$\boldsymbol{x} = (1, 2)^\top$, $\boldsymbol{y} = (3, -1)^\top$ なら $\phi(\boldsymbol{x}) = (1, 2\sqrt{2}, 4)^\top$, $\phi(\boldsymbol{y}) = (9, -3\sqrt{2}, 1)^\top$ で $\langle \phi(\boldsymbol{x}), \phi(\boldsymbol{y}) \rangle = 9 - 12 + 4 = 1$、一方 $\boldsymbol{x}^\top \boldsymbol{y} = 1$ より $(\boldsymbol{x}^\top \boldsymbol{y})^2 = 1$。

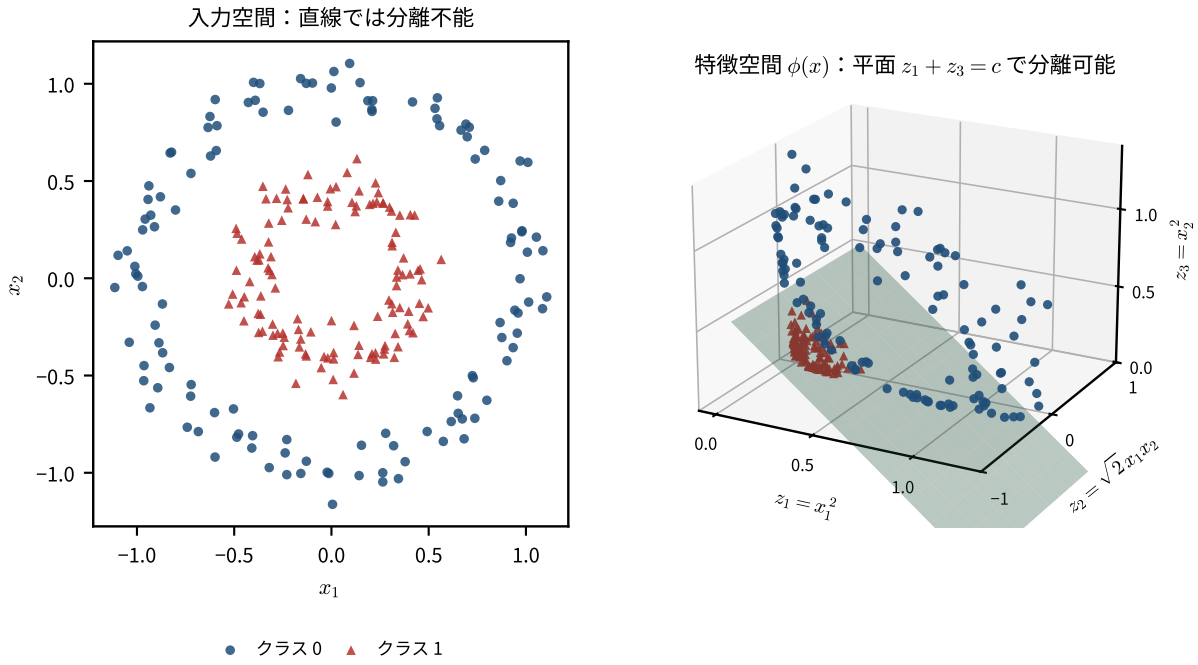


図7.1　特徴写像による線形化。左の同心円データは $\mathbb{R}^2$ の直線では分離できないが、$\phi(\boldsymbol{x}) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$ で $\mathbb{R}^3$ に写すと右のように平面で分離できる。分離平面を入力空間に引き戻すと円になる。

注意 7.1. d 次元で p 次の単項式をすべて並べた特徴写像の次元は $\binom{d+p-1}{p}$ で、$d = 100$, $p = 5$ なら約 9.2×10^7 次元となり陽には保持できないが、$(\boldsymbol{x}^\top \boldsymbol{y})^5$ の計算コストは $O(d)$ のままである。**高次元の特徴空間を、そこに立ち入らずに使う**のが要点である。

ただし $(\boldsymbol{x}^\top \boldsymbol{y})^2$ は「ある ϕ の内積として書ける」ことが最初から分かっていた例にすぎない。$k(\boldsymbol{x}, \boldsymbol{y}) = \exp(-\|\boldsymbol{x} - \boldsymbol{y}\|^2 / 2\sigma^2)$（ガウスカーネル）に対応する ϕ は存在するのか、するとしたらどんな空間への写像か、そして ϕ を経由せずに k だけを見て判定できるのか。これらに答えるのが本章の目標である。

7.2　距離空間と完備性

無限次元では「近い」を明示的に決めておかないと議論が進まない。最小限の枠組みを用意する。

定義 7.2 (距離空間)**.** 集合 M と関数 $\rho : M \times M \to \mathbb{R}$ の組 (M, ρ) が**距離空間** (metric space) であるとは、任意の $x, y, z \in M$ に対し次が成り立つことをいう。

(M1) $\rho(x, y) \geq 0$ かつ $\rho(x, y) = 0 \iff x = y$（非負性・非退化性）
(M2) $\rho(x, y) = \rho(y, x)$（対称性）
(M3) $\rho(x, z) \leq \rho(x, y) + \rho(y, z)$（三角不等式）

点列 $(x_m) \subset M$ が x に**収束する**とは $\rho(x_m, x) \to 0$ をいい、$x_m \to x$ と書く。極限は一意である（$x_m \to x$ かつ $x_m \to y$ なら $\rho(x, y) \leq \rho(x, x_m) + \rho(x_m, y) \to 0$ より $x = y$）。

収束の定義には極限 x が最初から必要である。しかし解析では「極限が何かはまだ分からないが点列は落ち着いていく」という状況を扱いたい。そのための概念が Cauchy 列である。

定義 7.3 (Cauchy 列・完備性)**.** 点列 $(x_m) \subset M$ が **Cauchy 列**であるとは、任意の $\varepsilon > 0$ に対しある N が存在して $l, m \geq N$ ならば $\rho(x_l, x_m) < \varepsilon$ となることをいう。距離空間 (M, ρ) が**完備** (complete) であるとは、M 内の任意の Cauchy 列が M の元に収束することをいう。

収束列は必ず Cauchy 列である（$\rho(x_l, x_m) \leq \rho(x_l, x) + \rho(x, x_m)$）が、逆は一般には成り立たない。それが「穴が空いている」ということである。

例 7.4 ($\mathbb{Q}$ は完備でない)**.** $\mathbb{Q}$ に $\rho(x, y) = |x - y|$ を入れる。$x_1 = 1$, $x_{m+1} = \frac{1}{2}\left(x_m + \frac{2}{x_m}\right)$ で定まる列 $1, \frac{3}{2}, \frac{17}{12}, \frac{577}{408}, \ldots$ はすべて有理数の Cauchy 列だが、極限は $\sqrt{2} \notin \mathbb{Q}$ である。「$x^2 = 2$ の解を探す」という問題の解が $\mathbb{Q}$ に存在しない、と言い換えてもよい。$\mathbb{R}$ はこの穴を埋めて作られる。

例 7.5 ($C[0,1]$ は L^2 ノルムで完備でない)**.** $[0, 1]$ 上の連続関数全体を $C[0, 1]$ とし、距離を $\rho_2(f, g) = \left(\int_0^1 |f(t) - g(t)|^2 \, \mathrm{d}t\right)^{1/2}$

で入れる。$m \geq 2$ に対し

$$f_m(t) = \begin{cases} 0, & 0 \leq t \leq \frac{1}{2}, \\ m\big(t - \frac{1}{2}\big), & \frac{1}{2} < t < \frac{1}{2} + \frac{1}{m}, \\ 1, & \frac{1}{2} + \frac{1}{m} \leq t \leq 1 \end{cases}$$

と定めると、各 f_m は連続である。$l \leq m$ のとき f_l と f_m が異なるのは幅 $1/l$ の区間だけで、そこでの差は高々 1 だから $\rho_2(f_l, f_m)^2 \leq 1/l \to 0$、すなわち (f_m) は Cauchy 列である。一方、$H(t) = \mathbf{1}\{t > 1/2\}$（Heaviside 関数）に対して $\rho_2(f_m, H)^2 \leq 1/m \to 0$ である。もし (f_m) が連続関数 f に ρ_2 で収束するなら $\rho_2(f, H) = 0$ となるが、f が連続で H が $t = 1/2$ で跳ぶ以上これは不可能である[*1]。よって $(C[0,1], \rho_2)$ は完備でない。この穴を埋めて得られるのが $L^2[0,1]$ である。

完備性がデータ解析で効く場面は二つある。

第一に、最適化問題の解の存在である。$\min_{f \in \mathcal{F}} J(f)$ を解くとき、下限 $J^* = \inf_f J(f)$ に対する最小化列 (f_m) を作るのが標準的な手順だが、(f_m) が Cauchy 列でも $\mathcal{F}$ が完備でなければ極限が $\mathcal{F}$ の外に逃げ、「最小値を達成する f」が存在しない。例 7.4 で $\sqrt{2}$ が有理数の中に無いのと同じ事情である。

第二に、極限操作の正当化である。無限級数 $f = \sum_i c_i e_i$ の部分和が Cauchy 列であることは Bessel の不等式から出るが、それが空間の元に収束すると言えるのは完備性のおかげである。Moore–Aronszajn の定理（定理 7.32）も「完備化を取る」操作の上に成り立っている。

測度論について

本講義では測度論を仮定しない。$L^2[a,b]$ は「$\int_a^b |f|^2 \, \mathrm{d}t < \infty$ を満たす関数の全体（ただしほとんど至るところ一致する関数は同一視する）」という直感的な理解で通す。L^2 が完備であること（Riesz–Fischer の定理）は**認めて使う**。証明には Lebesgue 積分の収束定理が必要であり、本講義の範囲を超える。以下、測度論を要する箇所は「※ 測度論を要するため省略」と明示する。

7.3　ノルム空間・内積空間・Hilbert 空間

距離だけでは足りない。データ解析ではベクトルの和とスカラー倍が要るし、「長さ」「角度」も欲しい。そこで線形構造と両立する距離を段階的に導入する。以下ベクトル空間はすべて $\mathbb{R}$ 上のものとする（複素数体上でも同様に構成できるが、本講義で扱うカーネルはすべて実数値なので実の場合に限る）。

2.2節では $\mathbb{R}^d$ の標準内積・ユークリッドノルム・距離を扱った。ここではそこで現れた性質を**公理として抽出し**、任意のベクトル空間へ一般化する。一般化して得をするのは、**無限次元では完備性が自動でない**からである（例 7.5がその例だった）。有限次元のノルム空間は必ず完備なので、第2章では完備性を問う必要がなかった。

定義 7.6 (ノルム空間・Banach 空間)**.** ベクトル空間 V 上の関数 $\|\cdot\| : V \to \mathbb{R}$ が**ノルム**であるとは、任意の $f, g \in V$, $a \in \mathbb{R}$ に対し

(N1) $\|f\| \geq 0$ かつ $\|f\| = 0 \iff f = 0$
(N2) $\|af\| = |a| \, \|f\|$（斉次性）
(N3) $\|f + g\| \leq \|f\| + \|g\|$（三角不等式）

が成り立つことをいう。ノルムを備えたベクトル空間の組 $(V, \|\cdot\|)$ を **ノルム空間**（normed space）という。(N1)–(N3) は $\mathbb{R}^d$ のユークリッドノルムがもつ性質（命題 2.5）を公理として抜き出したもので、V が無限次元でもよいという点だけが違う。

ノルム空間では $\rho(f, g) := \|f - g\|$ が V 上の距離になる（$f - h = (f - g) + (g - h)$ に (N1)–(N3) を使えばよく、次元を使っていない）。そこでノルム空間は距離空間でもあり、完備性を問うことができる。この距離について**完備**なノルム空間を **Banach 空間**（Banach space）という。

定義 7.7 (内積空間・Hilbert 空間)**.** ベクトル空間 V 上の関数 $\langle \cdot, \cdot \rangle : V \times V \to \mathbb{R}$ が**内積**であるとは、任意の $f, g, h \in V$, $a, b \in \mathbb{R}$ に対し

(I1) $\langle af + bg, h \rangle = a\langle f, h \rangle + b\langle g, h \rangle$（第 1 変数について線形）
(I2) $\langle f, g \rangle = \langle g, f \rangle$（対称性）
(I3) $\langle f, f \rangle \geq 0$ かつ $\langle f, f \rangle = 0 \iff f = 0$（正定値性）

が成り立つことをいう。内積を備えたベクトル空間の組 $(V, \langle \cdot, \cdot \rangle)$ を **内積空間**（inner product space）、あるいは**前 Hilbert 空間**（pre-Hilbert space）という。(I1)–(I3) も $\mathbb{R}^d$ の標準内積（定義 2.3）がもつ性質そのものである。

[*1] より丁寧には、f が連続で $\int_0^1 |f - H|^2 \, \mathrm{d}t = 0$ とすると、$f = H$ が成り立たない点の近傍で $|f - H|$ は正の下限をもち、積分が正になって矛盾する。

内積空間では $\|f\| \coloneqq \langle f,f\rangle^{1/2}$ がノルムになり、これを**誘導ノルム**と呼ぶ。実際、定理 2.4の Cauchy–Schwarz の不等式 $|\langle f,g\rangle| \le \|f\|\|g\|$ とそこからの三角不等式の導出は (I1)–(I3) しか使っていないので、無限次元でもそのまま通用する。したがって内積空間はノルム空間でもあり、さらに距離空間でもある。この誘導ノルムについて**完備**な内積空間を **Hilbert 空間**（Hilbert space）という。

包含関係は「内積空間 $\subset$ ノルム空間 $\subset$ 距離空間」かつ「Hilbert 空間 $\subset$ Banach 空間」であり、完備性を付けるのが縦、構造を弱めるのが横である。左の包含はいずれも**誘導**によるもので、内積から誘導ノルム $\|f\| = \langle f,f\rangle^{1/2}$、ノルムから距離 $\rho(f,g) = \|f-g\|$ が作られる（2.2節の鎖がそのまま無限次元で通用する）。逆向きは一般に成り立たない。なお $\|\cdot\|$ が実際にノルムであること、とくに三角不等式は Cauchy–Schwarz の不等式

$$|\langle f,g\rangle| \le \|f\|\,\|g\| \tag{7.2}$$

から従う。証明は有限次元と同じで、$0 \le \|f-tg\|^2 = \|f\|^2 - 2t\langle f,g\rangle + t^2\|g\|^2$ が全ての $t\in\mathbb{R}$ で成り立つことから判別式が非正、として得られる。また (7.2) より内積は連続である：$f_m \to f$ なら $|\langle f_m,g\rangle - \langle f,g\rangle| \le \|f_m-f\|\|g\| \to 0$。この連続性を以後何度も使う。

すべてのノルムが内積から来るわけではない。判定条件は簡潔である。

命題 7.8 (中線定理／平行四辺形則)**.** 内積空間のノルムは、任意の f,g に対し

$$\|f+g\|^2 + \|f-g\|^2 = 2\|f\|^2 + 2\|g\|^2 \tag{7.3}$$

を満たす。逆に、ノルム空間のノルムが (7.3) を満たせば、

$$\langle f,g\rangle \coloneqq \tfrac{1}{4}\bigl(\|f+g\|^2 - \|f-g\|^2\bigr) \tag{7.4}$$

は内積であり、そのノルムは元のノルムに一致する（Jordan–von Neumann の定理）。

証明. 前半のみ示す。双線形性から $\|f\pm g\|^2 = \|f\|^2 \pm 2\langle f,g\rangle + \|g\|^2$ で、辺々加えれば $\langle f,g\rangle$ の項が相殺して (7.3) を得る。後半（(7.4) の加法性と斉次性の確認）は初等的だが場合分けが長いので省略する。有理数倍の斉次性を先に示し、連続性で実数倍に拡張するのが筋道である。 ∎

(7.3) は「平行四辺形の対角線の二乗和は辺の二乗和の 2 倍」という初等幾何の定理そのものである。無限次元でもこれが成り立つ空間では有限次元と同じ幾何が使え、破れる空間では「直交」が定義できない。

例 7.9 (主要な例)**.** $\mathbb{R}^d$ に $\langle \boldsymbol{x},\boldsymbol{y}\rangle = \boldsymbol{x}^{\top}\boldsymbol{y}$、$\ell^2 \coloneqq \{(c_1,c_2,\dots) : \sum_i c_i^2 < \infty\}$ に $\langle \boldsymbol{c},\boldsymbol{d}\rangle = \sum_i c_i d_i$、$L^2[a,b]$ に $\langle f,g\rangle = \int_a^b fg\,\mathrm{d}t$ はいずれも Hilbert 空間である（後二つが無限次元。L^2 の完備性は認めて使う）。一方 $C[0,1]$ に $\|f\|_\infty = \max_t|f(t)|$ を入れると Banach 空間だが Hilbert 空間ではない。実際 $f(t)=1$, $g(t)=t$ なら $\|f+g\|_\infty = 2$, $\|f-g\|_\infty = 1$, $\|f\|_\infty = \|g\|_\infty = 1$ で (7.3) の左辺 5、右辺 4 が一致せず、$\|\cdot\|_\infty$ はどんな内積からも来ない。$C[0,1]$ に L^2 内積を入れたものは内積空間だが完備でなく（例 7.5）、これも Hilbert 空間ではない。

7.4 Hilbert 空間の幾何

本節が本章の技術的な中心である。主張は一点に尽きる。**Hilbert 空間では、$\mathbb{R}^d$ で慣れ親しんだ幾何がそのまま通用する**。ただしその証明には、有限次元では自明だった箇所で完備性が効いてくる。

$\langle f,g\rangle = 0$ のとき $f \perp g$ と書き、部分集合 $S\subset\mathcal{H}$ に対し $S^{\perp} \coloneqq \{f\in\mathcal{H} : \langle f,g\rangle = 0\ \forall g\in S\}$ を S の**直交補空間**という。内積の連続性から $S^{\perp}$ はつねに**閉**部分空間である（$f_m\in S^{\perp}$, $f_m\to f$ なら $\langle f,g\rangle = \lim\langle f_m,g\rangle = 0$）。$S$ 自身が閉である必要はない。

$\mathbb{R}^d$ では「部分空間への最短点＝直交射影」であった。無限次元でも同じことが、しかも部分空間より広い閉凸集合に対して成り立つ。完備性の最初の出番である。

定理 7.10 (射影定理)**.** $\mathcal{H}$ を Hilbert 空間、$C\subset\mathcal{H}$ を空でない閉凸集合とする。任意の $f\in\mathcal{H}$ に対し $\|f-g^*\| = \inf_{g\in C}\|f-g\| =: \delta$ を満たす $g^*\in C$ がただ一つ存在する。とくに $C=M$ が閉部分空間のとき、g^* は $f-g^*\in M^{\perp}$ で特徴づけられ、$\mathcal{H} = M\oplus M^{\perp}$（直交直和分解）が成り立つ。

証明. **(存在)** 下限の定義より、$\|f-g_m\|\to\delta$ となる列 $(g_m)\subset C$ が取れる。この列が Cauchy 列であることを中線定理から示す。(7.3) を $u = f-g_l$, $v = f-g_m$ に適用すると、$u+v = 2f-(g_l+g_m)$, $u-v = g_m-g_l$ だから

$$\|2f-(g_l+g_m)\|^2 + \|g_m-g_l\|^2 = 2\|f-g_l\|^2 + 2\|f-g_m\|^2. \tag{7.5}$$

左辺第 1 項は $4\left\|f-\frac{g_l+g_m}{2}\right\|^2$ に等しい。C は凸だから中点 $\frac{g_l+g_m}{2}$ も C に属し、したがって $\left\|f-\frac{g_l+g_m}{2}\right\|\geq\delta$、すなわち左辺第 1 項は $4\delta^2$ 以上である。よって (7.5) から

$$\|g_m-g_l\|^2\leq 2\|f-g_l\|^2+2\|f-g_m\|^2-4\delta^2. \tag{7.6}$$

$l,m\to\infty$ のとき右辺は $2\delta^2+2\delta^2-4\delta^2=0$ に収束するから、(g_m) は Cauchy 列である。$\mathcal{H}$ は完備だから極限 $g^*\in\mathcal{H}$ が存在し、C は閉だから $g^*\in C$。ノルムの連続性より $\|f-g^*\|=\lim\|f-g_m\|=\delta$。

(一意性) g_1^*,g_2^* がともに最小点なら、上の議論の (g_m) として $g_1^*,g_2^*,g_1^*,g_2^*,\dots$ を取ればよい。すなわち (7.6) で $g_l=g_1^*$, $g_m=g_2^*$ とすると $\|g_2^*-g_1^*\|^2\leq 2\delta^2+2\delta^2-4\delta^2=0$、よって $g_1^*=g_2^*$。

(部分空間の場合) $C=M$ を閉部分空間とし $h:=f-g^*$ とおく。任意の $u\in M$, $t\in\mathbb{R}$ に対し $g^*+tu\in M$ だから

$$\delta^2\leq\|f-g^*-tu\|^2=\|h\|^2-2t\langle h,u\rangle+t^2\|u\|^2.$$

$\|h\|^2=\delta^2$ なので $-2t\langle h,u\rangle+t^2\|u\|^2\geq 0$ がすべての $t\in\mathbb{R}$ で成り立つ。t を 0 の近くで正負に動かすと $\langle h,u\rangle=0$ でなければならない[*2]。$u\in M$ は任意だから $h\in M^\perp$。逆に $f=g+h$（$g\in M$, $h\in M^\perp$）と書けたとすると、任意の $u\in M$ に対し Pythagoras の定理から $\|f-u\|^2=\|(g-u)+h\|^2=\|g-u\|^2+\|h\|^2\geq\|h\|^2$ であり、等号は $u=g$ のときに限る。すなわち g は最短点であり、一意性から $g=g^*$。分解の一意性も同様に従い、$\mathcal{H}=M\oplus M^\perp$ を得る。 ■

注意 7.11. 完備性をどこで使ったかを確認しておく。最小化列 (g_m) が Cauchy 列であることは中線定理と凸性だけから出たが、その極限が存在すると言うには完備性が要る。例 7.5 の $C[0,1]$ で同じ議論をすると最小化列は Cauchy だが極限が不連続関数になり、最小点が空間内に存在しない。「完備でないと最適化の解が存在しない」とはこのことである。

例 7.12 (2 次元での確認)**.** $\mathcal{H}=\mathbb{R}^2$, $M=\operatorname{span}\{\boldsymbol{u}\}$, $\boldsymbol{u}=(1,1)^\top/\sqrt{2}$, $f=(3,1)^\top$ とする。$g^*=\langle f,\boldsymbol{u}\rangle\boldsymbol{u}=(2,2)^\top$、残差 $h=(1,-1)^\top$ は確かに $\langle h,\boldsymbol{u}\rangle=0$ を満たし、$\|f-g^*\|=\sqrt{2}$。M 上の他の点、たとえば $(1,1)^\top$ では距離が $2>\sqrt{2}$ である。第2章の直交射影がそのまま無限次元に持ち上がったのが定理 7.10である。

定義 7.13 (正規直交系)**.** $\mathcal{H}$ の元の族 $\{e_i\}_{i\in I}$ が**正規直交系**（orthonormal system, ONS）であるとは、$\langle e_i,e_j\rangle=\delta_{ij}$（$i=j$ なら 1、そうでなければ 0）が成り立つことをいう。さらに $\operatorname{span}\{e_i\}_{i\in I}$ が $\mathcal{H}$ で稠密であるとき、$\{e_i\}$ は**完全**（complete）であるといい、**完全正規直交系**（complete orthonormal system, CONS）と呼ぶ。

$\mathbb{R}^d$ の標準基底に相当する概念である。無限次元では「基底」を線形代数の意味（有限個の線形結合で全てが書ける）で使うと族が非常に大きくなってしまうため、「稠密」で置き換えるのが標準である。

定理 7.14 (Bessel の不等式と Parseval の等式)**.** $\{e_i\}_{i\geq1}$ を可算な正規直交系、$f\in\mathcal{H}$、$c_i:=\langle f,e_i\rangle$ とする。このとき $\sum_{i\geq1}c_i^2\leq\|f\|^2$（**Bessel の不等式**）が成り立ち、さらに $\{e_i\}$ が完全ならば $f=\sum_{i\geq1}c_ie_i$ かつ $\|f\|^2=\sum_{i\geq1}c_i^2$（**Parseval の等式**）が成り立つ（級数は $\mathcal{H}$ のノルムで収束する）。

証明. $S_m:=\sum_{i\leq m}c_ie_i$ とおく。正規直交性から $j\leq m$ で $\langle f-S_m,e_j\rangle=c_j-c_j=0$ なので $f-S_m\perp S_m$、よって Pythagoras の定理より

$$\|f\|^2=\|f-S_m\|^2+\|S_m\|^2=\|f-S_m\|^2+\sum_{i\leq m}c_i^2. \tag{7.7}$$

第 1 項は非負だから $\sum_{i\leq m}c_i^2\leq\|f\|^2$ が全ての m で成り立ち、$m\to\infty$ として Bessel の不等式を得る。

したがって $\sum_i c_i^2$ は収束し、$l<m$ で $\|S_m-S_l\|^2=\sum_{i=l+1}^m c_i^2\to0$、すなわち (S_m) は Cauchy 列だから完備性よりある $g\in\mathcal{H}$ に収束する。$h:=f-g$ とおくと内積の連続性より各 j で $\langle h,e_j\rangle=0$、よって $h\perp\operatorname{span}\{e_i\}$ とその閉包。完全性よりその閉包は $\mathcal{H}$ 全体だから $h=0$、すなわち $f=\sum_i c_ie_i$。(7.7) で $m\to\infty$ とすれば Parseval の等式を得る。 ■

注意 7.15 (可分性と ℓ^2 との同型)**.** $\mathcal{H}$ が**可分**（separable）であるとは可算な稠密部分集合をもつことをいい、本講義に現れる Hilbert 空間はすべて可分である。可分な無限次元 Hilbert 空間は可算な CONS をもち（稠密可算集合に Gram–Schmidt を適用）、定理 7.14 により $f\mapsto(\langle f,e_i\rangle)_i$ が ℓ^2 への内積を保つ全単射を与える。すなわち **可分無限次元 Hilbert 空間は本質的に ℓ^2 ただ一つ**である。結果のみ用いる。

RKHS の定義の核心となる定理に進む。$\mathbb{R}^d$ では線形写像 $L:\mathbb{R}^d\to\mathbb{R}$ は必ずある $\boldsymbol{g}$ を使って $L(\boldsymbol{x})=\boldsymbol{g}^\top\boldsymbol{x}$ と書けた（$\boldsymbol{g}$ の第 i 成分は $L(\boldsymbol{e}_i)$）。無限次元でも同じことが言えるなら、「関数 f にその点 x での値 $f(x)$ を対応させる」操作もまた何らかの元との内積で表せる。それが再生核の正体である。

定義 7.16 (有界線形汎関数)**.** 線形写像 $L:\mathcal{H}\to\mathbb{R}$ が**有界**であるとは、ある定数 $C\geq0$ が存在して $|L(f)|\leq C\|f\|$ が全ての $f\in\mathcal{H}$ で成り立つことをいう。このとき $\|L\|:=\sup_{f\neq0}|L(f)|/\|f\|$ を L のノルムという。

[*2] 実際 $\langle h,u\rangle\neq0$ なら $t=\langle h,u\rangle/\|u\|^2$ と取れば左辺は $-\langle h,u\rangle^2/\|u\|^2<0$ となり矛盾する。

命題 7.17 (有界性と連続性の同値)**.** 線形写像 $L:\mathcal{H}\to\mathbb{R}$ について、次は同値である。(i) L は有界、(ii) L は $\mathcal{H}$ 上連続、(iii) L は 0 で連続。

証明. (i)⇒(ii)：$|L(f)-L(g)|=|L(f-g)|\le C\|f-g\|$ より Lipschitz 連続。(ii)⇒(iii) は自明。(iii)⇒(i)：0 での連続性より $\varepsilon=1$ に対しある $\delta>0$ があって $\|f\|\le\delta\Rightarrow|L(f)|\le 1$。任意の $f\neq 0$ で $\delta f/\|f\|$ はノルム δ だから $|L(f)|\le\|f\|/\delta$、$C=1/\delta$ でよい。 ■

$\mathbb{R}^d$ 上の線形汎関数は**つねに**有界である（$L(\boldsymbol{x})=\sum_i x_i L(\boldsymbol{e}_i)$ と Cauchy–Schwarz による）が、無限次元ではそうではない。ℓ^2 上の $L(\boldsymbol{c})=\sum_i i c_i$ は発散しうるし、$C[0,1]$ に L^2 内積を入れた空間で $\delta_{1/2}(f)=f(1/2)$ は有界でない（例 7.29）。**「有界」という仮定は無限次元では本質的な制約である。**

定理 7.18 (Riesz の表現定理)**.** $\mathcal{H}$ を Hilbert 空間、$L:\mathcal{H}\to\mathbb{R}$ を有界線形汎関数とする。このとき $g\in\mathcal{H}$ がただ一つ存在して

$$L(f)=\langle f,g\rangle\qquad(\forall f\in\mathcal{H}) \tag{7.8}$$

が成り立つ。さらに $\|L\|=\|g\|$ である。

主張の形は有限次元版（命題 2.11）とまったく同じである。違いは仮定に**有界**が入ったことだけで、有限次元では線形性から有界性が従ったのに対し、無限次元ではこれを課さないと表現ベクトルが存在しない。証明も変わる。有限次元では正規直交基底で展開して $\boldsymbol{a}=\sum_i\varphi(\boldsymbol{u}_i)\boldsymbol{u}_i$ と作れたが、無限次元では代わりに $\operatorname{Ker}L$ への射影（定理 7.10）を使う。

証明. $L=0$ なら $g=0$ でよいので $L\neq 0$ とし、$N:=\operatorname{Ker}L$ とおく。L は線形なので N は部分空間、連続なので $N=L^{-1}(\{0\})$ は閉である。$L\neq 0$ より $N\neq\mathcal{H}$ だから、定理 7.10の分解 $\mathcal{H}=N\oplus N^{\perp}$ より $N^{\perp}\neq\{0\}$、すなわち $\|u\|=1$ なる $u\in N^{\perp}$ が取れる。

$N^{\perp}$ が 1 次元であること。 $v\in N^{\perp}$ を任意に取る。$L(u)\neq 0$ である（$L(u)=0$ なら $u\in N\cap N^{\perp}=\{0\}$ となり $\|u\|=1$ に矛盾）。そこで

$$w:=v-\frac{L(v)}{L(u)}\,u$$

とおくと $L(w)=0$ より $w\in N$、一方 $v,u\in N^{\perp}$ より $w\in N^{\perp}$。よって $w\in N\cap N^{\perp}=\{0\}$、すなわち $v=\frac{L(v)}{L(u)}u$。v は任意だから $N^{\perp}=\operatorname{span}\{u\}$ で、これは 1 次元である。

表現元の構成。 任意の $f\in\mathcal{H}$ を $f=f_N+\langle f,u\rangle u$ （$f_N\in N$）と分解する[*3]。L の線形性と $L(f_N)=0$ から

$$L(f)=\langle f,u\rangle L(u)=\langle f,\,L(u)\,u\rangle.$$

よって $g:=L(u)\,u$ が (7.8) を満たす。

一意性。 g_1,g_2 がともに (7.8) を満たせば全ての f で $\langle f,g_1-g_2\rangle=0$。$f=g_1-g_2$ と取れば $g_1=g_2$。

ノルムの等式。 Cauchy–Schwarz より $|L(f)|\le\|f\|\|g\|$ なので $\|L\|\le\|g\|$。逆に $f=g\neq 0$ を代入すると $|L(g)|=\|g\|^2$ より $\|L\|\ge\|g\|$。よって $\|L\|=\|g\|$。 ■

Riesz の表現定理の読み方

「有界な線形汎関数は内積の片側として実現される」。ここから直ちに次が言える。$\mathcal{H}$ が関数の空間で、各点 x での値を返す汎関数 $\delta_x:f\mapsto f(x)$ が有界なら、ある $k_x\in\mathcal{H}$ が存在して $f(x)=\langle f,k_x\rangle$ となる。この k_x の族が**再生核**であり、$k(x,y):=\langle k_y,k_x\rangle$ が本章の主役のカーネルである。7.7節でこの筋道を正式に辿る。

7.5　有界作用素とコンパクト作用素

汎関数の次は作用素である。第2章の対称固有値分解 $\boldsymbol{A}=\sum_i\lambda_i\boldsymbol{u}_i\boldsymbol{u}_i^{\top}$ が無限次元でどこまで生き延びるかを見ておく。本節の結果は7.9節の Mercer の定理で使う。

定義 7.19 (有界作用素・自己共役作用素)**.** 線形写像 $T:\mathcal{H}\to\mathcal{H}$ が**有界**であるとは $\|T\|_{\mathrm{op}}:=\sup_{\|f\|\le 1}\|Tf\|<\infty$ をいう（命題 7.17と同じ議論で有界性と連続性は同値）。有界作用素 T が**自己共役**（self-adjoint）であるとは $\langle Tf,g\rangle=\langle f,Tg\rangle$ が全ての f,g で成り立つこと、**半正定値**であるとはさらに $\langle Tf,f\rangle\ge 0$ が成り立つことをいう。有限次元では自己共役＝対称行列、半正定値＝半正定値行列である。

[*3]実際 $f-\langle f,u\rangle u$ は u と直交し、$N^{\perp}=\operatorname{span}\{u\}$ だから $N^{\perp\perp}=N$（N は閉部分空間）より N に属する。

有限次元との最大の違いは、**有界自己共役作用素であっても固有値をもつとは限らない**ことである。$L^2[0,1]$ 上の掛け算作用素 $(Tf)(t) = tf(t)$ は有界かつ自己共役だが $tf(t) = \lambda f(t)$ を満たす $f \neq 0$ はない（$t \neq \lambda$ でほとんど至るところ $f = 0$）。行列の固有値分解を持ち上げるには、もう一段強い条件が要る。

定義 7.20 (コンパクト作用素)**.** 有界作用素 T が**コンパクト**であるとは、任意の有界列 (f_m) に対し (Tf_m) が収束部分列をもつことをいう。同値な特徴づけとして、T が有限階作用素（値域が有限次元）の列の作用素ノルム極限として書けること、がある。

直感的には「無限次元を有限次元でいくらでもよく近似できる」作用素である。有限次元では全ての線形写像がコンパクトで、上の掛け算作用素はコンパクトでない。

定理 7.21 (コンパクト自己共役作用素のスペクトル定理)**.** $\mathcal{H}$ を可分な Hilbert 空間、$T : \mathcal{H} \to \mathcal{H}$ をコンパクトかつ自己共役な作用素とする。このとき次が成り立つ。

(i) 固有値はすべて実数で、$\operatorname{Ker} T$ の直交補空間の正規直交基底 $\{e_i\}_{i \in I}$（I は高々可算）と実数列 $\{\lambda_i\}$ が存在して $Te_i = \lambda_i e_i$。
(ii) I が無限集合のとき $\lambda_i \to 0$。とくに $|\lambda_i| > \varepsilon$ なる i は任意の $\varepsilon > 0$ に対し有限個で、0 以外の固有値の重複度は有限。
(iii) 任意の f に対し $Tf = \sum_{i \in I} \lambda_i \langle f, e_i \rangle e_i$ が $\mathcal{H}$ のノルムで収束し、$\|T\|_{\mathrm{op}} = \max_i |\lambda_i|$。
(iv) T が半正定値ならば全ての $\lambda_i \geq 0$。

証明は本講義の範囲を超えるので**結果のみ**を用いる。筋道としては、自己共役性から従う $\|T\|_{\mathrm{op}} = \sup_{\|f\|=1} |\langle Tf, f \rangle|$ を使って Rayleigh 商の最大化列を取り、コンパクト性で収束部分列を抜き出して最大固有ベクトルを作り、その直交補空間に T を制限して同じ操作を繰り返す。**第3章で PCA の主成分を逐次的に取り出した手続きと同じ構造**であり、有限次元では有界閉集合のコンパクト性が自動的に効くのに対し、無限次元では T のコンパクト性がその役割を肩代わりする点だけが異なる。

例 7.22 (積分作用素と Hilbert–Schmidt 作用素)**.** $\mathcal{X} \subset \mathbb{R}^d$ をコンパクト集合、μ を $\mathcal{X}$ 上の有限測度、k を $\iint k^2 \, \mathrm{d}\mu \, \mathrm{d}\mu < \infty$ を満たす関数とする。

$$(T_k f)(x) \coloneqq \int_{\mathcal{X}} k(x, y) f(y) \, \mathrm{d}\mu(y) \tag{7.9}$$

で定まる $T_k : L^2(\mu) \to L^2(\mu)$ を**積分作用素**、k をその**核**という。T_k は **Hilbert–Schmidt 作用素**と呼ばれ、つねにコンパクトである（k を $L^2(\mu \otimes \mu)$ の CONS で展開して打ち切れば有限階作用素の列が得られ、T_k に作用素ノルムで収束する）。k が対称なら T_k は自己共役なので 定理 7.21が使える。これが Mercer の定理の舞台装置である。

なお $\mathcal{X} = \{x_1, \dots, x_n\}$ が有限集合、μ が各点に重み $1/n$ を置く測度なら $L^2(\mu) \cong \mathbb{R}^n$、$(T_k f)(x_i) = \frac{1}{n} \sum_j k(x_i, x_j) f(x_j)$ となり T_k は $\frac{1}{n}\boldsymbol{K}$ そのもの、定理 7.21はその対称固有値分解に他ならない。すなわち**積分作用素 T_k は、有限標本上の $\frac{1}{n}\boldsymbol{K}$ に対応する母集団版**とみなせる。ただし両者が作用する空間は $L^2(\mu)$ と $\mathbb{R}^n$ で別物なので、「$\boldsymbol{K}$ が T_k に収束する」という言い方は正確でない。対応するのは経験分布についての積分作用素と母分布についての積分作用素である。

7.6　正定値カーネル

7.1節の問い (1) に答える。「k がある特徴写像の内積として書ける」ための条件は、Gram 行列の半正定値性である。

定義 7.23 (正定値カーネル)**.** 集合 $\mathcal{X}$ 上の関数 $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ が**正定値カーネル**（positive definite kernel）であるとは、

(K1)（対称性）任意の $x, y \in \mathcal{X}$ に対し $k(x, y) = k(y, x)$、
(K2)（半正定値性）任意の $n \in \mathbb{N}$、任意の $x_1, \dots, x_n \in \mathcal{X}$、任意の $\boldsymbol{c} \in \mathbb{R}^n$ に対し

$$\sum_{i=1}^{n} \sum_{j=1}^{n} c_i c_j \, k(x_i, x_j) \;\geq\; 0 \tag{7.10}$$

が成り立つことをいう。(7.10) は Gram 行列 $\boldsymbol{K} = (k(x_i, x_j))_{ij} \in \mathbb{R}^{n \times n}$ が半正定値、すなわち $\boldsymbol{c}^{\top} \boldsymbol{K} \boldsymbol{c} \geq 0$ であることに他ならない。

用語には注意が必要である。行列では $\boldsymbol{c}^{\top} \boldsymbol{K} \boldsymbol{c} \geq 0$ を「半正定値」、$\boldsymbol{c} \neq \boldsymbol{0}$ で $\boldsymbol{c}^{\top} \boldsymbol{K} \boldsymbol{c} > 0$ を「正定値」と呼び分けるが、カーネルでは歴史的経緯から $\boldsymbol{c}^{\top} \boldsymbol{K} \boldsymbol{c} \geq 0$ の方を「正定値カーネル」と呼ぶのが慣例で（狭義のものは「狭義正定値カーネル」）、本書もこれに従う。また $\mathcal{X}$ が無限集合でも、条件は **任意の有限個の点**についてのものであることに注意する。

必要性の方向は易しい。もし $k(x, y) = \langle \phi(x), \phi(y) \rangle_{\mathcal{F}}$ と書けたなら

$$\sum_{i,j} c_i c_j k(x_i, x_j) = \Big\langle \sum_i c_i \phi(x_i), \; \sum_j c_j \phi(x_j) \Big\rangle_{\mathcal{F}} = \Big\| \sum_i c_i \phi(x_i) \Big\|_{\mathcal{F}}^2 \;\geq\; 0 \tag{7.11}$$

であり、対称性も内積の対称性から従う。本章の山場は**逆**、すなわち正定値性から特徴写像を構成することであり、それが7.7節の Moore–Aronszajn の定理である。

代表的な正定値カーネルを挙げる。$\mathcal{X} \subset \mathbb{R}^d$、$r = \|\boldsymbol{x} - \boldsymbol{y}\|$ とする。**線形** $\boldsymbol{x}^{\top} \boldsymbol{y}$（特徴空間は d 次元）と**多項式** $(\boldsymbol{x}^{\top} \boldsymbol{y} + c)^p$（$c \geq 0$, $p \in \mathbb{N}$、$\binom{d+p}{p}$ 次元）は (7.11) により正定値である。以下は特徴空間が無限次元になる。**ガウス RBF** $\exp(-r^2 / 2\sigma^2)$（$\sigma > 0$ を

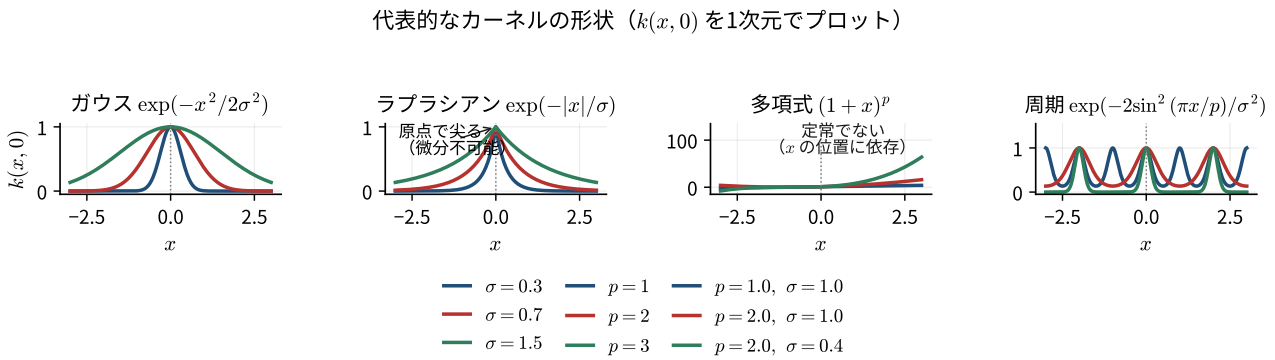


図7.2　代表的なカーネルの断面 $k(x,0)$。帯域幅の異なるガウス、ラプラシアン、次数の異なる多項式、周期カーネルを並べた。ガウスは原点で滑らかだがラプラシアンは尖っており、この違いが生成される関数の滑らかさに直結する。

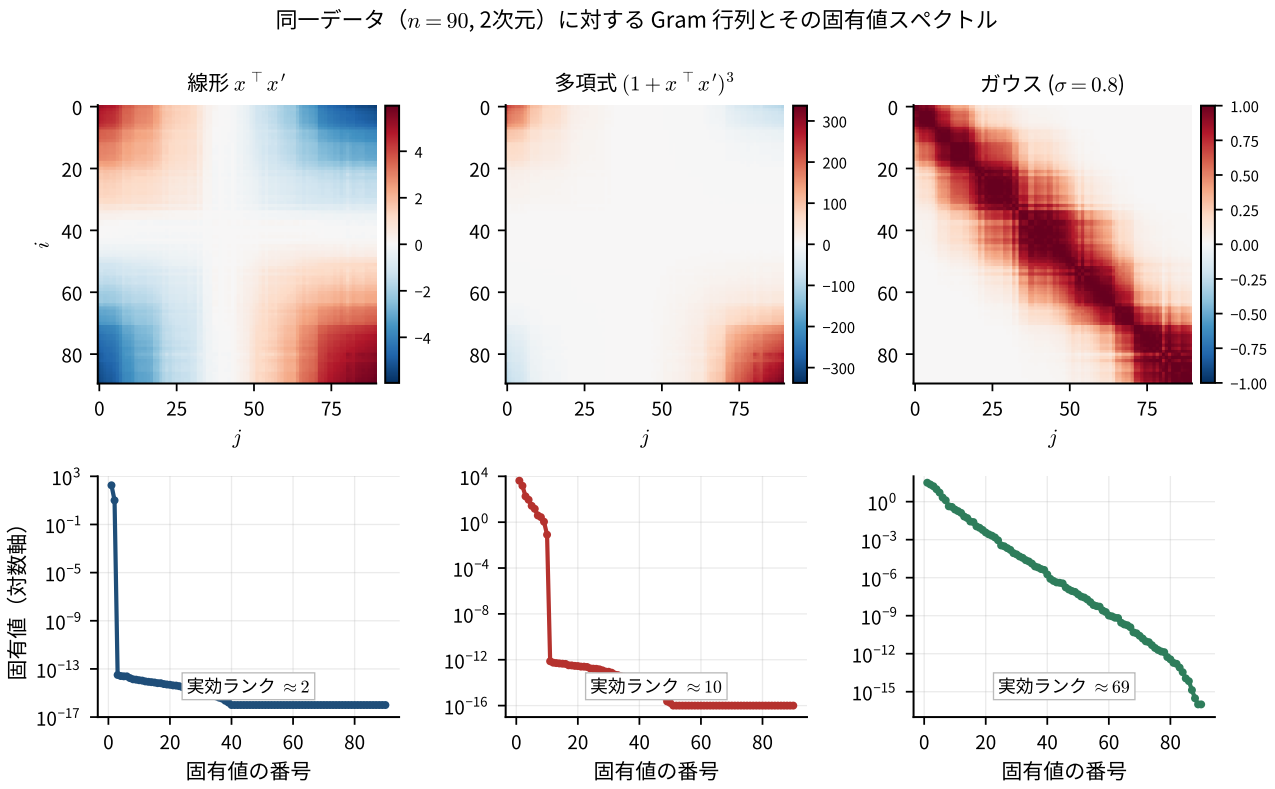


図7.3　同一のデータに対する線形・多項式・ガウスカーネルの Gram 行列とその固有値スペクトル。線形カーネルの階数は高々 d で頭打ちになるのに対し、ガウスカーネルの固有値は 0 に向かってなだらかに減衰し、階数は原理的に n である。

帯域幅という。正定値性は命題 7.27で示す)、**ラプラシアン** $\exp(-\|\boldsymbol{x}-\boldsymbol{y}\|_1/\sigma)$、**周期**（$d=1$）$\exp(-2\sin^2(\pi|x-y|/p)/\sigma^2)$、そして **Matérn** $\frac{2^{1-\nu}}{\Gamma(\nu)}(\sqrt{2\nu}r/\ell)^\nu K_\nu(\sqrt{2\nu}r/\ell)$（$K_\nu$ は第 2 種変形 Bessel 関数。形だけ挙げる。滑らかさパラメータ ν が生成される関数の微分可能性を制御し、$\nu=1/2$ でラプラシアン、$\nu\to\infty$ でガウスに一致する)。

さらに重要なのは、$\mathcal{X}$ **が** $\mathbb{R}^d$ **である必要はない**という点である。**文字列カーネル**は $\mathcal{X}$ を文字列全体とし、部分文字列 u の出現回数 $\#_u(s)$ と重み $w_u\ge 0$ を用いて $k(s,t)=\sum_u w_u\#_u(s)\#_u(t)$ と定める。これは $\phi(s)=(\sqrt{w_u}\#_u(s))_u$ の内積だから正定値である。グラフに対しても部分構造の出現頻度や乱歩の一致確率から同様に構成でき（**グラフカーネル**、8.9節)、ベクトルとして表現しにくい対象を扱えることがカーネル法の大きな強みである。

図 7.2と図 7.3を見比べると、カーネルの「形」と Gram 行列の「構造」の対応が読み取れる。帯域幅の小さいガウスカーネルの Gram 行列はほぼ単位行列（固有値がほぼ一定)、大きいと全成分が 1 に近づき階数がほぼ 1 になる。この両極端の間にちょうどよい帯域幅がある、というのが実務上の論点である。

一つひとつのカーネルについて (7.10) を確かめるのは大変である。幸い、正定値カーネルの全体は豊かな代数的構造をもつ。

定理 7.24 (カーネルの演算則)**.** k_1,k_2 を $\mathcal{X}$ 上の正定値カーネル、$a>0$ を定数とする。次はいずれも $\mathcal{X}$ 上の正定値カーネルである。

(1) $k_1 + k_2$（和）
(2) $a\,k_1$（正数倍）
(3) $k_1 k_2$（各点ごとの積；**Schur 積**）
(4) $k(x,y) = \lim_{m\to\infty} k_m(x,y)$（各点収束する正定値カーネル列の極限）
(5) $f(x)k_1(x,y)f(y)$（$f : \mathcal{X} \to \mathbb{R}$ は任意）
(6) $k_1(\psi(x), \psi(y))$（$\psi : \mathcal{X}' \to \mathcal{X}$ は任意の写像；このとき $\mathcal{X}'$ 上の正定値カーネル）
(7) $p(k_1)$（p は非負係数の多項式）、および $\exp(k_1)$

証明. (1)(2)：$\boldsymbol{c}^\top(\boldsymbol{K}_1 + \boldsymbol{K}_2)\boldsymbol{c} = \boldsymbol{c}^\top\boldsymbol{K}_1\boldsymbol{c} + \boldsymbol{c}^\top\boldsymbol{K}_2\boldsymbol{c} \ge 0$、$\boldsymbol{c}^\top(a\boldsymbol{K}_1)\boldsymbol{c} = a\,\boldsymbol{c}^\top\boldsymbol{K}_1\boldsymbol{c} \ge 0$。
(4)：各 m で $\boldsymbol{c}^\top\boldsymbol{K}_m\boldsymbol{c} \ge 0$、各成分が収束するから有限和の極限として $\boldsymbol{c}^\top\boldsymbol{K}\boldsymbol{c} = \lim_m \boldsymbol{c}^\top\boldsymbol{K}_m\boldsymbol{c} \ge 0$。対称性も極限で保たれる。
(5)：$\boldsymbol{D} = \operatorname{diag}(f(x_1), \dots, f(x_n))$ とおくと Gram 行列は $\boldsymbol{D}\boldsymbol{K}_1\boldsymbol{D}$ で、$\boldsymbol{c}^\top\boldsymbol{D}\boldsymbol{K}_1\boldsymbol{D}\boldsymbol{c} = (\boldsymbol{D}\boldsymbol{c})^\top\boldsymbol{K}_1(\boldsymbol{D}\boldsymbol{c}) \ge 0$（$\boldsymbol{D}$ は対称）。
(6)：$x'_1, \dots, x'_n \in \mathcal{X}'$ に対する Gram 行列は $\mathcal{X}$ の点 $\psi(x'_1), \dots, \psi(x'_n)$（重複可）に対する k_1 の Gram 行列に等しく半正定値。
(3)：**Schur 積定理**として別に証明する（補題 7.25）。
(7)：(1)(2)(3) より k_1^m とその非負係数の線形結合は正定値。定数関数 $c \ge 0$ も $\boldsymbol{c}^\top(c\mathbf{1}\mathbf{1}^\top)\boldsymbol{c} = c(\sum_i c_i)^2 \ge 0$ より正定値だから $p(k_1) = \sum_{m\le M} a_m k_1^m$（$a_m \ge 0$）は正定値。$\exp(k_1) = \lim_M \sum_{m\le M} k_1^m/m!$ は各点収束するので (4) より正定値。 ■

補題 7.25 (Schur 積定理)**.** $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{n\times n}$ をともに半正定値対称行列とすると、その成分ごとの積（Hadamard 積）$\boldsymbol{A} \circ \boldsymbol{B} = (A_{ij}B_{ij})_{ij}$ も半正定値である。

証明. $\boldsymbol{B}$ は半正定値対称だから、有限次元のスペクトル定理（第2章）により $\boldsymbol{B} = \sum_{l=1}^{n} \mu_l \boldsymbol{v}_l \boldsymbol{v}_l^\top$（$\mu_l \ge 0$、$\{\boldsymbol{v}_l\}$ は正規直交）と書ける。成分で書けば $B_{ij} = \sum_l \mu_l v_{li} v_{lj}$。したがって任意の $\boldsymbol{c} \in \mathbb{R}^n$ に対し

$$\begin{aligned} \boldsymbol{c}^\top(\boldsymbol{A}\circ\boldsymbol{B})\boldsymbol{c} &= \sum_{i,j} c_i c_j A_{ij} B_{ij} = \sum_{i,j} c_i c_j A_{ij} \sum_l \mu_l v_{li} v_{lj} \\ &= \sum_l \mu_l \sum_{i,j} (c_i v_{li})\, A_{ij}\, (c_j v_{lj}) = \sum_l \mu_l\; \boldsymbol{d}_l^\top \boldsymbol{A}\, \boldsymbol{d}_l, \end{aligned} \tag{7.12}$$

ただし $\boldsymbol{d}_l \coloneqq (c_1 v_{l1}, \dots, c_n v_{ln})^\top$ とおいた。$\boldsymbol{A}$ は半正定値だから $\boldsymbol{d}_l^\top \boldsymbol{A}\boldsymbol{d}_l \ge 0$、$\mu_l \ge 0$ だから (7.12) の右辺は非負である。対称性は明らかなので、$\boldsymbol{A}\circ\boldsymbol{B}$ は半正定値。 ■

例 7.26 (数値で見る Schur 積)**.** $\boldsymbol{A} = \left(\begin{smallmatrix} 2 & 1 \\ 1 & 2 \end{smallmatrix}\right)$（固有値 $1, 3$）、$\boldsymbol{B} = \left(\begin{smallmatrix} 1 & -1 \\ -1 & 1 \end{smallmatrix}\right)$（固有値 $0, 2$）に対し $\boldsymbol{A}\circ\boldsymbol{B} = \left(\begin{smallmatrix} 2 & -1 \\ -1 & 2 \end{smallmatrix}\right)$ は固有値 $1, 3$ で確かに半正定値である（この $\boldsymbol{A}, \boldsymbol{B}$ は可換で $\boldsymbol{A}\boldsymbol{B} = \boldsymbol{B}\boldsymbol{A}$ になる特殊な組だが、それは偶然である）。一般には通常の行列積は対称性すら保たない。実際 $\boldsymbol{B}' = \left(\begin{smallmatrix} 1 & 0 \\ 0 & 0 \end{smallmatrix}\right)$（固有値 $0, 1$）とすると $\boldsymbol{A}\boldsymbol{B}' = \left(\begin{smallmatrix} 2 & 0 \\ 1 & 0 \end{smallmatrix}\right)$、$\boldsymbol{B}'\boldsymbol{A} = \left(\begin{smallmatrix} 2 & 1 \\ 0 & 0 \end{smallmatrix}\right)$ でどちらも対称でなく、互いにも一致しない。一方 Schur 積 $\boldsymbol{A}\circ\boldsymbol{B}' = \left(\begin{smallmatrix} 2 & 0 \\ 0 & 0 \end{smallmatrix}\right)$ は固有値 $0, 2$ で半正定値のままである。**カーネルの積は行列積ではなく成分ごとの積であること**を取り違えないように。

演算則の威力を、最も重要な例で示そう。

命題 7.27 (ガウスカーネルは正定値)**.** $\sigma > 0$ とする。$k(\boldsymbol{x}, \boldsymbol{y}) = \exp\bigl(-\|\boldsymbol{x}-\boldsymbol{y}\|^2/(2\sigma^2)\bigr)$ は $\mathbb{R}^d$ 上の正定値カーネルである。

証明. 指数の肩を展開する。$\|\boldsymbol{x}-\boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 - 2\boldsymbol{x}^\top\boldsymbol{y} + \|\boldsymbol{y}\|^2$ だから

$$k(\boldsymbol{x}, \boldsymbol{y}) = \underbrace{e^{-\|\boldsymbol{x}\|^2/(2\sigma^2)}}_{=:f(\boldsymbol{x})} \cdot \exp\!\Bigl(\frac{\boldsymbol{x}^\top\boldsymbol{y}}{\sigma^2}\Bigr) \cdot \underbrace{e^{-\|\boldsymbol{y}\|^2/(2\sigma^2)}}_{=f(\boldsymbol{y})}. \tag{7.13}$$

右辺の中央の因子を見る。$k_0(\boldsymbol{x}, \boldsymbol{y}) = \boldsymbol{x}^\top\boldsymbol{y}$ は線形カーネルで正定値、定理 7.24(2) より k_0/σ^2 も正定値、同 (7) より $\exp(k_0/\sigma^2)$ も正定値である。最後に同 (5)（$f(\boldsymbol{x})k(\boldsymbol{x},\boldsymbol{y})f(\boldsymbol{y})$ の形）を適用すれば、(7.13) の右辺全体が正定値カーネルである。対称性は $\|\boldsymbol{x}-\boldsymbol{y}\| = \|\boldsymbol{y}-\boldsymbol{x}\|$ から明らか。 ■

注意 7.28. この証明は「線形カーネル → 指数 → 両側から関数を掛ける」の三段階で済んでいる。定義 (7.10) を直接検証しようとすると任意の n 点での半正定値性を示す必要があり、Fourier 変換（Bochner の定理 [71]）を持ち出すことになる。**演算則で組み立てる**方針の有効性がよく分かる例である。

リスト 7.1　カーネルの演算則の数値的検証。和・積・指数の Gram 行列が半正定値であることを最小固有値で確認し、ガウスカーネルを演算則どおりに組み立てて直接計算と照合する。

```
import numpy as np
X, sigma = np.random.default_rng(0).normal(size=(3, 200)), 1.0   # d×n 規約

```

```python
def k_gauss(A, B, s=sigma):                      # A: d×n, B: d×m -> n×m
    d2 = (np.sum(A**2, 0)[:, None] + np.sum(B**2, 0)[None, :] - 2*A.T@B)
    return np.exp(-d2 / (2 * s**2))

K1, K2 = X.T @ X, k_gauss(X, X)                  # 線形とガウス（ともに n×n）
for nm, K in {"k1": K1, "k2": K2, "k1+k2": K1+K2,
              "k1*k2": K1*K2, "exp(k1)": np.exp(K1)}.items():
    print(f"{nm:8s} min eig = {np.linalg.eigvalsh((K+K.T)/2).min(): .3e}")

# 命題 6.x の構成: k(x,y) = f(x) exp(x^T y / s^2) f(y)
f = np.exp(-np.sum(X**2, 0) / (2 * sigma**2))
print("max err =", np.abs(f[:,None]*np.exp(K1/sigma**2)*f[None,:] - K2).max())
```

実行結果は、線形が -6.38×10^{-14}（理論値 0 の丸め誤差。$d=3$ なので階数 3、残り 197 個の固有値は 0）、他はすべて 10^{-8} 台の正値であり、いずれも半正定値である。最後の行の差は 5.55×10^{-16} で、演算則による構成が直接計算と一致することが確認できる。

7.7　再生核ヒルベルト空間

道具は揃った。7.1節の問い (2)「暗黙に働いている空間は何か」に答える。$\mathcal{X}$ 上の実数値関数からなる Hilbert 空間 $\mathcal{H}$ を考えると、$f\in\mathcal{H}$ と点 x に対し値 $f(x)$ が定まる。ところが Hilbert 空間の構造は点ごとの値について何も保証しない。$L^2[0,1]$ では $\|f-g\|_{L^2}$ が小さくても $f(x)$ と $g(x)$ が大きく違いうる（1 点で値を変えても L^2 ノルムは変わらない）。

例 7.29（L^2 で評価汎関数は有界でない）. $C[0,1]$ に L^2 内積を入れた空間で $\delta_{1/2}(f)=f(1/2)$ を考える。$g_m(t)=\max\bigl(0,\,1-m|t-\tfrac12|\bigr)$（高さ 1、底辺の幅 $2/m$ の三角形）とすると $g_m(1/2)=1$ だが $\|g_m\|_{L^2}^2=\int|g_m|^2\,\mathrm{d}t=\frac{2}{3m}\to0$。よって $|\delta_{1/2}(g_m)|/\|g_m\|_{L^2}=\sqrt{3m/2}\to\infty$ となり、$\delta_{1/2}$ は有界でない。

一方、データ解析で扱う関数は「点での値」に意味がある。学習した予測関数 f に新しい点 $\boldsymbol{x}$ を入れて $f(\boldsymbol{x})$ を得るのだから、f が少し変われば $f(\boldsymbol{x})$ も少ししか変わらない、という性質が欲しい。これを要請したものが RKHS である。

定義 7.30（再生核ヒルベルト空間）. $\mathcal{X}$ を任意の集合とする。$\mathcal{X}$ 上の実数値関数からなる Hilbert 空間 $\mathcal{H}$ が **再生核ヒルベルト空間**（reproducing kernel Hilbert space, RKHS）であるとは、各 $x\in\mathcal{X}$ に対し評価汎関数 $\delta_x:\mathcal{H}\to\mathbb{R}$, $\delta_x(f)=f(x)$ が有界であること、すなわちある $C_x<\infty$ が存在して $|f(x)|\le C_x\|f\|_{\mathcal{H}}$ が全ての $f\in\mathcal{H}$ で成り立つことをいう。

ここで「関数の空間」という言い方は正確に受け取る必要がある。L^2 の元は厳密には「ほとんど至るところ一致する関数の同値類」であって点での値は定まらないのに対し、RKHS では $\mathcal{H}$ の元は**本物の関数**であり、すべての点で値が定まっていることを要求する。この違いが例 7.29に現れている。

定理 7.31（再生核の存在）. $\mathcal{H}$ を $\mathcal{X}$ 上の RKHS とする。このとき関数 $k:\mathcal{X}\times\mathcal{X}\to\mathbb{R}$ がただ一つ存在して、次が成り立つ。

(i) 各 $x\in\mathcal{X}$ について $k(\cdot,x)\in\mathcal{H}$、

(ii)（**再生性**）任意の $f\in\mathcal{H}$, $x\in\mathcal{X}$ に対し

$$f(x)=\langle f,k(\cdot,x)\rangle_{\mathcal{H}}. \tag{7.14}$$

さらに k は正定値対称であり、

$$k(x,y)=\langle k(\cdot,x),k(\cdot,y)\rangle_{\mathcal{H}} \tag{7.15}$$

が成り立つ。この k を $\mathcal{H}$ の**再生核**（reproducing kernel）という。

証明. 定義より δ_x は有界線形汎関数だから、Riesz の表現定理（定理 7.18）よりただ一つの $k_x\in\mathcal{H}$ が存在して $f(x)=\delta_x(f)=\langle f,k_x\rangle_{\mathcal{H}}$。そこで $k(y,x)\coloneqq k_x(y)$、すなわち $k(\cdot,x)\coloneqq k_x$ と定義すれば (i)(ii) を得る。一意性は Riesz の定理の一意性から各 x ごとに従う。

(7.15)：再生性 (7.14) を $f=k(\cdot,y)=k_y$ に適用すると $k_y(x)=\langle k_y,k_x\rangle_{\mathcal{H}}$、すなわち $k(x,y)=\langle k(\cdot,y),k(\cdot,x)\rangle_{\mathcal{H}}$。内積の対称性より $k(x,y)=k(y,x)$、これが対称性である。

正定値性：任意の $x_1,\dots,x_n$, $\boldsymbol{c}\in\mathbb{R}^n$ に対し (7.15) と内積の双線形性から

$$\sum_{i,j}c_ic_jk(x_i,x_j)=\Bigl\langle\sum_i c_ik(\cdot,x_i),\ \sum_j c_jk(\cdot,x_j)\Bigr\rangle_{\mathcal{H}}=\Bigl\|\sum_i c_ik(\cdot,x_i)\Bigr\|_{\mathcal{H}}^2\ \ge\ 0. \qquad\blacksquare$$

再生性 (7.14) は三通りに読める。第一に**評価＝内積**：関数の点での値が内積という代数的操作で書ける。第二に $k(\cdot,x)$ **は点 x の代理**：$\mathcal{H}$ の中で点 x を表すベクトルが $k(\cdot,x)$ である。第三に $\phi(x)=k(\cdot,x)$ **は特徴写像**：(7.15) より $k(x,y)=\langle\phi(x),\phi(y)\rangle_{\mathcal{H}}$ であり、カーネルは特徴写像の内積である。

図 7.4が示すように、RKHS の元はカーネルの平行移動 $k(\cdot,x_i)$ の線形結合（とその極限）である。この描像を厳密にしたのが次の定理である。

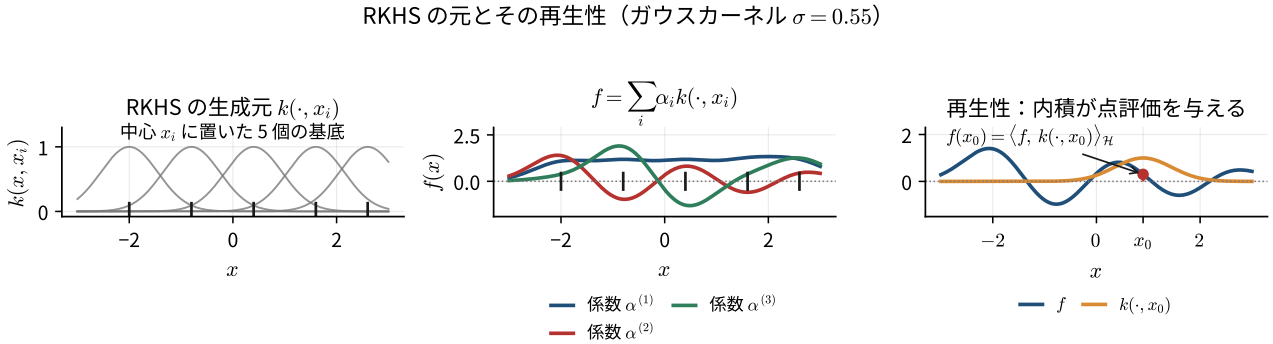


図7.4　RKHS の元。$f = \sum_i \alpha_i k(\cdot, x_i)$ が係数 α_i に応じてどんな関数になるかを数例示し、あわせて再生性 $f(x) = \langle f, k(\cdot, x)\rangle$ の模式図を添えた。カーネルの「山」を重ね合わせたものが RKHS の元である。

定理 7.31は「RKHS があれば正定値カーネルが得られる」と述べた。その完全な逆が成り立つ、というのが本章の最重要定理である。

定理 7.32 (Moore–Aronszajn [8])**.** $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ を正定値カーネルとする。このとき k を再生核とする $\mathcal{X}$ 上の RKHS $\mathcal{H}_k$ がただ一つ存在する。

証明は構成的である。手順は四段階で、**(a) 前 Hilbert 空間を作る、(b) 内積が well-defined であることを確かめる、(c) 完備化する、(d) 完備化した元が本当に関数として意味をもつことを確かめる**、という流れである。(d) がこの証明の急所であり、ここで評価汎関数の有界性が効く。

証明. (a) 前 Hilbert 空間の構成。 k の平行移動が張る空間 $\mathcal{H}_0 \coloneqq \operatorname{span}\{k(\cdot, x) : x \in \mathcal{X}\} = \{\sum_{i=1}^{n} \alpha_i k(\cdot, x_i) : n \in \mathbb{N}, \alpha_i \in \mathbb{R}, x_i \in \mathcal{X}\}$ を考える。これは $\mathcal{X}$ 上の関数からなるベクトル空間である。$f = \sum_i \alpha_i k(\cdot, x_i)$, $g = \sum_j \beta_j k(\cdot, y_j)$ に対し

$$\langle f, g\rangle_0 \coloneqq \sum_{i=1}^{n}\sum_{j=1}^{m} \alpha_i \beta_j\, k(x_i, y_j) \tag{7.16}$$

と定める。

(b) well-defined 性と内積の公理。 (7.16) の右辺は f, g の**表示**（α_i, x_i の取り方）に依存しそうに見えるが、実は依存しない。実際、右辺を書き換えると

$$\sum_{i,j} \alpha_i \beta_j k(x_i, y_j) = \sum_{j=1}^{m} \beta_j \Big(\sum_{i=1}^{n} \alpha_i k(y_j, x_i)\Big) = \sum_{j=1}^{m} \beta_j\, f(y_j) \tag{7.17}$$

であり（k の対称性を使った）、これは f の表示に依らない。同様に

$$\sum_{i,j} \alpha_i \beta_j k(x_i, y_j) = \sum_{i=1}^{n} \alpha_i\, g(x_i) \tag{7.18}$$

であり g の表示に依らない。二つ合わせて、(7.16) は f, g という**関数**のみで決まる。

対称性と双線形性は (7.16) から明らか。半正定値性は k の正定値性そのもので、$\langle f, f\rangle_0 = \sum_{i,j} \alpha_i \alpha_j k(x_i, x_j) \geq 0$。残るのは $\langle f, f\rangle_0 = 0 \Rightarrow f = 0$（正定値性）である。これには (7.17) の形の再生性

$$\langle f, k(\cdot, x)\rangle_0 = f(x) \qquad (f \in \mathcal{H}_0,\ x \in \mathcal{X}) \tag{7.19}$$

((7.18) で $g = k(\cdot, x)$ とした場合）と、半正定値な双線形形式に対して成り立つ Cauchy–Schwarz の不等式 $|\langle f, g\rangle_0| \leq \langle f, f\rangle_0^{1/2} \langle g, g\rangle_0^{1/2}$ を使う。すると

$$|f(x)| = |\langle f, k(\cdot, x)\rangle_0| \leq \langle f, f\rangle_0^{1/2}\, k(x, x)^{1/2} \tag{7.20}$$

であるから、$\langle f, f\rangle_0 = 0$ ならば全ての x で $f(x) = 0$、すなわち関数として $f = 0$。よって $\langle \cdot, \cdot\rangle_0$ は $\mathcal{H}_0$ 上の真の内積であり、$(\mathcal{H}_0, \langle \cdot, \cdot\rangle_0)$ は内積空間（前 Hilbert 空間）である。

(c) 完備化。 内積空間は一般に完備化できる。$\mathcal{H}_0$ の Cauchy 列全体を、差が 0 に収束する列どうしを同一視して得られる商空間 $\mathcal{H}_k$ には自然に内積が入り、$\mathcal{H}_0$ は稠密に埋め込まれ、$\mathcal{H}_k$ は完備になる（例 7.4 で $\mathbb{Q}$ から $\mathbb{R}$ を作るのと同じ操作）。ただしこの段階では $\mathcal{H}_k$ の元は「Cauchy 列の同値類」という抽象的な対象で、$\mathcal{X}$ 上の関数とは限らない。

(d) 抽象的な元を関数として実現する。 ここが要点である。$(f_m) \subset \mathcal{H}_0$ を Cauchy 列とする。(7.20) を $f_l - f_m$ に適用すると、各 $x \in \mathcal{X}$ に対し

$$|f_l(x) - f_m(x)| \leq \|f_l - f_m\|_0 \sqrt{k(x, x)} \;\longrightarrow\; 0 \tag{7.21}$$

だから、実数列 $(f_m(x))_m$ は Cauchy 列であり、$\mathbb{R}$ の完備性から収束する。そこで $f(x) \coloneqq \lim_m f_m(x)$ と定義すれば、Cauchy 列 (f_m) に対して $\mathcal{X}$ 上の関数 f が対応する。

この対応が**同値類のレベルで矛盾なく定まる**こと（$\|f_m - g_m\|_0 \to 0$ なら極限関数が一致すること）は (7.21) と同じ評価から従う。逆に**異なる同値類が同じ関数を与えない**ことを見る。$\|f_m\|_0 \to c$ かつ各点で $f_m(x) \to 0$ とすると、任意の $\varepsilon > 0$ に対し $l, m \geq N$ で $\|f_l - f_m\|_0 < \varepsilon$ とでき、

$$\|f_m\|_0^2 = \langle f_m, f_m - f_N\rangle_0 + \langle f_m, f_N\rangle_0 \leq \|f_m\|_0\, \varepsilon + \langle f_m, f_N\rangle_0.$$

ここで $f_N \in \mathcal{H}_0$ は有限和 $\sum_i \alpha_i k(\cdot, x_i)$ だから (7.18) より $\langle f_m, f_N\rangle_0 = \sum_i \alpha_i f_m(x_i) \to 0$。よって $c^2 \leq c\varepsilon$、ε は任意だから $c = 0$。すなわち関数として 0 になる同値類はゼロ元のみであり、$\mathcal{H}_k$ は $\mathcal{X}$ 上の関数の空間と同一視できる。

再生核であること。 $k(\cdot, x) \in \mathcal{H}_0 \subset \mathcal{H}_k$ であり、$f \in \mathcal{H}_k$ を $\mathcal{H}_0$ の列 $f_m \to f$ で近似すると、内積の連続性と (7.19) から $\langle f, k(\cdot, x)\rangle_{\mathcal{H}_k} = \lim_m \langle f_m, k(\cdot, x)\rangle_0 = \lim_m f_m(x) = f(x)$。よって再生性が $\mathcal{H}_k$ 全体で成り立つ。また (7.20) は極限でも保たれるので $|f(x)| \leq \sqrt{k(x,x)}\|f\|_{\mathcal{H}_k}$、すなわち評価汎関数は有界であり $\mathcal{H}_k$ は RKHS である。

一意性。 $\mathcal{H}'$ も k を再生核とする RKHS とする。再生性より $k(\cdot, x) \in \mathcal{H}'$ なので $\mathcal{H}_0 \subset \mathcal{H}'$ であり、$\mathcal{H}_0$ 上の内積は (7.15) により両者で一致する。$\mathcal{H}'$ は完備だから閉包 $\overline{\mathcal{H}_0} \subset \mathcal{H}'$ を含み、これは $\mathcal{H}_k$ と等長同型である。あとは $\overline{\mathcal{H}_0} = \mathcal{H}'$ を示せばよい。$g \in \mathcal{H}'$ が $\overline{\mathcal{H}_0}$ に直交すれば、再生性より任意の x で $g(x) = \langle g, k(\cdot, x)\rangle_{\mathcal{H}'} = 0$、すなわち $g = 0$。定理 7.10の直交分解より $\mathcal{H}' = \overline{\mathcal{H}_0} = \mathcal{H}_k$。 ■

Moore–Aronszajn が言っていること

正定値カーネルk $\iff$ RKHS $\mathcal{H}_k$

片方を与えれば他方が一意に決まる。実務上の意味は大きい。**カーネル関数を一つ選ぶことは、暗黙のうちに関数空間（仮説集合）を一つ選ぶことである**。ガウスか多項式かの選択は、どんな関数を学習の候補にするかの選択に等しい。

$\|f\|_{\mathcal{H}}$ は何を意味するのか。答えは「f の滑らかさ」である。平行移動不変なカーネル $k(x, y) = \kappa(x - y)$ について見てみよう。κ の Fourier 変換 $\hat{\kappa}(\boldsymbol{\omega})$ が正で可積分なとき、対応する RKHS は

$$\mathcal{H}_k = \left\{ f \;:\; \|f\|_{\mathcal{H}}^2 = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \frac{|\hat{f}(\boldsymbol{\omega})|^2}{\hat{\kappa}(\boldsymbol{\omega})}\, \mathrm{d}\boldsymbol{\omega} < \infty \right\} \tag{7.22}$$

と表される（※ 証明には Bochner の定理と Plancherel の定理が必要なので省略する）。$\hat{f}$ は f の Fourier 変換で、$|\hat{f}(\boldsymbol{\omega})|^2$ は周波数 $\boldsymbol{\omega}$ の成分の強さである。読み方は明快で、分母 $\hat{\kappa}(\boldsymbol{\omega})$ が高周波で急速に 0 に近づくカーネルでは、高周波成分をわずかでも持つと $\|f\|_{\mathcal{H}}$ が巨大になる。つまり**高周波成分が強く罰せられる**。

例 7.33 (ガウスカーネルの場合)**.** $\kappa(\boldsymbol{z}) = \exp(-\|\boldsymbol{z}\|^2/2\sigma^2)$ の Fourier 変換は $\hat{\kappa}(\boldsymbol{\omega}) = (2\pi\sigma^2)^{d/2} \exp(-\sigma^2\|\boldsymbol{\omega}\|^2/2)$ で、(7.22) に入れると

$$\|f\|_{\mathcal{H}}^2 = \frac{1}{(2\pi)^d (2\pi\sigma^2)^{d/2}} \int |\hat{f}(\boldsymbol{\omega})|^2\, e^{\sigma^2\|\boldsymbol{\omega}\|^2/2}\, \mathrm{d}\boldsymbol{\omega}. \tag{7.23}$$

罰則の重み $e^{\sigma^2\|\omega\|^2/2}$ は周波数の二乗に対して **指数的に**増大する。ゆえにガウスカーネルの RKHS の元は極めて滑らかで、実際すべて解析的である。帯域幅 σ を大きくすると罰則がさらに厳しくなって $\mathcal{H}$ は狭くなり、$\sigma \to 0$ では空間が広がるが過学習しやすくなる。

注意 7.34. 序論(第1章)の第一の軸 $\min_f \frac{1}{n}\sum_i L(y_i, f(\boldsymbol{x}_i)) + \lambda\Omega(f)$ で $\Omega(f) = \|f\|_{\mathcal{H}}^2$ と取ったものがカーネル法である。(7.23) は、この正則化項が**周波数領域での重み付き罰則**に他ならないことを示す。ラプラシアンカーネルなら $\hat{\kappa}(\omega) \propto (1 + \sigma^2\omega^2)^{-1}$ で罰則は多項式的にしか増えず、生成される関数は連続だが微分可能とは限らない。図 7.2のカーネルの尖り具合が、そのまま関数空間の滑らかさに翻訳されている。

7.8　特徴写像

定理 7.32の副産物として、任意の正定値カーネルに対し特徴写像が構成できたことになる。改めて述べておこう。

定義 7.35 (特徴写像)**.** Hilbert 空間 $\mathcal{F}$ と写像 $\phi : \mathcal{X} \to \mathcal{F}$ の組が k の **特徴写像**（feature map）であるとは、$k(x, y) = \langle \phi(x), \phi(y)\rangle_{\mathcal{F}}$ が全ての $x, y \in \mathcal{X}$ で成り立つことをいう。$\mathcal{F}$ を**特徴空間**という。

特徴写像が手元にあれば、特徴空間の幾何はすべて k の値だけで書ける。たとえば二点間の距離は ϕ を経由せずに

$$\|\phi(\boldsymbol{x}) - \phi(\boldsymbol{y})\|_{\mathcal{H}}^2 = \langle \phi(\boldsymbol{x}), \phi(\boldsymbol{x})\rangle - 2\langle \phi(\boldsymbol{x}), \phi(\boldsymbol{y})\rangle + \langle \phi(\boldsymbol{y}), \phi(\boldsymbol{y})\rangle = k(\boldsymbol{x}, \boldsymbol{x}) - 2k(\boldsymbol{x}, \boldsymbol{y}) + k(\boldsymbol{y}, \boldsymbol{y})$$

と計算できる（ガウスカーネルなら $k(\boldsymbol{x},\boldsymbol{x})=1$ だから $2-2k(\boldsymbol{x},\boldsymbol{y})\in[0,2)$ で、特徴空間では任意の二点が距離 $\sqrt{2}$ 未満になる）。同様にノルムは $\|\phi(\boldsymbol{x})\|^2=k(\boldsymbol{x},\boldsymbol{x})$、直交は $k(\boldsymbol{x},\boldsymbol{y})=0$ である。表 7.1の右列が「k の値だけから計算できる」というのはこの意味である。

系 7.36 (標準特徴写像)**.** k を正定値カーネル、$\mathcal{H}_k$ をその RKHS とすると $\phi:\mathcal{X}\to\mathcal{H}_k$, $\phi(x):=k(\cdot,x)$ は k の特徴写像である。これを**標準特徴写像**（canonical feature map）という。

証明. (7.15) そのものである。 ■

つまり「k に対応する ϕ は存在するか」という7.1節の問いには、**正定値でありさえすれば必ず存在する**と答えられる。しかも特徴空間の姿は RKHS として明示的に与えられる。

注意 7.37 (特徴行列と Gram 行列)**.** 特徴空間が有限次元 $\mathcal{F}=\mathbb{R}^M$ のときは、n 個の特徴ベクトルを **データ行列と同じ規約で**——すなわち列に並べて——

$$\boldsymbol{\Phi}:=\begin{pmatrix}\phi(\boldsymbol{x}_1) & \cdots & \phi(\boldsymbol{x}_n)\end{pmatrix}\in\mathbb{R}^{M\times n} \tag{7.24}$$

と書ける。このとき Gram 行列は

$$\boldsymbol{K}=\boldsymbol{\Phi}^{\top}\boldsymbol{\Phi}\in\mathbb{R}^{n\times n},\qquad K_{ij}=\phi(\boldsymbol{x}_i)^{\top}\phi(\boldsymbol{x}_j)=k(\boldsymbol{x}_i,\boldsymbol{x}_j) \tag{7.25}$$

である。次元を数えれば $(n\times M)(M\times n)=(n\times n)$ で、$\boldsymbol{K}$ の大きさが M ではなく n で決まることが見て取れる。$\boldsymbol{X}\in\mathbb{R}^{d\times n}$ に対する $\boldsymbol{X}^{\top}\boldsymbol{X}$ とまったく同じ形であり、線形カーネル $\phi=\mathrm{id}$ のとき $\boldsymbol{\Phi}=\boldsymbol{X}$、$\boldsymbol{K}=\boldsymbol{X}^{\top}\boldsymbol{X}$ に一致する。一方 $\boldsymbol{\Phi}\boldsymbol{\Phi}^{\top}\in\mathbb{R}^{M\times M}$ は（$1/n$ 倍すれば）特徴空間の共分散行列であって、$M=\infty$ では行列として書けない。カーネル法が $\boldsymbol{\Phi}^{\top}\boldsymbol{\Phi}$ の側だけを使うのは、まさにこの理由による。

RKHS はカーネルから一意に決まる（定理 7.32）が、**特徴写像は一意ではない**。同じカーネルに対し、まったく違う空間へのまったく違う写像がいくらでも存在する。

例 7.38 (同じカーネル、異なる特徴写像)**.** $\mathcal{X}=\mathbb{R}^2$, $k(\boldsymbol{x},\boldsymbol{y})=(\boldsymbol{x}^{\top}\boldsymbol{y})^2$ とする。次の四つはいずれも同じ k を与える。(a) $\phi_1(\boldsymbol{x})=(x_1^2,\sqrt{2}x_1x_2,x_2^2)\in\mathbb{R}^3$（(7.1) で確認済み）。(b) $\phi_2(\boldsymbol{x})=(x_1^2,x_1x_2,x_1x_2,x_2^2)\in\mathbb{R}^4$：内積は $x_1^2y_1^2+2x_1x_2y_1y_2+x_2^2y_2^2$ で (a) と同じだが次元が違う。(c) $\phi_3=\boldsymbol{Q}\phi_1$（$\boldsymbol{Q}$ は任意の直交行列）：直交変換は内積を保つ。(d) $\phi_4(\boldsymbol{x})=k(\cdot,\boldsymbol{x})\in\mathcal{H}_k$：標準特徴写像。$\mathcal{H}_k$ は 2 次形式 $f(\boldsymbol{x})=\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}$（$\boldsymbol{A}$ は 2×2 対称）の全体と同型で $\dim\mathcal{H}_k=3$。**一意なのは内積の値であって写像そのものではない**。実務上これは朗報で、カーネルさえ決まればどの特徴写像を思い浮かべても計算結果は変わらない。なお特徴空間の次元は写像に依存する（上では 3 と 4）が、**最小の次元**は $\dim\mathcal{H}_k$ に等しくカーネルから一意に決まる。多項式カーネルでは有限 $\binom{d+p}{p}$、ガウスカーネルでは無限次元である。後者を次項で見る。

ガウスカーネルの特徴空間が無限次元であることを、$d=1$ の場合に明示的な級数で示す。これは学生にとって最も印象的な計算のひとつである。

命題 7.39 (1 次元ガウスカーネルの明示的特徴写像)**.** $\mathcal{X}=\mathbb{R}$, $k(x,y)=\exp\bigl(-(x-y)^2/(2\sigma^2)\bigr)$ とする。$\phi:\mathbb{R}\to\ell^2$ を

$$\phi(x)=\left(e^{-x^2/(2\sigma^2)}\frac{1}{\sqrt{m!}}\left(\frac{x}{\sigma}\right)^m\right)_{m=0,1,2,\dots} \tag{7.26}$$

で定めると $k(x,y)=\langle\phi(x),\phi(y)\rangle_{\ell^2}$ である。とくにガウスカーネルの特徴空間は無限次元である。

証明. (7.13) と同じ分解から出発する。

$$k(x,y)=e^{-x^2/(2\sigma^2)}\cdot e^{xy/\sigma^2}\cdot e^{-y^2/(2\sigma^2)}. \tag{7.27}$$

中央の因子を Taylor 展開で開くと $e^{xy/\sigma^2}=\sum_{m\ge0}\frac{1}{m!}(\frac{xy}{\sigma^2})^m=\sum_{m\ge0}\frac{1}{\sqrt{m!}}(\frac{x}{\sigma})^m\cdot\frac{1}{\sqrt{m!}}(\frac{y}{\sigma})^m$ となる。$1/m!$ を $1/\sqrt{m!}$ 二つに分けたのが要点である。これを (7.27) に戻し、x の因子と y の因子をまとめれば

$$k(x,y)=\sum_{m=0}^{\infty}\underbrace{\left(e^{-x^2/(2\sigma^2)}\tfrac{1}{\sqrt{m!}}(x/\sigma)^m\right)}_{\phi_m(x)}\underbrace{\left(e^{-y^2/(2\sigma^2)}\tfrac{1}{\sqrt{m!}}(y/\sigma)^m\right)}_{\phi_m(y)}=\langle\phi(x),\phi(y)\rangle_{\ell^2}.$$

級数は絶対収束（$e^{|xy|/\sigma^2}<\infty$）なので問題なく、$\|\phi(x)\|_{\ell^2}^2=k(x,x)=1$ より $\phi(x)\in\ell^2$。

無限次元性：ϕ_m は m 次多項式に $e^{-x^2/2\sigma^2}$ を掛けたもので異なる m について線形独立である。特徴空間が有限次元ならば Gram 行列の階数は上に有界になるが、相異なる n 点に対するガウスカーネルの Gram 行列はつねに正則（狭義正定値）である。よって無限次元。 ■

ガウスカーネルの値を計算するコストは $O(1)$ だが、その裏では $\phi(x) = e^{-x^2/2\sigma^2}\big(1,\ \frac{x}{\sigma},\ \frac{1}{\sqrt{2}}\frac{x^2}{\sigma^2},\ \frac{1}{\sqrt{6}}\frac{x^3}{\sigma^3}, \dots\big)$ という**無限次元の**ベクトルの内積が計算されている。無限次元の内積を $O(1)$ で計算する——これがカーネルトリックの威力である。d 次元では各座標の展開のテンソル積になり、m 次の項は d 変数の m 次単項式すべてを含む。

(7.26) を第 N 項で打ち切って $\langle \phi(x), \phi(y) \rangle$ を数値計算すると（$\sigma = 1$、5 点で評価）、k との最大誤差は $N = 5$ で 3.7×10^{-1}、$N = 10$ で 8.1×10^{-3}、$N = 30$ で 2.2×10^{-16}（倍精度の丸め誤差）となる。無限次元の内積が有限項で実用上完全に再現できている。

7.9 Mercer の定理

Moore–Aronszajn の定理は $\mathcal{X}$ に何の構造も仮定せず（位相も測度も不要）に RKHS を構成した。その代償として特徴写像 $\phi(x) = k(\cdot, x)$ は「関数そのもの」という抽象的な形をしている。これに対し Mercer の定理は、$\mathcal{X}$ のコンパクト性、k の連続性、測度を仮定する代わりに**固有関数という具体的な形の**特徴写像を与える。

定理 7.40 (Mercer [54]；この一般形は [73, 71])**.** $\mathcal{X} \subset \mathbb{R}^d$ をコンパクト集合、μ を $\mathcal{X}$ 上の有限 Borel 測度でその台が $\mathcal{X}$ 全体であるもの、$k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ を連続な正定値カーネルとする。積分作用素 $T_k : L^2(\mu) \to L^2(\mu)$ を (7.9) で定める。このとき T_k の固有値 $\lambda_1 \geq \lambda_2 \geq \cdots \geq 0$（重複を込めて並べる）と対応する固有関数 $e_1, e_2, \dots$（$L^2(\mu)$ で正規直交、かつ $\lambda_i > 0$ のものは連続にとれる）が存在し、

$$k(x, y) = \sum_{i=1}^{\infty} \lambda_i \, e_i(x) e_i(y) \tag{7.28}$$

が $\mathcal{X} \times \mathcal{X}$ 上**一様かつ絶対収束**する。さらに $\sum_i \lambda_i = \int_{\mathcal{X}} k(x, x) \, \mathrm{d}\mu(x) < \infty$。

注意 7.41 (定理の一般性について)**.** Mercer [54] の原論文が扱ったのはコンパクト**区間**上の連続対称核であり、上に述べた「$\mathbb{R}^d$ のコンパクト集合と台が全体の有限 Borel 測度」という一般形はその後の積分作用素論による整備の結果である。現代的な定式化と証明は Steinwart–Christmann [73] の第 4 章、あるいは Schölkopf–Smola [71] を参照されたい。歴史的な名前として「Mercer の定理」を用いるのは通例であるが、一般形を引用する場合は後者を挙げるのが正確である。

証明の筋道. 完全な証明は与えず、どの定理をどう使うかを示す。

(1) T_k **はコンパクトかつ自己共役。** $\mathcal{X}$ がコンパクトで k が連続だから k は有界、μ が有限測度なので $\iint k^2 \, \mathrm{d}\mu \, \mathrm{d}\mu < \infty$。よって T_k は Hilbert–Schmidt であり例 7.22よりコンパクト。k の対称性から自己共役。

(2) **スペクトル定理の適用。**定理 7.21より、実固有値 $\{\lambda_i\}$ と $L^2(\mu)$ の正規直交系 $\{e_i\}$ が存在して $T_k e_i = \lambda_i e_i$、$\lambda_i \to 0$。

(3) **固有値の非負性と固有関数の連続性。** k の正定値性から $\langle T_k f, f \rangle = \iint k(x, y) f(y) f(x) \, \mathrm{d}\mu(y) \, \mathrm{d}\mu(x) \geq 0$ が従い（(7.10) の積分版）、T_k は半正定値、定理 7.21(iv) より $\lambda_i \geq 0$。また $\lambda_i > 0$ なら $e_i = \lambda_i^{-1} T_k e_i$ で右辺は連続関数 k の積分だから連続。

この非負性の導出には注意が要る。「有限和で近似する」議論を **任意の** $f \in L^2(\mu)$ **に対して直接行うことはできない。**L^2 の元は各点の値が定まらないので $f(x_i)$ を代表点で読むことに意味がなく、可測関数を階段関数で**一様に**近似する操作も一般には許されない。正しい順序は次の二段である。まず f が**連続**な場合に示す。$\mathcal{X}$ をコンパクト性から直径 δ 以下の有限個の Borel 集合 $A_1, \dots, A_N$（互いに素、$\bigcup A_l = \mathcal{X}$）に分割し代表点 $x_l \in A_l$ を取ると、$c_l := f(x_l)\mu(A_l)$ に対し (7.10) より $\sum_{l,l'} c_l c_{l'} k(x_l, x_{l'}) \geq 0$ である。左辺と $\iint k f f \, \mathrm{d}\mu \, \mathrm{d}\mu$ の差は、k と f がコンパクト集合上の連続関数ゆえ一様連続であることから $\delta \to 0$ で 0 に収束する（$\mu(\mathcal{X}) < \infty$ を使う）。よって連続な f に対し $\langle T_k f, f \rangle \geq 0$。次に $\mathcal{X}$ がコンパクト、μ が有限 Borel 測度なので $C(\mathcal{X})$ は $L^2(\mu)$ で稠密であり（※ 測度論を要するため認めて使う）、T_k が有界だから $f \mapsto \langle T_k f, f \rangle$ は L^2 で連続、したがって非負性が $L^2(\mu)$ 全体に延びる。

(4) **各点絶対収束から一様収束へ。**残差 $k_M(x, y) := k(x, y) - \sum_{i \leq M} \lambda_i e_i(x) e_i(y)$ もまた正定値カーネルである（残差作用素が半正定値）。正定値カーネルは対角で非負なので $\sum_{i \leq M} \lambda_i e_i(x)^2 \leq k(x, x)$、左辺は単調増加かつ上に有界だから収束し、Cauchy–Schwarz より (7.28) は各点絶対収束する。各項が連続、部分和が単調増加、極限 $k(x, x)$ が連続という状況では対角線上の収束が一様になり（**Dini の定理**）、非対角へは同じ Cauchy–Schwarz で拡張する。

省略した部分：T_k が Hilbert–Schmidt であることの詳細、(3) で用いた $C(\mathcal{X})$ の $L^2(\mu)$ における稠密性、(4) の残差カーネルの正定値性、および Dini の定理の証明。いずれも測度論または位相空間論の標準的な議論による。 ■

系 7.42 (Mercer 特徴写像)**.** 定理 7.40の設定で $\phi_{\mathrm{M}}(x) := (\sqrt{\lambda_1} e_1(x), \sqrt{\lambda_2} e_2(x), \dots)$ は $\mathcal{X}$ から ℓ^2 への特徴写像であり、RKHS は

$$\mathcal{H}_k = \Big\{ f = \sum_i c_i e_i \ :\ \|f\|_{\mathcal{H}}^2 = \sum_{i : \lambda_i > 0} \frac{c_i^2}{\lambda_i} < \infty \Big\} \tag{7.29}$$

と表される。

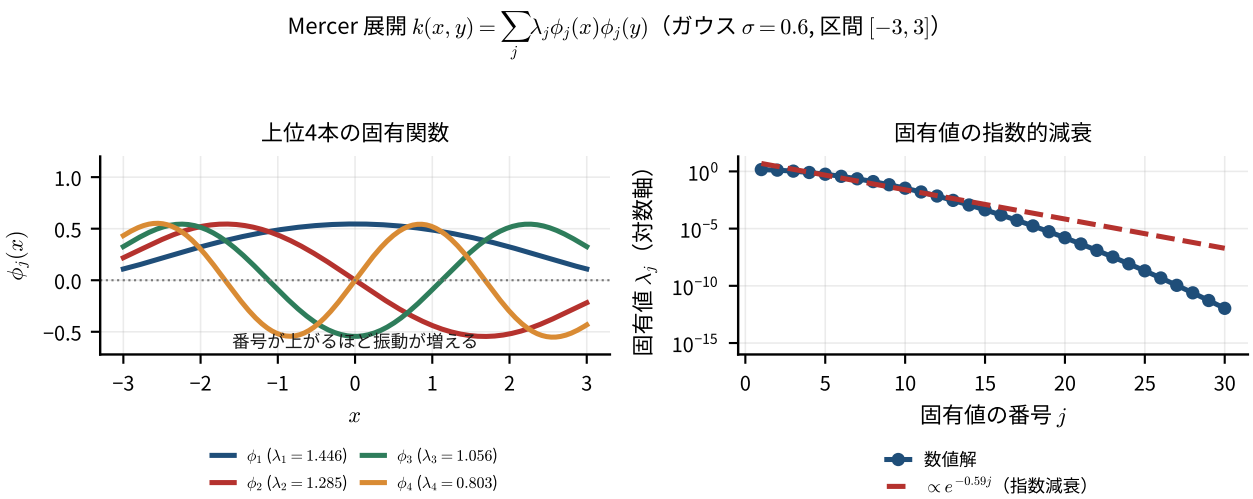


図7.5　ガウスカーネルの Mercer 展開。左は数値的に離散化して求めた上位 4 本の固有関数で、番号が大きくなるほど振動が激しくなる。右は固有値の減衰であり、指数的に速く 0 に近づく。この減衰の速さが RKHS の狭さ、すなわち関数の滑らかさに対応する。

証明. $\langle \phi_{\mathrm{M}}(x), \phi_{\mathrm{M}}(y)\rangle_{\ell^2} = \sum_i \lambda_i e_i(x) e_i(y) = k(x,y)$ が (7.28) そのもの。$\|\phi_{\mathrm{M}}(x)\|^2 = k(x,x) < \infty$ より $\phi_{\mathrm{M}}(x) \in \ell^2$。(7.29) については、右辺の空間で $\langle f, g\rangle := \sum_i c_i d_i/\lambda_i$ とすると $k(\cdot,y) = \sum_i \lambda_i e_i(y) e_i$ なので $\langle f, k(\cdot,y)\rangle = \sum_i c_i \lambda_i e_i(y)/\lambda_i = \sum_i c_i e_i(y) = f(y)$、すなわち再生性が成り立つ。一意性（定理 7.32）よりこれが $\mathcal{H}_k$ である。 ■

(7.29) は7.7節の「RKHS ノルムは滑らかさを測る」という主張のより透明な表現である。λ_i が小さい成分 e_i に係数を持たせると c_i^2/λ_i が大きくなって強く罰せられ、図 7.5のとおり小さい λ_i に対応する e_i は振動の激しい関数である。

例 7.43 (Mercer 展開の数値計算)**.** $\mathcal{X} = [-1,1]$、μ を一様測度、$\sigma = 0.3$ のガウスカーネルとする。$\mathcal{X}$ を $m = 400$ 点の等間隔格子で離散化し重み $w = 2/m$ を用いると積分作用素は行列 $w\boldsymbol{K}$ で近似される（リスト 7.2）。固有分解すると上位 6 個の固有値は $0.6924,\ 0.5452,\ 0.3675,\ 0.2131,\ 0.1072,\ 0.0472$ と急速に減衰する。固有関数は $e_i(t_j) = v_{ji}/\sqrt{w}$ で復元でき、この正規化で $\int e_i^2\,\mathrm{d}\mu \approx 1$ となる。展開 (7.28) を r 項で打ち切ったときの最大誤差は $r = 2$ で 0.803、$r = 6$ で 0.086、$r = 20$ で 10^{-5} 未満である。

リスト 7.2　Mercer 固有関数の数値計算。積分作用素を格子上の行列で近似し（Nyström 法）、固有値・固有関数と展開の打ち切り誤差を求める。

```
import numpy as np
m, sigma = 400, 0.3
grid, w = np.linspace(-1.0, 1.0, m), 2.0 / m        # 格子と一様測度の重み
K = np.exp(-(grid[:, None] - grid[None, :])**2 / (2*sigma**2))

vals, vecs = np.linalg.eigh(w * K)                  # T_k の離散化 = w*K
order = np.argsort(vals)[::-1]
lam, ef = vals[order], vecs[:, order] / np.sqrt(w)
print("上位6固有値:", np.round(lam[:6], 4),
      "  int e_1^2 dmu =", np.round((ef[:, 0]**2).sum() * w, 6))
for r in [2, 6, 20]:
    print(f"r={r:2d} max err =",
          f"{np.abs((ef[:,:r]*lam[:r]) @ ef[:,:r].T - K).max():.4f}")
```

二つの定理は同じ RKHS を別の角度から捉えたものだが、仮定と得られる情報が異なる。Moore–Aronszajn は $\mathcal{X}$ に何も仮定せず k の正定値性だけを要求し、測度も不要である。得られる特徴空間は $\mathcal{H}_k$ そのもの、特徴写像は $\phi(x) = k(\cdot,x)$ で、完備化によって定義されるため抽象的である。Mercer は $\mathcal{X}$ のコンパクト性、k の連続性、台が $\mathcal{X}$ 全体の測度 μ を要求する代わりに、特徴空間を ℓ^2、特徴写像を $\phi(x) = (\sqrt{\lambda_i} e_i(x))_i$ という固有関数の具体形で与える。

重要なのは測度への依存の仕方である。Mercer 展開の固有関数と固有値は μ に依存して変わるが、それらを組み合わせた $\sum_i \lambda_i e_i(x) e_i(y) = k(x,y)$ と、そこから定まる RKHS は μ に依らない。**RKHS はカーネルだけで決まる不変な対象であり、Mercer 展開はその一つの座標表示にすぎない。**第8章のカーネル PCA では、この Mercer 展開の経験版（Gram 行列の固有分解）が主役になる。

7.10　四つの見方の整理

本章で扱った対象は、すべて同じ数学的対象の異なる側面である四つの見方に整理できる。計算したい量に応じて使い分ければよい。四つとは、(i) **正定値カーネル** $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$（Gram 行列が半正定値。出発点であり、実装で Gram 行列を作るときの見方）、(ii) **RKHS** $\mathcal{H}_k$（評価汎関数が有界な関数の Hilbert 空間。k から一意に決まり、表現定理や正則化の理論で使う）、(iii) **特徴写像** $\phi : \mathcal{X} \to \mathcal{F}$ で $k = \langle \phi, \phi \rangle$（一意ではないが、線形化の直感を与える）、(iv) **Mercer 展開** $k = \sum_i \lambda_i e_i e_i$（測度 μ に依存するが、近似誤差や収束レートの解析に向く）である。

対応関係を図式で書けば次のようになる。

$$\underbrace{k \text{ 正定値}}_{\text{定義 7.23}} \xleftrightarrow[\text{定理 7.32}]{\text{定理 7.31}} \underbrace{\mathcal{H}_k \text{ RKHS}}_{\text{定義 7.30}} \xrightarrow{\text{系 7.36}} \underbrace{\phi(x) = k(\cdot, x)}_{\text{標準特徴写像}} \xleftarrow{\text{系 7.42}} \underbrace{\big(\sqrt{\lambda_i} e_i(x)\big)_i}_{\text{Mercer}}$$

本章の到達点と次章への橋渡し

7.1節で立てた三つの問いに答えが出た。(1) k が満たすべき条件は**対称性と正定値性**である（定義 7.23）。(2) 暗黙に働いている空間は**再生核ヒルベルト空間** $\mathcal{H}_k$ であり、カーネルから一意に決まる（定理 7.32）。(3) $\mathcal{H}_k$ の中では $\mathbb{R}^d$ と同じ幾何——直交射影、正規直交展開、最短点の存在——がすべて使える（7.4節）。第8章では双対 PCA の内積を k に置き換えてカーネル PCA を導き、表現定理によって無限次元の最適化が有限次元に帰着することを示す。第9章では同じ道具立てで SVM を扱う。**どちらの章でも、実際に計算するのは $n \times n$ の Gram 行列だけである。**

演習問題

演習 7.1 ((⋆) 多項式カーネルの特徴写像)**.** $\mathcal{X} = \mathbb{R}^2$, $k(\boldsymbol{x}, \boldsymbol{y}) = (\boldsymbol{x}^\top \boldsymbol{y})^2$ とする。(1) $k(\boldsymbol{x}, \boldsymbol{y}) = \langle \phi(\boldsymbol{x}), \phi(\boldsymbol{y}) \rangle$ を満たす $\phi : \mathbb{R}^2 \to \mathbb{R}^3$ を書き下し、等式を計算で確かめよ。(2) $\boldsymbol{x} = (2, -1)^\top$, $\boldsymbol{y} = (1, 3)^\top$ に対し $\phi(\boldsymbol{x}), \phi(\boldsymbol{y})$ とその内積、および $(\boldsymbol{x}^\top \boldsymbol{y})^2$ を数値で計算して一致を確認せよ。(3) $\mathcal{X} = \mathbb{R}^d$ に対する特徴写像を書き下し、その次元を d で表せ。

演習 7.2 ((⋆) 完備でない内積空間)**.** $C[0, 1]$ に L^2 内積を入れた空間 V を考える。(1) $f_m(t) = t^m$ は V で Cauchy 列か。理由とともに答えよ。(2) V の元 f の中で「$\|f\|_{L^2} \le 1$ かつ $f(1/2)$ が最大」となるものは存在するか。存在しないならその理由を例 7.29と関連づけて述べよ。

演習 7.3 ((⋆⋆) 射影定理の応用)**.** $\mathcal{H}$ を Hilbert 空間、$M \subset \mathcal{H}$ を閉部分空間、$P_M : \mathcal{H} \to M$ を $f \mapsto g^*$（定理 7.10の最短点）とする。(1) P_M は線形であることを示せ。(2) $P_M^2 = P_M$ かつ $\langle P_M f, g \rangle = \langle f, P_M g \rangle$（自己共役）を示せ。(3) $\|P_M\|_{\mathrm{op}} \le 1$ を示し、$M \neq \{0\}$ なら等号が成り立つことを示せ。また M が**閉でない**部分空間のとき最短点が存在しない例を挙げよ。

演習 7.4 ((⋆⋆) ガウスカーネルの正定値性を演算則から)**.** 定理 7.24の演算則のみを用いて次を示せ。(1) $\exp(\boldsymbol{x}^\top \boldsymbol{y} / \sigma^2)$ が $\mathbb{R}^d$ 上の正定値カーネルであること（使った演算則を番号で明示すること）。(2) ガウスカーネル $\exp(-\|\boldsymbol{x} - \boldsymbol{y}\|^2 / 2\sigma^2)$ が正定値であること。(3) 指数カーネル $\exp(-\|\boldsymbol{x} - \boldsymbol{y}\| / \sigma)$ は同じ手順では示せない。どこで議論が止まるか説明せよ（正定値であること自体は正しい）。(4) シグモイドカーネル $k(x, y) = \tanh(xy + 1)$ は正定値か。3 点 $x_1 = -2, x_2 = 0, x_3 = 2$ で Gram 行列を作り固有値を計算して判定せよ。

演習 7.5 ((⋆⋆) RKHS の元とノルム)**.** k を正定値カーネル、$\mathcal{H}_k$ をその RKHS とし、$f = \sum_{i=1}^n \alpha_i k(\cdot, x_i)$、$\boldsymbol{K} = (k(x_i, x_j))_{ij}$ とする。(1) $\|f\|_{\mathcal{H}}^2 = \boldsymbol{\alpha}^\top \boldsymbol{K} \boldsymbol{\alpha}$ を示し、$|f(x)| \le \|f\|_{\mathcal{H}} \sqrt{k(x, x)}$ を再生性から示せ。ガウスカーネルの場合、後者は何を意味するか。(2) $n = 3$、$x_1 = 0, x_2 = 1, x_3 = 2$、$\sigma = 1$ のガウスカーネル、$\boldsymbol{\alpha} = (1, -1, 1)^\top$ に対し $\|f\|_{\mathcal{H}}^2$ を数値で求めよ。(3) 同じ x_i に対し $f(0) = 1, f(1) = 0, f(2) = 1$ を満たす関数のうち $\|f\|_{\mathcal{H}}$ が最小のものを求めよ（$\boldsymbol{\alpha}$ を求めればよい）。これが第8章の表現定理の最も簡単な形である。

演習 7.6 ((⋆⋆⋆) Brown 運動のカーネル)**.** $\mathcal{X} = [0, 1]$ 上で $k(x, y) = \min(x, y)$ を考える。

(1) $\min(x, y) = \int_0^1 \mathbf{1}\{t \le x\} \mathbf{1}\{t \le y\} \, \mathrm{d}t$ を示し、これを用いて k が正定値であることを示せ。特徴写像は何か。

(2) $k(x, y) = \min(x, y)$ は標準 Brown 運動 B_t の共分散関数 $\mathrm{Cov}(B_x, B_y)$ に等しいことを確認せよ（$\mathrm{Var}(B_t) = t$、独立増分を用いる）。

(3) $\mathcal{H}_k$ を同定せよ。すなわち、

$$\mathcal{H}_k = \Big\{ f : [0, 1] \to \mathbb{R} \;\Big|\; f(0) = 0,\ f \text{ は絶対連続},\ \int_0^1 f'(t)^2 \, \mathrm{d}t < \infty \Big\}, \quad \|f\|_{\mathcal{H}}^2 = \int_0^1 f'(t)^2 \, \mathrm{d}t$$

となることを、再生性の確認によって示せ。（この空間を Cameron–Martin 空間という。）

(4) $0 < x_1 < \cdots < x_n \le 1$ に対する Gram 行列 $K_{ij} = \min(x_i, x_j)$ の逆行列は三重対角になる。$n = 3$、$x = (0.2, 0.5, 1.0)$ で $\boldsymbol{K}$ と $\boldsymbol{K}^{-1}$ を計算し確認せよ。

演習 7.7 ((⋆⋆) 実装：Gram 行列の正定値性を数値で確認)**.** NumPy を用いて次を行うプログラムを書け。(1) $n = 100$ 点を $\mathbb{R}^2$ から乱数生成し（$\boldsymbol{X} \in \mathbb{R}^{2\times 100}$、seed 固定)、線形・多項式（$c = 1, p = 3$)・ガウス（$\sigma = 1$)・ラプラシアン・シグモイド $\tanh(\boldsymbol{x}^\top \boldsymbol{y} + 1)$ の 5 種の Gram 行列を作り、それぞれの最小固有値を出力せよ。どれが正定値でないか。(2) ガウスカーネルの帯域幅 σ を 10^{-1} から 10^{2} まで対数的に変えたとき、Gram 行列の数値的階数（固有値が $10^{-10}\max_i \lambda_i$ を超える個数）がどう変わるかをプロットし、図 7.3の議論と照らして考察せよ。

演習 7.8 ((⋆⋆⋆) 実装：Mercer 固有関数の数値計算)**.** リスト 7.2を出発点として次を行え。

(1) $\mathcal{X} = [-1, 1]$、一様測度、ガウスカーネル $\sigma = 0.3$ に対し上位 6 個の固有値と固有関数を求め、固有関数をプロットせよ。番号が上がるにつれて何が起こるか。

(2) 直交性 $\int e_i e_j \,\mathrm{d}\mu \approx \delta_{ij}$ を数値で確認し、打ち切り階数 r に対する誤差 $\max_{x,y} |k(x,y) - \sum_{i\le r} \lambda_i e_i(x) e_i(y)|$ を $r = 1, \dots, 20$ でプロットして、片対数で見た減衰の様子を述べよ。

(3) $\sigma = 0.1$ と $\sigma = 1.0$ で同じ計算を行い、固有値の減衰の速さを比較せよ。(7.29) と例 7.33の議論と整合するか論じよ。

(4)（発展）格子点数 m を $100, 200, 400, 800$ と変えて上位固有値の推定値が収束することを確認せよ。積分の Riemann 和近似の収束であり、Nyström 法の基礎である。

第 8 章

カーネル PCA と表現定理

この章のねらい

前章で構成した再生核ヒルベルト空間（RKHS）を道具として使う。本章は二つの流れからなる。第一の流れは「双対 PCA → カーネルトリック → カーネル PCA」である。入力を内積を通してしか使わないアルゴリズムは、内積をカーネルに置き換えるだけで非線形化できる——これだけでカーネル PCA が完成する。第二の流れは「有限次元化という共通原理 → 表現定理 → カーネルリッジ回帰・SVM」である。無限次元の $\mathcal{H}$ の問題がなぜ有限個の係数で解けたのかを問い直すと、RKHS 上の正則化つき経験リスク最小化の解が必ず n 個のカーネル関数の線形結合で書けるという表現定理に行き着く。続けてカーネル CCA、分布の埋め込みへ適用し、最後に $O(n^3)$ の壁を破る Nyström 近似 [84] とランダムフーリエ特徴 [62] を扱う。[a]

[a] この章の計算は演習ノートブック `ch08_kernel_pca.ipynb` で再現できる。インストール不要で実行するには Google Colab で開く：
`https://colab.research.google.com/github/yusukeimoto/data-analysis-math-demos/blob/main/notebooks/ch08_kernel_pca.ipynb`

8.1 カーネルトリック：双対 PCA からの非線形化

第4章 の双対 PCA を思い出そう。データ行列は $\boldsymbol{X} \in \mathbb{R}^{d\times n}$（第 i 列が $\boldsymbol{x}_i$）であり、主 PCA が $d \times d$ 行列 $\widehat{\boldsymbol{\Sigma}} = \frac{1}{n}\widetilde{\boldsymbol{X}}\widetilde{\boldsymbol{X}}^{\top}$ の固有値問題を解くのに対し、双対 PCA は $n \times n$ 行列 $\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}$ の固有値問題を解いた。同じスコアを与えるが、決定的な違いがある。

この章の出発点

主 PCA は $\widehat{\boldsymbol{\Sigma}}$ を作るためにデータ点の**座標** $\boldsymbol{x}_i \in \mathbb{R}^d$ を必要とする。双対 PCA が必要とするのは $(\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}})_{ij} = \langle \tilde{\boldsymbol{x}}_i, \tilde{\boldsymbol{x}}_j \rangle$、すなわち**点どうしの内積の値だけ**である。座標は一度も使われない。

これがカーネル法の出発点である。アルゴリズムがデータを内積を通してしか参照しないなら、点の座標を知らなくても動く。したがって適当なヒルベルト空間 $\mathcal{H}$ への特徴写像（feature map）$\phi : \mathcal{X} \to \mathcal{H}$ を考え、$\langle \boldsymbol{x}_i, \boldsymbol{x}_j \rangle \longrightarrow \langle \phi(\boldsymbol{x}_i), \phi(\boldsymbol{x}_j) \rangle_{\mathcal{H}} = k(\boldsymbol{x}_i, \boldsymbol{x}_j)$ と読み替えれば、同じアルゴリズムがそのまま $\mathcal{H}$ 上で動作する。ϕ を陽に構成する必要はなく、k の値さえ計算できればよい。これを**カーネルトリック**（kernel trick）と呼ぶ。この操作に名前を与えておく。

定義 8.1 (カーネル法)**.** データを**内積（あるいは Gram 行列）を通してしか参照しない**アルゴリズムに対し、内積 $\langle \boldsymbol{x}, \boldsymbol{y} \rangle$ を正定値カーネル $k(\boldsymbol{x}, \boldsymbol{y})$（定義 7.23）に置き換えて得られる手法の総称を**カーネル法**（kernel method）という。

この定義が意味をもつのは前章の結果による。k が正定値なら Moore–Aronszajn の定理（定理 7.32）によりある Hilbert 空間 $\mathcal{H}$ と特徴写像 $\phi : \mathcal{X} \to \mathcal{H}$ が存在して $k(\boldsymbol{x}, \boldsymbol{y}) = \langle \phi(\boldsymbol{x}), \phi(\boldsymbol{y}) \rangle_{\mathcal{H}}$ と書けるので、置き換えの結果は**元のアルゴリズムを $\mathcal{H}$ 上でそのまま実行したもの**に等しい。したがってカーネル法とは

$$\text{「同じアルゴリズムを、 } \mathbb{R}^d \text{ ではなく特徴空間 } \mathcal{H} \text{ で走らせること」} \tag{8.1}$$

であり、ϕ を陽に構成せず k の値だけで計算を済ませるのがカーネルトリックである。用語を整理すると、**カーネル関数**が k そのもの、**カーネルトリック**が ϕ を経由しない計算の技法、**カーネル法**がその技法で作られた手法の総称である。

内積だけでは書けないものはカーネル化できない

定義 8.1の前提は「内積を通してしか参照しない」である。座標そのものを使う操作——たとえば「第 3 変数の値で場合分けする」「負荷量の成分を見てどの変数が効いたかを読む」「変数ごとに異なる罰則をかける」——は $\mathcal{H}$ に座標がないので持ち上がらない。第 1 主成分が**スコアは計算できるのに方向ベクトルは書き下せない**という本章の制約は、この定義から直接出る帰結である。

双対 PCA について言えば、

$$\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}} \;\longrightarrow\; \widetilde{\boldsymbol{K}} \tag{8.2}$$

という一行の置き換えがカーネル PCA である。左辺は $\mathbb{R}^d$ の点どうしの内積を (i,j) 成分に並べた $n\times n$ 行列、右辺はその内積を $k(\boldsymbol{x}_i,\boldsymbol{x}_j)$ に取り替えた同じ大きさの行列であり、置き換えの前後で**行列の形も添字の意味も変わらない**。これが「一行の置き換え」で済む理由である。$\widetilde{\boldsymbol{K}}$ は中心化した $\phi(\boldsymbol{x}_i)$ たちの Gram 行列で、8.2節 で $\widetilde{\boldsymbol{K}}=\boldsymbol{H}\boldsymbol{K}\boldsymbol{H}$ と計算できることを示す。主成分方向 $\boldsymbol{v}_j$（8.3節の記号）は $\mathcal{H}$ の元となり一般に書き下せないが、スコアと固有値は数値として計算できるので用は足りる。

注意 8.2 (三つの非線形化戦略のうちの一つ)**.** 第1章の非線形化の三戦略——(i) 明示的な特徴を人手で作る、(ii) カーネルで暗黙に特徴空間へ移る、(iii) 特徴自体を学習する——のうち本章は (ii) を扱う。(i) は ϕ を書き下すので $\dim\mathcal{H}$ が大きいと破綻するが、(ii) はこの制約を外し、計算量が**特徴空間の次元に陽に依存しない**形に持ち込む（依存するのはサンプル数 n とカーネル評価コスト C_k である）。その代償が $O(n^3)$ であり、8.10節 で見るように大規模データではふたたび (i) へ——今度は**ランダムに**構成した有限次元特徴へ——引き返す。なお「負荷量の成分を見てどの変数が効いているかを解釈する」操作は $\boldsymbol{v}_j$ が座標をもたないため実行できない。スパース PCA（第4章）が解釈性を狙うのと、カーネル PCA が表現力を狙うのは相反する方向である。

本章の地図

この先は二つの流れに分かれる。第一の流れ（8.2節–8.3節）は **双対 PCA → カーネルトリック → カーネル PCA** で、必要な道具は (8.2)の置き換えと中心化だけである。第二の流れ（8.4節以降）は**有限次元化という共通原理 → 表現定理 → カーネルリッジ回帰・SVM** で、「無限次元の問題がなぜ有限個の係数で解けたのか」を問い直すところから始まる。第一の流れに表現定理は必要ない。

8.2　中心化 Gram 行列

PCA は中心化されたデータに対して定義される。カーネル PCA でも特徴空間で中心化するが、$\phi(\boldsymbol{x}_i)$ を陽に持たないので「平均を引く」操作を Gram 行列の言葉に翻訳する必要がある。実装で最も間違えやすい箇所である。標本平均 $\bar\phi := \frac{1}{n}\sum_j \phi(\boldsymbol{x}_j)$ に対し、$\tilde\phi(\boldsymbol{x}_i) := \phi(\boldsymbol{x}_i) - \bar\phi$ と定義する。

命題 8.3 (中心化 Gram 行列)**.** $K_{ij}=k(\boldsymbol{x}_i,\boldsymbol{x}_j)$、$\boldsymbol{H}=\boldsymbol{I}_n-\frac{1}{n}\boldsymbol{1}\boldsymbol{1}^{\top}$ とすると、$\widetilde{\boldsymbol{K}}_{ij} := \langle\tilde\phi(\boldsymbol{x}_i),\tilde\phi(\boldsymbol{x}_j)\rangle_{\mathcal{H}}$ は

$$\widetilde{\boldsymbol{K}}=\boldsymbol{H}\boldsymbol{K}\boldsymbol{H}, \qquad \widetilde{\boldsymbol{K}}_{ij}=K_{ij}-\frac{1}{n}\sum_{a}K_{aj}-\frac{1}{n}\sum_{b}K_{ib}+\frac{1}{n^2}\sum_{a,b}K_{ab}. \tag{8.3}$$

証明. 内積の双線形性で展開する。

$$\begin{aligned}\widetilde{\boldsymbol{K}}_{ij} &= \Big\langle \phi(\boldsymbol{x}_i)-\tfrac{1}{n}\textstyle\sum_a\phi(\boldsymbol{x}_a),\ \phi(\boldsymbol{x}_j)-\tfrac{1}{n}\sum_b\phi(\boldsymbol{x}_b)\Big\rangle_{\mathcal{H}}\\ &= K_{ij}-\frac{1}{n}\sum_b K_{ib}-\frac{1}{n}\sum_a K_{aj}+\frac{1}{n^2}\sum_{a,b}K_{ab}.\end{aligned} \tag{8.4}$$

$\frac{1}{n}\boldsymbol{K}\boldsymbol{1}\boldsymbol{1}^{\top}$ は各行を行平均で、$\frac{1}{n}\boldsymbol{1}\boldsymbol{1}^{\top}\boldsymbol{K}$ は各列を列平均で、$\frac{1}{n^2}\boldsymbol{1}\boldsymbol{1}^{\top}\boldsymbol{K}\boldsymbol{1}\boldsymbol{1}^{\top}$ は全体を全体平均で埋めた行列だから、(8.4) は $\widetilde{\boldsymbol{K}}=\boldsymbol{K}-\frac{1}{n}\boldsymbol{K}\boldsymbol{1}\boldsymbol{1}^{\top}-\frac{1}{n}\boldsymbol{1}\boldsymbol{1}^{\top}\boldsymbol{K}+\frac{1}{n^2}\boldsymbol{1}\boldsymbol{1}^{\top}\boldsymbol{K}\boldsymbol{1}\boldsymbol{1}^{\top}$ であり、右辺は $(\boldsymbol{I}-\frac{1}{n}\boldsymbol{1}\boldsymbol{1}^{\top})\boldsymbol{K}(\boldsymbol{I}-\frac{1}{n}\boldsymbol{1}\boldsymbol{1}^{\top})$ の展開に等しい。 ■

注意 8.4. $\boldsymbol{H}$ は対称べき等（$\boldsymbol{H}^{\top}=\boldsymbol{H},\boldsymbol{H}^2=\boldsymbol{H}$）、すなわち $\boldsymbol{1}^{\perp}$ への直交射影である。$\boldsymbol{H}\boldsymbol{1}=\boldsymbol{0}$ より $\widetilde{\boldsymbol{K}}\boldsymbol{1}=\boldsymbol{0}$、つまり**中心化 Gram 行列は必ず $\boldsymbol{1}$ を固有値 0 の固有ベクトルにもち**、$\operatorname{rank}\widetilde{\boldsymbol{K}}\le n-1$ である。実装のよい検算になる。

例 8.5 (3×3 の手計算)**.** $\boldsymbol{K}=\begin{pmatrix}1&1/2&0\\1/2&1&1/2\\0&1/2&1\end{pmatrix}$ の行平均は $(1/2,2/3,1/2)$、全体平均は $5/9$ だから (8.3) より $\widetilde{\boldsymbol{K}}=\frac{1}{9}\begin{pmatrix}5&-1&-4\\-1&2&-1\\-4&-1&5\end{pmatrix}$。各行の和が 0 であること（注意 8.4）を確かめよ。固有値は $1,\ 1/3,\ 0$ で、対応する固有ベクトルは $(1,0,-1)^{\top}/\sqrt{2}$、$(1,-2,1)^{\top}/\sqrt{6}$、$\boldsymbol{1}/\sqrt{3}$ である。

新しい点 $\boldsymbol{x}_*$ を射影するとき、引くべき平均は**訓練データの平均** $\bar\phi$ であり、テスト点を含めた平均ではない。

命題 8.6 (テスト点の中心化)**.** $\boldsymbol{k}_* \coloneqq (k(\boldsymbol{x}_*, \boldsymbol{x}_1), \dots, k(\boldsymbol{x}_*, \boldsymbol{x}_n))^\top$ とおくと、$\tilde{k}_{*i} \coloneqq \langle \tilde{\phi}(\boldsymbol{x}_*), \tilde{\phi}(\boldsymbol{x}_i) \rangle_{\mathcal{H}}$ は

$$\tilde{k}_{*i} = k(\boldsymbol{x}_*, \boldsymbol{x}_i) - \frac{1}{n}\sum_{b} k(\boldsymbol{x}_*, \boldsymbol{x}_b) - \frac{1}{n}\sum_{a} K_{ai} + \frac{1}{n^2}\sum_{a,b} K_{ab}, \tag{8.5}$$

行ベクトルで書けば $\widetilde{\boldsymbol{k}}_*^\top = \big(\boldsymbol{k}_*^\top - \frac{1}{n}\mathbf{1}^\top \boldsymbol{K}\big)\boldsymbol{H}$。$m$ 個をまとめれば $\widetilde{\boldsymbol{K}}_* = \big(\boldsymbol{K}_* - \frac{1}{n}\mathbf{1}_m\mathbf{1}_n^\top \boldsymbol{K}\big)\boldsymbol{H}$ である。

証明. $\tilde{\phi}(\boldsymbol{x}_*) = \phi(\boldsymbol{x}_*) - \frac{1}{n}\sum_b \phi(\boldsymbol{x}_b)$ と $\tilde{\phi}(\boldsymbol{x}_i) = \phi(\boldsymbol{x}_i) - \frac{1}{n}\sum_a \phi(\boldsymbol{x}_a)$ の内積を双線形性で展開すれば (8.5) の四項がそのまま出る。行列表示は、$\boldsymbol{k}_*^\top \boldsymbol{H}$ の第 i 成分が第 1 項と第 2 項の差、$\frac{1}{n}\mathbf{1}^\top \boldsymbol{K}\boldsymbol{H}$ の第 i 成分が第 3 項と第 4 項の差（符号込み）になることから従う。訓練点 $\boldsymbol{x}_* = \boldsymbol{x}_i$ を代入すると $\boldsymbol{H}\boldsymbol{K}\boldsymbol{H}$ の第 i 行に一致する。 ■

実装で必ず間違える三点

(1) テスト点の中心化に $\boldsymbol{K}_*$ の行平均**だけ**を引いてはいけない。(8.5) の第 3 項（訓練 Gram の列平均）と第 4 項（全体平均）が要る。(2) 第 3 項・第 4 項は**訓練データから計算した値**を保存して使う。テスト集合から計算し直すと、テスト集合の大きさで結果が変わってしまう。(3) 単体テストは「訓練点を (8.5) に入れると $\boldsymbol{H}\boldsymbol{K}\boldsymbol{H}$ の対応する行になる」ことの確認である。

8.3　カーネル PCA

Schölkopf–Smola–Müller [70] が導入した手法で、「特徴空間で PCA を行う」という発想を Gram 行列の固有値問題として実行可能にしたものである。特徴写像 $\boldsymbol{\phi}$ を陽に扱わずに済むのは、8.1節のカーネルトリックと8.2節の中心化 Gram 行列だけで済む——表現定理（8.5節）は**要らない**。以下ではその二つだけを土台に導出する。

8.3.1　共分散作用素からの導出

特徴空間の標本共分散に相当する対象を定義する。$\mathcal{H}$ が有限次元 $\mathbb{R}^D$ なら $\frac{1}{n}\sum_i \tilde{\phi}(\boldsymbol{x}_i)\tilde{\phi}(\boldsymbol{x}_i)^\top$ という行列だが、無限次元でも同じ式が作用素として意味をもつ。

定義 8.7 (共分散作用素)**.** $\boldsymbol{C} : \mathcal{H} \to \mathcal{H}$ を $\boldsymbol{C}f \coloneqq \frac{1}{n}\sum_{i=1}^n \langle \tilde{\phi}(\boldsymbol{x}_i), f\rangle_{\mathcal{H}}\, \tilde{\phi}(\boldsymbol{x}_i)$ で定める。記号では $\boldsymbol{C} = \frac{1}{n}\sum_i \tilde{\phi}(\boldsymbol{x}_i)\tilde{\phi}(\boldsymbol{x}_i)^*$ と書く。$\boldsymbol{C}$ は自己共役・非負値で $\operatorname{rank}\boldsymbol{C} \le n-1$ である。

カーネル PCA とは固有値問題 $\boldsymbol{C}\boldsymbol{v} = \lambda \boldsymbol{v}$（$\|\boldsymbol{v}\|_{\mathcal{H}} = 1$, $\lambda > 0$）を解き、上位 k 個の固有ベクトルへの射影を主成分スコアとすることである。これは 第3章 で線形 PCA を「射影後の分散を最大にする方向」として特徴づけたのと同じ Rayleigh 商の枠組み（第1章の枠組み (2)）である。

定理 8.8 (カーネル PCA の有限次元化)**.** $\lambda > 0$ を $\boldsymbol{C}$ の固有値、$\boldsymbol{v}$ を対応する固有ベクトルとすると $\boldsymbol{v} \in \operatorname{span}\{\tilde{\phi}(\boldsymbol{x}_i)\}_{i=1}^n$ であり、$\boldsymbol{v} = \sum_i \alpha_i \tilde{\phi}(\boldsymbol{x}_i)$ と書けば係数 $\boldsymbol{\alpha}$ は

$$\widetilde{\boldsymbol{K}}\boldsymbol{\alpha} = n\lambda\, \boldsymbol{\alpha} \tag{8.6}$$

を満たす。逆も成り立つ。さらに $\mu \coloneqq n\lambda$ とおくと

$$\|\boldsymbol{v}\|_{\mathcal{H}} = 1 \iff \boldsymbol{\alpha}^\top \widetilde{\boldsymbol{K}}\boldsymbol{\alpha} = 1 \iff \mu\|\boldsymbol{\alpha}\|^2 = 1 \iff \|\boldsymbol{\alpha}\| = \frac{1}{\sqrt{\mu}} = \frac{1}{\sqrt{n\lambda}}. \tag{8.7}$$

証明. **(1)** $\lambda \boldsymbol{v} = \boldsymbol{C}\boldsymbol{v} = \frac{1}{n}\sum_i \langle \tilde{\phi}(\boldsymbol{x}_i), \boldsymbol{v}\rangle \tilde{\phi}(\boldsymbol{x}_i)$ の右辺は $\tilde{\phi}(\boldsymbol{x}_i)$ の線形結合だから、$\lambda > 0$ より $\boldsymbol{v} \in \operatorname{span}\{\tilde{\phi}(\boldsymbol{x}_i)\}$。$\boldsymbol{C}$ が $\tilde{\phi}(\boldsymbol{x}_i)$ たちの外積和でできていることだけを使った。同じ「有限次元化」が正則化つき最適化でも起こることは8.4節以降で一般原理として述べる。

(2) $\boldsymbol{v} = \sum_j \alpha_j \tilde{\phi}(\boldsymbol{x}_j)$ を代入すると $\boldsymbol{C}\boldsymbol{v} = \frac{1}{n}\sum_i (\widetilde{\boldsymbol{K}}\boldsymbol{\alpha})_i \tilde{\phi}(\boldsymbol{x}_i)$ であり、これが $\lambda\sum_i \alpha_i \tilde{\phi}(\boldsymbol{x}_i)$ に等しい。両辺と $\tilde{\phi}(\boldsymbol{x}_l)$ の内積をとると $\widetilde{\boldsymbol{K}}^2\boldsymbol{\alpha} = n\lambda \widetilde{\boldsymbol{K}}\boldsymbol{\alpha}$ を得る。これと (8.6) は厳密には同値でない。$\widetilde{\boldsymbol{K}}\boldsymbol{\alpha} = \mathbf{0}$ となる解は $\boldsymbol{v} = \mathbf{0}$ を与えるので捨てる。$\widetilde{\boldsymbol{K}}$ は対称なので $\mathbb{R}^n = \operatorname{Ker}\widetilde{\boldsymbol{K}} \oplus \operatorname{Im}\widetilde{\boldsymbol{K}}$ と分解でき、$\boldsymbol{\alpha} \in \operatorname{Ker}\widetilde{\boldsymbol{K}}$ なら $\|\boldsymbol{v}\|^2 = \boldsymbol{\alpha}^\top\widetilde{\boldsymbol{K}}\boldsymbol{\alpha} = 0$ で $\boldsymbol{v}$ に寄与しない。よって一般性を失わず $\boldsymbol{\alpha} \in \operatorname{Im}\widetilde{\boldsymbol{K}}$ とでき、その上で $\widetilde{\boldsymbol{K}}$ は可逆だから (8.6) が従う。

(3) $\|\boldsymbol{v}\|_{\mathcal{H}}^2 = \sum_{i,j}\alpha_i\alpha_j \widetilde{\boldsymbol{K}}_{ij} = \boldsymbol{\alpha}^\top\widetilde{\boldsymbol{K}}\boldsymbol{\alpha} = \mu\|\boldsymbol{\alpha}\|^2$ であり、これが 1 に等しいことが $\|\boldsymbol{v}\|_{\mathcal{H}} = 1$ と同値である。 ■

固有ベクトル $\boldsymbol{v}_j = \sum_i \alpha_{ji}\tilde{\phi}(\boldsymbol{x}_i)$ への射影が主成分スコアで、訓練点とテスト点についてそれぞれ

$$z_{ij} = \langle \tilde{\phi}(\boldsymbol{x}_i), \boldsymbol{v}_j\rangle = (\widetilde{\boldsymbol{K}}\boldsymbol{\alpha}_j)_i = \mu_j \alpha_{ji}, \qquad z_{*j} = \widetilde{\boldsymbol{k}}_*^\top \boldsymbol{\alpha}_j$$

（後者は 命題 8.6 による）。分散は $\frac{1}{n}\sum_i z_{ij}^2 = \frac{1}{n}\mu_j^2\|\boldsymbol{\alpha}_j\|^2 = \mu_j/n = \lambda_j$ となり「第 j 主成分の分散 $= \boldsymbol{C}$ の第 j 固有値」が成り立つ。寄与率は $\mu_j / \operatorname{tr}\widetilde{\boldsymbol{K}}$ である。

正規化を間違えるとスコアの尺度が狂う

`numpy.linalg.eigh` などが返す固有ベクトルは $\|\boldsymbol{\alpha}\| = 1$ に正規化されている。必要なのは $\|\boldsymbol{\alpha}\| = 1/\sqrt{\mu}$ だから**必ず $\sqrt{\mu}$ で割る**。忘れると各成分のスケールが $\sqrt{\mu_j}$ 倍ずれ、成分間の相対的な大きさが誤って表示される。μ_j が数値誤差レベルの成分は最初から捨てること。

カーネル PCA のアルゴリズム

(1) $\boldsymbol{K}$（$K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j)$）を計算（$O(n^2)$ 回のカーネル評価）。(2) 中心化 $\widetilde{\boldsymbol{K}} = \boldsymbol{H}\boldsymbol{K}\boldsymbol{H}$、行平均・列平均・全体平均を保存する。(3) $\widetilde{\boldsymbol{K}}$ を固有分解し降順に $\mu_1 \geq \cdots \geq \mu_n \geq 0$、$\|\boldsymbol{u}_j\| = 1$（$O(n^3)$）。(4) 正規化 $\boldsymbol{\alpha}_j := \boldsymbol{u}_j/\sqrt{\mu_j}$（$\mu_j > 0$ のみ）。(5) 訓練スコアは $\boldsymbol{A} := [\boldsymbol{\alpha}_1, \ldots, \boldsymbol{\alpha}_k] \in \mathbb{R}^{n\times k}$ として $\boldsymbol{Z} = \boldsymbol{A}^\top \widetilde{\boldsymbol{K}} \in \mathbb{R}^{k\times n}$（**第 i 列**がサンプル i のスコア $\boldsymbol{z}_i$）、テスト点は $z_{*j} = \widetilde{\boldsymbol{k}}_*^\top \boldsymbol{\alpha}_j$。

例 8.9（3 点での手計算）**.** 例 8.5 の $\widetilde{\boldsymbol{K}}$（固有値 $1, 1/3, 0$）では、$\mu_1 = 1$ に対し $\boldsymbol{\alpha}_1 = (1, 0, -1)^\top/\sqrt{2}$、$\mu_2 = 1/3$ に対し $\boldsymbol{\alpha}_2 = \sqrt{3}(1, -2, 1)^\top/\sqrt{6}$。第 j 成分の全点にわたるスコアは $\boldsymbol{Z}$ の**第 j 行** $\boldsymbol{\alpha}_j^\top \widetilde{\boldsymbol{K}} = \mu_j \boldsymbol{\alpha}_j^\top$ で、$j = 1$ では $(0.707, 0, -0.707)$、$j = 2$ では $(0.236, -0.471, 0.236)$ である。検算として各行のノルムの二乗が μ_j に等しい。$\boldsymbol{Z}$ の第 i 列が点 i のスコアなので、たとえば点 1 のスコアは $\boldsymbol{z}_1 = (0.707, 0.236)^\top$ である。第 1 成分は点 1 と点 3 を、第 2 成分は点 2 を他の二点から分離し、第 3 成分は固有値 0 なので情報をもたない。

リスト 8.1　カーネル PCA の数式どおりの実装とライブラリとの一致確認

```python
import numpy as np
from sklearn.datasets import make_circles
from sklearn.decomposition import KernelPCA

def rbf(A, B, s):                          # A: d×n, B: d×m -> n×m
    return np.exp(-((A[:, :, None] - B[:, None, :])**2).sum(0) / (2*s**2))

def kpca_fit(X, k, s):                     # X は d×n（列がサンプル）
    n = X.shape[1]
    K = rbf(X, X, s)
    H = np.eye(n) - np.ones((n, n)) / n
    Kt = H @ K @ H                         # 中心化 Gram 行列 (8.3)
    lam, U = np.linalg.eigh(Kt)            # 昇順
    lam, U = lam[::-1][:k], U[:, ::-1][:, :k]
    return K, Kt, lam, U / np.sqrt(lam)    # ||alpha||^2 = 1/mu  (8.7)

def kpca_transform(Xnew, X, K, A, s):      # (8.5) のテスト点中心化
    Kn = rbf(Xnew, X, s)
    Kn = Kn - Kn.mean(1, keepdims=True) - K.mean(0, keepdims=True) + K.mean()
    return Kn @ A

Xnd, _ = make_circles(n_samples=200, factor=0.3, noise=0.05, random_state=0)
X = Xnd.T                                  # make_circles は n×d を返すので転置
sigma, k = 0.5, 2
K, Kt, lam, A = kpca_fit(X, k, sigma)
Z = A.T @ Kt                               # k×n（第 i 列がサンプル i のスコア）
Xnew = np.array([[0.0, 1.0], [0.0, 0.0]])          # Xnew も d×2
ref = KernelPCA(n_components=k, kernel="rbf", gamma=1/(2*sigma**2))
# sklearn は n×d 規約なので転置して渡す（戻り値は n×k なので比較時に転置）
print("scores  :", np.allclose(np.abs(Z), np.abs(ref.fit_transform(X.T).T)))
print("variance:", np.allclose((Z**2).sum(1), lam))    # 行ごとの二乗和 = mu_j
print("test    :", np.allclose(np.abs(kpca_transform(Xnew, X, K, A, sigma).T),
                              np.abs(ref.transform(Xnew.T).T)))
```

出力は三行とも `True` である。二行目は $\sum_i z_{ij}^2 = \mu_j$ の確認で、これが通れば正規化 (8.7) が正しい。`sklearn` の `gamma` は $\exp(-\gamma\|\boldsymbol{x} - \boldsymbol{y}\|^2)$ の γ で $\gamma = 1/(2\sigma^2)$、一致は符号を除いてである（固有ベクトルの符号は不定）。

図 8.1 が典型的な結果で、特徴空間での線形な操作が入力空間では非線形に見えるというカーネル法の本質がここに現れている。

8.3.2　帯域幅の効き方

ガウスカーネルの帯域幅 σ は結果を左右する最重要のパラメータである（図 8.2）。

$\sigma \to 0$（**過小**）　$i \neq j$ で $k(\boldsymbol{x}_i, \boldsymbol{x}_j) \to 0$、$k(\boldsymbol{x}_i, \boldsymbol{x}_i) = 1$ なので $\boldsymbol{K} \to \boldsymbol{I}_n$、$\widetilde{\boldsymbol{K}} \to \boldsymbol{H}$。$\boldsymbol{H}$ の固有値は 1（重複度 $n-1$）と 0 だから上位固有値が縮退し主成分に順序がつかない。全点が特徴空間で互いに直交した単位ベクトルになり、「どの点も他のどの点とも同じだけ遠い」無情報な配置に潰れる。

$\sigma \to \infty$（**過大**） $u = \|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2/(2\sigma^2) \to 0$ で $e^{-u} = 1 - u + O(u^2)$ より $K_{ij} = 1 - \|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2/(2\sigma^2) + O(\sigma^{-4})$。$\boldsymbol{H}$ で挟むと定数項が消え、$\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2 = \|\boldsymbol{x}_i\|^2 + \|\boldsymbol{x}_j\|^2 - 2\boldsymbol{x}_i^\top \boldsymbol{x}_j$ のうち $\|\boldsymbol{x}_i\|^2$ に依存する項も消える（第6章 の二重中心化と同じ計算）。残るのは $\boldsymbol{x}_i^\top \boldsymbol{x}_j$ を (i,j) 成分にもつ $n \times n$ 行列 $\boldsymbol{X}^\top \boldsymbol{X}$ を $\boldsymbol{H}$ で挟んだもの、すなわち

$$\widetilde{\boldsymbol{K}} = \sigma^{-2}\, \boldsymbol{H}\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{H} + O(\sigma^{-4}) = \sigma^{-2}\, \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}} + O(\sigma^{-4}) \qquad (\sigma \to \infty), \tag{8.8}$$

であり（$\boldsymbol{H}\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{H} = (\boldsymbol{X}\boldsymbol{H})^\top (\boldsymbol{X}\boldsymbol{H}) = \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$ を使った）、すなわちカーネル PCA は線形 PCA に漸近する。非線形性は $O(\sigma^{-4})$ の項にしか現れない。

適切な σ 実用的な出発点は**メディアンヒューリスティック**

$$\sigma_{\mathrm{med}} \coloneqq \mathrm{median}\{\|\boldsymbol{x}_i - \boldsymbol{x}_j\| : i < j\} \tag{8.9}$$

である。$k(\boldsymbol{x}_i, \boldsymbol{x}_j)$ が 0 にも 1 にも張り付かないことを保証する方策で、理論的な最適性はないが実務ではよく働く。より丁寧には下流タスクを基準に交差検証する。

8.3.3 逆像問題

射影した点は $\mathcal{H}$ の元だが、これを入力空間の点として見たい場面がある（ノイズ除去：ノイズを含む $\boldsymbol{x}$ を特徴空間で射影して戻す）。ところが $\phi(\mathcal{X})$ は $\mathcal{H}$ の中の曲がった低次元多様体にすぎないので、$\mathcal{H}$ の一般の元に**逆像**（pre-image、$\phi(\boldsymbol{z}) = \Psi$ を満たす $\boldsymbol{z}$）は存在しない。ガウスカーネルでは $\|\phi(\boldsymbol{x})\|_{\mathcal{H}}^2 = k(\boldsymbol{x},\boldsymbol{x}) = 1$ なので $\phi(\mathcal{X})$ は単位球面上にあるが、二点の中点 $\frac{1}{2}(\phi(\boldsymbol{x}_1) + \phi(\boldsymbol{x}_2))$ のノルムの二乗は $\frac{1+k(\boldsymbol{x}_1,\boldsymbol{x}_2)}{2} < 1$ で球面から外れている。中点ですら逆像をもたない。

そこで**近似逆像** $\boldsymbol{z}^\star = \arg\min_{\boldsymbol{z}} \|\phi(\boldsymbol{z}) - \Psi\|_{\mathcal{H}}^2$ を求める。$\Psi = \sum_i \gamma_i \phi(\boldsymbol{x}_i)$ のとき目的関数は $k(\boldsymbol{z},\boldsymbol{z}) - 2\sum_i \gamma_i k(\boldsymbol{z},\boldsymbol{x}_i) + \mathrm{const}$ で、ガウスカーネルでは $k(\boldsymbol{z},\boldsymbol{z}) = 1$ が定数なので $\max_{\boldsymbol{z}} \sum_i \gamma_i k(\boldsymbol{z},\boldsymbol{x}_i)$ に帰着し、停留条件 $\nabla_{\boldsymbol{z}} \sum_i \gamma_i e^{-\|\boldsymbol{z}-\boldsymbol{x}_i\|^2/(2\sigma^2)} = \boldsymbol{0}$ を整理すると

$$\boldsymbol{z} = \frac{\sum_i \gamma_i \exp\!\big(-\|\boldsymbol{z} - \boldsymbol{x}_i\|^2/(2\sigma^2)\big)\, \boldsymbol{x}_i}{\sum_i \gamma_i \exp\!\big(-\|\boldsymbol{z} - \boldsymbol{x}_i\|^2/(2\sigma^2)\big)} \tag{8.10}$$

という不動点方程式を得る。右辺は「訓練点の重み付き平均、重みは現在の $\boldsymbol{z}$ への近さと γ_i の積」という形で、平均シフト法と同じ構造である。右辺に代入し直す反復（Mika らの固定点反復）が標準的だが、非凸問題の停留条件なので局所解に落ちる（初期値には元の点 $\boldsymbol{x}$ を使う）。手書き数字にガウスノイズを載せたデータでこれを行うと線形 PCA による除去よりも数字の形が保たれる。線形 PCA の主部分空間が線形なのに対し、カーネル PCA のそれは入力空間では曲がった多様体に対応するためである。

8.3.4 計算量と、カーネル PCA は一般化された MDS であること

Gram 行列の構成に $O(n^2)$ 回のカーネル評価とメモリ $O(n^2)$、固有分解に $O(n^3)$ を要する。上位 k 成分だけなら Lanczos 法で $O(n^2 k)$ に落ちるが $O(n^2)$ のメモリは変わらない。$n = 10^5$ なら $\boldsymbol{K}$ は倍精度で 80 GB であり素直な実装は破綻する（8.10節）。

命題 8.10 （双対 PCA・古典的 MDS との関係）**.** (i) **線形カーネル** $k(\boldsymbol{x},\boldsymbol{y}) = \boldsymbol{x}^\top \boldsymbol{y}$ ならカーネル PCA は 第4章 の双対 PCA（すなわち通常の線形 PCA）に一致する。このときの特徴空間と特徴写像は

$$\mathcal{H} = \mathbb{R}^d \text{（標準内積）}, \qquad \phi = \mathrm{id},\ \text{すなわち } \phi(\boldsymbol{x}) = \boldsymbol{x} \tag{8.11}$$

であり、**特徴空間が入力空間そのもの**という退化した場合にあたる。(ii) $D_{ij} = \|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2$ から $\boldsymbol{B} = -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}\boldsymbol{H}$ を作る古典的 MDS （第6章）は、$\widetilde{\boldsymbol{K}} = \boldsymbol{B}$ を用いたカーネル PCA に一致する。

証明. (i) まず特徴写像について。$\phi = \mathrm{id}$ と取れば $\langle \phi(\boldsymbol{x}), \phi(\boldsymbol{y}) \rangle_{\mathbb{R}^d} = \boldsymbol{x}^\top \boldsymbol{y} = k(\boldsymbol{x},\boldsymbol{y})$ だから (8.11)は確かに k の特徴写像である（定義 7.35）。なお特徴写像は一意ではなく、たとえば任意の直交行列 $\boldsymbol{R}$ に対し $\phi(\boldsymbol{x}) = \boldsymbol{R}\boldsymbol{x}$ も、$\phi(\boldsymbol{x}) = (\boldsymbol{x}, 0)$ という $\mathbb{R}^{d+1}$ の原点を通る超平面への埋め込みも同じ k を与える。Moore–Aronszajn の構成（定理 7.32）が与える標準的な RKHS は $\mathcal{H}_k = \{f_{\boldsymbol{a}}(\boldsymbol{x}) = \boldsymbol{a}^\top \boldsymbol{x} : \boldsymbol{a} \in \mathbb{R}^d\}$——$\mathbb{R}^d$ 上の線形関数の全体で、$\|f_{\boldsymbol{a}}\|_{\mathcal{H}_k} = \|\boldsymbol{a}\|$——であり、$\boldsymbol{a} \leftrightarrow f_{\boldsymbol{a}}$ で $\mathbb{R}^d$ と等長同型である。この意味で(8.11)を代表に取ってよい。

Gram 行列は $K_{ij} = \boldsymbol{x}_i^\top \boldsymbol{x}_j$、すなわち $\boldsymbol{K} = \boldsymbol{X}^\top \boldsymbol{X}$（$n \times n$）である。よって $\widetilde{\boldsymbol{K}} = \boldsymbol{H}\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{H} = (\boldsymbol{X}\boldsymbol{H})^\top (\boldsymbol{X}\boldsymbol{H}) = \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$（$\boldsymbol{H}$ が対称べき等で、$\boldsymbol{X}\boldsymbol{H}$ が中心化データ行列 $\widetilde{\boldsymbol{X}} \in \mathbb{R}^{d \times n}$ であることによる）。これは (8.2) の左辺である。

(ii) $\boldsymbol{d} \coloneqq (\|\boldsymbol{x}_1\|^2, \dots, \|\boldsymbol{x}_n\|^2)^\top$ とすると $\boldsymbol{D} = \boldsymbol{d}\boldsymbol{1}^\top + \boldsymbol{1}\boldsymbol{d}^\top - 2\boldsymbol{X}^\top \boldsymbol{X}$。$\boldsymbol{H}\boldsymbol{1} = \boldsymbol{0}$ より $\boldsymbol{H}(\boldsymbol{d}\boldsymbol{1}^\top)\boldsymbol{H} = (\boldsymbol{H}\boldsymbol{d})(\boldsymbol{1}^\top \boldsymbol{H}) = \boldsymbol{0}$、同様に $\boldsymbol{H}(\boldsymbol{1}\boldsymbol{d}^\top)\boldsymbol{H} = \boldsymbol{0}$ だから $\boldsymbol{B} = -\frac{1}{2}\boldsymbol{H}(-2\boldsymbol{X}^\top \boldsymbol{X})\boldsymbol{H} = \widetilde{\boldsymbol{X}}^\top \widetilde{\boldsymbol{X}}$ となり (i) の $\widetilde{\boldsymbol{K}}$ に等しい。より一般に、任意の正定値カーネルから作った $\widetilde{\boldsymbol{K}} = \boldsymbol{H}\boldsymbol{K}\boldsymbol{H}$ の固有分解は、カーネルが定める距離 $d_k(\boldsymbol{x},\boldsymbol{y})^2 = k(\boldsymbol{x},\boldsymbol{x}) - 2k(\boldsymbol{x},\boldsymbol{y}) + k(\boldsymbol{y},\boldsymbol{y})$ に基づく MDS を与える。 ■

注意 8.11 (線形カーネルのとき主成分方向はどこにあるか)**.** (i) で得た $\boldsymbol{G} \coloneqq \widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}} = \widetilde{\boldsymbol{K}}$（$n \times n$）は第4章 の双対 PCA の Gram 行列そのものである。$\widetilde{\boldsymbol{X}} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$（$\boldsymbol{U} \in \mathbb{R}^{d\times r}$ が変数側、$\boldsymbol{V} \in \mathbb{R}^{n\times r}$ がサンプル側）とすれば $\boldsymbol{G} = \boldsymbol{V}\boldsymbol{\Sigma}^2\boldsymbol{V}^{\top}$ だから、$\boldsymbol{G}$ の固有ベクトルは**サンプル側の** $\boldsymbol{v}_j \in \mathbb{R}^n$ であり、主成分方向 $\boldsymbol{u}_j \in \mathbb{R}^d$ は $\boldsymbol{u}_j = \widetilde{\boldsymbol{X}}\boldsymbol{v}_j/\sigma_j$ で復元される。次元を数えれば $(d\times n)(n\times 1) = (d\times 1)$ で合う。一般のカーネルではこの復元式の $\widetilde{\boldsymbol{X}}$ を $\boldsymbol{\Phi}$（注意 7.37）に読み替えることになり、$\boldsymbol{\Phi}$ を陽に持たないので $\boldsymbol{u}_j$ 自体は書き下せない。書き下せるのは $\boldsymbol{v}_j$ の側、すなわち $\boldsymbol{\alpha}_j \propto \boldsymbol{v}_j$ だけである——これが定理 8.8で $\boldsymbol{\alpha}$ が主役になる理由である。

すなわちカーネル PCA、古典的 MDS、双対 PCA、(適切な重み付き Gram 行列なら) Isomap やラプラシアン固有写像までもが「$n \times n$ の半正定値対称行列を作り、その上位固有ベクトルで埋め込む」同一の型に収まり、違いは行列の作り方だけである。これが第1章の枠組み (2) の一つの現れ方である。

8.4　無限次元から有限次元へ

定理 8.8で起きたことを振り返る。特徴空間 $\mathcal{H}$ が無限次元であっても、主成分方向は

$$\boldsymbol{v} \in \operatorname{span}\{\tilde{\phi}(\boldsymbol{x}_1), \dots, \tilde{\phi}(\boldsymbol{x}_n)\} \tag{8.12}$$

に取ることができ、したがって

$$\boldsymbol{v} = \sum_{i=1}^{n} \alpha_i \tilde{\phi}(\boldsymbol{x}_i) \tag{8.13}$$

と**有限個の係数** $\boldsymbol{\alpha} \in \mathbb{R}^n$ で表せた。無限次元の固有値問題が $n \times n$ 行列の固有値問題 (8.6) になったのはこのためである。

この現象はカーネル PCA に特有ではない。RKHS 上の広いクラスの**正則化つき最適化問題**でも、最適解は訓練データに対応する n 個のカーネル関数の線形結合 $f^{\star} = \sum_i \alpha_i k(\cdot, \boldsymbol{x}_i)$ として表される。それを保証するのが次節の **表現定理**である。

ただし**有限次元化が起こる理由は二つで別物**なので、区別しておきたい。

- カーネル PCA（定理 8.8）では、共分散作用素 $\boldsymbol{C}$ が $\tilde{\phi}(\boldsymbol{x}_i)$ たちの外積の和であることから、$\lambda\boldsymbol{v} = \boldsymbol{C}\boldsymbol{v}$ の右辺が自動的に $\operatorname{span}\{\tilde{\phi}(\boldsymbol{x}_i)\}$ に入る。**作用素の形**から出る帰結であり、罰則も損失も関係しない。
- 表現定理（次節）では、損失が f の値 $f(\boldsymbol{x}_1), \dots, f(\boldsymbol{x}_n)$ にしか依存せず、罰則が $\|f\|_{\mathcal{H}}$ の単調増加関数であることから、$\operatorname{span}\{k(\cdot, \boldsymbol{x}_i)\}$ に直交する成分が「損失を変えずに罰則だけを増やす無駄」になる。**目的関数の形**から出る帰結である。

結論の形——n 個の係数で閉じる——が同じなので同じ定理の系のように見えるが、カーネル PCA は表現定理を使わずに導けている。以降はこの「有限次元化」を一般原理として押さえ、カーネルリッジ回帰（8.6節）とサポートベクターマシン（第9章）に適用していく。

8.5　表現定理

前節で予告した一般原理を述べる。RKHS $\mathcal{H}$ は典型的に無限次元であり、その上での最小化は素朴には無限個の自由度を動かすことになる。ところが目的関数を眺めると、損失項は f の値 $f(\boldsymbol{x}_1), \dots, f(\boldsymbol{x}_n)$ という n 個の数にしか依存せず、再生性 $f(\boldsymbol{x}_i) = \langle f, k(\cdot, \boldsymbol{x}_i)\rangle_{\mathcal{H}}$（第7章）によりこれは f の $\operatorname{span}\{k(\cdot, \boldsymbol{x}_i)\}$ 成分だけで決まる。一方、罰則項はこの部分空間に直交する成分があればその分だけ大きくなる。すなわち直交成分は「損失を変えず罰則だけを増やす」無駄であり、最適解では消えているはずである。これが表現定理の全内容である。

定理 8.12 (表現定理, representer theorem)**.** k を $\mathcal{X}$ 上の正定値カーネル、$\mathcal{H}$ をその RKHS、データ $(\boldsymbol{x}_i, y_i)_{i=1}^n$ を固定する。任意の関数 $L : (\mathcal{X}\times\mathbb{R}\times\mathbb{R})^n \to \mathbb{R}\cup\{+\infty\}$ と狭義単調増加な $\Omega : [0,\infty) \to \mathbb{R}$ に対し、

$$\min_{f\in\mathcal{H}} J(f), \quad J(f) \coloneqq L\big((\boldsymbol{x}_i, y_i, f(\boldsymbol{x}_i))_{i=1}^n\big) + \Omega\big(\|f\|_{\mathcal{H}}\big) \tag{8.14}$$

が最小解をもつならば、**すべての**最小解は

$$f^{\star} = \sum_{i=1}^{n} \alpha_i\, k(\cdot, \boldsymbol{x}_i), \qquad \alpha_i \in \mathbb{R} \tag{8.15}$$

の形をとる。Ω が広義単調増加にすぎない場合は、この形の最小解が少なくとも一つ存在する。

証明. $\mathcal{H}_n \coloneqq \operatorname{span}\{k(\cdot, \boldsymbol{x}_1), \dots, k(\cdot, \boldsymbol{x}_n)\}$ は高々 n 次元、したがって閉部分空間なので直交分解 $\mathcal{H} = \mathcal{H}_n \oplus \mathcal{H}_n^{\perp}$ が成り立ち、任意の f は $f = f_{\parallel} + f_{\perp}$（$f_{\parallel} = \sum_i \alpha_i k(\cdot, \boldsymbol{x}_i) \in \mathcal{H}_n$, $f_{\perp} \in \mathcal{H}_n^{\perp}$）と一意に分解される。

第一段（損失項は $f_{\perp}$ に依存しない）. 再生性より $f(\boldsymbol{x}_j) = \langle f, k(\cdot, \boldsymbol{x}_j)\rangle = \langle f_{\parallel}, k(\cdot, \boldsymbol{x}_j)\rangle + \langle f_{\perp}, k(\cdot, \boldsymbol{x}_j)\rangle$ で、$k(\cdot, \boldsymbol{x}_j) \in \mathcal{H}_n$ かつ $f_{\perp} \in \mathcal{H}_n^{\perp}$ なので第二項は 0、$f(\boldsymbol{x}_j) = f_{\parallel}(\boldsymbol{x}_j)$ $(j = 1, \dots, n)$。L は f を $(f(\boldsymbol{x}_j))_j$ を通してしか見ないので、L の値は f と $f_{\parallel}$ で一致する。

第二段（罰則項は真に増える）． 直交性とピタゴラスの定理より $\|f\|_{\mathcal{H}}^2 = \|f_\parallel\|_{\mathcal{H}}^2 + \|f_\perp\|_{\mathcal{H}}^2 \geq \|f_\parallel\|_{\mathcal{H}}^2$ で等号成立は $f_\perp = 0$ に限るから、Ω が狭義単調増加なら $f_\perp \neq 0$ のとき $\Omega(\|f\|_{\mathcal{H}}) > \Omega(\|f_\parallel\|_{\mathcal{H}})$ が狭義に成り立つ。

第三段（結論）． 両段より任意の f について $J(f) \geq J(f_\parallel)$。$f^\star$ を最小解とすると $J(f^\star) \geq J(f_\parallel^\star)$ かつ最小性から $J(f^\star) \leq J(f_\parallel^\star)$、よって $f_\parallel^\star$ も最小解であり (8.15) の形の最小解が存在する。さらに Ω が狭義単調増加のとき $f_\perp^\star \neq 0$ を仮定すると第二段から $J(f^\star) > J(f_\parallel^\star)$ となり最小性に矛盾するので $f_\perp^\star = 0$。 ■

表現定理の意味

無限次元の問題 (8.14) が n 個の実数 $\boldsymbol{\alpha} \in \mathbb{R}^n$ の問題に**厳密に**帰着する。実際 $f = \sum_i \alpha_i k(\cdot, \boldsymbol{x}_i)$ を代入すると $f(\boldsymbol{x}_j) = (\boldsymbol{K}\boldsymbol{\alpha})_j$、$\|f\|_{\mathcal{H}}^2 = \sum_{i,j} \alpha_i \alpha_j k(\boldsymbol{x}_i, \boldsymbol{x}_j) = \boldsymbol{\alpha}^\top \boldsymbol{K}\boldsymbol{\alpha}$ となり、問題は $\min_{\boldsymbol{\alpha}\in\mathbb{R}^n} L\big((\boldsymbol{K}\boldsymbol{\alpha})_j\big) + \Omega(\sqrt{\boldsymbol{\alpha}^\top \boldsymbol{K}\boldsymbol{\alpha}})$ という n 変数問題になる。これがカーネル法の心臓部である。

例 8.13 ($\|f\|_{\mathcal{H}}^2 = \boldsymbol{\alpha}^\top \boldsymbol{K}\boldsymbol{\alpha}$ の確認)**．** $k(x,y) = e^{-(x-y)^2/2}$、$x_1 = 0, x_2 = 1$ なら $k(0,1) = e^{-1/2} = 0.6065$、$\boldsymbol{K} = \left(\begin{smallmatrix} 1 & 0.6065 \\ 0.6065 & 1 \end{smallmatrix}\right)$。$f = \alpha_1 k(\cdot,0) + \alpha_2 k(\cdot,1)$ のノルムは再生性を双線形に展開して $\|f\|_{\mathcal{H}}^2 = \alpha_1^2 + 1.213\alpha_1\alpha_2 + \alpha_2^2$ で、$\boldsymbol{\alpha} = (1,1)^\top$ なら 3.213、$\boldsymbol{\alpha} = (1,-1)^\top$ なら 0.787 である。

損失 L は凸である必要も連続である必要すらない。この一般性のおかげで、カーネルリッジ回帰（二乗損失、$\Omega(t) = \lambda t^2$；8.6節）、サポートベクターマシン（ヒンジ損失；第9章 の出発点）、カーネルロジスティック回帰などが同じ定理の系になる。

一般化を三つ挙げる。**半パラメトリック版**：罰則を課さない有限次元の関数系 $\psi_1, \dots, \psi_p$ を用意し $f = h + \sum_l \beta_l \psi_l$ ($h \in \mathcal{H}$) として $L + \Omega(\|h\|_{\mathcal{H}})$ を最小化すると、$(\psi_l(\boldsymbol{x}_i))_{il}$ が階数 p をもてば最小解は $f^\star = \sum_i \alpha_i k(\cdot, \boldsymbol{x}_i) + \sum_l \beta_l \psi_l$ の形をとる（証明は h を分解するだけ）。$p = 1, \psi_1 \equiv 1$ が「罰則なしバイアス項」である。**ベクトル値の場合**：出力が $\mathbb{R}^m$ なら行列値カーネル $K : \mathcal{X} \times \mathcal{X} \to \mathbb{R}^{m\times m}$ を考え $f^\star = \sum_i K(\cdot, \boldsymbol{x}_i)\boldsymbol{\alpha}_i$ に一般化される。**罰則の形**：Ω が $\|f_\perp\|$ の単調増加関数なら同じ議論が通るが、この単調性が破れる罰則（$\mathcal{H}$ 上の L^1 型など）では表現定理は一般に成り立たない。「n 項で閉じる」性質は内積構造と罰則の整合性に依存している。

表現定理は「よい解」を保証しない

定理が言うのは解の**形**だけであり、その解が汎化するとは言っていない。$\lambda \to 0$ とすれば $\boldsymbol{\alpha} = \boldsymbol{K}^{-1}\boldsymbol{y}$ が訓練データを完全に補間するが、これは典型的な過学習である。この点は 8.7節 で決定的な形で現れる。

8.6　カーネルリッジ回帰

表現定理の最も単純な応用が二乗損失＋二乗ノルム罰則の場合である。$\Omega(t) = \lambda t^2$ は狭義単調増加なので 定理 8.12 が使える。以下この手法を**カーネルリッジ回帰**（kernel ridge regression）と呼び、慣例に従い **KRR** と略記する。

定理 8.14 (カーネルリッジ回帰)**．** $\min_{f\in\mathcal{H}} \frac{1}{n}\sum_i (y_i - f(\boldsymbol{x}_i))^2 + \lambda\|f\|_{\mathcal{H}}^2$（$\lambda > 0$）の解は一意で、

$$f^\star = \sum_i \alpha_i k(\cdot, \boldsymbol{x}_i), \qquad \boldsymbol{\alpha} = (\boldsymbol{K} + n\lambda \boldsymbol{I}_n)^{-1}\boldsymbol{y}, \tag{8.16}$$

新しい点での予測は $f^\star(\boldsymbol{x}_*) = \boldsymbol{k}_*^\top \boldsymbol{\alpha}$ である。

証明． 表現定理より $f = \sum_i \alpha_i k(\cdot, \boldsymbol{x}_i)$ と置いてよく、このとき $J(\boldsymbol{\alpha}) = \frac{1}{n}\|\boldsymbol{y} - \boldsymbol{K}\boldsymbol{\alpha}\|^2 + \lambda \boldsymbol{\alpha}^\top \boldsymbol{K}\boldsymbol{\alpha}$。勾配は

$$\nabla J(\boldsymbol{\alpha}) = -\tfrac{2}{n}\boldsymbol{K}(\boldsymbol{y} - \boldsymbol{K}\boldsymbol{\alpha}) + 2\lambda \boldsymbol{K}\boldsymbol{\alpha} = \tfrac{2}{n}\boldsymbol{K}\big((\boldsymbol{K} + n\lambda \boldsymbol{I})\boldsymbol{\alpha} - \boldsymbol{y}\big),$$

$\boldsymbol{K}$ が半正定値なので J は凸であり $\nabla J = \boldsymbol{0}$ が最適性の必要十分条件で、$\lambda > 0$ より $\boldsymbol{K} + n\lambda \boldsymbol{I}$ は正定値ゆえ可逆、(8.16) はこれを満たす。$\boldsymbol{K}$ が特異なとき $\boldsymbol{\alpha}$ は一意でないが、二つの解の差は $\operatorname{Ker}\boldsymbol{K}$ に属し対応する関数の差のノルムは $(\boldsymbol{\alpha} - \boldsymbol{\alpha}')^\top \boldsymbol{K}(\boldsymbol{\alpha} - \boldsymbol{\alpha}') = 0$、すなわち**関数としては**同一で $f^\star$ は一意である。 ■

例 8.15 ($n = 2$ の手計算)**．** 例 8.13 の設定で $\boldsymbol{y} = (0,1)^\top$、$\lambda = 0.1$ とすると $n\lambda = 0.2$、$\boldsymbol{K} + 0.2\boldsymbol{I} = \left(\begin{smallmatrix} 1.2 & 0.6065 \\ 0.6065 & 1.2 \end{smallmatrix}\right)$ を解いて $\boldsymbol{\alpha} = (-0.5657, 1.1193)^\top$。訓練点での予測値は $\boldsymbol{K}\boldsymbol{\alpha} = (0.1131, 0.7761)^\top$ で観測値 $(0,1)$ に一致していない——正則化による縮小である。中間点では $f(0.5) = e^{-1/8}(-0.5657 + 1.1193) = 0.4885$ となめらかに補間される。$\lambda \to 0$ では $\boldsymbol{\alpha} \to \boldsymbol{K}^{-1}\boldsymbol{y} = (-0.9527, 1.5778)^\top$、$\boldsymbol{K}\boldsymbol{\alpha} = (0,1)^\top$ で完全補間になる。

8.6.1　リッジ回帰の SVD 表示との対応

第2章 の線形リッジ回帰は $\min_{\boldsymbol{w}} \frac{1}{n}\|\boldsymbol{y}-\boldsymbol{X}^\top\boldsymbol{w}\|^2+\lambda\|\boldsymbol{w}\|^2$、解は $\boldsymbol{w}=(\boldsymbol{X}\boldsymbol{X}^\top+n\lambda\boldsymbol{I}_d)^{-1}\boldsymbol{X}\boldsymbol{y}$ である（$\boldsymbol{X}\in\mathbb{R}^{d\times n}$ なので $\boldsymbol{X}\boldsymbol{X}^\top$ が $d\times d$、$\boldsymbol{X}\boldsymbol{y}$ が d 次ベクトルで次元が合う）。$\boldsymbol{X}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$（$\boldsymbol{U}\in\mathbb{R}^{d\times r}$ が変数側、$\boldsymbol{V}\in\mathbb{R}^{n\times r}$ がサンプル側）を代入して整理すると、予測値 $\hat{\boldsymbol{y}}=\boldsymbol{X}^\top\boldsymbol{w}$ は**サンプル側**の特異ベクトルで $\hat{\boldsymbol{y}}=\sum_i \frac{\sigma_i^2}{\sigma_i^2+n\lambda}\boldsymbol{v}_i\boldsymbol{v}_i^\top\boldsymbol{y}$ と書ける。係数は **フィルタ因子**と呼ばれ、σ_i が大きい（データがよく張っている）方向はそのまま通し、小さい方向は抑える。カーネルリッジ回帰でも $\boldsymbol{K}=\sum_i \mu_i\boldsymbol{u}_i\boldsymbol{u}_i^\top$ と固有分解すると

$$\hat{\boldsymbol{y}}=\boldsymbol{K}(\boldsymbol{K}+n\lambda\boldsymbol{I})^{-1}\boldsymbol{y}=\sum_{i=1}^{n}\frac{\mu_i}{\mu_i+n\lambda}\,\boldsymbol{u}_i\boldsymbol{u}_i^\top\boldsymbol{y}. \tag{8.17}$$

$\sigma_i^2\leftrightarrow\mu_i$ の対応で完全に同じ形である。偶然ではなく、線形カーネルなら $\boldsymbol{K}=\boldsymbol{X}^\top\boldsymbol{X}=\boldsymbol{V}\boldsymbol{\Sigma}^2\boldsymbol{V}^\top$ なので $\mu_i=\sigma_i^2$、しかも $\boldsymbol{K}$ の固有ベクトル $\boldsymbol{u}_i$ はサンプル側の特異ベクトル $\boldsymbol{v}_i$ そのものであり、両者は文字どおり一致する（$\boldsymbol{K}$ は $n\times n$ なのでその固有ベクトルはつねに $\mathbb{R}^n$ の元、すなわち **サンプル側**に住む。変数側の $\boldsymbol{U}$ は $\boldsymbol{K}$ には現れない）。$\boldsymbol{K}$ の固有ベクトルは（中心化すれば）カーネル PCA の $\boldsymbol{\alpha}_j$ の方向、すなわち主成分**スコア**を与える係数であり、μ_i が大きい成分ほど「データがよく説明できる滑らかな方向」である。カーネルリッジ回帰は $\boldsymbol{y}$ をこの基底で展開し、μ_i の小さい高周波成分を $\frac{\mu_i}{\mu_i+n\lambda}$ 倍に減衰させる。実効自由度は

$$\mathrm{df}(\lambda)\coloneqq\operatorname{tr}\left[\boldsymbol{K}(\boldsymbol{K}+n\lambda\boldsymbol{I})^{-1}\right]=\sum_{i}\frac{\mu_i}{\mu_i+n\lambda} \tag{8.18}$$

で測られ、$\lambda\to 0$ で $\operatorname{rank}\boldsymbol{K}$、$\lambda\to\infty$ で 0 に近づく。

この減衰の効き方は適合曲線に直接現れる。図 8.3は λ を変えたときのカーネルリッジ回帰の適合を並べたもので、λ が小さいと観測点を通ろうとして激しく振動し（過学習）、大きいと平坦化して真の関数から離れる（過平滑化）。中間に最良の λ があり、それを選ぶ道具が命題 8.17の一個抜き交差検証である。

8.6.2　LOO 交差検証の閉形式

λ を選ぶには、第 i 点だけを取り除いて学習した予測子がその点をどれだけ当てられるかを見たい。記号を定めておく。

定義 8.16 (一個抜き予測子)**.** $i=1,\dots,n$ に対し、第 i 点を除いた $n-1$ 点で学習した解

$$f^{(-i)}\coloneqq\operatorname*{arg\,min}_{f\in\mathcal{H}}\ \frac{1}{n}\sum_{j\neq i}(y_j-f(\boldsymbol{x}_j))^2+\lambda\|f\|_{\mathcal{H}}^2 \tag{8.19}$$

を**一個抜き予測子**（leave-one-out predictor）という。上付きの $(-i)$ は「第 i 点を除く」を表す。このとき

$$\mathrm{CV}(\lambda)\coloneqq\frac{1}{n}\sum_{i=1}^{n}\left(y_i-f^{(-i)}(\boldsymbol{x}_i)\right)^2 \tag{8.20}$$

を**一個抜き交差検証誤差**（leave-one-out cross-validation error, LOO 誤差）という。

和の範囲と正則化の重みに注意

(8.19)の第一項は $\frac{1}{n-1}$ ではなく $\frac{1}{n}$ で、和の範囲だけを $j\neq i$ に狭めている。すなわち n 点で学習するときと**同じ** λ を同じ重みで課している。この規約のもとでのみ命題 8.17の閉形式が厳密に成り立つ（演習 8.5で数値的に確かめる）。

$\mathrm{CV}(\lambda)$ を素朴に計算すると n 回の学習が必要である。しかし線形平滑化子には閉形式がある。

命題 8.17 (LOO の閉形式)**.** $\boldsymbol{S}\coloneqq\boldsymbol{K}(\boldsymbol{K}+n\lambda\boldsymbol{I})^{-1}$（ハット行列、$\hat{\boldsymbol{y}}=\boldsymbol{S}\boldsymbol{y}$）とすると

$$\mathrm{CV}(\lambda)=\frac{1}{n}\sum_{i=1}^{n}\left(\frac{y_i-(\boldsymbol{S}\boldsymbol{y})_i}{1-S_{ii}}\right)^2. \tag{8.21}$$

ただし 1 点を抜いた問題の正則化行列は $n\lambda\boldsymbol{I}$ のままとし、抜いた後の標本数 $n-1$ で読み替えない。

LOO では「何を固定するか」を先に決める

本書は KRR を $\frac{1}{n}\sum_i(y_i-f(\boldsymbol{x}_i))^2+\lambda\|f\|_{\mathcal{H}}^2$ と定義したので、罰則の実質的な重みは総和形式に直すと $\gamma\coloneqq n\lambda$ である。(8.21)が計算しているのは γ **を固定した**一個抜きであって、λ を固定した一個抜きではない。後者なら 1 点抜いた問題の正則化行列は $(n-1)\lambda\boldsymbol{I}$ になり、値がずれる。

実測（$n=80$、$x_i \sim \mathrm{Unif}[-3,3]$、$f_0(x)=\sin 2x + 0.3x$、ノイズ $\mathcal{N}(0,0.2^2)$、σ はメディアン規準で 1.8256、$\lambda = 10^{-3}$）：

計算法	CV
(a) 閉形式(8.21)（$n\lambda$）	0.162093
(b) n 回の再学習（$n\lambda$ のまま）	0.162093
(c) n 回の再学習（$(n-1)\lambda$ に読み替え）	0.161124

(a) と (b) は 2×10^{-16} の差で一致し、(c) は 9.7×10^{-4} ずれる。証明の「y_i を予測値で置き換えた問題の最小解が $f^{(-i)}$ である」という一段が正則化項を動かさないことを要求するので、この規約は本質的である。

証明. まず、$\boldsymbol{y}$ の第 i 成分だけを $f^{(-i)}(\boldsymbol{x}_i)$ に取り替えたベクトル

$$\boldsymbol{y}^{(i)} \coloneqq \big(y_1,\dots,y_{i-1},\, f^{(-i)}(\boldsymbol{x}_i),\, y_{i+1},\dots,y_n\big)^\top \tag{8.22}$$

を考える。この $\boldsymbol{y}^{(i)}$ で学習すると $f^{(-i)}$ 自身が最小解になる（目的関数の第 i 項が $f^{(-i)}$ で 0 になり、他の項は第 i 点を除いた元の問題と同じだから）。$\boldsymbol{S}$ の第 i 行を $\boldsymbol{s}_i^\top$ と書くと線形性より

$$f^{(-i)}(\boldsymbol{x}_i) = \boldsymbol{s}_i^\top \boldsymbol{y}^{(i)} = \boldsymbol{s}_i^\top \boldsymbol{y} - S_{ii} y_i + S_{ii} f^{(-i)}(\boldsymbol{x}_i),$$

すなわち $(1-S_{ii}) f^{(-i)}(\boldsymbol{x}_i) = (\boldsymbol{S}\boldsymbol{y})_i - S_{ii} y_i$。両辺を y_i から引いて $(1-S_{ii})$ で割ると $y_i - f^{(-i)}(\boldsymbol{x}_i) = \frac{y_i - (\boldsymbol{S}\boldsymbol{y})_i}{1-S_{ii}}$ を得る。二乗して平均すれば (8.21)。 ■

$\boldsymbol{S} = \sum_i \frac{\mu_i}{\mu_i + n\lambda} \boldsymbol{u}_i \boldsymbol{u}_i^\top$ だから、λ のグリッド探索は固有分解 $O(n^3)$ 一回で済む。

図 8.4は実際に λ を振って LOO 誤差を計算した結果である。左図は二つのことを同時に示している。第一に、閉形式(8.21)の値は定義どおり n 回学習し直した値と（丸め誤差の水準で）一致する——命題 8.17の数値的な確認である。第二に、LOO 誤差の最小点が**テスト誤差の最小点と一致**している。訓練誤差は λ を小さくすればいくらでも下がる（ノイズ分散を割り込む）のでモデル選択には使えないが、LOO 誤差は λ が小さすぎる側でも増えるので最小点が内点に現れる。これが交差検証を使う理由である。

ただし一致は偶然に助けられている面もある。LOO 誤差は n 個の値の平均なのでそれ自身に標本誤差があり、λ^* の位置はデータの実現によって一桁程度動く。左図で最小点付近の曲線が平坦なのは幸いで、λ を一桁外してもテスト誤差はほとんど悪化しない（$\lambda = 10^{-2}$ でテスト誤差 0.0516、最小値 0.0489 に対して 5.5 % 増）。

リスト 8.2　カーネルリッジ回帰と LOO 誤差の閉形式（総当たりとの一致確認）

```python
import numpy as np
from sklearn.kernel_ridge import KernelRidge

rng = np.random.default_rng(0)
X = np.sort(rng.uniform(-3, 3, 60))[None, :]          # 1×60 (d=1, n=60)
y = np.sin(X[0]) + 0.1 * rng.normal(size=60)
n, sigma, lam = X.shape[1], 0.7, 1e-2
K = rbf(X, X, sigma)                                  # リスト 7.1 の rbf

alpha = np.linalg.solve(K + n*lam*np.eye(n), y)       # (8.16) の係数
ref = KernelRidge(alpha=n*lam, kernel="rbf",
                  gamma=1/(2*sigma**2)).fit(X.T, y)   # sklearn は n×d なので転置
print("alpha:", np.allclose(alpha, ref.dual_coef_))

S = K @ np.linalg.inv(K + n*lam*np.eye(n))            # ハット行列
loo = np.mean(((y - S @ y) / (1 - np.diag(S)))**2)    # 閉形式 LOO (8.21)
brute = np.mean([(y[i] - rbf(X[:, i:i+1], np.delete(X, i, 1), sigma)
                  @ np.linalg.solve(
                      rbf(np.delete(X, i, 1), np.delete(X, i, 1), sigma)
                      + n*lam*np.eye(n-1), np.delete(y, i)))[0]**2
                 for i in range(n)])
print("LOO closed=%.6f brute=%.6f" % (loo, brute))
```

出力は `alpha agree: True` と `LOO closed=0.012850 brute=0.012850` である。`KernelRidge` の `alpha` は本書の $n\lambda$ に対応する（損失を $\frac{1}{n}$ で割っていないため）。この約束の違いは実装でよく混乱する。

ガウス過程回帰との一致　f に平均 0・共分散関数 k のガウス過程を事前分布として置き、$y_i = f(\boldsymbol{x}_i) + \varepsilon_i$、$\varepsilon_i \sim \mathcal{N}(0,\tau^2)$ 独立とすると、事後平均は $\mathbb{E}[f(\boldsymbol{x}_*) \mid \text{データ}] = \boldsymbol{k}_*^\top (\boldsymbol{K} + \tau^2 \boldsymbol{I})^{-1} \boldsymbol{y}$ で与えられる（証明は多変量正規分布の条件付き分布の公式による。本書では扱わない）。$\tau^2 = n\lambda$ とおけばこれは (8.16) と完全に一致する。正則化の立場では λ は関数の複雑さへの罰則の重みだが、ベイズの立場では $\lambda = \tau^2/n$ は観測ノイズ対事前分散の比であり、ノイズが大きければデータを信用せず事前分布

($f \approx 0$) に近づける、と読める。二つは同じ計算だが、後者は予測の**不確かさ** $k(\boldsymbol{x}_*,\boldsymbol{x}_*) - \boldsymbol{k}_*^\top (\boldsymbol{K}+\tau^2\boldsymbol{I})^{-1}\boldsymbol{k}_*$ も与え、λ や σ を周辺尤度最大化で選ぶという別の道を開く点で豊かである。

8.7　カーネル CCA

第6章 の正準相関分析（canonical correlation analysis, CCA）は、対になったデータ $(\boldsymbol{x}_i,\boldsymbol{y}_i)_{i=1}^n$ に対し射影後の相関 $\rho = \boldsymbol{w}_x^\top \widehat{\boldsymbol{\Sigma}}_{xy}\boldsymbol{w}_y / \sqrt{\boldsymbol{w}_x^\top \widehat{\boldsymbol{\Sigma}}_{xx}\boldsymbol{w}_x}\sqrt{\boldsymbol{w}_y^\top \widehat{\boldsymbol{\Sigma}}_{yy}\boldsymbol{w}_y}$ を最大化する手法であった。カーネル化は表現定理の要領で行う。$f = \sum_i \alpha_i k_x(\cdot,\boldsymbol{x}_i)$、$g = \sum_i \beta_i k_y(\cdot,\boldsymbol{y}_i)$ と置けば $(f(\boldsymbol{x}_i))_i = \widetilde{\boldsymbol{K}}_x\boldsymbol{\alpha}$、$(g(\boldsymbol{y}_i))_i = \widetilde{\boldsymbol{K}}_y\boldsymbol{\beta}$ だから

$$\rho(\boldsymbol{\alpha},\boldsymbol{\beta}) = \frac{\boldsymbol{\alpha}^\top \widetilde{\boldsymbol{K}}_x \widetilde{\boldsymbol{K}}_y \boldsymbol{\beta}}{\sqrt{\boldsymbol{\alpha}^\top \widetilde{\boldsymbol{K}}_x^2 \boldsymbol{\alpha}}\sqrt{\boldsymbol{\beta}^\top \widetilde{\boldsymbol{K}}_y^2 \boldsymbol{\beta}}} \tag{8.23}$$

を最大化することになる。ところがこの素朴なカーネル化は破綻する。

命題 8.18 (正則化なしのカーネル CCA の退化)**.** $\widetilde{\boldsymbol{K}}_x, \widetilde{\boldsymbol{K}}_y$ がともに階数 $n-1$ で $\operatorname{Ker}\widetilde{\boldsymbol{K}}_x = \operatorname{Ker}\widetilde{\boldsymbol{K}}_y = \operatorname{span}\{\mathbf{1}\}$ ならば、(8.23) の最大値はデータの内容によらず 1 である。すなわち $\boldsymbol{x}$ と $\boldsymbol{y}$ が統計的に完全に独立でも正準相関は 1 になる。

この仮定は絵空事ではない。ガウスカーネルの Gram 行列は **標本点が互いに相異なれば**正定値（したがって正則）であり（命題 7.27）、そのとき $\widetilde{\boldsymbol{K}} = \boldsymbol{HKH}$ について $\boldsymbol{HKHv} = \mathbf{0} \Rightarrow (\boldsymbol{Hv})^\top \boldsymbol{K}(\boldsymbol{Hv}) = 0 \Rightarrow \boldsymbol{Hv} = \mathbf{0}$ だから $\operatorname{Ker}\widetilde{\boldsymbol{K}} = \operatorname{span}\{\mathbf{1}\}$、$\operatorname{rank}\widetilde{\boldsymbol{K}} = n-1$ がつねに成り立つ。実測でも、$n = 30, 60, 15$ の無作為データで $\boldsymbol{K}$ の最小固有値は 1.2×10^{-3}, 6.1×10^{-6}, 0.34 といずれも正、$\operatorname{rank}\widetilde{\boldsymbol{K}}$ はすべて $n-1$ である（たとえばちょうど 1 組の 2 点だけが一致し他が相異なる場合は $\boldsymbol{K}$ が退化して $\operatorname{rank}\widetilde{\boldsymbol{K}} = n-2$ となり、重複が増えればさらに落ちる）。

証明. $V \coloneqq \{\boldsymbol{v}\in\mathbb{R}^n : \mathbf{1}^\top\boldsymbol{v} = 0\}$（次元 $n-1$）とおくと、仮定より $\widetilde{\boldsymbol{K}}_x, \widetilde{\boldsymbol{K}}_y$ の V 上への制限は可逆である。任意の $\boldsymbol{v}\in V\setminus\{\mathbf{0}\}$ をとり $\boldsymbol{\alpha} \coloneqq (\widetilde{\boldsymbol{K}}_x|_V)^{-1}\boldsymbol{v}$、$\boldsymbol{\beta} \coloneqq (\widetilde{\boldsymbol{K}}_y|_V)^{-1}\boldsymbol{v}$ と定めると $\widetilde{\boldsymbol{K}}_x\boldsymbol{\alpha} = \boldsymbol{v}$、$\widetilde{\boldsymbol{K}}_y\boldsymbol{\beta} = \boldsymbol{v}$ である。このとき (8.23) の分子は $(\widetilde{\boldsymbol{K}}_x\boldsymbol{\alpha})^\top(\widetilde{\boldsymbol{K}}_y\boldsymbol{\beta}) = \|\boldsymbol{v}\|^2$、分母は $\|\widetilde{\boldsymbol{K}}_x\boldsymbol{\alpha}\|\cdot\|\widetilde{\boldsymbol{K}}_y\boldsymbol{\beta}\| = \|\boldsymbol{v}\|^2$ だから $\rho = 1$。Cauchy–Schwarz より $\rho \le 1$ なので、これが最大値である。 ∎

意味は明快である。$\widetilde{\boldsymbol{K}}_x\boldsymbol{\alpha}$ が V の任意のベクトルを取りうるとは、「$f\in\mathcal{H}_x$ を選ぶことで訓練点上の値 $(f(\boldsymbol{x}_i))_i$ を（総和 0 の制約を除いて）**何にでも**できる」ということで、g も同じ。だからあらかじめ $\boldsymbol{v}$ を決めて $f(\boldsymbol{x}_i) = g(\boldsymbol{y}_i) = v_i$ となるよう選べば、n 点上で二つの値は完全に一致し相関は 1 になる。これはデータの構造を何も反映せず、RKHS の表現力が n 点を任意に補間できるほど大きいことの帰結にすぎない。表現定理の直後に述べた警告の実例である。対処は分母に正則化を入れて f, g のノルムに罰則を課すことで、標準的には $\boldsymbol{\alpha}^\top\widetilde{\boldsymbol{K}}_x\boldsymbol{\alpha} = \|f\|^2$ に由来する項を足して

$$\rho_\kappa(\boldsymbol{\alpha},\boldsymbol{\beta}) = \frac{\boldsymbol{\alpha}^\top \widetilde{\boldsymbol{K}}_x \widetilde{\boldsymbol{K}}_y \boldsymbol{\beta}}{\sqrt{\boldsymbol{\alpha}^\top(\widetilde{\boldsymbol{K}}_x^2 + \kappa\widetilde{\boldsymbol{K}}_x)\boldsymbol{\alpha}}\,\sqrt{\boldsymbol{\beta}^\top(\widetilde{\boldsymbol{K}}_y^2 + \kappa\widetilde{\boldsymbol{K}}_y)\boldsymbol{\beta}}} \qquad (\kappa > 0) \tag{8.24}$$

を最大化する。「分散 $+\ \kappa\times$ 関数の複雑さ」で正規化した相関で、無理に補間する f は分母が大きくなって罰せられる。最適性条件は一般化固有値問題

$$\begin{pmatrix} \mathbf{0} & \widetilde{\boldsymbol{K}}_x\widetilde{\boldsymbol{K}}_y \\ \widetilde{\boldsymbol{K}}_y\widetilde{\boldsymbol{K}}_x & \mathbf{0} \end{pmatrix}\begin{pmatrix}\boldsymbol{\alpha}\\ \boldsymbol{\beta}\end{pmatrix} = \rho \begin{pmatrix} \widetilde{\boldsymbol{K}}_x^2 + \kappa\widetilde{\boldsymbol{K}}_x & \mathbf{0} \\ \mathbf{0} & \widetilde{\boldsymbol{K}}_y^2 + \kappa\widetilde{\boldsymbol{K}}_y \end{pmatrix}\begin{pmatrix}\boldsymbol{\alpha}\\ \boldsymbol{\beta}\end{pmatrix} \tag{8.25}$$

であり、第6章 の $\boldsymbol{Aw} = \lambda\boldsymbol{Bw}$ の形そのものである。

ただし $\kappa > 0$ を加えるだけでは $\boldsymbol{B}$ **側は正定値にならない**。実際 $\widetilde{\boldsymbol{K}}_x\mathbf{1} = \mathbf{0}$（注意 8.4）より

$$(\widetilde{\boldsymbol{K}}_x^2 + \kappa\widetilde{\boldsymbol{K}}_x)\mathbf{1} = \mathbf{0} \tag{8.26}$$

であり、右辺の行列は κ の値によらず $\mathbf{1}$ を固有値 0 の固有ベクトルにもつ。κ が効くのは $\mathbf{1}$ に直交する方向の**条件数**であって、$\mathbf{1}$ 方向の特異性はそのまま残る。そこで 命題 8.18 の証明で用いた

$$V \coloneqq \mathbf{1}^\perp = \{\boldsymbol{v}\in\mathbb{R}^n : \mathbf{1}^\top\boldsymbol{v} = 0\} \tag{8.27}$$

に問題を制限する。$\operatorname{rank}\widetilde{\boldsymbol{K}}_x = \operatorname{rank}\widetilde{\boldsymbol{K}}_y = n-1$、$\operatorname{Ker}\widetilde{\boldsymbol{K}}_x = \operatorname{Ker}\widetilde{\boldsymbol{K}}_y = \operatorname{span}\{\mathbf{1}\}$ の仮定の下で $\widetilde{\boldsymbol{K}}_x|_V, \widetilde{\boldsymbol{K}}_y|_V$ は正定値だから、V 上では $\widetilde{\boldsymbol{K}}_x^2 + \kappa\widetilde{\boldsymbol{K}}_x$ も正定値になる。$\boldsymbol{Q}\in\mathbb{R}^{n\times(n-1)}$ を V の正規直交基底（$\boldsymbol{Q}^\top\mathbf{1} = \mathbf{0}$、$\boldsymbol{Q}^\top\boldsymbol{Q} = \boldsymbol{I}_{n-1}$）として $\boldsymbol{\alpha} = \boldsymbol{Qa}$、$\boldsymbol{\beta} = \boldsymbol{Qb}$ と座標をとれば、解くべきものは

$$\begin{pmatrix} \mathbf{0} & \boldsymbol{Q}^\top\widetilde{\boldsymbol{K}}_x\widetilde{\boldsymbol{K}}_y\boldsymbol{Q} \\ \boldsymbol{Q}^\top\widetilde{\boldsymbol{K}}_y\widetilde{\boldsymbol{K}}_x\boldsymbol{Q} & \mathbf{0} \end{pmatrix}\begin{pmatrix}\boldsymbol{a}\\ \boldsymbol{b}\end{pmatrix} = \rho \begin{pmatrix} \boldsymbol{Q}^\top(\widetilde{\boldsymbol{K}}_x^2 + \kappa\widetilde{\boldsymbol{K}}_x)\boldsymbol{Q} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{Q}^\top(\widetilde{\boldsymbol{K}}_y^2 + \kappa\widetilde{\boldsymbol{K}}_y)\boldsymbol{Q} \end{pmatrix}\begin{pmatrix}\boldsymbol{a}\\ \boldsymbol{b}\end{pmatrix} \tag{8.28}$$

という $2(n-1)$ 次元の問題であり、こちらは $\boldsymbol{B}$ 側が正定値な標準的な一般化固有値問題である。$\mathbf{1}$ 方向を落としても失うものはない。$\boldsymbol{\alpha}$ の $\mathbf{1}$ 成分は $\widetilde{\boldsymbol{K}}_x\boldsymbol{\alpha}$ に寄与しないので、(8.24) の値をまったく変えないからである。

κ を足すだけでは特異性は消えない

$n=40$、$\boldsymbol{x}_i,\boldsymbol{y}_i\in\mathbb{R}^2$ を互いに独立な標準正規乱数、$\sigma=1$ のガウスカーネルで実測すると、$\|\widetilde{\boldsymbol{K}}_x\mathbf{1}\|=5.2\times10^{-15}$、$\operatorname{rank}\widetilde{\boldsymbol{K}}_x=\operatorname{rank}\widetilde{\boldsymbol{K}}_y=39=n-1$ である。$\kappa=10^{-3}$ として $\boldsymbol{B}_x:=\widetilde{\boldsymbol{K}}_x^2+\kappa\widetilde{\boldsymbol{K}}_x$ を作ると最小固有値は -9.0×10^{-17}（理論値 0 の丸め誤差）で、その固有ベクトルは $\mathbf{1}/\sqrt{n}$ に一致し（内積の絶対値 0.99999995）、$\|\boldsymbol{B}_x\mathbf{1}\|=1.6\times10^{-14}$ である。すなわち $\boldsymbol{B}_x$ は**正定値でない**。同じ $\boldsymbol{B}_x$ を $V=\mathbf{1}^\perp$ に制限した $\boldsymbol{Q}^\top\boldsymbol{B}_x\boldsymbol{Q}$ の最小固有値は $3.5\times10^{-13}>0$ であり、正定値になる（$\widetilde{\boldsymbol{K}}_x|_V$ の最小固有値が 3.5×10^{-10}、最大が 8.35 なので、$\kappa\lambda_{\min}$ の水準まで持ち上がっている）。実装上の帰結は次の三点である。(1) $\mathbb{R}^n$ 全体で (8.25) を `scipy.linalg.eigh(A, B)` に渡すと Cholesky 分解が失敗する（$\boldsymbol{B}$ が正定値でないため）。(2) 対処は $\boldsymbol{Q}$ をとって (8.28) を解くか、$\boldsymbol{B}$ の擬似逆を使うことである。どちらでも同じ ρ が得られる（上の設定で $\kappa=10^{-3},10^{-1},1$ に対し 0.9950, 0.8400, 0.5326 が両者で一致）。(3) 便宜的に $\boldsymbol{B}+\delta\boldsymbol{I}$（$\delta=10^{-10}$ 程度）で「安定化」する実装も同じ値を返すが、これは $\mathbf{1}$ 方向にだけ人工的な分母 δ を与えて対応する固有値を $\rho\approx0$ に追い出す細工である（上の設定では $\mathbf{1}$ 方向に対応する ρ が 10^{-6} 未満になる）。特異性の原因を理解した上での応急処置と割り切るべきで、本来は $\mathbf{1}$ 方向を除くのが筋である。

例 8.19 (κ の効き方)**.** $n=40$、$\boldsymbol{x}_i,\boldsymbol{y}_i\in\mathbb{R}^2$ を互いに独立な標準正規乱数として生成し（真の相関は 0）、$\sigma=1$ のガウスカーネルで (8.28) を $V=\mathbf{1}^\perp$ 上で解くと、第一正準相関は $\kappa=10^{-8}$ で 1.0000、10^{-4} で 0.9994、10^{-2} で 0.9656、0.1 で 0.8400、1 で 0.5326 となる。κ が小さいと独立なデータでも相関 1 が出ることが数値でも確認できる。κ は保留データでの相関を基準に交差検証で選ぶのが実務的である。

同じ退化は、分母に $\widetilde{\boldsymbol{K}}$ の逆が現れる手法すべてで起こる（カーネル FDA、カーネル PLS など）。一般に「一般化固有値問題 $\boldsymbol{A}\boldsymbol{w}=\lambda\boldsymbol{B}\boldsymbol{w}$ をカーネル化すると $\boldsymbol{B}$ が特異または悪条件になる」と覚えておけばよい。処方は二段構えで、まず $\boldsymbol{B}\to\boldsymbol{B}+\kappa\widetilde{\boldsymbol{K}}$ のように $\widetilde{\boldsymbol{K}}$ の像の上で条件数を改善し、次に中心化に由来する $\mathbf{1}$ 方向を除いて $V=\mathbf{1}^\perp$ 上で解く。前者だけでは (8.26) のとおり特異性が残る。

8.8　カーネル平均埋め込みと MMD

ここまでカーネル法は「点 $\boldsymbol{x}$ を $\phi(\boldsymbol{x})$ に写す」道具であったが、同じ道具で**確率分布**も $\mathcal{H}$ の点に写せる。

定義 8.20 (カーネル平均埋め込み)**.** $\mathcal{X}$ 上の確率分布 P に対し $\mu_P:=\mathbb{E}_{X\sim P}[k(\cdot,X)]\in\mathcal{H}$ を P の**カーネル平均埋め込み**（kernel mean embedding）と呼ぶ。$\mathbb{E}_{X\sim P}\sqrt{k(X,X)}<\infty$（有界カーネルなら自動）のとき Bochner 積分として well-defined である。

再生性から、任意の $f\in\mathcal{H}$ について $\langle f,\mu_P\rangle_{\mathcal{H}}=\mathbb{E}_{X\sim P}[\langle f,k(\cdot,X)\rangle_{\mathcal{H}}]=\mathbb{E}_{X\sim P}[f(X)]$（以後この式を再生性の分布版と呼ぶ）、すなわち μ_P は「$\mathcal{H}$ のすべての関数の期待値をまとめて保持する対象」である。線形カーネルなら $\mu_P=\mathbb{E}[X]$、多項式カーネル $(1+\boldsymbol{x}^\top\boldsymbol{y})^2$ なら 1 次と 2 次のモーメントを含む。豊かなカーネルほど多くの情報が入るが、その極限として $P\mapsto\mu_P$ が単射になるカーネルを**特性的**（characteristic）という。特性的なら μ_P は分布の完全な要約になる（特性関数の名の由来も同じ発想）。ガウスカーネルとラプラシアンカーネルは $\mathbb{R}^d$ 上で特性的である（証明には Bochner の定理とスペクトル測度の台が $\mathbb{R}^d$ 全体であることを使う。ここでは述べるにとどめる）。線形カーネルは特性的でない：平均が同じで分散が違う分布を区別できない。

定義 8.21 (最大平均不一致 [35])**.** $\mathrm{MMD}(P,Q):=\|\mu_P-\mu_Q\|_{\mathcal{H}}$ を**最大平均不一致**（maximum mean discrepancy, MMD）と呼ぶ。

名称の由来は変分表示である。$\|u\|_{\mathcal{H}}=\sup_{\|f\|\le1}\langle f,u\rangle$ と再生性の分布版より $\mathrm{MMD}(P,Q)=\sup_{\|f\|_{\mathcal{H}}\le1}\big(\mathbb{E}_{X\sim P}[f(X)]-\mathbb{E}_{Y\sim Q}[f(Y)]\big)$、すなわち「単位球内の関数で測ったときの期待値の差の最大値」である。k が特性的なら $\mathrm{MMD}(P,Q)=0\iff P=Q$ で距離になる。二乗を展開すると、$\langle\mu_P,\mu_Q\rangle=\mathbb{E}_{X\sim P,Y\sim Q}[k(X,Y)]$（再生性の分布版と Fubini）より

$$\mathrm{MMD}^2(P,Q)=\mathbb{E}_{X,X'\sim P}[k(X,X')]-2\mathbb{E}_{X\sim P,Y\sim Q}[k(X,Y)]+\mathbb{E}_{Y,Y'\sim Q}[k(Y,Y')]. \tag{8.29}$$

カーネルの評価だけで書けており ϕ も $\mathcal{H}$ も陽に現れない。標本 $\boldsymbol{x}_1,\dots,\boldsymbol{x}_n\sim P$、$\boldsymbol{y}_1,\dots,\boldsymbol{y}_m\sim Q$ から推定するには第一項と第三項で対角成分を除けば不偏推定量（U 統計量）になる：

$$\widehat{\mathrm{MMD}}_u^2=\frac{1}{n(n-1)}\sum_{i\neq j}k(\boldsymbol{x}_i,\boldsymbol{x}_j)+\frac{1}{m(m-1)}\sum_{i\neq j}k(\boldsymbol{y}_i,\boldsymbol{y}_j)-\frac{2}{nm}\sum_{i,j}k(\boldsymbol{x}_i,\boldsymbol{y}_j). \tag{8.30}$$

対角を含める版（V 統計量）は非負だが上向きのバイアスをもつ。U 統計量版は $P=Q$ のとき負の値もとりうる。

数値例を挙げる。$\mathcal{X}=\mathbb{R}$、$\sigma=1$、$n=m=200$ で $P=\mathcal{N}(0,1)$ から二組の標本をとると $\widehat{\mathrm{MMD}}_u^2=-6.8\times10^{-4}$（同分布なので 0 付近、$U$ 統計量なので負にもなる）。$Q=\mathcal{N}(0.5,1)$ に変えると 1.69×10^{-2} となり一桁以上大きい。

帰無仮説 $H_0: P=Q$ の下で $n\widehat{\mathrm{MMD}}_u^2$ は重み付き χ^2 の無限和という非標準的な分布に従うため、実務では**置換検定**を用いる。二標本を合併して無作為に n 個と m 個に分け直し (8.30) を再計算する操作を B 回繰り返し、実際の値を超える割合を p 値とする。分布に何の仮定も置かず $\mathcal{X}$ が $\mathbb{R}^d$ でなくてもよい点が強力で、分布シフトの検出や生成モデルの評価に用いられる。

同じ発想を二変数に適用すると独立性の尺度が得られる。同時分布 P_{XY} と周辺の積 $P_X \otimes P_Y$ の間の MMD（積カーネルを用いる）を **Hilbert–Schmidt 独立性規準**（Hilbert–Schmidt independence criterion, HSIC）[34] と呼ぶ。名前は、同じ量が相互共分散作用素の Hilbert–Schmidt ノルムの二乗としても書けることに由来する。k_x, k_y が特性的なら $\mathrm{HSIC}=0 \iff X \perp Y$ で、経験推定量は中心化 Gram 行列を用いて

$$\widehat{\mathrm{HSIC}} = \frac{1}{n^2}\operatorname{tr}\left(\widetilde{\boldsymbol{K}}_x \widetilde{\boldsymbol{K}}_y\right) = \frac{1}{n^2}\operatorname{tr}\left(\boldsymbol{K}_x \boldsymbol{H} \boldsymbol{K}_y \boldsymbol{H}\right) \tag{8.31}$$

と簡単に書ける。線形カーネルではこれは共分散のフロベニウスノルムの二乗になり「相関 0」しか検出できないが、特性的カーネルなら非線形な依存も捉えられる。また (8.31) には $\widetilde{\boldsymbol{K}}$ の**逆**が現れないので 命題 8.18 の退化が起きず、正則化なしで使える。実務で独立性を測るならカーネル CCA より HSIC が扱いやすい。

8.9　カーネルの選択と設計

カーネル法の性能はカーネルの選択でほぼ決まる。ガウスカーネルの σ はメディアンヒューリスティック (8.9) を出発点とし、教師あり学習なら交差検証を使う。カーネルリッジ回帰では LOO の閉形式 (8.21) により (σ, λ) の二次元グリッド探索も現実的である。教師なしでは基準が自明でないため、下流タスクの性能か、(8.9) を中心に数倍・数分の一の範囲で結果の安定性を見るのが実務的である。

正定値カーネルの集合は次の操作で閉じている（第7章）。k_1, k_2 が正定値なら (a) $c_1 k_1 + c_2 k_2$（$c_i \geq 0$、特徴写像は直和）、(b) 積 $k_1 k_2$（テンソル積）、(c) $\psi(\boldsymbol{x}) k(\boldsymbol{x}, \boldsymbol{y}) \psi(\boldsymbol{y})$、(d) $\exp(k_1)$ がいずれも正定値である。和は「どちらかが似ていれば似ている」（OR 的）、積は「両方似てはじめて似ている」（AND 的）挙動を与えるので、異種のデータは各属性のカーネルを和や積で結合すればよい。候補の重み付き和 $\sum_m \theta_m k_m$ の $\boldsymbol{\theta}$ を学習器と同時に最適化するのが多重カーネル学習（MKL）で、$\theta_m \geq 0, \sum_m \theta_m = 1$ の下では凸問題になるが、等重み和や交差検証による単純な選択に負けることも多い。

必要なのは正定値性だけでベクトル空間の構造はいらないので、$\mathcal{X}$ が $\mathbb{R}^d$ でなくてもよい。**文字列カーネル**（長さ p の全部分列を特徴とする。特徴数は素朴には $|\Sigma|^p$ だが動的計画法で $O(p|s||t|)$ で計算でき、カーネルトリックの威力の典型例。生物配列解析で広く使われる）、**グラフカーネル**（ランダムウォーク、最短経路、Weisfeiler–Lehman など、共有する部分構造を数える）、そして 8.8節 の平均埋め込みを使えば集合や分布を入力とするカーネルも作れる。

正定値性の確認を怠らない

「類似度らしきもの」が正定値とは限らない。シグモイドカーネル $\tanh(a\boldsymbol{x}^\top \boldsymbol{y} + b)$ は一般に正定値でなく、$\boldsymbol{K}$ が負の固有値をもつと (8.7) の $\sqrt{\mu}$ が計算できない。実装では $\boldsymbol{K}$ の最小固有値を必ず確認し、わずかに負（数値誤差レベル）なら $\boldsymbol{K} + \varepsilon \boldsymbol{I}$ で補正、大きく負なら定式化を見直す。

8.10　大規模化：$O(n^3)$ の壁を破る

ここまでの手法はすべて $n \times n$ 行列の構成（$O(n^2)$ メモリ）と分解（$O(n^3)$ 時間）を要し、$n = 10^6$ では手も足も出ない。回避策を二つ扱う。どちらも「$\boldsymbol{K}$ を低ランクで近似する」あるいは「ϕ を有限次元で近似する」という同じ目標に異なる道から到達する。

8.10.1　Nyström 近似

n 点のうち $m \ll n$ 個（**ランドマーク**、添字集合 I）を選び $\boldsymbol{K}_{mm} := \boldsymbol{K}[I, I]$、$\boldsymbol{K}_{nm} := \boldsymbol{K}[:, I]$ として

$$\boldsymbol{K} \approx \hat{\boldsymbol{K}} := \boldsymbol{K}_{nm} \boldsymbol{K}_{mm}^{+} \boldsymbol{K}_{mn} \tag{8.32}$$

と近似する（$^+$ は Moore–Penrose 擬似逆行列）。

命題 8.22 (Nyström 近似の基本性質)**.** $\hat{\boldsymbol{K}}$ は半正定値対称で $\operatorname{rank} \hat{\boldsymbol{K}} \leq m$。また (i) ランドマーク上では厳密（$\hat{\boldsymbol{K}}[I, I] = \boldsymbol{K}[I, I]$、$\hat{\boldsymbol{K}}[:, I] = \boldsymbol{K}[:, I]$）、(ii) $\operatorname{Im} \boldsymbol{K}[:, I] = \operatorname{Im} \boldsymbol{K}$（選んだランドマーク列が $\boldsymbol{K}$ の列空間を張る）なら $\hat{\boldsymbol{K}} = \boldsymbol{K}$、(iii) $\boldsymbol{L} := \boldsymbol{K}_{nm} (\boldsymbol{K}_{mm}^{1/2})^{+} \in \mathbb{R}^{n \times m}$ とおくと $\hat{\boldsymbol{K}} = \boldsymbol{L}\boldsymbol{L}^\top$、言い換えれば $\boldsymbol{\Phi}_{\mathrm{Ny}} := \boldsymbol{L}^\top \in \mathbb{R}^{m \times n}$ が**陽な**特徴行列（注意 7.37 の規約で列がサンプル）であり $\hat{\boldsymbol{K}} = \boldsymbol{\Phi}_{\mathrm{Ny}}^\top \boldsymbol{\Phi}_{\mathrm{Ny}}$、その第 i 列が点 $\boldsymbol{x}_i$ の m 次元特徴ベクトルである。

証明. $\boldsymbol{K}_{mm}$ は半正定値対称だから平方根がとれ、$\boldsymbol{K}_{mm}^{+} = (\boldsymbol{K}_{mm}^{1/2})^{+}(\boldsymbol{K}_{mm}^{1/2})^{+}$ より $\hat{\boldsymbol{K}} = \boldsymbol{L}\boldsymbol{L}^{\top} = \boldsymbol{\Phi}_{\mathrm{Ny}}^{\top}\boldsymbol{\Phi}_{\mathrm{Ny}}$ （これが (iii)）。よって半正定値かつ $\operatorname{rank}\hat{\boldsymbol{K}} \le m$。(i)：擬似逆行列の定義 $\boldsymbol{A}\boldsymbol{A}^{+}\boldsymbol{A} = \boldsymbol{A}$ より $\hat{\boldsymbol{K}}[I,I] = \boldsymbol{K}_{mm}\boldsymbol{K}_{mm}^{+}\boldsymbol{K}_{mm} = \boldsymbol{K}_{mm}$。また $\boldsymbol{K}_{mm}^{+}\boldsymbol{K}_{mm}$ は $\operatorname{Im}\boldsymbol{K}_{mm}$ への射影で、Gram 行列の構造から $\boldsymbol{K}_{nm}$ の各行は $\operatorname{Im}\boldsymbol{K}_{mm}$ に入るので $\hat{\boldsymbol{K}}[:,I] = \boldsymbol{K}_{nm}$。(ii)：$\boldsymbol{K}$ は半正定値だから $\boldsymbol{K} = \boldsymbol{\Phi}^{\top}\boldsymbol{\Phi}$（$\boldsymbol{\Phi} \in \mathbb{R}^{r\times n}$、$r = \operatorname{rank}\boldsymbol{K}$、列がサンプル）と書ける。$\boldsymbol{\Phi}_I \in \mathbb{R}^{r\times m}$ をランドマーク**列**を集めた部分行列とすると $\boldsymbol{K}_{nm} = \boldsymbol{\Phi}^{\top}\boldsymbol{\Phi}_I$、$\boldsymbol{K}_{mm} = \boldsymbol{\Phi}_I^{\top}\boldsymbol{\Phi}_I$ である。仮定 $\operatorname{Im}\boldsymbol{K}[:,I] = \operatorname{Im}\boldsymbol{K}$ は $\operatorname{rank}\boldsymbol{\Phi}_I = r$、すなわち $\boldsymbol{\Phi}_I$ の列が $\mathbb{R}^r$ を張ることと同値だから、$\boldsymbol{P} \coloneqq \boldsymbol{\Phi}_I(\boldsymbol{\Phi}_I^{\top}\boldsymbol{\Phi}_I)^{+}\boldsymbol{\Phi}_I^{\top}$ は $\mathbb{R}^r$ 全体への直交射影、つまり $\boldsymbol{P} = \boldsymbol{I}_r$ である。よって

$$\hat{\boldsymbol{K}} = \boldsymbol{K}_{nm}\boldsymbol{K}_{mm}^{+}\boldsymbol{K}_{nm}^{\top} = \boldsymbol{\Phi}^{\top}\boldsymbol{\Phi}_I(\boldsymbol{\Phi}_I^{\top}\boldsymbol{\Phi}_I)^{+}\boldsymbol{\Phi}_I^{\top}\boldsymbol{\Phi} = \boldsymbol{\Phi}^{\top}\boldsymbol{P}\,\boldsymbol{\Phi} = \boldsymbol{\Phi}^{\top}\boldsymbol{\Phi} = \boldsymbol{K}.$$

■

$\operatorname{rank}\boldsymbol{K} \le m$ だけでは足りない

(ii) の仮定を「$\operatorname{rank}\boldsymbol{K} \le m$」に弱めると**偽になる**。$n = 2$、$\boldsymbol{K} = \operatorname{diag}(0,1)$、$m = 1$ で第 1 点をランドマークに選ぶと $\operatorname{rank}\boldsymbol{K} = 1 \le m$ にもかかわらず $\boldsymbol{K}_{mm} = (0)$、$\boldsymbol{K}_{nm} = \boldsymbol{0}$ だから $\hat{\boldsymbol{K}} = \boldsymbol{0} \neq \boldsymbol{K}$ である。$\operatorname{rank}\boldsymbol{K} \le m$ は「m 本で張れる**可能性がある**」ことしか言っておらず、実際に選んだ m 本が張るかどうかは別問題である。この例で第 2 点を選べば $\operatorname{Im}\boldsymbol{K}[:,I] = \operatorname{Im}\boldsymbol{K}$ が成り立ち $\hat{\boldsymbol{K}} = \boldsymbol{K}$ となる。実務上これは「ランドマークの選び方が効く」ことの最も単純な現れであり、一様ランダム選択よりレバレッジスコアや k-means 中心を使う方法が提案されているのはこのためである（本節後半および 例 8.23）。

幾何的には、$\hat{\boldsymbol{K}}$ は $\phi(\boldsymbol{x}_i)$ を $\mathcal{V}_I \coloneqq \operatorname{span}\{\phi(\boldsymbol{x}_j) : j \in I\}$ に直交射影してから内積をとったものである。実際、P_I を $\mathcal{V}_I$ への直交射影とすると $\langle P_I\phi(\boldsymbol{x}_i), P_I\phi(\boldsymbol{x}_j)\rangle = \langle P_I\phi(\boldsymbol{x}_i), \phi(\boldsymbol{x}_j)\rangle$ であり、これは (8.32) の右辺の (i,j) 成分になる。したがって誤差は「射影で落ちる成分」であり、$\boldsymbol{K} - \hat{\boldsymbol{K}} \succeq \boldsymbol{0}$ かつ $\operatorname{tr}(\boldsymbol{K} - \hat{\boldsymbol{K}}) = \sum_i \|\phi(\boldsymbol{x}_i) - P_I\phi(\boldsymbol{x}_i)\|_{\mathcal{H}}^2$ が成り立つ。半正定値性は Nyström が**下から**近似することを意味する。誤差は $\boldsymbol{K}$ の固有値が急速に減衰するとき小さい。ただし**第** $(m+1)$ **固有値以降の和** $\sum_{i>m}\lambda_i$ **がそのまま誤差の上界になるわけではない**。$\sum_{i>m}\lambda_i$ は階数 m の**最良**近似の誤差（Eckart–Young、第2章）であって、Nyström は $\boldsymbol{K}$ の上位固有空間ではなく $\mathcal{V}_I$ という**選んだランドマークが張る**部分空間へ射影するので、つねに $\operatorname{tr}(\boldsymbol{K} - \hat{\boldsymbol{K}}) \ge \sum_{i>m}\lambda_i$ である。等号は $\mathcal{V}_I$ が上位 m 次元の固有空間を含むときに限られ、命題 8.22(ii) の $\operatorname{Im}\boldsymbol{K}[:,I] = \operatorname{Im}\boldsymbol{K}$ はその極端な場合（誤差 0）にあたる。理論保証は「$\sum_{i>m}\lambda_i$ に、選び方に依存する係数と加法項を付けた形」になり、ランドマークの選び方がこの係数を決める。

例 8.23 (固有値の尾と実際の Nyström 誤差)**.** $\boldsymbol{X} \in \mathbb{R}^{2\times 200}$ を標準正規、$\sigma = 1.5$ のガウスカーネル（$\operatorname{tr}\boldsymbol{K} = 200$）として $\operatorname{tr}(\boldsymbol{K} - \hat{\boldsymbol{K}})$ を実測する。一様ランダムに m 点を選ぶ操作を 200 回繰り返した中央値は、$m = 10$ で 9.25（$\sum_{i>10}\lambda_i = 3.08$）、$m = 20$ で 2.29（尾は 0.114）、$m = 40$ で 0.35（尾は 1×10^{-4}）である。いずれも尾の和の 3–3000 倍で、900 回の試行すべてで $\operatorname{tr}(\boldsymbol{K} - \hat{\boldsymbol{K}}) > \sum_{i>m}\lambda_i$ が成り立った（最小比 2.04）。m を増やすほど比が悪くなるのは、$\boldsymbol{K}$ の実効的な階数を超えて m を増やしてもランドマークが張る空間が上位固有空間に一致していかないためである。

ランドマークの選び方には一様ランダム、列ノルム比例、レバレッジスコアサンプリング（理論的に最良に近いがスコアの計算が重い）、k-means の中心などがある。これらが一様ランダムより良いのは、命題 8.22(ii) の**張る／張らない**という二値の条件を「どれだけよく張るか」に量的に緩めた形で改善するからである。すなわち $\mathcal{V}_I$ を $\boldsymbol{K}$ の上位固有空間に近づけることが目標であり、レバレッジスコア $\ell_i = \sum_{j\le m} u_{ij}^2$（$\boldsymbol{u}_j$ は $\boldsymbol{K}$ の上位固有ベクトル）はまさに「点 i が上位固有空間をどれだけ担っているか」の指標である。k-means 中心は入力空間で散らばった点を選ぶことで、同じ方向に重なるランドマークの重複を避ける。例 8.23 と同じ設定での中央値は、$m = 20$ でレバレッジスコア 1.32、k-means 中心 0.54（一様ランダム 2.29、尾の和 0.114）、$m = 40$ でそれぞれ 0.039、0.013（一様ランダム 0.35）であり、m が実効階数に近いところで差が出る。m が小さすぎると（$m = 10$ ではレバレッジスコア 11.8 と一様ランダム 9.25 より悪い）上位固有空間の推定自体が当てにならないので、この種の重み付けは万能ではない。計算量は $O(nm)$ 回のカーネル評価と $O(nm^2)$ の演算、メモリ $O(nm)$ で、$m = O(\sqrt{n})$ なら全体で $O(n^2)$ に収まる。

8.10.2　ランダムフーリエ特徴

Nyström がデータ依存の近似であるのに対し、ランダムフーリエ特徴（random Fourier features, RFF）はデータを見ずにカーネル自体を近似する。根拠は次の定理である。

定理 8.24 (Bochner)**.** 連続な平行移動不変関数 $k(\boldsymbol{x},\boldsymbol{y}) = \psi(\boldsymbol{x}-\boldsymbol{y})$（$\psi(\boldsymbol{0}) = 1$）が正定値カーネルであるための必要十分条件は、$\psi$ が $\mathbb{R}^d$ 上のある確率測度 Λ の Fourier 変換 $\psi(\boldsymbol{\delta}) = \int_{\mathbb{R}^d} e^{\mathrm{i}\boldsymbol{\omega}^{\top}\boldsymbol{\delta}}\,\mathrm{d}\Lambda(\boldsymbol{\omega})$ であることである。

証明には正定値関数の表現論（測度論）が必要なのでここでは省略し、事実として使う。ψ が実数値なら Λ は原点対称で、右辺は $\int \cos(\boldsymbol{\omega}^{\top}\boldsymbol{\delta})\,\mathrm{d}\Lambda$ に等しい。ガウスカーネルの場合は $\Lambda = \mathcal{N}(\boldsymbol{0}, \sigma^{-2}\boldsymbol{I}_d)$（実際 $\boldsymbol{\omega} \sim \mathcal{N}(\boldsymbol{0}, \sigma^{-2}\boldsymbol{I})$ の特性関数が $\exp(-\|\boldsymbol{\delta}\|^2/(2\sigma^2))$）、ラプラシアンカーネルなら Cauchy 分布である。

定理 8.25 (ランダムフーリエ特徴の不偏性)**.** $\boldsymbol{\omega} \sim \Lambda$、$b \sim \mathrm{Unif}[0, 2\pi]$ を独立とし $\zeta_{\boldsymbol{\omega},b}(\boldsymbol{x}) \coloneqq \sqrt{2}\cos(\boldsymbol{\omega}^\top \boldsymbol{x} + b)$ とおくと

$$\mathbb{E}_{\boldsymbol{\omega},b}\big[\zeta_{\boldsymbol{\omega},b}(\boldsymbol{x})\,\zeta_{\boldsymbol{\omega},b}(\boldsymbol{y})\big] = k(\boldsymbol{x},\boldsymbol{y}) \qquad (\forall \boldsymbol{x},\boldsymbol{y} \in \mathbb{R}^d). \tag{8.33}$$

したがって $(\boldsymbol{\omega}_j, b_j)_{j=1}^{D}$ を独立に引いて

$$\boldsymbol{z}(\boldsymbol{x}) \coloneqq \sqrt{2/D}\,\big(\cos(\boldsymbol{\omega}_1^\top \boldsymbol{x} + b_1), \dots, \cos(\boldsymbol{\omega}_D^\top \boldsymbol{x} + b_D)\big)^\top \in \mathbb{R}^D \tag{8.34}$$

と定めれば $\mathbb{E}[\boldsymbol{z}(\boldsymbol{x})^\top \boldsymbol{z}(\boldsymbol{y})] = k(\boldsymbol{x},\boldsymbol{y})$ である。

証明. 積和公式 $2\cos A\cos B = \cos(A-B) + \cos(A+B)$ を $A = \boldsymbol{\omega}^\top \boldsymbol{x} + b$、$B = \boldsymbol{\omega}^\top \boldsymbol{y} + b$ に適用すると

$$\zeta_{\boldsymbol{\omega},b}(\boldsymbol{x})\zeta_{\boldsymbol{\omega},b}(\boldsymbol{y}) = \cos\big(\boldsymbol{\omega}^\top(\boldsymbol{x}-\boldsymbol{y})\big) + \cos\big(\boldsymbol{\omega}^\top(\boldsymbol{x}+\boldsymbol{y}) + 2b\big).$$

第二項の b に関する期待値は、$c \coloneqq \boldsymbol{\omega}^\top(\boldsymbol{x}+\boldsymbol{y})$ を固定して

$$\mathbb{E}_b[\cos(c+2b)] = \frac{1}{2\pi}\int_0^{2\pi} \cos(c+2b)\,\mathrm{d}b = \frac{1}{2\pi}\Big[\frac{\sin(c+2b)}{2}\Big]_0^{2\pi} = \frac{\sin(c+4\pi)-\sin c}{4\pi} = 0$$

($\sin$ の周期性による)。よって第二項は消え、$\mathbb{E}_{\boldsymbol{\omega}}[\cos(\boldsymbol{\omega}^\top(\boldsymbol{x}-\boldsymbol{y}))] = \psi(\boldsymbol{x}-\boldsymbol{y}) = k(\boldsymbol{x},\boldsymbol{y})$（定理 8.24 と ψ が実数値であること）から (8.33) を得る。$\boldsymbol{z}(\boldsymbol{x})^\top \boldsymbol{z}(\boldsymbol{y}) = \frac{1}{D}\sum_j \zeta_{\boldsymbol{\omega}_j,b_j}(\boldsymbol{x})\zeta_{\boldsymbol{\omega}_j,b_j}(\boldsymbol{y})$ は独立同分布な確率変数の平均だから、その期待値は (8.33) に等しい。 ■

ここで重要なのは、$\boldsymbol{z}:\mathbb{R}^d \to \mathbb{R}^D$ が**陽に書ける有限次元の特徴写像**だという点である。データを列に並べて

$$\boldsymbol{Z} \coloneqq \big(\boldsymbol{z}(\boldsymbol{x}_1) \quad \cdots \quad \boldsymbol{z}(\boldsymbol{x}_n)\big) \in \mathbb{R}^{D\times n} \tag{8.35}$$

と変換してしまえば、$\boldsymbol{Z}$ は $\boldsymbol{X} \in \mathbb{R}^{d\times n}$ の d を D に置き換えただけのデータ行列であり、あとは**線形**手法（線形 PCA、線形リッジ回帰、線形 SVM）をそのまま使えばよい。実際 $\boldsymbol{Z}^\top\boldsymbol{Z} \approx \boldsymbol{K}$（$n\times n$）が (8.33) の主張であり、$\frac{1}{n}\boldsymbol{Z}\boldsymbol{Z}^\top$（$D\times D$）が近似的な特徴空間共分散である。計算量 $O(nD^2)$、メモリ $O(nD)$ で n について**線形**である。カーネルトリックで無限次元に上がってからランダム化で有限次元に降りてくる往復が、ここで完結する。

各項は有界（$|\zeta\zeta| \le 2$）だから Hoeffding の不等式より各点で $\mathbb{P}[|\boldsymbol{z}(\boldsymbol{x})^\top\boldsymbol{z}(\boldsymbol{y}) - k(\boldsymbol{x},\boldsymbol{y})| \ge \varepsilon] \le 2\exp(-D\varepsilon^2/8)$、コンパクト集合上で一様に評価するには ε-被覆と和集合上界を使って $D = O\big(\frac{d}{\varepsilon^2}\log\frac{1}{\varepsilon}\big)$ で一様誤差 ε が高確率で達成される（Rahimi–Recht）。ε^{-2} の依存は Monte Carlo に固有で、高精度には D が大きくなる。

$n = 400$、$d = 2$、ガウスカーネル $\sigma = 1$、標準正規データで相対フロベニウス誤差 $\|\hat{\boldsymbol{K}} - \boldsymbol{K}\|_{\mathrm{F}}/\|\boldsymbol{K}\|_{\mathrm{F}}$ を実測すると（演習 8.8）、$\boldsymbol{X} \in \mathbb{R}^{2\times 400}$（標準正規、$\sigma$ はメディアンヒューリスティックで 1.675）、20 回平均で RFF は $D = 100, 400, 1600, 6400$ に対し 0.135, 0.060, 0.030, 0.015、Nyström は $m = 10, 20, 40$ に対し 2.2×10^{-2}, 4.1×10^{-3}, 5.5×10^{-4} となる。同じ特徴次元で比べると Nyström が圧倒的に正確で、$m = 20$ の Nyström が $D = 6400$ の RFF より良い。RFF の誤差は $D^{-1/2}$ でしか減らない（D を 4 倍して誤差が約半分。実測の傾きは -0.53）が、Nyström の誤差はカーネルの固有値減衰に従ってはるかに速く減る。絶対値は σ の取り方と乱数実現に依存するので、傾きと大小関係を見るのが要点である。データの分布を見て部分空間を選ぶか、データを無視してランダムに周波数を引くかの違いである。

すなわち Nyström は $\boldsymbol{K}$ をデータ依存に近似するので同次元での精度が高く任意の正定値カーネルに使えるが、m 点のランドマークを保持する必要がある。RFF はカーネル関数 k 自体をデータ非依存に近似するので精度は $O(D^{-1/2})$ にとどまり平行移動不変なカーネルに限られるが、訓練データを保持せず点ごとに独立に計算できるのでオンライン処理や分散処理に向く。

実務上の指針は単純で、データがメモリに乗り m 点のランドマークを保持できるなら Nyström、ストリーミングや分散環境なら RFF である（図 8.5）。

注意 8.26 (第10章への伏線)**.** (8.34) は「入力にランダムな線形変換 $\boldsymbol{\omega}_j^\top\boldsymbol{x} + b_j$ を施し、非線形関数 cos を通し、その線形結合をとる」構造、すなわち**隠れ層をランダムに固定した 1 層ニューラルネットワーク**にほかならない。逆に言えば、隠れ層を訓練せず出力層だけ学習するランダム特徴モデルはある種のカーネル法と等価である。さらに、幅を無限大に飛ばしたニューラルネットワークの学習ダイナミクスがある固定カーネル（neural tangent kernel, NTK）に支配されることが知られている。この線は 第10章 と 第11章 で展開される。カーネル法は古い話題ではなく、深層学習の理論的理解の中心にある道具の一つである。

演習問題

演習 8.1 (中心化 Gram 行列の導出 ($\star$))**.** $\tilde{\phi}(\boldsymbol{x}_i) = \phi(\boldsymbol{x}_i) - \frac{1}{n}\sum_j \phi(\boldsymbol{x}_j)$ に対し $\widetilde{\boldsymbol{K}}_{ij} = \langle\tilde{\phi}(\boldsymbol{x}_i), \tilde{\phi}(\boldsymbol{x}_j)\rangle_{\mathcal{H}}$ が $\widetilde{\boldsymbol{K}} = \boldsymbol{H}\boldsymbol{K}\boldsymbol{H}$ と書けること、$\widetilde{\boldsymbol{K}}\mathbf{1} = \mathbf{0}$、$\operatorname{rank}\widetilde{\boldsymbol{K}} \le n-1$ を示せ。また $\boldsymbol{K} = \begin{pmatrix} 1 & 1/2 & 0 \\ 1/2 & 1 & 1/2 \\ 0 & 1/2 & 1 \end{pmatrix}$ に対し $\widetilde{\boldsymbol{K}}$ とその固有値を手で計算せよ。

演習 8.2 (表現定理の証明 (★★))**.** 定理 8.12 を証明せよ。$\mathcal{H}$ を $\mathcal{H}_n = \mathrm{span}\{k(\cdot, \boldsymbol{x}_i)\}$ とその直交補空間に分解し、(a) 損失項が直交成分に依存しないこと、(b) 罰則項が直交成分の分だけ真に増えることを示して結論せよ。さらに Ω が広義単調増加にすぎない場合に「この形の最小解が存在する」までしか言えない理由を、$\Omega \equiv 0$ の場合を例に説明せよ。

演習 8.3 (カーネル PCA のスクラッチ実装 (★★)、実装)**.** 三日月データ `make_moons`（$n = 300$、`noise=0.08`）に対し、ガウスカーネル（σ はメディアンヒューリスティック (8.9)）でカーネル PCA をスクラッチ実装せよ。(a) $\widetilde{\boldsymbol{K}} = \boldsymbol{H}\boldsymbol{K}\boldsymbol{H}$ を固有分解し $\boldsymbol{\alpha}_j = \boldsymbol{u}_j / \sqrt{\mu_j}$ と正規化する。(b) スコアが $\sum_i z_{ij}^2 = \mu_j$ を満たすことを数値で確認せよ。(c) `KernelPCA` の結果と符号を除いて一致することを示せ。(d) テスト点用の変換を (8.5) に従って実装し、訓練点を入力すると $\widetilde{\boldsymbol{K}}$ の行が再現されることを確認せよ。(e) 第 1・2 主成分の散布図を線形 PCA と比較せよ。

演習 8.4 (帯域幅の極限 (★★))**.** ガウスカーネルについて次を示せ。(a) 点が相異なるとき $\sigma \to 0$ で $\boldsymbol{K} \to \boldsymbol{I}_n$、したがって $\widetilde{\boldsymbol{K}} \to \boldsymbol{H}$ となり上位 $n-1$ 個の固有値がすべて 1 に縮退する。(b) $\sigma \to \infty$ で $\widetilde{\boldsymbol{K}} = \sigma^{-2}\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}} + O(\sigma^{-4})$ となること（e^{-u} の展開と $\boldsymbol{H}\mathbf{1} = \mathbf{0}$ を使う。$\widetilde{\boldsymbol{K}}$ は $n \times n$ なので右辺も $n \times n$、すなわち $\widetilde{\boldsymbol{X}}^{\top}\widetilde{\boldsymbol{X}}$ の順序である）。(c) (b) の $O(\sigma^{-4})$ の項を明示的に書き下し、それが $\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^4$ に由来することを確認せよ。

演習 8.5 (カーネルリッジ回帰と LOO (★★)、実装)**.** $f_0(x) = \sin(2x) + 0.3x$、$x_i \sim \mathrm{Unif}[-3, 3]$（$n = 80$）、$y_i = f_0(x_i) + \varepsilon_i$、$\varepsilon_i \sim \mathcal{N}(0, 0.2^2)$ でデータを生成する。(a) $\boldsymbol{\alpha} = (\boldsymbol{K} + n\lambda \boldsymbol{I})^{-1}\boldsymbol{y}$ を実装し `KernelRidge`（`alpha`$= n\lambda$）と一致することを確認せよ。(b) $\boldsymbol{S} = \boldsymbol{K}(\boldsymbol{K} + n\lambda\boldsymbol{I})^{-1}$ を用いた LOO の閉形式 (8.21) を実装し、n 回学習する総当たりと一致することを確認せよ。(c) (σ, λ) を対数グリッドで動かして LOO 誤差最小の組を求め、その適合曲線と f_0 を重ねて描け。(d) 実効自由度 (8.18) を λ の関数としてプロットし、LOO 最小の λ での値を読み取れ。

演習 8.6 (カーネル CCA の退化 (★★★))**.** $\widetilde{\boldsymbol{K}}_x, \widetilde{\boldsymbol{K}}_y$ がともに階数 $n-1$ で $\mathrm{Ker}\,\widetilde{\boldsymbol{K}}_x = \mathrm{Ker}\,\widetilde{\boldsymbol{K}}_y = \mathrm{span}\{\mathbf{1}\}$ のとき、正則化なしのカーネル CCA (8.23) の最大値がデータの内容によらず 1 になることを示せ。またこの事実の意味を「RKHS の表現力」の言葉で説明せよ。さらに $\boldsymbol{x}_i, \boldsymbol{y}_i$ を互いに独立な乱数として生成し、κ を 10^{-8} から 1 まで動かしたときの第一正準相関を数値的に求め、κ が小さいと 1 に張り付くことを確認せよ。数値実験では、$\widetilde{\boldsymbol{K}}^2 + \kappa\widetilde{\boldsymbol{K}}$ が $\mathbf{1}$ を核にもつので (8.28) のとおり $V = \mathbf{1}^{\perp}$ 上で解くこと（あるいは擬似逆を使うこと）。$\mathbf{1}$ 方向を残したまま `scipy.linalg.eigh(A, B)` を呼ぶと $\boldsymbol{B}$ の Cholesky 分解が失敗する。

演習 8.7 (MMD と特性的カーネル (★★))**.** (a) $\|\mu_P - \mu_Q\|_{\mathcal{H}}^2$ を展開して (8.29) を導け（途中で $\langle \mu_P, \mu_Q \rangle = \mathbb{E}_{X \sim P, Y \sim Q}[k(X, Y)]$ を示すこと）。(b) (8.30) の U 統計量が不偏であること、対角を含めた V 統計量が上向きのバイアスをもつことを示せ。(c) 線形カーネルでは $\mathrm{MMD}(P, Q) = \|\mathbb{E}_P[X] - \mathbb{E}_Q[Y]\|$ となり平均が等しく分散が異なる分布を区別できないこと（線形カーネルが特性的でないこと）を示せ。

演習 8.8 (ランダムフーリエ特徴 (★★)、実装)**.** (a) 定理 8.25 を証明せよ（積和公式と $\mathbb{E}_b[\cos(c + 2b)] = 0$ を使う）。(b) ガウスカーネルのスペクトル測度が $\mathcal{N}(\mathbf{0}, \sigma^{-2}\boldsymbol{I}_d)$ であることを多変量正規分布の特性関数から確かめよ。(c) $\boldsymbol{X} \in \mathbb{R}^{2 \times 400}$（$n = 400$、標準正規、帯域幅はメディアンヒューリスティック (8.9)。この設定では $\sigma = 1.675$）に対し $D = 100, 400, 1600, 6400$ で特徴行列 $\boldsymbol{Z} \in \mathbb{R}^{D \times n}$ を作り（(8.35)）、$\boldsymbol{Z}^{\top}\boldsymbol{Z}$ と $\boldsymbol{K}$ の相対フロベニウス誤差を計算して $O(D^{-1/2})$ で減ることを両対数プロットで確認せよ（$n \times n$ どうしを比べるので $\boldsymbol{Z}^{\top}\boldsymbol{Z}$ の順序である）。(d) 同じデータで Nyström（$m = 10, 20, 40, 80$）の誤差を重ね、どちらがどういう意味で優れているか論ぜよ。(e) $\boldsymbol{z}(\boldsymbol{x}) = \frac{1}{\sqrt{D}}(\cos(\boldsymbol{\omega}_j^{\top}\boldsymbol{x}), \sin(\boldsymbol{\omega}_j^{\top}\boldsymbol{x}))_j \in \mathbb{R}^{2D}$ とする変種も不偏になることを示し、数値的に分散が小さくなることを確認せよ。

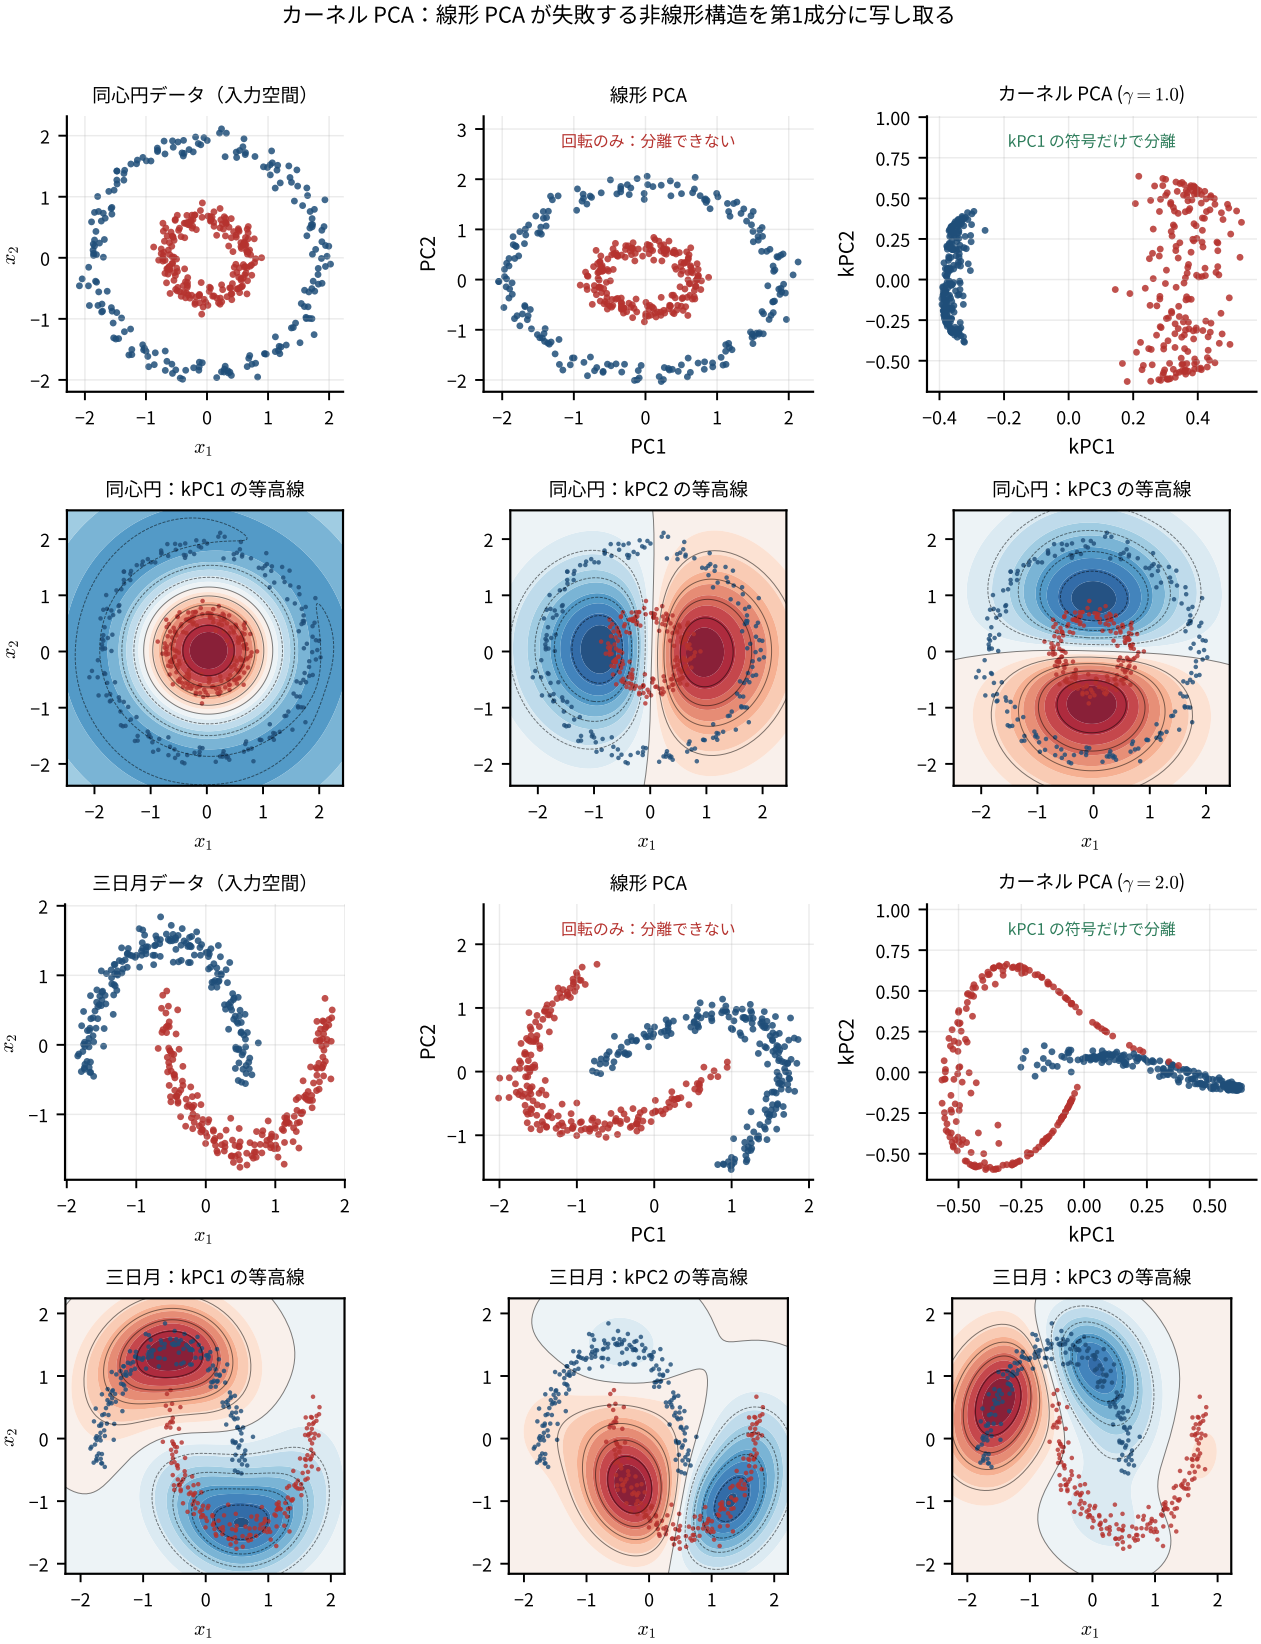


図8.1　同心円データと三日月データに対する線形 PCA とガウスカーネル PCA の比較。線形 PCA は座標の直交変換にすぎないため同心円を分離できないが、カーネル PCA の第 1 主成分は半径に相当する量を抽出して内側と外側を分離する。右側は主成分スコアを入力空間の関数として描いた等高線である。各 400 点、両軸を標準化してある（点間距離の中央値は同心円が 1.70、三日月が 1.76）。ガウスカーネルの帯域幅は **同心円が** $\sigma = 1/\sqrt{2} \fallingdotseq 0.707$（$\gamma = 1/(2\sigma^2) = 1.0$）、**三日月が** $\sigma = 0.5$（$\gamma = 2.0$）である。図中の表示は `sklearn` の引数に合わせて γ で、本文の σ とは $\gamma = 1/(2\sigma^2)$ で対応する。

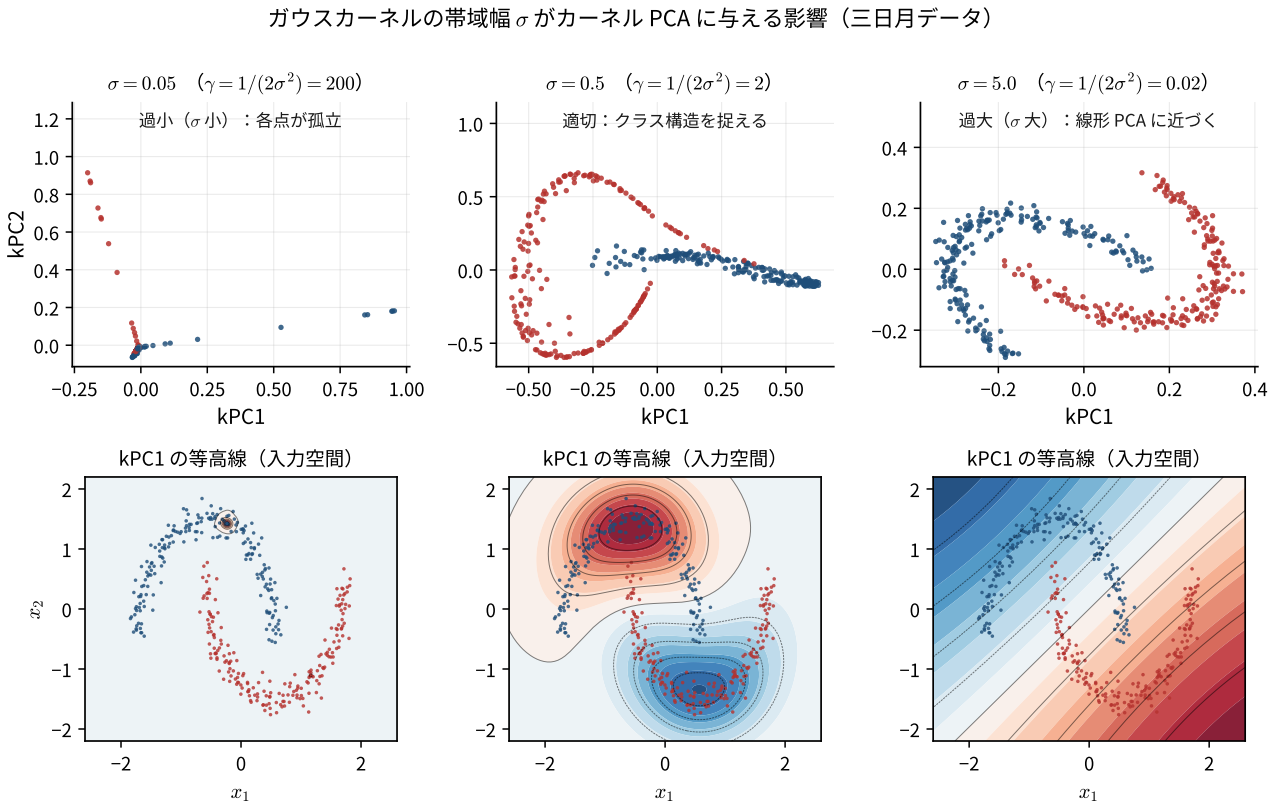


図8.2　帯域幅 σ を変えたときのカーネル PCA の埋め込み（上段）と第 1 主成分の入力空間での等高線（下段）。σ が小さすぎると Gram 行列が単位行列に近づいて各点が孤立し構造が消え（左、$\sigma = 0.05$）、大きすぎると線形 PCA に退化する（右、$\sigma = 5$）。中間の σ でのみデータの非線形構造が現れる（中、$\sigma = 0.5$）。実装では帯域幅を $\gamma = 1/(2\sigma^2)$ で指定するライブラリが多いので、対応する γ も併記した（`sklearn` の `gamma` はこの γ である）。

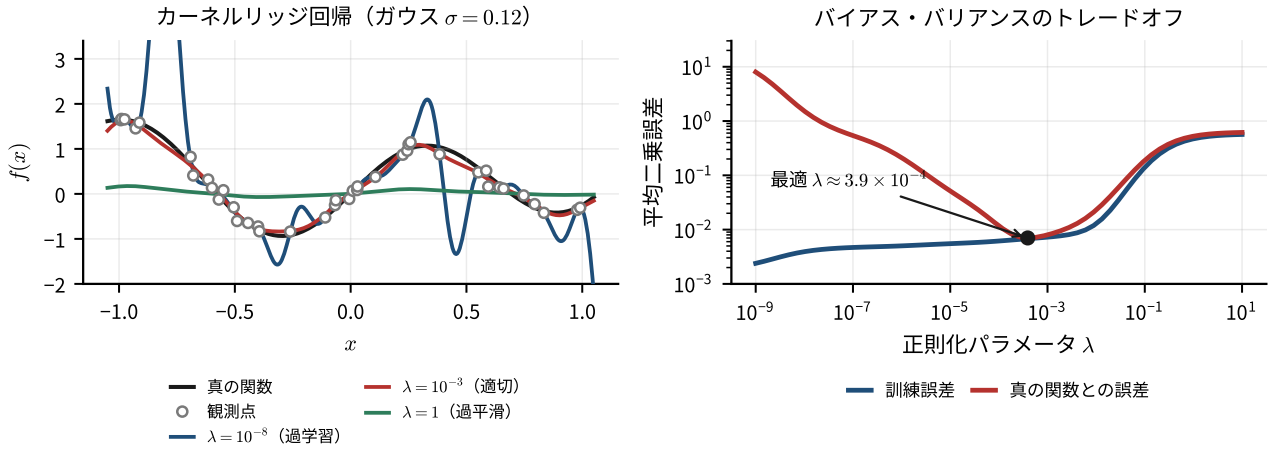


図8.3　正則化パラメータ λ を変えたときのカーネルリッジ回帰の適合曲線。λ が小さいと観測点を通ろうとして激しく振動し（過学習）、大きいと平坦化して真の関数から離れる（過平滑）。中間の λ で真の関数をよく再現する。

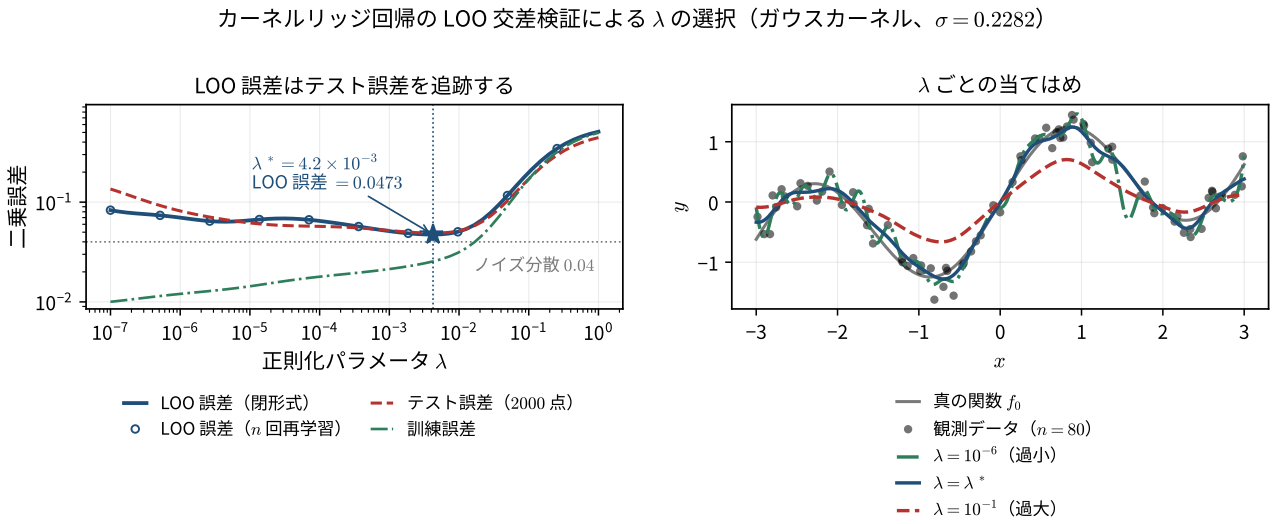


図8.4　LOO 交差検証による λ の選択。$n = 80$、$x_i \sim \mathrm{Unif}[-3, 3]$、$f_0(x) = \sin 2x + 0.3x$、ノイズ $\mathcal{N}(0, 0.2^2)$、ガウスカーネルの帯域幅は $\sigma = 0.2282$（メディアン規準 1.8256 の 1/8）である。**左**：(8.21)の閉形式で計算した LOO 誤差（実線）と、定義どおり n 回学習し直した値（白丸）。両者の差は最大 1.2×10^{-11} で、曲線は 60 点の λ すべてで重なっている。LOO 誤差は独立な 2000 点でのテスト誤差（破線）をよく追跡し、その最小点 $\lambda^* = 4.2 \times 10^{-3}$ はテスト誤差の最小点と一致した（どちらの誤差も λ^* で 0.0473 と 0.0489）。訓練誤差（一点鎖線）は λ について単調減少で、$\lambda = 10^{-6}$ では 0.0119 まで下がってノイズ分散 0.04 を割り込む——これが過学習である。**右**：三つの λ での当てはめ。$\lambda = 10^{-6}$ は観測点を追いかけて振動し、$\lambda = 10^{-1}$ は山と谷を均してしまう。λ^* では真の関数とほぼ重なる。

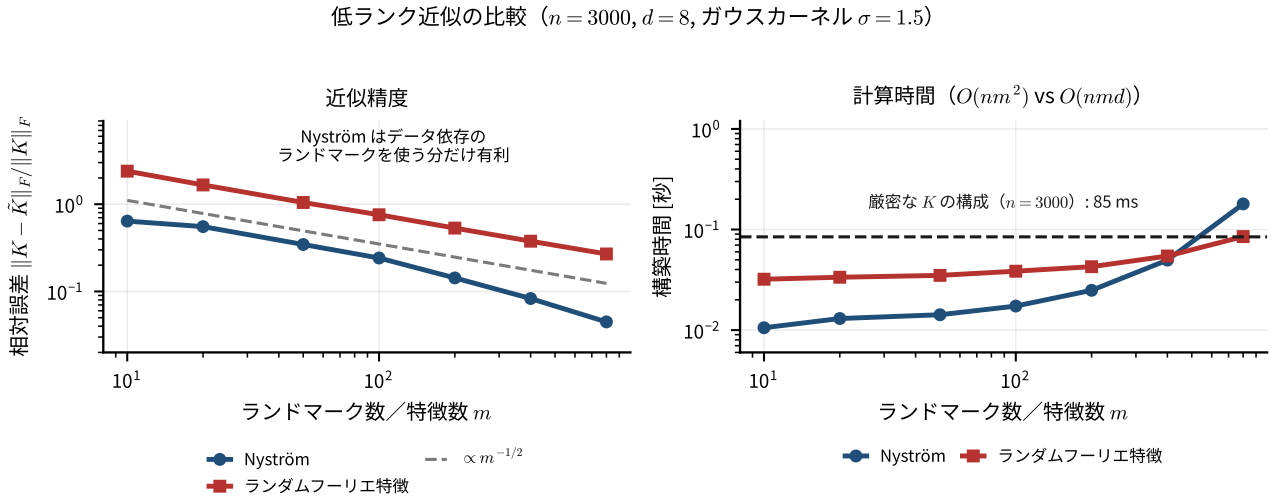


図8.5　Nyström 近似とランダムフーリエ特徴による Gram 行列近似の比較。ランドマーク数 m（あるいは特徴次元 D）に対する相対近似誤差と計算時間を示す。同じ次元数では Nyström の方が正確だが、ランダムフーリエ特徴は訓練データを保持せずオンラインに計算できる。

第 9 章

サポートベクターマシンと凸最適化

この章のねらい

本章では分類問題を扱う。線形分離可能なデータに対して分離超平面は無数に存在するが、「訓練点からもっとも遠い」超平面を選ぶという規準――マージン最大化――を立てると、問題は一意解をもつ凸二次計画問題になる。この問題のラグランジュ双対を作ると、データは内積を通してしか現れず、しかも解が少数の点（支持ベクトル）だけで表される。これを導くために必要な凸最適化の道具（双対性と KKT 条件）を本章で自己完結的に整備し、さらにソフトマージン化が第1章の正則化つき経験リスク最小化の枠組みにぴたりと収まること、カーネル化（第7章、第8章）が双対側でほぼ自動的に行えることを見る。[a]

[a] この章の計算は演習ノートブック `ch09_svm.ipynb` で再現できる。インストール不要で実行するには Google Colab で開く：`https://colab.research.google.com/github/yusukeimoto/data-analysis-math-demos/blob/main/notebooks/ch09_svm.ipynb`

9.1　分類問題とマージンという規準

本章の主題は教師つき学習、それも二値分類（binary classification）である。訓練データ

$$\mathcal{D}_n = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{n}, \qquad \boldsymbol{x}_i \in \mathcal{X} \subseteq \mathbb{R}^d, \quad y_i \in \{-1, +1\} \tag{9.1}$$

が与えられるとする。ラベルを $\{0,1\}$ でなく $\{-1,+1\}$ と取るのは本章を通じて本質的である。この符号化のもとでは「点 $\boldsymbol{x}_i$ が判別関数 f で正しく分類される」という条件が $y_i f(\boldsymbol{x}_i) > 0$ という一つの不等式で書けるからである。積 $y_i f(\boldsymbol{x}_i)$ を点 i における**マージン**（margin）と呼ぶ。符号が正しさを、絶対値が「どれだけ余裕をもって正しいか」を表すこの量が本章の主役である。判別関数はまず線形なもの $f(\boldsymbol{x}) = \boldsymbol{w}^\top \boldsymbol{x} + b$（$\boldsymbol{w} \in \mathbb{R}^d$、$b \in \mathbb{R}$）を考え、予測を $\hat{y}(\boldsymbol{x}) = \operatorname{sign} f(\boldsymbol{x})$ とする。バイアス b を分けて書くのは、後の双対問題で b だけが別扱いになるためである。

データが**線形分離可能**（linearly separable）であるとは、ある $(\boldsymbol{w}, b)$ が存在してすべての i で $y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) > 0$ となることをいう。ここで直ちに困った事態が生じる。分離可能ならばそのような $(\boldsymbol{w}, b)$ は**無数に**存在するのである。実際、分離する超平面を少し傾けても少し平行移動しても、n 本の有限個の不等式は破れない（図 9.1）。訓練誤差を規準にする限りこれらはすべて同点であり、別の規準で一つを選ばねばならない。

そこで発想を変える。欲しいのは訓練データの分類ではなく**未知の点**の分類である。観測された $\boldsymbol{x}_i$ の近傍にも同じクラスの点が散らばっていると考えるのが自然で、各点は半径 ρ 程度の「ゆらぎの球」を伴っている。境界がどの訓練点からも距離 ρ 以上離れていれば、ゆらぎが起きても分類結果は変わらない。

マージン最大化の原理

分離超平面が複数あるときは、**もっとも近い訓練点までの距離（マージン）が最大**になるものを選ぶ。これは「境界の位置の不確かさへの頑健性を最大化する」という要請の数学的表現であり、同時に解を一意に定める。

この原理から構成される分類器が**サポートベクターマシン**（support vector machine, SVM）である。9.10節で見るようにマージンの大小は汎化誤差の上界に定量的に効くので、この直感は定理として裏づけられる。

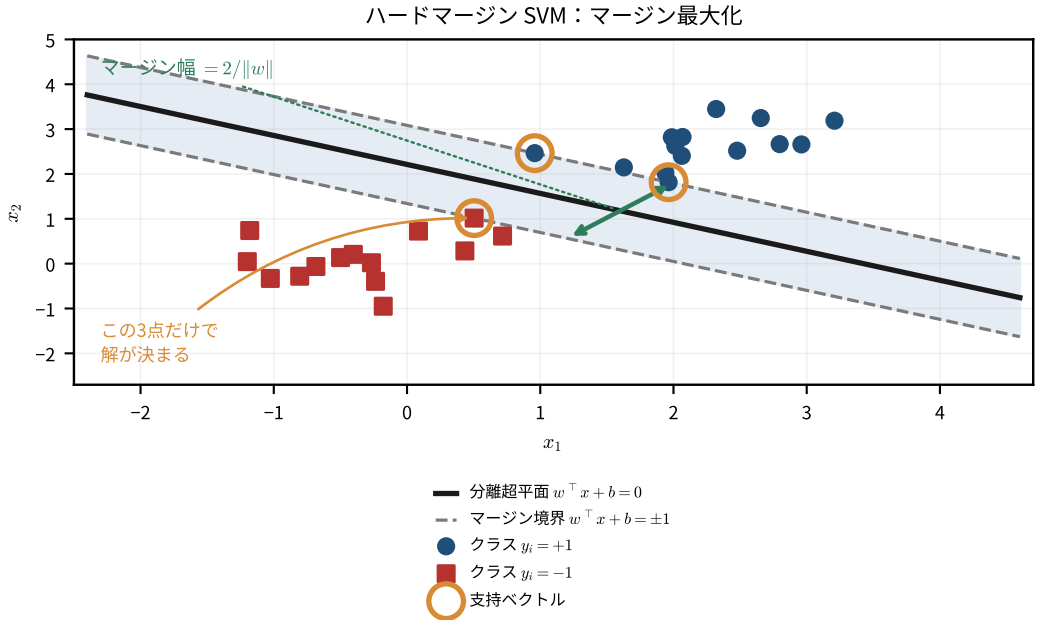


図9.1　ハードマージン SVM。線形分離可能なデータに対する分離超平面は無数にあるが、もっとも近い点までの距離を最大にするものは一意に定まる。マージン境界上に乗る少数の点（丸で強調）が支持ベクトルであり、マージン領域の幅は $2/\|\boldsymbol{w}\|$ に等しい。

9.2　幾何的準備：超平面と点の距離

マージンを最大化するには、まず「距離」を式で書かねばならない。

定義 9.1 (超平面)**.** $\boldsymbol{w}\in\mathbb{R}^d\setminus\{\boldsymbol{0}\}$、$b\in\mathbb{R}$ に対し $H_{\boldsymbol{w},b}:=\{\boldsymbol{x}\in\mathbb{R}^d:\boldsymbol{w}^\top\boldsymbol{x}+b=0\}$ を（アフィン）**超平面**といい、$\boldsymbol{w}$ を法線ベクトルと呼ぶ。

$\boldsymbol{x},\boldsymbol{x}'\in H_{\boldsymbol{w},b}$ なら $\boldsymbol{w}^\top(\boldsymbol{x}-\boldsymbol{x}')=0$ だから、$\boldsymbol{w}$ は超平面に平行な任意のベクトルと直交する。これが「法線」の名の由来である。

命題 9.2 (点と超平面の距離)**.** 任意の $\boldsymbol{z}\in\mathbb{R}^d$ に対し $\operatorname{dist}(\boldsymbol{z},H_{\boldsymbol{w},b}):=\min_{\boldsymbol{x}\in H_{\boldsymbol{w},b}}\|\boldsymbol{z}-\boldsymbol{x}\|=|\boldsymbol{w}^\top\boldsymbol{z}+b|/\|\boldsymbol{w}\|$。

証明. 右辺が下界であること：$\boldsymbol{x}\in H_{\boldsymbol{w},b}$ なら $\boldsymbol{w}^\top\boldsymbol{x}=-b$ だから、Cauchy–Schwarz の不等式より

$$|\boldsymbol{w}^\top\boldsymbol{z}+b|=|\boldsymbol{w}^\top(\boldsymbol{z}-\boldsymbol{x})|\le\|\boldsymbol{w}\|\,\|\boldsymbol{z}-\boldsymbol{x}\|,$$

両辺を $\|\boldsymbol{w}\|>0$ で割れば $\|\boldsymbol{z}-\boldsymbol{x}\|\ge|\boldsymbol{w}^\top\boldsymbol{z}+b|/\|\boldsymbol{w}\|$。これがすべての $\boldsymbol{x}\in H_{\boldsymbol{w},b}$ で成り立つので最小値についても成り立つ。達成されること：$\boldsymbol{x}^\star:=\boldsymbol{z}-\frac{\boldsymbol{w}^\top\boldsymbol{z}+b}{\|\boldsymbol{w}\|^2}\boldsymbol{w}$ とおくと $\boldsymbol{w}^\top\boldsymbol{x}^\star+b=\boldsymbol{w}^\top\boldsymbol{z}-(\boldsymbol{w}^\top\boldsymbol{z}+b)+b=0$ より $\boldsymbol{x}^\star\in H_{\boldsymbol{w},b}$ であり、$\|\boldsymbol{z}-\boldsymbol{x}^\star\|=|\boldsymbol{w}^\top\boldsymbol{z}+b|\|\boldsymbol{w}\|/\|\boldsymbol{w}\|^2$ が右辺に一致する。$\boldsymbol{x}^\star$ は $\boldsymbol{z}$ の $H_{\boldsymbol{w},b}$ への正射影であり、第2章の直交射影のアフィン版になっている。 ■

正しく分類されていれば $y_i(\boldsymbol{w}^\top\boldsymbol{x}_i+b)>0$ なので命題 9.2の絶対値が外せ、次の定義に至る。

定義 9.3 (関数マージンと幾何マージン)**.** 点 $(\boldsymbol{x}_i,y_i)$ の**関数マージン**を $\hat\gamma_i:=y_i(\boldsymbol{w}^\top\boldsymbol{x}_i+b)$、**幾何マージン**を $\gamma_i:=\hat\gamma_i/\|\boldsymbol{w}\|$ と定める。データ集合に対しては最小値 $\hat\gamma:=\min_i\hat\gamma_i$、$\gamma:=\min_i\gamma_i=\hat\gamma/\|\boldsymbol{w}\|$ を用いる。

スケールの任意性

$(\boldsymbol{w},b)$ と $(c\boldsymbol{w},cb)$（$c>0$）は同じ超平面・同じ予測を与えるが、関数マージンは c 倍される。したがって「関数マージンの最大化」は無意味である（$c\to\infty$ でいくらでも大きくできる）。幾何マージン $\hat\gamma_i/\|\boldsymbol{w}\|$ は c について不変であり、これが最大化すべき量である。

この自由度は逆に利用すると便利である。分離可能なら $\hat\gamma>0$ だから、$(\boldsymbol{w},b)$ を $\hat\gamma$ で割れば

$$\min_{1\le i\le n}y_i(\boldsymbol{w}^\top\boldsymbol{x}_i+b)=1 \tag{9.2}$$

と正規化できる。これを**正準形**（canonical form）といい、このとき幾何マージンは $\gamma=1/\|\boldsymbol{w}\|$ という簡単な式になる。「マージンを大きくする」ことと「$\|\boldsymbol{w}\|$ を小さくする」ことが同義になった。この一行が SVM の出発点である。

9.3　ハードマージン SVM の主問題

$\gamma = 1/\|\boldsymbol{w}\|$ の最大化は $\|\boldsymbol{w}\|$ の最小化と同じであり、さらに $t \mapsto \frac{1}{2}t^2$ が $t \geq 0$ で狭義単調増加だから $\frac{1}{2}\|\boldsymbol{w}\|^2$ を最小化しても解は変わらない。微分可能な二次関数になるぶんこちらが扱いやすい。

定義 9.4 (ハードマージン SVM)**.** 線形分離可能な訓練データ $\mathcal{D}_n$（(9.1)）に対する**ハードマージン SVM** とは

$$\min_{\boldsymbol{w}\in\mathbb{R}^d,\, b\in\mathbb{R}} \ \frac{1}{2}\|\boldsymbol{w}\|^2 \quad \text{s.t.} \quad y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1 \quad (i = 1, \dots, n) \tag{9.3}$$

である。

制約を $= 1$ でなく ≥ 1 にしてよい。もしすべての i で $y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) > 1$ なら、$(\boldsymbol{w}, b)$ を $(1-\varepsilon)$ 倍しても十分小さい $\varepsilon > 0$ に対して制約が保たれ目的関数は真に減少するから、最適ではない。よって最適解は自動的に正準形式 (9.2)を満たす。

命題 9.5 (マージン領域の幅)**.** 正準形のとき、二つのマージン境界 $H_\pm = \{\boldsymbol{x} : \boldsymbol{w}^\top \boldsymbol{x} + b = \pm 1\}$ の間の距離は $2/\|\boldsymbol{w}\|$ である。

証明. $\boldsymbol{x}_+ \in H_+$ をとる。H_- は $\boldsymbol{w}^\top \boldsymbol{x} + (b+1) = 0$ と書けるから、命題 9.2を法線 $\boldsymbol{w}$、切片 $b+1$ の超平面に適用して $\operatorname{dist}(\boldsymbol{x}_+, H_-) = |\boldsymbol{w}^\top \boldsymbol{x}_+ + b + 1|/\|\boldsymbol{w}\| = 2/\|\boldsymbol{w}\|$。二つの超平面は平行なのでこれは $\boldsymbol{x}_+$ の取り方によらない。 ■

すなわち式 (9.3)は「幅 $2/\|\boldsymbol{w}\|$ の帯の内部に訓練点を一つも入れずに帯の幅を最大にする」問題である（図 9.1）。

命題 9.6 (凸二次計画であること・解の一意性)**.** 式 (9.3)は目的関数が $(\boldsymbol{w}, b) \in \mathbb{R}^{d+1}$ の凸二次関数、制約が n 本の線形不等式である**凸二次計画問題**（convex quadratic program, QP）であり、実行可能領域が空でなければ最適な $\boldsymbol{w}^\star$ は一意である。

証明. 目的関数は係数行列 $\begin{pmatrix} \boldsymbol{I}_d & \boldsymbol{0} \\ \boldsymbol{0}^\top & 0 \end{pmatrix} \succeq 0$ の二次形式だから凸（命題 9.9）、制約 $1 - y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \leq 0$ はアフィンだから凸。一意性：$(\boldsymbol{w}_1, b_1), (\boldsymbol{w}_2, b_2)$ をともに最適解、$p^\star = \frac{1}{2}\|\boldsymbol{w}_1\|^2 = \frac{1}{2}\|\boldsymbol{w}_2\|^2$ とする。実行可能領域は凸だから中点も実行可能で、中線定理より $\|\frac{\boldsymbol{w}_1+\boldsymbol{w}_2}{2}\|^2 = 2p^\star - \frac{1}{4}\|\boldsymbol{w}_1 - \boldsymbol{w}_2\|^2$。最適性から $\frac{1}{2}\|\frac{\boldsymbol{w}_1+\boldsymbol{w}_2}{2}\|^2 \geq p^\star$ なので $\|\boldsymbol{w}_1 - \boldsymbol{w}_2\|^2 \leq 0$、すなわち $\boldsymbol{w}_1 = \boldsymbol{w}_2$。 ■

b の一意性は $\boldsymbol{w}$ の一意性から従う（$\min_{i:y_i=+1} \boldsymbol{w}^\top \boldsymbol{x}_i$ と $\max_{i:y_i=-1} \boldsymbol{w}^\top \boldsymbol{x}_i$ の中点で決まる）。

例 9.7 (3 点の例を手で解く)**.** $\boldsymbol{x}_1 = (0,0)^\top$（$y_1 = -1$）、$\boldsymbol{x}_2 = (2,0)^\top$、$\boldsymbol{x}_3 = (0,2)^\top$（ともに $y = +1$）とする。$\boldsymbol{x}_2 \leftrightarrow \boldsymbol{x}_3$ の対称性から $\boldsymbol{w} = (w, w)^\top$ としてよく、制約は $b \leq -1$ かつ $2w + b \geq 1$ の 2 本になる。目的関数 w^2 を小さくするには b を最大の $b = -1$ にとればよく、$2w \geq 2$ から $w = 1$。よって $\boldsymbol{w}^\star = (1,1)^\top$、$b^\star = -1$、$f(\boldsymbol{x}) = x_1 + x_2 - 1$、$\gamma = 1/\sqrt{2} \approx 0.707$ で、3 点すべてが $y_i f(\boldsymbol{x}_i) = 1$ をみたす支持ベクトルである。

9.4　凸最適化の道具立て

式 (9.3)をこのまま数値的に解いてもよいが、SVM の本質——支持ベクトルの疎性とカーネル化——は**双対問題**を経由してはじめて見える。必要な凸最適化の基礎を自己完結的に整備しよう。しばらく SVM を離れ、一般の問題

$$\min_{\boldsymbol{z}\in\mathcal{D}} \ f_0(\boldsymbol{z}) \quad \text{s.t.} \quad f_i(\boldsymbol{z}) \leq 0 \ (i = 1, \dots, m), \qquad h_j(\boldsymbol{z}) = 0 \ (j = 1, \dots, p) \tag{9.4}$$

を考える。$\mathcal{D} \subseteq \mathbb{R}^N$ は全関数の定義域の共通部分、最適値を $p^\star$ と書く。

9.4.1　凸集合・凸関数と局所最適性

定義 9.8 (凸集合・凸関数)**.** $S \subseteq \mathbb{R}^N$ が**凸**（convex）とは、$\boldsymbol{z}_1, \boldsymbol{z}_2 \in S$、$t \in [0,1]$ ならば $t\boldsymbol{z}_1 + (1-t)\boldsymbol{z}_2 \in S$ となることをいう。凸集合 S 上の f が**凸関数**とは、すべての $\boldsymbol{z}_1, \boldsymbol{z}_2 \in S$、$t \in [0,1]$ で $f(t\boldsymbol{z}_1 + (1-t)\boldsymbol{z}_2) \leq t f(\boldsymbol{z}_1) + (1-t) f(\boldsymbol{z}_2)$ が成り立つことをいい、不等号を逆にしたものを**凹関数**という。式 (9.4)で $f_0, \dots, f_m$ が凸、$h_1, \dots, h_p$ がアフィンのとき、これを**凸計画問題**という。

命題 9.9 (二次形式の凸性)**.** 対称行列 $\boldsymbol{A}$ に対し、$f(\boldsymbol{z}) = \frac{1}{2}\boldsymbol{z}^\top \boldsymbol{A}\boldsymbol{z} + \boldsymbol{c}^\top \boldsymbol{z}$ が凸であることと $\boldsymbol{A} \succeq 0$（半正定値）は同値。

証明. $\boldsymbol{z}_t = t\boldsymbol{z}_1 + (1-t)\boldsymbol{z}_2$、$\boldsymbol{u} = \boldsymbol{z}_1 - \boldsymbol{z}_2$ とおく。線形項は $t\boldsymbol{c}^\top \boldsymbol{z}_1 + (1-t)\boldsymbol{c}^\top \boldsymbol{z}_2 - \boldsymbol{c}^\top \boldsymbol{z}_t = 0$ で相殺するので二次項だけを見ればよい。$\boldsymbol{z}_1 = \boldsymbol{z}_t + (1-t)\boldsymbol{u}$、$\boldsymbol{z}_2 = \boldsymbol{z}_t - t\boldsymbol{u}$ を代入して展開すると、$\boldsymbol{z}_t^\top \boldsymbol{A}\boldsymbol{z}_t$ の項と $\boldsymbol{u}^\top \boldsymbol{A}\boldsymbol{z}_t$ の一次項がともに相殺し、

$$t \cdot \tfrac{1}{2}\boldsymbol{z}_1^\top \boldsymbol{A}\boldsymbol{z}_1 + (1-t) \cdot \tfrac{1}{2}\boldsymbol{z}_2^\top \boldsymbol{A}\boldsymbol{z}_2 - \tfrac{1}{2}\boldsymbol{z}_t^\top \boldsymbol{A}\boldsymbol{z}_t = \tfrac{1}{2}\big[t(1-t)^2 + (1-t)t^2\big]\boldsymbol{u}^\top \boldsymbol{A}\boldsymbol{u} = \tfrac{1}{2}\,t(1-t)\,\boldsymbol{u}^\top \boldsymbol{A}\boldsymbol{u}.$$

$t(1-t) \geq 0$ だから、これがすべての $\boldsymbol{u}$、$t \in [0,1]$ で非負であることと $\boldsymbol{A} \succeq 0$ は同値である。 ■

定理 9.10 (局所最適は大域最適)**.** 凸計画問題式 (9.4)の実行可能領域を F とする。$\boldsymbol{z}^\star \in F$ が**局所最適**、すなわちある $r > 0$ が存在して「$\boldsymbol{z} \in F$ かつ $\|\boldsymbol{z} - \boldsymbol{z}^\star\| < r$ ならば $f_0(\boldsymbol{z}) \geq f_0(\boldsymbol{z}^\star)$」が成り立つならば、$\boldsymbol{z}^\star$ は大域最適である。

証明. まず F は凸である。f_i が凸なら $f_i(\boldsymbol{z}_1) \le 0$、$f_i(\boldsymbol{z}_2) \le 0$ から $f_i(\boldsymbol{z}_t) \le t f_i(\boldsymbol{z}_1) + (1-t) f_i(\boldsymbol{z}_2) \le 0$ なので劣位集合は凸、アフィン等式の集合も凸、凸集合の共通部分は凸だからである。背理法で示す。$\boldsymbol{z}^\star$ が大域最適でないとすると $f_0(\boldsymbol{z}') < f_0(\boldsymbol{z}^\star)$ となる $\boldsymbol{z}' \in F$ がある。$t \in (0,1]$ に対し $\boldsymbol{z}_t = t\boldsymbol{z}' + (1-t)\boldsymbol{z}^\star \in F$ であり、f_0 の凸性から $f_0(\boldsymbol{z}_t) \le f_0(\boldsymbol{z}^\star) + t(f_0(\boldsymbol{z}') - f_0(\boldsymbol{z}^\star)) < f_0(\boldsymbol{z}^\star)$。$0 < t < r/\|\boldsymbol{z}' - \boldsymbol{z}^\star\|$ ととれば $\|\boldsymbol{z}_t - \boldsymbol{z}^\star\| < r$ となり、局所最適性から要請される $f_0(\boldsymbol{z}_t) \ge f_0(\boldsymbol{z}^\star)$ に矛盾する。 ■

非凸問題では局所解に落ち込む危険をつねに気にしなければならない（第10章のニューラルネットワークがそうである）。凸計画問題ではその心配がなく、「解けた」と言えばそれは大域解である。これが SVM を凸問題として定式化する利点である。

9.4.2　ラグランジュ双対

制約つき問題を扱う古典的な方法は、制約を目的関数に「値段をつけて」繰り込むことである。

定義 9.11 (ラグランジュ関数と双対関数)**.** 式 (9.4)に対し**ラグランジュ関数**を $L(\boldsymbol{z}, \boldsymbol{\lambda}, \boldsymbol{\mu}) \coloneqq f_0(\boldsymbol{z}) + \sum_{i=1}^{m} \lambda_i f_i(\boldsymbol{z}) + \sum_{j=1}^{p} \mu_j h_j(\boldsymbol{z})$、**ラグランジュ双対関数**を $g(\boldsymbol{\lambda}, \boldsymbol{\mu}) \coloneqq \inf_{\boldsymbol{z} \in \mathcal{D}} L(\boldsymbol{z}, \boldsymbol{\lambda}, \boldsymbol{\mu})$ で定める。λ_i, μ_j を**ラグランジュ乗数**（双対変数）という。

λ_i は「制約 $f_i(\boldsymbol{z}) \le 0$ を単位量だけ破るときに払う罰則」と読める。

命題 9.12 (双対関数はつねに凹)**.** f_i, h_j の凸性を**仮定しなくても**、g は $(\boldsymbol{\lambda}, \boldsymbol{\mu})$ の凹関数である。

証明. $\boldsymbol{z}$ を固定するごとに $(\boldsymbol{\lambda}, \boldsymbol{\mu}) \mapsto L(\boldsymbol{z}, \boldsymbol{\lambda}, \boldsymbol{\mu})$ は**アフィン**（係数 $f_i(\boldsymbol{z}), h_j(\boldsymbol{z})$ は定数）であり、アフィン関数は凹関数でもある。あとは凹関数族の各点下限が凹であることを見ればよい。$(\boldsymbol{\lambda}_t, \boldsymbol{\mu}_t) = t(\boldsymbol{\lambda}_1, \boldsymbol{\mu}_1) + (1-t)(\boldsymbol{\lambda}_2, \boldsymbol{\mu}_2)$ とおくと、任意の $\boldsymbol{z}$ で $L(\boldsymbol{z}, \boldsymbol{\lambda}_t, \boldsymbol{\mu}_t) = tL(\boldsymbol{z}, \boldsymbol{\lambda}_1, \boldsymbol{\mu}_1) + (1-t)L(\boldsymbol{z}, \boldsymbol{\lambda}_2, \boldsymbol{\mu}_2) \ge t g(\boldsymbol{\lambda}_1, \boldsymbol{\mu}_1) + (1-t) g(\boldsymbol{\lambda}_2, \boldsymbol{\mu}_2)$ であり、右辺は $\boldsymbol{z}$ によらない下界だから左辺の下限をとっても不等号は保たれる。 ■

もとの問題がどれほど厄介でも、**双対問題** $\max_{\boldsymbol{\lambda} \ge \boldsymbol{0}, \boldsymbol{\mu}} g(\boldsymbol{\lambda}, \boldsymbol{\mu})$ はつねに凹関数の最大化、すなわち凸問題になる。その最適値を $d^\star$ と書く。

定理 9.13 (弱双対性)**.** 任意の $\boldsymbol{\lambda} \ge \boldsymbol{0}$、任意の $\boldsymbol{\mu}$ に対し $g(\boldsymbol{\lambda}, \boldsymbol{\mu}) \le p^\star$。したがって $d^\star \le p^\star$。

証明. $\boldsymbol{z}$ を任意の実行可能点とする。$\lambda_i \ge 0$、$f_i(\boldsymbol{z}) \le 0$ より $\lambda_i f_i(\boldsymbol{z}) \le 0$、また $\mu_j h_j(\boldsymbol{z}) = 0$ だから $L(\boldsymbol{z}, \boldsymbol{\lambda}, \boldsymbol{\mu}) \le f_0(\boldsymbol{z})$。一方 $\boldsymbol{z} \in \mathcal{D}$ だから $g(\boldsymbol{\lambda}, \boldsymbol{\mu}) \le L(\boldsymbol{z}, \boldsymbol{\lambda}, \boldsymbol{\mu})$。合わせて $g(\boldsymbol{\lambda}, \boldsymbol{\mu}) \le f_0(\boldsymbol{z})$ がすべての実行可能点で成り立つので、右辺の下限をとって $g(\boldsymbol{\lambda}, \boldsymbol{\mu}) \le p^\star$。左辺の上限をとれば $d^\star \le p^\star$。 ■

差 $p^\star - d^\star \ge 0$ を**双対ギャップ**といい、これが 0 のとき**強双対性**が成り立つという。凸問題ではごく穏やかな条件でこれが成り立つ。

定理 9.14 (Slater の条件；結果のみ [17])**.** 式 (9.4)が凸計画問題で、$f_i(\boldsymbol{z}) < 0$ $(\forall i)$ かつ $h_j(\boldsymbol{z}) = 0$ $(\forall j)$ を満たす $\boldsymbol{z}$ が存在する（**Slater 条件**）とする。このとき $d^\star = p^\star$ であり、$p^\star > -\infty$ なら双対最適解が存在する。さらに、アフィンな f_i については狭義不等号 $<$ を $\le$ に緩めてよい。とくに **すべての制約がアフィンで実行可能領域が空でなければ**無条件に強双対性が成り立つ。

注意 9.15 (何を省いたか)**.** 証明には凸集合の分離定理を用いる。集合 $\mathcal{A} = \{(\boldsymbol{u}, \boldsymbol{v}, t) : \exists \boldsymbol{z} \in \mathcal{D},\ f_i(\boldsymbol{z}) \le u_i,\ h_j(\boldsymbol{z}) = v_j,\ f_0(\boldsymbol{z}) \le t\}$ が凸であることを示し、$(\boldsymbol{0}, \boldsymbol{0}, p^\star)$ が $\mathcal{A}$ の内部に属さないことから $\mathcal{A}$ を支持する超平面をとると、その法線ベクトルが双対最適解を与える、という筋である。Slater 条件はこの支持超平面が「垂直」に退化しない（t 方向の係数が 0 にならない）ことの保証に使う。本書は分離定理そのものの証明に立ち入らないので結果のみを用いる。なお SVM の主問題 式 (9.3)は制約がすべてアフィンなので、線形分離可能でありさえすれば強双対性が自動的に成り立つ。

9.4.3　KKT 条件

定理 9.16 (KKT 条件)**.** 式 (9.4)で $f_0, \dots, f_m, h_1, \dots, h_p$ が微分可能とする。$\boldsymbol{z}^\star$ が主最適解、$(\boldsymbol{\lambda}^\star, \boldsymbol{\mu}^\star)$ が双対最適解でギャップが 0 ならば、次の **Karush–Kuhn–Tucker（KKT）条件**が成り立つ。

$$\text{(i) 主実行可能性:} \quad f_i(\boldsymbol{z}^\star) \le 0 \ \ (i = 1, \dots, m), \quad h_j(\boldsymbol{z}^\star) = 0 \ \ (j = 1, \dots, p), \tag{9.5}$$

$$\text{(ii) 双対実行可能性:} \quad \lambda_i^\star \ge 0 \quad (i = 1, \dots, m), \tag{9.6}$$

$$\text{(iii) 相補性条件:} \quad \lambda_i^\star f_i(\boldsymbol{z}^\star) = 0 \quad (i = 1, \dots, m), \tag{9.7}$$

$$\text{(iv) 停留性:} \quad \nabla_{\boldsymbol{z}} L(\boldsymbol{z}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\mu}^\star) = \boldsymbol{0}. \tag{9.8}$$

逆に、問題が凸計画問題であるならば、(i)–(iv) が成り立つことは $\boldsymbol{z}^\star$ が主最適・$(\boldsymbol{\lambda}^\star, \boldsymbol{\mu}^\star)$ が双対最適でギャップが 0 であることと **同値**である。

証明.（必要性）ギャップ 0 より

$$f_0(\boldsymbol{z}^\star) = p^\star = d^\star = \inf_{\boldsymbol{z}\in\mathcal{D}} L(\boldsymbol{z},\boldsymbol{\lambda}^\star,\boldsymbol{\mu}^\star) \le L(\boldsymbol{z}^\star,\boldsymbol{\lambda}^\star,\boldsymbol{\mu}^\star) = f_0(\boldsymbol{z}^\star) + \sum_i \lambda_i^\star f_i(\boldsymbol{z}^\star) + \sum_j \mu_j^\star h_j(\boldsymbol{z}^\star).$$

$h_j(\boldsymbol{z}^\star) = 0$ であり、$\lambda_i^\star \ge 0$、$f_i(\boldsymbol{z}^\star) \le 0$ より $\sum_i \lambda_i^\star f_i(\boldsymbol{z}^\star) \le 0$ だから、右端は $f_0(\boldsymbol{z}^\star)$ 以下。左端と一致しているので上の不等式列は**すべて等号**である。まず $\sum_i \lambda_i^\star f_i(\boldsymbol{z}^\star) = 0$ で各項が ≤ 0 だから各項が 0、これが相補性式 (9.7)。次に $\inf_{\boldsymbol{z}} L(\boldsymbol{z},\boldsymbol{\lambda}^\star,\boldsymbol{\mu}^\star) = L(\boldsymbol{z}^\star,\boldsymbol{\lambda}^\star,\boldsymbol{\mu}^\star)$ は $\boldsymbol{z}^\star$ が $L(\cdot,\boldsymbol{\lambda}^\star,\boldsymbol{\mu}^\star)$ の最小点であることを意味し、微分可能性から停留性式 (9.8)を得る。(i),(ii) は仮定そのものである。

（凸のとき十分性）f_i が凸で $\lambda_i^\star \ge 0$、h_j がアフィンだから $\boldsymbol{z} \mapsto L(\boldsymbol{z},\boldsymbol{\lambda}^\star,\boldsymbol{\mu}^\star)$ は凸であり、凸微分可能関数の停留点は大域最小点なので式 (9.8)より

$$g(\boldsymbol{\lambda}^\star,\boldsymbol{\mu}^\star) = L(\boldsymbol{z}^\star,\boldsymbol{\lambda}^\star,\boldsymbol{\mu}^\star) = f_0(\boldsymbol{z}^\star) + \underbrace{\sum_i \lambda_i^\star f_i(\boldsymbol{z}^\star)}_{=0\ (\text{相補性})} + \underbrace{\sum_j \mu_j^\star h_j(\boldsymbol{z}^\star)}_{=0\ (\text{実行可能性})} = f_0(\boldsymbol{z}^\star).$$

弱双対性より $g(\boldsymbol{\lambda}^\star,\boldsymbol{\mu}^\star) \le d^\star \le p^\star \le f_0(\boldsymbol{z}^\star)$ で、左端と右端が一致したのですべて等号。すなわち $\boldsymbol{z}^\star$ は主最適、$(\boldsymbol{\lambda}^\star,\boldsymbol{\mu}^\star)$ は双対最適、ギャップは 0 である。 ■

相補性条件の読み方

$\lambda_i^\star f_i(\boldsymbol{z}^\star) = 0$ は「$\lambda_i^\star > 0 \Rightarrow f_i(\boldsymbol{z}^\star) = 0$（制約は等号で有効）」かつ「$f_i(\boldsymbol{z}^\star) < 0 \Rightarrow \lambda_i^\star = 0$（余裕のある制約の乗数は 0）」と読む。SVM ではこれが「マージンから離れた点は解に寄与しない」という**疎性**に直結する。

双対を考える利点は四つある。(1) **制約が簡単になる**：SVM では $d+1$ 個の変数と n 本の不等式が、n 個の変数と箱制約 1 組＋等式 1 本に変わる。(2) **データが内積を通してしか現れない**：これにより第7章のカーネルによる置き換えが可能になる。(3) **解の構造が見える**：相補性条件から解が少数の点だけで決まることが分かる。(4) **次元と標本数の役割が入れ替わる**：主問題の規模は d、双対問題の規模は n で、$d \gg n$ の高次元データ（第5章）では双対のほうが圧倒的に小さい。

9.5　SVM の双対問題と支持ベクトル

9.5.1　双対問題の導出

道具が揃ったので、ハードマージン SVM 式 (9.3)の双対をとる。制約を標準形 $f_i(\boldsymbol{w},b) = 1 - y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \le 0$ に書き直し、乗数を $\alpha_i \ge 0$ とすると

$$L(\boldsymbol{w},b,\boldsymbol{\alpha}) = \frac{1}{2}\|\boldsymbol{w}\|^2 - \sum_{i=1}^n \alpha_i y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) + \sum_{i=1}^n \alpha_i. \tag{9.9}$$

L は $\boldsymbol{w}$ について凸（二次の係数行列が $\boldsymbol{I}_d \succeq 0$）、$b$ について線形だから、$g(\boldsymbol{\alpha}) = \inf_{\boldsymbol{w},b} L$ は停留条件で求まる。$\nabla_{\boldsymbol{w}} \frac{1}{2}\|\boldsymbol{w}\|^2 = \boldsymbol{w}$、$\nabla_{\boldsymbol{w}}(\boldsymbol{w}^\top \boldsymbol{x}_i) = \boldsymbol{x}_i$ より

$$\nabla_{\boldsymbol{w}} L = \boldsymbol{w} - \sum_{i=1}^n \alpha_i y_i \boldsymbol{x}_i = \boldsymbol{0} \iff \boldsymbol{w} = \sum_{i=1}^n \alpha_i y_i \boldsymbol{x}_i, \tag{9.10}$$

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^n \alpha_i y_i = 0 \iff \sum_{i=1}^n \alpha_i y_i = 0. \tag{9.11}$$

式 (9.10)はきわめて重要で、**最適な重みベクトルは訓練点の線形結合になる**ことを述べている。これは第8章の表現定理の SVM における具体形である。式 (9.11)は下限が有限であるための条件でもある。実際 $\sum_i \alpha_i y_i \ne 0$ なら L は b について傾き $-\sum_i \alpha_i y_i \ne 0$ の一次関数なので $b \to \pm\infty$ で $-\infty$ に発散し、$g(\boldsymbol{\alpha}) = -\infty$ となる。

式 (9.10)と式 (9.11)を式 (9.9)に代入する。二次の項は

$$\frac{1}{2}\|\boldsymbol{w}\|^2 = \frac{1}{2}\Big(\sum_i \alpha_i y_i \boldsymbol{x}_i\Big)^\top \Big(\sum_j \alpha_j y_j \boldsymbol{x}_j\Big) = \frac{1}{2}\sum_{i=1}^n\sum_{j=1}^n \alpha_i\alpha_j y_i y_j\, \boldsymbol{x}_i^\top \boldsymbol{x}_j,$$

交差項は $b\sum_i \alpha_i y_i = 0$ を使うと

$$\sum_i \alpha_i y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) = \boldsymbol{w}^\top \sum_i \alpha_i y_i \boldsymbol{x}_i = \boldsymbol{w}^\top \boldsymbol{w} = \sum_{i,j} \alpha_i\alpha_j y_i y_j \boldsymbol{x}_i^\top \boldsymbol{x}_j.$$

よって $g(\boldsymbol{\alpha}) = \frac{1}{2}S - S + \sum_i \alpha_i$（$S$ は上の二重和）となり、次を得る。

定理 9.17 (ハードマージン SVM の双対問題)**.** 線形分離可能なデータに対し、式 (9.3)の双対問題は

$$\max_{\boldsymbol{\alpha}\in\mathbb{R}^n}\ W(\boldsymbol{\alpha}) \coloneqq \sum_{i=1}^{n}\alpha_i - \frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n}\alpha_i\alpha_j y_i y_j\, \boldsymbol{x}_i^{\top}\boldsymbol{x}_j \quad \text{s.t.} \quad \alpha_i \geq 0, \quad \sum_{i=1}^{n}\alpha_i y_i = 0 \tag{9.12}$$

である。制約はすべてアフィンで実行可能領域は空でない($\boldsymbol{\alpha}=\mathbf{0}$)から 定理 9.14により強双対性が成り立ち、$W(\boldsymbol{\alpha}^\star) = \frac{1}{2}\|\boldsymbol{w}^\star\|^2$。主解は $\boldsymbol{w}^\star = \sum_i \alpha_i^\star y_i \boldsymbol{x}_i$ で復元される。

行列で書くと見通しがよい。$K_{ij} = \boldsymbol{x}_i^{\top}\boldsymbol{x}_j$（線形カーネルの Gram 行列）、$\boldsymbol{Q} \coloneqq (\boldsymbol{y}\boldsymbol{y}^{\top}) \odot \boldsymbol{K}$（$\odot$ は成分ごとの積）とおけば

$$\max_{\boldsymbol{\alpha}}\ \mathbf{1}^{\top}\boldsymbol{\alpha} - \frac{1}{2}\boldsymbol{\alpha}^{\top}\boldsymbol{Q}\boldsymbol{\alpha} \quad \text{s.t.} \quad \boldsymbol{\alpha}\geq\mathbf{0},\ \boldsymbol{y}^{\top}\boldsymbol{\alpha} = 0. \tag{9.13}$$

$\boldsymbol{Q} = \boldsymbol{D}_y \boldsymbol{K} \boldsymbol{D}_y$（$\boldsymbol{D}_y = \mathrm{diag}(\boldsymbol{y})$）で $\boldsymbol{K}\succeq 0$ だから $\boldsymbol{Q}\succeq 0$、すなわち $-W$ は凸でこれも凸二次計画である。変数の個数は n であって d ではない。

9.5.2　支持ベクトルの疎性

定理 9.18 (支持ベクトル)**.** $(\boldsymbol{w}^\star, b^\star)$、$\boldsymbol{\alpha}^\star$ を主・双対の最適解とすると、各 i について

$$\alpha_i^\star\big(1 - y_i(\boldsymbol{w}^{\star\top}\boldsymbol{x}_i + b^\star)\big) = 0. \tag{9.14}$$

すなわち $\alpha_i^\star > 0 \Rightarrow y_i(\boldsymbol{w}^{\star\top}\boldsymbol{x}_i + b^\star) = 1$（点はマージン境界の上にある）、$y_i(\boldsymbol{w}^{\star\top}\boldsymbol{x}_i + b^\star) > 1 \Rightarrow \alpha_i^\star = 0$（マージンより外の点は解に寄与しない）。$\alpha_i^\star > 0$ の点を**支持ベクトル**（support vector, SV）と呼び、その添字集合を $\mathcal{S} = \{i : \alpha_i^\star > 0\}$ と書くと

$$\boldsymbol{w}^\star = \sum_{i\in\mathcal{S}} \alpha_i^\star y_i \boldsymbol{x}_i \tag{9.15}$$

と支持ベクトルだけの和になる。

証明. 主問題は凸計画でありすべての制約がアフィンなので、定理 9.14よりギャップは 0。したがって定理 9.16が適用でき、相補性条件式 (9.7)が $f_i(\boldsymbol{w}^\star, b^\star) = 1 - y_i(\boldsymbol{w}^{\star\top}\boldsymbol{x}_i + b^\star)$ に対して成り立つ。これが式 (9.14)である。二つの含意は積が 0 であることの言い換えにすぎない（後者は対偶をとればよい）。式 (9.15)は式 (9.10)で $\alpha_i^\star = 0$ の項を落としたもの。 ■

すなわち訓練後の判別関数は境界のすぐそばにある少数の点だけで決まり、マージンの外側の点はマージンを越えない限りいくら動かしても解は変わらない。すべての点が寄与する主成分分析とは対照的な性質であり、予測時の計算量が $|\mathcal{S}|$ に比例することを意味する。

$b^\star$ は次のように求める。支持ベクトル s に対し $y_s(\boldsymbol{w}^{\star\top}\boldsymbol{x}_s + b^\star) = 1$、$y_s^2 = 1$ を使って両辺に y_s を掛ければ $b^\star = y_s - \boldsymbol{w}^{\star\top}\boldsymbol{x}_s$。数値誤差を均すため、実際には $b^\star = |\mathcal{S}|^{-1}\sum_{s\in\mathcal{S}}\big(y_s - \sum_{i\in\mathcal{S}}\alpha_i^\star y_i \boldsymbol{x}_i^{\top}\boldsymbol{x}_s\big)$ と平均をとる。最終的な判別関数は

$$f(\boldsymbol{x}) = \boldsymbol{w}^{\star\top}\boldsymbol{x} + b^\star = \sum_{i\in\mathcal{S}} \alpha_i^\star y_i\, \boldsymbol{x}_i^{\top}\boldsymbol{x} + b^\star. \tag{9.16}$$

ここが決定的である。学習式 (9.12)にも予測式 (9.16)にも、データは**内積の形でしか現れない**。$\boldsymbol{w}^\star$ そのものを陽に持つ必要すらない。この事実が9.8節のカーネル化を可能にする。

例 9.19 (2 点の例：双対を手で解く)**.** $\boldsymbol{x}_1 = (0,0)^{\top}$ $(y_1 = -1)$、$\boldsymbol{x}_2 = (2,2)^{\top}$ $(y_2 = +1)$ とする。$\boldsymbol{K} = \left(\begin{smallmatrix}0&0\\0&8\end{smallmatrix}\right)$、$\boldsymbol{Q} = (\boldsymbol{y}\boldsymbol{y}^{\top})\odot\boldsymbol{K} = \left(\begin{smallmatrix}0&0\\0&8\end{smallmatrix}\right)$。等式制約 $-\alpha_1 + \alpha_2 = 0$ より $\alpha_1 = \alpha_2 = \alpha \geq 0$ で $W(\alpha) = 2\alpha - \frac{1}{2}\cdot 8\alpha^2 = 2\alpha - 4\alpha^2$。$W'(\alpha) = 2 - 8\alpha = 0$ より $\alpha^\star = 1/4$。よって $\boldsymbol{w}^\star = \alpha^\star(y_1\boldsymbol{x}_1 + y_2\boldsymbol{x}_2) = \frac{1}{4}(2,2)^{\top} = (\frac{1}{2},\frac{1}{2})^{\top}$、2 点とも支持ベクトルだから $b^\star = y_1 - \boldsymbol{w}^{\star\top}\boldsymbol{x}_1 = -1$。判別関数は $f(\boldsymbol{x}) = \frac{1}{2}(x_1 + x_2) - 1$、境界 $x_1 + x_2 = 2$ は 2 点の垂直二等分線であり、幾何マージン $1/\|\boldsymbol{w}^\star\| = \sqrt{2}$ は 2 点間距離 $2\sqrt{2}$ のちょうど半分である。双対の最適値 $W(\alpha^\star) = \frac{1}{4}$ は主の最適値 $\frac{1}{2}\|\boldsymbol{w}^\star\|^2 = \frac{1}{4}$ に一致し、強双対性が確認できる。

9.5.3　数値例：双対を自分で解いて `sklearn` と比べる

式 (9.13)は制約つき二次計画なので汎用ソルバで解ける。数式と実装の対応を見るために `scipy.optimize.minimize` の SLSQP で双対を直接解き、`sklearn.svm.SVC` と一致することを確かめる（リスト 9.1）。目的関数は最小化の形に直して $\frac{1}{2}\boldsymbol{\alpha}^{\top}\boldsymbol{Q}\boldsymbol{\alpha} - \mathbf{1}^{\top}\boldsymbol{\alpha}$、勾配は $\boldsymbol{Q}\boldsymbol{\alpha} - \mathbf{1}$ である。

リスト 9.1　SVM の双対問題を汎用ソルバで解き、`sklearn` と照合する。

```
import numpy as np
from scipy.optimize import minimize
```

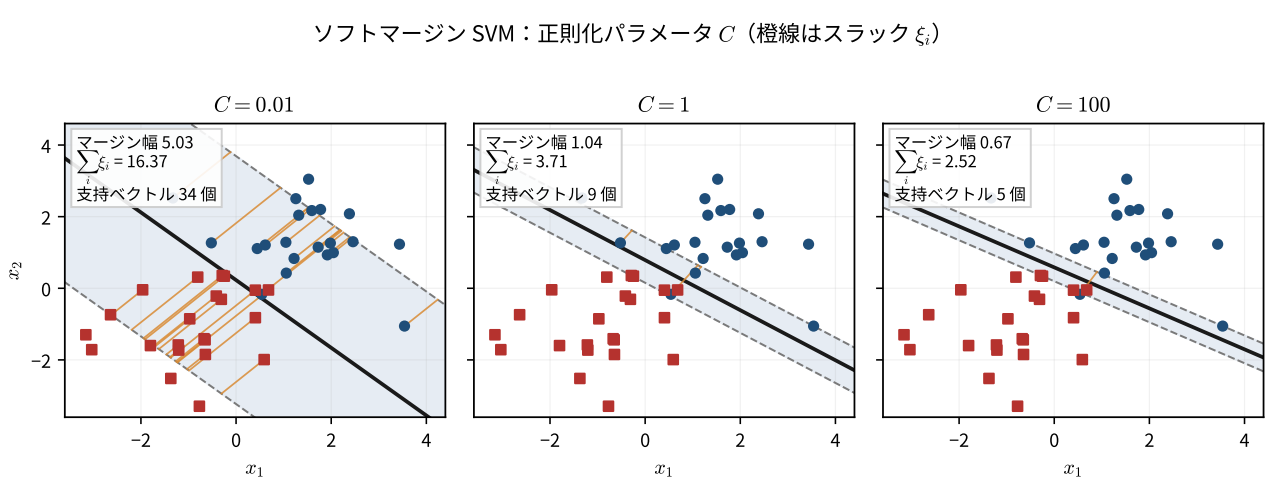


図9.2　ソフトマージン SVM における正則化パラメータ C の効果。C が小さいとマージンを広くとる代わりに多くの点がマージン領域に入り込み（スラック $\xi_i > 0$）、C が大きいとマージンは狭くなるが違反が減る。C はバイアスとバリアンスのトレードオフを制御している。

```
from sklearn.svm import SVC

def svm_dual(K, y, C):
    # max_a 1^T a - (1/2) a^T Q a  s.t. 0 <= a <= C, y^T a = 0
    Q = (y[:, None] * y[None, :]) * K            # Q_ij = y_i y_j K_ij
    fun = lambda a: 0.5 * a @ Q @ a - a.sum()    # 符号を反転して最小化
    jac = lambda a: Q @ a - np.ones(len(y))      # 勾配 Q a - 1
    cons = [{'type': 'eq', 'fun': lambda a: a @ y, 'jac': lambda a: y}]
    return minimize(fun, np.zeros(len(y)), jac=jac, bounds=[(0, C)] * len(y),
                    constraints=cons, method='SLSQP',
                    options={'maxiter': 500, 'ftol': 1e-12}).x

rng = np.random.default_rng(0)
X = np.vstack([rng.normal([-1.5, -1.0], 0.8, (20, 2)),
               rng.normal([1.5, 1.0], 0.8, (20, 2))]).T   # d×n : 列がサンプル
y, C = np.r_[-np.ones(20), np.ones(20)], 1.0

alpha = svm_dual(X.T @ X, y, C)              # 線形カーネル K = X^T X  (n×n)
w = X @ (alpha * y)                          # w = sum_i a_i y_i x_i  (d 次元)
free = (alpha > 1e-6) & (alpha < C - 1e-6)   # 0 < a_i < C の点だけで b を推定
b = np.mean(y[free] - X[:, free].T @ w)      # 列で選ぶ

clf = SVC(kernel='linear', C=C).fit(X.T, y)  # sklearn は n×d 規約なので転置
print(w, b)                                  # [1.0342 0.7114] -0.23586074
print(clf.coef_[0], clf.intercept_[0])       # sklearn と 8 桁一致
print(np.abs((X.T @ w + b) - clf.decision_function(X.T)).max())   # 2e-08
```

実行すると自作の $(\boldsymbol{w}, b) = (1.0342, 0.7114;\ -0.2359)$ が `sklearn` と小数点以下 8 桁まで一致し、判別関数値の最大差は 2×10^{-8} であった。α_i の多くはちょうど 0 になり、疎性が数値的にも確認できる。

9.6　ソフトマージン SVM

現実のデータは線形分離可能とは限らない。クラスが重なれば式 (9.3)の実行可能領域は空になり問題が定義できず、たとえ分離可能でも外れ値 1 点でマージンが極端に小さくなる。そこで制約を「破ってもよいが破った分だけ罰則を払う」形に緩める。各点に **スラック変数**（slack variable）$\xi_i \geq 0$ を導入して制約を $y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1 - \xi_i$ とする。$\xi_i = 0$ なら制約はもとのまま、$0 < \xi_i < 1$ ならマージン領域に入り込むが正しく分類され、$\xi_i > 1$ なら誤分類である。

定義 9.20（ソフトマージン SVM）. $C > 0$ を定数として

$$\min_{\boldsymbol{w}, b, \boldsymbol{\xi}} \ \frac{1}{2}\|\boldsymbol{w}\|^2 + C \sum_{i=1}^{n} \xi_i \quad \text{s.t.} \quad y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (i = 1, \ldots, n) \tag{9.17}$$

を**ソフトマージン SVM**（soft-margin SVM、C-SVM）という。

C は「マージンを広くとること」と「制約違反を減らすこと」の重みづけを決める。$C \to \infty$ でハードマージンに戻り、$C \to 0$ ではマージンを広げることだけを重視する（図 9.2）。

定理 9.21 (ソフトマージン SVM の双対問題)**.** 式 (9.17)の双対問題は

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{n} \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \boldsymbol{x}_i^{\top} \boldsymbol{x}_j \quad \text{s.t.} \quad 0 \le \alpha_i \le C, \quad \sum_i \alpha_i y_i = 0 \tag{9.18}$$

である。すなわちハードマージンの双対式 (9.12)に上限 $\alpha_i \le C$ （**箱制約**）が加わるだけで、目的関数はまったく同じ形をしている。

証明. 制約 $1 - \xi_i - y_i(\boldsymbol{w}^{\top}\boldsymbol{x}_i + b) \le 0$ に乗数 $\alpha_i \ge 0$、$-\xi_i \le 0$ に $\beta_i \ge 0$ を割り当てると

$$L = \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_i \xi_i + \sum_i \alpha_i\bigl(1 - \xi_i - y_i(\boldsymbol{w}^{\top}\boldsymbol{x}_i + b)\bigr) - \sum_i \beta_i \xi_i .$$

$\boldsymbol{w}$、b についての停留条件は前と同じで $\boldsymbol{w} = \sum_i \alpha_i y_i \boldsymbol{x}_i$、$\sum_i \alpha_i y_i = 0$。新たに

$$\frac{\partial L}{\partial \xi_i} = C - \alpha_i - \beta_i = 0 \quad \Longleftrightarrow \quad \beta_i = C - \alpha_i \tag{9.19}$$

が加わる。L は ξ_i について線形だから、係数が 0 でない限り下限は $-\infty$ であり、$g > -\infty$ には式 (9.19)が必要である。これを代入すると ξ_i を含む項は $(C - \alpha_i - \beta_i)\xi_i = 0$ と**完全に消え**、残りはハードマージンとまったく同じ計算になって $g(\boldsymbol{\alpha}) = \sum_i \alpha_i - \frac{1}{2}\sum_{i,j} \alpha_i \alpha_j y_i y_j \boldsymbol{x}_i^{\top}\boldsymbol{x}_j$。双対変数の制約は $\alpha_i \ge 0$ と $\beta_i = C - \alpha_i \ge 0$、すなわち $0 \le \alpha_i \le C$。$\boldsymbol{\beta}$ は目的関数から消えたので $\boldsymbol{\alpha}$ だけの問題が残る。制約はすべてアフィンで実行可能領域は空でない（$\boldsymbol{w} = \boldsymbol{0}$, $b = 0$, $\xi_i = 1$）から強双対性が成り立つ。 ■

驚くべき単純さである。スラック変数を n 個追加したのに、双対では「α_i に天井 C がついた」だけしか変わらない。$C \to \infty$ で箱制約が消えてハードマージンの双対に戻る。

9.6.1　支持ベクトルの三分類

ソフトマージンでは相補性条件が 2 組ある（$f(\boldsymbol{x}) = \boldsymbol{w}^{\top}\boldsymbol{x} + b$ と略記する）。

$$\alpha_i\bigl(1 - \xi_i - y_i f(\boldsymbol{x}_i)\bigr) = 0, \tag{9.20}$$

$$\beta_i \xi_i = (C - \alpha_i)\xi_i = 0. \tag{9.21}$$

定理 9.22 (支持ベクトルの三分類)**.** ソフトマージン SVM の最適解において、各 i は次のいずれかに属する。(a) $\alpha_i = 0$：式 (9.21)より $\xi_i = 0$（$C - \alpha_i = C > 0$）で、主実行可能性から $y_i f(\boldsymbol{x}_i) \ge 1$。**マージンの外側の正しく分類された点**であり解に寄与しない。(b) $0 < \alpha_i < C$：式 (9.21)より $\xi_i = 0$、式 (9.20)より $y_i f(\boldsymbol{x}_i) = 1$。**ちょうどマージン境界上の点**で、**自由支持ベクトル**（free support vector, free SV）と呼ぶ。(c) $\alpha_i = C$：式 (9.20)より $y_i f(\boldsymbol{x}_i) = 1 - \xi_i$ で ξ_i は 0 でなくてよい。**マージン領域の内側に入り込んだ点**（$0 < \xi_i \le 1$）または**誤分類された点**（$\xi_i > 1$）で、有界な支持ベクトル（bounded SV）と呼ぶ。逆向きにも $y_i f(\boldsymbol{x}_i) > 1 \Rightarrow \alpha_i = 0$、$y_i f(\boldsymbol{x}_i) < 1 \Rightarrow \alpha_i = C$ が成り立つ。

証明. (a)(b)(c) は 2 本の相補性条件と主実行可能性 $\xi_i \ge 0$, $y_i f(\boldsymbol{x}_i) \ge 1 - \xi_i$ を組み合わせただけである。逆向き：$y_i f(\boldsymbol{x}_i) > 1$ なら $\xi_i \ge 0$ より $1 - \xi_i - y_i f(\boldsymbol{x}_i) < 0$ だから式 (9.20)より $\alpha_i = 0$。$y_i f(\boldsymbol{x}_i) < 1$ なら主実行可能性から $\xi_i \ge 1 - y_i f(\boldsymbol{x}_i) > 0$ なので 式 (9.21)より $\alpha_i = C$。 ■

この三分類は実用的にも有益で、学習後に α_i を見ればどの点が境界を決めているか、どの点がマージンを侵しているかが分かる。b の計算には (b) の点だけを使う（9.5.2節の $\mathcal{S}$ を「$0 < \alpha_i < C$ の集合」に置き換える）。

b の計算にはどの点を使うか

$\alpha_i = C$ の点（マージン侵入・誤分類）では $y_i f(\boldsymbol{x}_i) = 1$ が成り立たないので、b の推定に含めてはならない。実装では $10^{-6} \le \alpha_i \le C - 10^{-6}$ のような閾値で選別する。$0 < \alpha_i < C$ の点が一つも存在しない（C が極端に小さいときに起こりうる）場合は、KKT 条件から b の許容区間を求めてその中点をとるなどの処理が必要になる。

C は第1章以来くり返し現れる正則化パラメータの一種で、9.7節で見るように $1/(2C)$ が正則化係数 λ に対応する。C が大きいと制約違反への罰が重く $\|\boldsymbol{w}\|$ が大きくなって判別関数が急峻になる（バリアンス大・バイアス小、過学習の傾向）。C が小さいと $\|\boldsymbol{w}\|$ の抑制を優先して多くの違反を許す（バイアス大・バリアンス小、過小適合の傾向）。実務では交差検証で選ぶ。

注意 9.23 (ν-SVM)**.** C は適切な大きさの見当がつきにくい。これを $[0, 1]$ の解釈しやすいパラメータに置き換えたのが ν-SVM で、$\min_{\boldsymbol{w},b,\boldsymbol{\xi},\rho} \frac{1}{2}\|\boldsymbol{w}\|^2 - \nu\rho + \frac{1}{n}\sum_i \xi_i$ s.t. $y_i(\boldsymbol{w}^{\top}\boldsymbol{x}_i + b) \ge \rho - \xi_i$、$\xi_i \ge 0$、$\rho \ge 0$ とマージン幅 ρ 自体を変数にする。このとき ν は**マージン誤り**（$\xi_i > 0$ **の点**）**の割合の上界**であり、同時に**支持ベクトルの割合の下界**であることが示される。C-SVM と ν-SVM は適切なパラメータ対応のもとで同じ解の族を与える。

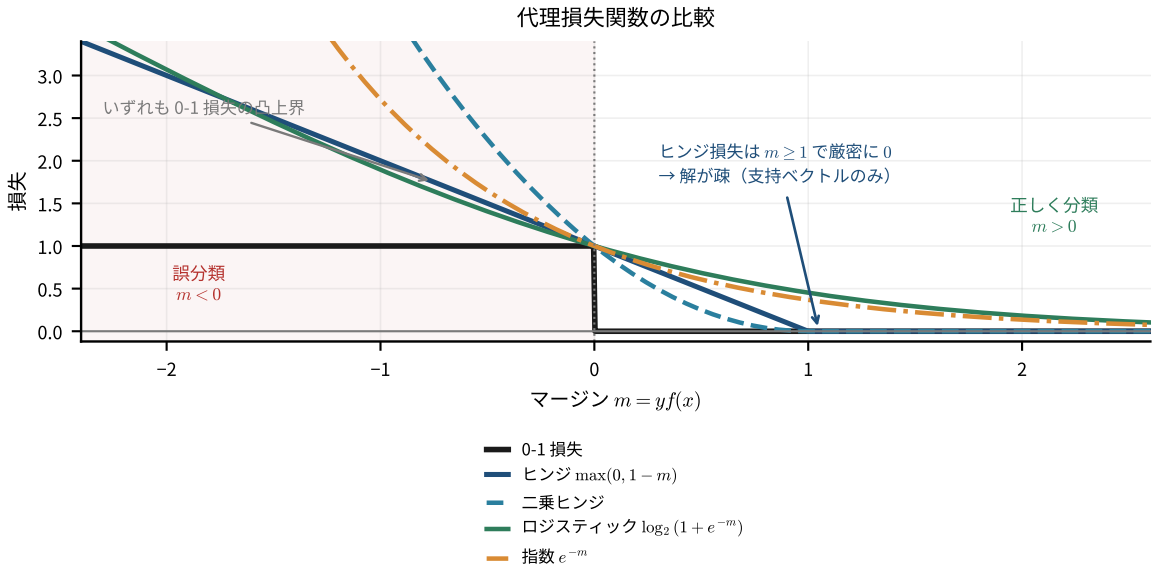


図9.3　代表的な分類損失をマージン $u = yf(\boldsymbol{x})$ の関数として比較したもの。いずれも 0-1 損失の凸上界になっているが、$u \geq 1$ でちょうど 0 になるのはヒンジ損失と二乗ヒンジ損失だけであり、この平坦部分が SVM の解の疎性を生む。

9.7　正則化リスク最小化としての SVM

ソフトマージン SVM は「マージン最大化＋制約の緩和」という幾何的な動機から出てきた特殊な問題に見える。しかし ξ_i を消去すると別の顔が現れる。

定理 9.24 (ヒンジ損失表現)**.** $f(\boldsymbol{x}) = \boldsymbol{w}^\top \boldsymbol{x} + b$ とする。式 (9.17)は制約なしの問題

$$\min_{\boldsymbol{w},b} \; C\sum_{i=1}^{n} \max\bigl(0,\; 1 - y_i f(\boldsymbol{x}_i)\bigr) + \frac{1}{2}\|\boldsymbol{w}\|^2 \tag{9.22}$$

と同値であり、両者の最適な $(\boldsymbol{w}, b)$ は一致する。両辺を C で割り $\lambda := \frac{1}{2C}$ とおけば

$$\min_{\boldsymbol{w},b} \; \sum_{i=1}^{n} \ell_{\mathrm{hinge}}\bigl(y_i, f(\boldsymbol{x}_i)\bigr) + \lambda\|\boldsymbol{w}\|^2, \qquad \ell_{\mathrm{hinge}}(y,t) := \max(0, 1 - yt) \tag{9.23}$$

という形になる。

証明. $(\boldsymbol{w}, b)$ を固定して $\boldsymbol{\xi}$ について最小化する。目的関数の $\boldsymbol{\xi}$ 依存部分は $C\sum_i \xi_i$ で、ξ_i どうしは独立、制約も $\xi_i \geq 0$、$\xi_i \geq 1 - y_i f(\boldsymbol{x}_i)$ と各 i ごとに分離している（第 2 の不等式は $y_i f(\boldsymbol{x}_i) \geq 1 - \xi_i$ の移項）。$C > 0$ だから ξ_i は小さいほどよく、2 本の下界の大きいほうで最小値をとる：$\xi_i^\star = \max(0, 1 - y_i f(\boldsymbol{x}_i))$。これを代入すると $\boldsymbol{\xi}$ 消去後の目的関数は $\frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_i \max(0, 1 - y_i f(\boldsymbol{x}_i))$ となる。一般に $\min_{u,v} F(u,v) = \min_u(\min_v F(u,v))$（下限の結合則）だから、$(\boldsymbol{w}, b, \boldsymbol{\xi})$ についての最小化は $(\boldsymbol{w}, b)$ についての式 (9.22)の最小化に等しい。逆に式 (9.22)の最適解に対し9.7節で $\boldsymbol{\xi}^\star$ を定めれば式 (9.17)の実行可能点で同じ目的値を与えるから、最適値も一致する。 ■

第　章の枠組みへの回収

式 (9.23)は、第1章で提示した正則化つき経験リスク最小化 $\min_f \frac{1}{n}\sum_i L(y_i, f(\boldsymbol{x}_i)) + \lambda\Omega(f)$ において、損失 L をヒンジ損失、正則化項 $\Omega(f)$ を $\|\boldsymbol{w}\|^2$（RKHS では $\|f\|_{\mathcal{H}}^2$）としたものである。マージン最大化という幾何的原理と、正則化つき経験リスク最小化という統計的原理がここで完全に一致した。$\|\boldsymbol{w}\|^2$ による正則化は「マージンを広くとる」ことと同義だったのである。

分類の本来の目的は誤分類率、すなわち **0-1 損失** $\ell_{01}(y,t) = \mathbf{1}\{yt \leq 0\}$ の期待値を小さくすることだが、ℓ_{01} は非凸かつ不連続でその経験リスク最小化は NP 困難である。そこで凸な**代理損失** (surrogate loss) で置き換える。代表的なものを $u = yf(\boldsymbol{x})$ の関数として並べると、0-1 が $\mathbf{1}\{u \leq 0\}$、ヒンジが $\max(0, 1-u)$、ロジスティックが $\log_2(1+e^{-u})$、指数が e^{-u}、二乗ヒンジが $\max(0,1-u)^2$ である（図 9.3）。

命題 9.25 (ヒンジ損失は 0-1 損失の凸上界)**.** すべての $u \in \mathbb{R}$ で $\mathbf{1}\{u \leq 0\} \leq \max(0, 1-u)$ が成り立ち、右辺は u の凸関数である。

証明. $u \le 0$ のとき左辺は 1、右辺は $1-u \ge 1$。$u > 0$ のとき左辺は 0、右辺は ≥ 0。凸性は、max が凸関数（定数関数 0 とアフィン関数 $1-u$）の上限であることによる。実際 h_1, h_2 が凸なら $h = \max(h_1, h_2)$ について $h(tz_1 + (1-t)z_2) = \max_k h_k(tz_1 + (1-t)z_2) \le \max_k (t h_k(z_1) + (1-t)h_k(z_2)) \le t h(z_1) + (1-t)h(z_2)$。 ■

この上界性により、ヒンジ損失の経験リスクを小さくすれば訓練誤分類率もそれ以下に抑えられる。ヒンジ損失は 0-1 損失に対して分類キャリブレーションされており、無限標本極限では Bayes 最適な符号を復元することが知られている。

ヒンジ損失に固有の性質は、$u \ge 1$ で恒等的に 0 であり微分も 0 になることである。十分正しく分類された点は勾配に寄与せず、双対では $\alpha_i = 0$ となる（定理 9.22(a)）。一方ロジスティック損失や指数損失は $u \to \infty$ で 0 に**漸近**するだけで決して 0 にならないので、すべての点が解に寄与し疎性は生じない。**この平坦部分こそが SVM の疎性の源**である。

注意 9.26 (ロジスティック回帰との比較)**.** ロジスティック回帰は $\ell(u) = \log(1 + e^{-u})$ を損失とする。相違点は四つある。$\mathbb{P}(y = 1 \mid \boldsymbol{x}) = \sigma(f(\boldsymbol{x}))$ を直接モデル化するので**確率出力**が得られる（SVM の $f(\boldsymbol{x})$ は符号つき距離であって確率ではなく、Platt スケーリング等で後付けの校正を要する）。**疎性**は SVM のみがもち、ロジスティック回帰は全点が寄与する。**分離可能なとき**ロジスティック回帰は正則化がないと $\|\boldsymbol{w}\| \to \infty$ で発散するが、SVM は有限の最大マージン解に収束する。**外れ値への感受性**は損失の増大の速さで決まり、SVM（線形）、ロジスティック（ほぼ線形）、指数損失（AdaBoost、指数的）の順に敏感になる。

9.8　カーネル SVM

9.5節で強調したように、双対問題式 (9.18)と判別関数式 (9.16)にはデータが内積の形でしか現れない。そこで第7章の正定値カーネル $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ を用意し、$\boldsymbol{x}_i^\top \boldsymbol{x}_j$ をすべて $k(\boldsymbol{x}_i, \boldsymbol{x}_j)$ に置き換える。

SVM の成立

歴史的な順序も本章の論理の順序とほぼ同じである。マージン最大化に基づく分類器を最適化問題として定式化し、双対側で内積をカーネルに置き換えるという着想を示したのが Boser–Guyon–Vapnik [16]（1992 年、COLT）である。線形分離可能でないデータに対するスラック変数の導入——本章の 9.6節のソフトマージン——と **support-vector network** という名称は Cortes–Vapnik [25]（1995 年）による。統計的学習理論の側からの体系的な位置づけは Vapnik [79] にまとめられている。つまり「カーネル化」は後付けの拡張ではなく、最初の論文から双対表示と一体で提案されていた。

定義 9.27 (カーネル SVM)**.** $K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j)$ とする。**カーネル SVM** とは

$$\max_{\boldsymbol{\alpha}} \ \sum_{i} \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \, k(\boldsymbol{x}_i, \boldsymbol{x}_j) \quad \text{s.t.} \quad 0 \le \alpha_i \le C, \ \sum_i \alpha_i y_i = 0 \tag{9.24}$$

を解き、判別関数を

$$f(\boldsymbol{x}) = \sum_{i \in \mathcal{S}} \alpha_i y_i \, k(\boldsymbol{x}_i, \boldsymbol{x}) + b, \qquad b = \frac{1}{|\mathcal{S}_{\mathrm{free}}|} \sum_{s \in \mathcal{S}_{\mathrm{free}}} \Big(y_s - \sum_{i \in \mathcal{S}} \alpha_i y_i k(\boldsymbol{x}_i, \boldsymbol{x}_s) \Big) \tag{9.25}$$

とするものである（$\mathcal{S}_{\mathrm{free}} = \{ i : 0 < \alpha_i < C \}$）。

これが正当な手続きであることは二通りに理解できる。第一に、k が正定値なら特徴写像 $\phi : \mathcal{X} \to \mathcal{H}$ が存在して $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \phi(\boldsymbol{x}), \phi(\boldsymbol{x}') \rangle_{\mathcal{H}}$ と書けるから（第7章）、カーネル SVM は $\mathcal{H}$ における線形 SVM そのものである。$\boldsymbol{K} \succeq 0$ より $\boldsymbol{Q} = \boldsymbol{D}_y \boldsymbol{K} \boldsymbol{D}_y \succeq 0$ なので式 (9.24)はやはり凸二次計画である。第二に、主問題側から見るとこれは RKHS 上の正則化リスク最小化 $\min_{f \in \mathcal{H}, b} C \sum_i \max(0, 1 - y_i(f(\boldsymbol{x}_i) + b)) + \frac{1}{2}\|f\|_{\mathcal{H}}^2$ であり、第8章の**表現定理**によって最適解は $f = \sum_i c_i k(\boldsymbol{x}_i, \cdot)$ の形をとる。SVM ではさらに KKT 条件が $c_i = \alpha_i y_i$ かつ多くの c_i が 0 であることを言っている。表現定理は「有限次元に落ちる」ことを保証し、相補性条件は「そのうえ疎になる」ことを保証する、という関係である。

例 9.28 (2×2 の Gram 行列で手計算)**.** $\mathcal{X} = \mathbb{R}$、$x_1 = 0$ ($y_1 = -1$)、$x_2 = 1$ ($y_2 = +1$)、ガウスカーネル $k(x, x') = \exp(-\gamma(x - x')^2)$、$\gamma = \log 2$ とする。$k(x_1, x_2) = e^{-\log 2} = 1/2$ だから $\boldsymbol{K} = \left(\begin{smallmatrix} 1 & 1/2 \\ 1/2 & 1 \end{smallmatrix}\right)$、$\boldsymbol{Q} = \left(\begin{smallmatrix} 1 & -1/2 \\ -1/2 & 1 \end{smallmatrix}\right)$。等式制約から $\alpha_1 = \alpha_2 = \alpha$ で $W(\alpha) = 2\alpha - \frac{1}{2}(\alpha^2 - \alpha^2/2 - \alpha^2/2 + \alpha^2) = 2\alpha - \frac{1}{2}\alpha^2$。$W'(\alpha) = 2 - \alpha = 0$ より $\alpha^\star = 2$（$C \ge 2$ なら箱制約に触れない）。判別関数は $f(x) = 2(-1)k(0, x) + 2(+1)k(1, x) + b = 2(e^{-\gamma(x-1)^2} - e^{-\gamma x^2}) + b$。$b$ は x_1 が支持ベクトルであることから $f(0) = -1$ で決まり、$f(0) = 2(\frac{1}{2} - 1) + b = -1 + b$ より $b = 0$。検算すると $f(1) = 2(1 - \frac{1}{2}) = 1$ で、もう一方の点でも $y_2 f(x_2) = 1$ が成り立つ。また $\frac{1}{2}\|f\|_{\mathcal{H}}^2 = \frac{1}{2}\boldsymbol{\alpha}^\top \boldsymbol{Q} \boldsymbol{\alpha} = \frac{1}{2}(4 - 2 - 2 + 4) = 2$ と $W(\alpha^\star) = 4 - 2 = 2$ が一致し、強双対性も確認できる。

RBF（ガウス）カーネル $k(\boldsymbol{x}, \boldsymbol{x}') = \exp(-\gamma \|\boldsymbol{x} - \boldsymbol{x}'\|^2)$ では調整すべきハイパーパラメータが γ と C の 2 つになる。役割は異なり、γ は特徴写像そのもの（＝仮説空間 $\mathcal{H}$）を決め、C はその中でどれだけ複雑な f を許すかを決める。両者は独立でないので、対数スケールで $\gamma \in \{10^{-3}, \dots, 10^{1}\}$、$C \in \{10^{-2}, \dots, 10^{3}\}$ 程度の**二次元グリッド**を交差検証にかけるのが標準である。

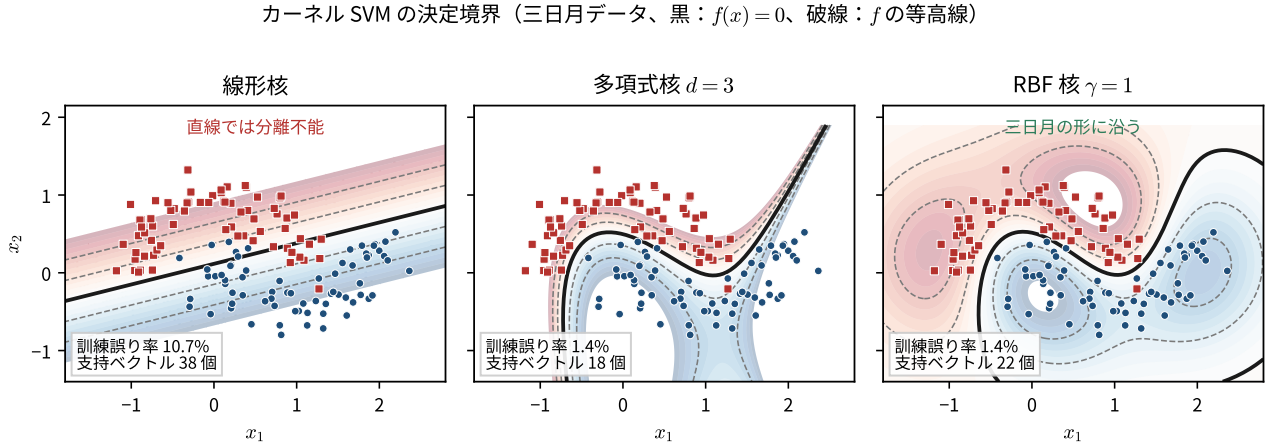


図9.4　カーネル SVM の決定境界。線形カーネルでは三日月形のデータを分離できないが、多項式カーネルと RBF カーネルは曲がった境界を実現する。等高線は決定関数 $f(\boldsymbol{x})$ の値で、$f=\pm1$ の等高線がマージン境界に対応する。

カーネルの選択が決定境界をどう変えるかは図 9.4に見える。線形カーネルでは三日月形のデータを分離できないが、多項式カーネルと RBF カーネルは曲がった境界を実現する。等高線が決定関数 $f(\boldsymbol{x})$ の値で、$f=\pm1$ の線がマージンの縁である。

リスト 9.2　RBF カーネル SVM を双対から自前で解き、`sklearn` と照合する。

```python
from sklearn.datasets import make_moons

def rbf_kernel(A, B, gamma):
    # A: d×n_A, B: d×n_B（列がサンプル）→ 返り値は n_A×n_B
    sq = (A**2).sum(0)[:, None] + (B**2).sum(0)[None, :] - 2 * A.T @ B
    return np.exp(-gamma * sq)

X, y01 = make_moons(n_samples=100, noise=0.25, random_state=0)
X = X.T                                  # make_moons は n×d なので転置
y, (gamma, C) = 2.0 * y01 - 1.0, (1.0, 5.0)   # ラベルを {-1,+1} に

K = rbf_kernel(X, X, gamma)
alpha = svm_dual(K, y, C)                # リスト 8.1 の関数をそのまま使う
sv, free = alpha > 1e-6, (alpha > 1e-6) & (alpha < C - 1e-6)
b = np.mean(y[free] - (alpha * y) @ K[:, free])
f_mine = (alpha * y) @ K + b             # 式 (9.25) の f(x_i)

clf = SVC(kernel='rbf', gamma=gamma, C=C).fit(X.T, y)  # sklearn は n×d 規約なので転置
print(sv.sum(), clf.n_support_.sum())                  # 21 21
print(np.abs(f_mine - clf.decision_function(X.T)).max())   # 8e-04
```

実行すると支持ベクトル数はどちらも 21（全 100 点中）、決定関数の最大差は 8×10^{-4} であった（SLSQP の収束精度による）。100 点のうち 21 点だけで境界が決まっていることが疎性の実例である。

$\gamma\to\infty$ の危険

ガウスカーネルの Gram 行列は $\boldsymbol{x}_i$ がすべて相異なれば正則である。$\gamma\to\infty$ では $\boldsymbol{K}\to\boldsymbol{I}_n$ に近づき、双対問題は $\max_{\boldsymbol{\alpha}}\sum_i\alpha_i-\frac{1}{2}\sum_i\alpha_i^2$ に退化して $\alpha_i\to\min(1,C)$、判別関数は各訓練点の近傍にだけ立つ「針の山」になる。このとき訓練データは（C が十分大きければ）**必ず**完全に分離できるが、新しい点はほぼすべて $f(\boldsymbol{x})\approx b$ と判定され汎化しない。「訓練誤差 0」は良い分類器の証拠にならないという典型例である。目安としては $\gamma\approx1/(d\cdot\mathrm{Var}[x])$（`sklearn` の `gamma='scale'`）あたりから探索を始めるとよい。

9.9　最適化アルゴリズム

双対問題式 (9.24)は変数 n 個の凸二次計画だが、行列 $\boldsymbol{Q}$ は $n\times n$ の密行列なので n が 10^5 を超えるとメモリにすら載らず、汎用 QP ソルバは使えない。座標降下（1 変数ずつ更新）を試みるとすぐ壁にぶつかる。等式制約 $\sum_i\alpha_iy_i=0$ があるため α_1 だけを動かすと制約が破れるのである。**最小の**動かせる単位は 2 変数で、これが **SMO**（sequential minimal optimization）の出発点である。

α_p,α_q の 2 つだけを変数として他を固定すると、等式制約から $\alpha_py_p+\alpha_qy_q=-\sum_{i\neq p,q}\alpha_iy_i$（定数）なので α_q は α_p の一次関数として決まる。代入すると目的関数は α_p の**一変数二次関数**になり、その頂点は解析的に求まる。あとは箱制約が α_p に課す区間 $[L,H]$ に切り詰めればよい。行列演算も反復解法も不要で、四則演算だけで 1 ステップが終わる。

アルゴリズムの骨格はこうである。(1) $\boldsymbol{\alpha} \leftarrow \mathbf{0}$、$b \leftarrow 0$ で初期化する。(2) KKT 条件の違反量、すなわち「$\alpha_i < C$ かつ $y_i f(\boldsymbol{x}_i) < 1-\varepsilon$」または「$\alpha_i > 0$ かつ $y_i f(\boldsymbol{x}_i) > 1+\varepsilon$」を調べ、もっとも大きく違反する添字 p を選ぶ。(3) p と組む q を、更新量 $|E_p - E_q|$（$E_i = f(\boldsymbol{x}_i) - y_i$ は誤差）が最大になるように選ぶ（ヒューリスティック）。(4) α_p, α_q の 2 変数部分問題を解析的に解いて更新し、区間 $[L, H]$ に切り詰めたうえで b を KKT 条件から更新する。(5) すべての i が精度 ε で KKT 条件を満たすまで (2) に戻る。

各反復で目的関数は単調に増加し収束が保証される。$\boldsymbol{Q}$ 全体を保持せず必要な行だけをその都度計算する（あるいはキャッシュする）のでメモリは $O(n)$ で済む。`libsvm`（したがって `sklearn.svm.SVC`）はこの方式の改良版を実装しており、計算量は経験的に $O(n^2) \sim O(n^3)$ 程度である。n が 10^6 を超えると $O(n^2)$ でも重すぎるが、カーネルを使わず線形 SVM に限れば主問題式 (9.22)を直接扱う方法がある。**双対座標降下**では、線形カーネルなら $\boldsymbol{w} = \sum_i \alpha_i y_i \boldsymbol{x}_i$ を明示的に保持できるので α_i を 1 つ更新するコストが $O(d)$（疎ベクトルなら非零成分数）になる。等式制約は b を $\boldsymbol{x}$ に定数 1 を追加して吸収すれば消えるので 1 変数ずつ更新できる。これが `liblinear`（`sklearn.svm.LinearSVC`）の中核である。もう一つの **Pegasos**（確率的劣勾配法）は、目的関数 $\frac{\lambda}{2}\|\boldsymbol{w}\|^2 + \frac{1}{n}\sum_i \max(0, 1 - y_i \boldsymbol{w}^\top \boldsymbol{x}_i)$ に対し各反復で 1 点 i をランダムに選び、学習率 $\eta_t = 1/(\lambda t)$ で劣勾配ステップ $\boldsymbol{w} \leftarrow (1-\eta_t\lambda)\boldsymbol{w} + \eta_t y_i \boldsymbol{x}_i \mathbf{1}\{y_i \boldsymbol{w}^\top \boldsymbol{x}_i < 1\}$ を行う。ε 精度に達するまでの反復数が $O(1/(\lambda\varepsilon))$ と n **に依存しない**のが特徴で、実装は数行で済む。

リスト 9.3　Pegasos（確率的劣勾配法）による線形 SVM の学習。

```python
def pegasos(X, y, lam, T, seed=0):
    # X は d×n（列がサンプル）。第 i サンプルは X[:, i]
    # min_w (lam/2)||w||^2 + (1/n) sum_i max(0, 1 - y_i w^T x_i)
    rng, w = np.random.default_rng(seed), np.zeros(X.shape[0])
    for t in range(1, T + 1):
        i, eta = rng.integers(len(y)), 1.0 / (lam * t)  # 学習率 1/(lambda t)
        if y[i] * (X[:, i] @ w) < 1:                    # ヒンジが有効な領域
            w = (1 - eta * lam) * w + eta * y[i] * X[:, i]
        else:                                           # 平坦な領域：正則化項のみ
            w = (1 - eta * lam) * w
    return w

Xb = np.vstack([X, np.ones(X.shape[1])])        # (d+1)×n : 定数行で b を吸収
lam = 1.0 / (C * len(y))                        # lam = 1/(Cn)
obj = lambda w: 0.5*lam*w@w + np.mean(np.maximum(0, 1 - y*(Xb.T@w)))
print(obj(pegasos(Xb, y, lam, T=200000)))   # 0.34134（最適値 0.34069）
```

$T = 2 \times 10^5$ 回の反復で目的値は 0.34134 となり、数値最適化で求めた最適値 0.34069 にほぼ到達している（差は 7×10^{-4} 程度で、確率的手法の収束の遅さを反映している）。

9.10　マージンによる汎化誤差の評価

9.1節では「境界が訓練点から遠いほどノイズに強い」という直感からマージン最大化を導入した。それが定理として裏づけられることを、証明の細部には立ち入らずに述べる（完全な証明には集中不等式と対称化の議論が必要で、本書の範囲を超える）。

データ $(\boldsymbol{x}, y)$ が未知の分布 P から独立に生成されるとし、f の**真のリスク**（汎化誤差）を $R(f) \coloneqq \mathbb{P}[y f(\boldsymbol{x}) \le 0]$ とする。単なる訓練誤差では過学習した f を見抜けないので、「余裕をもって正しいか」を要求する**マージン誤差** $\hat{R}_\rho(f) \coloneqq \frac{1}{n}\sum_i \mathbf{1}\{y_i f(\boldsymbol{x}_i) < \rho\}$（$\rho > 0$）を導入する。$\rho$ を大きくとるほど $\hat{R}_\rho$ は大きくなるので、「大きな ρ で $\hat{R}_\rho$ が小さい」ことは強い主張である。仮説集合の複雑さは次で測る。

定義 9.29 (Rademacher 複雑度)**.** $\sigma_1, \dots, \sigma_n$ を独立に $\mathbb{P}(\sigma_i = \pm 1) = 1/2$ に従う確率変数（Rademacher 変数）として、関数族 $\mathcal{F}$ の**経験 Rademacher 複雑度**を

$$\hat{\mathcal{R}}_n(\mathcal{F}) \coloneqq \mathbb{E}_{\boldsymbol{\sigma}}\left[\sup_{f \in \mathcal{F}} \frac{1}{n}\sum_{i=1}^{n} \sigma_i f(\boldsymbol{x}_i)\right] \tag{9.26}$$

で定め、その標本についての期待値 $\mathcal{R}_n(\mathcal{F}) = \mathbb{E}[\hat{\mathcal{R}}_n(\mathcal{F})]$ を Rademacher 複雑度という。

これは「でたらめな符号 $\boldsymbol{\sigma}$ に $\mathcal{F}$ の元がどれだけよく当てはまってしまうか」を測る量であり、$\mathcal{F}$ が豊かならランダムなラベルにも適合できてしまい大きくなる。

定理 9.30 (マージンに基づく汎化誤差限界；結果のみ)**.** $\mathcal{F}$ を有界な実数値関数族とする。任意の $\delta \in (0,1)$ に対し確率 $1-\delta$ 以上で、すべての $f \in \mathcal{F}$ と固定した $\rho > 0$ について

$$R(f) \;\le\; \hat{R}_\rho(f) + \frac{2}{\rho}\,\mathcal{R}_n(\mathcal{F}) + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \tag{9.27}$$

証明の骨子だけ述べる。まず 0-1 損失を、ρ 幅の傾斜をもつ区分線形関数 φ_ρ（$u \le 0$ で 1、$u \ge \rho$ で 0、その間は線形）で上から抑える。φ_ρ は Lipschitz 定数 $1/\rho$ をもつので、Talagrand の縮約補題により $\varphi_\rho \circ \mathcal{F}$ の Rademacher 複雑度は $\mathcal{F}$ のそれ

の $1/\rho$ 倍以下になる。次に一様大数の法則（McDiarmid の不等式＋対称化）を $\varphi_\rho \circ \mathcal{F}$ に適用すれば式 (9.27)を得る。係数 2 は対称化から、最後の項は McDiarmid の不等式からくる。

SVM の仮説集合は $\|f\|_{\mathcal{H}} \le B$ という RKHS の球であり、その複雑度は簡潔に評価できる。

定理 9.31 (RKHS 球の Rademacher 複雑度；結果のみ [73])**.** $\mathcal{F}_B = \{f \in \mathcal{H} : \|f\|_{\mathcal{H}} \le B\}$、Gram 行列を $\boldsymbol{K}$ とすると $\hat{\mathcal{R}}_n(\mathcal{F}_B) \le B\sqrt{\operatorname{tr}\boldsymbol{K}}/n$。

導出の筋はこうである。再生性 $f(\boldsymbol{x}_i) = \langle f, k(\cdot,\boldsymbol{x}_i)\rangle_{\mathcal{H}}$ より $\frac{1}{n}\sum_i \sigma_i f(\boldsymbol{x}_i) = \langle f, \frac{1}{n}\sum_i \sigma_i k(\cdot,\boldsymbol{x}_i)\rangle_{\mathcal{H}}$ であり、Cauchy–Schwarz の不等式から $\|f\|_{\mathcal{H}} \le B$ のもとでの上限は $\frac{B}{n}\|\sum_i \sigma_i k(\cdot,\boldsymbol{x}_i)\|_{\mathcal{H}}$。その期待値を Jensen の不等式で二乗平均に置き換えると、$\mathbb{E}[\sigma_i\sigma_j] = \delta_{ij}$ より $\mathbb{E}\|\sum_i \sigma_i k(\cdot,\boldsymbol{x}_i)\|_{\mathcal{H}}^2 = \sum_{i,j}\mathbb{E}[\sigma_i\sigma_j]K_{ij} = \operatorname{tr}\boldsymbol{K}$ となる。

高次元でも SVM が機能する理由

$k(\boldsymbol{x},\boldsymbol{x}) \le \kappa^2$ なら $\operatorname{tr}\boldsymbol{K} \le n\kappa^2$ だから、二つの定理を合わせて $R(f) \lesssim \hat{R}_\rho(f) + \frac{2B\kappa}{\rho\sqrt{n}} + 3\sqrt{\log(2/\delta)/(2n)}$。右辺に**入力次元 d が現れない**。効いているのはマージン ρ、RKHS ノルムの上界 B、カーネルの trace だけである。これが $d \gg n$ の高次元データ（第5章）や、$\mathcal{H}$ が無限次元になるガウスカーネルでも SVM が破綻しない理由である。

注意 9.32 (第5章との対比)**.** 第5章では標本共分散行列の固有値が d/n に応じて歪むこと、高次元では距離が集中して近傍が意味を失うことを見た。一見すると高次元では何もできないように思える。しかし式 (9.27)が示すのは、**予測**という目的に限れば次元そのものは障害ではないということである。鍵はマージンという「有効な複雑度」で仮説を測ることであり、パラメータ数 d で測るのが粗すぎたのである。すなわち ℓ_2 正則化が実質的な自由度を d からマージン依存の量に置き換えている。

もう一つ、SVM に固有の簡潔な評価がある。

定理 9.33 (LOO 誤差の支持ベクトル数による評価)**.** n 点で学習したハードマージン SVM の一個抜き交差検証誤差 $\hat{R}_{\mathrm{LOO}}$（定義 8.16；n 回の学習のうち除いた 1 点を誤る割合）は $\hat{R}_{\mathrm{LOO}} \le |\mathcal{S}|/n$（$|\mathcal{S}|$ は支持ベクトルの個数）を満たす。さらに $\hat{R}_{\mathrm{LOO}}$ の期待値は $n-1$ **点で学習した** SVM の期待汎化誤差に等しいので

$$\mathbb{E}\big[R(f_{n-1})\big] = \mathbb{E}\big[\hat{R}_{\mathrm{LOO}}(f_n)\big] \le \frac{\mathbb{E}[|\mathcal{S}|]}{n} \tag{9.28}$$

が成り立つ [79, 71]。ここで f_m は m 点で学習した判別関数、R は真の分布についての誤り率、期待値は訓練標本について取る。

証明の直感. $\alpha_j^\star = 0$ である点 $\boldsymbol{x}_j$ を訓練集合から取り除いても、残りの $\boldsymbol{\alpha}^\star$ は依然として（j を除いた）双対問題の KKT 条件をすべて満たす。すなわち解は変わらず判別関数も同一である。もとの解は $\boldsymbol{x}_j$ をマージンの外側で正しく分類していた（定理 9.22(a)）から、$\boldsymbol{x}_j$ を除いて学習した分類器も $\boldsymbol{x}_j$ を正しく分類する。つまり **LOO で誤りうるのは支持ベクトルだけ**であり、誤りの回数は $|\mathcal{S}|$ を超えない。厳密には「j を除いた問題の最適解が、もとの解の j 成分を落としたものに一致する」ことを双対問題の最適性から確認すればよい。ソフトマージンでも同様の議論が可能だが、$\alpha_j = C$ の点の扱いに注意が必要である。 ■

支持ベクトルが少ないほど汎化するというこの主張は、疎性が単なる計算上の利点ではなく統計的な意味をもつことを示している。リスト 9.2の例では 100 点中 21 点が支持ベクトルだったので LOO 誤差は 21% 以下と保証される（実際にはこれよりずっと小さい）。

「n 点の汎化誤差」ではなく「$n-1$ 点の汎化誤差」

(9.28)の左辺の添字に注意したい。LOO が不偏に推定するのは n 点で学習した分類器の汎化誤差ではなく、1 **点少ない** $n-1$ 点で学習した分類器の汎化誤差である（各回の学習が $n-1$ 点で行われるのだから当然である）。n が大きければ差は小さいが、n が数十の場面では無視できない。また不偏なのは**期待値**についてであって、個々のデータでの $\hat{R}_{\mathrm{LOO}}$ は分散が大きい——n 個の項が強く相関するためで、k 分割（$k < n$）のほうが分散が小さいことも多い。

9.11　回帰と一クラスへの拡張

同じ枠組みは回帰（$y_i \in \mathbb{R}$）にも移植できる。鍵は損失関数の取り替えで、ヒンジ損失の「平坦な部分が疎性を生む」性質を回帰で再現するには、誤差が小さいうちは損失を 0 にすればよい。

定義 9.34 (ε-不感損失と SVR)**.** $\varepsilon > 0$ に対し **ε-不感損失**（ε-insensitive loss）を $\ell_\varepsilon(y,t) \coloneqq \max(0, |y-t| - \varepsilon)$ と定める。**サポートベクター回帰**（support vector regression, SVR）は $\min_{\boldsymbol{w},b} C\sum_i \ell_\varepsilon(y_i, \boldsymbol{w}^\top\boldsymbol{x}_i + b) + \frac{1}{2}\|\boldsymbol{w}\|^2$ を解く手法である。

スラック変数を上側・下側の 2 組 $\xi_i, \xi_i^* \ge 0$ 導入して制約つきに書き直し、同じ手順で双対をとると、乗数 $\alpha_i, \alpha_i^* \in [0, C]$ について

$$\max_{\boldsymbol{\alpha},\boldsymbol{\alpha}^*} \; -\frac{1}{2}\sum_{i,j}(\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*)k(\boldsymbol{x}_i,\boldsymbol{x}_j) - \varepsilon\sum_i(\alpha_i + \alpha_i^*) + \sum_i y_i(\alpha_i - \alpha_i^*) \tag{9.29}$$

を $\sum_i(\alpha_i-\alpha_i^*)=0$、$0\le\alpha_i,\alpha_i^*\le C$ のもとで解く問題になる。予測は $f(\boldsymbol{x})=\sum_i(\alpha_i-\alpha_i^*)k(\boldsymbol{x}_i,\boldsymbol{x})+b$。相補性条件から ε 管（tube）$|y_i-f(\boldsymbol{x}_i)|<\varepsilon$ の内側の点では $\alpha_i=\alpha_i^*=0$ となり、やはり疎な解が得られる。ε は「どれだけの誤差を無視するか」、C は正則化の強さを制御する。第8章のカーネルリッジ回帰と比べると、SVR は疎性をもつ代わりに解析解をもたないという関係にある。

ラベルがない状況で「データの大部分を含む領域」を求めたいのが異常検知の設定である。**一クラス SVM**（one-class SVM）は特徴空間の原点をただ一つの「負例」とみなし、原点からできるだけ遠い超平面でデータを切り出す：$\min_{\boldsymbol{w},\rho,\boldsymbol{\xi}}\ \frac{1}{2}\|\boldsymbol{w}\|^2-\rho+\frac{1}{\nu n}\sum_i\xi_i$ s.t. $\langle\boldsymbol{w},\phi(\boldsymbol{x}_i)\rangle\ge\rho-\xi_i$、$\xi_i\ge0$。判定は $f(\boldsymbol{x})=\langle\boldsymbol{w},\phi(\boldsymbol{x})\rangle-\rho$ の符号で行い $f(\boldsymbol{x})<0$ を異常とする。$\nu\in(0,1]$ は ν-SVM と同様、異常と判定される点の割合の上界かつ支持ベクトル割合の下界を与える。ガウスカーネルを使えば、これはデータの台（support）の水準集合を推定する手続きとみなせる。

9.12　まとめ

出発点は「分離超平面が無数にあるとき、どれを選ぶか」という問いだった。「もっとも近い点までの距離を最大化する」という規準を立て、スケールを正準形式 (9.2)に固定すると、それは $\frac{1}{2}\|\boldsymbol{w}\|^2$ の最小化という凸二次計画に翻訳された。その双対をとることで、最適な重みが訓練点の線形結合で書けること、相補性条件からその和が**マージン境界上の少数の点だけ**に支えられていること（疎性）、データが内積の形でしか現れないため 第7章のカーネルにそのまま置き換えられることが、同時に得られた。主問題の規模は d、双対問題の規模は n であり、$d\gg n$ では双対が有利になる。ソフトマージン化はこの構造をほとんど壊さず、双対には箱制約 $\alpha_i\le C$ が加わるだけだった。さらにスラック変数を消去すると SVM は「ヒンジ損失＋ℓ_2 正則化」という正則化つき経験リスク最小化式 (9.23)に等しく、第1章で掲げた第一の統一的枠組みに正確に収まる。最後に、マージンに基づく汎化誤差限界は SVM の性能を支配するのが入力次元 d ではなくマージン ρ と RKHS ノルム B であることを示した。第5章で見た高次元の困難と、SVM が高次元で機能するという経験的事実は、この一点で整合する。

演習問題

演習 9.1 (2 点の SVM を手で解く (⋆))**.** $d=2$、$\boldsymbol{x}_1=(1,1)^\top$（$y_1=-1$）、$\boldsymbol{x}_2=(3,3)^\top$（$y_2=+1$）の 2 点からなるデータを考える。

(1) $\boldsymbol{K}=\boldsymbol{X}^\top\boldsymbol{X}$ と $\boldsymbol{Q}=(\boldsymbol{y}\boldsymbol{y}^\top)\odot\boldsymbol{K}$ を書き下せ。

(2) 等式制約 $\sum_i\alpha_i y_i=0$ で双対問題を 1 変数に帰着させ $\alpha^\star$ を求めよ（$C=\infty$）。

(3) $\boldsymbol{w}^\star$、$b^\star$、幾何マージンを求め、境界が 2 点の垂直二等分線になることと、主・双対の最適値が一致することを確かめよ。

演習 9.2 (点と超平面の距離 (⋆))**.** $\mathbb{R}^3$ において超平面 $H:\ 2x_1-x_2+2x_3=6$ と点 $\boldsymbol{z}=(1,1,1)^\top$ を考える。

(1) $\boldsymbol{z}$ から H までの距離を命題 9.2により求めよ。

(2) 正射影 $\boldsymbol{x}^\star$ を求め、$\boldsymbol{z}-\boldsymbol{x}^\star$ が法線ベクトルに平行であることを確認せよ。

(3) H を正準形に直すことと $\boldsymbol{w}$ のスケールを固定することの関係を説明せよ。

演習 9.3 (双対問題の導出 (⋆⋆))**.** ハードマージン SVM 式 (9.3)について、以下を自分の手で実行せよ。

(1) ラグランジュ関数 $L(\boldsymbol{w},b,\boldsymbol{\alpha})$ を書き下せ。

(2) L が $\boldsymbol{w}$ について凸であることを命題 9.9で示し、$\nabla_{\boldsymbol{w}}L=\boldsymbol{0}$ から $\boldsymbol{w}=\sum_i\alpha_i y_i\boldsymbol{x}_i$ を導け。

(3) $\partial L/\partial b=0$ から $\sum_i\alpha_i y_i=0$ を導き、この条件が破れるとき $g(\boldsymbol{\alpha})=-\infty$ となる理由を説明せよ。

(4) (2)(3) を L に代入して式 (9.12)を導け。途中で $\|\boldsymbol{w}\|^2=\sum_{i,j}\alpha_i\alpha_j y_i y_j\boldsymbol{x}_i^\top\boldsymbol{x}_j$ を使う箇所を明示せよ。

(5) $\boldsymbol{Q}\succeq0$ を示し、双対問題が凸最適化問題であることを確認せよ。

演習 9.4 (ソフトマージンとヒンジ損失の等価性 (⋆⋆))**.** (1) $(\boldsymbol{w},b)$ を固定したとき式 (9.17)の $\boldsymbol{\xi}$ に関する最小化が各 i について独立であることを説明し、$\xi_i^\star=\max(0,1-y_i f(\boldsymbol{x}_i))$ を導け。

(2) これを用いて定理 9.24を証明せよ。とくに $\min_{u,v}F=\min_u\min_v F$ という置き換えが正当である理由を述べよ。

(3) $\lambda=1/(2C)$ で式 (9.23)が得られることを確認し、分離可能な場合に $C\to\infty$ の極限がハードマージンに対応することを説明せよ。

(4) ヒンジ損失の劣微分 $\partial\ell(u)$ を求めよ（$u=1$ で微分不可能）。

演習 9.5 (KKT 条件から支持ベクトルの三分類を読む (⋆⋆))**.** ソフトマージン SVM の KKT 条件式 (9.20)、式 (9.21)、$\beta_i=C-\alpha_i$、$\alpha_i,\beta_i,\xi_i\ge0$ から出発して、

(1) $\alpha_i=0\Rightarrow y_i f(\boldsymbol{x}_i)\ge1$、$0<\alpha_i<C\Rightarrow y_i f(\boldsymbol{x}_i)=1$、$\alpha_i=C\Rightarrow y_i f(\boldsymbol{x}_i)\le1$ をそれぞれ導け。

(2) 逆に $y_i f(\boldsymbol{x}_i)>1\Rightarrow\alpha_i=0$、$y_i f(\boldsymbol{x}_i)<1\Rightarrow\alpha_i=C$ を導け。

(3) b の推定に $0 < \alpha_i < C$ の点しか使えない理由を述べ、そのような点が存在しないときに b が満たすべき不等式系を書き下せ。

(4) 誤分類点は必ず $\alpha_i = C$ であることを示し、誤分類数がスラックの和 $\sum_i \xi_i^\star$ で抑えられることを示せ。

演習 9.6 (2×2 のカーネル行列で双対を解く ($\star\star$))**.** $\mathcal{X} = \mathbb{R}$、$x_1 = -1$ ($y_1 = -1$)、$x_2 = +1$ ($y_2 = +1$)、ガウスカーネル $k(x, x') = \exp(-\gamma(x - x')^2)$ とし、$c \coloneqq k(x_1, x_2) = e^{-4\gamma} \in (0, 1)$ とおく。

(1) $\boldsymbol{K}$ と $\boldsymbol{Q}$ を c で表し、$\boldsymbol{Q} \succeq 0$ を確認せよ。

(2) $C = \infty$ の双対を解いて $\alpha^\star$ を c で表せ。

(3) 判別関数 $f(x)$ を求め、対称性から $b = 0$ であることを示せ。

(4) $\gamma \to \infty$ ($c \to 0$) と $\gamma \to 0$ ($c \to 1$) の極限で $\alpha^\star$ と $\|f\|_{\mathcal{H}}^2 = \boldsymbol{\alpha}^\top \boldsymbol{Q} \boldsymbol{\alpha}$ がどう振る舞うかを論じ、9.8節の warnbox の主張と対応させよ。

演習 9.7 (双対問題を解いて `sklearn` と照合する（実装、$\star\star$))**.** リスト 9.1を出発点として、次を実装せよ。

(1) `scipy.optimize.minimize`（SLSQP）か `cvxopt.solvers.qp` で 式 (9.18)を解く関数を書け。勾配 $\boldsymbol{Q}\boldsymbol{\alpha} - \mathbf{1}$ は解析的に与えること。

(2) `make_blobs` で 2 クラス・$n = 60$ のデータを作り $C = 1$ で解き、$\boldsymbol{w}, b$ が `SVC(kernel='linear')` と 10^{-6} 以内で一致することを確認せよ。

(3) α_i を大きい順に並べた図で疎性を確認し、$\alpha_i > 10^{-6}$ の個数を `clf.n_support_.sum()` と比べよ。

(4) C を 10^{-2} から 10^{2} まで対数的に変えて支持ベクトル数、$\|\boldsymbol{w}\|$、マージン、訓練誤差をプロットし、C の役割を考察せよ。

演習 9.8 (カーネル SVM とハイパーパラメータ探索（実装、$\star\star$))**.** (1) `make_moons(n_samples=200, noise=0.3)` に対し RBF カーネル SVM を $\gamma \in \{0.1, 0.3, 1, 3, 10, 30\}$、$C \in \{0.1, 1, 10, 100\}$ のグリッドで 5 分割交差検証し、精度をヒートマップで表示せよ。

(2) 最良の (γ, C)、$\gamma = 100$（過大）、$C = 0.01$（過小）の決定境界を等高線で描き比較せよ。

(3) γ を大きくすると訓練精度が 1 に近づき交差検証精度が下がることを数値で示せ（9.8節の warnbox の主張の確認）。

(4) 支持ベクトルの割合を (γ, C) の関数としてプロットせよ。さらに定理 9.33の上界を検証するために、**線形分離可能な**データ（たとえば `make_blobs` の 2 クラス、あるいは `make_moons(noise=0.15)`）に $C = 10^6$ のほぼハードマージン SVM を当て、n 回の再学習で LOO 誤差を実際に計算して支持ベクトル割合と比較せよ。このとき $\alpha_i = C$ となる点が存在しないこと（真にハードマージン解であること）を確認する必要がある。定理 9.33はハードマージンの LOO についての定理なので、有限 C のソフトマージンの k 分割交差検証誤差に当てはめてはならない。

第 10 章

ニューラルネットワークと万能近似定理

この章のねらい

第7章と第8章では特徴写像をカーネルの選択という形で人間が指定した。ニューラルネットワークは特徴写像そのものをデータから学習する。本章の中心は万能近似定理であり、1 隠れ層のネットワークが連続関数を一様に近似できることを、関数解析による証明と構成的証明の二通りで示す。あわせて、この定理が何を言っていて何を言っていないのかを明確にし、ReLU 網の近似率、深さの効果、Barron クラス、誤差逆伝播法までを扱う。[a]

[a] この章の計算は演習ノートブック `ch10_neural_network.ipynb` で再現できる。インストール不要で実行するには Google Colab で開く：
`https://colab.research.google.com/github/yusukeimoto/data-analysis-math-demos/blob/main/notebooks/ch10_neural_network.ipynb`

10.1　学習される特徴——第三の非線形化戦略

第1章で挙げた非線形化の三戦略は、(i) 明示的な特徴写像 $\boldsymbol{\phi}$ を書き下す、(ii) 内積 $k(\boldsymbol{x},\boldsymbol{x}') = \langle \boldsymbol{\phi}(\boldsymbol{x}), \boldsymbol{\phi}(\boldsymbol{x}') \rangle$ のみを指定して $\boldsymbol{\phi}$ を陽に扱わない（カーネル）、(iii) $\boldsymbol{\phi}$ を有限個のパラメータで表し、そのパラメータ自身をデータから決める、であった。本章は (iii) を扱う。

カーネル法の弱点は二つある。第一に、カーネル k すなわち特徴空間の形状を、データを見る前に人間が決めねばならない。「画像は平行移動しても同じ物体」といった構造を手書きのカーネルに翻訳するのは容易でない。第二に、第8章の表現定理により解は必ず $f = \sum_{i=1}^{n} \alpha_i k(\cdot, \boldsymbol{x}_i)$ の形をとり、基底 $k(\cdot,\boldsymbol{x}_i)$ は訓練点の位置に **固定**されている。動くのは係数だけであり、これは**線形近似**（linear approximation）である。ニューラルネットワークは基底 $\sigma(\boldsymbol{w}_j^{\top}\boldsymbol{x} + b_j)$ の向き $\boldsymbol{w}_j$ と位置 b_j も同時に選ぶ**非線形近似**（nonlinear approximation）であり、10.7節で見るようにこの違いが近似速度に本質的な差を生む。

本章の一行要約

ニューラルネットワークとは、リッジ関数 $\boldsymbol{x} \mapsto \sigma(\boldsymbol{w}^{\top}\boldsymbol{x} + b)$ を基底とし、係数だけでなく基底自身もデータから選ぶ関数近似器である。万能近似定理は「基底の族が十分豊かである」ことを保証するが、「少数の基底で足りる」ことも「最適化で見つかる」ことも保証しない。

10.2　モデルの定義

生物の神経細胞は多数の入力の重み付き和が閾値を超えたときに発火する。その極端に単純化したモデルが人工ニューロンである。

定義 10.1 (活性化関数と人工ニューロン)**. 活性化関数**（activation function）とは、入力の重み付き和に適用する関数 $\sigma : \mathbb{R} \to \mathbb{R}$ のことをいう。連続性・微分可能性・単調性はいずれも要求しない（ReLU は 0 で微分できず、GELU は単調でない）。重み $\boldsymbol{w} \in \mathbb{R}^d$、バイアス $b \in \mathbb{R}$、活性化関数 σ に対し、写像 $\boldsymbol{x} \mapsto \sigma(\boldsymbol{w}^{\top}\boldsymbol{x} + b)$ を**人工ニューロン**という。

定義として課すのは $\mathbb{R}$ から $\mathbb{R}$ への写像であることだけで、通常は**非線形**な σ を使う。恒等写像 $\sigma(t) = t$ も形式上は活性化関数だが、これだけを何層合成しても全体はアフィン写像のままで、非線形な表現力は得られない（演習 10.6で、恒等写像が判別的

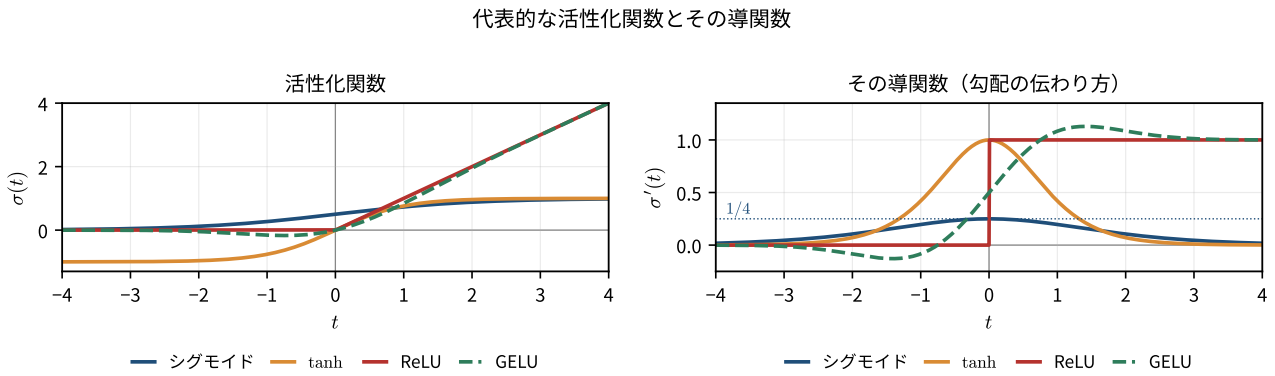


図10.1　代表的な活性化関数（左）とその導関数（右）。シグモイドの導関数は $t=0$ で最大値 $1/4$（点線）をとり両側で 0 に飽和する。tanh の導関数の最大値は 1 である。ReLU の導関数は $t>0$ で 1、$t<0$ で 0 の階段関数で、$t=0$ では微分できない。GELU は ReLU を滑らかにしたものだが単調ではなく、導関数が負になる区間がある。

でないことを確かめる）。なお10.4節の万能近似定理が扱うのは一般の活性化関数ではなく、両端で極限をもつ**シグモイド型**（定義 10.2）などの条件を満たすものに限られる。すなわち「活性化関数」⊃「シグモイド型活性化関数」という包含関係である。

この形の関数、すなわち 1 変数関数を 1 次形式に合成したものを**リッジ関数**（ridge function）という。$\boldsymbol{w}$ に直交する方向には定数で、$\boldsymbol{w}$ 方向にのみ変化する。代表的な活性化関数は次の通り。

シグモイド関数　$\sigma(t)=1/(1+e^{-t})$。値域 $(0,1)$、単調増加、有界、$\sigma'=\sigma(1-\sigma)\le 1/4$。

双曲線正接　$\tanh t = 2\,\mathrm{sigmoid}(2t)-1$。値域 $(-1,1)$、奇関数、$\sigma'\le 1$。

ReLU　**Rectified Linear Unit**（整流線形ユニット）の略で、$\sigma(t)=\max(t,0)=t_+$。有界でない。$t\neq 0$ で $\sigma'=\mathbf{1}\{t>0\}$。区分線形で、正の側で勾配が減衰しない。

GELU　**Gaussian Error Linear Unit** の略で、$\sigma(t)=t\Phi(t)$（Φ は標準正規の累積分布関数）。ReLU の滑らかな近似。

概形は図 10.1に示した。左は関数そのもの、右はその導関数である。シグモイドと tanh は両側で飽和して導関数が 0 に近づくのに対し、ReLU は正の側で導関数が 1 のまま一定である。この違いが深い網での勾配の伝わり方を左右する（10.8節）。GELU は $t\approx -0.75$ で最小値 -0.17 をとる非単調な関数で、導関数も負の値（最小 -0.13）をとる点で他の三つと異なる。

定義 10.2（シグモイド型関数）**.** 可測関数 σ が $\sigma(t)\to 1$ $(t\to+\infty)$、$\sigma(t)\to 0$ $(t\to-\infty)$ を満たすとき **シグモイド型**（sigmoidal）であるという。

階段関数 $\mathbf{1}\{t>0\}$ もシグモイド型である。tanh 自身はそうでないが $(\tanh t+1)/2$ がそうなので、以下の議論は tanh にも及ぶ。単調性も連続性も要求していない点に注意。

一方**可測性と（両端の極限から従う）有界性は落とせない**。可測でなければ以下の証明で現れる $\int \sigma(\lambda(\boldsymbol{w}^{\top}\boldsymbol{x}+b)+\varphi)\,\mathrm{d}\mu(\boldsymbol{x})$ が定義されず、有界でなければ優収束定理が使えない（どこでどう効くかは演習 10.6で確かめる）。$t\to\pm\infty$ での極限が存在することから σ は両側の外側で有界であり、可測な σ が有界区間上で非有界になる余地は残るので、以下では $\sup_t|\sigma(t)|<\infty$ も仮定する。

定義 10.3（1 隠れ層ネットワーク）**.** 幅（width）m の 1 隠れ層ネットワークの全体を

$$\mathcal{F}_m^{\sigma} \coloneqq \left\{ \boldsymbol{x}\mapsto \sum_{j=1}^{m} c_j\,\sigma(\boldsymbol{w}_j^{\top}\boldsymbol{x}+b_j) \;:\; c_j,b_j\in\mathbb{R},\ \boldsymbol{w}_j\in\mathbb{R}^d \right\},\qquad \mathcal{F}^{\sigma}\coloneqq\bigcup_{m\ge 1}\mathcal{F}_m^{\sigma}$$

と定める。

$\mathcal{F}_m^{\sigma}$ は m を固定すると線形空間ではないが、二つの元の和は幅が高々 $2m$ の元だから、和集合 $\mathcal{F}^{\sigma}$ は $C(\mathbb{R}^d)$ の線形部分空間である。この事実を10.4節で使う。

出力を次の層の入力にすれば深い網が得られる。これを定義として書いておく。

定義：多層パーセプトロン

$L\in\mathbb{N}$ と層幅 $n_0=d,n_1,\dots,n_L$ をとり、各 $l=1,\dots,L$ に対し $\boldsymbol{W}^{(l)}\in\mathbb{R}^{n_l\times n_{l-1}}$、$\boldsymbol{b}^{(l)}\in\mathbb{R}^{n_l}$ とする。活性化関数 σ

（定義 10.1）を成分ごとに作用させる記法で

$$\begin{aligned} \boldsymbol{h}^{(0)} &= \boldsymbol{x}, \\ \boldsymbol{z}^{(l)} &= \boldsymbol{W}^{(l)}\boldsymbol{h}^{(l-1)} + \boldsymbol{b}^{(l)} \qquad (l = 1, \dots, L), \\ \boldsymbol{h}^{(l)} &= \sigma\big(\boldsymbol{z}^{(l)}\big) \qquad\qquad (l = 1, \dots, L-1), \\ f_{\boldsymbol{\theta}}(\boldsymbol{x}) &= \boldsymbol{z}^{(L)} \end{aligned} \tag{10.1}$$

で定まる写像 $f_{\boldsymbol{\theta}} : \mathbb{R}^{n_0} \to \mathbb{R}^{n_L}$ を L 層の**全結合順伝播ニューラルネットワーク**、または**多層パーセプトロン**（multilayer perceptron, MLP）という。$\boldsymbol{\theta} = \{\boldsymbol{W}^{(l)}, \boldsymbol{b}^{(l)}\}_{l=1}^{L}$ を**パラメータ**、$n_1, \dots, n_{L-1}$ を**隠れ層の幅**という。

ニューラルネットワークには畳み込み網・再帰型網・Transformer など多くの種類があるが、本章ではそのうち最も基本的な MLP を扱う。以下、特に断らない限り「ニューラルネットワーク」はこのモデルを指す。式 (10.1)の各層はアフィン変換と活性化の二段に分け、前者の出力 $\boldsymbol{z}^{(l)}$ を**事前活性**（pre-activation）、後者の出力 $\boldsymbol{h}^{(l)}$ を **活性**（activation）と呼ぶ。$\boldsymbol{h}^{(l-1)} \to \boldsymbol{z}^{(l)} \to \boldsymbol{h}^{(l)}$ と書いておくと、10.8節の誤差逆伝播がこの二段構造の逆向きの再帰としてそのまま書ける（微分に現れるのは $\sigma'(\boldsymbol{z}^{(l)})$ であって、$\boldsymbol{h}^{(l)}$ だけからは一般に復元できない。$\sigma = \tanh$ なら $\sigma'(z) = 1 - \sigma(z)^2 = 1 - h^2$ と活性だけで書けるが、これは特殊な事情である）。第1章の枠組みで読めば $\boldsymbol{\phi}(\boldsymbol{x}) := \boldsymbol{h}^{(L-1)}$ が学習される特徴写像で、最終層はその上の線形モデルである。$\boldsymbol{\phi}$ を固定して最終層だけ解くのがカーネル法（凸問題）、$\boldsymbol{\phi}$ も一緒に動かすのがニューラルネットワーク（非凸問題）である。

例 10.4 (パラメータ数)**.** 層幅 $(n_0, \dots, n_L)$ のときパラメータ数は $P = \sum_{l=1}^{L}(n_{l-1}n_l + n_l)$。$d = 784$、隠れ 2 層で幅 256、出力 10 なら $P = 200{,}960 + 65{,}792 + 2{,}570 = 269{,}322$。同じ入出力を幅 m の 1 隠れ層で作ると $P = 795m + 10$ で、$m = 339$ が同程度である。同じ予算を「浅く広く」使うか「深く狭く」使うか——これが10.6節の主題である。

10.3　表現力の問い：XOR から万能性へ

隠れ層のないモデル $f(\boldsymbol{x}) = \operatorname{sign}(\boldsymbol{w}^{\top}\boldsymbol{x} + b)$ を**パーセプトロン**という。1969 年に Minsky と Papert が指摘した次の事実が、この分野の転換点となった。

命題 10.5 (XOR の表現不可能性)**.** $\boldsymbol{x}_1 = (0,0)^{\top}$, $\boldsymbol{x}_2 = (0,1)^{\top}$, $\boldsymbol{x}_3 = (1,0)^{\top}$, $\boldsymbol{x}_4 = (1,1)^{\top}$ にラベル $y_1 = y_4 = 0$, $y_2 = y_3 = 1$ を与える。このとき任意のアフィン関数 $g(\boldsymbol{x}) = \boldsymbol{w}^{\top}\boldsymbol{x} + b$ について $g(\boldsymbol{x}_2), g(\boldsymbol{x}_3) > 0 > g(\boldsymbol{x}_1), g(\boldsymbol{x}_4)$ となることはない。

証明. g がアフィンなら凸結合について $g(\sum \lambda_i \boldsymbol{x}_i) = \sum \lambda_i g(\boldsymbol{x}_i)$ が成り立つ。$g(\boldsymbol{x}_2), g(\boldsymbol{x}_3) > 0$ なら $g(\tfrac{1}{2}\boldsymbol{x}_2 + \tfrac{1}{2}\boldsymbol{x}_3) > 0$、$g(\boldsymbol{x}_1), g(\boldsymbol{x}_4) < 0$ なら $g(\tfrac{1}{2}\boldsymbol{x}_1 + \tfrac{1}{2}\boldsymbol{x}_4) < 0$。ところが $\tfrac{1}{2}\boldsymbol{x}_2 + \tfrac{1}{2}\boldsymbol{x}_3 = (\tfrac{1}{2}, \tfrac{1}{2}) = \tfrac{1}{2}\boldsymbol{x}_1 + \tfrac{1}{2}\boldsymbol{x}_4$ であり、同じ点での g の値が正かつ負となって矛盾する。 ■

幾何的には、ラベル 1 の 2 点を結ぶ線分とラベル 0 の 2 点を結ぶ線分が正方形の対角線どうしで交わっている。線形分離可能性とは二つのクラスの凸包が交わらないことであった（第9章）。隠れ層はこの状況を座標変換によって解消する。

例 10.6 (XOR を解く 1 隠れ層ネットワーク)**.** σ を階段関数 $\mathbf{1}\{t > 0\}$ とし、$\boldsymbol{w}_1 = \boldsymbol{w}_2 = (1,1)^{\top}$、$b_1 = -1/2$、$b_2 = -3/2$、$c_1 = 1$、$c_2 = -1$ とおく。すなわち

$$f(\boldsymbol{x}) = \mathbf{1}\{x_1 + x_2 - \tfrac{1}{2} > 0\} - \mathbf{1}\{x_1 + x_2 - \tfrac{3}{2} > 0\}. \tag{10.2}$$

$s := x_1 + x_2$ とすると $s(\boldsymbol{x}_1) = 0$, $s(\boldsymbol{x}_2) = s(\boldsymbol{x}_3) = 1$, $s(\boldsymbol{x}_4) = 2$ である。(10.2)は s の関数として

$$f = \mathbf{1}\{\tfrac{1}{2} < s \le \tfrac{3}{2}\} \qquad \Big(\text{すなわち} f = 0 \ (s \le \tfrac{1}{2}), \quad f = 1 \ (\tfrac{1}{2} < s \le \tfrac{3}{2}), \quad f = 0 \ (s > \tfrac{3}{2})\Big)$$

であり（右端が閉じているのは $s = \tfrac{3}{2}$ で $\mathbf{1}\{s - \tfrac{3}{2} > 0\} = 0$ だからである）、4 点では $s = 1$ のときだけ 1 をとるから、XOR を厳密に表現する。

この構成は本章の伏線である。f は「二つのシグモイド型関数の差」であり、これが 10.4.2節に現れる**バンプ関数**に他ならない（同節で見るように、一様ノルムでの近似にはバンプの代わりに連続な hat 関数を使う）。XOR が解けた理由は、隠れ層が 4 点を s 軸上の 3 点に潰し、中央の帯を切り出したことにある。隠れ層とは、線形分離できる座標系を作る装置である。滑らかなシグモイドなら傾き a を大きくすれば XOR を任意の精度で近似できる。ロジスティック関数 $\sigma(t) = 1/(1 + e^{-t})$ で $a = 40$ とすると、4 点での値を小数第 4 位まで丸めて $(0.0000, 1.0000, 1.0000, 0.0000)$ となる（厳密には誤差が残り、$s = 0, 2$ では 2.1×10^{-9}、$s = 1$ では 4.1×10^{-9} である。$a = 20$ なら 4.5×10^{-5}、$a = 80$ なら倍精度の丸めに埋もれる）。

リスト 10.1　XOR を 1 隠れ層で表現する（式(10.2)の実装）

```python
import numpy as np
def sigma(z): return 1.0 / (1.0 + np.exp(-z))

X = np.array([[0.,0.],[0.,1.],[1.,0.],[1.,1.]]).T  # d×B = 2×4 : 列が入力
W = np.array([[1.,1.],[1.,1.]])                    # m×d, w_1 = w_2 = (1,1)
b = np.array([-0.5, -1.5])                         # thresholds 1/2 and 3/2
c = np.array([1.0, -1.0])                          # output weights: difference
H = sigma(40.0 * (W @ X + b[:, None]))             # hidden layer, shape (m,B)=(2,4)
print(np.round(c @ H, 4))                          # -> [0. 1. 1. 0.]
```

有限個の点なら点ごとにバンプを置けば必ず表現できる。問題は連続関数である。

10.4　万能近似定理

以下 $I_d := [0,1]^d$ とし、$C(I_d)$ は一様ノルム $\|f\|_\infty = \sup_{\boldsymbol{x}\in I_d}|f(\boldsymbol{x})|$ を入れたバナッハ空間とする。

定義 10.7 (判別的関数)**.** $\mathcal{M}(I_d)$ を I_d 上の有限符号付き正則ボレル測度全体とする。σ が**判別的**（discriminatory）であるとは、$\mu \in \mathcal{M}(I_d)$ が

$$\int_{I_d} \sigma(\boldsymbol{w}^\top \boldsymbol{x} + b)\,\mathrm{d}\mu(\boldsymbol{x}) = 0 \qquad \text{for all } \boldsymbol{w}\in\mathbb{R}^d,\ b\in\mathbb{R} \tag{10.3}$$

を満たすならば必ず $\mu = 0$ となることをいう。

すなわち「リッジ関数の族 $\{\sigma(\boldsymbol{w}^\top\cdot + b)\}$ がすべての測度を見分けるのに十分豊か」という条件である。抽象的だが、補題 10.12でシグモイド型ならこれを満たすことを示す。

定理 10.8 (万能近似定理、Cybenko 1989 [27])**.** σ を連続な判別的関数とする。このとき $\mathcal{F}^\sigma$ は $C(I_d)$ で一様ノルムに関して稠密である。すなわち任意の $f\in C(I_d)$ と $\varepsilon>0$ に対し m と $c_j, b_j\in\mathbb{R}$, $\boldsymbol{w}_j\in\mathbb{R}^d$ が存在して

$$\sup_{\boldsymbol{x}\in I_d}\left| f(\boldsymbol{x}) - \sum_{j=1}^{m} c_j\,\sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + b_j)\right| < \varepsilon. \tag{10.4}$$

特に σ が連続・有界・単調増加で非定数ならば（アフィン変換でシグモイド型に規格化できるので）結論が成り立つ。

注意 10.9 (仮定の緩め方と出典)**.** Cybenko [27] の証明は「判別的」という仮定に依拠する（10.4.1節）。その後 Hornik [41] は、活性化関数が**有界で非定数**であれば（単調性も連続性も要らず、可測であればよい）同じ稠密性が成り立つことを示した。さらに $L^p(\mu)$ ノルムでの稠密性、コンパクト集合上の一様収束、多層の場合への拡張も同論文で整理されている。現代的には「活性化関数が多項式でなければ万能近似が成り立つ」という形で述べられることが多い。本講義で扱う ReLU $\sigma(t)=\max(0,t)$ は**有界でない**ので Hornik の定理の枠にはそのまま収まらないが、命題 10.18で見るように区分線形関数を厳密に表現できるため別の道筋で稠密性が従う。

10.4.1　証明その一：関数解析による証明

第7章の関数解析が効く場面である。次の二つは主張のみを述べて用いる。

定理 10.10 (Hahn–Banach の系、主張のみ)**.** V をノルム空間、$S\subsetneq V$ を閉線形部分空間とすると、S 上で恒等的に 0 でありながら V 上では非零な有界線形汎関数 $L\in V^*$ が存在する。

定理 10.11 (Riesz–Markov の表現定理、主張のみ)**.** K をコンパクト Hausdorff 空間とする。$C(K)$ 上の任意の有界線形汎関数 L に対し $\mu\in\mathcal{M}(K)$ が一意に存在して $L(f)=\int_K f\,\mathrm{d}\mu$ が成り立つ。

道具の位置づけを先に述べる。示したいのは「$\mathcal{F}^\sigma$ の閉包が $C(I_d)$ 全体」という **全体的**な主張であり、直接示すのは難しい。そこで否定を仮定して **Hahn–Banach** で「その部分空間を潰す汎関数」という具体物を取り出し、**Riesz–Markov** でそれを測度という扱いやすい対象に翻訳する。測度になれば Fourier 変換が使え、矛盾を導ける。これが設計図である。

定理 *10.8*の証明. 示すべき稠密性は、$\mathcal{F}^\sigma$ の $C(I_d)$ における閉包を $S := \overline{\mathcal{F}^\sigma}$ と書けば $S = C(I_d)$ と言い換えられる。閉包をとる点が肝心である。定義 10.3の直後に注意したとおり $\mathcal{F}^\sigma$ は線形部分空間だが、無限次元のノルム空間では線形部分空間が閉である保証はなく（次の警告を見よ）、定理 10.10をそのまま $\mathcal{F}^\sigma$ に適用することはできない。一方、線形部分空間の閉包は必ず閉線形部分空間である。実際、$g,g'\in S$ と $\alpha,\beta\in\mathbb{R}$ に対し $g_n\to g$, $g_n'\to g'$（$g_n,g_n'\in\mathcal{F}^\sigma$）をとれば $\alpha g_n+\beta g_n'\in\mathcal{F}^\sigma$ が $\alpha g+\beta g'$ に収束するので $\alpha g+\beta g'\in S$ であり、閉包は定義から閉である。よって S は定理 10.10が要求する形になっている。

背理法により $S \neq C(I_d)$ とする。S は閉線形部分空間だから定理 10.10により $L \in C(I_d)^*$, $L \neq 0$, かつ $L(g) = 0$ $(g \in S)$ なる L が存在する。I_d はコンパクト距離空間だから定理 10.11が使えて、ある $\mu \in \mathcal{M}(I_d)$ が存在して

$$L(f) = \int_{I_d} f \,\mathrm{d}\mu \quad (f \in C(I_d)), \qquad \mu \neq 0 \tag{10.5}$$

($L \neq 0$ より $\mu \neq 0$)。σ は連続だから任意の $\boldsymbol{w}, b$ に対し $\boldsymbol{x} \mapsto \sigma(\boldsymbol{w}^\top \boldsymbol{x} + b)$ は $\mathcal{F}^\sigma \subset S$ の元であり（$m = 1$, $c_1 = 1$）、上の二つの性質から $\int_{I_d} \sigma(\boldsymbol{w}^\top \boldsymbol{x} + b)\,\mathrm{d}\mu(\boldsymbol{x}) = 0$ がすべての $\boldsymbol{w}, b$ で成り立つ。σ は判別的だから $\mu = 0$ となり、$\mu \neq 0$ に矛盾する。よって $\overline{\mathcal{F}^\sigma} = S = C(I_d)$、すなわち $\mathcal{F}^\sigma$ は稠密である。 ■

線形部分空間であることから閉であることは従わない

有限次元のノルム空間では線形部分空間は必ず閉だが、無限次元では偽である。$C([0,1])$ の中の多項式全体 $\mathcal{P}$ は線形部分空間であり、Weierstrass の多項式近似定理より $\overline{\mathcal{P}} = C([0,1])$ である。しかし $\mathcal{P} \neq C([0,1])$（多項式でない連続関数がある）だから $\mathcal{P}$ は閉でない。$\mathcal{F}^\sigma$ もまさに同じ立場にあり、定理 10.8が主張しているのは「$\mathcal{F}^\sigma$ の閉包が全体」という命題そのものである。したがって定理 10.10を使うときは $S = \mathcal{F}^\sigma$ ではなく $S = \overline{\mathcal{F}^\sigma}$ とおかねばならない。$L \neq 0$ が S 上で 0 であれば $\mathcal{F}^\sigma \subset S$ 上でも 0 なので、この置き換えで証明は何も損なわれない。

肝心の「シグモイド型なら判別的」がまだ残っている。ここが実質的な数学である。

補題 10.12 (シグモイド型関数は判別的)**.** σ が有界可測なシグモイド型関数ならば σ は判別的である。

証明. $\mu \in \mathcal{M}(I_d)$ が(10.3)を満たすとし、$\mu = 0$ を示す。

第 1 段（極限で指示関数を作る）. $\boldsymbol{w}, b, \varphi$ を固定し $\lambda > 0$ に対し $\sigma_\lambda(\boldsymbol{x}) := \sigma(\lambda(\boldsymbol{w}^\top \boldsymbol{x} + b) + \varphi)$ とおく。$\lambda \boldsymbol{w}$ と $\lambda b + \varphi$ を改めて $\boldsymbol{w}, b$ と読み替えれば仮定より $\int \sigma_\lambda \,\mathrm{d}\mu = 0$ である。$\lambda \to \infty$ とすると定義 10.2より各点で

$$\sigma_\lambda(\boldsymbol{x}) \longrightarrow \gamma(\boldsymbol{x}) := \begin{cases} 1, & \boldsymbol{w}^\top \boldsymbol{x} + b > 0, \\ 0, & \boldsymbol{w}^\top \boldsymbol{x} + b < 0, \\ \sigma(\varphi), & \boldsymbol{w}^\top \boldsymbol{x} + b = 0. \end{cases} \tag{10.6}$$

σ は有界（$|\sigma| \leq M$）で $|\mu|(I_d) < \infty$ だから定数 M が可積分な優関数となり、**Lebesgue の優収束定理**が使える。$\Pi_{\boldsymbol{w},b} := \{\boldsymbol{x} \in I_d : \boldsymbol{w}^\top \boldsymbol{x} + b = 0\}$、$H_{\boldsymbol{w},b} := \{\boldsymbol{x} \in I_d : \boldsymbol{w}^\top \boldsymbol{x} + b > 0\}$ とおけば

$$0 = \lim_{\lambda \to \infty} \int \sigma_\lambda \,\mathrm{d}\mu = \int \gamma \,\mathrm{d}\mu = \sigma(\varphi)\,\mu(\Pi_{\boldsymbol{w},b}) + \mu(H_{\boldsymbol{w},b}). \tag{10.7}$$

第 2 段（半空間の測度が消える）. (10.7)はすべての φ で成り立つ。$\varphi \to -\infty$ とすると $\sigma(\varphi) \to 0$ だから $\mu(H_{\boldsymbol{w},b}) = 0$。これを戻して $\sigma(\varphi) \neq 0$ なる φ を一つ選べば $\mu(\Pi_{\boldsymbol{w},b}) = 0$。よって

$$\mu(H_{\boldsymbol{w},b}) = \mu(\Pi_{\boldsymbol{w},b}) = 0 \qquad \text{for all } \boldsymbol{w}, b. \tag{10.8}$$

符号付き測度では正負が打ち消し合いうるので、これだけでは $\mu = 0$ とは言えない。

第 3 段（Fourier 変換へ）. $\boldsymbol{w}$ を固定し、有界可測関数 $h : \mathbb{R} \to \mathbb{R}$ に対し $F(h) := \int_{I_d} h(\boldsymbol{w}^\top \boldsymbol{x})\,\mathrm{d}\mu(\boldsymbol{x})$ とおくと $|F(h)| \leq \|h\|_\infty |\mu|(I_d)$ だから F は有界線形汎関数である。(10.8)より任意の θ で $F(\mathbf{1}\{t \geq \theta\}) = \mu(H_{\boldsymbol{w},-\theta}) + \mu(\Pi_{\boldsymbol{w},-\theta}) = 0$ であり、したがって区間の指示関数 $\mathbf{1}\{t \in [\theta_1, \theta_2)\} = \mathbf{1}\{t \geq \theta_1\} - \mathbf{1}\{t \geq \theta_2\}$ にも $F = 0$。線形性より、区間の指示関数の有限線形結合——すなわち**区間階段関数**——の上で $F = 0$ である。

ここで必要なのは $h = \cos, \sin$ の二つだけであることに注意する。I_d は有界だから $J := \{\boldsymbol{w}^\top \boldsymbol{x} : \boldsymbol{x} \in I_d\}$ はコンパクト区間であり、$\cos, \sin$ は J 上で一様連続である。そこで J を幅 δ の小区間に分割し各小区間で値を固定した区間階段関数 h_δ をとれば $\sup_{t \in J} |h(t) - h_\delta(t)| \to 0$ $(\delta \to 0)$ となる。F は $|F(h) - F(h_\delta)| \leq \sup_J |h - h_\delta| \cdot |\mu|(I_d)$ を満たすから、$F(h_\delta) = 0$ より $F(\cos) = F(\sin) = 0$。$h = \cos, \sin$ に適用すれば

$$\widehat{\mu}(\boldsymbol{w}) := \int_{I_d} e^{\mathrm{i}\boldsymbol{w}^\top \boldsymbol{x}} \,\mathrm{d}\mu(\boldsymbol{x}) = F(\cos) + \mathrm{i}F(\sin) = 0 \tag{10.9}$$

となる。$\boldsymbol{w}$ は任意だから μ の Fourier 変換は恒等的に 0 であり、Fourier 変換の単射性より $\mu = 0$。 ■

「単関数は有界可測関数を一様に近似する」は使えない

σ-加法族に関する一般の単関数（可測集合の指示関数の有限線形結合）なら有界可測関数を一様に近似できるが、上の第 3 段で $F=0$ が示せているのは**区間**階段関数の上だけである。一般の有界 Borel 関数は区間階段関数では一様近似できない。反例として $h=\mathbf{1}\{t\in\mathbb{Q}\}$（有理数の指示関数）をとると、任意の区間階段関数 s は幅正の区間上で定数だから、その区間内に有理点と無理点の双方があるので $\sup|h-s|\geq 1/2$ である。したがって「区間階段 $\Rightarrow$ 有界可測」への一様近似による飛躍は正しくない。上の証明は**必要なのが連続関数** $\cos,\sin$ **だけである**ことを使って穴を回避している。なお、F が有界かつ区間の指示関数上で消えることから単調族定理（monotone class theorem）を経由すれば、実は J 上のすべての有界 Borel 関数で $F=0$ が結論できる。一様近似ではなく各点収束＋優収束を使う点が違いであり、そちらを通しても構わない。本証明に必要なのは $\cos,\sin$ だけなので、より弱い一様連続性の議論で足りる。

注意 10.13 (省略した部分の明示)**.** 証明を与えずに用いたのは、(i) Hahn–Banach、(ii) Riesz–Markov、(iii) 優収束定理、(iv) 有限符号付き測度に対する Fourier 変換の単射性、の四つである。いずれも関数解析・測度論の標準的な結果であり、それ以外はすべて上に書いてある。$\lambda\to\infty$ で指示関数を作る第 1 段が、「滑らかなシグモイドを使っているのに階段関数の議論ができる」ことの理由であり、この証明の技術的な核心である。

10.4.2　証明その二：hat 関数による構成的証明

上の証明は短いが背理法なので、どんなネットワークが f を近似するのかを教えない。ここでは実際に構成する。構成の出発点は例 10.6の「二つのシグモイドの差」だが、どの関数を近似の中間目標に据えるかで結論が変わる。まず一様ノルムでの障害を見ておこう。

不連続な階段関数は連続なネットワークで一様近似できない

σ が連続なら $\mathcal{F}^\sigma$ の元はすべて連続である。連続関数列の一様極限は連続だから、**不連続関数は** $\mathcal{F}^\sigma$ **の一様ノルムでの閉包に入りえない**。定量的にも、$\varphi:=\mathbf{1}\{b_1<x<b_2\}$（ジャンプ幅 1）と任意の連続 u について $u(b_1^-)=u(b_1)=u(b_1^+)$ だから中間値の議論により $\|\varphi-u\|_\infty\geq 1/2$ である。実際、例 10.6の二つのシグモイドの差

$$\beta_a(x):=\sigma\big(a(x-b_1)\big)-\sigma\big(a(x-b_2)\big)\qquad(b_1<b_2)\tag{10.10}$$

は $a\to\infty$ で、$x\neq b_1,b_2$ をみたす各点において $\varphi=\mathbf{1}\{b_1<x<b_2\}$ に収束する（演習 10.2）。ただし**境界の 2 点では収束先が** φ **の値と違う**。実際ロジスティック関数なら $\beta_a(b_1)=\sigma(0)-\sigma(a(b_1-b_2))\to\sigma(0)=1/2$、同様に $\beta_a(b_2)=\sigma(a(b_2-b_1))-\sigma(0)\to 1-\sigma(0)=1/2$ であり、$b_1=1/3$, $b_2=2/3$、$\sigma(t)=1/(1+e^{-t})$ で数値的に測ると $\sup_x|\beta_a-\varphi|$ は $a=10,10^2,10^3,10^4$ に対し 0.5344, 0.4999, 0.4992, 0.4917 で、$1/2$ から下がらない。したがって「階段関数を経由して一様近似する」道は**原理的に閉ざされている**。経由すべき中間目標は連続関数、すなわち区分線形な hat 関数でなければならない。

第 1 段：ランプ関数はシグモイドの平均で一様近似できる。 $\rho(s):=\min(\max(s,0),1)$（**ランプ関数**）とおく。これは連続な区分線形関数であり、以下すべての構成の部品になる。

補題 10.14 (ランプ関数の一様近似)**.** σ を（連続性を仮定せず）シグモイド型かつ有界とする。任意の $\varepsilon>0$ に対し $M\in\mathbb{N}$ と $a>0$ が存在して

$$\sup_{s\in\mathbb{R}}\Big|\rho(s)-\frac{1}{M}\sum_{i=1}^{M}\sigma\big(a(s-\tau_i)\big)\Big|<\varepsilon,\qquad \tau_i:=\frac{i-1/2}{M}\tag{10.11}$$

が成り立つ。特に ρ は M 個のシグモイド素子の線形結合で一様に近似できる。

証明. 二段に分ける。まず σ を階段関数 $\mathbf{1}\{t>0\}$ に置き換えた $\rho_M(s):=\frac{1}{M}\sum_{i=1}^{M}\mathbf{1}\{s>\tau_i\}$ を考える。$\rho(s)=\int_0^1\mathbf{1}\{s>u\}\,\mathrm{d}u$ であり ρ_M はこの積分の中点則による近似だから、被積分関数が u について単調であることを使えば $\sup_s|\rho-\rho_M|\leq 1/(2M)$（等号が成り立つ）。

次に階段をシグモイドに戻す。$\Delta(s):=\frac{1}{M}\sum_i\big(\sigma(a(s-\tau_i))-\mathbf{1}\{s>\tau_i\}\big)$ を評価する。$|\sigma|\leq M_\sigma$ とし $\eta(T):=\sup_{t\geq T}|\sigma(t)-1|+\sup_{t\leq -T}|\sigma(t)|$ とおくと、定義 10.2より $\eta(T)\to 0$（$T\to\infty$）である。$\delta>0$ を固定して和を二つに分ける。$|s-\tau_i|\geq\delta$ なる項は $|a(s-\tau_i)|\geq a\delta$ だから各項が $\eta(a\delta)$ 以下で、その平均も $\eta(a\delta)$ 以下。$|s-\tau_i|<\delta$ なる i は τ_i の間隔が $1/M$ ゆえ高々 $2\delta M+1$ 個で、各項は $M_\sigma+1$ で抑えられる。よって

$$\sup_s|\rho-\rho_M-\Delta|\leq\frac{1}{2M}+\eta(a\delta)+(M_\sigma+1)\Big(2\delta+\frac{1}{M}\Big).\tag{10.12}$$

$\varepsilon>0$ に対し、まず M を $\frac{1}{2M}+\frac{M_\sigma+1}{M}<\varepsilon/3$ となるようにとり、次に δ を $2(M_\sigma+1)\delta<\varepsilon/3$ となるようにとり、最後に a を $\eta(a\delta)<\varepsilon/3$ となるようにとればよい。 ■

ロジスティック関数 $\sigma(t)=1/(1+e^{-t})$ で(10.11)の左辺を数値的に測ると、$a=4M$ のとき $M=4,16,64$ のいずれでも誤差 $\times M=0.1217$ と $1/M$ に正確に比例し、$a=5.5M$ で最良の $0.0643/M$ となる。階段関数を使った ρ_M の誤差 $1/(2M)=0.5/M$ よりむしろ小さい。滑らかさがここでは有利に働いている。ReLU なら $\rho(s)=s_+-(s-1)_+$ と**厳密に**表せるので、この段は不要である。

第 2 段：hat 関数の 1 の分割で 1 次元の連続関数を近似する。近似の対象を定理 10.8と同じ記号で $f\in C([0,1])$ とし、$h:=1/N$、$t_k:=kh$（$k=0,\dots,N$）とおく。**hat 関数**（三角関数）を

$$\Lambda_k(x):=\max\Bigl(0,\,1-\frac{|x-t_k|}{h}\Bigr) \tag{10.13}$$

と定める。Λ_k は t_k を頂点とする高さ 1 の三角形で、$[0,1]$ 上で

$$\sum_{k=0}^{N}\Lambda_k(x)=1\qquad(x\in[0,1]) \tag{10.14}$$

が成り立つ（**1 の分割**、partition of unity）。実際 $x\in[t_k,t_{k+1}]$ なら $\Lambda_k(x)=(t_{k+1}-x)/h$、$\Lambda_{k+1}(x)=(x-t_k)/h$ で他は 0 だから和は 1 である。

そこで f の**区分線形補間**

$$f_N(x):=\sum_{k=0}^{N}f(t_k)\Lambda_k(x) \tag{10.15}$$

をとる。f の連続度を $\omega_f(\delta):=\sup\{|f(x)-f(x')|:|x-x'|\le\delta\}$ とすると

$$\sup_{x\in[0,1]}|f(x)-f_N(x)|\le\omega_f(h) \tag{10.16}$$

である。証明は一行：$x\in[t_k,t_{k+1}]$ のとき(10.14)より $f_N(x)$ は $f(t_k)$ と $f(t_{k+1})$ の凸結合だから $|f(x)-f_N(x)|\le\max\{|f(x)-f(t_k)|,|f(x)-f(t_{k+1})|\}\le\omega_f(h)$。$f$ は $[0,1]$ 上一様連続なので $\omega_f(h)\to0$（$h\to0$）であり、これで**一様**な評価が得られた。階段関数のときと違って中間目標 f_N 自身が連続である点が本質的である。

f_N をネットワークに翻訳する。$R_k(x):=\rho\bigl((x-t_{k-1})/h\bigr)$（$k=1,\dots,N$）とおくと $\Lambda_0=1-R_1$、$\Lambda_k=R_k-R_{k+1}$ $(1\le k\le N-1)$、$\Lambda_N=R_N$ だから、(10.15)は telescope して

$$f_N(x)=f(t_0)+\sum_{k=1}^{N}\bigl(f(t_k)-f(t_{k-1})\bigr)R_k(x) \tag{10.17}$$

となる。すなわち f_N は N 個のランプ関数と定数項の線形結合である。補題 10.14より各 R_k を M 個のシグモイド素子で誤差 ε_M 以下に一様近似できるので、**この分割に沿った増分の総和**

$$V_N(f):=\sum_{k=1}^{N}|f(t_k)-f(t_{k-1})|$$

を係数の重みとして

$$\sup_{x\in[0,1]}|f(x)-\tilde f(x)|\le\omega_f(h)+V_N(f)\,\varepsilon_M \tag{10.18}$$

を満たす $\tilde f$ が得られる。ここで N（したがって h と $V_N(f)$）を先に固定し、そのうえで M を大きくする順序が大切である。N を固定すれば $V_N(f)$ は有限個の和なのでつねに有限であり、$M\to\infty$ で $\varepsilon_M\to0$ だから第 2 項は 0 に送れる。（連続関数の**全変動** $\sup_P\sum_k|f(t_k)-f(t_{k-1})|$（$P$ は分割全体を走る）は ∞ になりうるので、ここで全変動を持ち出してはいけない。たとえば $f(x)=x\sin(1/x)$、$f(0)=0$ は $[0,1]$ 上連続だが有界変動でない。）したがって h を小さくして第 1 項を、続いて M を大きくして第 2 項を $\varepsilon/2$ 以下にすれば、**1 隠れ層**で $\sup|f-\tilde f|<\varepsilon$ が達成される。$d=1$ ではこれで定理 10.8の構成的証明が完結した（ただし定義 10.2に加えて σ の有界性を使っている）。ReLU なら第 1 段が厳密なので、$N+2$ 素子で f_N を **厳密に**表現できる（命題 10.18）。

この $\tilde f$ のパラメータは**すべて書き下せる**。補題 10.14を $s=(x-t_{k-1})/h$ に適用し、$t_{k-1}/h=k-1$、$1/h=N$ を使うと

$$R_k(x)\approx\widetilde{R}_k(x):=\frac{1}{M}\sum_{i=1}^{M}\sigma\Bigl(aNx-a\bigl(k-1+\tfrac{i-1/2}{M}\bigr)\Bigr)$$

であり、これを(10.17)に代入すれば

$$\tilde f(x)=f(0)+\sum_{k=1}^{N}\sum_{i=1}^{M}\underbrace{\frac{f(t_k)-f(t_{k-1})}{M}}_{c_{k,i}}\,\sigma\Big(\underbrace{aN}_{w_{k,i}}\,x\underbrace{-a\big(k-1+\tfrac{i-1/2}{M}\big)}_{b_{k,i}}\Big) \tag{10.19}$$

となる。隠れ素子を (k,i) で番号付けすると、重みは**全素子で共通**の $w_{k,i}=aN=a/h$、バイアス $b_{k,i}$ は $[0,1]$ を NM 等分した点に沿って等間隔に並び、出力係数 $c_{k,i}$ は f の**局所的な増分** $f(t_k)-f(t_{k-1})$ を M 等分したものである。万能近似定理の $c_j,\boldsymbol{w}_j,b_j$ が具体的に何であったかが、ここで初めて見える。

定数項 $f(0)$ の扱いだけ注意が要る。定義 10.3の $\mathcal{F}_m^\sigma$ には出力側の定数項がないので、(10.19)をそのまま $\mathcal{F}_{NM}^\sigma$ の元と呼ぶことはできない。定数は素子 1 個で作れる：$\sigma(b_0)\neq 0$ となる b_0 を取り（シグモイド型なら b_0 を大きくすれば $\sigma(b_0)\to 1\neq 0$）、$\boldsymbol{w}_0=\boldsymbol{0}$、$c_0=f(0)/\sigma(b_0)$ とおけば $c_0\sigma(\boldsymbol{w}_0^{\top}\boldsymbol{x}+b_0)=f(0)$ である。したがって正しくは

$$\tilde f\in\mathcal{F}_{NM+1}^\sigma$$

である。素子 1 個の差なので結論には影響しないが、幅を数えるときは忘れないようにしたい（定義 10.3を $c_0+\sum_j c_j\sigma(\boldsymbol{w}_j^{\top}\boldsymbol{x}+b_j)$ と定義する流儀もあり、その場合は NM のままである。本書が定数項を置かないのは定理 10.8の原典 [27] の形に合わせたためである）。

構成の数値確認

$f(x)=\sin 2\pi x+\frac{1}{2}x$、$\sigma$ をロジスティック関数として(10.19)をそのまま実装すると、$\sup_{[0,1]}|f-\tilde f|$ は $(N,M,a)=(8,8,60)$ で 0.0757、$(16,16,120)$ で 0.0196、$(32,32,240)$ で 0.0049 となる。N を倍にすると誤差がおよそ $1/4$ になるのは、この f が C^2 で区分線形補間の誤差が $O(h^2)$ だからである（定理 10.19）。素子数は $NM+1$ なので $65,257,1025$ と増える——1 隠れ層で任意精度は出るが、**素子数の増え方は激しい**。これが10.7節の問題意識につながる。

第 3 段：多次元は hat のテンソル積で。 $d\ge 2$ では格子点 $\boldsymbol{x}_{\boldsymbol{\nu}}:=(t_{\nu_1},\dots,t_{\nu_d})$（$\boldsymbol{\nu}\in\{0,\dots,N\}^d$）と

$$\Lambda_{\boldsymbol{\nu}}(\boldsymbol{x}):=\prod_{j=1}^{d}\Lambda_{\nu_j}(x_j),\qquad f_N(\boldsymbol{x}):=\sum_{\boldsymbol{\nu}}f(\boldsymbol{x}_{\boldsymbol{\nu}})\Lambda_{\boldsymbol{\nu}}(\boldsymbol{x}) \tag{10.20}$$

をとる。(10.14)を各座標に適用すれば $\sum_{\boldsymbol{\nu}}\Lambda_{\boldsymbol{\nu}}\equiv 1$ かつ $\Lambda_{\boldsymbol{\nu}}\ge 0$ で、$\boldsymbol{x}$ を含む小立方体の外の項は 0 だから、$f_N(\boldsymbol{x})$ はその立方体の 2^d 個の頂点での値の凸結合である（**多重線形補間**）。立方体の直径は $\sqrt{d}h$ なので、第 2 段と同じ一行の議論で

$$\sup_{\boldsymbol{x}\in I_d}|f(\boldsymbol{x})-f_N(\boldsymbol{x})|\le\omega_f\big(\sqrt{d}\,h\big) \tag{10.21}$$

を得る。f は I_d 上一様連続だから右辺は $h\to 0$ で 0 に収束し、目標関数の側の一様近似は完了する。

残るのは $\Lambda_{\boldsymbol{\nu}}$ が d 個の 1 変数関数の**積**であることだ。1 隠れ層ネットワークはリッジ関数の和しか作れないので積を直接には作れない。しかし積は

$$uv=\frac{(u+v)^2-(u-v)^2}{4} \tag{10.22}$$

と平方の差に書けて、$q(t):=t^2/4$ は 1 変数の連続関数だから第 2 段の区分線形補間でコンパクト区間上一様に近似できる。したがって u,v を作る層の上に一枚層を足せば積が一様近似でき、$\lceil\log_2 d\rceil$ 段重ねれば d 個の積が得られる。数値で確かめると、q を $[-1,2]$ 上 K 等分の区分線形関数で置き換えた $\tilde q(u+v)-\tilde q(u-v)$ の $[0,1]^2$ 上での誤差 $\sup|uv-\tilde q(u+v)+\tilde q(u-v)|$ は $K=4,16,64$ に対し 3.52×10^{-2}, 2.20×10^{-3}, 1.37×10^{-4} であり、$O(K^{-2})$ で 0 に収束する。　□

注意 10.15（構成的証明が払う二つの代償）**.** 第一の、そして見落としやすい代償は**中間目標の選び方**である。区間の指示関数（バンプ）を経由して階段関数を作る素朴な構成は、上の警告のとおり一様ノルムでは破綻する。連続な hat 関数と 1 の分割に置き換えることで初めて一様評価(10.16)が立つ。教科書的な記述で「バンプを並べて階段を作る」と書かれることがあるが、それは一様ノルムの主張としては正しくない（L^p ノルムなら正しい。注意 10.16）。

第二の代償は**層の数**である。$d=1$ では第 2 段だけで 1 隠れ層に収まるが、$d\ge 2$ では (10.20)の積を実現するために(10.22)の平方近似を積む必要があり、この構成が直接与えるのは深さ $O(\log d)$ のネットワークによる万能近似であって、定理 10.8が主張する 1 隠れ層のそれではない。1 隠れ層で構成的に示すには Radon 変換を経由するようなより込み入った議論を要する。**1 隠れ層で十分だ**という強い主張を短く得られる点にこそ、関数解析的証明の価値がある。二つの証明は互いを補い合っている。

注意 10.16（階段関数の構成を活かす道：L^p 近似に落とす）**.** 一様ノルムを $L^p(\mu)$ ノルム（$1\le p<\infty$、μ は I_d 上の有限測度）に弱めれば、階段関数を経由する構成はそのまま使える（図 10.2）。中点値をとった階段関数 $f_N=\sum_k f(\bar t_k)\mathbf{1}\{t_k<x<t_{k+1}\}$ は分割点を除いて $|f-f_N|\le\omega_f(h)$ を満たし、分割点の集合は有限だから μ が非原子的（例えば Lebesgue 測度）なら測度 0

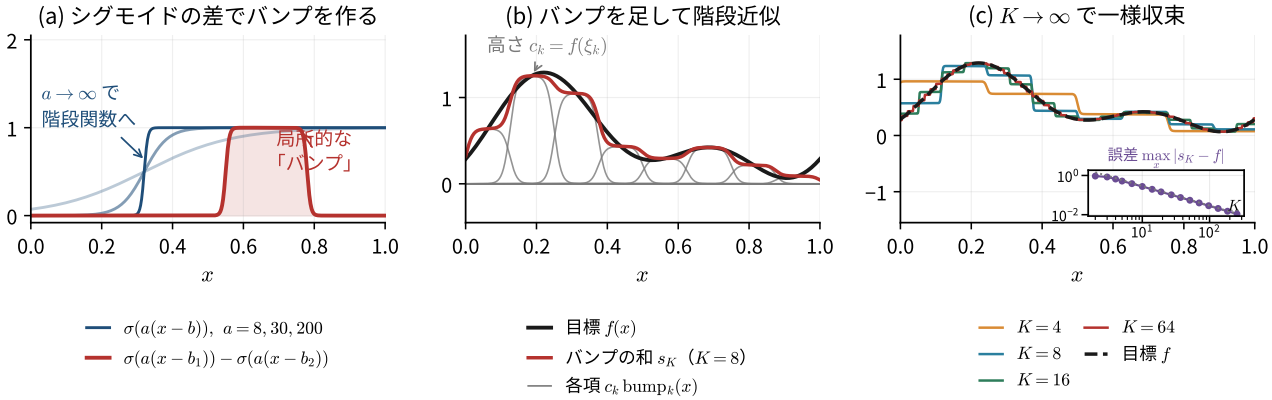


図10.2　階段関数を経由する素朴な構成の三段階。(a) 二つのシグモイドの差 $\sigma(a(x-b_1)) - \sigma(a(x-b_2))$ は傾き a を大きくすると区間 $[b_1, b_2]$ の指示関数（バンプ）に近づく。(b) 高さを調整したバンプの和が階段関数を与える。(c) 分割を細かくすれば階段関数が目的関数に近づく。ただし収束は各点収束および L^p 収束であって **一様収束ではない**（バンプは端点で値 $\sigma(0)$ に留まり、極限の階段関数は不連続だから連続関数で一様近似できない）。一様ノルムでの証明には(10.13)の hat 関数を用いる。

で、$\|f - f_N\|_{L^p(\mu)} \le \omega_f(h)\,\mu(I_d)^{1/p}$ となる。バンプ β_a の収束は境界 2 点を除く各点で成り立ち、μ が非原子的ならその 2 点は測度 0 だから、優収束定理により $\|\mathbf{1}\{t_k < x < t_{k+1}\} - \beta_a\|_{L^p(\mu)} \to 0$ なので、L^p では階段近似から所望の結論が得られる。多次元の「和 + 閾値」による箱の構成も同様に L^p では正当化できる。一様ノルムでの主張が必要なときだけ hat 関数に取り替えればよい、という整理になる。実際10.7節の Barron の定理は $L^2(\mu)$ での主張であり、その証明が使うのはこの L^p 版である。

例 10.17 (1 次元での数値実験：二つの構成の比較)**.** $g(x) = \sin(2\pi x) + x/2$ を $[0,1]$ 上で近似する。

階段（バンプ）構成：N 個のバンプ（$m = 2N$ 個のシグモイド、傾き $a = 50N$）で近似すると L^2 誤差は $N = 8, 16, 32, 64, 128$ に対し 0.1467, 0.0729, 0.0365, 0.0184, 0.0094 であった。N を倍にすると誤差がほぼ半分、すなわち $O(m^{-1})$ の減衰で、階段近似の誤差が g の Lipschitz 定数 × 刻み幅で決まることと整合する。一方**一様**誤差は同じ設定で 0.4570, 0.3554, 0.3029, 0.2765, 0.2632 と 0 に収束しない。最大値は常に区間端 $x = 1$ で達成される。原因は明快で、$x = 1$ では最後のバンプが半分しか立ち上がらないため、近似値が $g(1) = 0.5$ ではなく $\frac{1}{2}g(1) = 0.25$ に近づくことである（実測値は $N = 8, 32, 128$ に対し 0.0430, 0.1971, 0.2368 で、N を増やすと 0.25 に漸近する）。上の警告が数値に現れている。

hat 構成：(10.15)の区分線形補間の一様誤差は同じ N に対し 7.04×10^{-2}, 1.88×10^{-2}, 4.79×10^{-3}, 1.20×10^{-3}, 3.01×10^{-4} であり、$O(N^{-2})$ で 0 に収束する。これを補題 10.14どおり N 個のランプ × ランプあたり M 個のロジスティック素子（$a = 4M/h$）で実現すると、$(N, M) = (16, 16)$（$m = 256$ 素子）で一様誤差 0.0190、$(32, 32)$（$m = 1024$）で 0.0048、$(64, 64)$（$m = 4096$）で 0.0012 となり、区分線形補間そのものの誤差 0.0188, 0.0048, 0.0012 との相対差はそれぞれ 0.75%, 0.49%, 0.36% にすぎない。すなわち $M = N$ 程度ならランプの近似誤差は補間誤差に埋もれ、実質的に第 2 段の $O(N^{-2})$ がそのまま出る。$(N, M) = (16, 4)$（$m = 64$）でも 0.0193（相対差 2.2%）で、M は小さくてよい。

10.4.3　定理の意味と、それ以上に重要な限界

定理 10.8はしばしば「だから深層学習は何でもできる」という文脈で引用されるが、それは誤読である。定理が**言っていないこと**を三つ挙げよう。

(1) 幅について何も言っていない。定理は「ある m が存在する」としか述べない。その m の大きさは証明の中身でわかる。構成的証明では格子点が $(N+1)^d$ 個必要で（(10.20)）、f の Lipschitz 定数を Λ とすれば(10.21)より精度 ε には $N \approx \sqrt{d}\Lambda/\varepsilon$ が要るから

$$m = O\big((\Lambda/\varepsilon)^d\big) = O(\varepsilon^{-d}). \tag{10.23}$$

これは第5章の**次元の呪い**そのものである。$d = 100$, $\varepsilon = 0.1$ なら $m = 10^{100}$ で宇宙の原子数を超える。しかも証明が下手なのではなく、Lipschitz 連続関数のクラス全体に対しては $m = \Omega(\varepsilon^{-d})$ という下界が知られており、指数依存は本質的である。

(2) 学習可能性について何も言っていない。定理はパラメータの**存在**を主張するだけで、勾配降下法などで**見つけられる**かには触れない。10.9節で見るように学習問題は非凸であり、存在と到達可能性の間には大きな隔たりがある。**(3) 汎化についても何も言っていない。**定理は与えられた f の近似の話であって有限サンプルからの推定の話ではなく、近似能力が高いことはむしろ過適合の危険が高いことを意味する。

よくある誤解：「万能近似定理があるから深層学習は成功する」

これは誤りである。第一に、万能近似定理は **1 隠れ層**について成り立つ定理であり、深層である必然性を全く説明しない。定理を根拠にするならむしろ「浅くて十分」という結論になる。第二に、保証される幅は一般に $O(\varepsilon^{-d})$ で指数的であり、実用サイズのネットワークの成功を説明しない。第三に、定理は**存在定理**であって最適化の収束を何も言わない。深層学習が成功する理由は、万能近似性ではなく「実データが従う関数クラスの構造」「深さによる効率的な表現」「勾配法の暗黙の正則化」といった別の要因に求めねばならない。本章の10.6節と10.7節が前二者に、第11章が第三に対応する。

10.5　ReLU 網の近似理論

ReLU は有界でないので定義 10.2を満たさず補題 10.12が使えないが、別のルートで万能性が示せる。

命題 10.18 (ReLU 網は区分線形関数を厳密に表現する)**.** 1 次元入力の場合、$f(x)=\sum_{j=1}^{m} c_j(a_jx-\theta_j)_+ + c_0 + c_{-1}x$ が表す関数の全体は、折れ点を高々 m 個もつ連続な区分線形関数（高々 $m+1$ 個の線形片）の全体と一致する。

証明. ($\subseteq$) $(a_jx-\theta_j)_+$ は $x=\theta_j/a_j$ に折れ点を一つもつ連続区分線形関数であり、その線形結合の折れ点は各項の折れ点の和集合に含まれるので高々 m 個。

($\supseteq$) 折れ点 $\theta_1<\cdots<\theta_m$ をもつ連続区分線形関数 g の、区間 (θ_k,θ_{k+1}) での傾きを s_k（$\theta_0=-\infty$）とおくと

$$g(x)=g(\theta_1)+s_0(x-\theta_1)+\sum_{k=1}^{m}(s_k-s_{k-1})(x-\theta_k)_+. \tag{10.24}$$

実際、右辺は連続で、$x<\theta_1$ では傾き s_0、$\theta_k<x<\theta_{k+1}$ では傾き $s_0+\sum_{l\le k}(s_l-s_{l-1})=s_k$ となり、$x=\theta_1$ での値も一致するので両辺は等しい。 ∎

(10.24)は「傾きの差分を ReLU の係数に載せる」公式である。ReLU 網の学習とは折れ点の位置 θ_k と傾きの跳び s_k-s_{k-1} を同時に選ぶことに他ならず、折れ点が可変であることが非線形近似の利点の源である。

定理 10.19 (1 次元 C^2 関数の近似率)**.** $g\in C^2([0,1])$、$M:=\max_x|g''(x)|$ とすると、m 個の ReLU 素子をもつ 1 隠れ層ネットワーク f が存在して $\|g-f\|_\infty\le M/(8m^2)$。

証明. $t_k=k/m$ を節点とし、f を各節点で g に一致する折れ線とする。命題 10.18より f は m 個以下の ReLU 素子と線形項で厳密に表現できる。$h=1/m$、$e:=g-f$ とおく。$x\in[t_k,t_{k+1}]$ を固定し

$$\phi(u):=e(u)-e(x)\frac{(u-t_k)(u-t_{k+1})}{(x-t_k)(x-t_{k+1})}$$

とおくと ϕ は 3 点 t_k,x,t_{k+1} で 0 になる。Rolle の定理を二回使えば $\phi''(\eta_x)=0$ なる $\eta_x\in(t_k,t_{k+1})$ が存在する。f はこの区間で線形なので $e''=g''$ であり、$\phi''(u)=g''(u)-2e(x)/\{(x-t_k)(x-t_{k+1})\}$ から

$$e(x)=\tfrac{1}{2}g''(\eta_x)(x-t_k)(x-t_{k+1}). \tag{10.25}$$

$|(x-t_k)(x-t_{k+1})|\le h^2/4$ より $|e(x)|\le Mh^2/8=M/(8m^2)$。 ∎

1 次元では ε 近似に $m=O(\varepsilon^{-1/2})$ で足りる。一般の d 次元 C^2 関数では $m=O(\varepsilon^{-d/2})$ となり、やはり次元の呪いを受ける。

図 10.3はこの収束を数値で確かめたものである。隠れ素子数 m を増やすと折れ点が増えて sin 曲線への当てはまりが改善し、両対数プロットの傾きは -2 に近い。これは誤差が $O(m^{-2})$、すなわち定理 10.19の主張と整合する。

数値でも確認できる。$g(x)=\sin(2\pi x)$（$M=4\pi^2$）を m 等分の折れ線で近似した一様誤差は $m=8,16,32,64,128$ に対し 7.04×10^{-2}, 1.88×10^{-2}, 4.79×10^{-3}, 1.20×10^{-3}, 3.01×10^{-4} であり、m^2 を掛けると 4.50, 4.82, 4.91, 4.93, 4.93 と一定値に収束する。理論上界 $M/8=4.94$ とほぼ一致し、評価がタイトであることもわかる。

10.6　深さの効果

例 10.4の問い——同じ予算を浅く広く使うか深く狭く使うか——に答える。結論は**深いほうが指数的に有利な関数が存在する**であり、鍵は合成が折れ点を掛け算的に増やすという事実である。

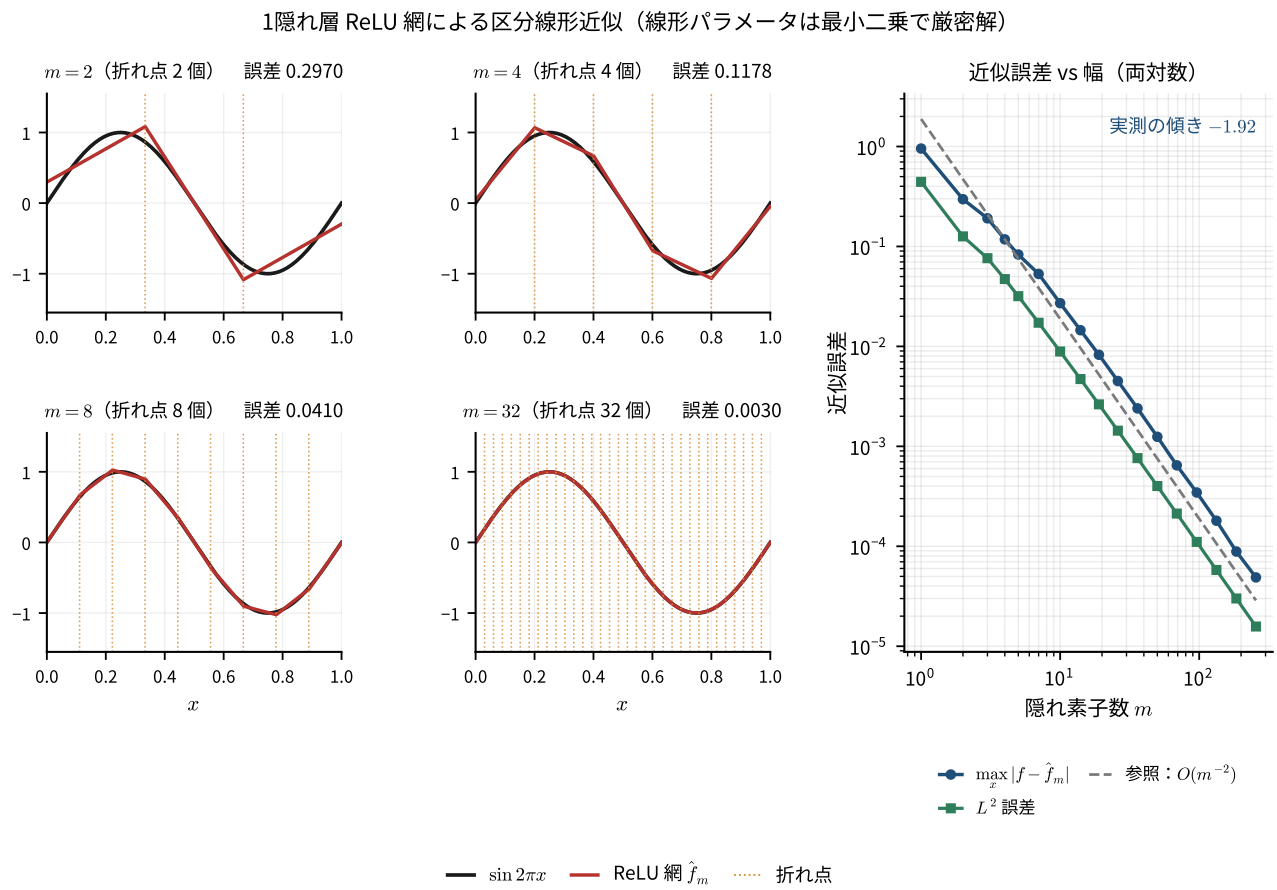


図10.3　ReLU 網による区分線形近似。隠れ素子数 m を増やすと折れ点が増え sin 曲線への当てはまりが改善する。右の両対数プロットの傾きは -2 に近く、定理 10.19の $O(m^{-2})$ が数値的に確認できる。

定義 10.20（三角波写像）. $T(x) := 1 - |2x - 1|$（$x \le 1/2$ で $2x$、$x \ge 1/2$ で $2 - 2x$）とする。$[0,1]$ 上では ReLU で $T(x) = 2x_+ - 4(x - \frac{1}{2})_+$ と厳密に表現でき、幅 2 の 1 隠れ層で実現できる。この二項の表現は $x > 1$ では $2 - 2x < 0$ と負に発散するので、$\mathbb{R}$ 全体で $T = \max(0, 1 - |2x - 1|)$ に一致させたい場合は第三項を足して $2x_+ - 4(x - \frac{1}{2})_+ + 2(x - 1)_+$ とする（演習 10.5）。以下の合成では T の像が $[0,1]$ に収まるので定義域を $[0,1]$ に限れば二項で足りる。

定理 10.21（三角波の合成は折れ点を指数的に増やす）. $T^{\circ L} := T \circ \cdots \circ T$（$L$ 回）は各区間 $I_k^{(L)} := [k2^{-L}, (k+1)2^{-L}]$（$k = 0, \dots, 2^L - 1$）上でアフィンかつ $[0,1]$ の上への全単射である。したがって $T^{\circ L}$ はちょうど 2^L 個の線形片と $2^L - 1$ 個の折れ点をもち、2^{L-1} 個の山を作る。

証明. L に関する帰納法。$L = 1$ は定義そのもの（$[0,1/2]$ と $[1/2,1]$ でそれぞれ $[0,1]$ 上へのアフィン全単射）。L で成り立つとし $T^{\circ(L+1)} = T^{\circ L} \circ T$ と分解する。T は $[0,1/2]$ を $[0,1]$ 上へアフィンに（傾き 2 で）写すから、$[0,1/2]$ を 2^L 等分した小区間 $[k2^{-(L+1)}, (k+1)2^{-(L+1)}]$ を $I_k^{(L)}$ の上へアフィン全単射に写す。帰納法の仮定より $T^{\circ L}$ は $I_k^{(L)}$ 上でアフィンかつ $[0,1]$ 上への全単射だから、合成も $[k2^{-(L+1)}, (k+1)2^{-(L+1)}]$ 上でアフィンかつ $[0,1]$ 上への全単射である。$[1/2,1]$ についても T が向きを逆にして $[0,1]$ 上へ写すことから同様。以上で 2^{L+1} 個すべての小区間について主張が示された。各小区間で $[0,1]$ 上への全単射だから隣接区間では単調性の向きが交互に入れ替わり、内点 $2^{L+1} - 1$ 個はすべて真の折れ点である。上昇と下降が交互に 2^{L+1} 回並ぶので山は 2^L 個。 ∎

数値的にも $L = 1, \dots, 6$ での折れ点数は $1, 3, 7, 15, 31, 63$、すなわち $2^L - 1$ である。$T^{\circ L}$ を実現する ReLU 網は定義 10.20を L 回積むだけなので深さ L、幅 2、パラメータ数 $O(L)$ で済む。浅い網ではどうか。この対比が図 10.4である。合成の回数 L に対して折れ点は指数的に増える一方、必要なパラメータ数は L に比例するだけで、同じパラメータ数の浅いネットワークではこの振動を再現できない。深さが表現力を生む最も簡明な例である。

補題 10.22（区分線形片の数の上界）. 1 次元入力・幅 $\le w$・隠れ層 $\le k$ の ReLU 網が表す関数の折れ点数は高々 $(2w)^k$ である。

証明. 第 l 層の素子の出力がもつ折れ点数の最大値を B_l とおく（$B_0 = 0$）。第 $l+1$ 層の素子は $\sigma(\sum_{i=1}^{w} u_i h_i(x) + b)$ の形で、内側の線形結合の折れ点は各 h_i の折れ点の和集合に含まれるので高々 wB_l 個。折れ点 p 個の連続区分線形関数に ReLU を掛

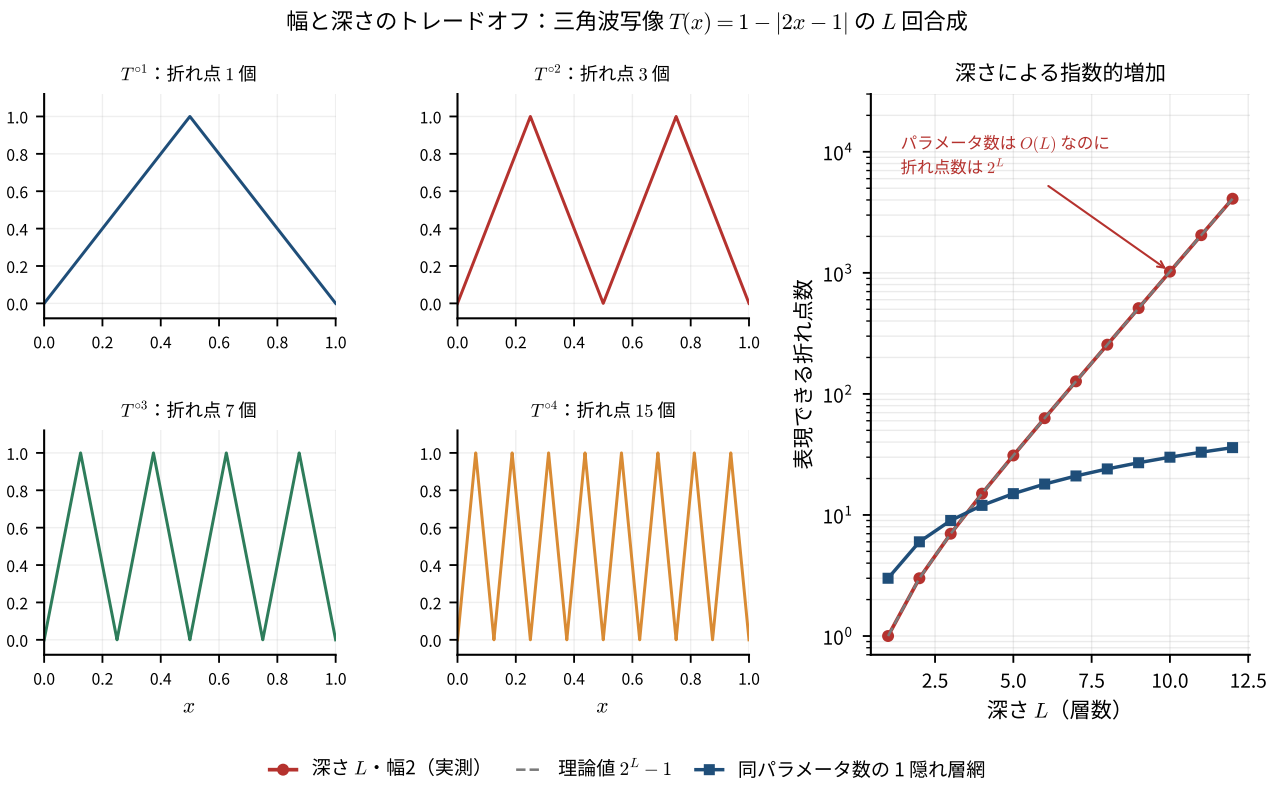


図10.4　幅と深さのトレードオフ。三角波写像 T を L 回合成すると折れ点は 2^L-1 個に指数的に増えるが、必要なパラメータ数は L に比例するだけである。同じパラメータ数の浅いネットワークが表現できる折れ点数は高々多項式的にしか増えない。

けると、各線形片が高々 1 回 0 を横切るので折れ点は高々 $p+1$ 個増える。よって $B_{l+1}\le 2wB_l+1$ であり、$B_0=0$ から $B_k\le\sum_{i=0}^{k-1}(2w)^i\le(2w)^k$（$w\ge 1$）。 ■

系 10.23 (深さと幅の分離)**.** $T^{\circ L}$ を隠れ層 k 層の ReLU 網で厳密に表現するには $(2w)^k\ge 2^L-1$、すなわち $w=\Omega(2^{L/k})$ が必要である。特に k を定数に固定すると必要な幅は L について指数的に増大する。実際、定理 10.21より折れ点は 2^L-1 個であり、補題 10.22よりこれが $(2w)^k$ 以下でなければならない。

近似についても同様の分離が知られている。

定理 10.24 (Telgarsky の分離定理、主張のみ [74])**.** 任意の L に対し、深さ $O(L^2)$・幅 $O(1)$ の ReLU 網で表現できる $f_L:[0,1]\to[0,1]$ が存在して、深さ $\le L$・幅 $\le 2^L$ の任意の ReLU 網 g に対し $\int_0^1|f_L-g|\,\mathrm{d}x\ge 1/6$ が成り立つ。すなわち、深い網が容易に表現する関数の中には、浅い網では指数的な幅を使っても定数精度でさえ近似できないものがある。

読み方には注意が要る。系 10.23は「**ある関数については**深いほうが効率的」と言うに過ぎず、すべての関数についてではない。また、表現できることと学習できることは別問題である（$T^{\circ L}$ は表現は容易だが勾配法での学習は極めて難しい）。それでも「深さは幅で代替できない」という定性的事実を確立した点で、これらの定理は重要である。

10.7　Barron クラス——次元の呪いを回避する

(10.23)の壁は、Lipschitz 関数という広すぎるクラスを相手にしたことから来る。クラスを絞れば状況は一変する。

定義 10.25 (Barron クラス [12])**.** $\mathbb{R}^d$ 上の有限複素測度 $\hat f$ が存在して

$$f(\boldsymbol{x})=\int_{\mathbb{R}^d} e^{\mathrm{i}\boldsymbol{\omega}^\top\boldsymbol{x}}\,\mathrm{d}\hat f(\boldsymbol{\omega})\quad(\boldsymbol{x}\in B),\qquad C_f:=\int_{\mathbb{R}^d}\|\boldsymbol{\omega}\|\,|\mathrm{d}\hat f|(\boldsymbol{\omega})<\infty \tag{10.26}$$

と書けるとき f は **Barron クラス**に属するといい、C_f を Barron 定数という。ここで $|\mathrm{d}\hat f|$ は $\hat f$ の全変動測度である。

定義を**測度**で書いたことには理由がある。密度 $\widehat f(\boldsymbol{\omega})\,\mathrm{d}\boldsymbol{\omega}$ に限ると $f(\boldsymbol{x})=\sin(\boldsymbol{w}^\top\boldsymbol{x})$ のような単一周波数の関数が定義から外れてしまう（例 10.28）。測度で書けば $\hat f$ が原子（デルタ測度）をもつ場合も統一的に扱え、$\hat f$ が密度 $\widehat f$ をもつ場合は $|\mathrm{d}\hat f|=|\widehat f(\boldsymbol{\omega})|\,\mathrm{d}\boldsymbol{\omega}$ で以前の定義に一致する。実関数 f を扱うので $\hat f$ は $\overline{\mathrm{d}\hat f(\boldsymbol{\omega})}=\mathrm{d}\hat f(-\boldsymbol{\omega})$（エルミート対称）を満たすものとする。

$\|\boldsymbol{\omega}\|$ の重みは「f の勾配の Fourier 側での総量」を測っており、$C_f < \infty$ は高周波成分が少ないことを意味する。定義に d が陽に現れない点が重要である。

定理 10.26 (Barron 1993 [12])**.** $B \subset \mathbb{R}^d$ を原点を含む半径 r の有界集合、μ を B 上の確率測度とする。f が Barron クラスに属するとき、任意の m に対し m 個のシグモイド型隠れ素子をもつ 1 隠れ層ネットワーク f_m（と定数項）が存在して

$$\int_B \bigl(f(\boldsymbol{x}) - f_m(\boldsymbol{x})\bigr)^2 \,\mathrm{d}\mu(\boldsymbol{x}) \le \frac{(2rC_f)^2}{m}. \tag{10.27}$$

すなわち L^2 誤差は $O(m^{-1/2})$ であり、**その定数は次元 d に陽に依存しない**。

証明の概略（*Maurey* の議論）. **第 1 段：f をリッジ関数の閉凸包の元として表す。**極分解 $\mathrm{d}\hat{f}(\boldsymbol{\omega}) = e^{\mathrm{i}\theta(\boldsymbol{\omega})}|\,\mathrm{d}\hat{f}|(\boldsymbol{\omega})$ を使い、f が実であることから実部をとると $f(\boldsymbol{x}) - f(\boldsymbol{0}) = \int (\cos(\boldsymbol{\omega}^{\top}\boldsymbol{x} + \theta(\boldsymbol{\omega})) - \cos\theta(\boldsymbol{\omega}))|\,\mathrm{d}\hat{f}|(\boldsymbol{\omega})$ であり、被積分関数は $\boldsymbol{\omega}^{\top}\boldsymbol{x}$ にのみ依存するリッジ関数である。$C_f > 0$ とし（$C_f = 0$ なら f は B 上定数で主張は自明）$\Lambda(\mathrm{d}\boldsymbol{\omega}) := \|\boldsymbol{\omega}\|\,|\,\mathrm{d}\hat{f}|(\boldsymbol{\omega})/C_f$ とおくと Λ は確率測度で、

$$f(\boldsymbol{x}) - f(\boldsymbol{0}) = C_f \int g_{\boldsymbol{\omega}}(\boldsymbol{x})\,\Lambda(\mathrm{d}\boldsymbol{\omega}), \qquad g_{\boldsymbol{\omega}}(\boldsymbol{x}) := \frac{\cos(\boldsymbol{\omega}^{\top}\boldsymbol{x} + \theta(\boldsymbol{\omega})) - \cos\theta(\boldsymbol{\omega})}{\|\boldsymbol{\omega}\|} \tag{10.28}$$

と書ける（$\|\boldsymbol{\omega}\| = 0$ の原子は被積分関数が 0 なので除いてよい）。$|\cos u - \cos v| \le |u - v|$ より $\boldsymbol{x} \in B$ で $|g_{\boldsymbol{\omega}}(\boldsymbol{x})| \le |\boldsymbol{\omega}^{\top}\boldsymbol{x}|/\|\boldsymbol{\omega}\| \le r$、すなわち $\|C_f g_{\boldsymbol{\omega}}\|_{\infty} \le rC_f$ で一様有界である。

ここから「$f - f(\boldsymbol{0})$ がシグモイド型素子の集合 $\mathcal{G}$ の閉凸包に属する」を結論するには、次の三点を認める必要がある。本講義ではこれを**仮定として立てて**先へ進む。

(A1) (10.28)の積分を $\mathcal{H} := L^2(\mu)$ 値の **Bochner 積分**として読む。$\boldsymbol{\omega} \mapsto g_{\boldsymbol{\omega}}$ は $\mathcal{H}$ ノルムで一様有界かつ（cos の連続性から）弱可測なので Bochner 可積分であり、(10.28)は $\mathcal{H}$ の元としての等式である。したがって $f^{\star} := f - f(\boldsymbol{0})$ は $\{C_f g_{\boldsymbol{\omega}}\}$ の**閉**凸包に属する（Bochner 積分は積分核の閉凸包に入る）。

(A2) 各 $C_f g_{\boldsymbol{\omega}}$ は、1 変数関数 $u \mapsto C_f(\cos(u + \theta) - \cos\theta)/\|\boldsymbol{\omega}\|$ がコンパクト区間 $\{\boldsymbol{\omega}^{\top}\boldsymbol{x} : \boldsymbol{x} \in B\}$ 上で有界変動であることから、$\pm b$（$b := 2rC_f$）でノルムが抑えられたシグモイド型素子 $\boldsymbol{x} \mapsto \pm b\,\sigma(\boldsymbol{w}^{\top}\boldsymbol{x} + \beta)$ の凸結合で $\mathcal{H}$ ノルム任意精度に近似できる（注意 10.16の L^p 版の階段近似）。ここで一様ノルムではなく $L^2(\mu)$ ノルムを使う点が本質的である（10.4.2節の警告を見よ）。

(A3) 閉凸包をとる操作は (A1) と (A2) を貼り合わせても閉凸包の外に出ない（閉凸包の閉凸包は元の閉凸包）。

以上を認めれば、$\mathcal{G} := \{\boldsymbol{x} \mapsto \pm b\,\sigma(\boldsymbol{w}^{\top}\boldsymbol{x} + \beta) : \boldsymbol{w} \in \mathbb{R}^d, \beta \in \mathbb{R}\}$ が $\sup_{g \in \mathcal{G}} \|g\|_{\mathcal{H}} \le b\,\mu(B)^{1/2} \le b$（$\mu$ は確率測度、$|\sigma| \le 1$ と規格化）を満たし、$f^{\star}$ は $\mathcal{G}$ の閉凸包に属する。

第 2 段：Maurey の確率的選択。$f^{\star}$ は $\mathcal{G}$ の閉凸包の元だから、$\varepsilon' > 0$ を任意にとれば $\mathcal{G}$ の有限凸結合 $f^{\star}_{\varepsilon'}$ で $\|f^{\star} - f^{\star}_{\varepsilon'}\|_{\mathcal{H}} < \varepsilon'$ となるものがある。以下 $f^{\star}$ が $\mathcal{G}$ の（有限）凸結合そのものである場合に評価を書き、最後に $\varepsilon' \to 0$ とすればよい（ε' は m に依らず取れるので、下の上界は保たれる）。このとき $\mathcal{G}$ 上の確率測度 P が存在して $f^{\star} = \mathbb{E}_{g \sim P}[g]$。$g_1, \dots, g_m$ を P から独立同分布に抽出し $\bar{g}_m := \frac{1}{m}\sum_{j} g_j$ とおくと $\mathbb{E}[\bar{g}_m] = f^{\star}$ であり、独立性から交差項が消えて

$$\mathbb{E}\bigl[\|\bar{g}_m - f^{\star}\|_{\mathcal{H}}^2\bigr] = \frac{1}{m^2}\sum_{j=1}^{m} \mathbb{E}\bigl[\|g_j - f^{\star}\|_{\mathcal{H}}^2\bigr] = \frac{1}{m}\Bigl(\mathbb{E}\|g\|_{\mathcal{H}}^2 - \|f^{\star}\|_{\mathcal{H}}^2\Bigr) \le \frac{b^2}{m}. \tag{10.29}$$

期待値が b^2/m 以下なら、その値以下を実現する標本が**少なくとも一つ**存在する（第一モーメント法）。その実現が $f_m = f(\boldsymbol{0}) + \bar{g}_m$ を与える。

証明を与えずに認めたのは第 1 段の (A1)–(A3)、すなわち Bochner 積分としての (10.28)の意味づけ、閉凸包への所属、および有界変動関数のシグモイド型素子による L^2 近似である。本質は(10.29)の**分散の $1/m$ 減衰**にあり、そこは完全に書いた。 ■

注意 10.27 (何を認めて使っているか)**.** 上の証明で厳密化を省いたのは第 1 段の (A1)–(A3) だけである。原論文 [12] はこれらを（近似の順序を入れ替えた形で）きちんと扱っており、結論(10.27)は 定義 10.25の測度による定義のもとで正しい。なお (A2) が $L^2(\mu)$ ノルムであることは省略ではなく**必然**である。有界変動関数のシグモイド型素子による近似を一様ノルムで行おうとすると10.4.2節の障害に突き当たる。定理の主張が $L^2(\mu)$ である理由の一つがここにある。

なぜ次元の呪いが消えたのか

(10.29)のどこにも d が現れない。鍵は二つある。

(1) 関数クラスを制限した。 Barron クラスは Lipschitz 関数より真に狭く、$C_f < \infty$ は f が少数のリッジ方向の重ね合わせで書けることを要求する。単一のリッジ関数 $f(\boldsymbol{x}) = g(\boldsymbol{w}^{\top}\boldsymbol{x})$ は d によらず C_f が一定で、典型例である。呪いが消えたのではなく、呪いを受けない部分クラスを切り出したのである。

(2) 基底を固定していない（非線形近似）。 m 個の固定基底の線形結合による **線形近似**では、滑らかさ s のクラスに対し誤差 $O(m^{-s/d})$ が限界で、d が指数に現れることを避けられない（Kolmogorov n-幅の下界）。ニューラルネットワークは基底 $\sigma(\boldsymbol{w}_j^{\top}\cdot+b_j)$ の向きを f に応じて選ぶ。これが $O(m^{-1/2})$ を可能にする。第8章のカーネル法は基底が $k(\cdot,\boldsymbol{x}_i)$ に固定されており、線形近似の側にいる。ここがカーネル法とニューラルネットワークの理論的な分かれ目である。

例 10.28 (Barron 定数の計算例)**.** d 次元で $f(\boldsymbol{x})=\sin(\boldsymbol{w}^{\top}\boldsymbol{x})$ ($\|\boldsymbol{w}\|=\kappa$) を考える。$\sin u=(e^{\mathrm{i}u}-e^{-\mathrm{i}u})/(2\mathrm{i})$ より、(10.26)の Fourier 測度は $\hat f=\frac{1}{2\mathrm{i}}(\delta_{\boldsymbol{w}}-\delta_{-\boldsymbol{w}})$ という**原子測度**であり、$|\mathrm{d}\hat f|=\frac12(\delta_{\boldsymbol{w}}+\delta_{-\boldsymbol{w}})$ だから

$$C_f=\int\|\boldsymbol{\omega}\|\,|\mathrm{d}\hat f|(\boldsymbol{\omega})=\tfrac12\|\boldsymbol{w}\|+\tfrac12\|-\boldsymbol{w}\|=\|\boldsymbol{w}\|=\kappa \tag{10.30}$$

で d に依存しない。定義 10.25を密度 $\widehat f(\boldsymbol{\omega})\,\mathrm{d}\boldsymbol{\omega}$ で書いていたらこの例は定義の外に出てしまう（$\pm\boldsymbol{w}$ の 1 点に台をもつ絶対連続測度は存在しない）。測度で定義しておいた効果がここに現れている。したがって m 素子で L^2 誤差 $O(\kappa/\sqrt{m})$ が達成でき、$d=1000$ でも $m=10^4$ 程度で実用的な精度になる。同じ関数を格子上の区分定数近似で捉えようとすれば $O(\varepsilon^{-d})$ 個の基底が要る。**関数の向きに合わせて基底を選ぶ**ことの威力がここに現れている。

10.8　学習：誤差逆伝播法

学習は第1章の正則化つき経験リスク最小化

$$\min_{\boldsymbol{\theta}}\ \mathcal{L}(\boldsymbol{\theta})\coloneqq\frac1n\sum_{i=1}^{n}\ell\big(y_i,f_{\boldsymbol{\theta}}(\boldsymbol{x}_i)\big)+\lambda\Omega(\boldsymbol{\theta}) \tag{10.31}$$

の形をとる（$\Omega(\boldsymbol{\theta})=\|\boldsymbol{\theta}\|^2$ が重み減衰）。違いは $f_{\boldsymbol{\theta}}$ が $\boldsymbol{\theta}$ について非線形であり $\mathcal{L}$ が非凸になる点にある。勾配を効率よく計算する方法が **誤差逆伝播法**（backpropagation）である。

記号は(10.1)のままである。すなわち $\boldsymbol{h}^{(0)}=\boldsymbol{x}$、事前活性 $\boldsymbol{z}^{(l)}=\boldsymbol{W}^{(l)}\boldsymbol{h}^{(l-1)}+\boldsymbol{b}^{(l)}$、活性 $\boldsymbol{h}^{(l)}=\sigma(\boldsymbol{z}^{(l)})$（$\sigma$ は成分ごとに作用、$l=1,\dots,L-1$）であり、出力は $f(\boldsymbol{x})=\boldsymbol{z}^{(L)}$ である。

まず 2 層で計算してみる。1 サンプル $(\boldsymbol{x},\boldsymbol{y})$、二乗損失 $\ell=\frac12\|\boldsymbol{z}^{(2)}-\boldsymbol{y}\|^2$、$\boldsymbol{z}^{(1)}=\boldsymbol{W}^{(1)}\boldsymbol{x}+\boldsymbol{b}^{(1)}$, $\boldsymbol{h}^{(1)}=\sigma(\boldsymbol{z}^{(1)})$, $\boldsymbol{z}^{(2)}=\boldsymbol{W}^{(2)}\boldsymbol{h}^{(1)}+\boldsymbol{b}^{(2)}$ とし、$\boldsymbol{\delta}^{(l)}\coloneqq\partial\ell/\partial\boldsymbol{z}^{(l)}$ とおく。出力層は $\boldsymbol{\delta}^{(2)}=\boldsymbol{z}^{(2)}-\boldsymbol{y}$ である。$z_p^{(2)}=\sum_q W_{pq}^{(2)}h_q^{(1)}+b_p^{(2)}$ より $\partial z_p^{(2)}/\partial W_{pq}^{(2)}=h_q^{(1)}$ だから、連鎖律で

$$\frac{\partial\ell}{\partial\boldsymbol{W}^{(2)}}=\boldsymbol{\delta}^{(2)}\big(\boldsymbol{h}^{(1)}\big)^{\top},\qquad \boldsymbol{\delta}^{(1)}=\Big(\big(\boldsymbol{W}^{(2)}\big)^{\top}\boldsymbol{\delta}^{(2)}\Big)\odot\sigma'\big(\boldsymbol{z}^{(1)}\big),\qquad \frac{\partial\ell}{\partial\boldsymbol{W}^{(1)}}=\boldsymbol{\delta}^{(1)}\boldsymbol{x}^{\top}. \tag{10.32}$$

中央の式は、$z_q^{(1)}$ が $\boldsymbol{h}^{(1)}$ を通じてすべての $z_p^{(2)}$ に影響することから $\delta_q^{(1)}=\big(\sum_p\delta_p^{(2)}W_{pq}^{(2)}\big)\sigma'(z_q^{(1)})$ を行列形に書いたものである（$\odot$ は成分ごとの積）。この構造は層数によらない。

命題 10.29 (誤差逆伝播)**.** (10.1)のネットワークに対し $\boldsymbol{\delta}^{(L)}=\partial\ell/\partial\boldsymbol{z}^{(L)}$ から

$$\boldsymbol{\delta}^{(l)}=\Big(\big(\boldsymbol{W}^{(l+1)}\big)^{\top}\boldsymbol{\delta}^{(l+1)}\Big)\odot\sigma'\big(\boldsymbol{z}^{(l)}\big),\qquad l=L-1,\dots,1 \tag{10.33}$$

と後ろ向きに再帰すれば $\partial\ell/\partial\boldsymbol{W}^{(l)}=\boldsymbol{\delta}^{(l)}(\boldsymbol{h}^{(l-1)})^{\top}$、$\partial\ell/\partial\boldsymbol{b}^{(l)}=\boldsymbol{\delta}^{(l)}$ が得られる（$\boldsymbol{h}^{(l-1)}$ は(10.1)の活性、$\boldsymbol{h}^{(0)}=\boldsymbol{x}$）。

証明. $l=L$ は(10.32)と同じ計算である。$l+1$ で成り立つとする。$\boldsymbol{z}^{(l)}$ は $\boldsymbol{h}^{(l)}=\sigma(\boldsymbol{z}^{(l)})$ を通じて $\boldsymbol{z}^{(l+1)}$ にのみ影響し、他の経路はない。連鎖律より $\boldsymbol{\delta}^{(l)}=(\partial\boldsymbol{z}^{(l+1)}/\partial\boldsymbol{z}^{(l)})^{\top}\boldsymbol{\delta}^{(l+1)}$ であり、ヤコビ行列は $\boldsymbol{W}^{(l+1)}\,\mathrm{diag}(\sigma'(\boldsymbol{z}^{(l)}))$ だから、転置すれば(10.33)の右辺に一致する。重みの勾配も同様。 ■

確率勾配降下法と甘利俊一

> 誤差逆伝播法は Rumelhart, Hinton, Williams の 1986 年の論文 [67] で広く知られるようになったが、「多層ネットワークを勾配で学習させる」という発想自体はそれよりずっと早く現れている。日本の**甘利俊一**（1936–）は 1967 年の論文 [2] で、パターン識別器の重みを**確率勾配降下法**——1 サンプルごとに勾配を推定して少しずつ更新する方法——で学習させる枠組みを与えた。翌年の著書 [3] には、5 層のうち 2 層を可変にしたネットワークが線形分離不可能なクラスを分けられるようになる計算機実験が載っている（実験自体は研究室の大学院生・斎藤庄司が 1967 年に行い、修士論文として日本語で発表した）。中間層が「内部表現」を獲得する現象を、この時期に実際に見ていたわけである。
>
> ただし帰属は正確に述べておきたい。甘利の 1967 年の仕事は **勾配を使って多層網を学習させる**ことの先駆だが、勾配を出力側から入力側へ再帰的に計算する(10.33)の組み方（今日の逆伝播、すなわち自動微分の逆モード）を明示したものではない。逆モードの自動微分としての定式化と、それが多層網の学習に有効であることの実証は別の系譜に属する。甘利自身は

> 後に [4] で、誤差逆伝播法を確率勾配法の一つの実装として位置づけ直している。
>
> この系譜はさらに続く。パラメータ空間を平坦なユークリッド空間ではなく Fisher 情報行列を計量とする Riemann 空間とみなし、$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \boldsymbol{G}(\boldsymbol{\theta})^{-1} \nabla \mathcal{L}$ と更新するのが甘利の**自然勾配法** [5] である。ここで $\boldsymbol{G}(\boldsymbol{\theta})$ は **Fisher 情報行列**（モデルの対数尤度の勾配の共分散 $\mathbb{E}\big[\nabla \log p_{\boldsymbol{\theta}} \, (\nabla \log p_{\boldsymbol{\theta}})^{\top}\big]$）である。これは「勾配降下の向きがパラメータの取り方に依存してしまう」という素朴な勾配法の弱点を、情報幾何の言葉で解決したものである。第 2 章の Rayleigh 商が物理から来ていたように、ここでも最適化の手続きが幾何の問題として捉え直されている。

順伝播は各層で $O(n_{l-1} n_l)$、逆伝播も転置行列との積で同じである。したがって **勾配の計算コストは関数値の計算コストの定数倍**（2〜3 倍）で済む。数値微分ならパラメータ数 P に対し $O(P)$ 回の順伝播が要ることと比べると、この差は決定的である。これは**リバースモード自動微分**の一般原理の特別な場合であり、計算グラフを一度前向きに辿って中間値を保存し、一度後ろ向きに随伴変数を伝播させる、という形に抽象化される。

リスト 10.2　誤差逆伝播のスクラッチ実装（式(10.32)、(10.33)）と数値微分による検証

```python
import numpy as np

def loss_grad(p, X, Y):
    # X は d×n、Y は n_out×n（ともに列がサンプル）
    W1, b1, W2, b2 = p
    n = X.shape[1]
    Z1 = W1 @ X + b1[:, None]; A1 = np.tanh(Z1)                 # forward
    Z2 = W2 @ A1 + b2[:, None]
    R = Z2 - Y
    L = 0.5 * np.sum(R**2) / n
    D2 = R / n                          # delta at output layer, shape (n_out,n)
    gW2, gb2 = D2 @ A1.T, D2.sum(1)  # dL/dW2 = delta a^T（外積をサンプルで和）
    D1 = (W2.T @ D2) * (1 - A1**2)   # backprop: (W^T delta) * sigma'
    gW1, gb1 = D1 @ X.T, D1.sum(1)
    return L, [gW1, gb1, gW2, gb2]

rng = np.random.default_rng(0)
X, Y = rng.normal(size=(7,3)).T, rng.normal(size=(7,2)).T   # d×n, n_out×n
p = [rng.normal(0, np.sqrt(2/3), (5,3)), np.zeros(5),      # He init
     rng.normal(0, np.sqrt(1/5), (2,5)), np.zeros(2)]
L, g = loss_grad(p, X, Y)

h = 1e-6                                                    # central difference
for i, P in enumerate(p):
    gn = np.zeros_like(P)
    for idx in np.ndindex(P.shape):        # perturb one entry at a time
        old = P[idx]
        P[idx] = old + h; Lp, _ = loss_grad(p, X, Y)
        P[idx] = old - h; Lm, _ = loss_grad(p, X, Y)
        P[idx] = old;     gn[idx] = (Lp - Lm) / (2*h)
    print(i, np.max(np.abs(gn - g[i])) / np.max(np.abs(gn)))
# -> 1.1e-09, 2.7e-09, 1.8e-10, 3.3e-10 : matches numerical gradients
```

相対誤差は中心差分の丸め誤差の水準であり、数式がそのままコードの数行に対応することを確認してほしい。

10.8.1　勾配消失・爆発と初期化

(10.33)を $l = 1$ まで展開すると行列の積 $\boldsymbol{\delta}^{(1)} = \big(\prod_{l=2}^{L} \mathrm{diag}(\sigma'(\boldsymbol{z}^{(l-1)}))(\boldsymbol{W}^{(l)})^{\top}\big)\boldsymbol{\delta}^{(L)}$ が現れ、作用素ノルムをとれば $\|\boldsymbol{\delta}^{(1)}\| \le (\|\sigma'\|_{\infty} \max_l \|\boldsymbol{W}^{(l)}\|_{\mathrm{op}})^{L-1} \|\boldsymbol{\delta}^{(L)}\|$ となる。括弧内が 1 より小さければ勾配は層数について指数的に減衰し（**勾配消失**）、大きければ指数的に増大する（**勾配爆発**）。シグモイドは $\|\sigma'\|_{\infty} = 1/4$ なので消失側に倒れやすい。ReLU が使われる理由の一つは $\sigma' \in \{0, 1\}$ で減衰因子が入らないことである。

初期化はこの積を 1 に近く保つよう設計する。重みを平均 0・分散 v の独立同分布とすると $\mathrm{Var}(z_p^{(l)}) = \sum_{q=1}^{n_{l-1}} \mathrm{Var}(W_{pq}) \mathbb{E}[(h_q^{(l-1)})^2] = n_{l-1} v \, \mathbb{E}[(h^{(l-1)})^2]$ である。tanh のように原点近傍で線形なら $\mathbb{E}[h^2] \approx \mathrm{Var}(z^{(l-1)})$ なので、分散を層間で保つには $v = 1/n_{l-1}$。逆伝播側の保存は $v = 1/n_l$ を要求するので、両者の妥協として $v_{\mathrm{Xavier}} = 2/(n_{l-1} + n_l)$ とするのが **Xavier（Glorot）初期化**である。ReLU では z が原点対称なら $\mathbb{E}[(z_+)^2] = \tfrac{1}{2}\mathbb{E}[z^2]$ と半減するので、それを補って

$$v_{\mathrm{He}} = 2/n_{l-1} \tag{10.34}$$

とするのが **He 初期化**であり、因子 2 が ReLU による半減を打ち消している。

10.8.2　確率的勾配降下法

n が大きいと全和の勾配は高価である。サイズ B のミニバッチ $\mathcal{I}_t$ を無作為に選び

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \eta_t \Big(\frac{1}{B} \sum_{i \in \mathcal{I}_t} \nabla_{\boldsymbol{\theta}} \ell\big(y_i, f_{\boldsymbol{\theta}_t}(\boldsymbol{x}_i)\big) + \lambda \nabla_{\boldsymbol{\theta}} \Omega(\boldsymbol{\theta}_t) \Big) \tag{10.35}$$

と更新するのが**確率的勾配降下法**（stochastic gradient descent, SGD）である。ミニバッチ勾配は全勾配の不偏推定量であり、その分散が探索にノイズを与える。このノイズは単なる妥協ではなく汎化に寄与すると考えられている。同じ訓練誤差を達成する解が無数にある中で SGD は「平坦な」極小に落ちやすく、それが汎化と相関するという観察がある。これを**暗黙の正則化**（implicit regularization）と呼び、第11章で論じる。

10.9　非凸性——SVM との対比

第9章の SVM は凸二次計画であり、大域最適解が一意に定まり双対問題を解けば必ずそこに到達できた。ニューラルネットワークではこれが崩れる。

命題 10.30（置換対称性）**.** $f(\boldsymbol{x}) = \sum_{j=1}^{m} c_j \sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + b_j)$ は隠れ素子の添字の置換で不変である。σ が奇関数（tanh など）ならば各素子の符号反転 $(\boldsymbol{w}_j, b_j, c_j) \mapsto (-\boldsymbol{w}_j, -b_j, -c_j)$ でも不変である。すなわち位数 $2^m m!$ の群 $G = (\mathbb{Z}/2)^m \rtimes S_m$ がパラメータ空間に作用し、その作用は表す関数を変えない。したがって **各素子が非零で互いに異なる**（$(\boldsymbol{w}_j, b_j, c_j) \neq \boldsymbol{0}$ であり、$j \neq j'$ に対し $(\boldsymbol{w}_j, b_j, c_j) \neq \pm(\boldsymbol{w}_{j'}, b_{j'}, c_{j'})$）ならば、同じ関数を表すパラメータがちょうど $2^m m!$ 個存在する。

証明. 和は可換なので置換不変。符号反転については σ が奇関数なら $(-c_j)\sigma(-\boldsymbol{w}_j^\top \boldsymbol{x} - b_j) = (-c_j)(-\sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + b_j)) = c_j \sigma(\boldsymbol{w}_j^\top \boldsymbol{x} + b_j)$。よって G の作用は関数を保つ。軌道の大きさは軌道・固定部分群定理より $|G|/|G_\theta| = 2^m m!/|G_\theta|$（$G_\theta$ は θ の固定部分群）で、上の非退化条件は $G_\theta = \{e\}$ と同値である。実際、$g \in G_\theta$ が素子 j を j' に写して符号 ε を掛けるなら $(\boldsymbol{w}_j, b_j, c_j) = \varepsilon(\boldsymbol{w}_{j'}, b_{j'}, c_{j'})$ が必要で、条件から $j = j'$ かつ $\varepsilon = +1$。 ■

退化した点では軌道が小さくなる

非退化条件を落とすと個数はちょうど $2^m m!$ にならない。極端な例として全パラメータが $\boldsymbol{0}$ なら群のどの元も θ を動かさないので $G_\theta = G$、軌道は **1 点**である。$m = 3$、$d = 2$ で数え上げると、一般の点では軌道サイズ $48 = 2^3 \cdot 3!$、全ゼロでは 1、三素子がすべて同一なら 8、一素子だけ $\boldsymbol{0}$ なら 24 になる。つまり $2^m m!$ は**上限**であって、常に達成される個数ではない。

この対称性が損失地形の非凸性を直接に説明する。同じ関数を表す二点はどちらも損失を同じ値にするが、その**中点**は一般に別の関数を表すので損失が上がる。$\sigma = \tanh$、$m = 2$、$d = 1$ で $f^\star(x) = \tanh(x)$ を学習させる場合、第 1 素子だけを使う解 θ_A と第 2 素子だけを使う解 θ_B はいずれも損失 0 だが、中点 $(\theta_A + \theta_B)/2$ は $x \mapsto \frac{1}{2}\tanh(x/2) + \frac{1}{2}\tanh(x/2) = \tanh(x/2)$ を表すので $[-2, 2]$ 上の二乗損失が 0.0580 になる。損失関数が凸なら中点の値は両端の平均以下（この場合 0）でなければならないから、これは非凸性の証明である。

$m = 100$ なら $2^{100} \cdot 100! \approx 10^{188}$ 個の同値な大域最適解がある。凸関数の最小点集合は凸だが、これら離散的に散らばった点の中点は一般に最適解でないから、$\mathcal{L}$ は凸ではありえない。高次元の非凸最適化では**鞍点**が多数現れることがあり、また過剰パラメータ化された領域（$P \gg n$）では最小解が孤立せず連結した集合をなす場合がある。ただしこれらは損失地形の**一般的な定理ではなく**、ネットワーク構造・データ・損失関数に依存する性質である（ランダム行列に基づく「臨界点のほとんどは鞍点」という直観は、Hessian の固有値がランダムに振る舞うモデルについてのものであって、一般のニューラルネットワークの損失関数について証明された主張ではない）。

左列は「カーネル法一般」ではない

表 10.1の左列が成り立つのは、基底を $k(\cdot, \boldsymbol{x}_i)$ に固定して **係数について**二次の正則化つき凸問題を解く場合である。カーネル法全体では三つの行が崩れる。

- **凸性**：カーネル PCA（第8章）は凸最適化ではなく固有値問題である。帯域幅 σ も最適化するならその依存性は凸でない。
- **一意性**：$\lambda > 0$ の KRR は目的関数が狭義凸なので一意だが、SVM の切片 b は支持ベクトルの配置によっては区間でしか決まらず、カーネル PCA は固有値が縮退すれば主成分方向が一意でない。
- **近似率**：$O(m^{-s/d})$ 型は、Sobolev 型の滑らかさ s を仮定したときに **基底を固定した線形近似**で現れる典型的な次元依存率である。同じ関数クラスでも仮定が変われば率は変わる。Barron クラスの $O(m^{-1/2})$ と並べて読むときは、**クラスが違う**こと（定義 10.25）に注意する。

表10.1　固定基底型のカーネル法（カーネルリッジ回帰、ソフトマージン SVM など）とニューラルネットワークの対比。表現力を得る代償として最適化の保証を失う、というトレードオフが読み取れる。左列はカーネルリッジ回帰やソフトマージン SVM のように**正則化つき凸問題として定式化されるもの**を指し、カーネル法一般の性質ではない（下の注意を見よ）。

	固定基底型カーネル法（第8章・第9章）	ニューラルネットワーク
特徴写像 $\boldsymbol{\phi}$	人が k を通じて指定	データから学習
基底	$k(\cdot, \boldsymbol{x}_i)$ に固定	向き $\boldsymbol{w}_j$ も可変
近似の型	線形近似（基底は固定）	非線形近似
最適化問題	凸（大域最適が保証）	非凸（保証なし）
解の一意性	一意（正則化 $\lambda > 0$ の KRR）	$2^m m!$ 重の対称性
最悪近似率	$O(m^{-s/d})$ 型（Sobolev 型の滑らかさ s の下）	Barron クラスで $O(m^{-1/2})$

要するにこの表は「基底を固定するか、基底ごと動かすか」の対比であって、カーネルという道具の良し悪しの表ではない。

残された問い（第11章へ）

非凸問題を解いているのだから、勾配降下法が大域最適に到達する理由はなく、実際その保証もない。それにもかかわらず深層ネットワークは実用上よく動く。しかもパラメータ数がサンプル数を大きく超えて（$P \gg n$）訓練誤差がゼロになる領域で、なおテスト誤差が下がり続けることさえある。古典的なバイアス・分散のトレードオフからは説明できないこの現象にどう答えるか。第11章で無限幅極限（NTK）と二重降下という二つの糸口を扱う。

演習問題

演習 10.1 ($\star$)**.** 例 10.6とは異なる重み $(\boldsymbol{w}_1, b_1, \boldsymbol{w}_2, b_2, c_1, c_2)$ で XOR を表現する 1 隠れ層ネットワーク（活性化は階段関数）を一組構成し、4 点すべてで正しいことを確認せよ。また、隠れ素子が 1 個（$m = 1$）では XOR を表現できないことを示せ。

演習 10.2 ($\star\star$)**.** σ を連続なシグモイド型関数、$b_1 < b_2$ とし、$\beta_a(x) = \sigma(a(x - b_1)) - \sigma(a(x - b_2))$ とおく（式(10.10)）。

(1) $a \to \infty$ のとき、$x \neq b_1, b_2$ をみたす各 x で $\beta_a(x) \to \mathbf{1}\{b_1 < x < b_2\}$ が成り立つことを示せ（境界の 2 点は (3) で扱う）。

(2) 任意の $\delta \in (0, (b_2 - b_1)/2)$ に対し、$E_\delta := \{x \in \mathbb{R} : |x - b_1| \geq \delta,\ |x - b_2| \geq \delta\}$ 上で収束が一様であることを示せ。

(3) $x = b_1$ および $x = b_2$ における β_a の値の極限を求め（σ が連続で $\sigma(0)$ が定まる場合）、収束が $\mathbb{R}$ 全体では一様でないことを示せ。

演習 10.3 ($\star$)**.** (10.13)の hat 関数 Λ_k（$h = 1/N$、$t_k = kh$、$k = 0, \dots, N$）について、**1 の分割**(10.14)、すなわち

$$\sum_{k=0}^{N} \Lambda_k(x) = 1 \qquad (x \in [0,1])$$

が成り立つことを示せ。（x を含む小区間 $[t_k, t_{k+1}]$ を固定し、その上で 0 にならない Λ_j がどれかを調べればよい。端の小区間 $[t_0, t_1]$、$[t_{N-1}, t_N]$ でも同じ議論が通ることを確認すること。）

演習 10.4 ($\star\star$)**.** (10.13)の hat 関数 Λ_k（$h = 1/N$、$t_k = kh$）と $f \in C([0,1])$ について。以下では演習 10.3の 1 の分割(10.14)を用いてよい。

(1) 区分線形補間 $f_N = \sum_k f(t_k)\Lambda_k$ について $\sup_{[0,1]} |f - f_N| \leq \omega_f(h)$（式(10.16)）を示せ。さらに $f \in C^2$ なら $\leq \|f''\|_\infty h^2/8$ に改良できることを 定理 10.19の議論から導け。

(2) 一方、中点値の階段関数 $\tilde{f}_N = \sum_k f(\bar{t}_k)\mathbf{1}\{t_k < x < t_{k+1}\}$ について、$f(0) \neq 0$ ならば N をどれだけ大きくしても $\sup_{[0,1]} |f - \tilde{f}_N| \geq |f(0)|$ であることを示せ。hat 関数を使う理由がここにある。

演習 10.5 ($\star\star$)**.** $T(x) = 1 - |2x - 1|$ とする。

(1) $x \in [0,1]$ において T を 2 個の ReLU 素子で厳密に表現せよ。また $\mathbb{R}$ 全体で $\max(0, T)$ に一致させるには 3 個必要であることを確かめよ。

(2) $T^{\circ L}$ の折れ点の個数がちょうど $2^L - 1$ であることを、定理 10.21の帰納法を自分で再構成して示せ。

(3) $T^{\circ L}$ を 1 隠れ層の ReLU 網で厳密に表現するために必要な幅の下界を求めよ。

演習 10.6 (⋆⋆)**.** 補題 10.12の証明の第 2 段で、$\varphi \to -\infty$ の極限を用いて $\mu(H_{\boldsymbol{w},b}) = 0$ を導いた。この議論において、σ が有界であることをどこで使ったかを指摘せよ。また、$\sigma(t) = t$（恒等写像）としたとき、σ が判別的でないことを $d = 1$、$I_1 = [0,1]$ の具体的な符号付き測度の例で示せ。

演習 10.7 (⋆⋆⋆)**.** 定理 10.26の証明第 2 段（Maurey の議論）を、次の設定で自分で書き下せ。ヒルベルト空間 $\mathcal{H}$ の部分集合 $\mathcal{G}$ が $\sup_{g\in\mathcal{G}}\|g\| \le b$ を満たし、f が $\mathcal{G}$ の凸包に属するとする（有限凸結合でよい）。このとき $g_1,\dots,g_m \in \mathcal{G}$ が存在して $\|f - \frac{1}{m}\sum_{j} g_j\|^2 \le (b^2 - \|f\|^2)/m$ となることを示せ。さらに、この評価が $\mathcal{H}$ の次元に依存しないことが、なぜ Barron の定理で「次元の呪いの回避」につながるのかを説明せよ。

演習 10.8 (実装, ⋆⋆)**.** リスト 10.2を拡張し、隠れ層を 2 層（幅 m_1, m_2、活性化 tanh）にしたネットワークの誤差逆伝播を NumPy でスクラッチ実装せよ。

(1) 命題 10.29の(10.33)をそのままループとして実装し、中心差分による数値微分と全パラメータで相対誤差 10^{-6} 以下で一致することを確認せよ。

(2) 活性化を ReLU に変えて同じ検証を行い、$z = 0$ 近傍で数値微分が一致しにくい理由を述べよ。

(3) 初期化を $v = 1/n_{l-1}$（Xavier 型）と $v = 2/n_{l-1}$（He 型）で変えて 10 層の ReLU 網を作り、各層での順伝播の活性の分散 $\mathrm{Var}(h^{(l)})$ を l の関数としてプロットし、式(10.34)の主張を数値的に検証せよ。

演習 10.9 (実装, ⋆⋆)**.** $g(x) = \sin(2\pi x)$、$x \in [0,1]$ とする。

(1) m 等分の節点で g を区分線形補間し、その一様誤差を $m = 4, 8, \dots, 256$ について数値的に求め、両対数プロットの傾きが -2 になることを確認せよ（定理 10.19）。

(2) 式(10.24)を用いて、この折れ線を実際に ReLU の線形結合として構成し、両者が機械精度で一致することを確かめよ。

(3) 同じ g をシグモイドのバンプ（式(10.10)、N 個）で近似したときの L^2 誤差の減衰率を求め、(1) と比較して減衰が遅い理由を説明せよ。また一様誤差を測り、$N \to \infty$ でも 0 に収束しないことを確認して、その理由を10.4.2節の警告と照らして述べよ。

演習 10.10 (実装, ⋆⋆⋆)**.** 1 隠れ層 tanh ネットワークを幅 $m = 2, 4, 8, \dots, 128$ と変えて、$d = 1$ の目標関数 $g(x) = \sin(2\pi x) + \frac{1}{2}\sin(6\pi x)$ を $[0,1]$ 上の等間隔 1000 点で二乗誤差最小化により学習し（SGD あるいは Adam、十分な反復回数）、学習後の L^2 誤差を m の関数として両対数プロットせよ。

(1) 観測される減衰率を定理 10.26の $O(m^{-1/2})$ および 定理 10.19の $O(m^{-2})$ と比較し、どちらに近いか論ぜよ。

(2) 各 m について異なる乱数初期値で 10 回学習し、誤差のばらつきを箱ひげ図で示せ。幅が大きいほどばらつきが小さくなるか。

(3) $d = 5$ に拡張し（$g(\boldsymbol{x}) = \sin(2\pi \boldsymbol{w}^{\top}\boldsymbol{x})$、$\boldsymbol{w}$ は固定）、減衰率が d にどう依存するかを調べよ。Barron クラスの理論と整合するか。

演習 10.11 (⋆⋆)**.** (10.15)の $f_N(x) = \sum_{k=0}^{N} f(t_k)\Lambda_k(x)$ が f の**区分線形補間**であること、すなわち

(a) $f_N(t_j) = f(t_j)$ $(j = 0,\dots,N)$、

(b) 各小区間 $[t_k, t_{k+1}]$ $(k = 0,\dots,N-1)$ 上で f_N は x の 1 次式である、

を示せ。さらに (a)(b) をみたす関数は一意であること（したがって f_N が「区分線形補間」と呼ぶべき唯一の関数であること）を示せ。

（ヒント）(a) は $\Lambda_k(t_j) = \delta_{jk}$ から従う。(b) は $x \in [t_k, t_{k+1}]$ で Λ_k, Λ_{k+1} 以外が 0 になることを使い、f_N を $f(t_k), f(t_{k+1})$ の 1 次結合として明示的に書け。一意性は差を考えて、各小区間で 1 次式かつ両端で 0 なら恒等的に 0 であることを使う。

第 11 章

発展的話題

この章のねらい

線形代数から PCA、高次元統計、関数解析、カーネル法、ニューラルネットワークまでを一本の線でたどってきた。この最終章では、その先にある現代的な話題を五つ選んで紹介する。ねらいは新しい定理を積み上げることではなく、**すでに手にした道具だけで現代の話題がどこまで理解できるか**を示すことにある。**NTK** は第10章のネットワークを第7章のカーネル法として読み直す試み、二**重降下**は第2章の最小ノルム解と第5章のランダム行列理論が結びつく場所、**多様体学習**は第6章の一般化固有値問題と第8章のカーネル PCA の応用、**行列補完**は第2章の特異値と第9章の凸最適化の組合せ、**最適輸送**は第7章の MMD と並べると位置づけが明確になる。各節は独立に読め、先へ進むための文献を最後に挙げる。[a]

[a] この章の計算は演習ノートブック `ch11_advanced.ipynb` で再現できる。インストール不要で実行するには Google Colab で開く：`https://colab.research.google.com/github/yusukeimoto/data-analysis-math-demos/blob/main/notebooks/ch11_advanced.ipynb`

11.1 ランダム特徴とニューラルタンジェントカーネル

11.1.1 最終隠れ層をどう扱うか

式 (10.1)の MLP の最終隠れ層を $\boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x}) \coloneqq \boldsymbol{h}^{(L-1)} \in \mathbb{R}^{p}$ と書くと、出力は $f(\boldsymbol{x}) = \boldsymbol{a}^{\top}\boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x}) + b$ という**特徴 $\boldsymbol{h}_{\boldsymbol{\theta}}$ の上の線形モデル**である。第10章では $\boldsymbol{h}_{\boldsymbol{\theta}}$ と $\boldsymbol{a}$ の両方をデータから学習した。$\boldsymbol{h}_{\boldsymbol{\theta}}$ の扱いを変えた三つの場合を並べると、ニューラルネットワークとカーネル法の関係が見える。

(1) 特徴を固定する。 $\boldsymbol{h}$ を固定して $\boldsymbol{a}$ だけを学習するなら、これは固定特徴上の線形回帰にすぎない。第7章で見たとおり、こうした問題は双対側から $k(\boldsymbol{x}, \boldsymbol{x}') = \boldsymbol{h}(\boldsymbol{x})^{\top}\boldsymbol{h}(\boldsymbol{x}')$ というカーネルの言葉でも書ける（正定値性は $\sum_{i,j} c_i c_j k(\boldsymbol{x}_i, \boldsymbol{x}_j) = \left\| \sum_i c_i \boldsymbol{h}(\boldsymbol{x}_i) \right\|^2 \geq 0$ による）。カーネルが主役なのではなく、**固定された特徴の上の線形モデルは、その特徴の内積を使ったカーネル法としても表せる**という双対性である。$\boldsymbol{h}(\boldsymbol{x}) = \boldsymbol{x}$ なら線形カーネル、Gauss カーネルに対応する無限次元の特徴をとれば第7章以来のカーネル法そのもので、カーネルリッジ回帰や SVM なら凸最適化、カーネル PCA なら固有値問題になる。

(2) 特徴をランダムに固定する。 $\boldsymbol{h}$ を MLP の隠れ層の形に取り、その重みを**ランダムに引いて固定**する。有限幅なら第8章のランダム特徴で、幅を無限にすると $\boldsymbol{h}(\boldsymbol{x})^{\top}\boldsymbol{h}(\boldsymbol{x}')$ が決まった極限カーネルに収束する。**ネットワークのランダムな隠れ層が、無限幅でカーネルになる**というこの対応が次の小節の主題である。

(3) 特徴を学習する。 $\boldsymbol{h}_{\boldsymbol{\theta}}$ も学習すれば問題は非凸になり、特徴は固定されない。これが第10章の立場である。全パラメータを学習するときに現れるカーネルは隠れ層の内積ではなく、パラメータに関する勾配を特徴とみなしたもので、11.1.3節で扱う。

補足：最終隠れ層の後ろにカーネル法を置く

MLP は学習した表現 $\boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x})$ の後ろに**線形層**を置き、$f(\boldsymbol{x}) = \boldsymbol{a}^{\top}\boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x})$ とする。ここを線形層ではなく**カーネル法**にする方法もあり、**deep kernel learning** [83] と呼ばれる。既存のカーネル k_0 を使って

$$k_{\boldsymbol{\theta}}(\boldsymbol{x}, \boldsymbol{x}') \coloneqq k_0\big(\boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x}), \boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x}')\big), \qquad f(\boldsymbol{x}) = \sum_{i=1}^{n} \alpha_i \, k_0\big(\boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x}), \boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x}_i)\big)$$

とし、$\boldsymbol{\theta}$（表現）と $\boldsymbol{\alpha}$（カーネル法の係数）を一緒に学習する。k_0 を Gauss カーネルにとれば $k_{\boldsymbol{\theta}}(\boldsymbol{x},\boldsymbol{x}') = \exp\bigl(-\|\boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x}) - \boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x}')\|^2/2s^2\bigr)$ で、従来のカーネル法は $\boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x}) = \boldsymbol{x}$ に固定した場合にあたる。

11.1.2　無限幅で現れる NNGP カーネル

幅 m の 2 層ネットワークを

$$f(\boldsymbol{x};\boldsymbol{\theta}) = \frac{1}{\sqrt{m}}\sum_{r=1}^{m} a_r\,\sigma(\boldsymbol{w}_r^\top \boldsymbol{x} + b_r), \qquad \boldsymbol{\theta} = (a_1,\dots,a_m,\boldsymbol{w}_1,\dots,\boldsymbol{w}_m,b_1,\dots,b_m) \tag{11.1}$$

と書く（$\boldsymbol{w}_r \in \mathbb{R}^d$、$a_r, b_r \in \mathbb{R}$）。式 (10.1)で $L=2$、$n_1 = m$ とした 1 隠れ層ネットワークに、幅で決まる規格化 $1/\sqrt{m}$ を付けたものである（この規格化は本質的で、後で理由が分かる）。隠れ層のパラメータ $(\boldsymbol{w}_r, b_r)$ を初期値のまま固定し出力層 a_r だけを学習すると、式 (11.1)は $\boldsymbol{a}$ について線形で、$f(\boldsymbol{x};\boldsymbol{a}) = \langle \boldsymbol{a}, \boldsymbol{\phi}_m(\boldsymbol{x})\rangle$、$\boldsymbol{\phi}_m(\boldsymbol{x}) = m^{-1/2}(\sigma(\boldsymbol{w}_1^\top\boldsymbol{x}+b_1),\dots,\sigma(\boldsymbol{w}_m^\top\boldsymbol{x}+b_m))^\top$ という **明示的特徴写像による線形モデル**にほかならない。n 点をまとめた**特徴行列**は $\boldsymbol{\Phi} = [\boldsymbol{\phi}_m(\boldsymbol{x}_1),\dots,\boldsymbol{\phi}_m(\boldsymbol{x}_n)] \in \mathbb{R}^{m\times n}$（第 i 列が $\boldsymbol{\phi}_m(\boldsymbol{x}_i)$）で、隠れ層の重みを $\boldsymbol{R} = (\boldsymbol{w}_1,\dots,\boldsymbol{w}_m)^\top \in \mathbb{R}^{m\times d}$、バイアスを $\boldsymbol{b} = (b_1,\dots,b_m)^\top$ と並べれば $\boldsymbol{\Phi} = m^{-1/2}\sigma(\boldsymbol{R}\boldsymbol{X} + \boldsymbol{b}\boldsymbol{1}_n^\top)$ と**左から掛ける**形になる（$\boldsymbol{X} \in \mathbb{R}^{d\times n}$、$\sigma$ は成分ごと）。Gram 行列は $\boldsymbol{K}_m = \boldsymbol{\Phi}^\top\boldsymbol{\Phi} \in \mathbb{R}^{n\times n}$ である。これは第8章のランダムフーリエ特徴と同じ構造で、対応するカーネルは大数の法則により

$$k_m(\boldsymbol{x},\boldsymbol{x}') = \frac{1}{m}\sum_{r=1}^{m}\sigma(\boldsymbol{w}_r^\top\boldsymbol{x}+b_r)\sigma(\boldsymbol{w}_r^\top\boldsymbol{x}'+b_r) \xrightarrow[m\to\infty]{\text{a.s.}} k_\sigma(\boldsymbol{x},\boldsymbol{x}') \coloneqq \mathbb{E}_{\boldsymbol{w},b}\bigl[\sigma(\boldsymbol{w}^\top\boldsymbol{x}+b)\sigma(\boldsymbol{w}^\top\boldsymbol{x}'+b)\bigr] \tag{11.2}$$

に収束する（$(\boldsymbol{w}_r, b_r)$ は独立同分布、たとえば $\boldsymbol{w} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}_d)$、$b \sim \mathcal{N}(0,\beta^2)$）。さらに $a_r \sim \mathcal{N}(0,1)$ とすれば、式 (11.1)は独立確率変数の和を $\sqrt{m}$ で割ったものだから中心極限定理により、$m\to\infty$ で平均 0・共分散関数 k_σ のガウス過程に分布収束する。これを **NNGP カーネル**（neural network Gaussian process kernel）と呼ぶ [57, 48]。

以下、ReLU カーネルと NTK の閉形式を簡潔に導くため、**本節の残りでは $b_r \equiv 0$ に固定して学習対象から外し**、$\boldsymbol{\theta} = (a_1,\dots,a_m,\boldsymbol{w}_1,\dots,\boldsymbol{w}_m)$ とする（b_r も学習するなら、後の式 (11.5)にバイアス方向の勾配の寄与が加わる）。一般の b_r でも式 (11.2)までの枠組みはそのまま通るが、次の命題の証明は $\boldsymbol{w}$ の分布の回転不変性で問題を $\boldsymbol{x},\boldsymbol{x}'$ の張る 2 次元平面に落とすので、$b \neq 0$ だと角度だけの計算にならない。ReLU ではこの期待値が閉形式で書ける。

命題 11.1（arccos カーネル [23]）**.** $\sigma(t) = \max(t,0)$、$\boldsymbol{w} \sim \mathcal{N}(\boldsymbol{0},\boldsymbol{I}_d)$ とする。$\boldsymbol{x},\boldsymbol{x}' \neq \boldsymbol{0}$ のなす角を $\vartheta \coloneqq \arccos\bigl(\boldsymbol{x}^\top\boldsymbol{x}'/(\|\boldsymbol{x}\|\|\boldsymbol{x}'\|)\bigr) \in [0,\pi]$ とすると

$$k_\sigma(\boldsymbol{x},\boldsymbol{x}') = \frac{\|\boldsymbol{x}\|\|\boldsymbol{x}'\|}{2\pi}\bigl(\sin\vartheta + (\pi-\vartheta)\cos\vartheta\bigr). \tag{11.3}$$

証明. $\boldsymbol{w}$ の分布は回転不変だから、$\boldsymbol{x},\boldsymbol{x}'$ の張る 2 次元部分空間への射影だけを見ればよい。その中で $\boldsymbol{x} = \|\boldsymbol{x}\|(1,0)^\top$、$\boldsymbol{x}' = \|\boldsymbol{x}'\|(\cos\vartheta,\sin\vartheta)^\top$ と取り $\boldsymbol{w} = \rho(\cos\psi,\sin\psi)^\top$ と極座標表示すると、ρ,ψ は独立で ψ は $[0,2\pi)$ 上一様、$\mathbb{E}[\rho^2] = 2$ である。$\sigma(\boldsymbol{w}^\top\boldsymbol{x})\sigma(\boldsymbol{w}^\top\boldsymbol{x}') = \rho^2\|\boldsymbol{x}\|\|\boldsymbol{x}'\|\sigma(\cos\psi)\sigma(\cos(\psi-\vartheta))$ で、両因子が正になるのは $\psi \in (\vartheta-\pi/2, \pi/2)$（長さ $\pi-\vartheta$）のときだから、$\mathbb{E}[\sigma(\boldsymbol{w}^\top\boldsymbol{x})\sigma(\boldsymbol{w}^\top\boldsymbol{x}')] = \frac{2\|\boldsymbol{x}\|\|\boldsymbol{x}'\|}{2\pi}\int_{\vartheta-\pi/2}^{\pi/2}\cos\psi\cos(\psi-\vartheta)\,\mathrm{d}\psi$。積和公式 $\cos\psi\cos(\psi-\vartheta) = \frac{1}{2}\{\cos\vartheta + \cos(2\psi-\vartheta)\}$ より積分は $\frac{1}{2}\{(\pi-\vartheta)\cos\vartheta + \sin\vartheta\}$ となり、式 (11.3)を得る。 ■

数値で見ると、単位ベクトルでは $\vartheta = 0$ で $k_\sigma = \frac{1}{2\pi}(0+\pi) = \frac{1}{2}$、$\vartheta = \pi/2$（直交）で $\frac{1}{2\pi}(1+0) \approx 0.159$、$\vartheta = \pi$ で 0 である。直交する二点でも 0 にならない点が線形カーネル $\boldsymbol{x}^\top\boldsymbol{x}'$ との違いである。

11.1.3　接空間の特徴写像と NTK

ここまでの $k_{\boldsymbol{\theta}}$ は隠れ層の特徴 $\boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x})$ の内積だった。全パラメータを学習するときに現れるのは、これとは別の特徴写像である。$\boldsymbol{\theta}_0$ のまわりで一次 Taylor 展開すると

$$f(\boldsymbol{x};\boldsymbol{\theta}) \approx f(\boldsymbol{x};\boldsymbol{\theta}_0) + \langle \nabla_{\boldsymbol{\theta}} f(\boldsymbol{x};\boldsymbol{\theta}_0), \boldsymbol{\theta}-\boldsymbol{\theta}_0\rangle$$

だから、$\boldsymbol{\theta}$ を動かして得られる関数のクラスは、**パラメータ空間の**特徴写像 $\boldsymbol{\psi}_{\boldsymbol{\theta}_0}(\boldsymbol{x}) \coloneqq \nabla_{\boldsymbol{\theta}} f(\boldsymbol{x};\boldsymbol{\theta}_0)$ をもつ線形モデルである。その内積 $\langle \boldsymbol{\psi}_{\boldsymbol{\theta}_0}(\boldsymbol{x}), \boldsymbol{\psi}_{\boldsymbol{\theta}_0}(\boldsymbol{x}')\rangle$ が **ニューラルタンジェントカーネル**で、以下ではこれが学習の動きを決めることを見る。すなわち「NTK とは、ネットワークを初期値のまわりで線形化したときに現れるカーネル」である。

二乗損失 $L(\boldsymbol{\theta}) = \frac{1}{2}\sum_i (f(\boldsymbol{x}_i;\boldsymbol{\theta}) - y_i)^2$ の勾配流 $\dot{\boldsymbol{\theta}} = -\nabla_{\boldsymbol{\theta}} L$ を考え、予測値ベクトル $\boldsymbol{u}(t)$ とヤコビ行列 $\boldsymbol{J}(\boldsymbol{\theta}) \in \mathbb{R}^{n\times P}$（$J_{i\cdot} = \nabla_{\boldsymbol{\theta}} f(\boldsymbol{x}_i;\boldsymbol{\theta})^\top$）を導入すると、連鎖律から

$$\dot{\boldsymbol{u}} = \boldsymbol{J}\dot{\boldsymbol{\theta}} = -\boldsymbol{J}\boldsymbol{J}^\top(\boldsymbol{u}-\boldsymbol{y}) = -\boldsymbol{\Theta}_m(\boldsymbol{\theta})(\boldsymbol{u}-\boldsymbol{y}), \qquad \boldsymbol{\Theta}_m \coloneqq \boldsymbol{J}\boldsymbol{J}^\top. \tag{11.4}$$

つまり**関数値の動きは $n\times n$ 行列 $\boldsymbol{\Theta}_m$ だけで決まる**。この行列の成分はカーネルの形をしている。

定義 11.2 (ニューラルタンジェントカーネル [44])**.** $\Theta_m(\boldsymbol{x},\boldsymbol{x}';\boldsymbol{\theta}) \coloneqq \langle \nabla_{\boldsymbol{\theta}} f(\boldsymbol{x};\boldsymbol{\theta}), \nabla_{\boldsymbol{\theta}} f(\boldsymbol{x}';\boldsymbol{\theta})\rangle$ を**ニューラルタンジェントカーネル**（neural tangent kernel, NTK）と呼び、$\boldsymbol{\Theta}_m = (\Theta_m(\boldsymbol{x}_i,\boldsymbol{x}_j))_{ij}$ をその Gram 行列とする。

式 (11.1)の勾配 $\partial f/\partial a_r = \sigma(\boldsymbol{w}_r^\top \boldsymbol{x})/\sqrt{m}$、$\partial f/\partial \boldsymbol{w}_r = a_r \sigma'(\boldsymbol{w}_r^\top \boldsymbol{x})\boldsymbol{x}/\sqrt{m}$ から

$$\Theta_m(\boldsymbol{x},\boldsymbol{x}') = \underbrace{\frac{1}{m}\sum_{r} \sigma(\boldsymbol{w}_r^\top \boldsymbol{x})\sigma(\boldsymbol{w}_r^\top \boldsymbol{x}')}_{=k_m(\boldsymbol{x},\boldsymbol{x}')} + (\boldsymbol{x}^\top \boldsymbol{x}') \underbrace{\frac{1}{m}\sum_{r} a_r^2\, \sigma'(\boldsymbol{w}_r^\top \boldsymbol{x})\sigma'(\boldsymbol{w}_r^\top \boldsymbol{x}')}_{\text{隠れ層の寄与}}. \tag{11.5}$$

ReLU では $\sigma'(t) = \mathbf{1}\{t>0\}$、$\mathbb{E}[a^2]=1$ だから第二項の極限は $(\boldsymbol{x}^\top\boldsymbol{x}')\mathbb{P}(\boldsymbol{w}^\top\boldsymbol{x}>0, \boldsymbol{w}^\top\boldsymbol{x}'>0) = (\boldsymbol{x}^\top\boldsymbol{x}')(\pi-\vartheta)/(2\pi)$ であり、

$$\Theta(\boldsymbol{x},\boldsymbol{x}') = \frac{\|\boldsymbol{x}\|\|\boldsymbol{x}'\|}{2\pi}\big(\sin\vartheta + (\pi-\vartheta)\cos\vartheta\big) + (\boldsymbol{x}^\top\boldsymbol{x}')\frac{\pi-\vartheta}{2\pi} \tag{11.6}$$

を得る。これが 2 層 ReLU 網の NTK である。$\boldsymbol{x}=\boldsymbol{x}'$ とすると $\Theta(\boldsymbol{x},\boldsymbol{x}) = \|\boldsymbol{x}\|^2/2 + \|\boldsymbol{x}\|^2/2 = \|\boldsymbol{x}\|^2$ と対角が揃う。$d=3$、$m=2\times10^5$ で 式 (11.5)を実測すると式 (11.6)との最大差は 9×10^{-3} で、$O(1/\sqrt{m})$ のオーダーに合う（リスト 11.1）。

11.1.4　なぜ無限幅ではカーネル法に戻るのか

無限幅極限では二つのことが同時に起こる。第一に、初期 NTK $\boldsymbol{\Theta}_m(\boldsymbol{\theta}(0))$ は 式 (11.5)の平均が大数の法則で期待値に収束することにより、m に依存しない決定論的なカーネル $\boldsymbol{\Theta}$（ReLU なら式 (11.6)）に収束する。第二に、学習中の変化も消える（理由は後述）。すなわち

$$\boldsymbol{\Theta}_m(\boldsymbol{\theta}(t)) \;\approx\; \boldsymbol{\Theta}_m(\boldsymbol{\theta}(0)) \;\xrightarrow[m\to\infty]{}\; \boldsymbol{\Theta}$$

である。これを認めると式 (11.4)は $\dot{\boldsymbol{u}} = -\boldsymbol{\Theta}(\boldsymbol{u}-\boldsymbol{y})$ という定数係数の線形常微分方程式になり、$\boldsymbol{u}(t)-\boldsymbol{y} = e^{-t\boldsymbol{\Theta}}(\boldsymbol{u}(0)-\boldsymbol{y})$ と解ける。$\boldsymbol{\Theta}\succ 0$ なら $t\to\infty$ で必ず補間解に達し、収束速度は $\lambda_{\min}(\boldsymbol{\Theta})$ で決まる。訓練点以外での予測も同様に解け、極限は

$$f_\infty(\boldsymbol{x}) = f_0(\boldsymbol{x}) + \Theta(\boldsymbol{x},\boldsymbol{X})\,\boldsymbol{\Theta}^{-1}\big(\boldsymbol{y}-\boldsymbol{u}(0)\big), \qquad \Theta(\boldsymbol{x},\boldsymbol{X}) = \big(\Theta(\boldsymbol{x},\boldsymbol{x}_1),\dots,\Theta(\boldsymbol{x},\boldsymbol{x}_n)\big) \tag{11.7}$$

となる。初期関数からの残差に対する、カーネル Θ の**カーネル回帰**（第8章の表現定理そのもの）である。

カーネルが動かないことは**仮定ではなく、式 (11.1)の $1/\sqrt{m}$ 規格化のもとで導かれる**。個々の素子についての勾配は $\partial f/\partial a_r = \sigma(\boldsymbol{w}_r^\top\boldsymbol{x})/\sqrt{m}$、$\partial f/\partial \boldsymbol{w}_r = a_r\sigma'(\boldsymbol{w}_r^\top\boldsymbol{x})\boldsymbol{x}/\sqrt{m}$ でいずれも $O(m^{-1/2})$ だから、有限時間の勾配流では各パラメータは $O(m^{-1/2})$ しか動かない（$\|\boldsymbol{\theta}(t)-\boldsymbol{\theta}(0)\|$ 全体は $O(1)$ だが、$O(m)$ 個の成分に薄く分散している）。一方 $\boldsymbol{\Theta}_m$ は m 個の素子の寄与の平均 $\Theta_m(\boldsymbol{x},\boldsymbol{x}') = \frac{1}{m}\sum_r$(第 r 素子の寄与) なので、各素子の寄与の変化も $O(m^{-1/2})$ であり、適切な正則性と初期 NTK の正定値性のもとで

$$\sup_{t}\|\boldsymbol{\Theta}_m(\boldsymbol{\theta}(t)) - \boldsymbol{\Theta}_m(\boldsymbol{\theta}(0))\|_{\mathrm{op}} \to 0 \qquad (m\to\infty)$$

が示される [44, 22]。パラメータの**相対的な**変化が小さいだけではこの結論は出ず、素子ごとの寄与の勾配が $O(m^{-1/2})$ であることが本質である。前節の一次 Taylor 展開の言葉で言えば、特徴写像 $\boldsymbol{\psi}_{\boldsymbol{\theta}_0}(\boldsymbol{x}) = \nabla_{\boldsymbol{\theta}} f(\boldsymbol{x};\boldsymbol{\theta}_0)$ が初期値のまま動かず、二次以上の項が $m\to\infty$ で消える、ということである。学習されるはずの特徴が学習されないので、**この極限では固定カーネルによる回帰に戻る**。厳密な定理にするには (i) $\lambda_{\min}(\boldsymbol{\Theta})>0$、(ii) 収束の一様性、(iii) ReLU の非可微分点の扱いを詰める必要がある。本質的な困難はないが記述量が多いので [44, 22] に譲る。

強調しておくと、凍結するのは**無限幅だから**ではない。式 (11.1)の規格化（NTK パラメータ化）と、それに合う初期化・学習率のもとでの極限だから凍結するのであって、規格化を変えれば無限幅でも特徴 $\boldsymbol{h}_{\boldsymbol{\theta}}(\boldsymbol{x})$ 自体が $O(1)$ 動き、カーネルが学習中に変化する**平均場（mean-field）**の極限が得られる。NTK が記述しているのは「幅の広いネットワークの学習一般」ではなく、**パラメータが初期値の近くに留まる lazy training の極限**である。

リスト 11.1　2 層 ReLU 網の NTK：解析形（式 (11.6)）と、有限幅網の勾配の内積として直接計算した経験 NTK の一致（$d=3$、$m=2\times10^5$ で最大差 9.0×10^{-3}）。

```python
import numpy as np

def ntk_relu(X, Xp):                          # 解析形 (11.6)。X は d×n（列がサンプル）
    nx, ny = np.linalg.norm(X, axis=0)[:, None], np.linalg.norm(Xp, axis=0)[None, :]
    th = np.arccos(np.clip(X.T @ Xp / (nx * ny), -1.0, 1.0))
    k0 = nx * ny * (np.sin(th) + (np.pi - th) * np.cos(th)) / (2*np.pi)
    return k0 + (X.T @ Xp) * (np.pi - th) / (2*np.pi)

def ntk_empirical(X, W, a):                   # 勾配の内積 (11.5) を直接計算
    m = W.shape[0]                            # W は m×d（第 r 行が w_r）：変更なし
    S = np.maximum(W @ X, 0.0) / np.sqrt(m)           # m×n : da 方向の勾配
```

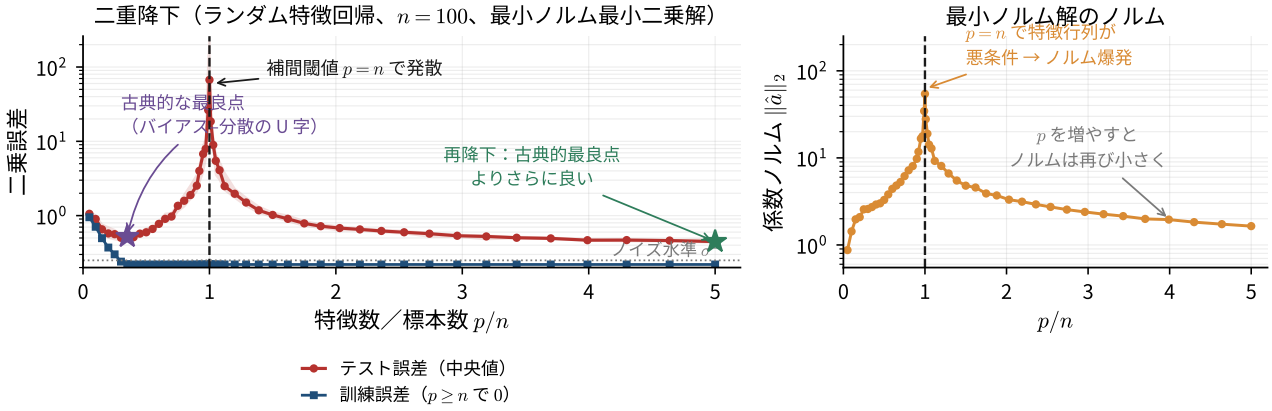


図11.1　二重降下。テスト誤差は古典的な U 字を描いたあと補間閾値 $p/n=1$ で発散し、その先で再び下降する。ランダム特徴回帰の実測で、右端は古典領域の最良値より小さい。

```
    D = (W @ X > 0) * a[:, None] / np.sqrt(m)          # m×n : dW 方向の係数
    return S.T @ S + (D.T @ D) * (X.T @ X)             # いずれも  n×n

rng, m = np.random.default_rng(0), 200000
X = rng.normal(size=(4, 3)).T                  # d×n = 3×4
W, a = rng.normal(size=(m, 3)), rng.normal(size=m)
print(np.abs(ntk_relu(X, X) - ntk_empirical(X, W, a)).max())      # 9.0e-03
```

注意 11.3 (NTK は深層学習の説明になっているか)**.** NTK が教えるのは「無限幅・小さい学習率・特定の規格化」のもとで勾配降下による学習が **固定されたカーネルによる回帰**と一致する、という事実である。そこでは特徴写像 $\psi(\boldsymbol{x})=\nabla_{\boldsymbol{\theta}} f(\boldsymbol{x};\boldsymbol{\theta}_0)$ が初期値だけで決まりデータを見ても変わらない（**lazy training** [22]）。しかし第10章で述べたとおり深層学習の実際の強みは**データに応じて特徴が学習される**ことにあると考えられており、実験的にも有限幅の網は対応する NTK 回帰を上回ることが多い。NTK は「深層学習の一部はカーネル法として厳密に解析できる」ことを示す足場だが、成功の説明としては不十分である。

11.2　過剰パラメータ化と二重降下

11.2.1　U 字曲線とその先

教科書の説明を、まず式で確かめておく。真の関係を $y=f_0(\boldsymbol{x})+\varepsilon$（$\mathbb{E}[\varepsilon]=0$、$\mathrm{Var}(\varepsilon)=\sigma^2$）とし、訓練データ D から得られる予測関数を $\hat{f}_D$ と書く。D を取り直したときのばらつきを考え、固定した $\boldsymbol{x}$ で

$$\mathrm{Bias}(\boldsymbol{x}) \coloneqq \mathbb{E}_D[\hat{f}_D(\boldsymbol{x})]-f_0(\boldsymbol{x}), \qquad \mathrm{Var}(\boldsymbol{x}) \coloneqq \mathbb{E}_D\Big[\big(\hat{f}_D(\boldsymbol{x})-\mathbb{E}_D[\hat{f}_D(\boldsymbol{x})]\big)^2\Big]$$

と定める。バイアスは**学習を何度繰り返して平均しても残る系統的なずれ**（真の関数が曲線なのに直線しか使わなければ、どれだけデータを取り直しても曲線は表せない）、バリアンスは **訓練データを少し変えたときの予測の揺れ**（ノイズまで追いかける複雑なモデルで大きい）である。$\hat{f}_D(\boldsymbol{x})-f_0(\boldsymbol{x})$ を「ばらつき」と「バイアス」の和に分けて二乗し期待値を取ると交差項が消え、さらに独立なテスト観測 $Y=f_0(\boldsymbol{x})+\varepsilon$ に対する二乗誤差では ε の分だけ項が増えて

$$\mathbb{E}_D\big[(\hat{f}_D(\boldsymbol{x})-f_0(\boldsymbol{x}))^2\big]=\mathrm{Bias}(\boldsymbol{x})^2+\mathrm{Var}(\boldsymbol{x}), \qquad \mathbb{E}\big[(\hat{f}_D(\boldsymbol{x})-Y)^2\big]=\mathrm{Bias}(\boldsymbol{x})^2+\mathrm{Var}(\boldsymbol{x})+\sigma^2$$

となる。最後の σ^2 はどんなモデルでも消せない**既約ノイズ**である（図 11.1の「ノイズ水準 σ^2」がこれにあたる）。古典的には、モデルの複雑さ p を上げるとバイアスは減りバリアンスは増えるので、その和であるテスト誤差は U 字を描く――これが教科書の説明である。ところが第10章で触れたように、パラメータ数が標本数を大きく超えるモデルは訓練誤差ゼロ（補間）でありながらよく汎化する。Belkin ら [14] は、複雑さを $p/n>1$ まで延ばすとテスト誤差が $p/n=1$（**補間閾値**, interpolation threshold）で一度発散したのち**再び下降する**ことを多くのモデルで観察した。これが**二重降下**（double descent）である（図 11.1）。

11.2.2　最小ノルム補間解が鍵である

計画行列を $\boldsymbol{X}\in\mathbb{R}^{p\times n}$（第 i 列が $\boldsymbol{x}_i$）と取ると、線形予測は $\hat{\boldsymbol{y}}=\boldsymbol{X}^\top\boldsymbol{w}$ である。$p>n$ のとき $\boldsymbol{X}^\top\boldsymbol{w}=\boldsymbol{y}$ の解は無数にある。勾配降下を $\boldsymbol{w}=\boldsymbol{0}$ から走らせると、第2章で示したとおりその中で ***ノルム最小の解***

$$\hat{\boldsymbol{w}}=\arg\min\{\|\boldsymbol{w}\| : \boldsymbol{X}^\top\boldsymbol{w}=\boldsymbol{y}\}=(\boldsymbol{X}^\top)^{+}\boldsymbol{y}=\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{y} \tag{11.8}$$

に収束する。理由は二行で済む。$\mathcal{L}(\boldsymbol{w}) = \|\boldsymbol{X}^\top \boldsymbol{w} - \boldsymbol{y}\|^2$ の勾配は $\nabla\mathcal{L}(\boldsymbol{w}) = 2\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{w} - \boldsymbol{y}) \in \mathrm{Im}(\boldsymbol{X})$ だから、$\boldsymbol{w}_0 = \boldsymbol{0}$ から始めればすべての反復が $\boldsymbol{w}_k \in \mathrm{Im}(\boldsymbol{X})$ に留まる。一方定理 2.32より最小二乗解の全体は $(\boldsymbol{X}^\top)^+\boldsymbol{y} + \mathrm{Ker}(\boldsymbol{X}^\top)$ であり、$\mathrm{Im}(\boldsymbol{X}) = \mathrm{Ker}(\boldsymbol{X}^\top)^\perp$ だから、このうち $\mathrm{Im}(\boldsymbol{X})$ に属するのは $(\boldsymbol{X}^\top)^+\boldsymbol{y}$ だけである。すなわち **$\boldsymbol{0}$ から始めた勾配降下は $\mathrm{Ker}(\boldsymbol{X}^\top)$ 方向の成分を一度も作らないので、最小ノルム解を選ぶ。**

収束そのものも簡約 SVD $\boldsymbol{X} = \boldsymbol{U}_r\boldsymbol{\Sigma}_r\boldsymbol{V}_r^\top$ で確かめられる。$\boldsymbol{w}_k = \boldsymbol{U}_r\boldsymbol{c}_k$ と書くと、学習率 η の勾配降下 $\boldsymbol{w}_{k+1} = \boldsymbol{w}_k - 2\eta\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{w}_k - \boldsymbol{y})$ は

$$\boldsymbol{c}_{k+1} = (\boldsymbol{I} - 2\eta\boldsymbol{\Sigma}_r^2)\boldsymbol{c}_k + 2\eta\boldsymbol{\Sigma}_r\boldsymbol{V}_r^\top\boldsymbol{y}$$

となり、$0 < \eta < 1/\sigma_1^2$ なら各成分で $|1 - 2\eta\sigma_i^2| < 1$ だから $\boldsymbol{c}_k \to \boldsymbol{\Sigma}_r^{-1}\boldsymbol{V}_r^\top\boldsymbol{y}$、すなわち $\boldsymbol{w}_k \to \boldsymbol{U}_r\boldsymbol{\Sigma}_r^{-1}\boldsymbol{V}_r^\top\boldsymbol{y} = (\boldsymbol{X}^\top)^+\boldsymbol{y}$ である（η がこの範囲を外れると σ_1 の成分が発散する）。「どの補間解を選ぶか」が明示的な正則化項なしにアルゴリズムによって決まる。これを**暗黙の正則化**（implicit regularization）と呼ぶ。このノルムがパラメータ数とともにどう動くかを、第5章の道具で計算できる。

定理 11.4 (最小ノルム補間解のリスク)**.** $\boldsymbol{X} \in \mathbb{R}^{p\times n}$ の成分を独立に $\mathcal{N}(0,1)$ とし、真の信号がなく $\boldsymbol{y} = \boldsymbol{\varepsilon} \sim \mathcal{N}(\boldsymbol{0}, \sigma^2\boldsymbol{I}_n)$ とする。テスト点 $\boldsymbol{x} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}_p)$ に対するリスクを $R(\hat{\boldsymbol{w}}) = \mathbb{E}_{\boldsymbol{x}}[(\boldsymbol{x}^\top\hat{\boldsymbol{w}})^2] = \|\hat{\boldsymbol{w}}\|^2$ とすると

$$\mathbb{E}\big[R(\hat{\boldsymbol{w}})\big] = \begin{cases} \sigma^2 p/(n-p-1), & p < n-1 \quad \text{(最小二乗解)},\\ \sigma^2 n/(p-n-1), & p > n+1 \quad \text{(最小ノルム補間解)}. \end{cases} \tag{11.9}$$

証明. $p < n$ では正規方程式（第2章）より $\hat{\boldsymbol{w}} = (\boldsymbol{X}\boldsymbol{X}^\top)^{-1}\boldsymbol{X}\boldsymbol{\varepsilon}$（$\boldsymbol{X}\boldsymbol{X}^\top$ は $p\times p$ で正則）だから $\boldsymbol{X}$ で条件付けて $\mathbb{E}[\|\hat{\boldsymbol{w}}\|^2 \mid \boldsymbol{X}] = \sigma^2\,\mathrm{tr}((\boldsymbol{X}\boldsymbol{X}^\top)^{-1})$、$p > n$ では式 (11.8) より $\|\hat{\boldsymbol{w}}\|^2 = \boldsymbol{\varepsilon}^\top(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{\varepsilon}$（$\boldsymbol{X}^\top\boldsymbol{X}$ は $n\times n$）で $\mathbb{E}[\|\hat{\boldsymbol{w}}\|^2 \mid \boldsymbol{X}] = \sigma^2\,\mathrm{tr}((\boldsymbol{X}^\top\boldsymbol{X})^{-1})$。いずれも $\mathrm{tr}(\boldsymbol{W}^{-1})$（$\boldsymbol{W}$ はサイズ $q = \min(n,p)$、自由度 $N = \max(n,p)$ の Wishart 行列）の期待値であり、逆 Wishart 分布の平均が $\boldsymbol{I}_q/(N-q-1)$ であることから $\mathbb{E}[\mathrm{tr}(\boldsymbol{W}^{-1})] = q/(N-q-1)$。$q, N$ を代入して式 (11.9) を得る。 ■

注意 11.5 (Marchenko–Pastur による読み替え)**.** 式 (11.9) は第5章の Marchenko–Pastur（MP）則から漸近的に導ける。$\gamma = p/n < 1$ とすると $\widehat{\boldsymbol{\Sigma}} = \boldsymbol{X}\boldsymbol{X}^\top/n$（$p\times p$）の固有値分布は台 $[(1-\sqrt{\gamma})^2, (1+\sqrt{\gamma})^2]$ の MP_γ に収束し、積分公式

$$\int x^{-1}\,\mathrm{dMP}_\gamma(x) = \frac{1}{1-\gamma} \qquad (\gamma < 1) \tag{11.10}$$

より $\mathrm{tr}((\boldsymbol{X}\boldsymbol{X}^\top)^{-1}) = \frac{1}{n}\,\mathrm{tr}(\widehat{\boldsymbol{\Sigma}}^{-1}) \approx \gamma/(1-\gamma)$ となって式 (11.9) の $p/(n-p-1)$ と一致する（$n = 4000$、$p = 2000$ の実測で $\frac{1}{p}\,\mathrm{tr}(\widehat{\boldsymbol{\Sigma}}^{-1}) = 2.0043$、理論値 2）。**発散の正体**もこの式に現れている：$\gamma \to 1$ で台の左端 $(1-\sqrt{\gamma})^2$ が 0 に落ちるため $1/x$ の積分が発散する。補間閾値でテスト誤差が爆発するのは、標本共分散行列の最小固有値が 0 に潰れて $\widehat{\boldsymbol{\Sigma}}^{-1}$ が制御を失うからだ、と言い切れる。

式 (11.9) の後半は、p が増えるとリスクが $\sigma^2 n/p$ のように減ることを示す。補間の「負担」を多くの座標に分散できるため $\|\hat{\boldsymbol{w}}\|$ が小さくなる、つまり最小ノルムという暗黙の正則化がパラメータの増加とともに**強くなる**。これが第二の下降の仕組みである。11.1節のランダム特徴モデルはこの現象の実験場で、特徴数 m を動かすと $m = n$ で切り替わりが起こる。Mei–Montanari [52] は $n, d, m \to \infty$（比を固定）の極限でテストリスクの厳密な漸近式を導き、$m/n = 1$ での発散とその先での下降を証明した。

「大きいほど良い」ではない

Hastie ら [39] が示したように、リッジ回帰の λ を各 p で最適に選べばそのリスク曲線は二重降下曲線を**全域で下から押さえる**。明示的な正則化を正しく行えば補間閾値の発散も第二の下降も現れない。二重降下は「正則化をアルゴリズム任せにしたときに何が起こるか」を描いた曲線であって、過剰パラメータ化それ自体の利益を示すものではない。

11.3　多様体学習

11.3.1　多様体仮説

28×28 画素の手書き数字は $\mathbb{R}^{784}$ の点だが、「意味のある画像」は筆の太さ・傾き・位置といった少数のパラメータで生成される低次元の集合の近傍にあるだろう。これが**多様体仮説**（manifold hypothesis）である。形式的には、データ分布の台が $\mathbb{R}^d$ 内の k 次元部分多様体 $\mathcal{M}$（$k \ll d$）の近傍に集中していると仮定する。PCA は $\mathcal{M}$ が線形部分空間のときの正解を与えるが、$\mathcal{M}$ が曲がっていると多様体を「まっすぐに引き伸ばす」ことができない。そこで**局所的にはユークリッド的である**という性質を使い、局所情報だけから大域的な座標を組み立てる戦略が生まれる（図 11.2）。

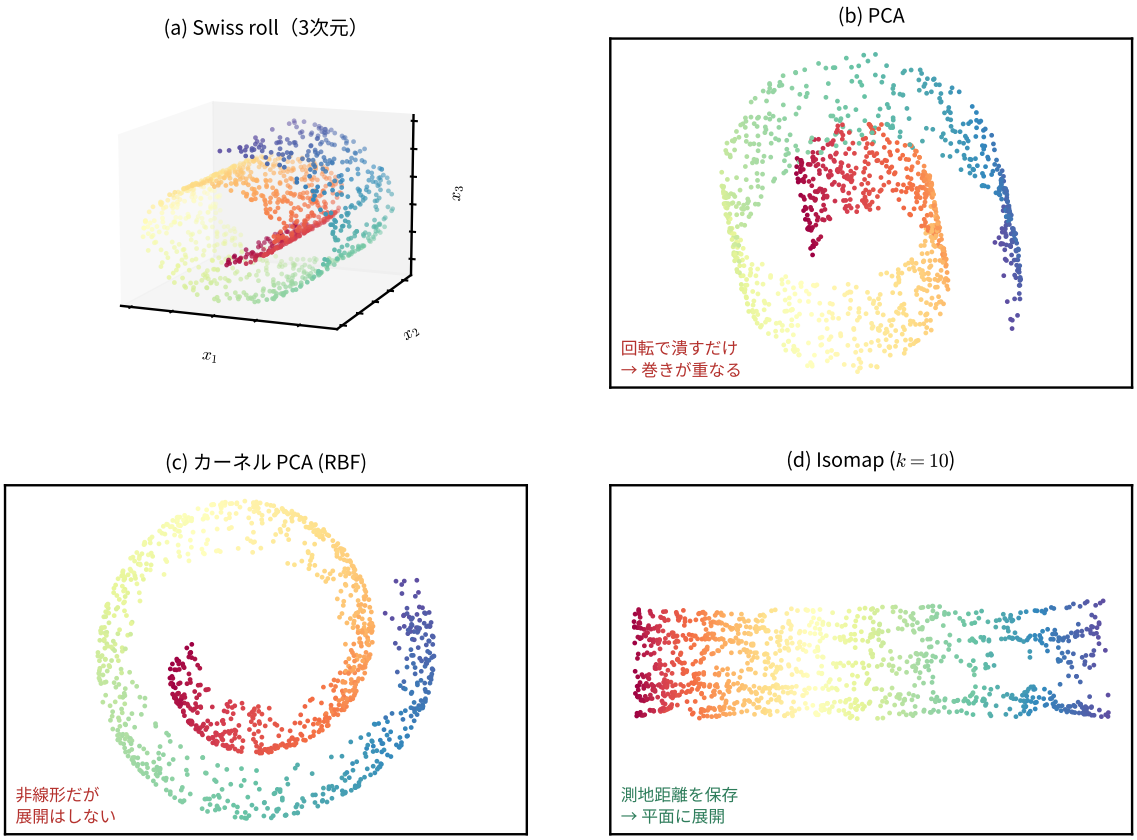


図11.2　Swiss roll に対する各手法の埋め込み。線形 PCA は巻きを潰すが、近傍グラフの情報を使う手法は巻きを展開して二次元の帯を復元する。曲がった多様体で PCA が失敗する典型例である。

11.3.2　四つの方法：何を最小化しているか

k 近傍グラフの重みを $w_{ij} \geq 0$（例えば $\exp(-\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2/(2\sigma^2))$、非近傍は 0）とし、$\boldsymbol{W} = (w_{ij})$、$\boldsymbol{D} = \mathrm{diag}(\boldsymbol{W}\mathbf{1})$、グラフラプラシアン $\boldsymbol{L} = \boldsymbol{D} - \boldsymbol{W}$ とする（いずれも $n \times n$ で、この節を通じて変更はない）。埋め込みは $\boldsymbol{Y} \in \mathbb{R}^{k \times n}$（**第 i 列**が点 i の座標 $\boldsymbol{y}_i \in \mathbb{R}^k$）と書く。

Isomap [75] は近傍グラフ上の最短経路長 $d_G(i,j)$ で測地距離を近似し、$\boldsymbol{B} = -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}_G^{(2)}\boldsymbol{H}$（$\boldsymbol{D}_G^{(2)} = (d_G(i,j)^2)$、$\boldsymbol{H}$ は中心化行列）に対して $\boldsymbol{Y} = \arg\min_{\boldsymbol{Y}} \|\boldsymbol{B} - \boldsymbol{Y}^\top \boldsymbol{Y}\|_{\mathrm{F}}^2$ を解く。制約は $\boldsymbol{Y}^\top\boldsymbol{Y} \succeq 0$（$\boldsymbol{Y} \in \mathbb{R}^{k\times n}$ なので階数も k 以下）なので、これは単なる階数 k の Eckart–Young ではなく**半正定値制約つき**の最良近似である。解は $\boldsymbol{B}$ の**正の**固有値のうち上位 k 個とその固有ベクトルで与えられ（命題 6.25）、$\boldsymbol{Y}$ の各**行**が固有ベクトルを $\sqrt{\lambda_j}$ 倍したものである。負の固有値は捨てる。$\boldsymbol{B}$ の作り方は第6章の古典的 MDS と同一である。実際 $\boldsymbol{B} = -\frac{1}{2}\boldsymbol{H}\boldsymbol{D}^{(2)}\boldsymbol{H}$ は距離行列の二重中心化で、$\boldsymbol{D}$ が Euclid 距離なら $\boldsymbol{B} = \widetilde{\boldsymbol{X}}^\top\widetilde{\boldsymbol{X}}$ となって主成分分析に一致した（定理 6.20）。Isomap はこの $\boldsymbol{D}$ を**測地距離の近似に取り替えた古典的 MDS** にほかならない。非線形性はアルゴリズムではなく**距離の定義**に入っている。

多様体上の距離を測るので、Swiss roll のように「近くに見えて遠い」点対を正しく引き離せる。

グラフ最短経路から作った B は半正定値でない

古典的 MDS では $\boldsymbol{B} = \widetilde{\boldsymbol{X}}^\top\widetilde{\boldsymbol{X}} \succeq 0$ が保証されるが（定理 6.20）、d_G が Euclid 距離でない場合その保証は失われる。$\boldsymbol{B} \succeq 0$ は距離行列が Euclid 埋め込み可能であることと同値で、測地距離の近似はそうならないのが普通である。実測しよう。`sklearn` の `make_swiss_roll`（`noise=0`、`random_state=0`）から n 点を取り、8 近傍グラフの最短経路長で $\boldsymbol{B}$ を作る。

n	負の個数	$[\lambda_{\min}, \lambda_{\max}]$	$\sum\lvert\lambda_-\rvert / \sum\lambda_+$	$\lvert\lambda_{\min}\rvert/\lambda_1$
400	200	$[-1.50\times10^{4},\ 7.11\times10^{4}]$	32.97 %	21.09 %
800	422	$[-5.18\times10^{3},\ 6.19\times10^{5}]$	4.69 %	0.84 %
1600	843	$[-8.73\times10^{3},\ 1.25\times10^{6}]$	4.43 %	0.70 %

どの n でも約半数の固有値が負である。重要なのは個数ではなく**大きさ**で、$n=800$ 以上では負の寄与は正の 5 % 未満に収まり、最大の負固有値は λ_1 の 1 % に満たない。この「負の固有値が小さい」ことが Isomap が実用になる理由である。一方 $n=400$ では負の寄与が 33 % に達する。点が疎だと 8 近傍が多様体上で遠くまで届いてしまい、最短経路長が測地距離をよく近似しないからである。つまり負の固有値の大きさは**近傍グラフが測地距離をどれだけよく近似しているかの指標**であり、これが大きいときは k や ε、あるいは標本数を見直す合図になる。なお同じ点集合を Euclid 距離で扱えば、どの n でも最小固有値は -10^{-11} 程度、すなわち丸め誤差の範囲で $\boldsymbol{B}\succeq 0$ となり、階数は 3 である。

局所線形埋め込み（LLE） [66] は、各点を近傍の線形結合で再構成する重み $\boldsymbol{W}^\star=\arg\min_{\boldsymbol{W}}\sum_i\|\boldsymbol{x}_i-\sum_{j\in N(i)}W_{ij}\boldsymbol{x}_j\|^2$（制約 $\sum_j W_{ij}=1$、$W_{ij}=0$ $(j\notin N(i))$）をまず求める。和が 1 という制約により $\boldsymbol{W}^\star$ は平行移動・回転・スケールに不変な**局所的な形**の記述になる。次にこの形を保つ低次元座標を $\boldsymbol{Y}\boldsymbol{Y}^\top=\boldsymbol{I}_k$、$\boldsymbol{Y}\boldsymbol{1}=\boldsymbol{0}$ のもとで

$$\boldsymbol{Y}^\star=\arg\min_{\boldsymbol{Y}}\ \sum_i\Bigl\|\boldsymbol{y}_i-\sum_j W^\star_{ij}\boldsymbol{y}_j\Bigr\|^2=\arg\min_{\boldsymbol{Y}}\ \operatorname{tr}(\boldsymbol{Y}\boldsymbol{M}\boldsymbol{Y}^\top),\qquad \boldsymbol{M}=(\boldsymbol{I}-\boldsymbol{W}^\star)^\top(\boldsymbol{I}-\boldsymbol{W}^\star) \tag{11.11}$$

として求める（$\boldsymbol{M}$ は $n\times n$ で不変、$(k\times n)(n\times n)(n\times k)=(k\times k)$）。$\boldsymbol{M}\succeq 0$、$\boldsymbol{M}\boldsymbol{1}=\boldsymbol{0}$ だから解は $\boldsymbol{M}$ の**下位**固有ベクトル（自明な $\boldsymbol{1}$ を除く第 $2\sim k+1$ 番目）を $\boldsymbol{Y}$ の行に並べたものである。

ラプラシアン固有写像 [13] は、「近い点を近くに写す」という要請をそのまま書き下す：

$$\min_{\boldsymbol{Y}}\ \tfrac{1}{2}\sum_{i,j}w_{ij}\|\boldsymbol{y}_i-\boldsymbol{y}_j\|^2=\operatorname{tr}(\boldsymbol{Y}\boldsymbol{L}\boldsymbol{Y}^\top)\qquad\text{s.t.}\quad \boldsymbol{Y}\boldsymbol{D}\boldsymbol{Y}^\top=\boldsymbol{I}_k,\ \boldsymbol{Y}\boldsymbol{D}\boldsymbol{1}=\boldsymbol{0}. \tag{11.12}$$

制約は自明解と定数解を排除するためのものである。これは第6章の **一般化固有値問題** $\boldsymbol{L}\boldsymbol{v}=\lambda\boldsymbol{D}\boldsymbol{v}$ にほかならず、Rayleigh 商 $\boldsymbol{v}^\top\boldsymbol{L}\boldsymbol{v}/\boldsymbol{v}^\top\boldsymbol{D}\boldsymbol{v}$ の最小化を自明解 $\boldsymbol{v}=\boldsymbol{1}$ に直交する範囲で行っている（第1章の枠組み (2) がそのまま現れている）。

例 11.6 (パスグラフ)**.** n 点が一直線に並び隣どうしだけ重み 1 で結ばれたグラフで、簡単のため $\boldsymbol{D}=\boldsymbol{I}$ とすると $\lambda_k=4\sin^2(\pi k/(2n))$、$v_k(i)=\cos(\pi k(i+\tfrac12)/n)$ $(k=0,\dots,n-1)$ と閉形式で書ける。$n=5$ では $\lambda=0,\,0.382,\,1.382,\,2.618,\,3.618$ で、λ_1 の固有ベクトルは $\boldsymbol{v}_1\propto(1,\,0.618,\,0,\,-0.618,\,-1)^\top$、つまり **点を左から右へ順序づける一次元座標**である。「近傍関係だけから並び順を復元する」働きが、この最小例でそのまま見える。

拡散写像 [24] は、$\boldsymbol{P}=\boldsymbol{D}^{-1}\boldsymbol{W}$ をランダムウォークの遷移行列とし、その固有値 $1=\mu_0>\mu_1\ge\cdots$ と右固有ベクトル $\boldsymbol{\psi}_j$ から $\Psi_t(\boldsymbol{x}_i)=(\mu_1^t\psi_1(i),\dots,\mu_k^t\psi_k(i))^\top$ と定める。座標のユークリッド距離は t ステップ後の遷移確率分布どうしの重みつき L^2 距離（**拡散距離**）に一致する。

$\boldsymbol{P}$ は対称ではないが、対称行列と相似である。ここは間違えやすいので命題として書き下す。

命題 11.7 (遷移行列・対称正規化・正規化ラプラシアン)**.** $\boldsymbol{D}\succ 0$（すべての次数が正）とし

$$\boldsymbol{S}\coloneqq\boldsymbol{D}^{-1/2}\boldsymbol{W}\boldsymbol{D}^{-1/2},\qquad \boldsymbol{L}_{\mathrm{sym}}\coloneqq\boldsymbol{D}^{-1/2}\boldsymbol{L}\boldsymbol{D}^{-1/2}$$

とおく。このとき次が成り立つ。

1. $\boldsymbol{S}$ は対称で、$\boldsymbol{S}=\boldsymbol{D}^{1/2}\boldsymbol{P}\boldsymbol{D}^{-1/2}$、すなわち $\boldsymbol{P}\sim\boldsymbol{S}$（相似）。特に $\boldsymbol{P}$ の固有値はすべて実である。
2. $\boldsymbol{L}_{\mathrm{sym}}=\boldsymbol{I}-\boldsymbol{S}$。したがって固有値は
$$\mu_j(\boldsymbol{P})=1-\lambda_j(\boldsymbol{L}_{\mathrm{sym}}) \tag{11.13}$$
で対応し、$\boldsymbol{P}$ の**大きい**固有値が $\boldsymbol{L}_{\mathrm{sym}}$ の**小さい**固有値に当たる。
3. $\boldsymbol{S}\boldsymbol{u}_j=\mu_j\boldsymbol{u}_j$（$\boldsymbol{u}_j$ は正規直交）とすると $\boldsymbol{\psi}_j\coloneqq\boldsymbol{D}^{-1/2}\boldsymbol{u}_j$ が $\boldsymbol{P}$ の右固有ベクトルで $\boldsymbol{P}\boldsymbol{\psi}_j=\mu_j\boldsymbol{\psi}_j$、かつ $\boldsymbol{\psi}_j^\top\boldsymbol{D}\boldsymbol{\psi}_l=\delta_{jl}$。

証明. (1) $\boldsymbol{W}$ が対称なら $\boldsymbol{S}^\top=\boldsymbol{D}^{-1/2}\boldsymbol{W}^\top\boldsymbol{D}^{-1/2}=\boldsymbol{S}$。また $\boldsymbol{D}^{1/2}\boldsymbol{P}\boldsymbol{D}^{-1/2}=\boldsymbol{D}^{1/2}\boldsymbol{D}^{-1}\boldsymbol{W}\boldsymbol{D}^{-1/2}=\boldsymbol{D}^{-1/2}\boldsymbol{W}\boldsymbol{D}^{-1/2}=\boldsymbol{S}$ で、$\boldsymbol{D}^{1/2}$ が正則だから相似。相似な行列は固有値を共有し、対称行列の固有値は実である。(2) $\boldsymbol{L}=\boldsymbol{D}-\boldsymbol{W}$ を代入して $\boldsymbol{D}^{-1/2}(\boldsymbol{D}-\boldsymbol{W})\boldsymbol{D}^{-1/2}=\boldsymbol{I}-\boldsymbol{S}$。よって $\boldsymbol{S}$ の固有値 μ と $\boldsymbol{L}_{\mathrm{sym}}$ の固有値 $1-\mu$ が同じ固有ベクトルで対応し、(1) と併せて 式 (11.13)を得る。(3) $\boldsymbol{S}\boldsymbol{u}_j=\mu_j\boldsymbol{u}_j$ に左から $\boldsymbol{D}^{-1/2}$ を掛けると $\boldsymbol{D}^{-1/2}\boldsymbol{S}\boldsymbol{D}^{1/2}(\boldsymbol{D}^{-1/2}\boldsymbol{u}_j)=\mu_j\boldsymbol{D}^{-1/2}\boldsymbol{u}_j$ で、$\boldsymbol{D}^{-1/2}\boldsymbol{S}\boldsymbol{D}^{1/2}=\boldsymbol{D}^{-1}\boldsymbol{W}=\boldsymbol{P}$ だから $\boldsymbol{P}\boldsymbol{\psi}_j=\mu_j\boldsymbol{\psi}_j$。また $\boldsymbol{\psi}_j^\top\boldsymbol{D}\boldsymbol{\psi}_l=\boldsymbol{u}_j^\top\boldsymbol{D}^{-1/2}\boldsymbol{D}\boldsymbol{D}^{-1/2}\boldsymbol{u}_l=\boldsymbol{u}_j^\top\boldsymbol{u}_l=\delta_{jl}$。 ■

P が相似なのは S であって L_{sym} ではない

$P = D^{-1}W$ と相似なのは $S = D^{-1/2}WD^{-1/2}$ であり、$L_{\mathrm{sym}} = D^{-1/2}LD^{-1/2} = I - S$ とは**相似ではない**。両者の固有値は式 (11.13)のように $\mu \mapsto 1-\mu$ で**反転**して対応するので、大小の順序も逆になる。$n = 8$ のガウス重みグラフで実測すると、P と S の固有値は昇順に並べて最大差 1.3×10^{-15}（一致）、$\mu_j(P)$ と $1-\lambda_j(L_{\mathrm{sym}})$ の最大差も 1.2×10^{-15} であるのに対し、$\mu_j(P)$ を $\lambda_j(L_{\mathrm{sym}})$ と**同じ向きに**並べて比べると最大差は 1.30 に達する。固有ベクトルも $P\psi_j - \mu_j\psi_j$ の最大成分が 3.3×10^{-16}、$\psi_j^{\top} D \psi_l = \delta_{jl}$ の誤差が 4.4×10^{-16} で 命題 11.7(3) が確認できる。

命題 11.7により、拡散写像はラプラシアン固有写像と**同じ固有ベクトル**（L_{sym} の固有ベクトルを $D^{-1/2}$ で変換したもの、すなわち一般化固有値問題 $Lv = \lambda Dv$ の解）を使い、第 j 座標に重み $\mu_j^t = (1-\lambda_j)^t$ を掛けたものだと分かる。t を大きくすると $|\mu_j|$ の小さい成分——すなわち L_{sym} の固有値が 1 に近い成分——が速く減衰し、粗い構造だけが残る。拡散距離も命題 11.7(3) の正規化から従う：$\pi_i = d_i / \sum_l d_l$ を定常分布とし ψ_j を $\psi_j^{\top}\,\mathrm{diag}(\pi)\psi_l = \delta_{jl}$ と規格化すれば

$$D_t(i,i')^2 := \sum_{l} \frac{\left(P^t_{il} - P^t_{i'l}\right)^2}{\pi_l} = \sum_{j \geq 1} \mu_j^{2t} \left(\psi_j(i) - \psi_j(i')\right)^2 \tag{11.14}$$

が成り立つ（$j=0$ の項は ψ_0 が定数ベクトルなので落ちる）。上と同じグラフの $t=3$、$(i,i') = (1,6)$ で両辺を実測するとともに 0.19122285 である。重み $1/\pi_l$ と ψ_j の規格化は対応しており、$\psi_j^{\top} D \psi_l = \delta_{jl}$ の規格化を使うと式 (11.14)の右辺は $\sum_l d_l$ 倍だけずれる（同じ例で 0.01405935）ので、**どの規格化を採るかを必ず揃えること**。

多様体学習の統一的な見方

Ham ら [37] は、上の手法がいずれも**適切に選んだ Gram 行列に対するカーネル PCA**（第8章）として書けることを示した。Isomap は $K = -\frac{1}{2} H D_G^{(2)} H$、LLE は $K = \lambda_{\max}(M) I - M$、ラプラシアン固有写像は $K = L^{+}$（小さい固有値が K の大きい固有値になる）、拡散写像は $K = (D^{1/2} P D^{-1/2})^t = S^t$（命題 11.7の対称行列 S の冪。P 自身は対称でないのでそのままではカーネルにならない）である。違いは「どのカーネルを使うか」だけで、「内積を取り替える」操作を身につけていれば**カーネルの設計の問題**に還元される。

11.3.3　t-SNE と UMAP：可視化のための手法

t-SNE [78] は固有値問題を解かない。入力空間で条件付き確率 $p_{j|i} \propto \exp(-\|x_i - x_j\|^2 / (2\sigma_i^2))$（$\sigma_i$ は perplexity に合わせて点ごとに調整）を対称化して p_{ij} とし、埋め込み側では裾の重い Student-t 分布 $q_{ij} \propto (1 + \|y_i - y_j\|^2)^{-1}$（$y_i$ は $Y \in \mathbb{R}^{k \times n}$ の第 i 列）を使って

$$\min_{Y} \ \mathrm{KL}(P \,\|\, Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}} \tag{11.15}$$

を勾配法で解く。UMAP [51] はファジィ単体集合の言葉で近傍構造を定式化し、KL の代わりに交差エントロピーを負例サンプリングで近似最小化する（t-SNE より高速）。

式 (11.15)の KL は非対称である。p_{ij} が大きいのに q_{ij} が小さいと巨大な罰則がかかるが逆は軽い。つまり「**近いものを近くに**」は**強く要求するが**「**遠いものを遠くに**」は**ほとんど要求しない**。これが t-SNE 図の性質を決めている。

t-SNE / UMAP の図を読むときの注意

読み取ってよいのは、どの点が同じ塊に入るかという**局所的な近傍関係**だけである。**塊どうしの距離**は元の空間で近いことも遠いこともあり、**塊の大きさ・密度**も反映されない（t-SNE は密な領域を広げ疎な領域を縮める）。**塊の形**は最適化の副産物であることが多く、**大域的な配置**は perplexity や乱数シードで容易に変わる。安定な特徴だけを信じ、主張したい構造は必ず元の空間での量で裏を取ること。

11.4　行列補完と核ノルム

11.4.1　Netflix 問題と凸緩和

n 人の利用者と d 本の映画の評価行列 $M \in \mathbb{R}^{d \times n}$（**第 i 列**が利用者 i の評価ベクトル）のうち観測されるのは添字集合 Ω の成分だけで $|\Omega| \ll dn$ である。残りを埋めよ、というのが**行列補完**で、何の仮定もなければ不可能だから「好みは少数の潜在因子で決まる」という仮定 $\mathrm{rank}(M) = r \ll \min(d,n)$ を置く。ランク r の行列は $r(d+n-r)$ 個のパラメータで決まるから、

$|\Omega|$ がこれを十分上回れば望みはある。素直な定式化 $\min_{\boldsymbol{X}} \operatorname{rank}(\boldsymbol{X})$ s.t. $X_{ij} = M_{ij}$ $((i,j)\in\Omega)$ は NP 困難である [30, 65]。$\operatorname{rank}(\boldsymbol{X})$ は特異値ベクトルの非零成分数 $\|\boldsymbol{\sigma}(\boldsymbol{X})\|_0$ だから、ℓ_0 を ℓ_1 で緩和する LASSO の発想と同様に次を導入する。

定義 11.8 (核ノルム)**.** $\boldsymbol{X}\in\mathbb{R}^{d\times n}$ の**核ノルム**（nuclear norm, trace norm）を $\|\boldsymbol{X}\|_* := \sum_{i=1}^{q}\sigma_i(\boldsymbol{X})$、$q=\min(d,n)$ と定める。

命題 11.9. $\|\boldsymbol{X}\|_* = \max\{\langle \boldsymbol{X},\boldsymbol{Y}\rangle_{\mathrm{F}} : \|\boldsymbol{Y}\|_{\mathrm{op}}\le 1\}$ であり、特に $\|\cdot\|_*$ は凸である。また $\|\boldsymbol{X}\|_{\mathrm{op}}\le 1$ ならば $\|\boldsymbol{X}\|_*\le \operatorname{rank}(\boldsymbol{X})$。

証明. von Neumann のトレース不等式 $\langle \boldsymbol{X},\boldsymbol{Y}\rangle_{\mathrm{F}} \le \sum_i \sigma_i(\boldsymbol{X})\sigma_i(\boldsymbol{Y})$ より $\sigma_i(\boldsymbol{Y})\le 1$ のとき $\langle \boldsymbol{X},\boldsymbol{Y}\rangle_{\mathrm{F}}\le\|\boldsymbol{X}\|_*$ で、等号は $\boldsymbol{X}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$ に対し $\boldsymbol{Y}=\boldsymbol{U}\boldsymbol{V}^{\top}$ で達成される。線形関数の上限（支持関数）は常に凸だから $\|\cdot\|_*$ は凸。後半は $r=\operatorname{rank}(\boldsymbol{X})$ とすると非零特異値が r 個で各々 $\sigma_i\le\|\boldsymbol{X}\|_{\mathrm{op}}\le 1$ だから $\|\boldsymbol{X}\|_*\le r$。 ■

さらに強く、**単位作用素ノルム球上で $\|\cdot\|_*$ は $\operatorname{rank}(\cdot)$ の凸包絡である**（その球上で rank を下から押さえる凸関数のうち最大のもの）[30]。証明は rank の Fenchel 共役を計算して双共役が $\|\cdot\|_*$ に一致することを見る手順だが、共役の計算に準備が要るのでここでは省略し、上の易しい向きのみを示した。ℓ_1 が単位 ℓ_∞ 球上で ℓ_0 の凸包絡であるのと平行な事実である。そこで問題を

$$\min_{\boldsymbol{X}} \|\boldsymbol{X}\|_* \quad \text{s.t.} \quad X_{ij}=M_{ij}\ \ ((i,j)\in\Omega) \tag{11.16}$$

に置き換える。半正定値計画として書ける凸問題である。復元保証は次のとおりである。

まず、どのような行列なら復元できるのかを測る量を用意する。特異ベクトルが標準基底に集中している行列（例えば $\boldsymbol{e}_1\boldsymbol{e}_1^{\top}$）は、その一点を観測し損ねると復元しようがない。この「集中していないこと」を数値化する。

定義 11.10 (コヒーレンス [19])**.** $\boldsymbol{M}\in\mathbb{R}^{d\times n}$ をランク r とし、その特異値分解の左・右特異ベクトルの張る空間への直交射影を $\boldsymbol{P}_U$、$\boldsymbol{P}_V$ とする。

$$\mu_0(\boldsymbol{M}) := \max\Big\{ \tfrac{d}{r}\max_{1\le i\le d}\|\boldsymbol{P}_U\boldsymbol{e}_i\|^2,\ \tfrac{n}{r}\max_{1\le j\le n}\|\boldsymbol{P}_V\boldsymbol{e}_j\|^2 \Big\} \tag{11.17}$$

を $\boldsymbol{M}$ の**コヒーレンス母数**（coherence parameter）と呼ぶ。

$\|\boldsymbol{P}_U\boldsymbol{e}_i\|^2$ の総和は $\operatorname{tr}\boldsymbol{P}_U = r$ なので平均は r/d、したがって常に $1\le\mu_0\le \max(d,n)/r$ である。$\mu_0=1$ は特異ベクトルが全座標に均等に広がった最良の場合、$\mu_0=\max(d,n)/r$ は一つの座標に完全に集中した最悪の場合である。実測すると、60×60 のランダムなランク 3 行列（成分独立標準正規の積）では $\mu_0=4.94$（上限 20）、$\boldsymbol{e}_1\boldsymbol{e}_1^{\top}$ では $\mu_0=60.0$（上限 60 そのもの）、注意 11.12の 2×2 例のランク 1 部分 $(1,3)^{\top}(1,2)$ では $\mu_0=1.80$（上限 2 の 90%）である。

定理 11.11 (復元保証（概略・主張のみ）[19, 20, 65])**.** $\boldsymbol{M}\in\mathbb{R}^{n\times n}$ をランク r、コヒーレンス母数 μ_0（定義 11.10）の行列とし、Ω を一様ランダムに選んだ $|\Omega|=m$ 個の添字とする。ある普遍定数 C に対し

$$m \ \ge\ C\,\mu_0\, n r \log^2 n$$

であれば、式 (11.16)の解は高い確率で $\boldsymbol{M}$ に**厳密に**一致する。

自由度 $r(2n-r)\approx 2nr$ に対し $\log^2 n$ の因子しか払っていない。凸緩和がほぼ最適である、という驚くべき結果である。

定理 11.11は概略版である

上の主張は m **が** n, r **にどう依存するかを読み取ることだけを目的とした概略**であり、このままでは定理を再証明できない。正確な定式化には少なくとも次が必要である。**(i) コヒーレンス条件**——原論文は式 (11.17)の μ_0 に加えて $\boldsymbol{P}_U\boldsymbol{M}$ の成分の一様有界性にあたる第二の条件（μ_1 条件、あるいは $\|\boldsymbol{U}\boldsymbol{V}^{\top}\|_\infty\le\sqrt{\mu_1 r/(dn)}$ の形）を課し、m の下界は μ_0 と μ_1 の両方に依存する。**(ii) 標本抽出の様式**——添字を復元ありで引くか（with replacement、Ω が多重集合になる）なしで引くか、あるいは各成分を独立に確率 $p=m/n^2$ で観測するか（Bernoulli モデル）で解析が変わる。三者は互換ではなく、比較には移行の議論が必要である。**(iii) 確率評価**——「高い確率で」は $1-cn^{-\beta}$ の形で、β と $\log^2 n$ の指数・定数 C は互いに依存する（[20] は r が大きい領域で $\log^2 n$ を $\log n$ に改善している）。**(iv) 誤差なしの仮定**——観測値が正確であることを使っている。ノイズがある場合は「厳密一致」ではなく誤差の上界の主張になる。正確な仮定と証明は [19, 20, 65] を参照せよ。

注意 11.12 (標本が足りなければ緩和は破綻する)**.** $\boldsymbol{M}=\left(\begin{smallmatrix}1 & 2\\ 3 & x\end{smallmatrix}\right)$ の左上三成分だけが観測されているとしよう。ランク 1 にする x は $x-6=0$ より $x=6$ ただ一つで、そのとき $\|\boldsymbol{M}\|_*=\sqrt{50}\approx 7.07$。一方 $x=1$ では特異値が 3.618, 1.382 で $\|\boldsymbol{M}\|_*=5.00$ と小さく、実際これが核ノルム最小化の最適解であって **ランク最小の補完とは一致しない**。観測数 3 は自由度 $r(2n-r)=3$ ちょうどで 定理 11.11の余裕がなく、しかもコヒーレンスも高い（真のランク 1 部分の $\mu_0=1.80$ は上限 2 の 90% である）。加えて観測位置が一様ランダムでもない。凸緩和は魔法ではない。

11.4.2　特異値閾値化アルゴリズム

式 (11.16)を解く鍵は、核ノルムの近接写像が明示的に書けることである。

定理 11.13 (核ノルムの近接写像 = 特異値の軟閾値化)**.** $\boldsymbol{Y}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$、$\boldsymbol{\Sigma}=\operatorname{diag}(s_1,\dots,s_q)$、$\tau>0$ に対し

$$\mathcal{D}_\tau(\boldsymbol{Y}) \coloneqq \arg\min_{\boldsymbol{X}} \ \tfrac{1}{2}\|\boldsymbol{X}-\boldsymbol{Y}\|_{\mathrm{F}}^2+\tau\|\boldsymbol{X}\|_* \ = \ \boldsymbol{U}\ \operatorname{diag}\bigl((s_i-\tau)_+\bigr)\,\boldsymbol{V}^{\top}. \tag{11.18}$$

証明. 目的関数は $\frac{1}{2}\|\boldsymbol{X}\|_{\mathrm{F}}^2-\langle \boldsymbol{X},\boldsymbol{Y}\rangle_{\mathrm{F}}+\frac{1}{2}\|\boldsymbol{Y}\|_{\mathrm{F}}^2+\tau\|\boldsymbol{X}\|_*$。$\|\boldsymbol{X}\|_{\mathrm{F}}^2=\sum_i \sigma_i(\boldsymbol{X})^2$ と von Neumann の不等式 $\langle \boldsymbol{X},\boldsymbol{Y}\rangle_{\mathrm{F}}\le \sum_i \sigma_i(\boldsymbol{X})s_i$ より、任意の $\boldsymbol{X}$ に対し

$$\tfrac{1}{2}\|\boldsymbol{X}-\boldsymbol{Y}\|_{\mathrm{F}}^2+\tau\|\boldsymbol{X}\|_* \ \ge \ \tfrac{1}{2}\|\boldsymbol{Y}\|_{\mathrm{F}}^2+\sum_{i=1}^{q}\Bigl[\tfrac{1}{2}\sigma_i(\boldsymbol{X})^2-(s_i-\tau)\sigma_i(\boldsymbol{X})\Bigr],$$

等号成立は $\boldsymbol{X}$ が $\boldsymbol{Y}$ と同じ特異ベクトルを持つときである。右辺は $\sigma_i(\boldsymbol{X})\ge 0$ について分離し、各項の $\sigma\ge 0$ での最小は $\sigma=(s_i-\tau)_+$ で達成される。よって式 (11.18)が最小解であり、目的関数が狭義凸だから一意である。 ∎

観測射影を $\mathcal{P}_\Omega$ と書くと、罰則付き問題 $\min_{\boldsymbol{X}} \frac{1}{2}\|\mathcal{P}_\Omega(\boldsymbol{X}-\boldsymbol{M})\|_{\mathrm{F}}^2+\lambda\|\boldsymbol{X}\|_*$ の近接勾配反復はステップ幅 1 で

$$\boldsymbol{X}^{(t+1)}=\mathcal{D}_\lambda\Bigl(\mathcal{P}_\Omega(\boldsymbol{M})+\mathcal{P}_\Omega^{\perp}(\boldsymbol{X}^{(t)})\Bigr) \tag{11.19}$$

という簡潔な形になる（**soft-impute** [50]）。「観測成分は真値で埋め、未観測成分は現在の推定で埋め、全体を軟閾値化する」という反復である。等式制約版に対応するのが Cai–Candès–Shen の**特異値閾値化**（singular value thresholding, SVT）[18]で、$\boldsymbol{X}^{(t)}=\mathcal{D}_\tau(\boldsymbol{Y}^{(t-1)})$、$\boldsymbol{Y}^{(t)}=\boldsymbol{Y}^{(t-1)}+\delta\mathcal{P}_\Omega(\boldsymbol{M}-\boldsymbol{X}^{(t)})$ と更新する。第4章のロバスト PCA（$\min\|\boldsymbol{L}\|_*+\lambda\|\boldsymbol{S}\|_1$）も同じ枠組みで、そこで使った特異値の軟閾値化は定理 11.13そのものであった。

例 11.14. 式 (11.19)は数行で実装できる。`prox_nuc(Y,t)` を `U,s,Vt=svd(Y); (U*maximum(s-t,0))@Vt` と定め、`X=prox_nuc(mask*M+(1-mask)*X, lam)` を反復するだけである。60 × 60、ランク 3 の行列の 71% を観測し λ を 10 → 3 → 1 → 0.3 → 0.1 → 0.03 → 0.01 と温かい出発点で下げながら各 2000 回反復すると、相対誤差 $\|\hat{\boldsymbol{X}}-\boldsymbol{M}\|_{\mathrm{F}}/\|\boldsymbol{M}\|_{\mathrm{F}}=2.4\times10^{-4}$、推定ランク 3（真値と一致）で復元される。$\lambda$ を最初から 0.01 にすると収束が遅い。

11.5　最適輸送と Wasserstein 距離

11.5.1　Monge から Kantorovich へ

砂山 μ を穴 ν に移す。$\boldsymbol{x}$ の砂を $T(\boldsymbol{x})$ に運ぶコストが $c(\boldsymbol{x},T(\boldsymbol{x}))$ のとき、総コストを最小にする運び方 T を求めよ。制約は「運んだ結果がちょうど ν になること」で、これを押し出し測度で書く。本書は測度論を前提にしないので、使う用語だけ先に挙げておく。

最小限の用語：測度空間と可測写像

集合 $\mathcal{X}$ の部分集合の族 $\mathcal{A}$ が、$\mathcal{X}\in\mathcal{A}$ をみたし、補集合と可算合併で閉じるとき、$\mathcal{A}$ を **σ-加法族**といい、その元を**可測集合**という。$\mu:\mathcal{A}\to[0,\infty]$ が $\mu(\emptyset)=0$ と可算加法性（互いに交わらない $A_1,A_2,\dots$ に対し $\mu(\bigcup_k A_k)=\sum_k \mu(A_k)$）をみたすとき μ を**測度**、組 $(\mathcal{X},\mathcal{A},\mu)$ を**測度空間**という。$\mu(\mathcal{X})=1$ なら**確率測度**で、その全体を $\mathcal{P}(\mathcal{X})$ と書く。写像 $T:\mathcal{X}\to\mathcal{Y}$ が**可測**であるとは、$\mathcal{Y}$ の任意の可測集合 B に対し $T^{-1}(B)$ が $\mathcal{X}$ の可測集合であることをいう。本節で必要なのは $\mathcal{X}=\mathbb{R}^d$ の場合だけで、可測集合は開集合から生成される Borel 集合、測度は体積を与える Lebesgue 測度や確率分布を考えればよい（連続写像は可測である）。

定義 11.15 (押し出し測度)**.** 可測写像 $T:\mathcal{X}\to\mathcal{Y}$ と $\mathcal{X}$ 上の測度 μ に対し、$\mathcal{Y}$ の可測集合 B について

$$(T_{\#}\mu)(B)\coloneqq\mu\bigl(T^{-1}(B)\bigr)$$

で定まる $\mathcal{Y}$ 上の測度 $T_{\#}\mu$ を、μ の T による**押し出し測度**（pushforward measure）という。

$T_{\#}\mu$ は μ の質量を $\boldsymbol{x}\mapsto T(\boldsymbol{x})$ で移したあとの分布である。同値な特徴づけとして、任意の有界可測関数 φ に対し

$$\int_{\mathcal{Y}}\varphi(\boldsymbol{y})\,\mathrm{d}(T_{\#}\mu)(\boldsymbol{y})=\int_{\mathcal{X}}\varphi(T(\boldsymbol{x}))\,\mathrm{d}\mu(\boldsymbol{x})$$

が成り立つ（指示関数 $\varphi=\mathbf{1}\{\boldsymbol{y}\in B\}$ では定義そのもので、単関数と単調収束で一般の φ に拡張される）。確率変数の言葉では、$X\sim\mu$ ならば $T(X)\sim T_{\#}\mu$ である。たとえば $\mu=\frac{1}{2}\delta_0+\frac{1}{2}\delta_1$、$T(x)=2x$ なら $T_{\#}\mu=\frac{1}{2}\delta_0+\frac{1}{2}\delta_2$ である（質量 1/2 が 0 → 0、残りが 1 → 2 と移っただけ）。したがって $T_{\#}\mu=\nu$ は μ **の質量を** T **で運んだ結果がちょうど** ν **になる**ことを意味する。

定義 11.16 (Monge の問題)**.** $\mu \in \mathcal{P}(\mathcal{X})$、$\nu \in \mathcal{P}(\mathcal{Y})$ と可測なコスト関数 $c : \mathcal{X} \times \mathcal{Y} \to [0, \infty]$ に対し

$$\inf\left\{ \int_{\mathcal{X}} c\big(\boldsymbol{x}, T(\boldsymbol{x})\big)\, \mathrm{d}\mu(\boldsymbol{x}) \ : \ T : \mathcal{X} \to \mathcal{Y} \text{ は可測},\ T_{\#}\mu = \nu \right\}$$

を求める問題を **Monge の問題**（1781 年）といい、下限を達成する T を **最適輸送写像**という。

制約 $T_{\#}\mu = \nu$ は T について非線形で、そもそも最適輸送写像が存在しないことがある（$\mu = \delta_0$、$\nu = \frac{1}{2}\delta_{-1} + \frac{1}{2}\delta_1$ では一点の砂を二箇所に分けられない）。Kantorovich（1942 年）は**砂を分割してよい**ことにし、輸送写像の代わりに結合分布を考えた。これが次のカップリングである。

定義 11.17 (カップリング（輸送計画）)**.** $\mu \in \mathcal{P}(\mathcal{X})$、$\nu \in \mathcal{P}(\mathcal{Y})$ とする。積空間 $\mathcal{X} \times \mathcal{Y}$ 上の確率測度 π が

$$\pi(A \times \mathcal{Y}) = \mu(A), \qquad \pi(\mathcal{X} \times B) = \nu(B) \qquad (\text{任意の可測} A \subset \mathcal{X},\ B \subset \mathcal{Y}) \tag{11.20}$$

すなわち二つの周辺分布がそれぞれ μ, ν に一致するとき、π を μ と ν の **カップリング**（coupling、結合分布）という。最適輸送の文脈では **輸送計画**（transport plan）とも呼ぶ。カップリング全体の集合を $\Pi(\mu, \nu)$ と書く。

$\pi(A \times B)$ は「A にあった砂のうち B へ運ばれる量」である。離散の場合は行列 $\boldsymbol{P} = (P_{ij})$ で、P_{ij} が点 i から点 j へ運ぶ質量、(11.20)は行和・列和の制約 $\boldsymbol{P}\mathbf{1} = \boldsymbol{a}$、$\boldsymbol{P}^{\top}\mathbf{1} = \boldsymbol{b}$ になる。すなわち(11.21)の $U(\boldsymbol{a}, \boldsymbol{b})$ が離散版の $\Pi(\mu, \nu)$ である。

「計画」という呼び方は線形計画としての出自を反映している。Monge の輸送写像 T は $\pi = (\mathrm{id}, T)_{\#}\mu$ というカップリング（$\boldsymbol{x} \mapsto (\boldsymbol{x}, T(\boldsymbol{x}))$ による $\mathcal{X} \times \mathcal{Y}$ への押し出しで、$\boldsymbol{x}$ の砂の行き先が $T(\boldsymbol{x})$ 一点に集まる **決定的な**カップリング）に対応するので、Kantorovich の問題は Monge の問題の緩和である。一方 $\mu \otimes \nu$（独立カップリング）は常に $\Pi(\mu, \nu)$ に属するので、この集合は空でない。

定義 11.18 (Kantorovich 問題と最適輸送計画 [81])**.** $\Pi(\mu, \nu)$ を定義 11.17のカップリングの集合、$c : \mathcal{X} \times \mathcal{Y} \to [0, \infty]$ を可測なコスト関数とする。輸送計画 π を変数とする最小化問題

$$\mathrm{OT}_c(\mu, \nu) \coloneqq \inf_{\pi \in \Pi(\mu, \nu)} \int_{\mathcal{X} \times \mathcal{Y}} c(\boldsymbol{x}, \boldsymbol{y})\, \mathrm{d}\pi(\boldsymbol{x}, \boldsymbol{y})$$

を **Kantorovich の最適輸送問題**という。この下限を達成する $\pi^{\star} \in \Pi(\mu, \nu)$、すなわち $\int c\, \mathrm{d}\pi^{\star} = \mathrm{OT}_c(\mu, \nu)$ をみたす $\pi^{\star}$ を **最適輸送計画**（optimal transport plan）または**最適カップリング**という。

$\Pi(\mu, \nu)$ の元はどれも輸送計画であり、そのうちコストを最小にするものが最適輸送計画である、という区別に注意されたい。Monge の問題（定義 11.16）と違い、最適輸送計画は**必ず存在する**。$\Pi(\mu, \nu)$ が空でなく（積測度が入る）凸かつ弱位相でコンパクトで、c が下半連続だからである。

コストを $\|\boldsymbol{x} - \boldsymbol{y}\|^p$ に取ると、最小値そのものが距離になる。

定義 11.19 (Wasserstein 距離)**.** $\mathcal{X} = \mathcal{Y} = \mathbb{R}^d$、$c(\boldsymbol{x}, \boldsymbol{y}) = \|\boldsymbol{x} - \boldsymbol{y}\|^p$（$p \geq 1$）のとき $W_p(\mu, \nu) \coloneqq \mathrm{OT}_c(\mu, \nu)^{1/p}$ を **p-Wasserstein 距離**という。これは

$$\mathcal{P}_p(\mathbb{R}^d) \coloneqq \left\{ \mu \in \mathcal{P}(\mathbb{R}^d) : \int_{\mathbb{R}^d} \|\boldsymbol{x}\|^p\, \mathrm{d}\mu(\boldsymbol{x}) < \infty \right\}$$

すなわち p 次モーメントが有限な確率測度の全体の上の距離である。

目的関数は π について線形だから Kantorovich 問題は無限次元の線形計画で、離散の場合は有限次元の線形計画そのものになる。$\boldsymbol{a} \in \mathbb{R}^n$、$\boldsymbol{b} \in \mathbb{R}^m$ を確率ベクトル、$\boldsymbol{C}$ をコスト行列とすると

$$\min_{\boldsymbol{P} \in U(\boldsymbol{a}, \boldsymbol{b})} \langle \boldsymbol{C}, \boldsymbol{P} \rangle_{\mathrm{F}}, \qquad U(\boldsymbol{a}, \boldsymbol{b}) = \{ \boldsymbol{P} \in \mathbb{R}^{n \times m}_{\geq 0} : \boldsymbol{P}\mathbf{1}_m = \boldsymbol{a},\ \boldsymbol{P}^{\top}\mathbf{1}_n = \boldsymbol{b} \}. \tag{11.21}$$

であり、最小解 $\boldsymbol{P}^{\star}$ が**最適輸送計画行列**である。制約集合 $U(\boldsymbol{a}, \boldsymbol{b})$ は行和・列和を指定した非負行列の集合で、**輸送多面体**（transportation polytope）と呼ばれる [61]。有界な凸多面体だから線形計画の最小値は頂点で達成される。特に $n = m$、$\boldsymbol{a} = \boldsymbol{b} = \mathbf{1}_n/n$ のとき $nU(\boldsymbol{a}, \boldsymbol{b})$ は二重確率行列の全体（Birkhoff 多面体）で、その頂点は置換行列である。すなわちこの場合、最適輸送計画は点と点の一対一対応として選べる。

L^2 距離と比べよう。$\mu_t = \delta_t$、$\nu = \delta_0$ とすると $W_2(\mu_t, \nu) = |t|$ で分布の「ずれ」を素直に測るが、台が重ならない限り全変動距離は常に 2、L^2 距離もほぼ一定で t の情報を持たない。W_p は**台の幾何を見ている**のである。この違いは補間で最もはっきりする（図 11.3）：L^2 の線形補間 $(1-s)f_\mu + sf_\nu$ は片方の山が薄れ他方が濃くなる「フェードイン・フェードアウト」になるのに対し、Wasserstein 補間（測地線、displacement interpolation）では山が**移動**する。

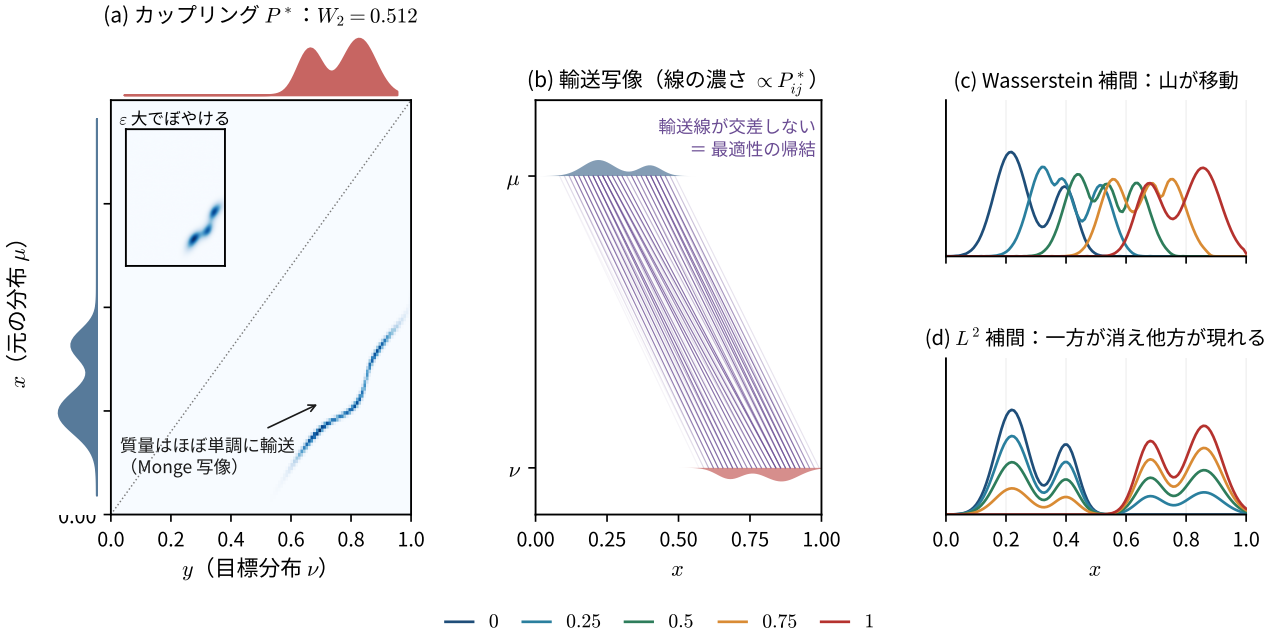


図11.3　最適輸送。最適カップリング行列 $\boldsymbol{P}^\star$ と質量を運ぶ対応関係、および補間。Wasserstein 補間では山が移動し、L^2 補間では一方が薄れて他方が濃くなる。

11.5.2　一次元では閉形式になる

一次元は特別で、最適輸送が完全に解ける。以下、累積分布関数 F_μ の一般化逆（分位関数）を $F_\mu^{-1}(u) = \inf\{x : F_\mu(x) \ge u\}$ と書く。

定理 11.20 (一次元最適輸送)**.** $\mu, \nu \in \mathcal{P}_2(\mathbb{R})$ とすると

$$W_2(\mu,\nu)^2 = \int_0^1 \left|F_\mu^{-1}(u) - F_\nu^{-1}(u)\right|^2 \mathrm{d}u, \tag{11.22}$$

であり、最適カップリングは $U \sim \mathrm{Unif}[0,1]$ として $\pi^\star = \mathrm{law}\big(F_\mu^{-1}(U), F_\nu^{-1}(U)\big)$（**単調カップリング**）である。

証明. $(X,Y) \sim \pi \in \Pi(\mu,\nu)$ とすると $\mathbb{E}[(X-Y)^2] = \mathbb{E}[X^2] + \mathbb{E}[Y^2] - 2\mathbb{E}[XY]$ で、第一・二項は π に依らない。よって W_2^2 の最小化は $\mathrm{Cov}(X,Y)$ の**最大化**と同値である。

Hoeffding の共分散恒等式を示す。(X',Y') を独立なコピーとすると $2\,\mathrm{Cov}(X,Y) = \mathbb{E}[(X-X')(Y-Y')]$。恒等式 $x - x' = \int_{\mathbb{R}} (\mathbf{1}\{x > s\} - \mathbf{1}\{x' > s\})\,\mathrm{d}s$ を両因子に使い Fubini により

$$2\,\mathrm{Cov}(X,Y) = \iint_{\mathbb{R}\times\mathbb{R}} \big[H(s,t) - F_\mu^c(s) F_\nu^c(t)\big]\,\mathrm{d}s\,\mathrm{d}t \cdot 2, \qquad H(s,t) \coloneqq \mathbb{P}(X > s, Y > t),\quad F_\mu^c(s) \coloneqq \mathbb{P}(X > s).$$

第二項は π に依らないから、$\mathrm{Cov}(X,Y)$ の最大化は各 (s,t) で $H(s,t)$ を最大化することに帰着する。Fréchet–Hoeffding の上界より常に $H(s,t) \le \min(F_\mu^c(s), F_\nu^c(t))$ が成り立ち、単調カップリングでは $\{X > s\}$ と $\{Y > t\}$ がともに U の上側区間となるので一方が他方を含み、上界を達成する。よって単調カップリングが最適で、そのコストが式 (11.22)である。 ■

例 11.21. n 点ずつの等重み経験分布では、式 (11.22)は「両方を昇順に並べ替えて差の二乗平均を取る」ことに帰着する。$n = 5$ の乱数例で線形計画を解いた値 0.041045 とソートして計算した値は小数第 15 位まで一致する。$O(n \log n)$ で解けるのが一次元の強みである。

11.5.3　エントロピー正則化と Sinkhorn アルゴリズム

一般次元では式 (11.21)は nm 変数の線形計画である。一般の線形計画ではなく、$n+m$ 個の頂点と nm 本の辺をもつ完全二部グラフ上の **最小費用流問題**という構造をもつので、それを使う専用の解法がある。それでも $n = m$ の場合に代表的な厳密解法の計算量は n^3 程度以上で、大規模な問題では計算負荷が高い（アルゴリズムごとに評価は異なる）。対比の要点は次の一点である。これから見る Sinkhorn は、一反復が $\boldsymbol{K}\boldsymbol{v}$ と $\boldsymbol{K}^\top\boldsymbol{u}$ という行列ベクトル積だけなので**一反復あたり** $O(nm)$ であり、行

列のまま扱える。Cuturi [26] はエントロピー項を加えることを提案した：

$$\min_{\boldsymbol{P}\in U(\boldsymbol{a},\boldsymbol{b})} \langle \boldsymbol{C},\boldsymbol{P}\rangle_{\mathrm{F}} - \varepsilon H(\boldsymbol{P}), \qquad H(\boldsymbol{P}) = -\sum_{ij} P_{ij}(\log P_{ij} - 1). \tag{11.23}$$

$-H$ は狭義凸だから解は一意で、しかも次の形をしている。

命題 11.22. $\varepsilon > 0$ とし、$a_i > 0$ $(\forall i)$、$b_j > 0$ $(\forall j)$、$C_{ij} < \infty$ $(\forall i,j)$ を仮定する。このとき式 (11.23)の解 $\boldsymbol{P}^\star$ はすべての成分が正であり、$\boldsymbol{K} \coloneqq \exp(-\boldsymbol{C}/\varepsilon)$（成分ごと）を用いて $\boldsymbol{P}^\star = \operatorname{diag}(\boldsymbol{u})\boldsymbol{K}\operatorname{diag}(\boldsymbol{v})$（$\boldsymbol{u}\in\mathbb{R}^n_{>0}$、$\boldsymbol{v}\in\mathbb{R}^m_{>0}$）の形に書ける。

証明. まず $P^\star_{ij} > 0$ を見る。仮定より $\boldsymbol{K}$ は成分がすべて正だから $\boldsymbol{P}^0 \coloneqq \operatorname{diag}(\boldsymbol{a})\boldsymbol{K}\operatorname{diag}(\boldsymbol{b})/(\boldsymbol{a}^\top\boldsymbol{K}\boldsymbol{b})$ を出発点として $U(\boldsymbol{a},\boldsymbol{b})$ の相対内部（全成分が正）は空でない。$P^\star_{ij} = 0$ となる (i,j) があったとし、$\boldsymbol{P}_s \coloneqq (1-s)\boldsymbol{P}^\star + s\boldsymbol{P}^+$（$\boldsymbol{P}^+ \in U(\boldsymbol{a},\boldsymbol{b})$ は全成分正）を考えると、$-H$ の $s\to 0^+$ での方向微分は $\varepsilon\log P_{ij} \to -\infty$ の項をもつため $-\infty$ に発散する。一方 $\langle \boldsymbol{C},\boldsymbol{P}_s\rangle_{\mathrm{F}}$ は $C_{ij} < \infty$ より s について有界な一次関数である。よって十分小さい $s > 0$ で目的関数が $\boldsymbol{P}^\star$ より小さくなり最適性に反する。したがって $\boldsymbol{P}^\star$ は $U(\boldsymbol{a},\boldsymbol{b})$ の相対内部にあり、すべての成分が正である（$a_i = 0$ なら第 i 行は $\boldsymbol{0}$ に強制されるので、この議論には $\boldsymbol{a},\boldsymbol{b} > 0$ が必要である）。

$\boldsymbol{P}^\star$ が相対内部にあるので、不等式制約 $P_{ij} \geq 0$ は非活性で、周辺制約の Lagrange 乗数 $\boldsymbol{f},\boldsymbol{g}$ だけを考えればよい。Lagrangian は $\sum_{ij}[C_{ij}P_{ij} + \varepsilon P_{ij}(\log P_{ij} - 1)] + \boldsymbol{f}^\top(\boldsymbol{P}\boldsymbol{1} - \boldsymbol{a}) + \boldsymbol{g}^\top(\boldsymbol{P}^\top\boldsymbol{1} - \boldsymbol{b})$ で、停留条件 $C_{ij} + \varepsilon\log P^\star_{ij} + f_i + g_j = 0$ から $P^\star_{ij} = e^{-f_i/\varepsilon}e^{-C_{ij}/\varepsilon}e^{-g_j/\varepsilon}$。$u_i = e^{-f_i/\varepsilon}$、$v_j = e^{-g_j/\varepsilon}$ とおけばよい。$-H$ が狭義凸で $U(\boldsymbol{a},\boldsymbol{b})$ が凸コンパクトだから最小解は一意である。 ■

注意 11.23 (仮定が要る理由)**.** $a_i > 0$、$b_j > 0$、$C_{ij} < \infty$ はどれも $P^\star_{ij} > 0$ を通じて指数形の導出に使われる。$a_i = 0$ なら第 i 行は $\boldsymbol{0}$ で $\log P_{ij}$ が定義できず（実測でも該当行が $(0,0,0)$ になる）、$C_{ij} = +\infty$（禁止された輸送）なら $P^\star_{ij} = 0$ となってその成分では停留条件が使えない（実測で $P^\star_{13} = 0$）。いずれも $\operatorname{diag}(\boldsymbol{u})\boldsymbol{K}\operatorname{diag}(\boldsymbol{v})$ の形自体は $u_i = 0$ や $K_{ij} = 0$ を許せば保たれるが、上の証明はそのままでは通らない。なお実装で ε が小さいときに $\boldsymbol{P}^\star$ の成分が 0 と表示されるのは**数値的なアンダーフロー**であって理論的な 0 ではない：同じ例で $\varepsilon = 1, 0.5, 0.2$ の最小成分は 2.9×10^{-5}、3.6×10^{-9}、5.0×10^{-21} と正で、$\exp(-\max_{ij} C_{ij}/\varepsilon)$ のオーダーに従って小さくなる。

あとは $\boldsymbol{u},\boldsymbol{v}$ を周辺制約に合わせるだけである。$\boldsymbol{P}\boldsymbol{1} = \boldsymbol{a}$ は $\boldsymbol{u}\odot(\boldsymbol{K}\boldsymbol{v}) = \boldsymbol{a}$、$\boldsymbol{P}^\top\boldsymbol{1} = \boldsymbol{b}$ は $\boldsymbol{v}\odot(\boldsymbol{K}^\top\boldsymbol{u}) = \boldsymbol{b}$ なので、交互に解けばよい。

Sinkhorn アルゴリズムは次の三行である。$\boldsymbol{K}\leftarrow\exp(-\boldsymbol{C}/\varepsilon)$（成分ごと）、$\boldsymbol{u}\leftarrow\boldsymbol{1}_n$、$\boldsymbol{v}\leftarrow\boldsymbol{1}_m$ と初期化し、収束するまで $\boldsymbol{u}\leftarrow\boldsymbol{a}\oslash(\boldsymbol{K}\boldsymbol{v})$、$\boldsymbol{v}\leftarrow\boldsymbol{b}\oslash(\boldsymbol{K}^\top\boldsymbol{u})$ を交互に繰り返して（$\oslash$ は成分ごとの除算）$\boldsymbol{P}^\star = \operatorname{diag}(\boldsymbol{u})\boldsymbol{K}\operatorname{diag}(\boldsymbol{v})$ を出力する。一反復は行列ベクトル積二回、すなわち $O(nm)$ である。これは Sinkhorn–Knopp の **行列スケーリング**（正行列を二重確率行列にする）[72] そのものである。収束そのものは [72] が示しており、Hilbert 射影距離のもとで縮小写像になること——したがって**線形（幾何）収束**すること——は Franklin–Lorenz [31] による。GPU 上で並列化しやすく微分可能でもあるため深層学習と組み合わせやすい。

$\varepsilon\to 0$ では $\boldsymbol{P}^\star$ は非正則化 OT の**最適解集合のうちエントロピー最大のもの**に収束する（下の警告ボックス）。実装上は $\boldsymbol{K}$ の成分がアンダーフローするので対数領域での計算が必要になる。逆に ε が大きいと $\boldsymbol{P}^\star\to\boldsymbol{a}\boldsymbol{b}^\top$（独立カップリング）に潰れる。

$\varepsilon\to 0$ の極限は「LP の解」ではなく「エントロピー最大の LP 最適解」

非正則化問題式 (11.21)の最適解が一意でないとき、「$\varepsilon\to0$ で $\boldsymbol{P}^\star$ は線形計画の解に収束する」という言い方は不正確である。正しくは

$$\boldsymbol{P}^\star_\varepsilon \xrightarrow[\varepsilon\to0]{} \arg\max\{H(\boldsymbol{P}) : \boldsymbol{P} \text{ は式 (11.21)の最適解}\}$$

であり、**最適解集合の中でエントロピー最大のものが選択される**。これはエントロピー項が $O(\varepsilon)$ の摂動として働き、最適解が縮退している方向だけで順序を決めるためである（辞書式の二段階最小化）。

最小例。 $\boldsymbol{x}_1 = (0,0)^\top$、$\boldsymbol{x}_2 = (1,1)^\top$ を $\boldsymbol{y}_1 = (1,0)^\top$、$\boldsymbol{y}_2 = (0,1)^\top$ へ等重み $\boldsymbol{a} = \boldsymbol{b} = (\frac12,\frac12)^\top$ で運ぶ二乗コストは $\boldsymbol{C} = \left(\begin{smallmatrix}1&1\\1&1\end{smallmatrix}\right)$ と**定数**になり、$U(\boldsymbol{a},\boldsymbol{b})$ のすべての要素がコスト 1 で最適である（線形計画の値も 1）。二つの置換行列の半分 $\boldsymbol{P}_{\mathrm{id}}$、$\boldsymbol{P}_{\mathrm{swap}}$ はどちらもエントロピー $H = 0.6931$、一方すべて $\frac14$ の $\boldsymbol{P}_{\mathrm{mix}}$ は $H = 1.3863$ である。Sinkhorn を回すと $\varepsilon = 1, 10^{-1}, 10^{-2}, 10^{-3}$ のいずれでも $\boldsymbol{P}^\star = \left(\begin{smallmatrix}0.25&0.25\\0.25&0.25\end{smallmatrix}\right)$、$\boldsymbol{P}_{\mathrm{mix}}$ との最大差は 7.8×10^{-15} 以下で、**頂点（置換行列）ではなくエントロピー最大の点**が選ばれている。

頂点が複数ある例。 $\boldsymbol{x} = \{(0,0),(1,1),(3,0)\}$、$\boldsymbol{y} = \{(1,0),(0,1),(3,1)\}$、等重み $\frac13$ の二乗コストでは最適解が面をなす。線形計画（`highs`）が返す頂点は $P_{12} = P_{21} = P_{33} = \frac13$ で $H = 1.0986$、その面の中心 $P_{11} = P_{12} = P_{21} = P_{22} = \frac16$、$P_{33} = \frac13$ は同じコスト 1 で $H = 1.5607$ とより大きい。Sinkhorn は $\varepsilon = 10^{-1}, 3\times10^{-2}, 10^{-2}, 3\times10^{-3}$ でいずれもコスト 1.000000、$H = 1.560710$、面の中心との最大差 3.1×10^{-14} 以下に収束し、LP の頂点とは $\frac16$ だけ離れたままである。

リスト 11.2　Sinkhorn アルゴリズムの実装。$n=6$、$m=5$ の一次元例で $\varepsilon=10^{-3}$ とすると、`scipy.optimize.linprog` による厳密値 0.129656 に対し 0.129707 を返し、周辺制約は機械精度（2.8×10^{-17}）で満たされる。

```python
import numpy as np

def sinkhorn(a, b, C, eps, n_iter=2000):
    K = np.exp(-C / eps)
    u, v = np.ones_like(a), np.ones_like(b)
    for _ in range(n_iter):
        u = a / (K @ v)          # 行の周辺分布を a に合わせる
        v = b / (K.T @ u)        # 列の周辺分布を b に合わせる
    return u[:, None] * K * v[None, :]

rng, n, m = np.random.default_rng(0), 6, 5
xs, ys = np.sort(rng.random(n)), np.sort(rng.random(m))
C, a, b = (xs[:, None] - ys[None, :])**2, np.full(n, 1/n), np.full(m, 1/m)
P = sinkhorn(a, b, C, eps=1e-3)
print((P * C).sum(), np.abs(P.sum(1) - a).max())    # 0.129707  2.8e-17
```

11.5.4　応用と、MMD との比較

生成モデルでは W_1 距離を Kantorovich–Rubinstein 双対 $W_1(\mu,\nu)=\sup\{\int f\,\mathrm{d}\mu-\int f\,\mathrm{d}\nu:\|f\|_{\mathrm{Lip}}\le 1\}$ の形で目的関数に使う（WGAN [7]）。ドメイン適応ではソースとターゲットの間の輸送計画でラベルを運び、単一細胞遺伝子発現の解析では異なる時点で測定された（同一細胞を追跡できない）細胞集団の間の最適輸送から発生軌跡を推定する [69]。第7章の MMD と並べておこう。どちらも**積分確率距離** $d_{\mathcal{F}}(\mu,\nu)=\sup_{f\in\mathcal{F}}(\int f\,\mathrm{d}\mu-\int f\,\mathrm{d}\nu)$ の形で、違いは関数クラス $\mathcal{F}$ である。

MMD は $\mathcal{F}$ を RKHS の単位球に取り、Gram 行列の平均として $O(n^2)$ の閉形式で計算できる。有界なカーネルのもとでは $|\widehat{\mathrm{MMD}}-\mathrm{MMD}|$ が $O_P(n^{-1/2})$ で、**この率は次元に依らない** [35]。W_1 は $\mathcal{F}$ を 1-Lipschitz 関数に取る。n 点と n 点の間の離散最適輸送は線形計画で、厳密解法の計算量は代表的なもので n^3 程度以上、Sinkhorn は**一反復あたり** $O(n^2)$ で、必要な反復数は目標精度と ε に依存する（11.5.3節）。推定の側では、$\mathbb{R}^d$ 上のコンパクト台をもつ分布に対し $\mathbb{E}[W_1(\hat{\mu}_n,\mu)]=O(n^{-1/d})$（$d>2$）が典型的な率で、次元の呪いを受ける。$d\le 2$ や分布に追加の構造（低次元台など）がある場合は率が変わるので、$n^{-1/d}$ は「高次元で効く代表的な上界」として読む。

つまり MMD は計算が軽く高次元でも推定しやすいがカーネルの選び方に敏感で、帯域幅が小さいと台が交わらない二分布について「離れている」ことしか分からなくなる。W_1 は幾何を素直に反映するが計算も推定も重い。用途で使い分ける。

11.5.5　Gromov–Wasserstein 距離：空間を共有しない対象を比べる

Wasserstein 距離は μ と ν が同じ空間にあること——少なくともコスト $c(\boldsymbol{x},\boldsymbol{y})$ が書けること——を前提にしている。ところが実際には、次元も座標系も違う二つの点群を比べたい場面がある。別の実験で測った細胞集団、別のコーパスで学習した単語埋め込み、頂点数の違う二つのグラフ。$\boldsymbol{x}\in\mathbb{R}^{d_1}$ と $\boldsymbol{y}\in\mathbb{R}^{d_2}$ の間に $\|\boldsymbol{x}-\boldsymbol{y}\|$ は定義できない。

Gromov–Wasserstein 距離 [53] はこの困難を、点の比較をやめて **点対の距離の比較**に置き換えることで回避する。比べる対象を**距離測度空間** $(\mathcal{X},d_{\mathcal{X}},\mu)$、$(\mathcal{Y},d_{\mathcal{Y}},\nu)$——距離と確率測度を備えた空間——とし、

$$\mathrm{GW}_p(\mathcal{X},\mathcal{Y})^p\coloneqq\inf_{\pi\in\Pi(\mu,\nu)}\iint\bigl|d_{\mathcal{X}}(\boldsymbol{x},\boldsymbol{x}')-d_{\mathcal{Y}}(\boldsymbol{y},\boldsymbol{y}')\bigr|^p\,\mathrm{d}\pi(\boldsymbol{x},\boldsymbol{y})\,\mathrm{d}\pi(\boldsymbol{x}',\boldsymbol{y}') \tag{11.24}$$

と定める。π は定義 11.17のカップリングそのままである。被積分関数の読み方が要点である：$\boldsymbol{x}\leftrightarrow\boldsymbol{y}$ と $\boldsymbol{x}'\leftrightarrow\boldsymbol{y}'$ を **同時に**対応づけたとき、$\mathcal{X}$ 側の 2 点間距離と $\mathcal{Y}$ 側の 2 点間距離がどれだけ食い違うかを測り、その食い違いをカップリングについて最小化する。Mémoli [53] はこれが距離測度空間の同型類の上で真の距離になることを示した。

離散版は $\boldsymbol{C}^{\mathcal{X}}\in\mathbb{R}^{n\times n}$、$\boldsymbol{C}^{\mathcal{Y}}\in\mathbb{R}^{m\times m}$ を距離（またはカーネル）行列として

$$\min_{\boldsymbol{P}\in U(\boldsymbol{a},\boldsymbol{b})}\sum_{i,k=1}^{n}\sum_{j,l=1}^{m}\bigl|C^{\mathcal{X}}_{ik}-C^{\mathcal{Y}}_{jl}\bigr|^p\,P_{ij}P_{kl} \tag{11.25}$$

である。(11.21)との違いは決定的で、目的関数が $\boldsymbol{P}$ について **二次**になっている。制約は同じ凸多面体 $U(\boldsymbol{a},\boldsymbol{b})$ だが目的関数が非凸なので、これは線形計画ではなく二次割当問題（NP 困難）である。実務では Peyré–Cuturi–Solomon [60] の反復——各反復で目的関数を $\boldsymbol{P}$ について線形化し、エントロピー正則化つき最適輸送（Sinkhorn）を 1 回解く——で局所最適を求める。

Gromov–Wasserstein は等長変換で不変

$\mathcal{Y}$ が $\mathcal{X}$ の等長なコピーであれば GW $=0$ である。$d_{\mathcal{Y}}$ が $d_{\mathcal{X}}$ と一致するので、対応させる置換を正しく選べば(11.24)の被積分関数が恒等的に 0 になる。$n=6$ の点群で総当たりで確認すると、回転と平行移動を施したコピーに対し $\mathrm{GW}_2^2=3.5\times10^{-31}$、鏡映に対し 0 である。同じ二組で W_2^2 はそれぞれ 34.20、0.81 で、こちらは座標がずれた分だけ増

える。無関係な点群では $\mathrm{GW}_2^2 = 148.96$ と有意に大きい。
つまり座標系を共有しない対象を比べられるのが GW の利点だが、裏を返せば**向きや位置の情報は落ちる**。鏡像を区別したい問題には使えない。

$\mathcal{X} = \mathcal{Y}$、$d$ を Euclid 距離にとっても GW と W_p は一致しない。W_p は絶対座標を、GW は距離の関係だけを見ているからである。用途は「対応関係そのものを求めたい」場面である：グラフの照合、異なるモダリティの単一細胞データ（scRNA-seq と scATAC-seq）の統合、異言語の単語埋め込み空間の対応づけ。最適な $\boldsymbol{P}$ が対応表として読める点が有用である。

11.6　単一細胞データ解析への応用：RECODE と scEGOT

本章の最後に、これまでの道具が実際の研究でどう使われているかを一つの分野で見ておく。**単一細胞 RNA シーケンシング**（scRNA-seq）は、細胞 1 個ずつについて数万個の遺伝子の発現量を数える技術である。得られるデータは $\boldsymbol{X} \in \mathbb{R}^{d \times n}$（$d \sim 10^4$ 個の遺伝子 $\times$ $n \sim 10^3$–10^5 個の細胞）で、まさに第5章が扱った $d \gg n$ の高次元データである。京都大学のグループが開発した二つの方法を紹介する。どちらも本講義で扱った数学がそのまま骨格になっている。

11.6.1　RECODE：次元の呪いを解く

scRNA-seq の観測値は**ランダムサンプリングノイズ**を持つ。細胞内の mRNA 分子のうち実際に読まれるのは一部で、その数え上げが確率的にゆらぐ。一つの遺伝子だけを見ればノイズは小さいが、10^4 個の遺伝子にわたって蓄積すると、第5章で見たとおり距離・寄与率・主成分方向のすべてが壊れる。RECODE（resolution of the curse of dimensionality、「次元の呪いの解消」）[43] はこの問題を高次元統計の立場から扱う。

通常の低ランク近似との違い。 観測を $\boldsymbol{X} = \boldsymbol{X}^{\mathrm{true}} + \boldsymbol{E}$ と書く。定理 2.28の Eckart–Young–Mirsky が与える階数 ℓ の最良近似

$$\mathrm{LR}_\ell(\boldsymbol{X}) = \sum_{i=1}^{\ell} \sqrt{(n-1)\lambda_{\boldsymbol{X},i}}\, \boldsymbol{u}_i \boldsymbol{v}_i^{\top}$$

（$\lambda_{\boldsymbol{X},i}$ は標本共分散 $\boldsymbol{S}_{\boldsymbol{X}}$ の固有値、$\boldsymbol{u}_i, \boldsymbol{v}_i$ は $\boldsymbol{X} - \overline{\boldsymbol{X}}$ の特異ベクトル）は、あくまで**観測行列 $\boldsymbol{X}$ への**最良近似である。我々が近づきたいのは $\boldsymbol{X}^{\mathrm{true}}$ であり、両者は一致しない。第5章で見たとおり、$d \gg n$ では $\lambda_{\boldsymbol{X},i}$ はノイズの分だけ系統的に過大だからである。そこで**打ち切りと同時に特異値を書き換える**：

$$\mathrm{YA}_\ell(\boldsymbol{X}) = \sum_{i=1}^{\ell} \sqrt{(n-1)\tilde{\lambda}_{\boldsymbol{X},i}}\, \boldsymbol{u}_i \boldsymbol{v}_i^{\top}, \qquad \tilde{\lambda}_{\boldsymbol{X},i} \coloneqq \lambda_{\boldsymbol{X},i} - \frac{1}{d_0 - i} \sum_{j=i+1}^{d_0} \lambda_{\boldsymbol{X},j} \quad (d_0 \coloneqq \min\{n, d\})$$

とする [6]。違いは $\lambda \to \tilde{\lambda}$ の一点だけである。補正項は**末尾固有値の平均**、すなわち信号を含まない方向に残っているノイズ分散の推定値で、これを差し引くのがノイズ掃き出し法（noise reduction methodology）である。特異値の言葉で書けば $\tilde{\sigma}_i = \bigl(\sigma_i^2 - \frac{1}{d_0 - i}\sum_{j>i}\sigma_j^2\bigr)^{1/2}$ となり、**階数の打ち切りに特異値の縮小を重ねた**形になっている——5.7節の縮小推定と同じ思想である。YA_ℓ は重心 $\boldsymbol{\mu}_{\boldsymbol{X}}$ と主成分方向 $\boldsymbol{u}_i$ をそのまま保ち、各方向の分散だけを $\lambda_{\boldsymbol{X},i} \to \tilde{\lambda}_{\boldsymbol{X},i}$ と書き換える写像である。

ランダムサンプリングノイズの分散は観測量で書ける。 ここまでは「ノイズ分散がどの特徴量でも等しい」ことを暗に使っている。scRNA-seq ではこれが破れる。細胞 j における遺伝子 i の観測カウントを c_{ij}、総カウントを $t_j = \sum_i c_{ij}$ とし、相対発現量 $x_{ij} \coloneqq c_{ij}/t_j$ を考える。測定は細胞内の RNA 分子集団からのランダムな抜き取りなので、t_j と真の相対発現量 x_{ij}^{true} を与えたときのカウントは二項分布に従い、x_{ij}^{true} が小さく t_j が大きいことから Poisson 近似 $c_{ij} \mid (t_j = t,\ x_{ij}^{\mathrm{true}} = y) \sim \mathrm{Poisson}(ty)$ が使える。このとき、t_j や x_{ij}^{true} の**周辺分布を一切仮定せずに**

$$\mathrm{Var}(x_{ij}) = \mathrm{Var}\bigl(x_{ij}^{\mathrm{true}}\bigr) + \mathbb{E}\Bigl(\frac{x_{ij}}{t_j}\Bigr)$$

が成り立つ [43]。実際、Poisson 分布の平均と分散がともに ty であることから $\mathbb{E}(x_{ij}) = \mathbb{E}(x_{ij}^{\mathrm{true}})$、$\mathbb{E}(x_{ij}^2) = \mathbb{E}[(x_{ij}^{\mathrm{true}})^2] + \mathbb{E}(x_{ij}^{\mathrm{true}}/t_j)$ であり、最後に $\mathbb{E}(x_{ij}/t_j) = \mathbb{E}(x_{ij}^{\mathrm{true}}/t_j)$ を使えばよい。右辺第 2 項は $\mathbb{E}(c_{ij}/t_j^2)$、すなわち**観測データだけから計算できる量**である。負の二項分布などを当てはめてパラメータを推定する必要がない点が要である。

遺伝子を、細胞によって真の発現量が変わる**有意**遺伝子、全細胞で一定の**非有意**遺伝子（ハウスキーピング遺伝子が典型）、全細胞で 0 の**サイレント**遺伝子に分けると、非有意遺伝子では $\mathrm{Var}(x_{ij}) = \mathbb{E}(x_{ij}/t_j)$——観測分散がすべてノイズ——となる。同時に、なぜ素朴な低ランク近似が効かないかもはっきりする。発現量が 3–4 桁違えば

$$\underbrace{\mathrm{Var}(x_{ij})}_{\text{有意だが発現量が小さい}} \quad \ll \quad \underbrace{\mathrm{Var}(x_{i'j})}_{\text{非有意だが発現量が大きい}}$$

が普通に起こり、PCA は後者を主成分として拾ってしまう。主成分方向そのものが壊れるので、固有値をいくら補正しても直らない。

ノイズ分散安定化正規化（NVSN）。 不等式を解消するには、各遺伝子をそのノイズ標準偏差で割ればよい：

$$z_{ij} \coloneqq \frac{x_{ij}}{\sqrt{\mathbb{E}(x_{ij}/t_j)}}, \qquad \text{このとき} \quad \mathrm{Var}(z_{ij}) = \begin{cases} \mathrm{Var}(z_{ij}^{\mathrm{true}}) + 1, & \text{有意}, \\ 1, & \text{非有意}, \\ 0, & \text{サイレント}. \end{cases}$$

これを**ノイズ分散安定化正規化**（noise variance-stabilizing normalization, NVSN）と呼び、行列としての写像を F と書く。全特徴量の分散を 1 に揃える z スコア化とは別物である：z スコア化は信号の分散も一緒に 1 に潰すが、NVSN が 1 に揃えるのは**ノイズの床**だけで、信号は $\mathrm{Var}(z_{ij}^{\mathrm{true}})$ としてその上に残る。

以上を合成したものが RECODE である：

$$\mathrm{RECODE}(\boldsymbol{C}) = F^{-1}\Big(\mathrm{YA}_{\ell_{\mathrm{opt}}}\big(F(\boldsymbol{C})\big)\Big), \qquad \ell_{\mathrm{opt}} = \min\Big\{k \;:\; \sum_{i>k} \lambda_{F(\boldsymbol{C}),i} \le d-k\Big\}.$$

ℓ_{opt} の右辺 $d-k$ は「残り $d-k$ 方向がすべてノイズだとしたときの分散の総和」で、NVSN によってノイズ分散が 1 に固定されているからこう書ける。すなわち信号ランクもノイズ分散も、ユーザが調整する必要がない。等方化されるのは**母**固有値であって、**標本**固有値ではないことには注意が要る。高次元では標本固有値は5.5節の Marchenko–Pastur 則に従って台 $[(1-\sqrt{\gamma})^2, (1+\sqrt{\gamma})^2]$ 全体に**広がる**（$\gamma = d/n$）。MP 則が与えてくれるのは「純粋なノイズなら標本固有値がどの程度広がるか」という定量的な目安であり、YA_ℓ の補正項はまさにその広がりを末尾固有値の平均としてデータから測ったものである。

「等方化すれば固有値がそろう」ではない

母共分散のノイズ部分を $\sigma^2\boldsymbol{I}$ にしても、標本固有値は一点には集まらない。$d = 2000$、$n = 500$（$\gamma = 4$）の標準正規ノイズで実測すると、非零の標本固有値は $[1.02,\ 9.10]$ に広がり（MP の台は $[1, 9]$）、最大と最小の比は 8.9 倍である。等方化が与えるのは**ノイズ由来の固有値が従うべき分布が既知になる**ことであって、固有値がそろうことではない。同じ設定に母固有値 7 のスパイクを一つ加えると標本固有値は 12.2（BBP の予測 11.7、5.6節）まで膨らむので、残した成分の分散もそのままでは使えない——これが主成分分散の補正が要る理由である。

人工データで確かめる

Poisson サンプリングで $d = 3000$ 遺伝子・$n = 1000$ 細胞を生成する（相対発現量は 4 桁にわたり、300 個を有意遺伝子、総カウントは $t_j \in [3000, 30000]$）。NVSN 前の遺伝子ごとの標本分散は最大と最小で 1.1×10^7 倍の開きがある。非有意遺伝子では標本分散 $/\mathbb{E}(x_{ij}/t_j)$ の中央値が 1.006（四分位 $[0.986, 1.071]$）で、上の分散表現が実際に成り立っている。NVSN 後の分散は非有意遺伝子で中央値 1.006 （5–95 パーセンタイル 0.949–1.247）、有意遺伝子で中央値 1.36 と、床が 1 に揃う。ℓ_{opt} は真の階数と同じ 2 と推定された。固有値は真値 (656.2, 62.0) に対し標本 (661.0, 66.6)、NRM 補正後 (658.0, 63.6) である。効果が最も見えるのは**寄与率**で、真値 (0.914, 0.086) に対し観測データからは (0.178, 0.018) しか得られない（残りはノイズ床が食っている）のに対し、補正後は (0.912, 0.088) と真値を再現する。真の行列との Frobenius 誤差は観測 1731、LR_ℓ で 92.0、YA_ℓ で 90.9。**構造の回復は階数を落とすこと自体が効いており、寄与率の回復には固有値の補正が要る**という役割分担が読める。

この方法の特徴は**次元削減をしない**点にある [43]。主成分を上位 k 個で打ち切るのではなく、全遺伝子の発現量を補正して返すので、発現量の低い遺伝子や希少な細胞集団の情報が残る。PCA が「捨てる」ことでノイズを除くのに対し、RECODE は「縮める」ことでノイズを除く。5.7節で縮小推定を扱ったとき、$\widehat{\boldsymbol{\Sigma}}$ の固有値が上位で過大・下位で過小に評価されることを見た。RECODE はその補正を、ノイズ分散が独立に推定できるという測定の構造を使って行っている。理論的な背景は青嶋・矢田の高次元統計 [6] である。

11.6.2　scEGOT：最適輸送で細胞の分化を追う

次の問いは動きである。細胞が未分化な状態から特定の細胞種へ分化していく過程を知りたい。ところが scRNA-seq は測定のために細胞を壊すので、**同じ細胞を追跡できない**。時点 $t_1, t_2, \ldots$ で別々の細胞集団のスナップショットが得られるだけである。時点 t_i の分布 μ_i と時点 t_{i+1} の分布 μ_{i+1} をつなぐ対応を推定する問題は、まさに定義 11.17の輸送計画を求める問題である。「細胞は無駄な動きをしない」という仮定を最適輸送として定式化するのが Waddington-OT [69] 以来の流れである。

通常の最適輸送との違い。 素直にやるなら、二つの時点の細胞をそれぞれ経験測度 $\hat{\mu}_t = \frac{1}{n}\sum_{i=1}^{n}\delta_{\boldsymbol{x}_i}$、$\hat{\mu}_{t+1} = \frac{1}{m}\sum_{j=1}^{m}\delta_{\boldsymbol{y}_j}$ とみなし、式 (11.23)のエントロピー正則化つき問題

$$\min_{\boldsymbol{P}\in U(\mathbf{1}_n/n,\ \mathbf{1}_m/m)} \sum_{i,j}\|\boldsymbol{x}_i-\boldsymbol{y}_j\|^2 P_{ij} - \varepsilon H(\boldsymbol{P})$$

を解くことになる。これが**細胞レベルの**最適輸送で、Waddington-OT [69] の立場である。難点が二つある。$\boldsymbol{P}$ が $n\times m$ 行列であること（$n,m\sim 10^3$–10^5）、そして P_{ij} が「細胞 i から細胞 j へ」という対応であって、生物学的な解釈をもたないことである。

scEGOT [86] は、各時点の細胞集団を**混合ガウス分布**で表す：

$$\mu_t = \sum_{k=1}^{K}\pi_k\,\mathcal{N}(\boldsymbol{m}_k,\boldsymbol{\Sigma}_k),\qquad \mu_{t+1} = \sum_{l=1}^{L}\rho_l\,\mathcal{N}(\boldsymbol{n}_l,\boldsymbol{\Lambda}_l)$$

（K,L は数個から数十個で、一つの成分が一つの細胞種に対応する）。そして輸送を **成分のあいだ**で解く。成分間のコストには、ガウス分布どうしの W_2 距離が閉形式で書けること [61] を使う：

$$C_{kl} \coloneqq W_2^2\big(\mathcal{N}(\boldsymbol{m}_k,\boldsymbol{\Sigma}_k),\mathcal{N}(\boldsymbol{n}_l,\boldsymbol{\Lambda}_l)\big) = \|\boldsymbol{m}_k-\boldsymbol{n}_l\|^2 + \operatorname{tr}\Big(\boldsymbol{\Sigma}_k+\boldsymbol{\Lambda}_l-2\big(\boldsymbol{\Sigma}_k^{1/2}\boldsymbol{\Lambda}_l\boldsymbol{\Sigma}_k^{1/2}\big)^{1/2}\Big).$$

あとは $K\times L$ の小さな問題 $\min_{\boldsymbol{W}\in U(\boldsymbol{\pi},\boldsymbol{\rho})}\sum_{k,l}C_{kl}W_{kl}-\varepsilon H(\boldsymbol{W})$ を Sinkhorn で解けばよい。細胞レベルの $n\times m$ が成分レベルの $K\times L$ になり、W_{kl}/π_k が**細胞種 k から細胞種 l への移行率**としてそのまま読める。

数学的には、これは $\Pi(\mu_t,\mu_{t+1})$ 全体ではなく、**それ自身が混合ガウス分布であるカップリング**に制限した問題を解いていることにあたる。制限した分だけコストは下がらないので、得られる距離 MW_2 は常に $\mathrm{MW}_2\ge W_2$ を満たし、一般には等号が成り立たない [29]。W_2 の計算の近道ではなく、**解釈可能性と計算量のためにカップリングの集合を狭めた別の問題**である、と読むのが正しい。

細胞一つ一つの行き先は、成分対ごとの輸送を責任度で混ぜて復元する。11.5.1節の Monge 写像は、ガウス分布どうしのあいだでは閉形式のアフィン写像

$$T_{kl}(\boldsymbol{x}) = \boldsymbol{n}_l + \boldsymbol{A}_{kl}(\boldsymbol{x}-\boldsymbol{m}_k),\qquad \boldsymbol{A}_{kl} = \boldsymbol{\Sigma}_k^{-1/2}\big(\boldsymbol{\Sigma}_k^{1/2}\boldsymbol{\Lambda}_l\boldsymbol{\Sigma}_k^{1/2}\big)^{1/2}\boldsymbol{\Sigma}_k^{-1/2}$$

で与えられるので、細胞 $\boldsymbol{x}$ の速度ベクトルを

$$\boldsymbol{v}(\boldsymbol{x}) = \sum_{k,l}P_{kl}(\boldsymbol{x})\,T_{kl}(\boldsymbol{x}) - \boldsymbol{x},\qquad P_{kl}(\boldsymbol{x}) = \frac{W_{kl}\,g_k(\boldsymbol{x})}{\sum_{k'}\pi_{k'}g_{k'}(\boldsymbol{x})}$$

と定める（g_k は第 k 成分の密度、$P_{kl}(\boldsymbol{x})$ は「この細胞が成分 k に属し l へ行く」確率）。これは混合型カップリングの重心射影 $\boldsymbol{x}\mapsto\int \boldsymbol{y}\,\mathrm{d}\pi(\boldsymbol{y}\mid\boldsymbol{x})$ にほかならない。時点の間の補間も成分対ごとに閉形式で、$s\in[0,1]$ に対し $\mathcal{N}\big((1-s)\boldsymbol{m}_k+s\boldsymbol{n}_l,\ \boldsymbol{B}_{kl}(s)\boldsymbol{\Sigma}_k\boldsymbol{B}_{kl}(s)\big)$、$\boldsymbol{B}_{kl}(s)=(1-s)\boldsymbol{I}+s\boldsymbol{A}_{kl}$ を重み W_{kl} で混ぜれば、各時刻の分布が混合ガウス分布として得られる。ここから、細胞種をノード・移行率をエッジとするグラフ、連続的な分化の様子、そして細胞の移動方向を表すベクトル場が得られる。

制限した分だけコストは上がる

一次元で厳密に比べられる。$\mu_t = 0.6\,\mathcal{N}(0,0.6)+0.4\,\mathcal{N}(3,0.5)$、$\mu_{t+1} = 0.45\,\mathcal{N}(0.5,0.5)+0.35\,\mathcal{N}(4,0.7)+0.20\,\mathcal{N}(-2,0.4)$ とすると、定理 11.20の分位関数による閉形式から $W_2^2 = 0.5711$ である（分位関数を 2×10^4 点と 8×10^4 点で数値積分して一致）。一方、成分間コスト C_{kl} を使って 2×3 の線形計画を解くと $\mathrm{MW}_2^2 = 1.5742$ で、2.76 倍になる。混合ガウス分布という形を保つカップリングに制限した代償である。二次元の分岐の例（時点 t が 2 成分、$t+1$ が 3 成分）では、成分レベルの輸送計画から移行率 W_{kl}/π_k が $(0.667,\,0,\,0.333)$、$(0.125,\,0.875,\,0)$ と読め、一方の細胞種だけが二つに分岐したことが行列として現れる。このとき解くべき行列は 2×3 の 6 成分で、同じ標本を細胞レベルで扱えば $2000\times2000 = 4.0\times10^6$ 成分である。

実際にヒトの始原生殖細胞様細胞（PGCLC）の誘導系に適用して、前駆細胞集団と分岐の時刻を同定した報告がある [86]。

この講義の道具がどこで使われたか

RECODE は第5章（高次元統計・固有値の縮小）、scEGOT は11.5節（最適輸送・Sinkhorn）と混合ガウス分布、そして両者の前処理に第3章の PCA が使われている。scEGOT の実装は前処理に RECODE を呼ぶので、二つは実際に連結して使われる。異なるモダリティ（scRNA-seq と scATAC-seq）を統合したい場面では座標系を共有しないので、11.5.5節の Gromov–Wasserstein が候補になる。

表11.1　本講義で扱った手法を三つの軸で整理したもの。横に読めば一つの手法が三つの選択の組合せであること、縦に読めば同じ選択が異なる章で繰り返し現れることが見える。

手法（章）	内積・距離	制約・正則化	関数クラス
PCA（第3章）	標準内積	直交・単位ノルム	線形射影
LDA・CCA（第6章）	$\boldsymbol{B}^{-1}$ 重み	一般化直交	線形
カーネル PCA（第8章）	カーネル k	直交	RKHS
SVM（第9章）	カーネル k	マージン最大化	RKHS
NTK・二重降下（11.1–11.2節）	Θ（固定）	最小ノルム（暗黙）	RKHS
多様体学習（11.3節）	測地・拡散距離	一般化直交	非線形埋め込み
行列補完（11.4節）	Frobenius	核ノルム	低ランク
最適輸送（11.5節）	輸送コスト c	周辺制約・エントロピー	Lipschitz 関数

「線形代数から始めて、高次元の統計、カーネル、最適輸送まで」という本講義の道筋が、一つの研究分野の中でそのまま使われている——これが本節を置いた理由である。

11.7　講義のまとめと読書案内

11.7.1　三つの軸で全体を見る

第1章で二つの統一的枠組み（表 1.1）と非線形化の三戦略（表 1.2）を提示した。全 11 章を終えた今、三つの軸で全体を整理できる：**内積を変える**（標準内積、$\boldsymbol{B}^{-1}$ 重み、カーネル k、測地距離、輸送コスト）、**制約・正則化を変える**（直交制約、ℓ_2、ℓ_1、核ノルム、最小ノルム）、**関数クラスを変える**（線形、RKHS、ニューラルネットワーク、Lipschitz 関数）である。

表 11.1が示すのは、新しい手法はたいてい既存の手法の三つの選択のうち一つを差し替えたものだということである。「何を内積とし、何を制約とし、どんな関数を許しているのか」という三つの問いを立てられれば、講義で扱わなかった手法にも同じやり方で入っていける。そしてその答えを計算する道具は、ほとんどの場合**固有値問題を解くか、凸最適化を解くか**のどちらかである。

11.7.2　さらに学ぶための読書案内

数値線形代数は Trefethen–Bau [77]（薄いのに本質を突く名著で SVD と条件数の扱いが良い）から入り、参照書に Golub–Van Loan [33]、摂動論に Horn–Johnson [40]。**高次元統計**は Vershynin [80]（集中不等式から入る現代的入門で 第5章の証明の多くがある）と、より統計寄りの Wainwright [82]；ランダム行列そのものは Bai–Silverstein [9]。**カーネル法**は Schölkopf–Smola [71]（アルゴリズムと理論のバランスが良い標準的教科書）、厳密さを求めるなら一貫性や収束率まで扱う Steinwart–Christmann [73] が決定版、ガウス過程との関係は Rasmussen–Williams [63]。日本語では赤穂 [1] が最も読みやすく、福水 [32] が正定値カーネルの数学的基礎を丁寧に押さえている。**機械学習全般**は統計的視点の Hastie–Tibshirani–Friedman [38]、ベイズ的視点の Bishop [15]、最も新しく網羅的な Murphy [55, 56]；学習理論は Vapnik [79] と金森 [46]。**凸最適化**は Boyd–Vandenberghe [17] 一冊で足り、双対性の章は第9章を深めるのに役立つ。**最適輸送**は計算に軸足を置いた Peyré–Cuturi [61] が最短経路で、理論は Villani [81]（重厚）か Santambrogio [68]（読みやすい）。

最後に一つ助言を。新しい手法に出会ったら、まず 2×2 **の例で手を動かす**こと。小さい行列で固有値を手計算し、数式どおりに実装した結果とライブラリの出力を突き合わせる。この習慣が、論文の主張を鵜呑みにせず自分で確かめる力を作る。

演習問題

演習 11.1 ((★★) NTK の基本性質)**.** 式 (11.6)の NTK Θ について次を示せ。(a) $\Theta(\boldsymbol{x},\boldsymbol{x})=\|\boldsymbol{x}\|^2$。(b) 正斉次性 $\Theta(c\boldsymbol{x},c\boldsymbol{x}')=c^2\Theta(\boldsymbol{x},\boldsymbol{x}')$（$c>0$）。(c) 単位ベクトルが直交するとき $\Theta=1/(2\pi)$、$\boldsymbol{x}'=-\boldsymbol{x}$ のとき $\Theta=0$。(d) Θ が正定値カーネル（第7章の意味）であることを式 (11.5)の有限幅表示から説明せよ。

演習 11.2 ((★★★) 二重降下と Marchenko–Pastur)**.** $\gamma\in(0,1)$ の MP 密度 $\mathrm{dMP}_\gamma(x)=\frac{\sqrt{(\lambda_+-x)(x-\lambda_-)}}{2\pi\gamma x}\mathbf{1}\{\lambda_-\le x\le\lambda_+\}\,\mathrm{d}x$（$\lambda_\pm=(1\pm\sqrt{\gamma})^2$）について次を示せ。(a) $\int x\,\mathrm{dMP}_\gamma=1$。(b) $\int x^{-1}\,\mathrm{dMP}_\gamma=1/(1-\gamma)$（式 (11.10)）。(c) (b) から $\gamma\to1^-$ での発散を説明し、定理 11.4の有限 n,p の式 $\sigma^2p/(n-p-1)$ と漸近的に整合することを確かめよ。(d) $\gamma>1$ では $\widehat{\boldsymbol{\Sigma}}=\boldsymbol{X}\boldsymbol{X}^\top/n$

$(p\times p)$ は特異だが Gram 行列 $\boldsymbol{X}^\top\boldsymbol{X}/p$（$n\times n$）は正則である。対応する積分を書き、$\sigma^2 n/(p-n-1)$ との整合を示せ。**ヒント**：Stieltjes 変換 $s(z)=\int (x-z)^{-1}\,\mathrm{dMP}_\gamma(x)$ が $\gamma z s^2+(z+\gamma-1)s+1=0$ を満たすことを使うと (b) は $s(0)$ から求まる。

演習 11.3 ((★★) ラプラシアン固有写像とパスグラフ)**.** (a) 式 (11.12)の目的関数が $\frac{1}{2}\sum_{ij} w_{ij}\|\boldsymbol{y}_i-\boldsymbol{y}_j\|^2=\mathrm{tr}(\boldsymbol{Y}\boldsymbol{L}\boldsymbol{Y}^\top)$ に等しいことを示せ（$\boldsymbol{Y}\in\mathbb{R}^{k\times n}$、第 i 列が $\boldsymbol{y}_i$）。(b) 制約 $\boldsymbol{Y}\boldsymbol{D}\boldsymbol{Y}^\top=\boldsymbol{I}_k$ のもとでの最小化が一般化固有値問題 $\boldsymbol{L}\boldsymbol{v}=\lambda\boldsymbol{D}\boldsymbol{v}$ の小さい方から k 個の解で与えられることを、第6章の議論に沿って示せ。(c) $\boldsymbol{L}\mathbf{1}=\mathbf{0}$ を示し、制約 $\boldsymbol{Y}\boldsymbol{D}\mathbf{1}=\mathbf{0}$ が必要な理由を述べよ。(d) n 点のパスグラフ（重み 1、$\boldsymbol{D}=\boldsymbol{I}$）で $v_k(i)=\cos(\pi k(i+\frac{1}{2})/n)$ が固有値 $\lambda_k=4\sin^2(\pi k/(2n))$ の固有ベクトルであることを直接代入で確かめ、$n=5$、$k=1$ の数値を書き下せ。

演習 11.4 ((★★) 核ノルムと 2×2 補完)**.** (a) $\|\boldsymbol{X}\|_{\mathrm{op}}\le 1$ ならば $\|\boldsymbol{X}\|_*\le\mathrm{rank}(\boldsymbol{X})$ を示し、さらに $\|\boldsymbol{X}\|_*\le\sqrt{\mathrm{rank}(\boldsymbol{X})}\|\boldsymbol{X}\|_{\mathrm{F}}$ も示せ。(b) 2×2 行列で $\|\boldsymbol{M}\|_*^2=\|\boldsymbol{M}\|_{\mathrm{F}}^2+2|\det\boldsymbol{M}|$ を示し、これを用いて $\boldsymbol{M}(x)=\left(\begin{smallmatrix}1&2\\3&x\end{smallmatrix}\right)$ の核ノルムを x の関数として求めよ。(c) (b) から $\|\boldsymbol{M}(x)\|_*$ を最小化する x を求めよ。ランク 1 になる x と一致するか。この例が定理 11.11の仮定をどう破っているかを述べよ。

演習 11.5 ((★★) 実装：二重降下曲線の再現)**.** ランダム特徴回帰で図 11.1を再現せよ。(a) $n=100$、$d=20$、$\boldsymbol{x}_i\sim\mathcal{N}(\mathbf{0},\boldsymbol{I}_d)$、$y_i=\boldsymbol{x}_i^\top\boldsymbol{w}^\star+\varepsilon_i$（$\|\boldsymbol{w}^\star\|=1$、$\varepsilon_i\sim\mathcal{N}(0,0.1^2)$）で訓練・テストデータ（$n_{\mathrm{test}}=2000$）を生成する。(b) 特徴数 m を 5 から 1000 まで変えて $\boldsymbol{\phi}_m(\boldsymbol{x})=\mathrm{ReLU}(\boldsymbol{W}\boldsymbol{x})/\sqrt{m}$（$\boldsymbol{W}\in\mathbb{R}^{m\times d}$ は標準正規で固定）を作り、特徴行列を $\boldsymbol{\Phi}=[\boldsymbol{\phi}_m(\boldsymbol{x}_1),\dots,\boldsymbol{\phi}_m(\boldsymbol{x}_n)]\in\mathbb{R}^{m\times n}$（列がサンプル）として最小ノルム解を `numpy.linalg.pinv` で求めよ。(c) テスト二乗誤差を m/n の関数としてプロットし、$m/n=1$ での発散とその先の再降下を確認せよ（20 回平均）。(d) 同じ $\boldsymbol{\Phi}$ にリッジ回帰（λ をグリッド探索）を行い、その曲線が (c) を全域で下回ることを確認せよ。

演習 11.6 ((★★★) 実装：Sinkhorn と一次元閉形式)**.** (a) $W_1(\mu,\nu)=\int_{\mathbb{R}}|F_\mu(t)-F_\nu(t)|\,\mathrm{d}t$ を示せ（**ヒント**：定理 11.20と同様に単調カップリングが最適であることを使い、$\int_0^1|F_\mu^{-1}(u)-F_\nu^{-1}(u)|\,\mathrm{d}u$ を u-t 平面の面積として読み替える）。(b) リスト 11.2を自分で実装し、$n=m=50$ の一次元例で線形計画の解、Sinkhorn の解、(a) の閉形式（$p=1$）、式 (11.22)（$p=2$）の四つを比較せよ。(c) ε を 10^{-1} から 10^{-4} まで変え、Sinkhorn 値と線形計画値の差をプロットせよ。どこから数値的に破綻するか、原因は何か。(d) 対数領域での実装（`logsumexp` を使う）で (c) の破綻が解消することを確認せよ。

参考文献

[1] 赤穂昭太郎, **カーネル多変量解析——非線形データ解析の新しい展開**, 岩波書店, 2008.

[2] S. Amari, "A theory of adaptive pattern classifiers," *IEEE Transactions on Electronic Computers*, vol. EC-16, no. 3, pp. 299–307, 1967.

[3] 甘利俊一, 『情報理論 II —情報の幾何学的理論—』(北川敏男編, 情報科学講座 A·2·5) , 共立出版, 1968, ISBN 978-4-320-02012-2.

[4] S. Amari, "Backpropagation and stochastic gradient descent method," *Neurocomputing*, vol. 5, no. 4–5, pp. 185–196, 1993.

[5] S. Amari, "Natural gradient works efficiently in learning," *Neural Computation*, vol. 10, no. 2, pp. 251–276, 1998.

[6] 青嶋誠, 矢田和善, **高次元の統計学**, 統計学 One Point 11, 共立出版, 2019.

[7] M. Arjovsky, S. Chintala, and L. Bottou, "Wasserstein generative adversarial networks," in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, PMLR 70, pp. 214–223, 2017.

[8] N. Aronszajn, "Theory of reproducing kernels," *Transactions of the American Mathematical Society*, vol. 68, no. 3, pp. 337–404, 1950.

[9] Z. Bai and J. W. Silverstein, *Spectral Analysis of Large Dimensional Random Matrices*, 2nd ed., Springer, 2010.

[10] J. Baik, G. Ben Arous, and S. Péché, "Phase transition of the largest eigenvalue for nonnull complex sample covariance matrices," *The Annals of Probability*, vol. 33, no. 5, pp. 1643–1697, 2005.

[11] J. Baik and J. W. Silverstein, "Eigenvalues of large sample covariance matrices of spiked population models," *Journal of Multivariate Analysis*, vol. 97, no. 6, pp. 1382–1408, 2006.

[12] A. R. Barron, "Universal approximation bounds for superpositions of a sigmoidal function," *IEEE Transactions on Information Theory*, vol. 39, no. 3, pp. 930–945, 1993.

[13] M. Belkin and P. Niyogi, "Laplacian eigenmaps for dimensionality reduction and data representation," *Neural Computation*, vol. 15, no. 6, pp. 1373–1396, 2003.

[14] M. Belkin, D. Hsu, S. Ma, and S. Mandal, "Reconciling modern machine-learning practice and the classical bias–variance trade-off," *Proceedings of the National Academy of Sciences*, vol. 116, no. 32, pp. 15849–15854, 2019.

[15] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.

[16] B. E. Boser, I. M. Guyon, and V. N. Vapnik, "A training algorithm for optimal margin classifiers," in *Proceedings of the Fifth Annual Workshop on Computational Learning Theory (COLT)*, ACM, pp. 144–152, 1992.

[17] S. Boyd and L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004.

[18] J.-F. Cai, E. J. Candès, and Z. Shen, "A singular value thresholding algorithm for matrix completion," *SIAM Journal on Optimization*, vol. 20, no. 4, pp. 1956–1982, 2010.

[19] E. J. Candès and B. Recht, "Exact matrix completion via convex optimization," *Foundations of Computational Mathematics*, vol. 9, no. 6, pp. 717–772, 2009.

[20] E. J. Candès and T. Tao, "The power of convex relaxation: near-optimal matrix completion," *IEEE Transactions on Information Theory*, vol. 56, no. 5, pp. 2053–2080, 2010.

[21] E. J. Candès, X. Li, Y. Ma, and J. Wright, "Robust principal component analysis?," *Journal of the ACM*, vol. 58, no. 3, article 11, 2011.

[22] L. Chizat, E. Oyallon, and F. Bach, "On lazy training in differentiable programming," in *Advances in Neural Information Processing Systems 32 (NeurIPS)*, pp. 2937–2947, 2019.

[23] Y. Cho and L. K. Saul, "Kernel methods for deep learning," in *Advances in Neural Information Processing Systems 22 (NIPS)*, pp. 342–350, 2009.

[24] R. R. Coifman and S. Lafon, "Diffusion maps," *Applied and Computational Harmonic Analysis*, vol. 21, no. 1, pp. 5–30, 2006.

[25] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.

[26] M. Cuturi, "Sinkhorn distances: lightspeed computation of optimal transport," in *Advances in Neural Information Processing Systems 26 (NIPS)*, pp. 2292–2300, 2013.

[27] G. Cybenko, "Approximation by superpositions of a sigmoidal function," *Mathematics of Control, Signals and Systems*, vol. 2, no. 4, pp. 303–314, 1989.

[28] C. Davis and W. M. Kahan, “The rotation of eigenvectors by a perturbation. III,” *SIAM Journal on Numerical Analysis*, vol. 7, no. 1, pp. 1–46, 1970.

[29] J. Delon and A. Desolneux, “A Wasserstein-type distance in the space of Gaussian mixture models,” *SIAM Journal on Imaging Sciences*, vol. 13, no. 2, pp. 936–970, 2020.

[30] M. Fazel, *Matrix Rank Minimization with Applications*, Ph.D. thesis, Stanford University, 2002.

[31] J. Franklin and J. Lorenz, “On the scaling of multidimensional matrices,” *Linear Algebra and its Applications*, vol. 114–115, pp. 717–735, 1989.

[32] 福水健次, **カーネル法入門——正定値カーネルによるデータ解析**, 朝倉書店, 2010.

[33] G. H. Golub and C. F. Van Loan, *Matrix Computations*, 4th ed., Johns Hopkins University Press, 2013.

[34] A. Gretton, O. Bousquet, A. Smola, and B. Schölkopf, “Measuring statistical dependence with Hilbert–Schmidt norms,” in *Algorithmic Learning Theory (ALT 2005)*, Lecture Notes in Computer Science, vol. 3734, Springer, 2005, pp. 63–77.

[35] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Schölkopf, and A. Smola, “A kernel two-sample test,” *Journal of Machine Learning Research*, vol. 13, pp. 723–773, 2012.

[36] N. Halko, P.-G. Martinsson, and J. A. Tropp, “Finding structure with randomness: probabilistic algorithms for constructing approximate matrix decompositions,” *SIAM Review*, vol. 53, no. 2, pp. 217–288, 2011.

[37] J. Ham, D. D. Lee, S. Mika, and B. Schölkopf, “A kernel view of the dimensionality reduction of manifolds,” in *Proceedings of the 21st International Conference on Machine Learning (ICML)*, ACM, pp. 369–376, 2004.

[38] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed., Springer, 2009.

[39] T. Hastie, A. Montanari, S. Rosset, and R. J. Tibshirani, “Surprises in high-dimensional ridgeless least squares interpolation,” *The Annals of Statistics*, vol. 50, no. 2, pp. 949–986, 2022.

[40] R. A. Horn and C. R. Johnson, *Matrix Analysis*, 2nd ed., Cambridge University Press, 2013.

[41] K. Hornik, “Approximation capabilities of multilayer feedforward networks,” *Neural Networks*, vol. 4, no. 2, pp. 251–257, 1991.

[42] H. Hotelling, “Analysis of a complex of statistical variables into principal components,” *Journal of Educational Psychology*, vol. 24, no. 6, pp. 417–441, 1933 (続報 no. 7, pp. 498–520).

[43] Y. Imoto, T. Nakamura, E. G. Escolar, M. Yoshiwaki, Y. Kojima, Y. Yabuta, Y. Katou, T. Yamamoto, Y. Hiraoka, and M. Saitou, “Resolution of the curse of dimensionality in single-cell RNA sequencing data analysis,” *Life Science Alliance*, vol. 5, no. 12, e202201591, 2022.

[44] A. Jacot, F. Gabriel, and C. Hongler, “Neural tangent kernel: convergence and generalization in neural networks,” in *Advances in Neural Information Processing Systems 31 (NeurIPS)*, pp. 8571–8580, 2018.

[45] W. B. Johnson and J. Lindenstrauss, “Extensions of Lipschitz mappings into a Hilbert space,” in *Conference in Modern Analysis and Probability*, Contemporary Mathematics, vol. 26, American Mathematical Society, pp. 189–206, 1984.

[46] 金森敬文, **統計的学習理論**（機械学習プロフェッショナルシリーズ）, 講談社, 2015.

[47] O. Ledoit and M. Wolf, “A well-conditioned estimator for large-dimensional covariance matrices,” *Journal of Multivariate Analysis*, vol. 88, no. 2, pp. 365–411, 2004.

[48] J. Lee, Y. Bahri, R. Novak, S. S. Schoenholz, J. Pennington, and J. Sohl-Dickstein, “Deep neural networks as Gaussian processes,” in *International Conference on Learning Representations (ICLR)*, 2018.

[49] V. A. Marčenko and L. A. Pastur, “Distribution of eigenvalues for some sets of random matrices,” *Mathematics of the USSR-Sbornik*, vol. 1, no. 4, pp. 457–483, 1967.

[50] R. Mazumder, T. Hastie, and R. Tibshirani, “Spectral regularization algorithms for learning large incomplete matrices,” *Journal of Machine Learning Research*, vol. 11, pp. 2287–2322, 2010.

[51] L. McInnes, J. Healy, and J. Melville, “UMAP: uniform manifold approximation and projection for dimension reduction,” arXiv:1802.03426, 2018.

[52] S. Mei and A. Montanari, “The generalization error of random features regression: precise asymptotics and the double descent curve,” *Communications on Pure and Applied Mathematics*, vol. 75, no. 4, pp. 667–766, 2022.

[53] F. Mémoli, “Gromov–Wasserstein distances and the metric approach to object matching,” *Foundations of Computational Mathematics*, vol. 11, no. 4, pp. 417–487, 2011.

[54] J. Mercer, “Functions of positive and negative type, and their connection with the theory of integral equations,” *Philosophical Transactions of the Royal Society A*, vol. 209, pp. 415–446, 1909.

[55] K. P. Murphy, *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.

[56] K. P. Murphy, *Probabilistic Machine Learning: Advanced Topics*, MIT Press, 2023.

[57] R. M. Neal, *Bayesian Learning for Neural Networks*, Lecture Notes in Statistics 118, Springer, 1996.

[58] D. Paul, “Asymptotics of sample eigenstructure for a large dimensional spiked covariance model,” *Statistica Sinica*, vol. 17, no. 4, pp. 1617–1642, 2007.

[59] K. Pearson, “LIII. On lines and planes of closest fit to systems of points in space,” *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, ser. 6, vol. 2, no. 11, pp. 559–572, 1901.

[60] G. Peyré, M. Cuturi, and J. Solomon, “Gromov–Wasserstein averaging of kernel and distance matrices,” *Proceedings of the 33rd International Conference on Machine Learning* (PMLR vol. 48), pp. 2664–2672, 2016.

[61] G. Peyré and M. Cuturi, “Computational optimal transport,” *Foundations and Trends in Machine Learning*, vol. 11, no. 5–6, pp. 355–607, 2019.

[62] A. Rahimi and B. Recht, “Random features for large-scale kernel machines,” in *Advances in Neural Information Processing Systems 20 (NIPS)*, pp. 1177–1184, 2007.

[63] C. E. Rasmussen and C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006.

[64] J. W. Strutt (Lord Rayleigh), *The Theory of Sound*, Vols. I–II, Macmillan, London, 1877–1878（第 2 版 1894–96、Dover 版 1945）.

[65] B. Recht, M. Fazel, and P. A. Parrilo, “Guaranteed minimum-rank solutions of linear matrix equations via nuclear norm minimization,” *SIAM Review*, vol. 52, no. 3, pp. 471–501, 2010.

[66] S. T. Roweis and L. K. Saul, “Nonlinear dimensionality reduction by locally linear embedding,” *Science*, vol. 290, no. 5500, pp. 2323–2326, 2000.

[67] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, no. 6088, pp. 533–536, 1986.

[68] F. Santambrogio, *Optimal Transport for Applied Mathematicians*, Birkhäuser, 2015.

[69] G. Schiebinger, J. Shu, M. Tabaka, B. Cleary, V. Subramanian, A. Solomon, J. Gould, S. Liu, S. Lin, P. Berube, L. Lee, J. Chen, J. Brumbaugh, P. Rigollet, K. Hochedlinger, R. Jaenisch, A. Regev, and E. S. Lander, “Optimal-transport analysis of single-cell gene expression identifies developmental trajectories in reprogramming,” *Cell*, vol. 176, no. 4, pp. 928–943.e22, 2019.

[70] B. Schölkopf, A. Smola, and K.-R. Müller, “Nonlinear component analysis as a kernel eigenvalue problem,” *Neural Computation*, vol. 10, no. 5, pp. 1299–1319, 1998.

[71] B. Schölkopf and A. J. Smola, *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*, MIT Press, 2002.

[72] R. Sinkhorn and P. Knopp, “Concerning nonnegative matrices and doubly stochastic matrices,” *Pacific Journal of Mathematics*, vol. 21, no. 2, pp. 343–348, 1967.

[73] I. Steinwart and A. Christmann, *Support Vector Machines*, Springer, 2008.

[74] M. Telgarsky, “Benefits of depth in neural networks,” *Proceedings of the 29th Annual Conference on Learning Theory (COLT)*, PMLR vol. 49, pp. 1517–1539, 2016.

[75] J. B. Tenenbaum, V. de Silva, and J. C. Langford, “A global geometric framework for nonlinear dimensionality reduction,” *Science*, vol. 290, no. 5500, pp. 2319–2323, 2000.

[76] M. E. Tipping and C. M. Bishop, “Probabilistic principal component analysis,” *Journal of the Royal Statistical Society: Series B*, vol. 61, no. 3, pp. 611–622, 1999.

[77] L. N. Trefethen and D. Bau III, *Numerical Linear Algebra*, SIAM, 1997.

[78] L. van der Maaten and G. Hinton, “Visualizing data using t-SNE,” *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.

[79] V. N. Vapnik, *Statistical Learning Theory*, Wiley, 1998.

[80] R. Vershynin, *High-Dimensional Probability: An Introduction with Applications in Data Science*, Cambridge University Press, 2018.

[81] C. Villani, *Optimal Transport: Old and New*, Grundlehren der mathematischen Wissenschaften 338, Springer, 2009.

[82] M. J. Wainwright, *High-Dimensional Statistics: A Non-Asymptotic Viewpoint*, Cambridge University Press, 2019.

[83] A. G. Wilson, Z. Hu, R. Salakhutdinov, and E. P. Xing, “Deep kernel learning,” in *Proceedings of the 19th International Conference on Artificial Intelligence and Statistics (AISTATS)*, PMLR vol. 51, pp. 370–378, 2016.

[84] C. K. I. Williams and M. Seeger, “Using the Nyström method to speed up kernel machines,” in *Advances in Neural Information Processing Systems 13 (NIPS)*, pp. 682–688, 2000.

[85] Y. Yu, T. Wang, and R. J. Samworth, “A useful variant of the Davis–Kahan theorem for statisticians,” *Biometrika*, vol. 102, no. 2, pp. 315–323, 2015.

[86] T. Yachimura, H. Wang, Y. Imoto, M. Yoshida, S. Tasaki, Y. Kojima, Y. Yabuta, M. Saitou, and Y. Hiraoka, “scEGOT: single-cell trajectory inference framework based on entropic Gaussian mixture optimal transport,” *BMC Bioinformatics*, vol. 25, no. 1, 388, 2024.

[87] H. Zou, T. Hastie, and R. Tibshirani, “Sparse principal component analysis,” *Journal of Computational and Graphical Statistics*, vol. 15, no. 2, pp. 265–286, 2006.